ブラックホール攻撃: Occupancy Prediction を用いた自動運転に対するハイジャック攻撃の提案とその対策

鶴岡 豪[1,5,a)]　佐藤 貴海[2]　飯島涼[5]　森 達哉[1,3,4]

概要：3D Occupancy Prediction は，カメラ入力のみで周囲環境をボクセル単位の占有状態として表現する手法であり，カメラベースの自動運転にとって重要な仕組みである．物体検出と異なり走行可能領域そのものを表現し，その出力が直接プランナに入力されるため，わずかな誤認識が軌道の誤りに直結する．カメラベース自動運転に対する敵対的攻撃は数多く研究されてきたが，いずれも物体や車線の誤認識を対象としており，存在しない走行可能領域を作り出すという occupancy 特有の攻撃面は，我々の知る限り未検証である．本稿では，occupancy ベース自動運転に対する初の敵対的評価として Black Hole (BH) Attack を提案する．BH Attack は路側の単一パッチで存在しない道路を誤生成し，プランナにその方向の軌道を繰り返し選択させることで，攻撃者が指定した地点まで車両を誘導する．実現にあたり，(1) 二段階最適化，(2) 連続した偽道路を生成しつつ偽の障害物予測を抑制するロス，(3) 攻撃自身が誘起する視点変化を考慮した EoT を設計した．nuScenes・Waymo を用いた Open-Loop 評価では 3 つの occupancy モデルに対し最大 95% の攻撃成功率を，CARLA の Closed-Loop 評価では最大 96% のシーンで攻撃が成功し，車両をパッチへ衝突させた．また，物理世界実験でも BH Attack の成立を確認した．防御として PathGuard を提案し，脱輪の平均 1.8 秒前に 100% の精度で検知できることを確認した．

キーワード：自動運転，Occupancy Prediction, 敵対的攻撃

Black Hole Attack: Hijacking Occupancy-based Autonomous Driving

Go Tsuruoka[1,5,a)]　Takami Sato[2]　Ryo Iijima[5]　Tatsuya Mori[1,3,4]

Abstract: 3D occupancy prediction has been adopted in camera-based autonomous driving systems that feed its predictions directly into the planner, where the predicted road region determines where the vehicle can drive. We present the Black Hole Attack (BH Attack), which manipulates occupancy predictions to guide a victim vehicle toward an attacker-chosen location. The attack places a roadside adversarial patch that causes the model to predict a nonexistent road, making the planner repeatedly select trajectories toward the patch. To realize this attack, we introduce a two-stage optimization that bypasses the non-differentiable planner, a planner-aware loss that generates a connected road while suppressing false obstacle predictions, and an EoT that accounts for the viewpoints induced by the attack itself. In open-loop evaluation on nuScenes and Waymo, BH Attack achieves an ASR of 65%–95% against three occupancy prediction models. In closed-loop evaluation on CARLA, it drives the vehicle into the patch in at most 96% of the scenes, compared with 20% when the patch is optimized over fixed viewpoints. We further confirm the attack in the physical world. Finally, we propose PathGuard, a planner-aware defense that verifies only the occupancy around the selected trajectory, and show that it detects BH Attack with 100% accuracy without degrading benign performance.

Keywords: Autonomous Driving, Occupancy Prediction, Adversarial Example

[1] 早稲田大学/Waseda University
[2] 慶應義塾大学/Keio University
[3] 情報通信研究機構/NICT
[4] 理研 AIP/RIKEN
[5] 産業技術総合研究所/AIST
[a)] go@nsl.cs.waseda.ac.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

1. はじめに

自動運転システムは，走行すべき経路を決定するために，周囲の 3 次元環境がどのような構造をしているかを認識する必要がある．3D Occupancy Prediction（以下，Occupancy Prediction）は，この認識を担うシーン表現技術である．Occupancy Prediction は，自車周囲の 3 次元空間を一定サイズのボクセルに分割し，各ボクセルについて物体に占有されているか否か，およびそのクラス（道路，車両，歩行者など）を予測する．

Occupancy Prediction は，従来のシーン表現では実現が難しかった二つの性質を備える．第一に，任意形状の表現が可能な点である．従来広く用いられてきた 3D 物体検出は，物体を直方体として表現するため，路面の起伏や，工事車両・落下物といった非定型な物体を正確に表現できない．これに対し Occupancy Prediction は，空間をボクセル単位で記述するため，走行面や任意形状の物体をそのまま表現できる（図 1）．

第二に，カメラのみで密な 3 次元情報を得られる点である．同等に密な 3 次元情報は LiDAR からも取得できるが，LiDAR は導入および維持にコストを要する．Occupancy Prediction はカメラ画像のみから密な 3 次元表現を構成できるため，安価なセンサ構成で同等の情報を利用できる．これらの利点から，Occupancy Prediction はカメラベース自動運転における有望なシーン表現として注目されており，Tesla は既に自社の自動運転システムに Occupancy Prediction を採用している [1]．

上述の背景をもとに，Occupancy Prediction の出力をプランナへ直接入力し，予測された走行可能領域の上で障害物を回避する軌道を選択することで自動運転を実現する手法も提案されている [2]．このようなシステムにおいて，予測された道路領域は，プランナが走行可能な領域を判断するための根拠そのものとなる．したがって Occupancy Prediction の誤りは，認識結果の誤りに留まらず，プランナが生成する軌道，さらには実際の車両挙動にまで伝播しうる．例えば，本来は走行不可能な領域が道路として予測された場合，プランナは存在しない道路へ向かう軌道を選択し，危険な車両挙動を引き起こす可能性がある．

攻撃者がこのような誤りを意図的に引き起こす手段としては，AI モデルに対する敵対的サンプルが挙げられる．敵対的サンプルは，モデルの入力に摂動を加えることで出力を操作する攻撃であり，画像を入力とする物体識別や物体検出に対しては，デジタル空間上の摂動から物理世界に設置可能な敵対的パッチに至るまで，数多くの攻撃が提案され，その脅威が評価されてきた．一方で，Occupancy Prediction を対象とした敵対的攻撃に関する研究はほとんど行われていない．とりわけ，物理世界で実現可能な攻撃によって Occupancy Prediction を操作できるか，また



図 1 物体検知と Occupancy の比較

その操作が後段のプランニング判断や最終的な車両挙動にまで影響するかを，システムレベルで評価した研究は，我々の知る限り存在しない．上述の状況を鑑み，我々は Black Hole Attack（BH Attack）を提案する．BH Attack は，道路脇に設置した敵対的パッチによって，Occupancy Prediction に存在しない道路を予測させ，被害車両を攻撃者が指定したパッチ位置へ誘導する攻撃である．自動運転システムに対する従来の攻撃の多くが，車線逸脱や自己位置推定誤差といった走行の逸脱を引き起こすことを目的としていたのに対し，BH Attack は被害車両の到達地点を攻撃者が指定できる点で，車両挙動をより直接的に制御する攻撃である．

物理世界で有効な BH Attack を実現するには，三つの課題がある．第一に，プランナは候補軌道を離散的に選択するため，微分不可能な処理である．そのため，Planner の出力をパッチ最適化へ勾配として伝播できない．第二に，攻撃が成功すると車両軌道自体が変わり，パッチの観測視点も変化するため，固定視点で最適化したパッチは効果を失う．第三に，密な occupancy 上で一部のボクセルを road へ変えるだけでは，プランナが追従できる連続した走行可能領域にならない．これらの課題に対し，我々は三つの新たな手法からなる攻撃パイプラインを導入する．まず，未攻撃の road 領域を重点的に最適化しつつ障害物予測を抑制する Occupancy-aware loss を設計する．次に，ブラックボックス最適化 により車両を誘導可能な道路形状を探索し，勾配を用いた最適化によりその形状を生成するパッチを最適化する二段階手法を導入する．さらに， 車両モデルを用いて攻撃下の車両運動を予測し，攻撃環境下の自動車がいる位置を推定し，それを用いてパッチを最適化する．§3.1 では，評価対象となる Occupancy を用いた自動運転システムと脅威モデルについて定め，§4 では，BH Attack を実現するための攻撃パイプラインについて述べる．そして，§5 および，§6 では，データセットを用いた Open-Loop 評価およびシミュレータを用いた Closed-Loop 評価による攻撃の有効性評価を行う．また，§7 では，物理世界に BH Attack を適用し，実際に Occupancy を用いた自動運転に影響を与えるかを評価した．最後に §8 で BH Attack に対する防御を提案・評価する．本論文の貢献は以下である．

- Occupancy Prediction に対するシステムレベルの攻撃として最初の研究を行い，攻撃者が指定した地点へ被害車両を誘導する BH Attack を提案した．
- BH Attack を実現するために独自の攻撃パイプラインを設計し，微分不可能なプランナを迂回する二段階最

© 2026 Information Processing Society of Japan

適化と planner-aware occupancy 損失を設計した．

- 攻撃自身が観測視点を変えるという closed-loop 特有の問題を定式化し，攻撃誘起視点を考慮した EoT を導入した．固定視点で最適化する場合の攻撃成功率が最大 20% にとどまるのに対し，最大 96% を達成した．
- 実車を用いた物理世界評価により，実機の occupancy ベース自動運転システムに対しても BH Attack が有効であることを示した．
- BH Attack が既存のパッチ攻撃に対する防御手法では対処できないことを議論し，軽量かつ効果的な防御手法を設計，有効性を評価した．

2. 背景と関連研究

2.1 Occupancy Prediction

Occupancy Prediction は，車両周囲の 3 次元空間を密なボクセルグリッドとして表現し，各ボクセルに対して占有状態と，道路・車両・歩行者といった意味クラスを割り当てる手法である [3, 4]．物体をバウンディングボックスで近似する 3 次元物体検出とは異なり，Occupancy Prediction は物体形状や走行可能領域をボクセル単位で表現できる．また，LiDAR などのセンサが不要で，カメラのみで実現できるためコストに優れている．このような背景から，Occupancy Prediction はカメラベースの自動運転に必要な要素となっている．また，occupancy の結果を用いて経路計画を行う自動運転システムも提案されている．本研究で対象とする Occupancy を用いた自動運転については，§3.1 で述べる．

アーキテクチャ． Occupancy Prediction モデルは，主に深度ベースとトランスフォーマーベースに分類できる．深度ベース [3] は，画像から推定した深度情報を用いて 2 次元画像特徴を 3 次元空間へ投影する．一方，トランスフォーマーベース [5] は，3 次元クエリと attention を用いて多視点の画像特徴を集約する．また，両方式を組み合わせた hybrid 型のモデルである FB-Occ [6] も提案されている．本研究では，BH Attack を網羅的に評価するため，深度ベースの OpenOccupancy [3]，トランスフォーマーベースの SurroundOcc [5]，および hybrid 型の FB-Occ [6] を評価対象とする．

2.2 関連研究とその比較

DNN を用いた自動運転システムに対しては，物理的な敵対的パッチによって認識や自己位置推定を操作し，下流の車両挙動へ影響を及ぼす攻撃が報告されている [7, 8]．本研究は Occupancy Prediction に対する物理攻撃をシステムレベルで評価した初の研究である．

本研究に近い既存研究として，DRP [7] と AoR [8] がある．DRP は，路面上の敵対的パッチによって車線検出を操作し，車線中央維持システムに車両を車線外へ逸脱させる．AoR は，vSLAM の自己位置推定を操作し，車両の推定軌道を変化させる．これらが正常な走行経路からの逸脱を引き起こすのに対し，BH Attack は Occupancy Prediction を操作して Planner に攻撃者が指定した地点へ向かう軌道を選択させる，車両の誘導方向まで制御可能な攻撃である．

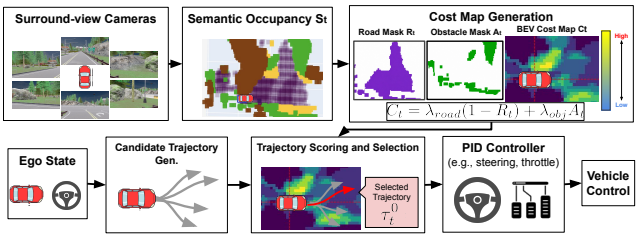


図 2 Occupancy を利用したカメラベースの AD の仕組み．

3. 攻撃対象システムと脅威モデル

3.1 対象となる自動運転

本研究では，Occupancy Prediction の結果を経路計画に用いるカメラベースの AD システムを対象とする．図 2 に示すように，対象システムは Perception, Planning, Control の三段から成る．サラウンドビュー画像から occupancy を推論し，それを BEV コストマップへ変換して候補軌道を評価し，選択した軌道を PID コントローラで追従する．以下，各段を順に述べる．

Occupancy Prediction． モデルはサラウンドビュー画像から occupancy S_t を推論する．プランナはこれを 2D の道路マスク R_t と障害物マスク A_t に変換する．ここで $R_t(x, y)$ は当該 BEV セルが road と予測されているか，$A_t(x, y)$ は障害物の有無を表す．

Occupancy に基づくプランニング． プランナは，道路外および障害物上の領域に高いコストを与える BEV コストマップを構築する：$C_t(x, y) = \lambda_{\text{road}}\big(1-R_t(x, y)\big)+\lambda_{\text{obj}}A_t(x, y)$．現在の自車状態から運動学的に実行可能な候補軌道集合 $\mathcal{T}_t$ を生成し，各軌道上の BEV コストを積算した軌道コスト $J_t(\tau)$ が最小となるものを選択する．

車両制御． 選択された軌道 τ_t^* は PID コントローラへ入力され，ハンドル・アクセル・ブレーキ指令へ変換される．対象コントローラは最初の 2 つの将来ウェイポイントから操舵目標と目標速度を決定する．

3.2 脅威モデル

攻撃目標． 攻撃者の目的は，物理シーン内の攻撃者が選んだ目標地点へ被害車両を誘導することである．単に occupancy の推論精度を低下させることや，軌道逸脱を引き起こすのではなく，本攻撃は occupancy の予測を操作し，プランナが目標地点へ接近する軌道を繰り返し選択するように仕向ける．

攻撃者の知識． 既存のパッチ攻撃に従い，本研究では，Occupancy Prediction モデルと対象プランナについて，そのアーキテクチャとパラメータを含めて把握しているホワイトボックスアクセスの攻撃者を想定する．また，カメラ

© 2026 Information Processing Society of Japan

の内部パラメータ等も事前調査等により把握できているものとする．また攻撃者は，対象シーンを事前に調査しシーンの画像などを取得できているものとする．攻撃者は静的な物理パッチの外観と設置位置を選択でき，被害車両が接近する前に，それを路側に設置できると仮定する．

4. 手法

4.1 設計上の課題

BH Attack により攻撃者が指定した地点へ車両を誘導するため，我々は以下の 3 つの課題に対処する必要がある．

C1：プランナの非微分可能性． BH Attack の目的は Occupancy Prediction の認識精度を単に低下させることではなく，プランナにパッチへ向かう軌道を選択させることである．しかし，プランナは候補軌道を occupancy 上で評価して最小コストの軌道を離散的に選択するため，その出力から敵対的パッチへ勾配を直接伝播できず，BH Attack を直接生成することはできない．

C2：閉ループ下での攻撃効果の維持． 攻撃によって車両軌道が変化すると，後続フレームではパッチの観測角度，距離，およびスケールも変化する．そのため，固定された視点のみで最適化したパッチは，攻撃自身が誘起した視点では効果を失う可能性があり，攻撃によって生じうる車両姿勢と視点変化を考慮してパッチを最適化する必要がある．

C3：密な occupancy に対するプランナレベルの攻撃． プランナを誘導するには，一部のボクセルを road クラスへ変化させるだけでは不十分であり，車両が追従できる連続した走行可能領域を生成する必要がある．標準的な交差エントロピーによる最適化では，一部が未攻撃のままや生成した道路内に誤った障害物が残りうるため，プランナがその領域を回避する場合がある．

4.2 設計概要

図 3 に示す攻撃パイプラインを設計する．まず，正常時の occupancy へ phantom road を直接注入し，プランナをパッチ方向へ誘導可能なシーンを特定する（§4.3）．次に，攻撃成功時と失敗時の車両運動を伝播させ，閉ループ実行中に遭遇しうる車両姿勢を推定する（§4.4）．得られた視点集合に対し，ブラックボックス最適化によってプランナを誘導する道路条件を決定し，その道路を occupancy 上に生成する単一の物理パッチを勾配法で最適化する（§4.5）．さらに，連続した phantom road を生成しつつ誤った障害物予測を抑制する planner-aware loss を導入する．

4.3 攻撃が有効なシーンの特定

計算コストの高いパッチ最適化に先立ち，BH Attack によって車両をパッチ位置へ誘導可能なシーンを特定する．敵対的パッチの効果を，幅 w と方位 ϕ を持つ phantom road $r = (w, \phi)$ としてモデル化し，正常時の occupancy 出力へ直接注入する．$\rho(r)$ を phantom road が覆う occupancy セル，$\tau(r) = (\tau_0, \ldots, \tau_K)$ を注入後の計画軌道，c をパッチ中心とする．軌道の進行方向とパッチ方向との平均角度差を $A(r)$ と定義し，これを最小化する $r^* = \arg\min_{r \in \mathcal{R}} A(r)$ を求める．微分不可能なプランナを含むため TPE を用いて最適化する．探索範囲および，平均角度差 $A(r)$ の詳細は §A.2.1.1 に示す．$\tau(r^*)$ の連続する 2 つ以上の将来ウェイポイントが $\rho(r^*)$ 内に存在する場合，そのシーンを攻撃可能と判定する．これは，対象コントローラが 2 つの将来ウェイポイントを用いて車両制御を決定するためである（§3.1）．

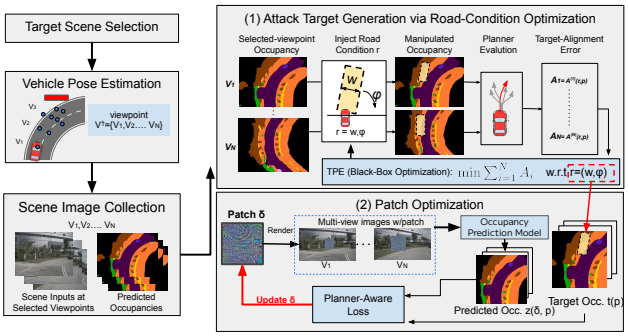


図 3 BH Attack の生成パイプラインの概要．攻撃者はシーンを選択し，攻撃条件下での車両姿勢を推定する．その後，二段階最適化を通じて BH Attack パッチを生成する．

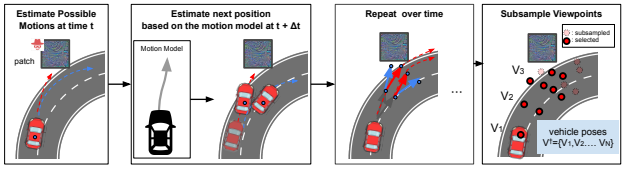


図 4 攻撃下における車両姿勢推定の仕組み．各シーンで攻撃成功時と失敗時の軌道をそれぞれ考慮することを繰り返す．

4.4 攻撃下における車両姿勢推定

閉ループ実行時に攻撃自身が誘起する視点変化をパッチ最適化へ取り込むため，将来遭遇しうる車両姿勢を推定する．各車両状態において攻撃成功時と失敗時の 2 つの運動を考え，それぞれから次状態を再帰的に伝播させることで姿勢集合を構築する．

正常時軌道と攻撃時軌道． 車両状態を $s = (p, v, \kappa)$ とし，運動学的に実行可能な候補軌道集合 $\mathcal{T}(s)$ を生成する．攻撃失敗時には正常時にプランナが選択する軌道を，成功時には $\mathcal{T}(s)$ のうちパッチ中心 c に最も接近する軌道を用いる．後者は攻撃が最大限に有効である場合を表す近似であり，詳細は付録 A.2.1 に示す．

車両運動を考慮した姿勢伝播． 計画軌道上のウェイポイントは将来の運動目標であり，実際には車両の現在の速度などの影響を受ける．そこで，選択された軌道から目標方位と目標速度を求め，車両のヨーレートおよび加減速制約を考慮して車両の位置を特定する．θ を現在方位と先見ホライズン T_h における軌道接線との角度差，v_{des} を同地点の目標速度とすると，状態遷移 $\mathcal{A}(s, \tau) = (p', v', \kappa')$. を次式

© 2026 Information Processing Society of Japan

で定義する：

$$\begin{aligned}\omega &= \mathrm{clip}\left(-\frac{\theta}{T_h}, -\omega_{\max}, \omega_{\max}\right),\\ v' &= v + \mathrm{clip}\left(v_{\mathrm{des}} - v, -a_{\mathrm{dec}}\Delta t, a_{\mathrm{acc}}\Delta t\right),\\ \psi' &= \mathrm{wrap}(\psi + \omega\Delta t), p'_{xy} = p_{xy} + v'\Delta t\,\mathbf{h}(\psi')\end{aligned} \tag{1}$$

ここで $p' = (p'_{xy}, \psi')$，$\mathbf{h}(\psi) = (-\sin\psi, \cos\psi)$ は車両の前方単位ベクトル，Δt は遷移間隔である．$\mathcal{A}$ を正常時軌道と攻撃時軌道の双方に適用し，攻撃失敗時と成功時に対応する次状態を再帰的に生成する．

姿勢の選択．得られた各姿勢に §4.3 の攻撃可能性判定を適用し，プランナをパッチへ誘導可能な姿勢のみを残す．さらにサブサンプリングを行い，後続の道路条件最適化とパッチ最適化に用いる視点集合 $\mathcal{V}^\dagger$ を得る．

4.5 二段階攻撃最適化

C1 に対処するため，プランナレベルの道路条件最適化と認識レベルのパッチ最適化を分離する．第 1 段階では，視点集合 $\mathcal{V}^\dagger$ にわたってプランナをパッチ方向へ誘導する phantom road をブラックボックス最適化により求める．第 2 段階では，得られた道路条件を目標 occupancy として，単一の物理パッチを勾配法で最適化する．

道路条件の最適化．道路条件 $r = (w, \phi)$ を世界座標系で定義し，各視点 $p \in \mathcal{V}^\dagger$ の occupancy 座標系へ変換する．$A(r; p)$ を，視点 p において r を注入した際の角度偏差 (式 (A.6)) とし，全視点にわたる平均偏差 $\frac{1}{|\mathcal{V}^\dagger|}\sum_{p\in\mathcal{V}^\dagger} A(r; p)$ を最小化する単一の道路条件 r^* を求める．この最適化には TPE を用いるため，微分不可能なプランナを介して勾配を伝播する必要がない．

パッチ最適化．第 2 段階では，すべての視点 $p \in \mathcal{V}^\dagger$ において r^* を生成する単一の RGB テクスチャ δ を最適化する．r^* から各視点の目標 occupancy $t(p)$ を構築し，その phantom road 領域を $\Omega(p)$ とする．$z(\delta, p)$ をパッチ δ をレンダリングした画像から得られる occupancy logit とする．単純な交差エントロピーによる最適化では，C3 で述べた未変換セルと誤った障害物予測が残るため，以下の 2 つの要素を導入する．

勾配平衡型の道路生成．攻撃領域 Ω を，まだ road クラスへと攻撃できていない領域 Υ と，攻撃済みの領域 $\bar{\Upsilon} = \Omega \setminus \Upsilon$ に分割する．両者の交差エントロピー勾配を個別に正規化し，未攻撃ボクセルの割合 $\gamma = |\Upsilon|/|\Omega|$ で重み付けする：

$$g_{\mathrm{road}} = \gamma\,\frac{\nabla_\delta \mathcal{L}_\Upsilon}{\|\nabla_\delta \mathcal{L}_\Upsilon\|_2 + \epsilon} + (1-\gamma)\,\frac{\nabla_\delta \mathcal{L}_{\bar{\Upsilon}}}{\|\nabla_\delta \mathcal{L}_{\bar{\Upsilon}}\|_2 + \epsilon}. \tag{2}$$

これにより，未攻撃領域を優先しながら，すでに攻撃された道路領域の生成も維持する．

障害物予測の抑制．phantom road 内での障害物の誤検知を低減するため，障害物クラスへの予測確率のみを低減するロスを導入する．具体的には $\mathcal{C}_{\mathrm{obj}}$ を障害物クラスの集合とし，$\hat{y}_v$ をボクセル v の予測クラス，$\mathcal{O} = \{v \in \Omega : \hat{y}_v \in \mathcal{C}_{\mathrm{obj}}\}$ を障害物と予測したボクセル集合とすると，

$$\mathcal{L}_{\mathrm{sup}} = \frac{1}{|\mathcal{O}|}\sum_{v\in\mathcal{O}}\sum_{c\in\mathcal{C}_{\mathrm{obj}}} \mathrm{softmax}(z_v)_c. \tag{3}$$

と定義する．最終的に，g_{road} と正規化した $\nabla_\delta \mathcal{L}_{\mathrm{sup}}$ を組み合わせてパッチを更新する．損失関数の最終更新式は付録 A.2.2 に示す．

パッチのレンダリングと EoT 単一の物理パッチを各視点・各カメラパラメータを用いてカメラ画像へ投影し，入力画像へ合成する．この処理は微分可能なため，occupancy 出力から共有テクスチャ δ へ勾配を逆伝播することができる．さらに，位置や回転を摂動する EoT を適用する．投影，合成，および EoT の詳細は付録 A.2.3 に示す．

5. デジタル実験 (Open-Loop)

BH Attack の有効性を，ディジタル領域における Open-Loop 評価及び Closed-Loop 評価の両方で評価する．まず，データセットを用いた Open-Loop 評価を行い，多様な走行条件およびモデルにわたる攻撃の有効性を評価する．

5.1 共通の評価設定

まず，Open-Loop 評価に共通する実験設定を述べる．特に断らない限り，すべての Open-Loop 評価は以下に従う．

対象モデル．BH Attack を，代表的な 3 つの Occupancy Prediction モデル，OpenOccupancy，SurroundOcc，および FB-Occ に対して評価する．いずれのモデルについても，公開されている学習済み重みを用いる．計画レベルでの攻撃有効性を評価するため，各対象モデルの occupancy 予測を §3.1 で述べたプランナへ入力する．

評価データセット．BH Attack を，Occupancy Prediction の学習・評価に用いられているデータセットである nuScenes および Waymo 上で評価する．これらはそれぞれ 150 および 798 のシーンを含む．

敵対的パッチの生成．路側に設置する 3 m × 3 m の敵対的パッチを用いる．これは道路脇にある広告の最小サイズよりも小さいものである [9]．パッチの最適化は 300 反復行う．

評価指標．Open-Loop 評価では $\mathrm{ASR}_{\mathrm{open}}$ を主要な指標として用いる．これは，計画軌道が敵対的に生成された道路に連続する 2 ステップ以上，すなわち 1 s 以上追従した評価シーンの割合と定義する．これは自動運転の Control が 2 計画ステップをもとに決めるためであり，下流の車両制御に影響を及ぼしうる攻撃を評価するものである．

5.2 道路曲率とパッチ設置位置にわたる攻撃実現可能性

さまざまな道路曲率とパッチ設置位置にわたる BH Attack の実現可能性を調査する．実現可能性に焦点を当てるため，本実験では敵対的パッチを用いず，occupancy 出力を直接操作する．そのうえで，プランナを実行し，BH

© 2026 Information Processing Society of Japan

Attack の実現可能性を評価する．

実験設定． nuScenes および Waymo データセットを用い，異なる道路曲率およびパッチ設置条件にわたって BH Attack を評価する．正常時の計画軌道の 3 s 間の方位変化に基づき，シーンを 5° 刻みの道路曲率に分類する．パッチ位置は，自車の進行方位を基準に，0°（Ctr），カーブ内側の 15°/30°（In-15/In-30），外側の 15°/30°（Out-15/Out-30）の 5 条件とする．道路脇にパッチを設置できる組合せのみを対象とし，各組合せについて §4.3 に従って 100 回 TPE で道路条件を最適化し，$\mathrm{ASR}_{\mathrm{open}}$ を評価する．

実験結果． 表 1 に nuScenes および Waymo における $\mathrm{ASR}_{\mathrm{open}}$ を示す．両データセットにおいて，Ctr と Out-15 がより高い $\mathrm{ASR}_{\mathrm{open}}$ を達成することがわかる．また，BH Attack はカーブにおいて特に有効であり，直線では $\mathrm{ASR}_{\mathrm{open}}$ が 67% だが，$|\Delta\psi| \geq 10\,\mathrm{deg}$ において，83%の $\mathrm{ASR}_{\mathrm{open}}$ となる．これは，プランナが自車の現在の進行方向の軌道を選ぶ傾向にあるためであると考えられる．以上の結果に基づき，パッチを用いた攻撃有効性評価では，Ctr を既定のパッチ設置位置として評価する．

5.3 攻撃有効性の評価

攻撃パイプラインを用いて生成した BH Attack が実際に有効かを評価する．

実験設定． §5.2 の実現可能性解析に基づき，正常時の計画軌道の 3 s 間の方位変化に応じてシーンを 3 つに分割する．Straight（< 5°），Gentle（5°–15°），および Sharp（≥ 15°）である．パッチ位置は曲線路で Ctr，直線路では設置可能シーンが少ないため Out-15 とする

各シーンについて，提案した攻撃方法に従ってパッチを最適化したうえで，得られる $\mathrm{ASR}_{\mathrm{open}}$ を評価する．BH Attack を，同一のパッチ設置位置およびサイズを用いる 2 つのベースライン，ランダムテクスチャと w/o Road Opt. について比較する．後者は，敵対的道路条件を最適化せずに occupancy の予測誤りを増やすようにロスを最大化させる手法である．

実験結果． 表 2 に示すように，BH Attack は大半の条件において Random および w/o Road Opt. を上回る $\mathrm{ASR}_{\mathrm{open}}$ を達成し 65%–95% に達する．この結果は，パッチ最適化に先立って道路条件を最適化することの重要性を示している．また BH Attack は，直線よりもカーブにおいて有効な傾向にあることがわかる．

5.4 アブレーション研究

§4.5 の損失設計を評価するため，§5.3 と同一のシーン選択・パッチ設置位置を用いて，nuScenes の Gentle のシーン上で 一般的なロスである CE ロス，および提案するロス (Ours) そして，障害物予測のないもの (GB) を比較する．表 3 に示すように，GB は OpenOccupancy と FB-Occ において CE よりも $\mathrm{ASR}_{\mathrm{open}}$ を改善する．さらに Hide を

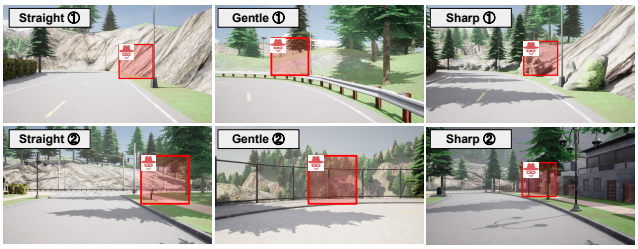


図 5 Closed-Loop 評価に用いたシーンの例

加えることで攻撃有効性は一層向上し，SurroundOcc で 20%，FB-Occ で 50% の $\mathrm{ASR}_{\mathrm{open}}$ の上昇が得られ，3 モデルすべてが 85% 以上に達する．この改善は，生成された道路上に残存してプランナの追従を妨げていた偽の障害物予測を抑制したことによる．したがって GB と Hide は，BH Attack を実現するうえで不可欠である．

5.5 その他のロバスト性評価

BH Attack のロバスト性を評価するため，パッチサイズと ASR_{open} の関係とモデル間転移性を調査した．1 m のパッチでも緩やかなカーブでは 3 モデルで $\mathrm{ASR}_{\mathrm{open}}$=75%–85%を達成し，攻撃効果は 2 m 程度から概ね飽和した．また，モデル間転移性はモデルのアーキテクチャに依存することが分かった．FB-Occ が最も転移しやすく $\mathrm{ASR}_{\mathrm{open}}$ は 70%以上となった．詳細は付録 A.3.2 に示す．

6. デジタル実験 (Closed-Loop)

一般的な運転シミュレータである CARLA [10] を用い，最適化された敵対的パッチを 物理オブジェクトとして配置し，自動運転システムを Closed-Loop で動作させ，BH Attack が自動運転車をパッチへ誘導できるかを検証する．

6.1 共通の実験設定

シーン選択． Open-Loop 評価（§5.2）と同一の基準に従って，*Straight*（< 5°），*Gentle*（5°–15°），*Sharp*（≥ 15°）に分類する．各カテゴリ 5 シーンを無作為に選択する．

AD システム． CARLA 上に §3.1 で述べた自動運転システムを実装する．カメラ構成は nuScenes に合わせ，システムは 20 Hz で動作する．

物理パッチ． CARLA 内に 3 m×3 m の路側看板を物理オブジェクトとして配置し，最適化したテクスチャを適用する．地上 1 m に設置し，車両移動に伴う視点・距離・スケール・照明変化を CARLA のレンダリングによって反映する．パッチは 900 反復最適化する．

評価指標． 評価指標として $\mathrm{ASR}_{\mathrm{closed}}$ を用いる．これは攻撃により車両が本来の経路から逸脱し，敵対的看板または誘導された軌道上の障害物に衝突したシーンの割合である．

6.2 攻撃有効性の評価

CARLA において，BH Attack が自動運転車を敵対的パッチへ誘導できるかを評価する．§6.1 で述べた 3 つの曲率条件それぞれについて 5 シーン，計 15 シーンで車両を走行させ，$\mathrm{ASR}_{\mathrm{closed}}$ を測定する．なお，各シーン初期位置をランダムに変更し 5 回試行した．

© 2026 Information Processing Society of Japan

表 1　カーブ条件およびパッチ設置位置ごとの $\mathrm{ASR}_{\mathrm{open}}$．添字は評価シーン数を表す．

$\lvert\Delta\psi\rvert$	In-30	In-15	Ctr	Out-15	Out-30
nuScenes					
0–5°	–	–	$100\%_{1}$	$67\%_{18}$	$50\%_{22}$
5–10°	$46\%_{26}$	$53\%_{15}$	–	$63\%_{27}$	$27\%_{26}$
10–15°	$50\%_{22}$	$18\%_{11}$	$75\%_{8}$	$88\%_{24}$	$68\%_{25}$
15–20°	$43\%_{21}$	$57\%_{7}$	$100\%_{5}$	$83\%_{18}$	$60\%_{20}$
20–25°	$65\%_{20}$	$40\%_{5}$	$92\%_{13}$	$100\%_{15}$	$74\%_{19}$
> 25°	$60\%_{15}$	$77\%_{13}$	$100\%_{18}$	$90\%_{20}$	$86\%_{22}$
Waymo					
0–5°	–	–	$50\%_{2}$	$67\%_{43}$	$54\%_{89}$
5–10°	$33\%_{9}$	$50\%_{2}$	$100\%_{1}$	$100\%_{6}$	$80\%_{10}$
10–15°	$33\%_{12}$	$40\%_{5}$	$80\%_{5}$	$94\%_{17}$	$78\%_{18}$
15–20°	$42\%_{19}$	$75\%_{4}$	$67\%_{9}$	$96\%_{23}$	$78\%_{23}$
20–25°	$89\%_{19}$	$80\%_{5}$	$74\%_{19}$	$94\%_{32}$	$81\%_{31}$
> 25°	$47\%_{17}$	$74\%_{19}$	$91\%_{33}$	$91\%_{33}$	$75\%_{32}$

表 2　$\mathrm{ASR}_{\mathrm{open}}$ の結果．直線シーンでは Out-15，曲線シーンでは Ctr にパッチを設置する．

		nuScenes			Waymo		
	手法	OpenOcc	SurrOcc	FB-Occ	OpenOcc	SurrOcc	FB-Occ
Straight	Random	5%	0%	5%	10%	5%	0%
	w/o Road Opt.	5%	10%	0%	5%	0%	5%
	Ours	**90%**	**70%**	**70%**	**85%**	**75%**	**65%**
Gentle	Random	15%	10%	10%	25%	30%	30%
	w/o Road Opt.	50%	15%	15%	25%	20%	40%
	Ours	**85%**	**95%**	**90%**	**85%**	**95%**	**85%**
Sharp	Random	5%	15%	40%	20%	5%	0%
	w/o Road Opt.	40%	10%	30%	35%	40%	20%
	Ours	**75%**	**85%**	**95%**	**80%**	**95%**	**75%**

表 3　nuScenes の緩やかなカーブにおける $\mathrm{ASR}_{\mathrm{open}}$．GB は提案する勾配平衡型の損失，Hide は障害物抑制項を表す．

構成	OpenOcc	SurrOcc	FB-Occ
CE	75%	80%	35%
GB	80%	75%	40%
GB + Hide	**85%**	**95%**	**90%**

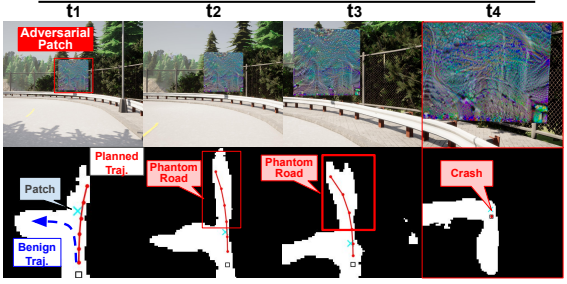


図 6　Closed-Loop 評価における攻撃の様子と occupancy．パッチにより正面に道路が誤認識され，パッチに向かうことがわかる．

実験設定．§4.4 で述べた車両ダイナミクスを考慮した EoT を用いる BH Attack を，Benign，Random，Baseline の 3 条件と比較する．まず，敵対的看板を設置しない Benign 条件を評価し，対象の自動運転システムが各シーンを正常に走行できることを確認する．次に，Random 条件として，同一の 3 m × 3 m の看板に無作為に生成したテクスチャを適用したものを設置する．さらに Baseline として，自車からパッチへ向かう方向に沿って 2 m 間隔でサンプリングした視点による EoT を用いて敵対的テクスチャを最適化する攻撃を評価する．BH Attack とは異なり，このベースラインは Closed-Loop 実行中に車両の応答によって誘起される視点変化を考慮しない．公平な比較のため，Baseline と BH Attack はパッチサイズなどの条件は同一とする．

実験結果．表 4 に各条件の $\mathrm{ASR}_{\mathrm{closed}}$ をまとめる．対象 AD システムは Benign および Random の両条件においてほぼすべての評価シーンを完走しており，路側看板の存在そのものや無作為なテクスチャだけに対してはロバストであることを示している．これに対し BH Attack は最大 96%の $\mathrm{ASR}_{\mathrm{closed}}$ を示し，Baseline の最大 20%を大きく上回る．この結果は，Closed-Loop での影響を明示的に組み込むことの有効性を示すものである．

6.3　現実的な設置条件下での攻撃

BH Attack の実環境での実現可能性をさらに調査するため，敵対的テクスチャを広告画像と混合する手法と，敵対的領域を広告の一部に埋め込む手法を評価した．Gentle の 5 シーンにおいて，いずれも 4/5 シーンで攻撃に成功し，外観を制約した場合でも BH Attack が有効であることを確認した．詳細は付録 A.4.1 に示す．

表 4　曲率条件ごとの $\mathrm{ASR}_{\mathrm{closed}}$．我々の攻撃が高い ASR_{closed} を示しており，提案手法が有効であることが分かる．

曲率	Benign	Random	Baseline	**BH (Ours)**
Straight	0% (0/25)	0% (0/25)	0% (0/25)	**60% (15/25)**
Gentle	0% (0/25)	0% (0/25)	20% (5/25)	**96% (24/25)**
Sharp	8% (2/25)	8% (2/25)	20% (5/25)	**92% (23/25)**

7.　物理世界評価

本節ではさらに，最適化した敵対的パッチを印刷して物理環境に設置し，物理環境で occupancy ベースの自動運転車をパッチへ誘導できるかを検証する．

7.1　評価設定

HiWonder 製車両に，nuScenes と同一の構成でカメラを配置搭載し，§3.1 に基づく AD プラットフォームで自動車を動作させる．車両，道路，およびパッチの幾何的な縮尺比を保った走行環境を構築し，§4.5 と同一の手法で生成した物理パッチを設置する．パッチサイズは 10cm x 10cm である．*Benign*，*Random*，*Baseline*，*BH Attack* の 4 条件を比較する．それぞれ §6.2 と同一の定義を用いる．

7.2　実験結果

Benign，Random のいずれにおいても車両は車線内を維持しテスト路を正常に走行することが分かった．また，Baseline においても，生成された敵対的パッチは車両を車線外へ逸脱させることができなかった．これに対し BH Attack では，車両は車線から逸脱して敵対的パッチへ向かって走行しており，BH Attack が実際の occupancy ベース AD システムを操作しうることを示している．

8.　防御

8.1　既存のパッチ攻撃を用いた防御の議論

Occupancy prediction を直接の対象とした防御は存在しない．しかし BH Attack はパッチ攻撃であり，パッチ攻撃に対する防御は原理的に転用しうる．既存防御は，攻撃に対する理論的保証を与える certified defense と，入力や時系列的な不整合から攻撃を検知する empirical defense に

© 2026 Information Processing Society of Japan



(a) Experimental setup (b) Capture images in front camera under benign and attack scenario

図 7 評価環境および Benign と Attack における結果.

大別できる．前者は，入力空間に対する網羅的な保証に大きな計算コストを要するため，リアルタイムかつ密な出力を扱う Occupancy Prediction への適用は困難である．そこで，実行時に適用可能な empirical defense に着目する．

代表的な empirical defense は，時系列での一貫性を利用して敵対的な認識結果を検知する．しかし，いずれも BH Attack の防御には適さない．VisionGuard [11] は ego vehicle の速度・加速度の時系列的不連続を手がかりとするが，BH Attack は プランナ に一貫した別軌道を選ばせるため，位置・方位・速度はいずれも滑らかに変化する．PhySense [12] は認識深度の不一致から偽物体を検知するが，phantom road は実在する路面上に生成されるため，その深度は地面と整合する．以上より既存の防御では BH Attack を防げず，独自の防御が必要となる．

8.2 PathGuard

我々は BH Attack に特化した防御である PathGuard を提案する．Occupancy prediction の誤認識のうち プランナ の判断を変えるのは，選択された軌道の周辺に限られる．そこで PathGuard は，プランナ が選択した 軌道 から逆算して検証すべき occupancy を特定する．検証対象を軌道周辺に絞ることで，カメラから観測できない ボクセル や遠方の曖昧な領域が持ち込む不確実性を排除し，benign 性能を損なわずに計算コストも削減する．PathGuard は，3D occupancy と 2D perception の不一致として妥当性を検証する．軌道 上で road と予測された ボクセル をカメラ画像へ投影し，その領域を独立した 2D segmentation model が道路と判断するかを確認し異なると判断した場合，その ボクセル を不整合とみなす．不整合が 30% を超えるフレームが 3 回以上続いたとき，攻撃と判定する．

8.3 PathGuard の評価

提案した PathGuard を CARLA を用いて評価した．CARLA 上の gentle シーン 25 本 (攻撃は成功した 24 本) を用い，各シーンについて benign 走行と攻撃走行を評価した．攻撃パッチは §6.1 で用いたものをそのまま使った．benign 25 本では警報が一度も発火しなかった．攻撃 24 本全てを検知し (検知率 100%)，警報は車両が道路を外れる平均 1.8 秒前に生じた．この余裕はプランナを安全側の軌道へフォールバックさせるのに十分である．

9. 結論

本論文では，Occupancy Prediction を用いた自動運転に対する初の攻撃である Black Hole 攻撃を提案し評価した．BH Attack は実在しない道路（phantom road）を路外に生成させることで，車両をパッチに向かうように誘導する攻撃である．本攻撃の実現において，二段階の最適化パイプラインと BH Attack 独自のロスを導入することで効果的に存在しない道路を生成することができた．また，closed-loop の視点変化を含めて patch を最適化することで，closed-loop 環境においても効果的に機能する攻撃を実現した．CARLA を用いた評価において，BH Attack は 最大 96% の攻撃成功率を達成し，車両を意図した方向に誘導できることが明らかになった．さらに，BH Attack に対する防御として PathGuard を設計・評価した．BH Attack を 100% の精度で逸脱の平均 1.8 秒前に検出した．

謝辞 本研究の一部は JST CREST JPMJCR23M4, JST 国家戦略分野の若手研究者及び博士後期課程学生の育成事業 (博士後期課程学生支援) JPMJBS2429, および BRIDGE R7-H05 の支援を受けたものです．

参考文献

[1] Workshop on autonomous driving at CVPR 2022. https://cvpr2022.wad.vision/, 2022.
[2] W Tong, et al. Scene as occupancy. In *ICCV*, 2023.
[3] X. Wang, et al. Openoccupancy: A large scale benchmark for surrounding semantic occupancy perception. In *ICCV*, 2023.
[4] Xiaoyu Tian, et al. Occ3d: A large-scale 3d occupancy prediction benchmark for autonomous driving. *NeurIPS*, 2023.
[5] Y. Wei, et al. Surroundocc: Multi-camera 3d occupancy prediction for autonomous driving. In *ICCV*, 2023.
[6] Z Li, et al. Fb-occ: 3d occupancy prediction based on forward-backward view transformation. *arXiv*, 2023.
[7] T Sato, et al. Dirty road can attack: Security of deep learning based automated lane centering under Physical-World attack. In *USENIX Security*, 2021.
[8] B Chen, et al. Adversary is on the road: Attacks on visual SLAM using unnoticeable adversarial patch. In *USENIX Security*, 2024.
[9] R. Queiroz. Billboard dimensions and sizes. https://dashtwo.com/blog/what-are-billboard-dimensions/.
[10] A Dosovitskiy, et al. Carla: An open urban driving simulator. In *CoRL*, 2017.
[11] X Han, et al. Visionguard: Secure and robust visual perception of autonomous vehicles in practice. In *CCS*, 2024.
[12] Z Yu, et al. Physense: Defending physically realizable attacks for autonomous systems via consistency reasoning. In *CCS*, 2024.

© 2026 Information Processing Society of Japan

研究倫理

本研究における攻撃の評価対象は，オープンソースのモデルおよび自動運転システムを対象としており，直ちに商用の自動運転車両に影響を与えるものではない．しかしながら，本攻撃が実在する自動運転車両において危害を加えうると明らかになった場合，直ちに responsible disclosure を進め，安全な自動運転の実現に寄与する．また，物理実験においては，ミニチュアを用いた評価を行っており，公道にある自動運転車両等には影響を与えることはない．

付　　録

A.1　Occupancy を用いた自動運転の詳細

§3.1 で述べた対象システムの各段を以下に詳述する．

Occupancy に基づくコスト構築．プランナは 3 次元 semantic occupancy を鳥瞰図（BEV）平面へ投影し，道路マスク R_t と障害物マスク A_t を構築する：

$$R_t(x,y) = \max_z \mathbb{I}[S_t(x,y,z) = c_{\text{road}}], \tag{A.1}$$

$$A_t(x,y) = \max_z \mathbb{I}[S_t(x,y,z) \in \mathcal{C}_{\text{obj}}], \tag{A.2}$$

ここで $\mathcal{C}_{\text{obj}}$ は，プランナが障害物として扱うセマンティッククラスの集合を表す．次にプランナは，これらのマスクから BEV コストマップ

$$C_t(x,y) = \lambda_{\text{road}}\big(1 - R_t(x,y)\big) + \lambda_{\text{obj}} A_t(x,y), \tag{A.3}$$

を構築する．λ_{road} と λ_{obj} はそれぞれ道路外の領域と障害物上の領域に与える重みであり，コストマップは道路と予測されていない位置，および障害物に占有されていると予測された位置に高いコストを与える．

候補軌道の生成．現在の自車状態 x_t から，運動学的に実行可能な候補軌道の有限集合 $\mathcal{T}_t$ を生成する．各候補 $\tau = \{p_\ell\}_{\ell=1}^{L}$ は将来のウェイポイント列であり，直線区間，一定曲率の円弧，およびクロソイド曲線を，車両の操舵・加速度制約の下で組み合わせて構成する．候補軌道の生成は自車状態と運動学的制約のみに依存し，occupancy の予測結果には依存しない．したがって攻撃は候補軌道の集合そのものではなく，その評価に用いるコストマップを操作することになる．

軌道コストと選択．各候補について，軌道上で車両が占める BEV セルにわたって式 (A.3) のコストを積算し，軌道コストを得る：

$$J_t(\tau) = \sum_{\ell=1}^{L} \sum_{(x,y)\in\mathcal{F}(p_\ell)} C_t(x,y) + C_{\text{learned}}(\tau). \tag{A.4}$$

ここで $\mathcal{F}(p_\ell)$ はウェイポイント p_ℓ において車両が占有する BEV セルの集合である．プランナは $\tau_t^* = \arg\min_{\tau\in\mathcal{T}_t} J_t(\tau)$ により最小コストの候補を選択する．この選択は候補集合上の離散的な操作であるため，τ_t^* から $\mathcal{M}_\theta$ へ勾配を伝播できない．

制御．選択された軌道 τ_t^* は PID コントローラへ入力される．コントローラは最初の 2 つの将来ウェイポイントから横方向の操舵目標と縦方向の目標速度を決定し，操舵・アクセル・ブレーキ指令へ変換する．このため，semantic occupancy の操作は BEV コストマップを変化させ，プランナに別の軌道を選択させることで，最終的に車両制御へ波及する．

A.2　攻撃アルゴリズムの詳細

A.2.1　攻撃時軌道の選択

§4.4 で述べたとおり，攻撃成功時の車両運動として，実行可能軌道の集合 $\mathcal{T}(s)$ のうちパッチ中心 c に最も接近する軌道を用いる：

$$\tau_{\text{attack}}(s) = \arg\min_{\tau\in\mathcal{T}(s)} \min_t \big\|T_p(w_t^\tau) - c\big\|_2. \tag{A.5}$$

ここで $T_p(w_t)$ は，軌道 τ 上のウェイポイント w_t を自車座標系から世界座標系へ変換する写像である．軌道全体ではなく最接近点のみを評価するのは，パッチへの接近が軌道の一部区間で生じれば，その時点の姿勢が後続の視点推定に反映されるためである．

A.2.1.1　目標整合誤差と探索範囲

§4.3 で述べた平均角度差を，軌道の進行方向とパッチ方向との角度差の平均として定義する：

$$A(r) = \frac{1}{K}\sum_{k=1}^{K} \angle\big(\tau_k - \tau_{k-1},\, c - \tau_{k-1,xy}\big), \tag{A.6}$$

ここで $\tau(r) = (\tau_0, \ldots, \tau_K)$ は phantom road r を注入した後の計画軌道，c はパッチ中心である．$A(r)$ が小さいほど，計画軌道がパッチ方向へ向いていることを表す．

探索範囲 $\mathcal{R}$ は，幅を $w \in [1.0, 5.0]$ m，方位を $\phi \in [-90°, 90°]$ とする．ここで $\phi = 0°$ は自車の進行方向を表し，正の値は右方向への回転を表す．プランナを介して勾配を伝播できないため，Optuna に実装された TPE により $A(r)$ を最小化する．

§4.5 の道路条件最適化では，視点 p において r を注入した際の角度偏差を $A(r;p)$ と表し，視点集合全体の平均 $\frac{1}{|\mathcal{V}^\dagger|}\sum_{p\in\mathcal{V}^\dagger} A(r;p)$ を最小化する．

A.2.2　Planner-aware Loss の詳細

§4.5 で述べたように，単純な交差エントロピー損失のみでは，phantom road の一部が road クラスへ変換されずに残る場合や，生成した道路領域内に誤った障害物予測が残る場合がある．そこで我々は，勾配平衡型の道路生成と障害物予測の抑制を組み合わせてパッチを最適化する．

勾配平衡型の道路生成．各最適化反復において，目標道路

© 2026 Information Processing Society of Japan

領域 Ω を，まだ road クラスへ変換されていないボクセル集合 Υ と，すでに road クラスが予測されている集合 $\bar{\Upsilon} = \Omega \setminus \Upsilon$ に分割し，それぞれに対して交差エントロピー損失 $\mathcal{L}_{\Upsilon}$ および $\mathcal{L}_{\bar{\Upsilon}}$ を計算する．両損失を単純に加算すると，勾配ノルムの大きい一方の項が更新を支配し，未変換領域の生成または生成済み道路の維持のいずれかが不十分となりうる．パッチ最適化への寄与を決めるのは損失値そのものではなく勾配ノルムであるため，我々は両者の勾配を個別に正規化したうえで，未変換セルの割合 $\gamma = |\Upsilon|/|\Omega|$ に基づいて統合する（本文の式 (2)）．γ は未変換ボクセルの割合から動的に決まるため，調整すべきハイパーパラメータではない．最適化の初期には大半のボクセルが Υ に属するため，更新は新たな領域を road クラスへ変換する方向に働く．road クラスへ変換されたボクセルが増えるにつれて $\bar{\Upsilon}$ からの寄与が増加し，残りの領域を変換しながら生成済みの道路を維持する．Υ または $\bar{\Upsilon}$ のいずれかが空集合の場合には，対応する勾配項を省略する．

障害物予測の抑制． phantom road 内に誤った障害物が予測されると，プランナはその領域を回避し，攻撃効果が低下する．これを除去する単純な方法として，当該ボクセルに empty クラスを明示的な目標として与えることが考えられる．しかしこれは road クラスの生成と競合する別の意味的目標を導入し，phantom road の生成を阻害しうる．そこで我々は置換先のクラスを指定せず，プランナが障害物として扱うクラスに割り当てられた確率のみを低減する．$\mathcal{C}_{\mathrm{obj}}$ を障害物クラスの集合，$\hat{y}_v$ をボクセル v の現在の予測クラスとし，

$$\mathcal{O} = \{v \in \Omega : \hat{y}_v \in \mathcal{C}_{\mathrm{obj}}\}, \quad \mathcal{L}_{\mathrm{sup}} = \frac{1}{|\mathcal{O}|} \sum_{v \in \mathcal{O}} \sum_{c \in \mathcal{C}_{\mathrm{obj}}} \mathrm{softmax}(z_v)_c \tag{A.7}$$

と定義する．この損失は特定の非障害物クラスへの変換を要求しないため，各ボクセルは road を含む任意の非障害物クラスへ遷移できる．$\mathcal{O}$ が空集合の場合には $\mathcal{L}_{\mathrm{sup}} = 0$ とし，その勾配を省略する．

最終的な更新． 勾配平衡型の道路生成による g_{road} と，正規化した障害物抑制損失の勾配を組み合わせ，Adam に与える更新勾配を次式で構成する：

$$g = g_{\mathrm{road}} + \lambda \frac{\nabla_{\delta} \mathcal{L}_{\mathrm{sup}}}{\|\nabla_{\delta} \mathcal{L}_{\mathrm{sup}}\|_2 + \epsilon}, \tag{A.8}$$

ここで λ は障害物抑制項の強度を制御する係数であり，ϵ は数値的不安定性を防ぐための微小定数である．

A.2.3 微分可能な多視点レンダリングの詳細

パッチの投影． 物理パッチの 4 隅 $(Q_1, \ldots, Q_4)$ を世界座標系で固定する．視点 p におけるカメラ m について，内部パラメータ行列 K_m と世界座標からカメラ座標への変換 $E_{m,p}$ を用いて各隅を画像平面へ投影する：

$$q_{i,m}^{(p)} = \pi\left(K_m E_{m,p} \widetilde{Q}_i\right), \qquad i = 1, \ldots, 4, \tag{A.9}$$

ここで $\widetilde{Q}_i$ は Q_i の同次座標表現，π は透視除算を表す．

テクスチャのワープと合成． パッチは平面であるため，投影された 4 隅 $q_{1:4,m}^{(p)}$ は，パッチテクスチャ δ から対応する画像四辺形への homography を一意に定める．我々は微分可能なバイリニアサンプリングによりテクスチャをワープし，元画像 $I_{p,m}$ と合成する：

$$\tilde{I}_{p,m} = (1 - M_{p,m}) \odot I_{p,m} + M_{p,m} \odot \mathcal{W}\left(\delta; q_{1:4,m}^{(p)}\right), \tag{A.10}$$

ここで $M_{p,m}$ は投影されたパッチマスク，$\mathcal{W}$ は微分可能なワープ演算，$\odot$ は要素ごとの積を表す．合成画像 $\{\tilde{I}_{p,m}\}_{m=1}^{K}$ をまとめて occupancy モデルへ入力して $z(\delta, p)$ を得る．式 (A.10) のすべての演算が微分可能であるため，occupancy 出力から共有テクスチャ δ まで勾配を逆伝播できる．すべてのカメラ・すべての視点が単一の δ を共有するため，得られる勾配は視点集合全体で平均化され，δ は物理的に実現可能な単一のパッチとして最適化される．

EoT による摂動． 実環境における設置誤差や照明・センサ条件の変動に対する頑健性を高めるため，最適化の各反復において，レンダリング前に公称のパッチ配置と画像に対して位置，スケール，回転，明度のランダムネスを追加する．

A.3 さらなる Open-Loop 評価

A.3.1 パッチサイズの影響

パッチサイズが攻撃有効性に与える影響を調査する．前実験と同一の nuScenes のシーンおよびパッチ設置位置を用い，3 m に加えて一辺 1 m および 2 m の正方形パッチを最適化し，$\mathrm{ASR}_{\mathrm{open}}$ を評価する．表 A·1 に示すように，$\mathrm{ASR}_{\mathrm{open}}$ はパッチサイズの増加に伴って概ね向上するが，2 m を超えるとその改善は限定的となる．

表 A·1 パッチサイズが $\mathrm{ASR}_{\mathrm{open}}$ に与える影響．3 m の行は表 2 で報告した実験と同一である．

条件	サイズ	OpenOcc	SurrOcc	FB-Occ
直線	1 m	60%	45%	55%
	2 m	85%	60%	80%
	3 m	90%	70%	70%
緩やか	1 m	75%	75%	85%
	2 m	80%	90%	95%
	3 m	85%	95%	90%
急	1 m	75%	50%	70%
	2 m	80%	75%	80%
	3 m	75%	85%	95%

A.3.2 攻撃の転移性

BH Attack が，異なるアーキテクチャを持つ他の Occupancy Prediction モデルへ転移するかについても評価す

© 2026 Information Processing Society of Japan

表 A·2 nuScenes の緩やかなカーブにおける攻撃転移性（$\mathrm{ASR}_{\mathrm{open}}$）．各セルは 20 シーンの結果である．対角成分は表 2 のホワイトボックス結果である．

		転移先モデル		
		OpenOcc	SurrOcc	FB-Occ
転移元	OpenOcc	85%	50%	75%
	SurrOcc	35%	95%	70%
	FB-Occ	30%	65%	90%

る．あるモデルに対してパッチを最適化し，他のモデルに対する攻撃有効性を評価する．§5.3 と同一の緩やかなカーブのシーンおよびパッチ設置位置を用いる．表 A·2 に，異なるアーキテクチャ間の攻撃転移性をまとめる．転移性は転移元および転移先のモデルに依存することがわかる．深度ベースの OpenOccupancy に対して生成した攻撃は Transformer ベースの SurroundOcc に対して効果が低く，その逆も同様であり，$\mathrm{ASR}_{\mathrm{open}}$ は高々 50% にとどまる．これに対し，いずれのモデルに対して生成した攻撃もハイブリッド型の FB-Occ に対しては有効であり続け，$\mathrm{ASR}_{\mathrm{open}}$ はそれぞれ 75% および 70% に達する．これは，FB-Occ が両アーキテクチャの特性を併せ持つためと考えられる．

A.4 さらなる Closed-Loop 評価

A.4.1 現実的な設置条件下での攻撃の詳細

攻撃が路側広告として自然に見えるようにする 2 つの制約の下でも BH Attack が有効であり続けるかを評価する．

A.4.1.1 実験設定

敵対的テクスチャを，より自然に見える路側広告に埋め込んだ場合にも BH Attack が有効であり続けるかを評価する．外観に関する 2 つの制約，すなわち (1) Ad Blending と (2) Region-Constrained Embedding を考える．いずれの設定においても，看板の設置位置，車両の初期状態，天候条件，および 900 反復という最適化予算は §6.2 と同一に保つ．Closed-Loop の攻撃有効性の評価には，同じく $\mathrm{ASR}_{\mathrm{closed}}$ を用いる．2 つの手法について攻撃を適用したシーンと元画像を図 A·1

Ad Blending. Ad Blending は，敵対的テクスチャを広告画像と合成する手法である．最適化されたテクスチャ δ をそのまま設置するのではなく，可視テクスチャを次のように構成する．

$$\delta_{\mathrm{blend}} = \alpha\delta + (1-\alpha)I_{\mathrm{ad}}, \tag{A.11}$$

ここで I_{ad} は攻撃者が選択または生成した広告画像である．最適化の際は δ_{blend} を用いて攻撃損失を計算し，合成演算を通して勾配を逆伝播させることで δ を更新する．最適化後は，δ ではなく δ_{blend} を設置する．本評価では $\alpha = 0.5$ とし，図 A·1 に示す広告画像を用いる．

表 A·3 Gentle の 5 シーンにおける，外観制約下での Closed-Loop 攻撃有効性．

設定	$\mathrm{ASR}_{\mathrm{closed}}$
Original	100% (5/5)
Ad Blending	80% (4/5)
Region-Constrained Embedding	80% (4/5)



(a) Ad Blending (b) Region-Constrained Embedding

図 A·1 2 つのステルス性考慮における攻撃適用時の画像および元画像

Region-Constrained Embedding. Region-Constrained Embedding は，敵対的テクスチャを広告看板の一部分のみに限定する手法である．テレビ広告を生成し，その画面領域のみを最適化して，広告のそれ以外の部分は変更しない．看板のサイズは $4\,\mathrm{m} \times 4\,\mathrm{m}$ とし，一般的な路側看板のおよそ 4.3 m という高さ [9] に匹敵する高さを用いる．最適化される画面領域は $3\,\mathrm{m} \times 1.5\,\mathrm{m}$ であり，敵対的領域の面積は $4.5\,\mathrm{m}^2$ となる．これは §6.2 で用いた $9.0\,\mathrm{m}^2$ の半分である．

A.4.1.2 実験結果

表 A·3 に示すように，BH Attack は両方の外観制約の下でも有効であり続ける．Ad Blending と Region-Constrained Embedding はいずれも Gentle の 5 シーン中 4 シーンで成功し，$\mathrm{ASR}_{\mathrm{closed}}$ は 80% に達する．これは §6.2 における外観制約なしの 100% という成功率よりは低いものの，敵対的テクスチャを広告と合成した場合や，敵対的領域を元の半分に制限した場合でも，BH Attack は有効であり続けることを示している．

© 2026 Information Processing Society of Japan