敵対的パッチによる偽障害物生成攻撃のシステムレベル評価

斧田 洋人[1,a)]　鶴岡 豪[1]　末次 響[1]　大西 健斗[2]　東 拓矢[2]　小関 義博[2]　中井 綱人[2]　森 達哉[1,3,4]

概要：自動運転においてカメラを用いた物体検出は，画像から物体を検出しただけで障害物を判断するのではない．検出された 2 次元の矩形は 3 次元空間上の障害物へ再構成された上で，複数フレームにわたる多物体追跡（Multi-ObjectTracking, MOT）を経て確定したものだけが予測と計画へ渡される．しかし認識機能に対する敵対的攻撃の多くは 2 次元検出器単体を対象に評価しており，この後段まで含めたシステム全体への影響は明らかでない．本研究では，路面に貼付した敵対的パッチによって存在しない障害物を検出させる出現攻撃を提案する．パッチ領域全体がひとつの検出枠として出力されるよう最適化することで，3 次元復元と MOT を経ても一貫した障害物として扱われることを狙う．提案したパッチに対し Apollo と CARLA を接続した走行環境でシステムレベル評価を行った．その結果，路面に平面のパッチが存在するのみで，接近した車両がこれを突発的に出現した障害物とみなし，急制動を起こすことを確認した．また偽の障害物が現れる距離を変えて評価し，車両挙動が出現距離に依存することを示した．

キーワード：敵対的パッチ，自動運転，物体検出，出現攻撃，システムレベル評価

System-Level Evaluation of False Obstacle Generation Attacks Using Adversarial Patches

Hiroto Onoda[1,a)]　Go Tsuruoka[1]　Kyo Suetsugu[1]　Kento Oonishi[2]　Takuya Higashi[2]
Yoshihiro Koseki[2]　Tsunato Nakai[2]　Tatsuya Mori[1,3,4]

Abstract: Camera-based autonomous driving does not judge obstacles from 2D image detection alone. Each detected 2D box is reconstructed into a 3D obstacle, and only those confirmed through tracking across multiple frames are passed to prediction and planning. Yet most adversarial attacks on perception are evaluated on the 2D detector alone, leaving their impact on this downstream pipeline unclear. This paper proposes an appearance attack that uses an adversarial patch placed on the road surface to make a non-existent obstacle be detected. By optimizing the patch so that its entire region is emitted as a single detection box, we aim to have it treated as a consistent obstacle even after 3D reconstruction and tracking. We conduct a system-level evaluation of the generated patches on a driving environment that connects the autonomous driving system Apollo with CARLA. Although only a flat patch is present on the road, the approaching vehicle treats it as a suddenly appearing obstacle and performs emergency braking. We further vary the distance at which the false obstacle appears, and show that the vehicle behavior depends on this distance.

Keywords: adversarial patch, autonomous driving, object detection, appearance attack, system-level evaluation

1. はじめに

自動運転において，周囲の障害物を認識する物体検出は安全性の中核をなす機能であり，高精度の物体検出技術は安全のため不可欠である．なかでもカメラを用いた物体検出は，LiDAR のような高価なセンサを必要とせず，導入

[1] 早稲田大学/Waseda University
[2] 三菱電機/Mitsubishi Electric
[3] 情報通信研究機構/NICT
[4] 理化学研究所 AIP/RIKEN AIP
[a)] honoda@nsl.cs.waseda.ac.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

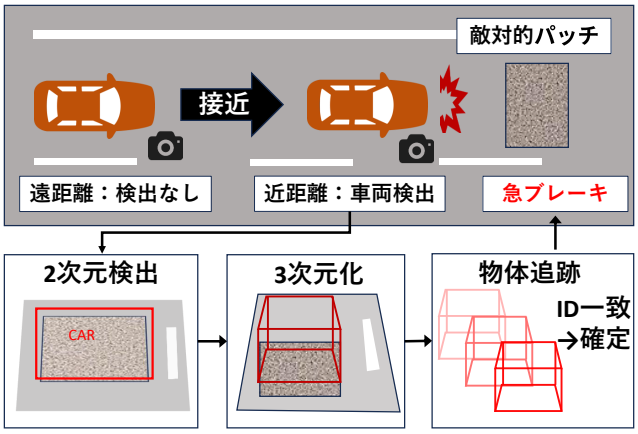


図 1　攻撃の概要.

の障壁が低い．一方で深層ニューラルネットワークは敵対的入力に対して脆弱であり，印刷した敵対的パッチを対象や周囲に配置することで操作できることが報告されている [1], [2]．ただし攻撃による検出器の誤りがただちに車両の危険な動きにつながるとは限らない．自動運転における物体検出では，検出結果が直接障害物として扱われないためである．検出された 2 次元の矩形から，障害物の 3 次元空間上の位置とサイズが推定され，さらに複数フレームにわたる多物体追跡（Multi-Object Tracking, MOT）を経て，同一の物体として繰り返し観測されたものだけが障害物として確定し，予測と計画へ渡される（2.1 節）．つまり 2 次元検出はパイプラインの入口に過ぎず，検出器を欺けたことと，それが車両の挙動に影響することは同じではない．攻撃の脅威を評価するには，後段まで含めた評価が必要である．

物体検出に対する敵対的攻撃は，その目標により二つに分かれる．一つは実在する物体を検出させない消失攻撃であり，車両や歩行者といった対象の表面に模様を貼付し，その物体が検出されないようにする．攻撃対象となる物体そのものに模様を貼付する必要があるため，対象への物理的アクセスを前提とすることが多い．もう一つは存在しない物体を検出させる出現攻撃で，路面や標識といった環境に模様を配置し，そこに物体があると検出させる．対象人物や車両に接触する必要がないため，攻撃者にとっての実行可能性が高い．

消失攻撃については，走行系まで含めた評価が行われている [3], [4]．一方，出現攻撃の評価は検出器単体に留まっている．先行研究 [5], [6] も，偽の障害物が知覚されれば緊急制動や危険な回避が起こりうると述べるにとどまり，それが実際に起きるかは確かめられていない．

そこで本研究は，2 次元検出を誤らせる出現攻撃が後段の 3 次元化と MOT を経て障害物として確定し，走行系の挙動にどのような影響を及ぼすのかを評価する．

攻撃のセットアップを **図 1** に示す．攻撃者は，自車が走行する車線の路面に，1 枚の敵対的パッチを平面として貼付する．パッチは，その領域全体が 2 次元検出器によって 1 台の車両（車両クラス）として検出されるよう最適化されている．遠方ではパッチは検出されず異常は生じないが，自車が一定の距離まで接近すると，パッチの位置に存在しない車両が突然検出される．この誤検出は 3 次元空間上の障害物へと再構成され，MOT を経て前方の障害物として確定し，急ブレーキを誘発する．すなわち本攻撃は，物体を消失させるのではなく，何もない路面に車両を出現させることで車両挙動を操作する．

以上を踏まえ，物理的な物体が存在しないにもかかわらず実運用の自動運転システムがどのような車両挙動を示すか，またその挙動が実在する障害物に対する挙動とどう異なるかを評価する．

このとき，誤検出によって何が起きるかは，偽の障害物が現れる距離によって変わると予想される．出現が近すぎれば制動が間に合わず，遠ければ余裕を持って緩やかに減速できる．両者の間に，大きな減速が生じる領域が存在すると考えられる．そこで本研究では，検出が生じる距離を変えた複数のパッチを作成し，出現距離を制御した条件下で車両挙動を評価する．

パッチは，対象とする 2 次元検出器 YOLOv11 [7] の検出学習損失を用いて最適化する．このとき，指定した距離の範囲では車両として検出され，それよりも遠距離では検出を抑制するように最適化する．これにより，遠方から接近する車両にとって，パッチが特定の距離で突然検出されるようになる．評価は二段階で行う．モデル単体評価では，パッチとの距離 10–110 m のテスト集合において距離別・視点角度別の偽検出率を評価する．システムレベル評価では，Apollo のカメラ単独構成と CARLA を接続した環境で，50 km/h で走行する車両の前方にパッチを設置して走行させる．

主要な結果は次の通りである．生成した誤検出は 2 次元検出にとどまらず，3 次元空間上の障害物へと再構成され，複数フレームにわたる MOT を経ても同一の障害物として維持された．すなわち偽の検出はパイプラインの各段で破綻なく維持され，予測と計画を経て最終的な制御にまで達した．その結果，物理的な物体が存在しないにもかかわらず，自車は 50 km/h から 1.6 km/h まで減速した．同一位置に実車両を置いた対照条件では，接近区間のほとんどでブレーキが踏まれず，自然な減速のみで停止に至る．このときの平均加速度は -1.57 m/s^2 である．これに対しパッチでは 23.1 m からブレーキによる減速が生じ，平均加速度は -5.69 m/s^2 と 3.6 倍に達する．また偽の障害物が現れる距離の上限を 15–40 m の範囲で変えたとき，20 m 以下では $v_{\min}$ が 27.8–39.2 km/h に留まり，25 m 以上では 1.6–11.9 km/h まで低下する．

本研究の貢献は次の 3 点である．

© 2026 Information Processing Society of Japan

- 敵対的パッチによる出現攻撃を，Apollo と CARLA を接続したシミュレーション環境において，2 次元検出から 3 次元復元と MOT を経て車両制御に至るまで end-to-end に評価した．
- 誤検出が 2 次元検出にとどまらず，3 次元復元と MOT を適用されても障害物として維持され，最終的な車両制御にまで影響を及ぼすことを示した．
- 攻撃が引き起こす車両挙動を，実在の障害物に対する挙動との対照および出現距離を制御した条件のもとで定量的に特徴づけた．

2. 背景と関連研究

2.1 2 次元検出に基づく単眼 3D 検出

カメラを用いた 3D 障害物検出の構成は二つに分かれる．一つは，画像特徴を直接 3 次元表現へ変換する end-to-end の単眼あるいは BEV 検出である．もう一つは，まず 2D 検出器で矩形を求め，そこから幾何的に 3D 障害物を再構成する構成である．本研究は後者，すなわち 2 次元検出に基づく単眼 3D 検出を対象とする．

この構成では．まず 2D 検出器が画像から障害物候補の矩形を出力する．次に，その矩形と検出されたクラスから 3 次元空間上の位置とサイズが推定される．推定された 3D 障害物は MOT へ渡され，複数フレームにわたって対応付けられたうえで予測と計画へ供給される．各段の具体的な処理は，対象システムを説明する際に改めて述べる．

ここで重要なのは，2 次元検出はこのパイプラインの入口に過ぎず，最終的な障害物の判断は 3 次元化と MOT を経て下される点である．したがって 2D 検出を誤らせる攻撃は 3D 空間上に存在しない障害物を作り出しうるが，後段の 3 次元化と MOT を経て破綻なく維持されなければ障害物として確定しない．

2.2 実世界における敵対的パッチ攻撃

深層学習モデルは，入力に摂動を加えて出力を意図的に誤らせる敵対的サンプル攻撃に脆弱である [8], [9]．この脆弱性はデジタル環境にとどまらず物理世界でも成立する．Athalye ら [10] は Expectation over Transformation (EoT) を提案して，視点や距離，照明の変動を考慮して摂動を最適化する手法を示した．また，物理世界ではカメラの撮影範囲全体に摂動を加えることは困難なため，摂動を特定の領域に集約し，印刷や設置による物理的な実装を容易にした敵対的パッチ [1] が主要な攻撃手段として確立している．

敵対的パッチ攻撃は，その目標により消失攻撃と出現攻撃に大別される [1], [5]．消失攻撃は対象物体の表面にパッチを貼付し，その物体が検出されないようにするものである，カメラを用いた 3D 検出に対しても研究があり，Li ら [11] は車両表面のテクスチャを最適化することで，対象が検出結果に現れないようにしている．さらに Cao ら [3] は，カメラと LiDAR の双方から検出されにくい立体物を作成し，前方に置いた場合の挙動を Apollo と LGSVL シミュレータ上で評価して，知覚の誤りが衝突に至るまでを走行系で評価している．一方の出現攻撃は，物体が存在しない空間にパッチを適用して，そこに物体があると認識させるものである．対象への物理的アクセスを必要とせず実行可能性は高いが，研究は消失攻撃に比べて少ない．先行研究 [5], [6] は，路面に貼ったポスターによって BEV 空間の 3D 検出器に存在しない物体を知覚させ，高い成功率を報告している．

しかしこれらの評価対象は検出器単体であり，3 次元化や MOT を経たシステム全体での車両の挙動は評価されていない．そこで本研究では，CARLA シミュレータ [12] と Apollo [13] を接続した走行環境を用い，出現攻撃による誤検出が実際の車両挙動に与える影響をシステムレベルで評価する．

2.3 多物体追跡

代表的な自動運転における物体検出は，物体検出に加えて多物体追跡 (Multi-Object Tracking, MOT) を行う．MOT はフレームごとの検出を時系列で対応付け，同一の物体に一貫した識別子を与える処理である．新たに現れた検出はただちに障害物として扱われるわけではなく，対応付けが数フレーム連続して成功して初めて追跡対象として確定する．逆に連続フレームで対応付けが失敗すると削除される．この仕組みにより，単一フレームの誤検出は後段の予測や計画へ伝わりにくい．Jia ら [14] は，1 フレームだけ検出を変えても MOT の結果は変わりにくく，攻撃には位置と時間の両面での安定性が必要であることを示した．本研究の攻撃にも同じ条件が課される．自車が接近するとパッチとの距離や視点は連続的に変化するが，その間，3 次元空間上の同じ位置に物体が存在すると安定して検出され続けなければならない．

3. 脅威モデルと対象システム

3.1 攻撃者のゴール

本研究における攻撃者のゴールは，実際には何も存在しない路面に障害物を検出させ，自動運転車に急な減速や回避を引き起こすことである．走行中の車両が前方に何もない地点で急減速すれば，その車両の走行が妨げられるだけでなく，後続車両との車間も急激に縮まり，衝突の危険が生じる．

このゴールを達成するには，まずパッチの位置に，実際には存在しない車両が検出される必要がある．さらに 2.3 節で述べた通り，MOT が障害物として確定するには，複数のフレームにわたって同じ位置に物体があると認識され続ける必要がある．

© 2026 Information Processing Society of Japan

自車が接近するとパッチとの距離と視点は連続的に変化する．この間に満たすべき条件は 2 つある．一つは検出が途切れないことであり，どの距離，どの視点からも偽検出が生じなければならない．もう一つは検出される位置が変わらないことであり，フレームごとに 3 次元空間上の異なる場所に物体が現れては，同一の物体として対応付けられない．前者に対しては，距離と視点角度を変えた多数の条件をまとめて満たすようにパッチを最適化する．後者に対しては，投影されたパッチを囲う矩形を教師として使うことで，パッチ領域を車両として認識されるようにする．パッチは路面に固定されているため自車の位置からその写り方が決まり，そこに矩形が出現し続ければ推定される 3 次元位置も毎回同じところになると考えられる．

3.2 攻撃者の能力

攻撃者の能力は既存のパッチ攻撃 [5], [6] と同じものを仮定する．すなわち攻撃者は路面に単一のパッチを設置でき，対象となる検出器のパラメータにアクセスできるホワイトボックス環境とする．

3.3 対象システム

本研究が対象とするのは，カメラによる物体検出から 3 次元化，MOT，予測，計画，制御までを備えた自動運転システムである．評価には，その代表例として Apollo を用いる．本研究ではカメラ単独構成とし，CARLA シミュレータと接続して走行させる．Apollo はカメラ知覚への攻撃を評価する研究で広く用いられており [3]，知覚から制御までを備えた実走可能なスタックである．カメラ知覚の 2D 検出器には YOLOv11 を用い，その出力を yolo3D [15] により 3D 化する構成とする．

知覚から制御までの流れは一方向に進む．まずカメラ画像から，2D 検出器が車両クラスの矩形を出力する．次に 3D 化が行われる．検出されたクラスに応じてテンプレート寸法が与えられ，車両であれば長さ 4.24 m，幅 1.75 m，高さ 1.56 m が初期値となる．奥行きは，この想定 3D 高さと 2D 矩形の画素高さの比に焦点距離を掛けて求める．物体が大きく写るほど近いという遠近の関係を用いており，矩形の画素高さが小さいほど遠方と解釈される．続いてカメラの地上高とピッチ角を用い，物体の足元が路面に接するよう位置を補正する．続いて MOT が行われる．ここでは，フレームごとに得られた検出を時系列で対応付け，同一の物体として繰り返し観測されたものを障害物として確定させる．確定した障害物には，将来の動きの予測が与えられる．この予測をもとに，走行軌道が計画される．前方に障害物があると判断されれば，停止や減速を含む軌道が選ばれる．最後に，選ばれた軌道に追従するよう，ステアリングとアクセル・ブレーキの制御量が決定される．したがって 2D 検出の誤りは，最終的な車両の操作にまで影響を与える．

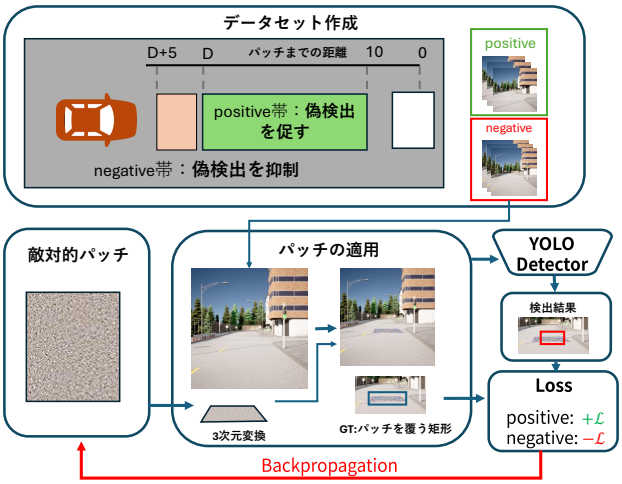


図 2 パッチ生成の流れ

表 1 記号の定義

記号	意味
δ	パッチのテクスチャ
X	シーン画像
X_{adv}	パッチを合成した画像
M	パッチ領域を表すマスク
d	自車からパッチまでの距離
D	positive 帯の終端
Y_{target}	教師（パッチを包含する矩形，車両クラス）
f	対象の検出器
t	EoT で与える変換
λ	正則化の重み

4. 攻撃手法

敵対的パッチ作成の流れを **図 2** に示す．パッチへ接近しながら撮影した画像を CARLA 上で用意し，パッチまでの距離が指定した範囲内にある画像を偽検出を促進する対象，その範囲より遠い画像を抑制する対象として分ける．画像 1 枚ごとにパッチのテクスチャを路面へ投影して合成し，検出器へ入力して，投影されたパッチを包含する矩形を教師とする検出損失を求める．この損失を促進対象では小さく，抑制対象では大きくするよう勾配をテクスチャへ逆伝播し，これを繰り返す．以下では各処理を順に述べる．

4.1 パッチの生成

用いる記号を **表 1** に示す．

レンダリング． パッチは 3 次元空間上の路面に置かれた平面として扱う．パッチ 4 隅の 3 次元座標は，カメラの内部・外部パラメータから定まる射影行列によって画像平面上へ写される．投影された 4 点が囲む領域を 1，それ以外を 0 とするマスク M を作り，テクスチャ δ を合成した画像 X_{adv} を次のように得る．

© 2026 Information Processing Society of Japan

$$X_{adv} = (1 - M) \odot X + M \odot \delta \tag{1}$$

$\odot$ は要素ごとの積である．この一連の変換は微分可能であり，画像上で計算した勾配をテクスチャへ逆伝播できる．

損失関数． 攻撃者の目標は，パッチの領域全体が 1 台の車両として検出されることである．そこで，投影されたパッチを囲う矩形を車両クラスの物体とみなし，これを教師 Y_{target} とする．合成画像 X_{adv} を検出器 f に入力したときの出力が Y_{target} に近づくほど，攻撃は成功に近い．この近さは，検出器が学習時に用いる検出損失 L で測ることができる．

$$L_{det}(\delta, d) = L\big(f(X_{adv}), Y_{target}\big) \tag{2}$$

ここで d は自車からパッチまでの距離であり，X_{adv} と Y_{target} は d に応じて変わる．また，L は分類項だけでなく矩形の位置と大きさに関する項を含む．そのため，得られるパッチは，車両クラスとして検出させるだけでなく，その検出矩形がパッチの投影領域と重なるように働く．これは 3.1 節で述べた，接近する間も同じ位置に物体があると認識され続けるという条件に対応する．

偽検出が生じる距離の制御． 以降，パッチの位置に車両が存在しないにもかかわらず車両クラスの検出が生じることを，偽検出と呼ぶ．

1 章で述べたように，偽の障害物は近距離で突然現れるほうが危険だと考えられる．そこで偽検出が現れ始める距離を制御するため，訓練に用いる画像を距離によって二つに分ける．偽の障害物を出現させる positive 帯（$10 \le d \le D$）では L_{det} を小さくして偽検出を促し，その外側の negative 帯（$D+1 \le d \le D+5$）では逆に大きくして偽検出を抑える．両者をまとめると，最小化する損失は次のようになる．

$$L_{band}(\delta) = \sum_{d \in \mathrm{pos}} L_{det}(\delta, d) - \sum_{d \in \mathrm{neg}} L_{det}(\delta, d) \tag{3}$$

第 2 項の符号が負であるため，negative 帯では検出損失が大きくなる方向，すなわち偽検出が生じにくくなる方向へ最適化が行われる．

EoT による頑健化． 以上は特定の視点に対する損失である．しかし実際には，自車の横位置や向きは走行ごとに変わる．そこで，明度の変動，平滑化，および設置位置と角度の変動を含む変換 t について期待値をとる [10]．さらに，隣接画素間の変化を抑えるため，Total Variation (TV) 損失 [16] による正則化を加える．細かい模様は撮影時のぼけや解像度の低下で失われやすいため，滑らかなパターンのほうが物理環境で機能しやすい．最終的に解く問題は次の通りである．

表 2 距離範囲ごとの偽検出率．negative 帯は positive 帯の終端から 5 m の範囲である

	positive 帯		negative 帯
#	範囲 [m]	偽検出率	偽検出率
1	10–15	0.983	0.000
2	10–20	0.973	0.000
3	10–25	0.994	0.000
4	10–30	0.990	0.000
5	10–35	0.896	0.000
6	10–40	0.887	0.000

$$\delta^{*} = \arg\min_{\delta} \; \mathbb{E}_{t}\big[L_{band}(\delta)\big] + \lambda\,\mathrm{TV}(\delta) \tag{4}$$

negative 帯を設けると，遠方では偽検出が生じなくなる．遠くから接近する車両にとっては，positive 帯の終端 D が偽の障害物の現れる距離になる．

パッチの物理サイズは 3×6 m とし，終端 D を 15, 20, 25, 30, 35, 40 m とした 6 枚を作成する．最適化には Adam を用い，正則化の重みは $\lambda = 0.1$ とした．

5. モデル単体評価

本章では，提案したパッチのデジタル空間上での性能を評価する．具体的には，指定した positive 帯の内側でのみ偽検出が生じるか，また訓練に用いなかった視点条件でも同じ傾向が保たれるかを評価する．

5.1 実験セットアップ

データセットの作成． 画像は，システムレベル評価と同一の CARLA シーンから生成する．パッチまでの距離 10–110 m を 1 m 刻みで 100 通りとり，これに視点条件を組み合わせる．視点は横方向オフセットと視点角度の 2 軸で変化させる．横方向オフセットは車線中心および $\pm$10, $\pm$20, $\pm$40 cm の 7 通りとし，このうち $\pm$10 cm を評価用，残る 5 通りを訓練用とする．視点角度は正面および $\pm 2^{\circ}$, $\pm 4^{\circ}$ の 5 通りである．

合計は $100 \times 7 \times 5 = 3500$ 枚である．横方向オフセットを訓練と評価で分け，訓練に用いなかった視点での挙動を確認する．

訓練に用いるのは，各パッチについて positive 帯と negative 帯に対応する距離の画像のみである．例えば $D = 25$ のパッチであれば，10–25 m と 26–30 m の画像を用いる．評価は 10–110 m の全距離に対して行う．

評価指標． 評価するのは，positive 帯および negative 帯における偽検出率と，各視点角度における positive 帯の偽検出率の平均である．偽検出の判定には，車両クラスの検出信頼度が 0.5 を超えることを条件とする．

5.2 実験結果

距離別の偽検出率を **表 2** に示す．positive 帯の内側では偽検出率が 0.887–0.994 である．一方 negative 帯では，

© 2026 Information Processing Society of Japan



図 3 D=30 における距離ごとの物体検出結果.
（左） 28m ,（中央） 30m ,（右） 32m

表 3 視点角度ごとの positive 帯における偽検出率（6 条件の平均）

$-4°$	$-2°$	$0°$	$+2°$	$+4°$
0.949	0.965	0.990	0.941	0.925

いずれの条件でも偽検出は生じなかった．negative 帯より遠方でも同様である．すなわち偽検出は指定した positive 帯の内側に限られる．終端 D の前後における検出結果の例を **図 3** に示す．$D = 30$ のパッチでは，28 m と 30 m ではパッチ全体が車両として検出されるのに対し，32 m では検出されない．偽検出の有無が終端 D を境に切り替わっている．

視点角度ごとの偽検出率を **表 3** に示す．正面から外れるほど偽検出率は低下するが，$\pm 4°$ の範囲では 0.925 を下回らない．すなわち視点角度が変わっても偽検出は安定して生じる．

以上より，パッチは終端 D 以内で偽検出を生じさせ，その外側では生じさせない．訓練に用いなかった視点条件でも同じ傾向が保たれる．

6. システムレベル評価

本章では，モデル単体評価で確認したパッチを実際に走行環境へ設置し，偽検出が車両の挙動に及ぼす影響を評価する．比較の基準として，同一位置に実車両を置いた条件も併せて評価する．

6.1 実験セットアップ

直線の一車線道路を，巡航速度 50 km/h で走行させる．パッチは車線中央の路面に配置する．自車はパッチの 278 m 手前から走行を開始し，パッチを通過して 70 m 先の地点までを 1 試行とする．

条件は，偽検出させる距離の終端 D を 15, 20, 25, 30, 35, 40 m とした 6 枚のパッチと，2 つの対照からなる．陰性対照はパッチも車両も設置しない条件，陽性対照はパッチを設置せず同一位置に実車両を配置した条件である．いずれの条件についても 6 試行を行う．

対照条件についてもパッチ条件と同数の試行を行う．

評価する値は，最低速度 $v_{\min}$，平均加速度，車両クラスを最初に検出したときのパッチまでの距離，およびブレーキを踏み始めたときのパッチまでの距離である．

平均加速度は，各条件で減速が生じている区間について算出する．攻撃条件では positive 帯（$D = 25$ であれば 10–25 m），陽性対照では検出後の全区間とする．陰性対照では減速がほとんど生じないため，この値は算出しない．



図 4 攻撃時における Apollo の各モジュールの出力（$D = 25$）．(左) 2 次元検出，(中央) 3 次元化と MOT，(右) 計画

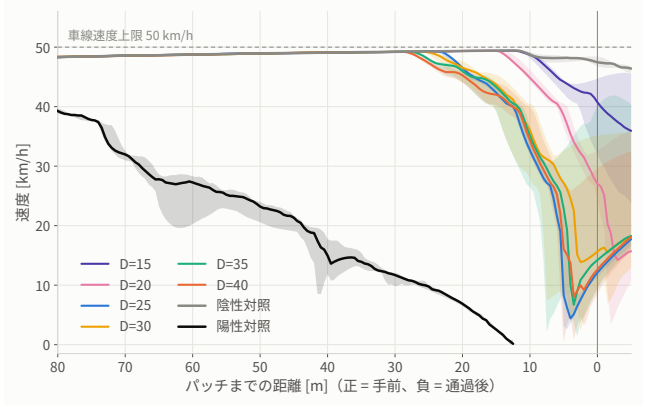


図 5 パッチまでの距離に対する速度プロファイル（実線は中央値，塗りつぶしは最小–最大の範囲を表す）

6.2 結果と考察

結果を **表 4** に示す． 路面に平面の塗装が存在するのみで，物理的な物体は一切設置されていないにもかかわらず，自車は減速した．$D = 25$ の条件では 27.9 m で検出が始まり，23.1 m から制動を開始して 1.6 km/h まで減速している．同一経路でパッチを設置しない陰性対照では $v_{\min}$ が 47.7 km/h であり，6 試行の標準偏差は 0.4 であった．すなわちこの経路では，パッチがなければ減速は生じない．

減速の大きさは終端 D に依存する．$D \leq 20$ m の条件では制動が間に合わず，$v_{\min}$ は 27.8 km/h および 39.2 km/h に留まる．標準偏差は小さく，6 試行を通じて同水準であった．**図 5** においても，この 2 条件の速度プロファイルは他条件から明確に分離している．一方 $D \geq 25$ m では $v_{\min}$ が 1.6–11.9 km/h まで低下する．ただしこの領域では標準偏差が大きく，条件間の差は試行間のばらつきに収まる．図 5 が示す通り，$D \geq 25$ m の 4 条件の速度プロファイルは互いに区別できない．

制動開始位置も同様である．表 4 の初ブレーキの列を見ると，$D = 15, 20, 25$ では終端 D を遠ざけるにつれて制動開始位置も遠くなる（11.4 m，14.1 m，23.1 m）．しかし $D \geq 30$ ではこの対応が成立せず，25.0 m，27.1 m，27.9 m と増分が小さくなる．すなわち，偽検出が起こる距離を遠くしても，より遠方から減速が始まるようにはならない．

© 2026 Information Processing Society of Japan

表 4 システムレベル評価の結果（各条件 6 試行）．$v_{\min}$ は平均 ± 標準偏差．平均 a は，各条件で減速が生じている区間（攻撃条件は positive 帯，陽性対照は検出後の全区間）の平均加速度である．陰性対照では減速がほとんど生じないため算出していない

条件	$v_{\min}$ [km/h]	初検出 [m]	初ブレーキ [m]	平均 a [m/s^2]
$D = 15$	39.2 ± 4.8	14.9	11.4	-3.03
$D = 20$	27.8 ± 2.3	19.7	14.1	-4.41
$D = 25$	1.6 ± 2.6	27.9	23.1	-5.69
$D = 30$	11.9 ± 9.9	32.5	25.0	-4.53
$D = 35$	6.0 ± 11.1	39.2	27.1	-4.97
$D = 40$	5.6 ± 9.3	41.9	27.9	-4.72
陽性対照（実車）	0.0 ± 0.0	≥ 278.4	—	-1.57
陰性対照（物体なし）	47.7 ± 0.4	—	—	—

表 5 制動開始時点における 3D 位置の誤差

条件	実際の距離 [m]	認識距離 [m]	誤差 [m]
$D = 15$	11.4	13.1	1.7
$D = 20$	14.1	19.8	5.6
$D = 25$	23.1	53.7	30.7
$D = 30$	25.0	64.0	39.0
$D = 35$	27.1	76.7	49.6
$D = 40$	27.9	81.4	53.5

原因は 3D 位置推定の誤差にある．制動を開始した時点での認識した障害物への距離の推定結果を **表 5** に示す．偽検出を始める距離が遠いパッチほど，3D 空間上でパッチの実位置よりも大きく遠方に推定されている．$D = 40$ の条件では，制動を開始した 27.9 m の時点で障害物を 81.4 m 先にあると認識しており，誤差は 53.5 m であった．この誤差は自車が接近するにつれて単調に縮小し，制動開始はいずれの条件でも誤差が縮小した後に生じている．

この誤差は，パッチが路面に置かれた平面であることに起因すると考えられる．検出される矩形は路面に沿った横長の形状となり，高さのある物体が生成する矩形とは異なる．3D 化の段階では見かけの大きさから奥行きが推定されるため，高さの小さい矩形は遠方の物体として解釈されうる．

次に，実障害物を置いた陽性対照と比較する．なお陽性対照の初検出距離は自車の走行開始位置に一致しており，表中の値は下限である．

陽性対照では，接近区間全体でブレーキが踏まれていなかった．車両はブレーキ操作を行わず自然な減速によって停止した．図 5 の実車の曲線が長い距離にわたって緩やかに下がり続けていることも，これと対応する．検出後の全区間における平均加速度は -1.57 m/s^2 であった．実車は遠方で検出されるため減速に使える距離が十分にあり，ブレーキ操作を必要としない．これに対し D = 25 のパッチでは制動開始が 23.1 m と遅く，停止までに使える距離が短い．その結果，減速区間における平均加速度は -5.69 m/s^2 と 3.6 倍に達する．パッチは突然出現する障害物として認識され，車両に急な制動を引き起こしている．

7. 議論

7.1 攻撃の限界

本研究のパッチは 2D 検出のみを目的関数としており，3D 位置は最適化の対象に含めていない．そのため，偽検出帯を遠くしても制動開始位置が前進せず，飽和した．

対象システムでは 3D 位置が 2D 検出矩形の形状から決定される．したがって目標とする矩形を選ぶことで 3D 位置を制御しうる．この飽和は対象システム固有の性質ではなく，3D 位置を考慮していない本攻撃の設計によるものである可能性がある．

7.2 今後の展望

急制動がもたらす影響の評価．障害物のない直線路での予期しない急減速は，攻撃対象車の走行を妨げるだけでなく，後続車両にも危険を生じうる．後続車両を配置した条件での追突可能性の評価を今後の課題とする．

3D 位置を制御するパッチ．7.1 節で述べた通り，検出矩形の形状を制御することで 3D 空間上の一貫した位置に物体を認識させられる可能性がある．これが実現すれば，出現距離と制動開始距離の対応が回復し，より遠距離での出現条件を評価できる．

他の 3D 検出手法への評価．障害物として確定した後の挙動，すなわち予測から制御までの過程は，障害物がどの検出手法によって得られたかに依らない．したがって本研究が示した，偽の障害物が近距離で現れたときの車両の影響は，他の物体検出手法でも変わらないと考えられる．一方，どの距離でどれだけ偽検出が生じるかは検出手法ごとに異なる．近年は BEV や Occupancy Prediction といった 3D 検出手法の研究が進んでおり，これらを対象とした攻撃の評価も必要である．

8. 結論

本研究は，敵対的パッチによる出現攻撃が自動運転システムに与える影響を，知覚から制御まで含めたパイプライン全体で評価した．Apollo と CARLA を接続した走行環

© 2026 Information Processing Society of Japan

境で評価した結果，路面に貼った平面のパッチによる誤検出は 2 次元検出にとどまらず，3 次元化と MOT を適用される中で障害物として確定し，予測と計画を経て制御に影響を及ぼした．物理的な物体を置かず，路面の塗装のみで，車両は急な制動を引き起こされた．

この制動は，実在する障害物を置いた場合とは異なる．実車は遠方から検出されるため減速に使える距離が十分にあり，接近区間でブレーキが踏まれることなく自然な減速のみで停止する．これに対しパッチは近距離で突然検出されるため，短い距離で減速する必要が生じ，平均加速度は 3.6 倍であった．

減速の大きさは偽の障害物が現れる距離に依存する．終端が 20 m 以下では制動が間に合わず，速度を大きく残したまま通過した．システムレベルの評価により攻撃が車両挙動に影響するには一定の距離が必要であることが明らかになった．

一方で偽検出帯を遠くしても制動開始位置は 25 m 付近で飽和し，より早く減速を始めさせることはできなかった．三次元位置を目的関数に含めた設計は今後の課題である．

謝辞 本研究の一部は JST CREST JPMJCR23M4 および，JST 国家戦略分野の若手研究者及び博士後期課程学生の育成事業（博士後期課程学生支援）JPMJBS2429 の助成を受けたものです．

参考文献

[1] Thys, S., Ranst, W. V. and Goedeme, T.: Fooling Automated Surveillance Cameras: Adversarial Patches to Attack Person Detection , *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, Los Alamitos, CA, USA, IEEE Computer Society, pp. 49–55 (2019).

[2] Eykholt, K., Evtimov, I., Fernandes, E., Li, B., Rahmati, A., Xiao, C., Prakash, A., Kohno, T. and Song, D.: Robust Physical-World Attacks on Deep Learning Visual Classification , *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, Los Alamitos, CA, USA, IEEE Computer Society, pp. 1625–1634 (online), DOI: 10.1109/CVPR.2018.00175 (2018).

[3] Cao, Y., Wang, N., Xiao, C., Yang, D., Fang, J., Yang, R., Chen, Q. A., Liu, M. and Li, B.: Invisible for Both Camera and LiDAR: Security of Multi-Sensor Fusion Based Perception in Autonomous Driving Under Physical-World Attacks, *IEEE Symposium on Security and Privacy (SP)*, pp. 176–194 (2021).

[4] Wang, N., Luo, Y., Sato, T., Xu, K. and Chen, Q. A.: Does Physical Adversarial Example Really Matter to Autonomous Driving? Towards System-Level Effect of Adversarial Object Evasion Attack, *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 4412–4423 (2023).

[5] Wang, J., Li, F., Lv, S., He, L. and Shen, C.: Physically Realizable Adversarial Creating Attack Against Vision-Based BEV Space 3D Object Detection, *IEEE Transactions on Image Processing*, Vol. 34, pp. 538–551 (online), DOI: 10.1109/TIP.2025.3526056 (2025).

[6] Wang, J., He, L., Yong, Y., Bi, H. and Li, F.: Invisible Triggers, Visible Threats! Road-Style Adversarial Creation Attack for Visual 3D Detection in Autonomous Driving, *AAAI Conference on Artificial Intelligence* (2026).

[7] Jocher, G. and Qiu, J.: Ultralytics YOLO11 (2024). Accessed: 2026-08-17.

[8] Liu, X., Yang, H., Liu, Z., Song, L., Li, H. and Chen, Y.: DPatch: An Adversarial Patch Attack on Object Detectors (2019).

[9] Goodfellow, I. J., Shlens, J. and Szegedy, C.: Explaining and Harnessing Adversarial Examples (2015). arXiv:1412.6572.

[10] Athalye, A., Engstrom, L., Ilyas, A. and Kwok, K.: Synthesizing Robust Adversarial Examples (2017).

[11] Li, L., Lian, Q. and Chen, Y.-C.: Adv3D: Generating 3D Adversarial Examples for 3D Object Detection in Driving Scenarios with NeRF, *2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pp. 10813–10820 (online), DOI: 10.1109/IROS58592.2024.10801323 (2024).

[12] Dosovitskiy, A., Ros, G., Codevilla, F., Lopez, A. and Koltun, V.: CARLA: An Open Urban Driving Simulator, *Proceedings of the 1st Annual Conference on Robot Learning* (Levine, S., Vanhoucke, V. and Goldberg, K., eds.), Proceedings of Machine Learning Research, Vol. 78, PMLR, pp. 1–16 (online), available from ⟨https://proceedings.mlr.press/v78/dosovitskiy17a.html⟩ (2017).

[13] Baidu: Apollo: An Open Autonomous Driving Platform (2017).

[14] Jia, Y., Lu, Y., Shen, J., Chen, Q. A., Chen, H., Zhong, Z. and Wei, T.: Fooling Detection Alone is Not Enough: Adversarial Attack against Multiple Object Tracking, *International Conference on Learning Representations (ICLR)* (2020).

[15] Baidu Apollo: Apollo Model YOLO3D, https://github.com/ApolloAuto/apollo-model-yolo3d. Accessed: 2026-08-17.

[16] Sharif, M., Bhagavatula, S., Bauer, L. and Reiter, M. K.: Accessorize to a Crime: Real and Stealthy Attacks on State-of-the-Art Face Recognition, *Proceedings of the 2016 ACM SIGSAC Conference on Computer and Communications Security*, pp. 1528–1540 (2016).

倫理的配慮

本研究は，シミュレータ上の仮想環境およびオープンソースモデルを用いて評価を行っており，実在する商用システムや特定の個人を対象としていない．また，使用データは全て 3D モデルによって生成されているため，個人情報やプライバシーを侵害する恐れはない．本研究で得られた知見は，敵対的攻撃の脅威を明らかにするとともに，モデルの堅牢性向上や防御手法の構築に資することを目的としており，悪意ある攻撃行為を助長する意図はない．研究の遂行にあたっては，技術の適切な使用に配慮し，倫理的な問題が生じないよう努めた．本研究が，物体検出モデルの脆弱性に対する理解を深め，より安全な AI システムの設計に寄与することを期待している．

© 2026 Information Processing Society of Japan