近傍の物体に擬態した敵対的パッチによるターゲット物体検出の妨害攻撃†

末次 響[1,a)]　鶴岡 豪[1]　斧田 洋人[1]　田中 優奈[2]　野本 一輝[2]　森 達哉[1,3,4]

概要：交通信号認識に対する敵対的攻撃は自動運転システムのセキュリティ上の脅威となるが，視覚的に目立つ敵対的パッチは実環境において気付かれずに設置することが難しい．本論文では，ターゲットである信号機そのものにはパッチを重ねず，信号機の近傍に，道路標識に擬態した敵対的パッチを設置することで，物体検出器によるターゲット物体（信号機）の検出を妨害する攻撃を提案する．信号機の近傍には道路標識が設置されることが多いという実環境の状況に着目し，パッチの模様と外形を道路標識に似せることでステルス性を高める．検出抑制損失，道路標識を模倣するためのカモフラージュ損失，EoT，TV 損失を用いてパッチを最適化する．デジタル実験と，信号機の模型を用いた実世界実験の両面で評価を行った結果，最良のパッチはデジタル実験で 85%の攻撃成功率（ASR）を達成し，実世界実験では複数の条件で 100%の ASR を記録した．これにより，近傍の物体への配置とステルス性を両立した信号機検出妨害攻撃の実現可能性を示す．

キーワード：敵対的パッチ，物体検出，信号機認識，自動運転，物理的敵対的攻撃

Disrupting Target Object Detection via Adversarial Patches Disguised as Nearby Objects

Kyo Suetsugu[1,a)]　Go Tsuruoka[1]　Hiroto Onoda[1]　Yuna Tanaka[2]　Kazuki Nomoto[2]
Tatsuya Mori[1,3,4]

Abstract: Adversarial attacks against traffic light recognition pose security risks to autonomous driving systems, but visually conspicuous patches are difficult to deploy stealthily in real-world environments. This paper presents an adversarial patch attack that, rather than overlaying the target traffic light itself, installs near the traffic light an adversarial patch disguised as a traffic sign, to disrupt the detection of the target object (the traffic light) by an object detector. Motivated by scenarios where traffic signs appear near traffic lights, our method makes the patch resemble a real traffic sign in both pattern and outline to improve stealthiness, and optimizes it using detection suppression loss, traffic-sign-based camouflage loss, EoT, and TV loss. We evaluate the attack in both digital experiments and physical-world experiments with a traffic light mock-up. The best patch achieved 85% ASR in digital experiments, and several physical-world conditions reached 100% ASR, demonstrating the feasibility of a stealthy traffic light detection attack that places the patch on a nearby object while remaining inconspicuous.

Keywords: adversarial patch, object detection, traffic light recognition, autonomous driving, physical adversarial attack

[1] 早稲田大学
Waseda University
[2] デロイト トーマツ サイバー合同会社
Deloitte Tohmatsu Cyber LLC
[3] 情報通信研究機構
National Institute of Information and Communications Technology
[4] 理化学研究所 革新知能統合研究センター
RIKEN Center for Advanced Intelligence Project
[a)] suetsugu@nsl.cs.waseda.ac.jp

† 本研究は著者らの過去の研究 [1], [2](SCIS2026,VehicleSec26) の内容を発展させ，提案する敵対的パッチのステルス性の評価と議論を追加したものである．

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

1. はじめに

米国では無人タクシーが商用運行され，日本国内でも公道実証が各地で進むなど，自動運転技術は実用化の段階に入りつつある．自動運転システムは，複数のタスクが組み合わさることで安全な走行を実現している．特に信号機認識 (Traffic Light Recognition，TLR) は，信号機の表示から通行可否を判断し，自動運転車が交差点を安全に通過する上で重要な機能である．TLR の誤りは，赤信号での交差点進入という致命的な事故を引き起こす．

一方で，TLR は敵対的攻撃 (adversarial attack) に対して脆弱であることが知られている．カメラベースの TLR は，カメラ画像から信号機の位置を特定する「検出」と，検出された信号機の表示色を判別する「状態分類」の 2 段階からなり，そのいずれにも深層学習モデル (DNN モデル) が用いられる．DNN モデルには，入力への微小な摂動によって出力を誤らせる敵対的攻撃への脆弱性が古くから指摘されてきた [3], [4]．さらに，画像に直接摂動を加えるのではなく，印刷したパッチ (adversarial patch) を現実世界に設置することでも同様の誤りを引き起こせることが確認されている [5], [6]．

TLR を標的とした攻撃も既に報告されており [7]，Pavlitska ら [8] は，信号機の近傍に配置した敵対的パッチによって表示色の推定結果を反転させられることを示し，シミュレータおよび実車走行データを用いた評価により攻撃の実現性を確認した．しかし，これらの攻撃はステルス性が低く，攻撃対象も状態分類段階に限られている．明らかに人工的な模様が信号機の脇に貼付されていれば，歩行者や道路管理者による通報・撤去を招き，攻撃を持続させることが難しい．また検出は状態分類の前段に位置するため，検出段階への攻撃が成功すれば，下流の状態分類器がいかに堅牢であってもシステムは信号機の状態に関する情報を一切得られない．一方で，検出段階を標的とした攻撃は検証されていない．

本稿では，ターゲットである信号機そのものにはパッチを重ねず，その近傍に，道路標識に擬態した敵対的パッチを設置することで，TLR の「検出」段階を妨害する攻撃を提案する．本攻撃では，信号機の近傍には道路標識が設置されていることが多いという性質を利用し，パッチの模様と外形を道路標識に似せることでステルス性の向上を図る．また，本攻撃は状態分類の前段である検出段階を標的とするため，状態分類器の性能によらず信号機の検出を妨害できる．攻撃の概要を図 1 に示す．

本研究の貢献は以下のとおりである．

- ターゲットである信号機の近傍に，道路標識に擬態した敵対的パッチを設置することで信号機（ターゲット物体）の検出を妨害する手法を提案し，パッチの位置と擬態対象となる道路標識の種類について網羅的な検証を行い，デジタル上で最大 85 %の攻撃成功率 (ASR) を達成した．
- 提案する攻撃を信号機模型と印刷したパッチを用いて実世界上で評価し，最大 100 %の ASR を達成した．

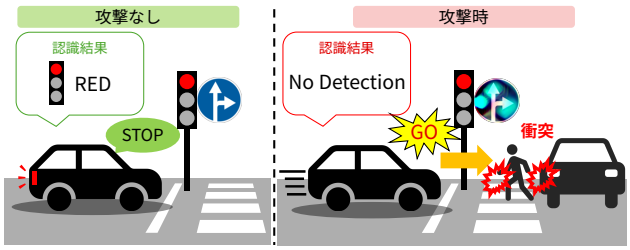


図 1: 提案する攻撃の概要図．

表 1: 信号機認識に対する攻撃の比較

攻撃	標的段階	物理的実現性	ステルス性
Tang ら [7]	検出	○	—
Yan ら [9]	分類	○	—
Yang ら [10]	検出・分類	×	なし
Bhupathiraju ら [11]	状態分類	○	—
Pavlitska ら [8]	状態分類	○	なし
パッチ（本研究）	**検出**	○	**あり**

以降，2 章で信号機認識システムと敵対的攻撃に関する背景および関連研究を述べ，3 章で提案攻撃を定式化する．4 章から 5 章でデジタル環境・物理環境の評価をそれぞれ示し，6 章で議論，7 章でまとめる．

2. 背景と関連研究

2.1 信号機認識システムのプロセス

信号機認識は DNN モデルを用いて道路上の信号機を認識することで実現される．このとき信号機の検出を DNN モデルで行い，次に検出した信号機に対して別の DNN モデルや分類器を用いて状態分類を行う 2 段階方式と，検出と状態分類を単一のモデルで行う 1 段階方式の二つの方式が存在する．本稿では，広く用いられている自動運転スタックである Apollo や Autoware で採用されている 2 段階方式について検討を行う．また，信号機の検出の前段階に HD マップの情報を用いるシステムも存在する．HD マップに記載されている信号機の位置情報を元に，カメラ画像内に映る信号機の位置を推測し，その周辺領域に絞って検出を行う手法である．いずれの方式でも，信号機を認識し，それが赤信号であった場合は，停止線などから停止目標位置を決定し，そこに向けて速度を調節し交差点の手前で適切に停止するよう設計されている．

2.2 信号機認識に対する攻撃

DNN モデルは入力に対する，微小な摂動の混入による敵対的攻撃に脆弱であることが知られている．特に物体検出モデルについては，実世界空間に，検出クラス誤りや検

© 2026 Information Processing Society of Japan

出の妨害を図る，敵対的パッチを配置する攻撃が存在することが報告されている [12], [13]．関連研究について表 1 に示す．信号機認識においても敵対的攻撃を含む攻撃手法について研究されている．Tang らは HD マップを用いる検出システムについて，GPS スプーフィングにより自己位置推定を攻撃することで，信号機の画面内の位置推定を誤らせ検出を妨害している [7]．Yan らは信号機検出用の車載カメラに対してレーザー光を瞬間的に入射することで，信号機位置にレーザー光を干渉させて信号機の状態分類を攻撃した [9]．Yang らは Apollo での信号機認識システムに対して，検出と状態分類に対して画像に摂動をかけ攻撃し，システムレベルで評価を行った [10]．Bhupathiraju らは信号機のライト内にレーザーを入射することでカメラでは偽の点灯があるように見せる攻撃を提案した [11]．Pavlitska らは状態分類を騙す敵対的パッチを提案し，実世界でのシステムレベル評価まで行った [8]．本稿が提案する道路標識に擬態する敵対的パッチは，標的段階を検出のみに絞り，敵対的攻撃の中では考慮されてこなかったステルス性を取り入れた攻撃を行う．

3. 提案攻撃

3.1 脅威モデル

攻撃対象． 本稿が提案する攻撃はカメラベースの自動運転車を対象とする．車両前方を撮影するカメラの映像から，DNN モデルを用いて信号機を検出し，後続の色分類に検出結果を渡すフローを前提とする．

攻撃者の目的: 本攻撃の目的は，信号機認識の検知機能を回避することである．これにより，赤信号にもかかわらず交差点への進入や青信号における急停止が引き起こり他の道路利用者との接触などの事故を引き起こす．

攻撃者の能力: 本研究では，既存のパッチ研究に従い，攻撃者がホワイトボックスであることを仮定する．つまり，攻撃対象の自動運転車の信号機検出モデルについて，アーキテクチャおよびパラメータが既知であることを仮定する．攻撃者は，道路上にパッチを設置する以外のアクセスは行わないことを仮定する．つまり，自動車に搭載されたカメラや内部システムそのものへのアクセスによる改変は行わない．攻撃者が信号機周辺に道路標識を模倣した敵対的パッチを設置する方法は，信号機周辺の既存の道路標識にパッチを上書きする方法と，道路標識を模倣したパッチを新規に設置する方法の 2 つが考えられる．パッチを上書きする方法では，ステッカーやプロジェクターでの投影が具体的な手段となる．新規に設置する方法ではパッチを印刷し信号機周辺に設置することとなる．本稿では印刷して道路標識を模倣したパッチを新設する方法を検証した．

物理的制約: 攻撃者がパッチを新設するにあたり，パッチの大きさや配置を次のように決定した．パッチの大きさは，パッチ生成に用いる DriveU Traffic Light Dataset (DTLD)[14] の画像の信号機とその周辺に配置される標識の大きさを目視で確認し，パッチに外接する正方形の幅を信号機の幅の 2.4 倍とした．この設定は DTLD の画像が撮影されたドイツの規格と整合する．標識の大きさは法令で定められており，通行する車両の速度に応じて，円形であれば直径が 420 mm，600 mm，750 mm と定められている [15]．信号機の横幅はメーカカタログより，ライトの直径に応じて 280 mm，360 mm などと設定されている [16]．これらは設定した 2.4 倍から大きく矛盾しない．

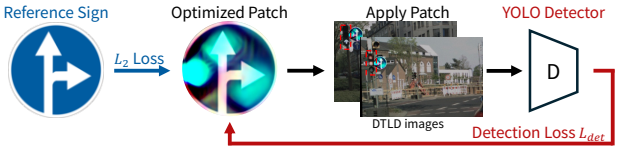


図 2: パッチ生成の概要図.

パッチの位置は，パッチが信号機の筐体と隙間を開けず隣り合うように，上下左右のいずれかの位置に設置することを考える．

3.2 攻撃シナリオ

攻撃者はまず対象とする交差点を選定し，信号機の近傍にある既存の道路標識，あるいは標識を設置しても不自然でない位置 (支柱，ポールなど) を特定する．次に，対象車両が用いる検出器に対して本手法によりパッチを生成し，標識と同等のサイズで印刷して対象位置に設置する．設置されたパッチは通常の道路標識に見えるため，歩行者や周辺住民，道路管理者による撤去を受けにくく，結果として攻撃は長時間にわたって持続する．対象車両が交差点に接近すると，その車載カメラはパッチと信号機を同一視野内に捉え，検出器は信号機を検出できなくなる．

3.3 問題の定式化

本攻撃の中核は，信号機の検出を消す損失と，擬態対象の標識との画素空間での L_2 距離を，単一の目的関数として同時に最小化することである．両者を重み付きで足し合わせることで，標識に見えながら信号機の検出を消すパッチが得られる．概要を図 2 に示す．

物体検出器 D に入力画像 x を与えると，推論時にはアンカーごとの予測 $y_i = (y_i^{\mathrm{box}}, y_i^{\mathrm{conf}}, y_i^{\mathrm{cls}})$ が N 個得られる．y_i^{box} は矩形，y_i^{conf} は物体らしさ (objectness)，y_i^{cls} はクラス確率ベクトルである．非最大値抑制 (NMS) を適用する前のこの出力を最適化の対象とすることで，損失をパッチ画素まで微分可能に保つ．

パッチを $p \in [0,1]^{3\times H_p \times W_p}$，その相対配置を l とし，$A(x,p,l)$ を貼り付け関数とする．A は，対象信号機の矩形 b^* を基準として外接正方形の幅が信号機幅の ρ 倍となるようスケールした p を，l で与えられる相対位置に合成した画像を返す．攻撃者の目的は，$D(A(x,p,l))$ に NMS

© 2026 Information Processing Society of Japan

を適用した結果に b^* と対応する検出が含まれないような p を求めることである．そこで，信号機クラスを TL として，貼り付け後のアンカー i の検出スコアを

$$s_i(p) = y_i'^{\mathrm{conf}} \cdot y_i'^{\mathrm{cls}}[\mathrm{TL}] \tag{1}$$

と定義する．NMS は信頼度しきい値を下回る候補を破棄するため，すべてのアンカーで s_i をしきい値以下に押し下げることが検出の消失に対応する．

3.4 損失関数の設計

前節の方針にしたがい，損失関数を次の重み付き和として設計した．

$$\mathcal{L}(p) = \lambda_{\mathrm{sup}}\mathcal{L}_{\mathrm{sup}}(p) + \lambda_{\mathrm{tv}}\mathcal{L}_{\mathrm{tv}}(p) + \lambda_{\mathrm{cam}}\mathcal{L}_{\mathrm{cam}}(p) \tag{2}$$

第 1 項が攻撃性能，第 2 項が印刷再現性，第 3 項が視覚的自然性を担う．

3.4.1 検出抑制損失 $\mathcal{L}_{\mathrm{sup}}$

検出抑制損失は，式 (1) のスコアがしきい値を超えているアンカーを罰する項である．抑制の対象とするアンカーの集合を $\mathcal{A}$，その要素数を $N_{\mathcal{A}}$ とし，信頼度しきい値 τ と温度 T を用いて $z_i = (s_i(p) - \tau)/T$ と正規化したうえで，各アンカーの罰則を $\phi_i = \mathrm{softplus}(z_i)$ とする．softplus を用いるのは，s_i が τ を下回った領域で勾配を緩やかに減衰させ，すでに抑制済みのアンカーへ最適化資源が費やされることを避けるためである．

ϕ_i の平均のみを最小化すると低スコアのアンカーが勾配を支配し，最大値のみを最小化すると勾配が単一のアンカーに集中して隣接アンカーが検出を担う振動が生じる．そこで，高スコア候補への集中と裾野への滑らかな勾配伝播を両立させるため，Top-k 項と LogSumExp 項の和を用いる．

$$\mathcal{L}_{\mathrm{sup}} = \frac{1}{k}\sum_{i\in\mathcal{K}}\phi_i + w_{\mathrm{lse}}\Big(\log\sum_{i\in\mathcal{A}} e^{z_i} - \log N_{\mathcal{A}}\Big) \tag{3}$$

$\mathcal{K} \subset \mathcal{A}$ は ϕ_i の上位 k 個のアンカー集合である．第 1 項は難例採掘 (hard negative mining) として働き，第 2 項は $\max_i z_i$ の滑らかな上界であって，$\log N_{\mathcal{A}}$ を引くことで候補数に依存しないスケールに正規化している．バッチに対しては各要素で式 (3) を評価し，その平均をとる．

候補集合 $\mathcal{A}$ は対象信号機の近傍に限定する．対象信号機の矩形 b^* を縦横それぞれ α 倍に拡張した領域に予測中心が含まれるアンカーのみを $\mathcal{A}$ とし，該当するアンカーが存在しない場合は全アンカーを対象とする．領域を拡張するのは，パッチの貼付によって検出矩形がわずかにずれた場合にも抑制が働くようにするためである．

3.4.2 平滑化損失 $\mathcal{L}_{\mathrm{tv}}$

印刷およびカメラによる再撮影を経てもパッチの効果が失われないように，隣接画素間の変動を抑える等方的な Total Variation 損失を用いる．位置 (u, v) における RGB 値のベクトルを $p_{u,v} \in [0,1]^3$ と書くと，本項は次のように定義される．

$$\begin{aligned} g_{u,v} &= \|p_{u,v} - p_{u+1,v}\|_2^2 \\ &\quad + \|p_{u,v} - p_{u,v+1}\|_2^2 \\ \mathcal{L}_{\mathrm{tv}}(p) &= \frac{1}{|\Omega|}\sum_{(u,v)\in\Omega}\sqrt{g_{u,v} + \epsilon} \end{aligned} \tag{4}$$

Ω は縦横の差分がともに定義できる画素位置の集合，ϵ は原点における微分可能性を保つための微小量である．縦横の色差を 3 次元ベクトルとして扱うため，色境界が画素位置ごとに 1 つの量としてまとめて罰される．これにより高周波な細部が抑制され，印刷解像度やカメラの点広がり関数によって失われにくい模様となる．

3.4.3 擬態損失 $\mathcal{L}_{\mathrm{cam}}$

パッチを道路標識に近づけるため，擬態対象とする標識画像 s との画素空間での平均二乗誤差 $\mathcal{L}_{\mathrm{cam}}(p) = \|p - s\|_2^2/(3H_pW_p)$ を用いる．s の解像度がパッチと異なる場合は双線形補間でリサイズする．要素数で正規化しているため本項の値はパッチ解像度に依存せず，重み λ_{cam} が攻撃成功率と視覚的自然性のトレードオフを制御する．

また，パッチの外形を標識に一致させるため，擬態対象の標識画像から生成したアルファマスク M を貼り付け時の合成係数として用いる．M が 0 の画素は背景がそのまま残るため，円形標識に擬態する場合はパッチの外形も円形となる．すなわちパッチの**外形**はマスクによって，**模様**は擬態損失によってそれぞれ標識へ近づけている．

3.5 EoT による物理頑健性の確保

デジタル空間だけではなく実世界で攻撃が成功するための最適化手法として，Expectation over Transformation (EoT)[17] を組み込んだ．変換の分布 $\mathcal{T}$ から変換 t をサンプリングし，パッチ貼り付け後の画像に適用したうえで損失を評価する．

$$\min_{p}\ \mathbb{E}_{x\sim\mathcal{X},\,t\sim\mathcal{T}}\big[\mathcal{L}\big(t(A(x,p,l))\big)\big] \tag{5}$$

$\mathcal{T}$ は 4 種の変換の合成であり，等方スケール (信号機までの距離)，輝度スケーリング (照明条件)，回転 (見込み角とカメラの傾き)，加法性ガウスノイズ (センサノイズ) の各パラメータを画像ごとに独立に一様分布から抽出する．いずれも微分可能に実装されており，勾配はパッチ画素まで逆伝播する．本稿の実験では，パッチ単体には輝度スケーリングのみを適用し，貼り付け後の画像全体には拡大縮小・回転・加法性ノイズを適用した．

3.6 最適化手順

最適化手順をアルゴリズム 1 に示す．パッチは一様乱数で初期化し，各ステップで学習画像のミニバッチと変換を

© 2026 Information Processing Society of Japan

Algorithm 1 標識擬態パッチの生成

入力: 検出器 D, 学習画像集合 $\mathcal{X}$, 標識画像 s, マスク M, 配置 l
出力: 敵対的パッチ p

$p \sim \mathcal{U}(0,1)^{3\times H_p \times W_p}$
$\mathcal{L}^{\text{best}} \leftarrow \infty$
for $e = 1$ **to** E **do**
  for ミニバッチ $B \subset \mathcal{X}$ **do**
    $t_p, t_x \sim \mathcal{T}$
    $\tilde{x} \leftarrow t_x\big(A(x, t_p(p), l; M)\big),\ x \in B$
    $s_i \leftarrow$ 式 (1) を $D(\tilde{x})$ から算出
    $\mathcal{L} \leftarrow \lambda_{\text{sup}}\mathcal{L}_{\text{sup}} + \lambda_{\text{tv}}\mathcal{L}_{\text{tv}} + \lambda_{\text{cam}}\mathcal{L}_{\text{cam}}$
    $p \leftarrow \text{clip}_{[0,1]}\big(\text{Adam}(p, \nabla_p\mathcal{L})\big)$
  end for
  エポック平均損失を $\mathcal{L}^{\text{best}}$ と比較し，改善時は p を保持
end for
return 最良損失を与えた p

サンプリングして損失を評価し，Adam によってパッチ画素を更新したのち値域 $[0,1]$ にクリップする．エポックごとの平均損失を監視し，最良損失を与えたパッチを最終出力とする．

4. デジタル環境での評価

4.1 実験設定とパッチ生成

評価には，DTLD で学習した YOLOv5 ベースの検出器を対象モデルとし，GTSRB の標識画像を擬態対象として用いた．検出器は DTLD の 6,657 枚の画像で学習したもので，同一のモデルをパッチ生成と評価の双方に用いるホワイトボックス設定である．擬態対象には，GTSRB 道路標識データセット [18] の 43 クラスそれぞれについて 1 枚ずつ用意された参照画像を用い，43 種類の標識に擬態するパッチをそれぞれ生成した．

パッチは，擬態対象クラスと設置位置の各組合せについて個別に最適化した．設置位置は対象信号機の上・下・左・右の 4 通りとし，パッチ幅はデジタル・実世界の双方の実験を通じて信号機幅の 2.4 倍に固定した．43 クラス × 4 位置の各条件について，同一の DTLD 画像 1,041 枚でパッチを最適化し，学習に用いていない DTLD 画像 1,388 枚で評価した．また，生成されたパッチが意図した標識として認識されることを，GTSRB で学習した ResNet-50 分類器によって確認した．

4.2 評価指標

評価指標には攻撃成功率 (Attack Success Rate, ASR) を用いる．デジタル環境における ASR は，パッチ適用前の画像では検出されていた信号機のうち，パッチ適用後に検出されなくなったものの割合と定義する．検出の同一性は，真のバウンディングボックスとの IoU が 0.5 以上であることをもって判定する．



(a) パッチなしの標識　(b) 最適化したパッチ

図 3: パッチの最適化に用いる標識画像と最適化したパッチ画像

表 2: パッチ設置位置ごとの平均 ASR (デジタル環境，43 クラス平均)

設置位置	左	右	上	下
平均 ASR	0.62	0.58	0.33	0.23

表 3: 擬態対象の外形ごとの平均 ASR (デジタル環境)

外形	円形	非円形
平均 ASR	0.54	0.29

提案手法はデジタル環境で最大 85% の ASR を達成した．この値を示したのは，図 3b に示したパッチを信号機の右側に配置した条件である．

設置位置による差は明確であり，左右への配置が上下への配置より一貫して有効であった．位置ごとの平均 ASR は左 62%, 右 58%, 上 33%, 下 23% であった (表 2)．これは，検出器が信号機の縦長の形状に強く反応しており，水平方向に隣接する物体の方が特徴抽出に干渉しやすいためと考えられる．

擬態対象の外形による差も観測された．円形の標識に擬態したパッチの平均 ASR は 54% であったのに対し，非円形の標識に擬態したパッチでは 29% に留まった (表 3)．円形パッチが有効な理由としては，信号機の灯火部と同様の円形構造が検出器の特徴抽出に干渉している可能性が考えられるが，本稿の範囲では要因の切り分けには至っていない．また，各条件での ASR については付録 A.1.1 に示す．

4.3 ステルス性の評価

本節では，生成されたパッチがどの程度「路側にあって自然なもの」として成立しているかを定量的に評価する．評価は 2 つの側面から行う．すなわち，生成パッチが擬態対象の標識クラスとして分類されるかという意味的整合性と，擬態対象テンプレートとの知覚的距離である．前者には GTSRB データセットで学習したモデルによる分類スコア，後者には LPIPS[19] を用いる．

意味的整合性について，ASR が特に高い左右にパッチを配置した場合で測定した．すべての結果は付録 A.1.3 に示す．GTSRB に含まれる擬態対象のテンプレートの標識

© 2026 Information Processing Society of Japan

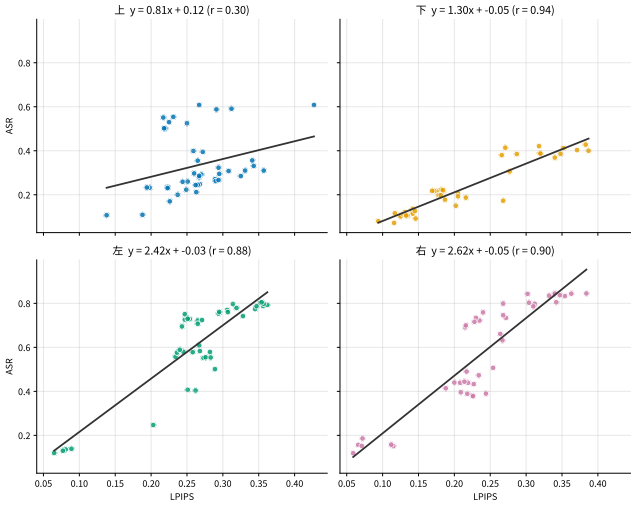


図 4: 上下左右の 4 箇所のパッチ配置における ASR と LPIPS の相関図.

画像の分類では，各クラスの全 43 枚の標識画像のうち，32 枚が正しく分類された．また右側に配置したパッチでは 26 枚が，左側に配置したパッチでは 25 枚が正しく分類された．多数のパッチが分類器に対して元の擬態対象の標識として振る舞うことが示された．分類結果の詳細は付録 A·2A·3A·4 に示す．

知覚的距離について，生成したパッチが擬態対象の標識にどの程度視覚的に近いかを LPIPS (Learned Perceptual Image Patch Similarity) [19] により定量化した．LPIPS は，2 枚の画像を学習済み CNN に入力して得られる中間層特徴の距離を，人間の知覚的類似度判断に一致するよう校正した指標であり，画素単位の差分に基づく L_2 距離や PSNR，SSIM よりも人間の見た目の近さをよく反映することが報告されている．本攻撃は擬態損失として画素空間の L_2 距離を最適化しているため，同じ L_2 距離で評価すれば最適化目的をそのまま測ることになる．そこで最適化に用いていない独立な指標として LPIPS を採用した．

測定は次の手順で行った．生成したパッチと擬態対象のテンプレート画像を，学習時と同一の幾何変換により 256×256 に整形し，標識の外形マスクを両画像に適用することで，標識領域のみを比較対象とした．特徴抽出器には AlexNet を用いた．LPIPS は値が小さいほど視覚的に類似していることを表す．

全パッチの平均 LPIPS は 0.246 であった．配置別では上 0.266，下 0.211，左 0.266，右 0.240 であり，配置による差は小さい．それぞれのパッチの ASR と LPIPS の関係を図 4 に示す．下，左，右の配置では相関係数がそれぞれ 0.94，0.88，0.90 と強い正の相関が見られ，上の配置では 0.30 と弱い正の相関にとどまった．LPIPS は値が小さいほど視覚的に類似していることを表すため，少なくとも下，左，右の配置においては，攻撃成功率と視覚的なステルス性がトレードオフの関係にあることを意味する．LPIPS の詳細は付録の表 A·5 に示す．

表 4: 実験セットアップ.

使用機材	名前
信号機検出モデル	DTLD でファインチューニングした YOLOv5
カメラ	C1-85H
信号機	WDM-JD100-3-RYG

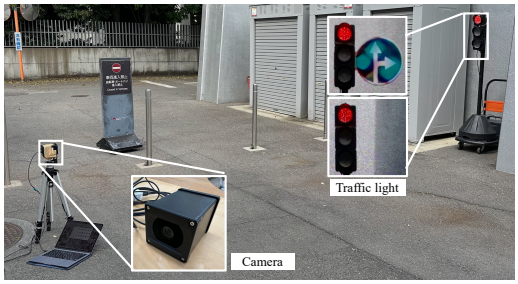
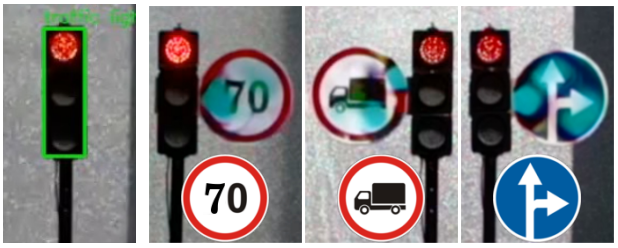


図 5: 実験のセットアップ，パッチを設置した信号機を距離と角度を変えてカメラで撮影する．



(a) Traffic light w/o patch　(b) Traffic light w/ patch

図 6: ベースラインの信号機とパッチを配置した状態の信号機.

5. 物理実験

本稿が提案する攻撃について，デジタル上のみならず物理世界でも有効であり現実的な脅威であることを示すため，物理実験を行なった．まず，物理実験の評価手法について示し，続いてその結果をまとめる．

5.1 実験設計

本稿が提案する攻撃について，静止した環境で，パッチを設置した信号機の映像を撮影し，検出モデルに入力しその検出結果から評価した．

実験環境．実験に使用した機材は表 4 に示す．信号機の検出に用いる検出モデルはデジタル実験で用いた，DTLD でファインチューニングしたものと同じモデルを使用した．また信号機を撮影するカメラは TIER IV 社製の C1 カメラ C1-85H [20] を使用した．信号機は赤，黄，青の 3 色が表示可能な模型である Shenzhen Wide Way Optoelectronics Co., Ltd の WDM-JD100-3-RYG を使用した．実験セットアップを図 5 に示す．

実験設定．本研究では，提案する敵対的パッチの物理環境でのロバスト性を検証するため，6 箇所の距離と角度の撮

© 2026 Information Processing Society of Japan

表 5: ベースラインの検出失敗率と物理環境下での ASR．ベースラインはパッチなしでの失敗率，他の列は ASR.

撮影条件	ベースライン	SL70	NV3.5	GoSR
2.5 m	0.000	0.000	0.000	0.690
5.0 m	0.000	0.043	**1.000**	**1.000**
7.5 m	0.000	**0.887**	**1.000**	**0.970**
10 m	0.003	0.723	0.000	**1.000**
左 30°	0.000	**1.000**	**1.000**	**1.000**
右 30°	0.000	**0.983**	**1.000**	0.353

影地点から，パッチを設置した信号機を撮影した．距離について，信号機と撮影するカメラの距離を 2.5 m，5 m，7.5 m，10 m と設定した．角度については，信号機とカメラの距離を 5 m に保ち，信号機の正面から左右 30° の位置から撮影を行なった．

攻撃に使用する敵対的パッチはデジタル実験で高い ASR を達成した，“Speed Limit 70 (SL70)” を右に配置した場合，“No vehicles over 3.5 t permitted (NV3.5)” を左に配置した場合，“Go straight or turn right ahead (GoSR)” を右に配置した場合の 3 つのパッチを印刷して用いた．これらのパッチは GTSRB で学習した ResNet-50 の分類器により擬態対象の標識と同一クラスに分類されることが確認された．パッチの大きさはデジタル実験と同様に，パッチに外接する正方形の幅が信号機の幅の 2.4 倍となるように設定した．パッチと信号機の位置について図 6 に示す．

評価手法．物理環境下の敵対的パッチは，デジタル実験とは異なる ASR を用いて評価を行なった．評価ではパッチを設置した信号機の映像を 10 秒間撮影し，その映像フレームのうち信号機が検出されなかった割合を ASR と定義した．

5.2 実験結果

実験の結果，物理環境下においても攻撃が成功することが示された．各撮影条件と ASR について，表 5 に示す．ベースラインでは 10 m 以外で検出が 100% 成功し，10 m においても 0.3% の未検出に留まった．攻撃では全 18 条件のうち 11 条件で 80%以上の ASR を達成した．距離が 2.5 m の場合ではすべてのパッチで ASR が低い傾向にある．これは，パッチ生成に用いた DTLD について，近距離のデータが少なかったことに起因すると考えられる．また，GoSR において撮影条件が 2.5 m および左 30° のとき，信号機の位置ではなくパッチの位置に信号機の誤検出が発生した．この検出された領域について， DTLD で学習した ResNet-50 の信号機の状態分類モデルに入力したところ，すべて青信号であると分類された．この事実によって，本稿が提案する敵対的パッチが，自動運転車の信号機の検出段階より後続の処理である状態分類にまで影響を及ぼす可能性があることが示唆される．

6. 議論

6.1 本研究の制約

本研究にはいくつかの制約がある．第一に，攻撃者が検出器のアーキテクチャおよびパラメータを既知とするホワイトボックス設定を仮定している点である．実運用系では内部情報が得られない場合が多く，ブラックボックス条件や転移性の検討が必要である．第二に，評価対象を DTLD で学習した YOLOv5 系の 2 段階方式検出器に限定している点である．最新世代や大規模な検出器，1 段階方式に対する有効性は未検証である．第三に，物理実験が静止環境・信号機模型・限られた距離と角度条件にとどまっている点である．走行中の動的条件や実車での評価は今後の課題である．

6.2 今後の研究方向性

今後の方向性として次が挙げられる．まず，ブラックボックス設定や検出器間の転移性の評価により，より現実的な脅威モデルへ拡張することである．次に，最新かつ大規模な検出器や 1 段階方式，HD マップ併用系を含むより広い対象への評価である．さらに，走行中の動的シーンやシミュレータと実車を統合したシステムレベル評価により，実際の運転判断への影響を定量化することである．加えて，本攻撃に対する防御，すなわち検出の頑健化や近傍領域の異常検知といった対策の検討も重要である．

7. まとめ

本稿では，ターゲットである信号機そのものにはパッチを重ねず，その近傍に道路標識に擬態した敵対的パッチを設置することで，物体検出器による信号機（ターゲット物体）の検出を妨害する攻撃を提案した．提案手法は，信号機の近傍に道路標識が設置されることが多いという実環境の性質を利用し，検出抑制損失，擬態損失，Total Variation 損失，および EoT を組み合わせてパッチを最適化することで，攻撃性能とステルス性を両立させる．評価では，パッチの設置位置と擬態対象とする標識の種類について網羅的な検証を行い，デジタル環境で最大 85% の攻撃成功率（ASR）を，信号機模型を用いた実世界実験で最大 100% の ASR を達成した．これにより，近傍の物体への配置とステルス性を両立した信号機検出妨害攻撃の実現可能性を示した．

ブラックボックス設定や最新の物体検出器への拡張，実践的な物理環境での評価，システムレベルでの評価，および防御手法の検討は今後の課題である．

謝辞 本研究の一部は JST CREST JPMJCR23M4, JST 国家戦略分野の若手研究者及び博士後期課程学生の育成事業（博士後期課程学生支援）JPMJBS2429 の助成を受けたものです．

© 2026 Information Processing Society of Japan

参考文献

[1] 末次 響, 鶴岡 豪, 野本 一輝, 田中 優奈, 斧田 洋人, and 森 達哉. 信号機検出モデルに対する traffic-light hiding attack の評価. In *2026* **年暗号と情報セキュリティシンポジウム予稿集** （*SCIS 2026*）, 2026.

[2] Kyo Suetsugu, Go Tsuruoka, Yuna Tanaka, Kazuki Nomoto, Hiroto Onoda, and Tatsuya Mori. Poster: Cloaking signals with signs: Traffic-Sign-Camouflaged adversarial patches against traffic light detection. In *4th USENIX Symposium on Vehicle Security and Privacy (VehicleSec 26)*, Baltimore, MD, August 2026. USENIX Association. Poster abstract.

[3] Christian Szegedy, Wojciech Zaremba, Ilya Sutskever, Joan Bruna, Dumitru Erhan, Ian Goodfellow, and Rob Fergus. Intriguing properties of neural networks, 2013.

[4] Ian J. Goodfellow, Jonathon Shlens, and Christian Szegedy. Explaining and harnessing adversarial examples. *CoRR*, abs/1412.6572, 2014.

[5] Tom B. Brown, Dandelion Mané, Aurko Roy, Martín Abadi, and Justin Gilmer. Adversarial patch, 2017.

[6] Kevin Eykholt, Ivan Evtimov, Earlence Fernandes, Bo Li, Amir Rahmati, Chaowei Xiao, Atul Prakash, Tadayoshi Kohno, and Dawn Song. Robust physical-world attacks on deep learning visual classification. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2018.

[7] Kanglan Tang, Junjie Shen, and Qi Alfred Chen. Fooling perception via location: A case of region-of-interest attacks on traffic light detection in autonomous driving. In *NDSS AutoSec*, 2021.

[8] Svetlana Pavlitska, Jamie Robb, Nikolai Polley, Melih Yazgan, and J. Marius Zöllner. Fool the stoplight: Realistic adversarial patch attacks on traffic light detectors. In *2025 IEEE Intelligent Vehicles Symposium (IV)*, pages 734–741, 2025.

[9] Chen Yan, Zhijian Xu, Zhanyuan Yin, Xiaoyu Ji, and Wenyuan Xu. Rolling colors: Adversarial laser exploits against traffic light recognition. In *31st USENIX Security Symposium (USENIX Security 22)*, pages 1957–1974, Boston, MA, August 2022. USENIX Association.

[10] Bo Yang and Jinqiu Yang. Sitar: Evaluating the adversarial robustness of traffic light recognition in level-4 autonomous driving. In *IEEE IV*, pages 1068–1075, 2024.

[11] Sri Hrushikesh Bhupathiraju, Takami Sato, Michael Clifford, Takeshi Sugawara, Qi Alfred Chen, and Sara Rampazzi. On the vulnerability of traffic light recognition systems to laser illumination attacks. In *VehicleSec*, 2024.

[12] Simen Thys, Wiebe Van Ranst, and Toon Goedeme. Fooling automated surveillance cameras: Adversarial patches to attack person detection. In *Proc.of CVPR Workshops*, 2019.

[13] Mark Lee and Zico Kolter. On physical adversarial patches for object detection, 2019.

[14] Andreas Fregin, Julian Muller, Ulrich Krebel, and Klaus Dietmayer. The driveu traffic light dataset: Introduction and comparison with existing datasets. In *2018 IEEE International Conference on Robotics and Automation (ICRA)*, pages 3376–3383, 2018.

[15] Bundesministerium für Verkehr, Bau und Stadtentwicklung. Allgemeine verwaltungsvorschrift zur straßenverkehrs-ordnung (VwV-StVO). `https://www.verwaltungsvorschriften-im-internet.de/bsvwvbund_26012001_S3236420014.htm`, 2001.

[16] SWARCO Traffic Systems GmbH. Signale fÜr die zukunft. `https://www.swarco.com/sites/default/files/public/downloads/2019-02/SWARCO_folder_signalgeber_DE_screen_0.pdf`.

[17] Anish Athalye, Logan Engstrom, Andrew Ilyas, and Kevin Kwok. Synthesizing robust adversarial examples. In *ICML*, pages 284–293. PMLR, 2018.

[18] Johannes Stallkamp, Marc Schlipsing, Jan Salmen, and Christian Igel. The German Traffic Sign Recognition Benchmark: A multi-class classification competition. In *IEEE International Joint Conference on Neural Networks*, pages 1453–1460, 2011.

[19] Richard Zhang, Phillip Isola, Alexei A. Efros, Eli Shechtman, and Oliver Wang. The Unreasonable Effectiveness of Deep Features as a Perceptual Metric . In *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 586–595, Los Alamitos, CA, USA, June 2018. IEEE Computer Society.

[20] TIER IV. C1 Camera Hardware Reference Manual. `https://tier4.github.io/edge-auto-docs/camera/reference_manual/C1_technical_reference_manual.htmll`.

8. 倫理的配慮

本研究は，自動運転システムの安全性向上に資することを目的としており，攻撃の悪用を意図するものではない．また，本研究は実際に運用されている自動運転製品や特定の商用システムを攻撃対象とするものではなく，公開データセットと信号機模型を用いた研究用の環境で検証を行っている．実験はすべて管理された環境で信号機模型を用いて実施しており，公道上の実際の交通や車両に影響を与えていない．また，攻撃をそのまま再現可能とする成果物（学習済みパッチや詳細なハイパーパラメーターの一部）の公開については，責任ある開示の観点から慎重に扱う．本研究で明らかにした脅威と対策の知見は，関連するベンダーや研究コミュニティと共有し，防御手法の発展に役立てることを想定している．

© 2026 Information Processing Society of Japan

付　　録

A.1　デジタル実験における ASR，生成したパッチの分類スコアおよび LPIPS

A.1.1　ASR

表 A·1: 各道路標識と配置ごとの ASR.

	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21
																						
上	0.23	0.23	0.53	0.55	0.53	0.55	0.25	0.50	0.50	0.61	0.59	0.26	0.11	0.33	0.59	0.29	0.35	0.61	0.21	0.27	0.25	0.40
下	0.22	0.21	0.22	0.22	0.22	0.22	0.41	0.18	0.20	0.21	0.19	0.14	0.22	0.15	0.20	0.31	0.19	0.17	0.12	0.11	0.13	0.09
左	0.73	0.73	0.73	0.72	0.75	0.72	0.77	0.73	0.70	0.71	0.75	0.58	0.61	0.50	0.56	0.74	0.76	0.55	0.58	0.40	0.58	0.25
右	0.72	0.73	0.72	0.69	0.76	0.70	0.80	0.73	0.75	0.51	0.44	0.38	0.63	0.19	0.44	0.80	0.66	0.39	0.44	0.40	0.43	0.15

	22	23	24	25	26	27	28	29	30	31	32	33	34	35	36	37	38	39	40	41	42
																					
上	0.11	0.40	0.24	0.17	0.24	0.22	0.28	0.23	0.30	0.20	0.26	0.30	0.31	0.31	0.32	0.36	0.31	0.28	0.29	0.26	0.27
下	0.08	0.11	0.10	0.07	0.12	0.12	0.10	0.11	0.11	0.11	0.42	0.39	0.41	0.40	0.39	0.39	0.43	0.40	0.38	0.38	0.37
左	0.14	0.56	0.55	0.12	0.13	0.58	0.58	0.14	0.59	0.41	0.76	0.77	0.79	0.79	0.80	0.80	0.80	0.81	0.80	0.78	0.79
右	0.12	0.16	0.44	0.41	0.16	0.47	0.39	0.15	0.38	0.49	0.80	0.84	0.83	0.84	0.85	0.83	0.84	0.84	0.84	0.80	0.79

A.1.2　ResNet-50 による分類スコア

表 A·2: GTSRB の標識画像に対する分類結果

真クラス	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21
分類クラス	0	1	1	1	4	1	0	1	0	9	10	11	12	13	14	15	16	17	18	19	20	21
分類スコア	0.817	1.000	0.952	0.867	0.869	0.997	0.137	0.270	0.555	1.000	0.996	0.995	1.000	1.000	1.000	1.000	0.834	1.000	1.000	0.593	0.980	0.982

真クラス	22	23	24	25	26	27	28	29	30	31	32	33	34	35	36	37	38	39	40	41	42
分類クラス	22	23	24	25	26	25	28	29	28	28	32	33	34	35	36	37	38	39	39	41	12
分類スコア	0.995	0.996	0.676	0.999	1.000	0.964	0.999	1.000	0.776	0.419	0.388	1.000	0.889	1.000	0.999	1.000	1.000	1.000	0.949	0.848	0.146

表 A·3: 信号機の右側のパッチの分類結果

真クラス	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21
分類クラス	1	1	2	2	4	5	1	1	8	9	10	11	12	13	14	15	0	17	11	26	33	21
分類スコア	0.620	0.998	0.984	0.935	0.999	0.893	0.389	0.642	0.469	0.991	0.992	1.000	1.000	1.000	1.000	1.000	0.811	1.000	0.999	0.319	0.813	0.997

真クラス	22	23	24	25	26	27	28	29	30	31	32	33	34	35	36	37	38	39	40	41	42
分類クラス	25	23	11	25	26	25	28	29	11	11	26	33	34	35	36	37	38	33	39	41	41
分類スコア	0.901	1.000	0.632	0.995	1.000	1.000	0.935	0.702	0.999	0.305	0.422	0.999	0.904	0.473	0.895	0.996	0.998	0.818	0.551	0.318	0.756

© 2026 Information Processing Society of Japan

表 A·4: 信号機の左側のパッチの分類結果

																									
真クラス	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21			
分類クラス	0	1	2	0	4	1	6	1	1	9	10	19	12	13	14	15	16	17	25	11	15	11			
分類スコア	0.999	0.999	0.674	0.369	1.000	0.935	0.759	0.999	0.714	0.990	0.662	0.659	1.000	1.000	1.000	1.000	0.380	1.000	0.986	0.482	0.526	0.364			

																									
真クラス	22	23	24	25	26	27	28	29	30	31	32	33	34	35	36	37	38	39	40	41	42				
分類クラス	25	23	18	25	26	25	28	29	28	11	26	33	15	35	36	37	38	39	39	41	26				
分類スコア	0.966	0.835	0.650	1.000	1.000	1.000	1.000	0.610	0.595	0.669	0.365	0.990	0.997	0.982	0.967	0.999	0.998	0.965	0.961	0.950	0.310				

A.1.3 LPIPS

表 A·5: 各道路標識と配置ごとの LPIPS.

																										
上	0.198	0.194	0.225	0.231	0.250	0.217	0.268	0.220	0.218	0.267	0.291	0.244	0.188	0.343	0.312	0.270	0.265	0.427	0.263	0.289	0.265	0.272			
下	0.175	0.178	0.185	0.172	0.182	0.169	0.271	0.187	0.178	0.205	0.216	0.142	0.184	0.202	0.181	0.277	0.205	0.268	0.141	0.142	0.145	0.146			
左	0.247	0.254	0.251	0.265	0.247	0.271	0.306	0.251	0.243	0.265	0.294	0.245	0.267	0.289	0.234	0.328	0.295	0.273	0.282	0.262	0.268	0.203			
右	0.235	0.230	0.228	0.215	0.240	0.216	0.268	0.272	0.268	0.254	0.219	0.225	0.267	0.072	0.200	0.342	0.264	0.244	0.208	0.209	0.227	0.115			

																										
上	0.138	0.259	0.262	0.226	0.223	0.249	0.267	0.223	0.260	0.237	0.290	0.295	0.308	0.331	0.294	0.341	0.357	0.325	0.267	0.251	0.294				
下	0.094	0.125	0.135	0.116	0.117	0.131	0.125	0.129	0.132	0.133	0.318	0.348	0.352	0.387	0.319	0.320	0.383	0.371	0.266	0.287	0.340				
左	0.081	0.276	0.283	0.065	0.077	0.258	0.236	0.089	0.240	0.251	0.307	0.345	0.356	0.362	0.352	0.352	0.357	0.354	0.314	0.319	0.347				
右	0.059	0.112	0.214	0.188	0.066	0.234	0.218	0.071	0.226	0.217	0.304	0.338	0.332	0.363	0.340	0.354	0.384	0.347	0.302	0.312	0.310				

© 2026 Information Processing Society of Japan