難読化の有無を考慮した可読文字列ベースのアンサンブルマルウェア検知

横山 蓮[1,a)]　青木 茂樹[1,b)]　宮本 貴朗[1]

概要：近年，マルウェアの難読化技術の高度化により，従来のシグネチャベース検知は困難となりつつある．実行ファイル全体を対象とした静的解析は解析コストが高く，難読化の影響も受けやすいという課題がある．そこで本研究では，実行ファイルから抽出した可読文字列に着目した軽量なマルウェア検知手法を提案する．具体的には，抽出した文字列群に対し TF-IDF により有効な単語を選別した後，Doc2Vec を用いて固定長ベクトルへ変換する．さらに，難読化の有無によってデータ分布が異なることを踏まえ，難読化データセット，非難読化データセット，および両者を混合したデータセットでそれぞれ個別に分類器を学習し，各分類器が出力する予測確率を特徴量としてメタモデルによるスタッキングで統合する．FFRI Dataset 2020 を用いた評価により，提案手法が F1-score 0.989 を達成し，単一の分類器を上回る高い検知性能を示すことを確認した．また，TF-IDF による定性分析を通じて，難読化群では機能 API 名が隠蔽される一方，パッカー識別子や復号・展開の処理過程に起因する特徴的な文字列が識別情報として機能することを明らかにし，本手法の妥当性を示した．

キーワード：マルウェア検知，難読化，可読文字列，スタッキング

Obfuscation-Aware Printable String-Based Ensemble Malware Detection

Ren Yokoyama[1,a)]　Shigeki Aoki[1,b)]　Takao Miyamoto[1]

Abstract: Recent advances in malware obfuscation techniques have made conventional signature-based detection increasingly ineffective. Although static analysis of entire executable files has been widely adopted for malware detection, it incurs high computational costs and is highly susceptible to the effects of obfuscation. To address these issues, this study proposes a lightweight malware detection method based on printable strings extracted from executable files. First, informative words are selected from the extracted strings using Term Frequency–Inverse Document Frequency (TF-IDF), and the selected words are transformed into fixed-length feature vectors using Doc2Vec. Considering that feature distributions differ depending on the presence of obfuscation, three individual classifiers are trained using an obfuscated dataset, a non-obfuscated dataset, and a mixed dataset, respectively. Their predicted probabilities are used as features and integrated via stacking with a meta-model. The proposed method was evaluated using the FFRI Dataset 2020, achieving an F1-score of 0.989 and demonstrating superior detection performance compared to single classifiers. Furthermore, qualitative analysis based on TF-IDF revealed that while functional API names are largely concealed in obfuscated malware, packer identifiers and characteristic strings derived from decryption and unpacking processes serve as effective discriminative features, demonstrating the validity of the proposed method.

Keywords: Malware Detection, Obfuscation, Printable Strings, Stacking

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

1. はじめに

近年，ランサムウェアをはじめとするマルウェアによるサイバー攻撃は高度化・巧妙化しており，パッキングや暗号化などの難読化技術の普及に伴い，従来のシグネチャベース検知では捕捉が困難となっている [1]．そのため，未知マルウェアに対しても高い検知性能を有する機械学習を用いた検知手法が数多く提案されている．

従来の機械学習によるマルウェア検知では，アセンブリ命令列，API 呼び出し列，バイト列，あるいは文献 [2] に代表される実行ファイル画像などを特徴量として利用する研究が数多く報告されている．しかし，これらの手法は逆アセンブル等の解析処理や画像変換といった前処理に伴うオーバーヘッドが大きく，高次元データを扱うため計算・メモリ負荷が大きいという課題がある．さらに，難読化によってバイナリ全体の構造や特徴が大きく変化しやすい．

一方，可読文字列は実行ファイルから容易に抽出可能な表層情報であり，API 名，DLL 名，ファイルパス，URL などプログラムの動作を反映する情報を含むことから，前処理および識別処理の双方において軽量な特徴量として注目されている．文献 [3] では，可読文字列を Doc2Vec により特徴ベクトルへ変換し，未知マルウェアを高精度に検知できることが示されている．さらに，可読文字列の出現頻度に基づき特徴語を選択することで，検知性能が向上することも報告されている．

しかし，これらの研究では，可読文字列の特徴分布が難読化の有無によって変化することについて十分に考慮されていない．難読化マルウェアでは API 名や DLL 名などの機能文字列が暗号化や圧縮により隠蔽される一方，復号や展開の処理過程に由来する特有の文字列が表出するという特徴がある．そのため，難読化・非難読化の両方を単一分類器で一括して学習させると特徴分布が混在し，識別境界が複雑化して分類性能が低下する懸念がある．

そこで本研究では，難読化の有無による可読文字列の特徴分布の違いに着目した，高精度かつ軽量なマルウェア検知手法を提案する．本手法ではまず，TF-IDF により選択した有効な特徴語からなる単語列に対し，Doc2Vec を用いて固定長の特徴ベクトルを生成する．次に，難読化データセット，非難読化データセット，および両者を混合したデータセットで個別に学習した 3 種類の分類器を構築する．その後，各分類器が出力する予測確率を特徴量としてメタモデルに入力するスタッキング構成により判定を統合する．また，難読化が可読文字列に与える影響を明らかにするため，TF-IDF による定性分析を行い，難読化・非難読化それぞれにおいて分類に寄与する特徴語の違いについても考察する．

[1] 大阪公立大学大学院情報学研究科
Graduate School of Informatics, Osaka Metropolitan University
[a)] sp25547u@st.omu.ac.jp
[b)] aoki@omu.ac.jp

2. 関連研究

近年，機械学習や深層学習を用いたマルウェア検知手法が数多く提案されている．文献 [4] では，実行ファイルをグレースケール画像へ変換し，畳み込みニューラルネットワーク (CNN) を用いてマルウェアを分類する手法が提案されている．この手法ではバイナリ全体の特徴を利用するため高い分類性能が期待できる一方，画像変換などの前処理に伴うオーバーヘッドが大きく，解析コストが高いという課題がある．また，難読化によってバイナリ全体の特徴が変化するため，検知性能への影響も懸念される．

実行ファイルから抽出した可読文字列は，API 名，DLL 名，ファイルパス，URL など，プログラムの動作を反映する情報を含むため，軽量な特徴量として利用されている．文献 [5] では，可読文字列の中から英単語辞書に登録された単語のみを抽出し，TF-IDF により特徴量を生成した後，SVM を用いてマルウェア検知を行う手法が提案されている．この手法は可読文字列のみを利用することで高速な検知を実現しているものの，辞書に未登録の API 名や DLL 名，パッカー識別子などの有効な特徴語を利用できないという課題がある．

文献 [3] では，可読文字列全体を Doc2Vec によって固定長ベクトルへ変換し，SVM を用いて未知マルウェアを検知する手法が提案されている．Doc2Vec を利用することで単語間の意味的関係を考慮した特徴表現が可能となり，高い検知性能を達成している．しかし，可読文字列全体を学習対象とするため，分類に寄与しない不要な単語も特徴量に含まれるという課題が存在する．そこで同文献では，可読文字列の出現頻度に着目し，良性・悪性それぞれで頻出する単語のみを利用してコーパスを構築する手法も提案されている．不要な単語を削減することで特徴量の質を向上させることができるため，検知性能の改善が報告されている．

文献 [6] では，可読文字列の語順を保持した自己注意機構付き LSTM を用い，自己注意重みから分類に寄与する特徴語を分析している．実験の結果，語順の考慮による精度向上は限定的である一方，分類に寄与する文字列を可視化できることが示されている．

文献 [7] では, 可読文字列に対して One-hot, LSI, Doc2Vec を適用してベクトル表現し，Random Forest，XGBoost，MLP など複数の分類器での識別性能を比較している．FFRI Dataset を用いた評価では，Doc2Vec と MLP の組み合わせが F1-score 0.981 を達成し，可読文字列が最新のマルウェア検知に有効な特徴であることが示された．また，学習データと評価データの年代を変更した実験においても性能が大きく低下しないことから，時系列変化に対し

© 2026 Information Processing Society of Japan

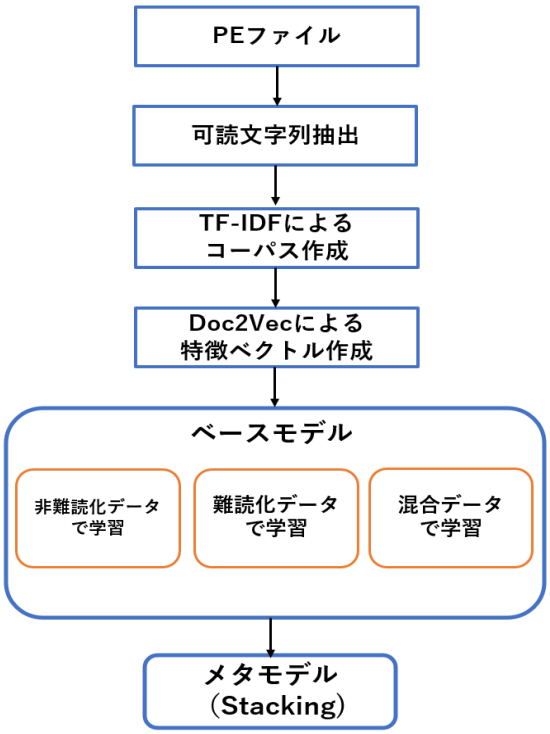


図 1 提案手法の概要
Fig. 1 Overview of the Proposed Method.

ても一定の頑健性を有することが報告されている．

これらの従来研究では，可読文字列の抽出方法や識別モデルの選定に焦点が当てられてきた一方で，難読化の有無によって可読文字列の特徴分布そのものが変化するという観点に着目した研究は見当たらない．また，難読化環境下においてどのような特徴語が識別情報として残存し機能しているかという，定性的なメカニズムの解明に踏み込んだ分析もなされていない．そこで本研究では，難読化の有無に応じたデータ分離学習とスタッキングの導入，およびTF-IDF に基づく定性分析を行うことで，これらの課題に対する新たなアプローチを提案する．

3. 提案手法

提案手法の流れを図 1 に示す．まず，PE ファイルから可読文字列を抽出する．次に，抽出した可読文字列に対して前処理を行い，TF-IDF を用いて重要な単語を選択する．選択した単語列を Doc2Vec により固定長の特徴ベクトルへ変換する．学習段階では，難読化マルウェア，非難読化マルウェア，および両者を混合したデータセットを用いてそれぞれ独立した分類器を学習する．未知検体の評価時には，事前判定を行わずに特徴ベクトルを 3 つの分類器へ同時入力し，各分類器が出力した予測確率をメタモデルへ入力するスタッキングを行うことで最終的な判定結果を得る．

3.1 可読文字列の抽出

PE ファイルには，API 名，DLL 名，ファイルパス，URL，レジストリキーなど，プログラムの動作に関する情報を含む可読文字列が存在する．本研究では，各検体に対して strings コマンド [8] を適用し，ASCII 文字列を抽出する．可読文字列は動的解析を必要とせず，高速かつ容易に取得できるため，軽量な特徴量として利用できる．

抽出した可読文字列に対して，英字を小文字へ統一し，記号を区切り文字として単語へ分割する．さらに，意味を持たない 1 文字および 2 文字の単語を除去し，特徴選択に用いる単語集合を作成する．

3.2 TF-IDF による特徴選択

抽出された可読文字列には，多数の一般的な単語や分類に寄与しない単語が含まれる．これらをそのまま用いると，特徴量が増加し，学習効率や分類性能の低下を招く可能性がある．そこで，本研究では TF-IDF (Term Frequency–Inverse Document Frequency) を用いて各単語の重要度を算出し，特徴選択を行う．

TF-IDF は，ある検体内で頻繁に出現し，他の検体ではあまり出現しない単語ほど高い値を与える指標であり，次式で定義される．

$$\mathrm{TF\text{-}IDF}(t,d) = \mathrm{TF}(t,d) \times \log \frac{N}{\mathrm{DF}(t)} \qquad (1)$$

ここで，$\mathrm{TF}(t,d)$ は文書 d における単語 t の出現頻度 (Term Frequency)，$\mathrm{DF}(t)$ は単語 t を含む文書数 (Document Frequency)，N は全文書数を表す．本研究では，訓練データ全体において算出された TF-IDF スコアの上位 600 単語を特徴語として採用し，それ以外の単語を除去することで，分類に有効な情報のみを保持したコーパスを構築する．

3.3 Doc2Vec による特徴ベクトル生成

TF-IDF により選択した単語列を Doc2Vec へ入力し，各検体を固定長の特徴ベクトルへ変換する．Doc2Vec は，Mikolov らによって提案された Paragraph Vector の実装の一つであり，単語ベクトルを生成する Word2Vec を文書単位へ拡張した手法である．Word2Vec は，単語の前後関係（文脈）をニューラルネットワークによって学習し，各単語を意味的特徴を保持した低次元ベクトルとして表現する．一方，Doc2Vec では単語ベクトルに加えて文書ベクトルを同時に学習することで，文書全体の意味的特徴を固定長ベクトルとして表現することができる．

Paragraph Vector には，Continuous Bag-of-Words (CBOW) モデルを拡張した Paragraph Vector with Distributed Memory (PV-DM) と，Skip-gram モデルを拡張した Paragraph Vector with Distributed Bag of Words (PV-DBOW) の 2 種類が提案されている．PV-DM は周辺単語

© 2026 Information Processing Society of Japan

と文書ベクトルから対象単語を予測することで文書の意味を学習するのに対し，PV-DBOW は文書ベクトルから文書内の単語を予測することで文書全体の特徴を学習する．

本研究では，各検体から抽出した可読文字列群を 1 つの文書として扱い，Doc2Vec を用いて固定長の文書ベクトルを生成する．生成された文書ベクトルは，可読文字列の出現頻度だけでなく単語間の意味的関係も反映しているため，分類器への入力特徴量として用いることで，高精度なマルウェア検知が期待できる．

なお，評価データの情報が特徴抽出過程に混入することを防ぐため，TF-IDF による特徴語選択および Doc2Vec の学習には訓練データのみを使用する．

3.4 難読化の有無を考慮したアンサンブル学習

難読化マルウェアでは API 名や DLL 名などの機能を直接表す文字列が暗号化や圧縮により隠蔽されるものの，復号や展開の処理過程に起因する特有の文字列が多く出現する傾向がある．これに対し，非難読化マルウェアでは，Windows API 名や DLL 名をはじめとする機能を反映した文字列がそのまま豊富に含まれる．このように，可読文字列の特徴分布は難読化の有無によって大きく異なるため，同一の分類器で両者を一括して学習させると識別境界が複雑化し，分類性能が低下する可能性がある．

そこで本研究では，難読化マルウェアおよび難読化クリーンウェアからなる難読化データセット，非難読化マルウェアおよび非難読化クリーンウェアからなる非難読化データセット，ならびに両者を含む混合データセットを作成し，それぞれを用いて 3 種類の分類器を学習する．各分類器は入力された検体に対してマルウェアである予測確率を出力する．これら 3 つの予測確率を新たな特徴量とし，メタモデルへ入力することで最終判定を行うスタッキングを採用した．

メタモデルの学習用特徴量を生成するため，訓練データ 16,000 検体に対して 5-fold 交差検証を行い，各 fold で得られた out-of-fold 予測確率を用いた．なお，5-fold 交差検証は最終性能の評価ではなく，メタモデル学習用の out-of-fold 予測を生成するために訓練データ内部で実施した．各検体について，難読化用，非難読化用，混合用の 3 分類器が出力するマルウェア確率を 3 次元の特徴ベクトルとして構成し，メタモデルを学習した．評価時には，未知検体の難読化の有無に関わらず，全訓練データで再学習した 3 つのベースモデルに特徴ベクトルを入力し，得られた予測確率をメタモデルへ入力した．

難読化・非難読化それぞれに特化した分類器と，全体的な特徴を学習した分類器を組み合わせることで，各分類器の長所を活かし，単一分類器では捉えにくい特徴を補完できると考えられる．

4. 実験

4.1 データセット

実験には，FFRI Dataset 2020[9] に収録されているクリーンウェア 75,000 件およびマルウェア 75,000 件のうち，それぞれ 10,000 件ずつを抽出した計 20,000 件を用いた．その内訳は，マルウェア・クリーンウェアともに難読化検体 5,000 件，非難読化検体 5,000 件である（表 1）．

本研究では，検体の難読化の有無を判定するため，情報エントロピーおよび PEiD による解析結果を用いた．情報エントロピーは実行ファイル内のデータのランダム性を表す指標であり，パッキングや暗号化が施された実行ファイルでは高い値を示す傾向がある．一方，PEiD は既知のパッカーやプロテクタを識別するツールである．文献 [10] ではパッキング済み実行ファイルの平均エントロピーとして 6.801 が報告されており，文献 [11] では既存研究および解析ツールにおいて 7.0 が高エントロピーの基準として利用されていることが示されている．本研究ではこれらを参考に，情報エントロピーが 6.8 以上であり，かつ PEiD によってパッカーまたはプロテクタが検出された検体を難読化検体と定義し，それ以外を非難読化検体として扱った．単一の指標では高圧縮な良性データ等による誤判定が生じる可能性があるため，両者を組み合わせることで難読化ラベルの確実性と純度を高めた判定を行っている．

これらの基準に基づき，難読化の有無による特徴分布の違いを検証するため，(1) 難読化検体のみ，(2) 非難読化検体のみ，(3) 両者を混合した検体の 3 種類の学習データセットを作成した．各データセットを用いてそれぞれ分類器を学習し，スタッキングによって統合した場合の検知性能を評価した．

4.2 実験条件

実験では，全 20,000 検体を訓練データ 80% と評価データ 20% に分割し，16,000 検体を訓練，4,000 検体を評価に使用した．

各検体から抽出した可読文字列に対して前処理を行った後，TF-IDF による特徴語選択を行った．このとき，評価データの情報が特徴抽出に混入することを防ぐため，TF-IDF の算出および特徴語の選択には訓練データのみを使用した．また，Doc2Vec についても訓練データのみを用いて学習し，評価データについては学習済み Doc2Vec モデルを用いて固定長特徴ベクトルへ変換した．Doc2Vec には PV-DM を採用し，ベクトル次元数を 100，学習エポック数を 30 と設定した．

生成した特徴ベクトルを入力として Random Forest 分類器を学習した．訓練データ 16,000 検体のうち，難読化検体 8,000 件（マルウェア・クリーンウェア各 4,000 件）を

© 2026 Information Processing Society of Japan

表 1 実験に使用した検体数
Table 1 Number of Samples Used in the Experiments.

	難読化	非難読化	合計
マルウェア	5,000	5,000	10,000
クリーンウェア	5,000	5,000	10,000
合計	10,000	10,000	20,000

表 2 各分類器の検知性能
Table 2 Detection Performance of Each Classifier.

学習データ → 評価データ	F1-score
非難読化検体でのみ学習した分類器	0.987
難読化検体でのみ学習した分類器	0.978
難読化・非難読化を混合した分類器	0.930
提案手法（スタッキング）	**0.989**

表 3 スタッキング構成による性能比較
(1) 難読化, (2) 非難読化, (3) 混合
Table 3 Comparison of Different Stacking Configurations.
(1) Obfuscated, (2) Non-obfuscated, (3) Mixed

スタッキングに用いた分類器	F1-score
全分類器（提案手法）	**0.989**
(1) + (2)	0.820
(1) + (3)	0.963
(2) + (3)	0.941
単純平均	0.933

用いて難読化用分類器，非難読化検体 8,000 件（マルウェア・クリーンウェア各 4,000 件）を用いて非難読化用分類器を構築した．また，両者を合わせた 16,000 件を用いて混合分類器を構築した．各分類器が出力するマルウェアの予測確率をスタッキングの入力特徴量とし，メタモデルには Gradient Boosting (GB) を採用した．

メタモデルの学習には，ベースモデルの訓練データに対する直接の予測値を使用することによる過学習を防ぐため，交差検証によって得られた out-of-fold 予測確率を用いた．具体的には，全 16,000 件の訓練データを共通の 5-fold に分割し，各 fold の学習データ内で難読化・非難読化・混合の各ベースモデルを構築して検証 fold へ適用することで，訓練データ全体に対するデータリークのない 3 次元特徴量を生成した．評価時には，全訓練データで再学習した各ベースモデルが評価データに対して出力した予測確率をメタモデルへ入力し，最終的な分類結果を得た．分類性能の評価指標には Accuracy および F1-score を用い，特に F1-score を主な評価指標として比較を行った．

4.3 実験結果・考察

各分類器における F1-score の評価結果を表 2 に示す．すべての分類器について，難読化検体および非難読化検体の両方を含む同一の評価データ 4,000 検体を用いて性能を評価した．

単一分類器の比較では，非難読化検体のみで学習した分類器が F1-score 0.987，難読化検体のみで学習した分類器が 0.978 となり，難読化・非難読化を混合して学習した分類器の 0.930 を大幅に上回った．混合分類器は 2 倍の学習データ数 (16,000 件) を有しているにもかかわらず性能が低迷したことから，性質の異なる特徴分布を単一モデルで一括学習させることが決定境界の複雑化を招き，識別性能を低下させることが実証された．すなわち，単にデータ量を増加させるよりも，難読化の有無に応じてデータを分離し，それぞれの特徴分布に特化した学習を行う方が有効であることが示された．

一方，非難読化用分類器が単体で F1-score 0.987 と高い性能を示した要因として，可読文字列の中には難読化の有無に関わらず残存する基本的な悪性動作に関連する文字列（共通特徴）が含まれており，これらが一定の識別能力に寄与したためと考えられる．しかし，暗号化や圧縮により機能文字列が隠蔽され，難読化処理固有の文字列へと特徴が推移した検体に対しては，非難読化用分類器単体では十分な識別精度を維持することに限界が生じると考えられる．

3 種類の分類器を Gradient Boosting を用いたスタッキングによって統合した提案手法では，最高値となる F1-score 0.989 を達成し，単一分類器の最高値 (0.987) を上回った．実験条件の違いに留意する必要はあるものの，可読文字列を用いた文献 [7] の報告値 (F1-score 0.981) と比較しても，提案手法は優れた検知性能を示した．

各スタッキング構成における比較結果を表 3 に示す．ここで，難読化用分類器 (1) と非難読化用分類器 (2) の 2 種類のみを組み合わせた場合，F1-score は 0.820 まで著しく低下した．これは，それぞれの分類器が特定の分布のみに特化して学習しているため，学習領域外（ドメイン外）の検体に対して不確実あるいは偏った予測確率を出力しやすく，2 者の予測値のみではメタモデルが妥当な判定境界を形成できないためであると考えられる．これに対し，データ全体を学習した混合分類器 (3) を加えることで，全体的な分布に基づく判定基準（ベースライン）が提示され，局所的な予測の不確実性が補正される．この結果，全域的な識別基準と領域特化型の補正信号が相互に補完し合い，3 分類器を統合した構成において最も高い識別性能が得られることが明らかとなった．

4.4 TF-IDF による特徴語分析

難読化群において高い TF-IDF 値を示した特徴語を表 4 に示す．Themida や FSG などのパッカーおよびプロテクタ関連語に加え，PSVW，PQVW，PQSVW，SVW3 などの短縮識別子，Load，Virtual，get などの動的ロード・メモリ管理に関連し得る語が確認された．また，Veri，verisign，Symantec，Trust などのコード署名・証明書関連語や，ZYYd，SSSSS，VVVVV，Nk0t，1YWe0 などの

© 2026 Information Processing Society of Japan

表 4 難読化群において高い TF-IDF 値を示した特徴語の分類
Table 4 Classification of Terms with High TF-IDF Scores in the Obfuscated Group.

分類	特徴語	TF-IDF 値
パッカー／プロテクタ関連語	Themida	0.0389
	FSG	0.0299
短縮識別子・パターン文字列	PSVW	0.0513
	PQVW	0.0352
	PQSVW	0.0318
	SVW3	0.0567
動的ロード・メモリ管理関連語	Load	0.1132
	Virtual	0.0617
	get	0.0721
コード署名・証明書関連語	Veri	0.0817
	verisign	0.0379
	Symantec	0.0679
	Trust	0.0277
非自然言語的文字列	ZYYd	0.0892
	SSSSS	0.0586
	VVVVV	0.0502
	Nk0t	0.0469
	1YWe0	0.0300

非自然言語的文字列も高い値を示した．

これらの結果から，難読化検体ではパッカー名のような明示的な識別子だけでなく，短縮識別子や非自然言語的文字列も有効な識別特徴として残存することが確認された．したがって，可読文字列は難読化環境下においても有効な識別特徴であり，難読化群に特化した分類器を組み込む本手法の有効性を裏付ける結果が得られた．

5. まとめ

本研究では，難読化の有無による可読文字列の特徴分布の違いに着目し，複数の分類器をスタッキングによって統合するマルウェア検知手法を提案した．提案手法では，PE ファイルから抽出した可読文字列に対して TF-IDF による特徴語選択を行い，Doc2Vec により固定長ベクトルへ変換した．さらに，難読化データセット，非難読化データセット，および両者を含む混合データセットからそれぞれ Random Forest 分類器を学習し，各分類器が出力する予測確率をメタモデルによって統合した．

FFRI Dataset 2020 から抽出したクリーンウェア 10,000 件およびマルウェア 10,000 件を用いて実験した結果，非難読化検体のみで学習した分類器では F1-score 0.987，難読化検体のみでは 0.978 となり，混合データのみで学習した分類器の 0.930 を上回った．この結果から，難読化の有無に応じた分離学習の有効性が示された．さらに，3 種類の分類器を統合した提案手法では F1-score 0.989 を達成し，本実験において最も高い検知性能を示した．また，2 種類の分類器のみを組み合わせた構成（F1-score 0.820 ～ 0.963）と比較しても，3 種類すべての分類器を統合する構成が最も有効であることを確認した．

TF-IDF による特徴語分析では，難読化群においてパッカー／プロテクタ関連語に加え，短縮識別子，動的ロード・メモリ管理に関連し得る語，コード署名・証明書関連語，非自然言語的文字列が高い値を示した．このことから，難読化が施された検体においても，その処理やファイル構造に由来する可読文字列が識別特徴として残存することが確認され，難読化環境下における可読文字列解析の有効性を定性的に裏付ける知見が得られた．

今後の課題としては，異なる年度の FFRI Dataset や異なる収集環境のデータを用いて提案手法の汎化性能を評価することや，PEiD では識別が困難な文字列暗号化や制御フロー難読化なども含め，難読化手法ごとの特徴分布および検知性能への影響を詳細に分析することなどが挙げられる．

参考文献

[1] キヤノン IT ソリューションズ: CYBERSECURITY REPORT THE FIRST HALF OF 2021 (オンライン), https://eset-info.canon-its.jp/files/user/malware_info/images/ranking/pdf/MalwareReport_2021FirstHalf.pdf (参照 2026-08-13).

[2] 高橋徹朗，三橋力麻，西垣正勝，大木哲史: ファイル情報を考慮した画像ベース難読化マルウェア検出手法の検討，コンピュータセキュリティシンポジウム 2024，pp. 1734–1741 (2024).

[3] 伊藤良，三村守，田中秀磨: 出現頻度の高い可読文字列を用いた未知のマルウェアの検知手法，コンピュータセキュリティシンポジウム 2018，pp. 454–461 (2018).

[4] Yakura, H., Shinozaki, S., Nishimura, R., Oyama, Y. and Sakuma, J.: Neural Malware Analysis with Attention Mechanism, *Computers & Security*, Vol. 87, 101592 (2019).

[5] Ye, Y., Chen, L., Wang, D., Li, T., Jiang, Q. and Zhao, M.: SBMDS: An interpretable string based malware detection system using SVM ensemble with bagging, *Journal in Computer Virology*, Vol. 5, No. 4, pp. 283–293 (2009).

[6] 菅野賢輝，三村守: 自己注意機構を用いたマルウェアの検知手法の提案，コンピュータセキュリティシンポジウム 2022，pp. 1020–1027 (2022).

[7] Mimura, M.: Evaluation of printable character-based malicious PE file-detection method, *Internet of Things*, Vol. 19, 100521 (2022).

[8] Microsoft Corp.: strings (オンライン), https://learn.microsoft.com/ja-jp/sysinternals/downloads/strings (参照 2026-08-13).

[9] 寺田真敏，秋山満昭，松木隆宏，畑田充弘，篠田陽一: マルウェア対策のための研究用データセット MWS Datasets ～コミュニティへの貢献とその課題～，情報処理学会研究報告，Vol. 2020-IFAT-139, No. 8, pp. 1–6 (2020).

[10] Lyda, R. and Hamrock, J.: Using Entropy Analysis to Find Encrypted and Packed Malware, *IEEE Security & Privacy*, Vol. 5, No. 2, pp. 40–45 (2007).

[11] Mantovani, A., Aonzo, S., Ugarte-Pedrero, X., Merlo,

© 2026 Information Processing Society of Japan

A. and Balzarotti, D.: Prevalence and Impact of Low-Entropy Packing Schemes in the Malware Ecosystem, *Network and Distributed System Security Symposium (NDSS)* (2020).

© 2026 Information Processing Society of Japan