階層型カルマンフィルタに基づく 大規模時空間統計データへの 差分プライバシー適用における有用性向上

赤塚 裕人[1,2]　萩原 淳一郎[3,1]　寺田 雅之[4,5]

概要：人口統計などの大規模時空間地理データを差分プライバシーの下で公開する取り組みが進んでおり，米国国勢調査の TopDown Algorithm や非負 Wavelet 法など，空間階層に沿ってノイズを注入する機構が代表的な設計となっている．これらの機構は，空間の階層分解で得られる係数ごとに独立なノイズを加えて統計を再構成するが，各時点のデータを独立に保護・公開する設計であり，時系列方向の構造は活用されていない．本稿では，各係数の公開値の時系列に階層型カルマンフィルタを適用し，注入されたノイズを低減する手法を提案する．本手法は，ノイズ分散が異なる階層ごとに独立なモデルを置き，そのパラメータを公開値のみから同定するとともに，非負性や集計値の整合といった統計としての要件を満たすことを特長とする．実運用規模の数値実験により，提案手法が適用前の出力と比べいずれの階層・空間スケールの精度も悪化させず，特に細粒度セルの誤差を大きく削減することを示す．

Hierarchical Kalman Filtering for Differentially Private Large-Scale Spatio-Temporal Statistical Data

Hiroto Akatsuka[1,2]　Junichiro Hagiwara[3,1]　Masayuki Terada[4,5]

Abstract: Large-scale spatio-temporal geographic data such as population statistics are increasingly released under differential privacy, and mechanisms that inject noise along a spatial hierarchy, including the U.S. Census TopDown Algorithm and the non-negative wavelet method, are representative designs. These mechanisms add independent noise to each coefficient of a hierarchical spatial decomposition and reconstruct the statistics, but protect and release each time point independently, leaving the temporal structure unexploited. We propose reducing the injected noise by applying hierarchical Kalman filtering to the released time series of each coefficient. The proposed method places an independent model on each level, reflecting the level-dependent noise variance, identifies its parameters solely from released values, and satisfies statistical requirements such as non-negativity and consistency of aggregates. Numerical experiments at operational scale show that the method does not degrade accuracy at any level or spatial scale compared with the original output, while substantially reducing the error of fine-grained cells.

[1] 京都橘大学 情報学教育研究センター
Center for Informatics Research and Education, Kyoto Tachibana University
[2] 株式会社アト
Ato Inc.
[3] 武庫川女子大学 社会情報学部
School of Social Informatics, Mukogawa Women's University
[4] 京都橘大学 工学部
Faculty of Engineering, Kyoto Tachibana University
[5] 株式会社 NTT ドコモ
NTT DOCOMO, INC.

1. はじめに

人口統計をはじめとする大規模な時空間地理データを，差分プライバシー（differential privacy; DP）[1] の保証の下で公開する取り組みが実運用の段階に入っている．米国国勢調査局は 2020 年国勢調査において，行政区分の階層に沿ってノイズを注入する TopDown Algorithm [2] により統計を作成・公開した．国内でも，空間の階層分解で得られ

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

る係数ごとに独立なノイズを加え，非負性を保って統計を再構成する非負 Wavelet 法（以下，NNW 法）[3] が提案されており，国勢調査データを用いて，TopDown Algorithm との精度比較が行われている [4]．これらはいずれも，ノイズを空間階層に沿って注入することで，単純なセル単位のノイズ付与では避けられない広域集計値の誤差蓄積を抑える設計である．本稿では，大規模な地理空間データが周期的に繰り返し公開されるシナリオにおいて，NNW 法と階層型カルマンフィルタを組み合わせ，広域集計値の誤差蓄積を抑えながら，さらにノイズを低減する手法を提案する．

人口分布や交通量分布などの地理空間データが，10 分ごと・1 時間ごとなどの周期で繰り返し最新時点のデータが公開される場合，各時点のデータは独立に保護・公開される．このとき，公開データの値の列は，真値の時系列にノイズが加わった系列となる．真値の時系列には強い連続性があるのに対し，ノイズは時点間で独立である．これは，各時点の保護の強さを変えないまま，時系列方向の情報を用いたフィルタリングによって統計の有用性をさらに高めうることを示唆する．実際，時系列 DP の分野では，ユーザレベルの FAST [5]，本稿と同じイベントレベルの PeGaSus [6]，w-event の RescueDP [7] など，平滑化・フィルタはストリーム公開の標準的な構成部品である．しかし，空間階層に沿ってノイズを注入する機構に，時系列情報を活用するフィルタを組み合わせてノイズを低減する方法は，著者らの知る限りこれまで検討されていない．

ここで，NNW 法とフィルタの組み合わせの方法は自明ではなく，フィルタの結合位置，モデル共有の粒度，パラメータ同定の方法，フィルタ後の統計要件の回復という，少なくとも 4 つの設計課題がある．3 章ではこれらの課題に対する提案手法の設計を与える．日本全国の人口分布データであるモバイル空間統計を用いた評価実験により，統計要件を満たす手法の中でセル単位の誤差が最小の水準にあり，かつ全スケールの広域集計値で NNW 法出力を悪化させない手法が，提案手法のみであることを示す．

2. 準備

2.1 差分プライバシー

差分プライバシー（DP）[1] は，1 レコードだけ異なる 2 つのデータベース D, D'（隣接データベース）に対する出力の確率分布の近さによってプライバシー保護を定義する基準である．ランダム化された機構 M が任意の隣接対と任意の出力集合 S に対して

$$\Pr[M(D) \in S] \leq e^{\varepsilon} \Pr[M(D') \in S]$$

を満たすならば，M は ε-DP を満たすという．ε は小さいほど保護が強い．代表的な実現手段が Laplace 機構であり，問合せの感度 Δ に対しスケール Δ/ε の Laplace ノイズを出力に加える．また DP は，保護済みの出力に元データを参照しない変換を施しても保証が劣化しないという後処理不変性を持つ [8]．

なお，本稿で対象とする保証単位は各時点のスナップショットであり，時点ごとの公開がそれぞれ独立に ε-DP を満たす設計を扱う．複数時点にわたる保証の合成はスコープ外とし，5 章で関連研究と併せて整理する．

2.2 非負 Wavelet 法

NNW 法 [3] は，人口メッシュ統計のような大規模かつ疎な集計データに対し，Laplace 機構の実用上の 3 課題（非負制約の逸脱・部分和精度の劣化・計算量の増大）を同時に解決する機構であり，本稿の提案手法で部品として用いる．NNW 法は次の 4 つの工程からなる．工程 1（1 次元化）では，2 次元のメッシュ空間を局所性保存写像で 1 次元の系列に並べ替える．工程 2（階層分解）では，Haar ウェーブレット変換により，最も細かい段 1 から最上位の段 L までの差係数と，全体平均にあたる最上位近似係数を得る．工程 3（ノイズ注入）では，各係数に独立な Laplace ノイズを加える．ノイズのスケールは，全体で ε-DP を満たすよう感度を階層に配分して定まる，段ごとの公開定数（設計値）であり，係数あたりの設計ノイズ分散は段を 1 つ降りる（細かくなる）ごとに 4 倍となる．工程 4（精緻化処理と再構成）では，係数列を上位から降下しながらウェーブレット逆変換する際，出力の非負性が保たれるように，親の値と整合しない差係数を許容範囲へ切り詰めて統計を再構成する．各工程の詳細は付録 C に示す．

この一連の処理の出力は ε-DP を満たし，また，スケール 2^l の部分和に含まれるノイズ分散は，領域サイズによらず一定以上に増えないことが保証される．3 章の提案が用いるのは，「係数ごとに独立なノイズ・段ごとの公開設計分散・非負のための精緻化処理」という構造だけであり，NNW 法はこの構造を持つ機構の代表である．以降は NNW 法を対象機構として議論する．

2.3 問題設定

問題　時点 $t = 1, \ldots, T$ における真値の統計の系列を入力とし，各時点で公開する統計の系列を出力する公開手法を構成する．手法は次の要件を満たす．

- **(R1) 保護**：各時点の公開が ε-DP を満たす．
- **(R2) 統計としての要件**：出力は非負であり，上位の集計値と整合する．ここで整合するとは，出力のセル値を束ねて得られる上位の集計値に，一方向の偏りを持ち込まないことをいう．
- **(R3) 因果性・オンライン性**：時点 t の出力は時点 t 以前の情報のみに依存する．
- **(R4) ノイズ注入以降の処理における真値の不参照**：ノイズ注入の後に置かれる処理は，学習・運用のいずれにおいても真値を参照しない．

© 2026 Information Processing Society of Japan

3. 提案手法

本章では提案手法を構成する．1 章で挙げた 4 つの設計課題と提案手法における設計は次のとおりであり，対応する節でその理由とともに詳述する．

課題 1（フィルタの結合位置）：フィルタを，NNW 法の内部，すなわちノイズ注入の直後（精緻化処理の前）の係数に適用するか，NNW 法の出力に適用するか．設計上のノイズ分散の厳密さと，精緻化処理によるノイズ除去の継承とが交換になる．提案手法は出力へ結合する（3.1 節）．

課題 2（モデル共有の粒度）：状態空間モデルをどの単位で共有するか．係数ごとの個別モデルは，数百万個のモデルの保持・更新を要するうえ，1 係数の系列だけから信号とノイズの分散を推定するのは困難である．一方，全係数で単一のモデルを共有する構成は，ノイズの分散が段ごとに 4 倍ずつ異なるため，どの段に合わせても他の段で破綻する．提案手法は段単位でモデルを共有する（3.3 節）．

課題 3（パラメータ同定）：カルマンフィルタの観測ノイズ分散に何を与えるか．NNW 法の設計値は段ごとの公開定数だが，出力に実際に残っているノイズの分散（以下，実効ノイズ分散）は精緻化処理により設計値から乖離し，その直接測定には真値が必要である．提案手法は，係数時系列の増分の統計から真値を使わずに推定する（3.3 節）．

課題 4（統計要件の回復）：フィルタは各係数の値を更新するため，統計を再構成すると負の値が生じうるが，負値の単純な切り上げは集計値にバイアスを生む．提案手法は集計値の整合を保ったまま非負性を回復する精緻化処理を適用する（3.4 節）．

以上の設計により，提案手法は，真値の系列に対して NNW 法を適用し，その出力の統計を階層分解して得られる係数の時系列に段別のカルマンフィルタを適用し，フィルタ後の係数に再び精緻化処理を適用して統計を再構成する，一体のパイプラインとなる．

3.1 NNW 法の適用と結合位置

提案手法の最初の工程は，各時点の真値の統計に対する NNW 法の適用である．この工程の出力は各時点で ε-DP を満たす統計であり，以降のすべての処理はこの出力のみを入力とする．

NNW 法とフィルタの結合位置に関しては，フィルタを NNW 法の内部で適用する構成（以下，直結構成）と，NNW 法の出力に対して適用する構成の 2 つが考えられ，両者の利得は異なる．直結構成は，その座標では設計上のノイズ分散が厳密に成り立ち，観測ノイズ分散としてそのまま用いることができる．一方で，出力に適用する構成は，精緻化処理がすでに除去したノイズの縮小分を引き継げる．提案手法は，後者を重視し，NNW 法の出力へ結合する構成とする．この利得の程度は，4 章の評価実験において示す．

3.2 階層分解（ウェーブレット変換）

続いて，各時点の NNW 法の出力統計に，NNW 法の工程 1 および 2 と同一の変換を適用し，段 $1..L$ の差係数と最上位近似係数を得る．これを時点ごとに繰り返すことで係数ごとの時系列が得られ，続くフィルタはこの係数時系列の上で動作する．

段 i の 1 つの係数に注目し，時点 t における係数の真値を x_t，この変換で得られるフィルタへの入力を z_t と書く（係数を区別する添字は省略）．この変換は NNW 法が再構成に用いる逆変換の逆写像であるため，z_t は NNW 法の内部で精緻化処理を経た直後の係数の値に厳密に一致する．したがって両者の差 $v_t = z_t - x_t$ は，NNW 法で注入されたノイズのうち，精緻化処理を経て出力に実際に残っている成分である．

3.3 階層型カルマンフィルタ

段 i に属するすべての係数の時系列に，共通のパラメータ (q_i, r_i) を持つ 1 次元のランダムウォーク状態空間モデルを置く：

$$x_t = x_{t-1} + w_t, \quad w_t \sim \mathcal{N}(0, q_i),$$

$$z_t = x_t + v_t, \quad v_t \sim \mathcal{N}(0, r_i).$$

各係数には独立にスカラーカルマンフィルタを適用する：

$$P_{t|t-1} = P_{t-1} + q_i, \quad K_t = \frac{P_{t|t-1}}{P_{t|t-1} + r_i},$$

$$\hat{x}_t = \hat{x}_{t-1} + K_t(z_t - \hat{x}_{t-1}), \quad P_t = (1 - K_t)P_{t|t-1}.$$

同一段内の全係数が (q_i, r_i) を共有するため，ゲイン K_t と分散 P_t の更新は段あたり 1 回でよく，係数側の処理は 1 次式の適用のみである．時点あたりの計算量は係数の数に比例し，処理は 1 パスかつ因果的であるため，周期公開の実運用にそのまま適用できる．

共有単位を段とする理由は次のとおりである．カルマンフィルタの平滑化の強さは信号対ノイズ比 $\phi = q/r$ で決まる．NNW 法における設計ノイズ分散は 1 段で 4 倍異なるため，全係数で単一の (q, r) を共有する一様適用は，どの段に合わせても他の段の ϕ が桁違いの誤りとなる．これに対し各段の係数は，設計ノイズ分散が同一であり，モデル共有が正当化される最も細かい単位である．

ランダムウォークという最小の信号モデルとしたのは，場所ごとの水準や日内変動など真値の変動特性が係数ごとに多様である中で，段内の全係数に共通に仮定できる性質が時間方向の連続性にとどまるためである．モデルの表現力の限界は評価で示す．全段は同一規則で処理され，段ごとに異なるのは，設計分散と，後述のパラメータ同定で z_t の系列から推定する値だけである．最上位近似係数も段の 1 つとして同一の規則で処理する．

パラメータ同定　観測ノイズ分散 r には，段ごとの設計

© 2026 Information Processing Society of Japan

値をそのまま用いるのではなく，z_t の系列から推定した実効ノイズ分散を用いる．パラメータは段単位で 1 日ごとに更新し，更新には前日までの z_t のみを用いる因果的なオンライン処理とする．

同定は z_t の増分 $\Delta z_t = z_t - z_{t-1}$ の標本統計に基づく．ランダムウォークモデルの下では $\mathrm{Var}(\Delta z) = q + 2r$，$\mathrm{Cov}(\Delta z_t, \Delta z_{t-1}) = -r$ が成り立つため，段内の全係数・全時点をプールした標本共分散から r と q を推定できる．最上位近似係数は，ウェーブレット変換の適用単位（以下，ブロック）ごとに 1 つであるため，全ブロックの系列を 1 つの段としてプールする．ただし，真値は厳密なランダムウォークではないため，素朴な推定 $\hat{r} = -\widehat{\mathrm{Cov}}(\Delta z_t, \Delta z_{t-1})$ には，真値の増分自身が持つ自己相関が混入する．この系統誤差を抑えるため，2 時点離れの共分散を相殺項に用いた補正推定量

$$\hat{r} = -\widehat{\mathrm{Cov}}(\Delta z_t, \Delta z_{t-1}) + \widehat{\mathrm{Cov}}(\Delta z_t, \Delta z_{t-2})$$

を用いる．推定量の導出と系統誤差の性質は付録 A に示す．

推定の失敗に対する保護として受理範囲を設ける．$0 < \hat{r} \le r_{\mathrm{design}}$（設計値）を満たす推定値のみを採用し，範囲外の値は設計値へフォールバックする．つまり，設計値を下回る側だけ推定に追従させ，上回る側は採用しない．ノイズの過大評価が真値の変動まで除去する過平滑につながるためである．最後に状態ノイズ分散を $\hat{q} = \max\{\widehat{\mathrm{Var}}(\Delta z) - 2\hat{r},\ 10^{-3}\hat{r}\}$ で得る．下限はフィルタの退化を防ぐために設ける．以上はすべて z_t のみの演算であり，真値や NNW 法内部の情報を一切用いていない．

3.4 精緻化処理による統計要件の回復

フィルタ後の係数列を単にウェーブレット逆変換すると非負性が保証されず，負値を 0 に切り上げる単純なクリップは集計値に過大バイアスを生む．そこで提案手法では，NNW 法の精緻化処理と同一の処理を，フィルタ後の係数列に対してもう一度適用する．すなわち，最上位から階層を降下しながら次の処理を行う．

フィルタ後の最上位近似係数を非負に丸めた値を起点とする．確定済みの親の値 $a \ge 0$ に対し，フィルタ後の差係数 $\hat{d}$ を子が非負となる範囲へ切り詰めた値

$$d = \min\{\max\{\hat{d},\ -2a\},\ 2a\}$$

を用いて，2 つの子の値を $a \pm d/2$ と定める．定めた子を次の親として，最も細かい段まで同じ操作を繰り返す．この処理により，出力の全セルは非負となり，かつ各親の値は子の和として全階層で厳密に保存されるため，上位の集計値は確定した係数の値と完全に整合する．

保証と全体の性質　NNW 法の出力は各時点 ε-DP を満たし，それ以降の処理は保護済みの出力のみを入力とするため，後処理不変性により全体として各時点 ε-DP を満たす．全体は各時点で 1 パスの因果的な処理である．

4. 評価

4.1 評価の目的と観点

本章では，日本全国の人口分布データであるモバイル空間統計を用いて提案手法を評価する．評価は 3 つの観点で行う．観点 1 は手法間の優劣で，本稿の問題設定に対して構成しうる手法の中で，提案手法が細粒度・広域集計のそれぞれで，どれだけの優位性があるかである．観点 2 は有用性で，出力は統計として使える水準にあるか，プライバシー保護を強めたとき，精度の劣化はどれだけ緩やかであるかである．観点 3 は設計課題と理論との照合で，4 つの設計課題に対して提案手法が妥当であったかを，当該の要素だけを置き換えた手法との比較で検証する．あわせて，観測される優劣が実効ノイズ構造とランダムウォークモデルの定常解から説明できるかを確認する．

4.2 実験設計

データと設定　実験にはモバイル空間統計を使用する．モバイル空間統計は，株式会社 NTT ドコモのモバイルネットワークデータから生成された，日本全国の人口分布に関するデータであり，4 次メッシュ単位の人口が 10 分間隔で推計されている．本実験では属性情報は使用せず，メッシュ単位の人口にまとめる．2025 年 7 月の 4 週間を対象とし，前半 2 週間を学習期間，後半 2 週間を評価対象期間（以下，評価窓）とする．データの詳細は付録 C に示す．NNW 法の適用では，先行研究 [3], [4], [9] と同一の空間設定を用いる．すなわち，一辺 256 km（2^{18} セル）の正方領域をウェーブレット変換の適用単位とし，全国の人口を含む 34 個のブロックのそれぞれに独立に適用する．

プライバシー強度は $\varepsilon \in \{0.01, 0.1, 1.0\}$ の 3 水準を評価する．強い保護を含めるのは，周期公開の運用では同一の対象が多数の時点の公開に寄与するため，時点あたりの ε を保守的に小さく設定することが想定されるためである．保証単位は 2.1 節のとおり各時点のスナップショットであり，複数時点にわたる合成保証を主張するものではない．

実験 1（実効ノイズ分散の測定）　NNW 法の出力に実際に残っているノイズの分散が，設計値からどれだけ乖離しているかを測定する．実効ノイズ分散は，真値の系列が既知である実験環境では，係数ごとの $v_t = z_t - x_t$ の分散として直接測定できる．測定は評価窓の全時点を対象とし，段ごとに平均する．

実験 2（手法比較）　ノイズ付与の方法，時系列フィルタ有無，モデル共有の方法，フィルタの結合位置，非負化・整合回復の方法を変えた手法群を，同一のデータ・プライバシー強度の下で比較する．評価指標は 2 つの座標系で定義する．段別 MSE は，段 i の係数空間における真値係数との平均二乗誤差であり，段 1〜18 およびブロック計の

© 2026 Information Processing Society of Japan

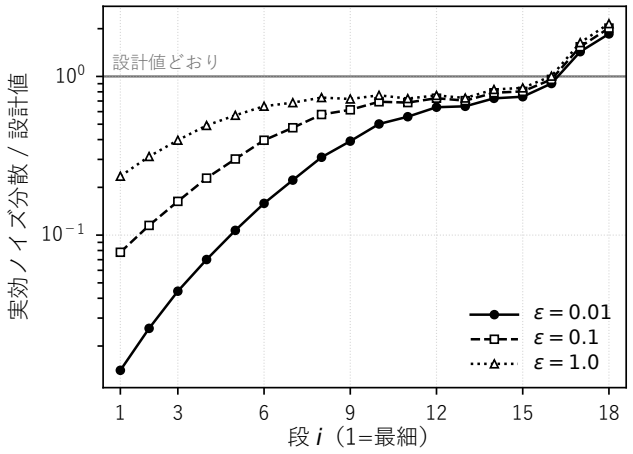


図 1 実効ノイズ分散と設計値との比（段別）
Fig. 1 Ratio of effective to designed noise variance by level.

全段で評価する．部分和 MAE は，メッシュ空間において 2^k セルからなる正方領域の人口和の平均絶対誤差であり，$k = 0$ から全域 $k = 26$ までの全スケールで評価する．ブロックより広域の $k > 18$ のスケールの部分和は，各ブロックの出力の集約として評価する．

比較手法　表 1 に比較手法を示す．比較は上記の軸で振り，セル独立ノイズを用いる構成については非負化なしとクリップの双方を評価する．また，フィルタを適用する手法は，パラメータを z_t の系列から推定して動作する．この同定の良否を手法間の差から切り分けるため，提案手法については，真値を参照して正しいパラメータを与えた場合（以下，真値参照版．学習期間でパラメータを決定）とも比較する．直結構成の観測ノイズ分散には，NNW 法での付与ノイズの設計値をそのまま使用し，状態ノイズ分散には提案手法の同定値を与える．各詳細は付録 C に示す．

4.3 結果

実験 1 の結果　図 1 に，NNW 法の出力で測定した実効ノイズ分散と設計値との比を段別に示す．細かい段では，精緻化処理がノイズを切り詰めるため実効ノイズ分散は設計値を大きく下回り，$\varepsilon = 0.1$ では段 1〜15 で設計値の 0.078〜0.80 倍，保護の強い $\varepsilon = 0.01$ では段 1 で 0.014 倍まで縮小する．一方，段 17・18 ではいずれの ε においても，実効ノイズ分散が設計値を上回り最大 2.15 倍となる．

この結果は，3.3 節の設計を裏づける．すなわち，設計値をそのまま観測ノイズ分散として用いるフィルタは細かい段で不正確になるため実効ノイズ分散の同定が必要であること，また受理範囲を縮小側だけに追従させる非対称設計が実効ノイズ分散の性質と合致することである．

実験 2 の結果（a）細粒度の精度（観点 1）　表 2 にセル単体の平均絶対誤差と総人口の変化を示す．セル独立ノイズを用いる構成は，$\varepsilon = 0.01$ を除き細粒度での誤差が提案手法より小さい．ただしこれらの構成は，出力が負値を含むか，クリップにより総人口を一方向に増加させるかのいずれかであり，(R2) を満たさない．(R2) を満たす手法に限ると，細粒度の誤差が最小であるのは提案手法とモデル共有版であり，提案手法は NNW 法出力の誤差を ε の昇順にそれぞれ 61.6%・40.2%・5.8%削減する．

(b) 広域集計の精度（観点 1）　図 2 に部分和 MAE の絶対値を全スケールについて示す．同じデータを NNW 法出力に対する比で表したものを付録 D の**図 D2** に示す．セル独立ノイズを用いる構成は，細粒度では優位であったが，広域では誤差が大きく増大する．素朴構成（負値を含む）は $\varepsilon = 0.1$ において $k \geq 5$ で誤差が提案手法を上回り，クリップを適用した構成では切り上げ分の蓄積が加わって全域で NNW 法出力の 1,841 倍に達する．モデル共有版は，セル単体では提案手法と並びながら中間スケールで大きく悪化する．これに対し提案手法の誤差は，いずれの ε においても全スケールで NNW 法出力より小さい．すなわち，(R2) を満たす手法の中で細粒度の誤差が最小であることと，全スケールで NNW 法出力を悪化させないこととを両立するのは提案手法のみである．

(c) 有用性（観点 2）　真値の平均セル人口は約 58.9 である．$\varepsilon = 0.01$ における NNW 法出力のセル誤差 54.79 は，全セルを 0 と出力した場合の誤差にほぼ等しく，細粒度の情報がほとんど残っていない水準である．提案手法はこれを 21.0 まで改善する．ε を 1.0 から 0.01 へ 2 桁強めたとき，誤差はセル独立ノイズのみの構成では厳密に 100 倍，素朴構成で 33 倍，NNW 法出力で 13.4 倍に増大するのに対し，提案手法では 5.5 倍にとどまる．この結果，$\varepsilon = 0.01$ における提案手法の誤差 21.0 は，保護が 1 桁緩い $\varepsilon = 0.1$ における NNW 法出力の誤差 18.3 と同水準にある．

(d) 設計課題の分離検証と理論との照合（観点 3）　4 つの設計課題のそれぞれについて，当該の要素だけを置き換えた手法と比較した．結合位置については，両構成の優劣が空間スケールで分かれた．細粒度では 3 水準の ε のすべてで提案手法の誤差が直結構成より小さく，$\varepsilon = 1.0$ では直結構成の誤差は NNW 法出力より大きい．一方，保護が最も強い $\varepsilon = 0.01$ の広域集計では直結構成の誤差が小さく，全域では 31.9%小さい．$\varepsilon = 0.1$・1.0 における同様の差は最大 1.7%・0.08%であり，実質的に同水準である．共有の粒度については，モデル共有版の段別 MSE 比が，$\varepsilon = 0.1$ の段 17 で最大 1777 に達する．同定については，真値参照版に対する提案手法の誤差比がセル単体で ε の昇順に 0.934 ／ 0.974 ／ 1.000 であり，真値を参照しないことによる精度の低下は認められない．統計要件の回復については，提案手法の精緻化処理は集計値の整合を厳密に保ち，総人口の真値との差は 0.014%以下である．理論との照合では，保護を強めるほど利得が拡大し，フィルタがほとんど低減できない段は $\varepsilon = 0.01$ で消滅するという定常解からの予測が，実測でも成り立つ．段別・スケール別の内

© 2026 Information Processing Society of Japan

表 1 比較手法
Table 1 Compared methods.

手法	ノイズ付与	フィルタ（共有単位）	フィルタの結合位置	非負化・整合回復	分離される差
NNW 法出力	NNW 法	なし	—	精緻化処理	（基準）
セル独立ノイズ	セル独立	なし	—	なし／クリップ	ノイズ付与の方法
素朴構成	セル独立	あり（全セル共通）	—	なし／クリップ	フィルタの有無
モデル共有版	NNW 法	あり（全段共通）	NNW 法出力	精緻化処理	モデル共有の単位
直結構成	NNW 法	あり（段別）	NNW 法内部	精緻化処理	フィルタの結合位置
提案手法	NNW 法	あり（段別）	NNW 法出力	精緻化処理	—

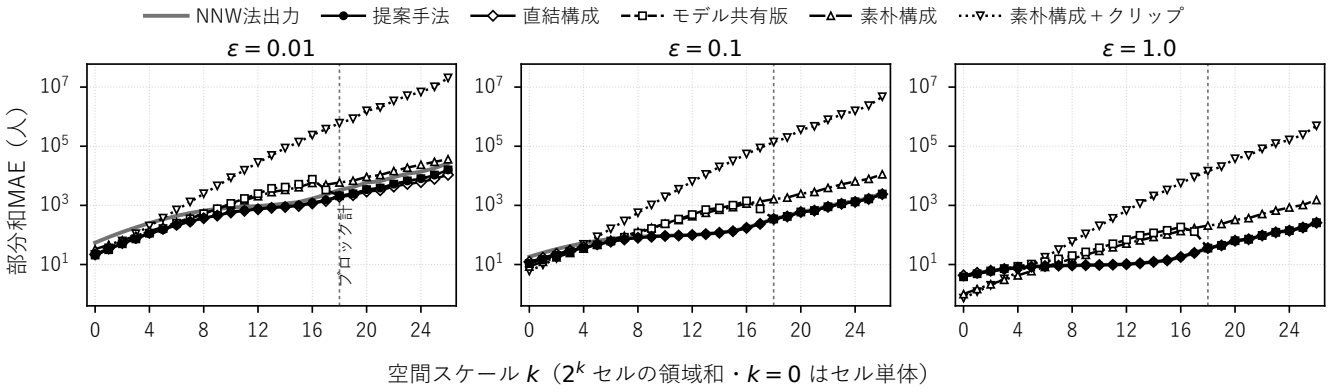


図 2 部分和 MAE（絶対値）
Fig. 2 Partial-sum MAE (absolute values).

表 2 セル単体（$k = 0$）の平均絶対誤差と総人口の変化（評価窓平均）．総人口の変化は，出力の総人口の真値の総人口に対する増加率であり，$\varepsilon = 0.01$ の値を示す
Table 2 Cell-level MAE and total-population change (the latter at $\varepsilon = 0.01$).

	セル MAE			総人口の変化
手法	ε=0.01	0.1	1.0	(0.01)
NNW 法出力	54.79	18.30	4.089	+0.013%
セル独立ノイズ（負値を含む）	100.0	10.00	1.000	+0.006%
セル独立ノイズ＋クリップ	56.56	6.526	0.7314	+73.8%
素朴構成（負値を含む）	32.93	8.597	0.9992	+0.003%
素朴構成＋クリップ	21.79	6.030	0.7322	+18.9%
モデル共有版	20.93	10.91	3.856	+0.013%
直結構成	21.85	12.32	4.330	+0.005%
提案手法	21.02	10.95	3.851	+0.013%

訳は付録 D に，定常解との照合は付録 B に示す．

4.4 考察

(1) 設計課題への答え

結合位置（課題 1）　両構成の優劣が空間スケールで分かれるのは，精緻化処理を通した後の係数を入力とすることの利害が，細粒度と広域とで逆になるためである．利点は，フィルタが受け取るノイズがすでに小さいことである．細かい段では実効ノイズ分散が設計値を大きく下回るため，提案手法はその小さなノイズから出発できる．細粒度で提案手法の誤差が直結構成より小さく，直結構成が細かい段で NNW 法出力より誤差を大きくするのはこのためである．代価は，精緻化処理が出力に残す 2 つの性質を引き継ぐことである．一つは誤差の再配置である．切り詰めは和を保存して行われるため，最上位近似係数の誤差の一部が同じブロックの段 17・18 の差係数へ移り，実効ノイズ分散が設計値を上回る．受理範囲は設計値を上限とするため，観測ノイズ分散を実効値まで上げられず平滑化が不足する．もう一つは総人口の正の偏りである．強い保護の下では，最上位近似係数の非負への丸めがブロック総人口に正の偏りを残す．詳細は付録 A に示す．フィルタは時点によらず同じ向きに乗る偏りを除去できないため，提案手法はこれを引き継ぐ．直結構成はどちらの性質も生じる前の係数をフィルタするため影響を受けない．$k \geq 19$ の部分和は複数のブロックの集計であり，Haar 分解の構造上，段 17・18 の誤差は寄与しない．$\varepsilon = 0.01$ の広域で直結構成の誤差が小さいのは，$k \leq 18$ では再配置が，$k \geq 19$ では偏りが効くためであり，偏りが小さい $\varepsilon = 0.1$ 以上では広域の差も消える．強い保護の下での広域集計を重視する場合には，結合位置の再検討が有効である．

共有の粒度（課題 2）　モデル共有版がセル単体で提案

© 2026 Information Processing Society of Japan

手法と並びながら中間の段で破綻するのは，段ごとに 4 倍ずつ異なるノイズ分散を単一の (q, r) で扱えないためである．全係数を一括して同定すると，係数の数が多く分散も大きい細かい段に推定が支配されるため，粗い側の段では観測ノイズ分散が過大となり，真値の変動まで平滑化する．その段の誤差は，Haar 分解の構造により対応する中間スケールの部分和に現れる．セル単体の指標では検出できないこの形の欠陥は，全段・全スケールで評価して初めて可視化される．

同定（課題 3）　提案手法と真値参照版では，精度の差は認められなかった．乖離が大きい細かい段では推定値が受理範囲の内側で採用されて乖離に追従し，それ以外の段では推定値が一貫して範囲外に出て設計値が用いられるため，誤同定が過平滑化として現れないと考えられる．加えて，真値参照版が学習期間で凍結したパラメータを使い続けるのに対し，提案手法の同定は評価窓の中でも日次で更新されるため，真値の統計の変化にも追従する．

統計要件の回復（課題 4）　クリップの切り上げはセル単位では小さな修正であるが，片側のみに働くため打ち消されずに蓄積し，総人口の一方向の増加として広域の集計に現れる．$\varepsilon = 1.0$ でセル単体の誤差が最小であったクリップありの構成が，全域では NNW 法出力の 1,900 倍前後の誤差を与えることは，非負性と集計整合を同時に満たすには精緻化処理を要することを示す．

(2) 有用性についての知見　保護を強めたときの提案手法の劣化の緩さは，時系列方向の情報の回復によるものであり，これを，劣化の原因の対比として示す．基準となるセル独立ノイズの構成では，誤差はノイズスケールに従い厳密に $1/\varepsilon$ で増大する．これに対し提案手法の劣化が大幅に緩やかであることは，信号対ノイズ比 ϕ の変化で説明できる．設計ノイズ分散は $1/\varepsilon^2$ に比例する一方で真値の変動は ε に依存しないため，保護が強いほど全段の ϕ は一様に小さくなり，時間方向の平滑化で除去できる誤差の割合が増える．一方，フィルタを用いない NNW 法出力の劣化も $1/\varepsilon$ より緩やかであるが，その原因は情報の消失である．精緻化処理は統計値が負にならないよう係数を切り詰めるため，ノイズが係数の規模に対して十分大きい領域では細かい段の係数の情報がほとんど失われる．このとき出力は，総人口や広域の集計値を保つ一方で，細かいスケールにおける配分の情報を失う．その結果，セル単位の誤差は，全セルを 0 と出力した場合の水準，すなわち真値の平均セル人口である約 58.9 で飽和する．これは有用性が保たれた緩やかさではなく，細粒度の情報を失った結果の頭打ちである．この飽和領域で提案手法がセル単位の誤差を 61.6%削減できることは，単一時点の公開出力にはほとんど残っていない細粒度の情報を，複数時点の公開値の蓄積から回復していることを示す．提案手法の劣化の緩さは，この回復によるものである．

(3) 改善の到達点　NNW 法出力を入力とする構成が到達しうる水準は，パラメータ同定の側では真値参照版が，信号モデルの側ではランダムウォークモデルの定常解が与える．同定については，提案手法の誤差は真値参照版と同水準であり，残る余地は小さい．信号モデルについては，モデルが正しければフィルタ後の段別 MSE は定常解 $P_i^* = \kappa(\phi_i)\, r_i$ に収束する．ここで r_i は実験 1 で測定した段 i の実効ノイズ分散，$\phi_i = q_i / r_i$ であり，状態ノイズ分散 q_i には真値の増分の分散を与える．提案手法の段別 MSE がこの到達水準まで下がり切らずに残す誤差は，到達水準に対する割合で，$\varepsilon = 1.0$ では全段で 3.0% 以下にとどまるのに対し，$\varepsilon = 0.1$ では段 3〜7 で 13〜26%，$\varepsilon = 0.01$ では段 3〜10 で 115〜256% に達する．すなわち，保護が強いほど，下がり切らずに残る誤差が大きい．残る改善余地は信号モデルの表現力にある．詳細は付録 B に示す．

(4) 限界と将来課題　本稿では状態空間モデルとしてランダムウォークという最小モデルを使用したが，到達水準に届いていないことが示すとおり，モデルの表現力に限界がある．特に，真値が持つ日周・週周期の構造を明示的に扱っておらず，そのモデル化が精度面の主要な課題である．

5. 関連研究

時系列・ストリームデータへの DP 適用の先行研究は，保証の単位と空間構造の扱いの 2 軸で整理できる．保証粒度には，1 時点の寄与を保護するイベントレベル，全期間の寄与を保護するユーザレベル，その中間の w-event プライバシー [10] がある．本稿の対象機構（NNW 法・TopDown Algorithm）は，保証粒度の軸ではイベント側に，空間構造の軸では階層ありに位置する．

空間構造の軸に沿う系では，ウェーブレット係数へのノイズ注入により任意の範囲カウント問合せのノイズ分散を定義域サイズの多対数に抑える Privelet [11] が階層注入の起点であり，Hay らは，階層カウントの公開値を整合性制約へ射影する事後補正が精度を高めることを示した [12]．実運用の機構として，本稿が対象とする NNW 法 [3] と TopDown Algorithm [2] がある．同一機構の改良軸として，ノイズ分布を Gaussian に置換しゼロ集中 DP における合成効率を高める提案 [9] があるが，機構側の変更であり本稿とは直交する．これらの系ではいずれも各時点の公開が独立に設計されており，公開出力の時間方向の構造は活用されていない．

時間方向の軸に沿う系には，ストリーム公開の保証自体を設計する研究がある．有限期間のユーザレベル保証の下で適応サンプリングとカルマンフィルタを組み合わせる FAST [5]，その空間への拡張として Quadtree に基づくセル集約を時間方向の推定と組み合わせた多次元時系列の公開 [13]，イベントレベル保証の下で摂動・グルーピング・平滑化を組み合わせる PeGaSus [6]，w-event 保証の下で

© 2026 Information Processing Society of Japan

適応的なグルーピング・予算配分とフィルタリングを組み合わせる RescueDP [7] が代表であり，制御の分野には，フィルタの出力自体に DP 保証を与える差分プライベートフィルタリング [14] がある．これらではフィルタリング・平滑化が保証を構成する機構の設計の一部であり，ノイズ注入・予算配分と一体である．本稿でも機構は構成要素であるが，フィルタは保護済みの公開出力のみを入力とし，保証の設計と予算の配分には関与しない．保証の単位と予算の扱いが異なるため，これらの手法と本稿の精度を直接比較することはできない．また空間構造の軸では，これらは単一の集約系列，または平坦なセル分割に対する集約・グルーピングを扱っており，空間階層に沿った段依存のノイズ分散という本稿の中心課題は現れない．

以上のとおり，空間階層機構の系では時間方向の構造が，時系列 DP の系では空間階層の構造が，それぞれ扱われていない．本稿は，空間階層機構のスナップショット毎公開という実運用形態を保ったまま，時系列 DP の系が機構の内側で用いてきたフィルタリングを，保証に関与しない構成として持ち込むものであり，著者らの知る限り，この交点を扱う研究は本稿が最初である．

6. おわりに

本稿では，空間階層ノイズ注入機構が周期的に公開する統計に対し，時系列方向の構造を利用して有用性を高める公開手法を提案した．提案手法は NNW 法出力へ階層別カルマンフィルタを結合し，増分統計に基づく因果的なパラメータ同定と，非負性および集計整合を回復する精緻化処理とを組み合わせた一体の構成である．評価実験により，統計としての要件を満たす手法の中で細粒度の誤差が最小の水準にあることと，全空間スケールで NNW 法出力を悪化させないこととを両立するのは提案手法のみであること，セル単位の誤差を $\varepsilon = 1.0$ で 5.8%，$\varepsilon = 0.01$ で 61.6% 削減すること，およびプライバシー保護を強めたときの精度の劣化がセル独立ノイズを用いる構成に比べて大幅に緩いことを示した．

今後の課題として信号モデルの高度化があげられる．真値が持つ日周・週周期の構造を状態方程式に持つモデルへの拡張と，時刻帯別の評価は，本稿のランダムウォークモデルが理論的な到達水準に対して残す取り逃しを縮める主要な方向である．

謝辞　本研究は，JST 経済安全保障重要技術育成プログラム（JPMJKP24U5）の支援を受けたものである．

参考文献

[1] Dwork, C.: Differential Privacy, Proc. 33rd Int. Conf. Automata, Languages and Programming (ICALP), LNCS 4052, pp.1–12, Springer (2006).

[2] Abowd, J., Ashmead, R., Cumings-Menon, R., Garfinkel, S., Heineck, M., Heiss, C., Johns, R., Kifer, D., Leclerc, P., Machanavajjhala, A., Moran, B., Sexton, W., Spence, M. and Zhuravlev, P.: The 2020 Census Disclosure Avoidance System TopDown Algorithm, Harvard Data Science Review, Special Issue 2 (2022). DOI 10.1162/99608f92.529e3cb9

[3] 寺田雅之，鈴木亮平，山口高康，本郷節之：大規模集計データへの差分プライバシの適用，情報処理学会論文誌，Vol.56, No.9, pp.1801–1816 (2015).

[4] Ito, S., Miura, T., Akatsuka, H. and Terada, M.: Differential Privacy and Its Applicability for Official Statistics in Japan – A Comparative Study Using Small Area Data from the Japanese Population Census, Privacy in Statistical Databases (PSD 2020), LNCS 12276, pp.337–352, Springer (2020).

[5] Fan, L. and Xiong, L.: An Adaptive Approach to Real-Time Aggregate Monitoring with Differential Privacy, IEEE Trans. Knowledge and Data Engineering, Vol.26, No.9, pp.2094–2106 (2014).

[6] Chen, Y., Machanavajjhala, A., Hay, M. and Miklau, G.: PeGaSus: Data-Adaptive Differentially Private Stream Processing, Proc. 2017 ACM SIGSAC Conf. on Computer and Communications Security (CCS 2017), pp.1375–1388 (2017).

[7] Wang, Q., Zhang, Y., Lu, X., Wang, Z., Qin, Z. and Ren, K.: RescueDP: Real-time Spatio-temporal Crowd-sourced Data Publishing with Differential Privacy, Proc. 35th Annual IEEE Int. Conf. on Computer Communications (INFOCOM 2016), pp.1–9 (2016). DOI 10.1109/INFOCOM.2016.7524458

[8] Dwork, C. and Roth, A.: The Algorithmic Foundations of Differential Privacy, Foundations and Trends in Theoretical Computer Science, Vol.9, No.3–4, pp.211–407 (2014).

[9] Ishioka, T. and Terada, M.: Utility of the Non-negative Wavelet Mechanism with Zero-Concentrated Differential Privacy, Advances in Information and Computer Security (IWSEC 2025), LNCS 16208, pp.290–306, Springer (2025).

[10] Kellaris, G., Papadopoulos, S., Xiao, X. and Papadias, D.: Differentially Private Event Sequences over Infinite Streams, Proc. VLDB Endowment, Vol.7, No.12, pp.1155–1166 (2014).

[11] Xiao, X., Wang, G. and Gehrke, J.: Differential Privacy via Wavelet Transforms, IEEE Trans. Knowledge and Data Engineering, Vol.23, No.8, pp.1200–1214 (2011).

[12] Hay, M., Rastogi, V., Miklau, G. and Suciu, D.: Boosting the Accuracy of Differentially Private Histograms Through Consistency, Proc. VLDB Endowment, Vol.3, No.1, pp.1021–1032 (2010).

[13] Fan, L., Xiong, L. and Sunderam, V.: Differentially Private Multi-dimensional Time Series Release for Traffic Monitoring, Proc. 27th IFIP WG 11.3 Conf. on Data and Applications Security and Privacy (DBSec 2013), LNCS 7964, pp.33–48, Springer (2013).

[14] Le Ny, J. and Pappas, G. J.: Differentially Private Filtering, IEEE Trans. Automatic Control, Vol.59, No.2, pp.341–354 (2014).

© 2026 Information Processing Society of Japan

付　　録

A　同定式の導出と受理範囲の設計根拠

推定量の導出　3.3 節のランダムウォークモデルの下で，公開値の増分 $\Delta z_t = z_t - z_{t-1}$ は，観測方程式 $z_t = x_t + v_t$ と状態方程式 $x_t = x_{t-1} + w_t$ を代入すると

$$\Delta z_t = (x_t - x_{t-1}) + (v_t - v_{t-1}) = w_t + v_t - v_{t-1}$$

と，3 つのノイズ項の和に書ける．モデルの仮定からすべての w_t・v_t は互いに独立であり，独立な項の和の分散は各項の分散の和なので

$$\mathrm{Var}(\Delta z) = \mathrm{Var}(w_t) + \mathrm{Var}(v_t) + \mathrm{Var}(v_{t-1}) = q + 2r$$

を得る．次に，1 時点前の増分 $\Delta z_{t-1} = w_{t-1} + v_{t-1} - v_{t-2}$ と見比べると，両者に共通して現れるノイズ項は v_{t-1} ただ 1 つであり，Δz_t には $-v_{t-1}$，Δz_{t-1} には $+v_{t-1}$ と逆符号で現れる．独立な項どうしは共分散に寄与しないため，共分散はこの共通項の分だけとなり

$$\mathrm{Cov}(\Delta z_t, \Delta z_{t-1}) = -\mathrm{Var}(v_{t-1}) = -r$$

を得る．2 時点以上離れた増分とはノイズ項を 1 つも共有しないため，$\mathrm{Cov}(\Delta z_t, \Delta z_{t-j}) = 0$（$j \geq 2$）である．同一の観測ノイズが隣接する増分に逆符号で現れて負の相関を作ること，そしてその大きさが r そのものであることが，真値を参照せずに公開値だけから r を推定できる仕組みの核である．真値が厳密なランダムウォークであれば，$\hat{r}_1 = -\widehat{\mathrm{Cov}}(\Delta z_t, \Delta z_{t-1})$ は不偏である．実際の真値はそうではないため，真値の増分の自己共分散 $\gamma(j) = \mathrm{Cov}(\Delta x_t, \Delta x_{t-j})$ が混入し，

$$\mathbb{E}[\hat{r}_1] = r - \gamma(1), \qquad \mathbb{E}[\hat{r}_2] = r - \gamma(1) + \gamma(2)$$

となる．ここで $\hat{r}_2$ は 3.3 節の lag-2 補正推定量である．すなわち補正により系統誤差は $\gamma(1)$ から $\gamma(1) - \gamma(2)$ へ縮む．

系統誤差の性質　真値の増分を，ゆっくり変動する成分と，時点間の相関が弱い高速変動成分とに分けて考える．前者の自己共分散は隣接ラグ間でほぼ等しく（$\gamma(1) \approx \gamma(2)$），差分でほぼ相殺される．これが lag-1 版に対する lag-2 版の利点である．一方，後者は $\gamma(1)$ にのみ負の寄与として現れ $\gamma(2)$ には現れないため，補正後も推定値を設計値超過側へ押す残差となる．真値の高速変動は，公開系列だけからは観測ノイズと原理的に区別できず，これをノイズとして数えることは真値変動の除去（過平滑化）に向かう．設計分散が段を上がるごとに急減する一方で，真値の変動は集約により増大するため，粗い段ではこの残差が r を相対的に大きく上回る．$\varepsilon = 0.1$ での実測でも，最も粗い段 18 と最上位近似係数の推定値は設計値の 1.9 倍・1.1 倍に達する．この偏りは推定量の期待値そのものに現れるため，標本数を増やしても解消しない系統誤差である．また中間の段では相殺の残差が負に振れ，推定値が負となる．いずれの失敗も受理範囲 $0 < \hat{r} \leq r_{\mathrm{design}}$ の外に出るため，設計値へのフォールバックとして処理される．

受理範囲の設計根拠　この受理範囲の下では，同定の導入が平滑化を設計値運用より強めることはない．推定値は設計値以下でのみ採用されるため，推定が失敗した場合を含め，フィルタの平滑化強度は「設計値そのまま」が上限となる．なお，精緻化処理による実効ノイズ分散の乖離は，縮小側（細かい段で設計値の 0.078〜0.80 倍）と超過側（段 17・18 で最大 2.15 倍）の両側である．超過側は，和の保存の下での精緻化処理が最上位近似係数の誤差の一部を同じブロックの差係数へ再配置することで生じると考えられる．受理範囲に上限を設定しているため，この超過側の実効ノイズ分散の採用が妨げられるが，これは意図的な保守化である．設計値を超える推定値には，推定の誤りと真の超過とが混在し，公開値のみからは区別できない．そこで誤りが過平滑化に落ちない側，すなわち平滑化を弱める側へ倒している．この保守化の代価は，超過側の帯である段 17・18 における平滑化の不足として現れ，その規模は直結構成との比較で定量化される．

全国計の偏り　差係数の切り詰めは子の対の和を保存するため，全国計を動かすことはない．全国計を変えうる操作は，降下の起点で負の最上位近似係数を 0 へ引き上げる丸めだけであり，これは片側にのみ働く．ノイズがブロックの人口規模に対して大きいほど引き上げの頻度は上がるため，強い保護の下で全国計に正の偏りが残る．$\varepsilon = 0.01$ における全国計の符号付き誤差は，NNW 法出力で +13,530（同スケールの平均絶対誤差 26,504 の約半分），これを引き継ぐ提案手法で +14,375，引き上げ前の係数を観測する直結構成で +5,171 である．提案手法の値が NNW 法出力とほぼ等しいのは，時点によらず同じ向きに乗る偏りが線形なフィルタで除去されないためである．直結構成で小さいのは，ノイズをフィルタで縮小した後の係数に丸めが適用され，引き上げの頻度が下がるためである．両者のランダム成分はほぼ等しく（標準偏差 12,570 対 12,458），$\varepsilon = 0.1$ では偏り自体が +812 と小さい．なお，この偏りは NNW 法出力と提案手法の総人口にも現れるが，その規模は全 ε で 0.02%未満であり，$\varepsilon = 1.0$ でも +0.46% であるクリップを用いる構成の増加とは水準が異なる．

B　定常解の閉形式と ε 依存の予測

閉形式　3.3 節のスカラーカルマンフィルタの事後分散の更新は $P_{t|t-1} = P_{t-1} + q$，$P_t = P_{t|t-1} r / (P_{t|t-1} + r)$ である．不動点 P^* は $P^* = (P^* + q) r / (P^* + q + r)$ を満たし，$\phi = q/r$ を用いて

© 2026 Information Processing Society of Japan

表 B1　閉形式による段別の予測誤差低減率 $\kappa(\phi_i)$

Table B1　Predicted level-wise error-reduction ratios $\kappa(\phi_i)$ in closed form.

段	ε=0.01	ε=0.1	ε=1.0
1	0.011	0.105	0.655
2	0.014	0.130	0.729
3	0.019	0.171	0.812
4	0.024	0.212	0.868
5	0.035	0.302	0.933
6	0.045	0.367	0.957
7	0.067	0.492	0.980
8	0.115	0.684	0.993
9	0.207	0.862	0.998
10	0.215	0.871	0.998
11	0.442	0.973	1.000
12	0.523	0.983	1.000
13	0.597	0.989	1.000
14	0.744	0.995	1.000
15	0.619	0.990	1.000
16	0.646	0.992	1.000
17	0.857	0.998	1.000
18	0.549	0.985	1.000

$$P^* = \kappa(\phi)\, r, \qquad \kappa(\phi) = \frac{-\phi + \sqrt{\phi^2 + 4\phi}}{2}$$

と閉形式で書ける．$\kappa(\phi)$ は ϕ の単調増加関数で，$\phi \to \infty$ で $\kappa \to 1$（ノイズに対し信号変動が大きく，フィルタはノイズをほとんど低減できない），$\phi \to 0$ で $\kappa \approx \sqrt{\phi}$（フィルタがノイズの大部分を低減する）となる．モデルが正しい場合，定常状態における係数 MSE の NNW 法出力に対する比である段別 MSE 比の理論値は $\kappa(\phi_i)$ である．

ε 依存の予測　設計ノイズ分散は Laplace スケール（$\propto 1/\varepsilon$）の 2 乗に比例するため $r_{\mathrm{design}} \propto 1/\varepsilon^2$ であり，q は真値の性質であって ε に依存しない．したがって $\phi_i \propto \varepsilon^2$ となり，ε を 0.1 から 0.01 にすると全段の ϕ は 10^{-2} 倍になる．κ は全段で低下，つまりフィルタによるノイズ低減効果が大きくなり，$\kappa > 0.97$ となるようなフィルタがほとんど低減できない段は消滅すると予測される．

表 B1 に，観測ノイズ分散 r に設計値を，状態ノイズ分散 q に真値の系列から測定した増分の分散を与えて計算した，フィルタ後の段別 MSE の NNW 法出力に対する比の予測値を示す．真値の統計と公開仕様のみから計算され，NNW 法出力の実測を用いない．1 に近いほどフィルタはノイズを低減できず，小さいほど低減が大きい．

フィルタがほとんどノイズを低減できない段は $\varepsilon = 1.0$ で段 7〜18 の 12 段，$\varepsilon = 0.1$ で段 11〜18 の 8 段であり，$\varepsilon = 0.01$ では存在しない．$\varepsilon = 1.0$ における実測の該当段数は 14 段であり，予測とよく一致する．保護を強めるほど κ は全段で低下し，利得は全段で拡大すると予測される．

事前予測の検証（$\varepsilon = 0.01$）　実運用では真値と突き合わせられないため，実効ノイズ分散は測定できない．そこで，より弱い保護である $\varepsilon = 0.1$ までの測定だけから $\varepsilon = 0.01$ の段別 MSE 比を予測し，実測と突き合わせることで，閉形式が運用前の設計にどこまで使えるかを検証する．予測は 2 通り構成する．予測 A は r に設計値を用いる．予測 B は r に，$\varepsilon = 0.1$ で実測した実効ノイズ分散を $1/\varepsilon^2$ 倍した値を用いる．予測 B は，精緻化処理によるノイズ縮小の比率が ε によらず一定であるという仮定にあたる．q にはいずれも真値の増分の分散を与える．検証の結果，フィルタがほとんど低減できない段の消滅はどちらの予測でも的中し，段別 MSE 比の値も大半の段で予測 B が実測に近かった．一方，細かい段では実測の比が両予測より大きく，予測ほどには低減できなかった．最も細かい段 1 では，予測 A が 0.011，予測 B が 0.039 であるのに対し，実測の段別 MSE 比は 0.110 である．予測が外れる原因は 2 つある．一つは，ノイズ縮小の比率が実際には ε に依存し，保護が強いほど切り詰めが進むことである．段 1 の実効ノイズ分散は，$\varepsilon = 0.1$ では設計値の 0.078 倍であるのに対し，$\varepsilon = 0.01$ では 0.014 倍まで縮む．もう一つは，$\varepsilon = 0.01$ では，ランダムウォークモデルで説明できない誤差がすべての段で残ることである．

信号モデルの表現力の限界の定量　最後に，ランダムウォークモデルの下で到達しうる誤差の水準と，実測の誤差とを比べ，モデルの限界を定量する．段 i のモデルが正しければ，フィルタ後の段別 MSE は定常解 $P_i^* = \kappa(\phi_i)\, r_i$ に一致する．ここで r_i は実測した実効ノイズ分散，q_i は真値の増分の分散であり，P_i^* は，設計値にもとづく事前予測である表 B1 と異なり，フィルタが実際に受け取るノイズを反映した到達水準である．実測の段別 MSE が P_i^* まで下がり切らずに残す差が，ランダムウォークでは説明できない誤差であり，モデルの表現力の限界の定量形である（実効ノイズ分散は NNW 法出力の段別 MSE に等しいため，実測の段別 MSE は，**表 D1** の段別 MSE 比に r_i を乗じて得られる）．この差を P_i^* に対する割合で表すと，$\varepsilon = 1.0$ では全段で 3.0% 以下にとどまる．すなわちフィルタは，このモデルで到達しうる水準とほぼ同じ誤差を達成している．一方，$\varepsilon = 0.1$ では段 3〜7 で 13〜26% に増え，$\varepsilon = 0.01$ ではすべての段で差が残り，段 3〜10 で 115〜256%，最小の段 17 でも 5.3% である．すなわち，保護が強いほど，モデルで説明できない誤差が大きい．実測が P_i^* を 1% を超えて下回るのは $\varepsilon = 0.1$ の段 1・2 のみで，それぞれ 6.9%・6.4% である．それでも部分和の誤差は全スケールで NNW 法出力より小さく，この差は信号モデルの高度化で縮めうる．

C　実験の詳細

NNW 法の各工程の詳細（2.2 節の補足）　工程 1 の Morton 順序写像による 1 次元化では，正方領域の部分和が 1 次元上の連続区間の和に対応する．工程 2 の Haar ウェー

© 2026 Information Processing Society of Japan

ブレット変換は，隣接する 2 値の対から平均 a と差 d を取り，平均の列に対してこれを再帰的に繰り返すことで階層分解を構成する．工程 4 の精緻化処理は，最上位近似係数が負の場合に 0 へ引き上げたうえで，確定済みの親 $a \geq 0$ の下で差係数を $|d| \leq 2a$ へ制限する補正であり，あわせて親がゼロの部分木は展開しない．差係数の制限は子の対の和を保存するため総和を変えず，総和を変えうる操作は起点の引き上げだけである．これにより出力は非負かつ疎に保たれ，計算量は非ゼロ出力数に対してほぼ線形となる．

真値系列とブロック分割　モバイル空間統計は，性別・年齢・居住市区町村別の 4 次メッシュ単位の人口を 10 分間隔で与える．本実験では属性情報を使用せず，2025 年 7 月 1 日 0 時 0 分から 7 月 28 日 23 時 50 分までの 28 日・4,032 時点を対象とする．対象総人口は約 1.08 億人，人口を含みうるセル（公開の存在マスク）は約 183 万セルである．空間は一辺 256 km（2^{18} セル）のブロックを単位とし，人口を含みうる 34 ブロックのそれぞれに NNW 法と提案手法を独立に適用する．ブロック内は Morton 順序で 1 次元化する．

NNW 法のパラメータ　設計ノイズ分散は [3] の感度の階層配分に従う段ごとの公開定数であり，段を 1 つ降りる（細かくなる）ごとに 4 倍となる．

フィルタと同定の実装　フィルタの初期値は状態 0・事後分散は十分大きな値とする．パラメータの初期値は $q = r = r_{\mathrm{design}}$，すなわち $\phi = 1$ の中立値とし，以後は 3.3 節の同定に従う．同定の標本統計は系列開始からの因果的な累積統計であり，毎日 0 時に段単位で更新する．初日は標本数不足のため更新しない．$\hat{q}$ の下限は $10^{-3}\hat{r}$ とする．

比較手法の実装　素朴構成は，存在マスク内の各セルに独立な Laplace ノイズを加える機構の出力に，全セル共通のスカラーカルマンフィルタを適用する．観測ノイズ分散はこの機構の公開定数である設計値，状態ノイズ分散は全セルをプールした増分統計から日次更新した値である．モデル共有版は，提案手法の段別モデルを全段共通の単一モデルに置き換えたものであり，同定は全段の係数をプールして行う．それ以外の結合位置・精緻化・更新規則は提案手法と同一である．直結構成は，NNW 法のノイズ注入直後の係数を対象とし，ブロック内で完結する段 $1..L$ の差係数と最上位近似係数に提案手法と同一の段別フィルタを適用したうえで，フィルタ後の係数から精緻化処理と同一の降下によって統計を再構成する．観測ノイズ分散には設計値を用い，状態ノイズ分散には提案手法の同定値を与える．すなわち，同定の側では直結構成に有利な条件を与えている．

評価指標の網羅性　4.2 節のとおり，段別 MSE は全段，部分和 MAE は全スケールで評価する．網羅的に評価するのは，Haar 分解の構造上，スケール k の部分和の誤差が段 k 以上の係数の誤差だけで決まるためである．細かい段での誤差の増減は広域の集計値の指標に現れず，その逆も成り立つ．例えばセル単体の誤差が小さくても，中間スケールの誤差が大きい可能性がある．

窓・指標・乱数　前半 14 日を学習期間，後半 14 日を評価窓とし，報告する値は評価窓内の対象時点の平均量またはその比である．対象時点は，段別 MSE では評価窓の全時点である 2,016 時点，部分和 MAE および表 2 の指標では評価窓内の 1 時間ごとの時点である 336 時点であり，この間引きは計算量のためである．対象時点は全手法で共通である．乱数種は時点番号に固定し，同一時点のノイズ実現を全比較手法で共有する．

表 D1　段別 MSE 比（フィルタ後／ NNW 法出力・評価窓平均）
Table D1　Level-wise MSE ratios (filtered / NNW output).

	提案			共有版			直結		
段	0.01	0.1	1.0	0.01	0.1	1.0	0.01	0.1	1.0
1	0.1096	0.3048	0.8836	0.1053	0.3053	0.8813	6.6627	2.8500	3.0679
2	0.0911	0.3145	0.8991	0.0967	0.3142	0.9060	4.4684	2.3648	2.5381
3	0.2062	0.4207	0.9314	0.2534	0.4725	0.9933	2.9142	2.5306	2.2105
4	0.1867	0.4397	0.9542	0.2658	0.5331	1.0805	1.7916	2.0126	1.8848
5	0.3721	0.5977	0.9790	0.8474	1.2961	1.5056	1.9377	2.1789	1.6955
6	0.3526	0.6068	0.9821	0.8244	1.4822	1.8417	1.4249	1.6597	1.5149
7	0.4420	0.7033	0.9892	1.7325	3.2837	3.2460	1.5605	1.5705	1.4472
8	0.5593	0.8175	0.9971	5.6600	11.3	8.6334	1.7785	1.4826	1.3533
9	0.6809	0.9168	0.9987	20.9	44.8	31.2	1.8649	1.4996	1.3911
10	0.6215	0.9125	0.9987	14.9	37.9	31.1	1.3121	1.3277	1.3163
11	0.7314	0.9946	0.9998	100.9	277.2	199.5	1.4120	1.4267	1.3806
12	0.7507	0.9887	0.9999	144.2	423.1	311.1	1.2425	1.3462	1.3128
13	0.7743	0.9932	1.0000	219.7	672.8	498.8	1.2221	1.4079	1.3676
14	0.8372	0.9963	1.0000	493.1	1504	1083	1.1597	1.2630	1.2133
15	0.7598	0.9919	0.9999	187.9	586.6	479.0	1.0302	1.2365	1.1934
16	0.7625	0.9928	1.0000	160.8	529.8	486.3	0.8527	1.0410	1.0235
17	0.8575	0.9975	1.0000	580.0	1777	1310	0.6202	0.6494	0.6279
18	0.6417	0.9806	0.9998	8.8477	43.6	110.0	0.3600	0.4886	0.4791

D　補足数値

本文の図 2 および 4.3 節の数値の詳細を示す．段別 MSE 比を**図 D1** に，本文の図 2 と同一のデータを NNW 法出力に対する比で表したものを図 D2 に示す．直結構成は，係数空間では最も粗い段でのみ誤差を大きく低減する．$\varepsilon = 0.01$ ではこれが $k \leq 18$ の部分和に現れ，$k \geq 8$ のすべてのスケールで直結構成の誤差が提案手法より小さい．表中の値は丸めの都合で 1.0000 と表示されることがあるが，提案手法の値はすべて厳密に 1 未満である．最大は段別では段 13・$\varepsilon = 1.0$ の 0.99996，部分和では $k = 26$・$\varepsilon = 1.0$ の 0.999999 である．また，表 2 の総人口の変化について，クリップを用いる 2 構成は $\varepsilon = 0.1$ で +5.90%／ +4.36%，$\varepsilon = 1.0$ で +0.46%／ +0.45% と全 ε で一方向に増加し，他の手法は全 ε で 0.02% 未満である．

表 D1 に段別 MSE 比を示す．1 未満が NNW 法出力からの改善を表す．「共有版」はモデル共有版，「直結」は直結構成．

© 2026 Information Processing Society of Japan

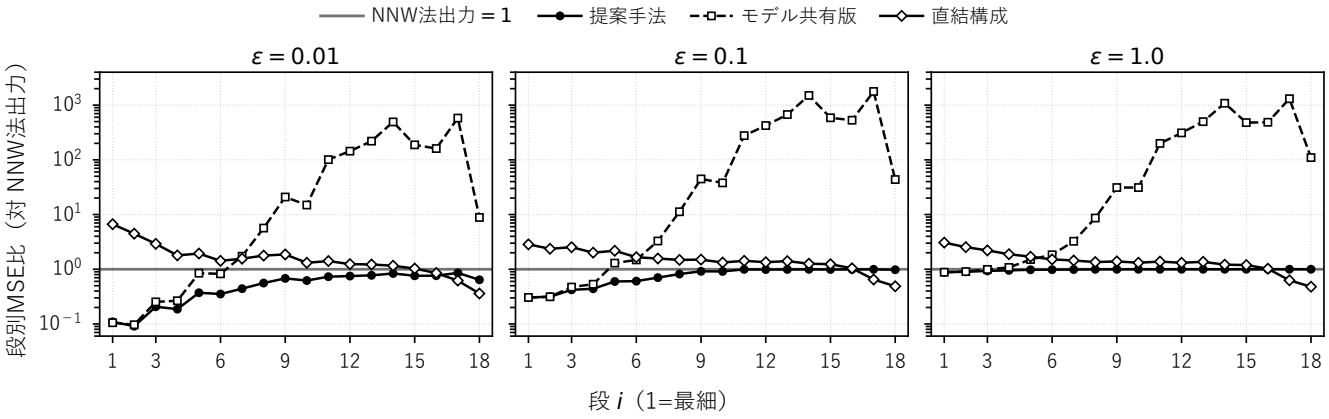


図 D1　段別 MSE 比（対 NNW 法出力）

Fig. D1　Level-wise MSE ratios relative to the output of the non-negative wavelet method.

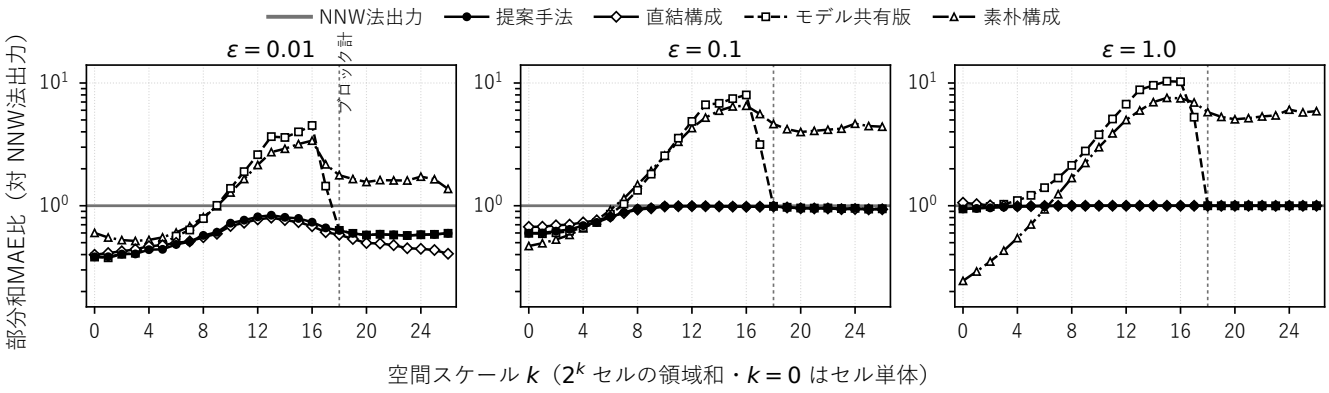


図 D2　部分和 MAE 比（対 NNW 法出力）．図 2 と同一のデータを NNW 法出力を基準とする比で表したもの

Fig. D2　Partial-sum MAE ratios relative to the output of the non-negative wavelet method (the same data as Fig. 2).

表 D2 に部分和 MAE 比を示す．提案手法と直結構成を 3 水準の ε で，モデル共有版と素朴構成（負値を含む）を $\varepsilon = 0.1$ で示す．他の ε でも傾向は同様である．共有版の $k \geq 18$ が提案手法と一致するのは，最上位近似係数のフィルタを共有する構成のためである．

表 D3 に NNW 法出力の部分和 MAE の絶対値を示す．表 D2 の比に本表を乗じることで，各手法の絶対誤差が復元できる．

表 D4 に，学習期間で真値を参照してパラメータを凍結した真値参照版に対する提案手法の誤差比を示す．1 未満は提案手法の誤差が小さいことを意味する．

真値を参照しない同定と真値参照の凍結との差は小さく，全スケール・全 ε を通じてセル・$\varepsilon = 0.01$ での -6.6% から $k = 10$・$\varepsilon = 0.01$ の $+2.3\%$ の範囲にとどまる．$\varepsilon \leq 0.1$ でセルの比が 1 を下回るのは，凍結値に対して日次更新の追従が働くためである．

© 2026 Information Processing Society of Japan

表 D2　部分和 MAE 比（対 NNW 法出力・評価窓平均）

Table D2　Partial-sum MAE ratios relative to the NNW output.

	提案			直結			共有版	素朴
k	0.01	0.1	1.0	0.01	0.1	1.0	0.1	0.1
0	0.3836	0.5981	0.9419	0.3987	0.6728	1.0590	0.5962	0.4697
1	0.3840	0.6003	0.9502	0.4117	0.6747	1.0306	0.5918	0.4950
2	0.4039	0.6205	0.9609	0.4256	0.6926	1.0068	0.6023	0.5301
3	0.4049	0.6415	0.9734	0.4408	0.7021	0.9965	0.6196	0.5789
4	0.4384	0.6888	0.9821	0.4685	0.7320	0.9886	0.6643	0.6548
5	0.4413	0.7312	0.9904	0.4763	0.7608	0.9925	0.7304	0.7611
6	0.4836	0.8062	0.9957	0.4986	0.8152	0.9958	0.8529	0.9244
7	0.5094	0.8822	0.9987	0.5124	0.8715	0.9978	1.0323	1.1472
8	0.5730	0.9464	0.9992	0.5535	0.9303	0.9993	1.3364	1.4848
9	0.6080	0.9609	0.9997	0.5909	0.9526	0.9997	1.8099	1.9215
10	0.7211	0.9923	0.9999	0.6834	0.9860	0.9999	2.5521	2.5607
11	0.7630	0.9910	1.0000	0.7268	0.9906	1.0000	3.5528	3.3224
12	0.8117	0.9935	1.0000	0.7733	0.9923	0.9999	4.8645	4.2964
13	0.8368	0.9932	0.9999	0.7988	0.9913	0.9998	6.6490	5.2234
14	0.8045	0.9906	0.9999	0.7643	0.9872	0.9998	6.8300	5.9490
15	0.7881	0.9880	0.9997	0.7350	0.9834	0.9996	7.4593	6.4448
16	0.7346	0.9834	0.9995	0.6814	0.9804	0.9995	7.9930	6.5228
17	0.6598	0.9845	0.9995	0.6088	0.9816	0.9995	3.1518	5.5902
18	0.6294	0.9890	0.9995	0.5805	0.9857	0.9994	0.9890	4.6325
19	0.5952	0.9713	0.9986	0.5360	0.9676	0.9985	0.9713	4.2082
20	0.5768	0.9581	0.9990	0.4966	0.9528	0.9990	0.9581	3.9899
21	0.5852	0.9564	0.9993	0.4925	0.9503	0.9992	0.9564	4.0773
22	0.5784	0.9586	0.9993	0.4773	0.9501	0.9992	0.9586	4.1650
23	0.5719	0.9483	0.9981	0.4505	0.9379	0.9979	0.9483	4.2456
24	0.5802	0.9527	0.9989	0.4457	0.9401	0.9987	0.9527	4.6587
25	0.5844	0.9395	0.9985	0.4357	0.9341	0.9985	0.9395	4.4600
26	0.5961	0.9442	1.0000	0.4061	0.9355	0.9999	0.9442	4.4060

表 D3　NNW 法出力の部分和 MAE（絶対値・評価窓平均）

Table D3　Partial-sum MAE of the NNW output (absolute values).

k	ε=0.01	ε=0.1	ε=1.0
0	54.792	18.303	4.089
4	250.8	52.949	7.872
8	662.6	86.446	9.353
12	953.2	100.2	10.227
16	1,696	176.9	18.060
18	3,348	351.3	35.841
22	9,001	937.3	95.863
26	26,504	2,555	258.3

表 D4　真値参照版に対する提案手法の誤差比（提案手法／真値参照版）

Table D4　Error ratios of the proposed method to the oracle variant.

量	ε=0.01	ε=0.1	ε=1.0
セル MAE 比	0.9344	0.9744	1.0003
$k = 9$	1.0168	1.0056	1.0000
$k = 13$	1.0166	1.0001	1.0000
$k = 18$	0.9984	1.0029	1.0000
$k = 26$	0.9964	0.9973	1.0001

© 2026 Information Processing Society of Japan