ストリーミングデータの w-event differential privacy に関する一考察

髙岡 陽色[1,a)]　王 立華[2]　野島 良[1]　菊池 浩明[3]

概要：ストリーミングデータの継続公開では，限られたプライバシー予算の下で高い公開精度を維持する必要がある．SPAS（Sampling-based Private Adaptive Sampling）は，Weighted Sparse Vector Technique（Weighted-SVT）により，公開時刻と公開予算を適応的に決定する．しかし，非公開時刻では直前の公開値を再利用するため，周期性や急激な変動を含む時系列では誤差が増大する．本研究では，次時刻のデータ予測と LightGBM による将来変動予測を組み合わせた PredictionSPAS を提案する．将来変動予測では，未来ウィンドウの分散を教師信号として学習し，予測分散に基づいて公開間隔を適応的に決定する．UCI Bike Sharing Dataset による評価では，$\varepsilon \in 0.5, 1.0, 2.0$ のすべてで，オリジナル SPAS（OfficialSPAS）と比較して MSE および MAE を改善し，公開率と Forced Release 回数も削減した．以上より，PredictionSPAS は SPAS と同一のプライバシー予算配分の下で，追加のプライバシー予算を必要とせずに有用性を改善できることを確認した．

キーワード：差分プライバシー，ストリーミングデータ，w-event differential privacy，時系列予測，weighted SVT

A Study on w-Event Differential Privacy Anonymization for Time-Series Data

Hiiro Takaoka[1,a)]　Lihua Wang[2]　Ryo Nojima[1]　Hiroaki Kikuchi[3]

Abstract: Continuous publication of streaming data requires maintaining high utility under a limited privacy budget. SPAS uses the Weighted Sparse Vector Technique (Weighted-SVT) to adaptively determine release times and privacy-budget allocation. However, reusing the most recently released value at non-release timestamps can reduce accuracy for time series with periodic patterns or abrupt changes. We propose PredictionSPAS, which combines next-value prediction with a LightGBM-based release prediction model. The model uses the variance over a future window as its prediction target and adaptively determines the release interval from the predicted variance. Experiments on the UCI Bike Sharing Dataset show that PredictionSPAS improves both MSE and MAE over the original SPAS (OfficialSPAS) for all evaluated privacy budgets, $\epsilon = 0.5, 1.0, 2.0$, while reducing the release rate and the number of forced releases. These results show that PredictionSPAS improves utility without requiring additional privacy budget beyond that used by SPAS.

Keywords: differential privacy, streaming data, w-event differential privacy, time-series prediction, weighted SVT

[1] 立命館大学
Ritsumeikan University
[2] 情報通信研究機構
National Institute of Information and Communications Technology
[3] 明治大学
Meiji University
[a)] is0674rf@ed.ritsumei.ac.jp

1. はじめに

交通量，購買数，医療統計，センサデータなど，時間とともに変化する集計値を継続的に公開する場面が増えている．一方，公開対象となる集計値には個人の行動や状態が

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

反映される場合があり，単純な公開はプライバシー漏洩につながる可能性がある．

差分プライバシー（Differential Privacy; DP）は，隣接するデータベースに対して出力の確率分布が大きく変化しないことを保証することにより，個々のデータに関する情報漏洩を抑制する枠組みであり，プライバシー保護を伴う統計解析の標準的な手法として広く研究されている [2], [4]．しかし，ストリーミングデータの各時刻に対して独立に差分プライバシー機構を適用すると，時間方向の合成によってプライバシー損失が累積するという問題がある [3], [13]．

この問題に対し，Kellaris らは，任意の長さ w の時間ウィンドウに含まれるイベント列に対してプライバシーを保証する w-event differential privacy を提案した [6]．その後，限られたプライバシー予算を効率的に利用するため，公開時刻や予算配分を適応的に制御する方式が提案されている．例えば，Budget Distribution（BD）および Budget Absorption（BA）[6]，Sparse Vector Technique（SVT）を用いる DSFT/DSAT [7]，過去の公開結果からサンプリング間隔を調整する RescueDP [10] や SecWeb [11]，時系列データをクラスタリングする PeGaSuS [1]，IoT の時空間データを対象とする AdaPub [12] などがある．

一方，これらの方式の性能はデータストリームの変動特性に依存し，すべてのデータストリームで一貫して高い精度を達成する方式は存在しないことが報告されている [9]．この課題に対し SPAS [8] は，過去のノイズ付き公開値から将来のデータ変動を推定し，長さ w のウィンドウにおける最適な公開回数 C_i^* を決定する．さらに，weighted Sparse Vector Technique（weighted SVT）により，データの変化に応じて公開時刻と公開予算を適応的に制御する．

しかし SPAS では，補正公開を行わない時刻に直前のノイズ付き公開値を再利用する．データが安定している場合には有効である一方，周期性やトレンドを持つデータでは真値との乖離が大きくなる可能性がある．例えば，

$$50, 100, 150, 50, 100, 150, \ldots$$

のような周期的なストリームでは，直前の公開値のみを再利用する方法では周期的な増減に追従しにくい．一方，過去の公開値から周期的な変動を推定できれば，新しい公開を行わない時刻においても，現在値をより高い精度で推定できる可能性がある．

そこで本稿では，過去の差分プライバシー公開値から現在値を予測する次データ予測と，将来のデータ変動を予測する公開予測を組み合わせた PredictionSPAS を提案する．次データ予測では，過去の差分プライバシー公開値のみから現在値を予測し，予測残差を weighted SVT により判定する．残差がしきい値以下の場合は予測値を公開し，しきい値を超えた場合のみラプラスノイズを付加した補正公開を行う．予測には既公開の差分プライバシー値のみを用いるため，追加のプライバシー予算を必要としない．

さらに，LightGBM を用いた Macro Predictor により将来ウィンドウのデータ変動の分散を予測し，その予測値に基づいて公開回数 C_i^* を適応的に決定する．これにより，変動が大きい場合は公開頻度を高め，小さい場合は公開頻度を抑えることで，プライバシー予算の効率的な利用を図る．

本稿では，Li らの論文 [8] および Li らが公開している SPAS のソースコード [14] を参照し，ウォームアップ，C_i^* の更新，weighted SVT による公開判定，残余予算状況に基づく強制公開，およびスライディングウィンドウ内の予算管理を含む公開アルゴリズムを再現した．その上で，非公開時刻において直前の公開値を用いる処理を次データの予測値を用いる処理に置き換え，予測された将来のウィンドウ分散に基づいて公開回数を制御する手法を提案する．UCI Bike Sharing Dataset [5] を用いた評価では，$\varepsilon = 0.5, 1.0, 2.0$ のすべての条件で OfficialSPAS と比較して MSE および MAE を改善し，公開率および強制公開回数を削減できることを確認した．

本稿の構成は以下の通りである．第 2 節では，ストリーミングデータ，w-event differential privacy，および weighted SVT を含む SPAS の概要を述べる．第 3 節では提案方式 PredictionSPAS について説明する．第 4 節では UCI Bike Sharing Dataset を用いた評価を行い，提案方式の有効性を検証する．最後に，第 5 節で本稿をまとめる．

2. 準備

2.1 ストリーミングデータ

時刻 i における真のデータを，d 個のカテゴリに対するカウントからなるヒストグラム

$$H_i = (H_i[1], H_i[2], \ldots, H_i[d])$$

とする．ここで，$H_i[j]$ は時刻 i におけるカテゴリ j のデータ数を表す．ストリーム全体を

$$\mathcal{H} = \{H_1, H_2, \ldots, H_i, \ldots\}$$

と表す．また，時刻 i に公開される値を $\widehat{H}_i$ とし，公開系列を

$$\widehat{\mathcal{H}} = \{\widehat{H}_1, \widehat{H}_2, \ldots, \widehat{H}_i, \ldots\}$$

とする．本稿の目的は，真のストリーム $\mathcal{H}$ と公開系列 $\widehat{\mathcal{H}}$ の誤差を抑えながら，w-event differential privacy を満たすことである．

ここで，差分プライバシーにおける隣接関係を定義する．本稿では，ある時刻におけるデータ集合から 1 レコードを追加または削除することで得られる二つのデータ集合を隣接とする．これをヒストグラムで表すと，二つのヒストグラム H_i, H_i' が $H_i \sim H_i'$ であるとは，$\|H_i - H_i'\|_1 \leq 1$ を満

© 2026 Information Processing Society of Japan

たすことをいう．すなわち，一人分のデータの追加または削除によって，いずれか一つのカテゴリのカウントが高々 1 だけ変化する場合を隣接とみなす．次に，時刻 i のヒストグラムそのものを公開する写像を $f_p(H_i) = H_i$ とする．この写像の ℓ_1 感度は，隣接する任意の H_i, H_i' に対して

$$\Delta_p = \max_{H_i \sim H_i'} \|f_p(H_i) - f_p(H_i')\|_1$$

と定義される．上記の隣接関係より，

$$\Delta_p = \max_{H_i \sim H_i'} \|H_i - H_i'\|_1 \leq 1$$

であるため，本稿では $\Delta_p = 1$ とする．したがって，プライバシー予算 ε' を用いてヒストグラムを公開する場合，各成分に $\mathrm{Lap}(\Delta_p/\varepsilon')$ に従うノイズを付加するラプラス機構を利用できる．

2.2 w-Event Differential Privacy

通常の event-level differential privacy では，一つの時刻における一つのイベントの変化を保護対象とする．一方，ストリーミングデータでは時間的に近接する複数のイベントが相関を持つ場合があるため，一つのイベントだけでなく，一定期間に含まれるイベント列全体を保護する必要がある．w-event differential privacy は，任意の長さ w の時間ウィンドウに含まれるイベント列に対して差分プライバシーを保証する枠組みである [6], [8].

二つのストリーム

$$\mathcal{H} = \{H_1, H_2, \ldots\}, \qquad \mathcal{H}' = \{H_1', H_2', \ldots\}$$

を考える．両ストリームで値が異なる時刻の集合を

$$I(\mathcal{H}, \mathcal{H}') = \{i \mid H_i \neq H_i'\}$$

とする．$\mathcal{H}$ と $\mathcal{H}'$ が w-隣接であるとは，以下の二つの条件を満たすことをいう．

(1) 値が異なる各時刻 $i \in I(\mathcal{H}, \mathcal{H}')$ において，H_i と H_i' は隣接する．すなわち，

$$H_i \sim H_i'$$

が成立する．

(2) 両ストリームで値が異なるすべての時刻が，長さ w 以下の一つの連続した時間ウィンドウに含まれる．すなわち，$I(\mathcal{H}, \mathcal{H}') \neq \emptyset$ のとき，

$$\max I(\mathcal{H}, \mathcal{H}') - \min I(\mathcal{H}, \mathcal{H}') + 1 \leq w$$

が成立する．

例えば $w = 3$ の場合，時刻 $5, 6, 7$ におけるデータがそれぞれ隣接する値へ変化した二つのストリームは w-隣接である．一方，時刻 5 と時刻 8 が異なる場合には，両時刻を長さ 3 の一つの時間ウィンドウに含めることができないため，w-隣接ではない．

公開アルゴリズム $\mathcal{M}$ が w-event ε-differential privacy を満たすとは，任意の w-隣接なストリーム $\mathcal{H}, \mathcal{H}'$ と任意の出力集合 O に対して，

$$\Pr[\mathcal{M}(\mathcal{H}) \in O] \leq e^{\varepsilon} \Pr[\mathcal{M}(\mathcal{H}') \in O]$$

が成立することをいう．

すなわち，ストリーム上の任意の長さ w の時間ウィンドウについて，そのウィンドウ内に含まれるイベント列が変化した場合でも，公開結果の確率分布の変化を e^{ε} 倍以内に抑える．この条件をスライディングウィンドウ上のすべての位置で満たすことにより，無限に継続するストリームに対しても，任意の長さ w の区間におけるプライバシー損失を ε 以下に制御する．

2.3 SPAS における公開回数と予算配分

SPAS [8] では，各スライディングウィンドウに対するプライバシー予算 ε を，

$$\varepsilon = \varepsilon_s + \varepsilon_p$$

の二つに分割する．ここで，ε_s は weighted SVT による公開判定に使用するプライバシー予算であり，ε_p は実際にヒストグラムへノイズを付加して公開するためのプライバシー予算である．SPAS では，

$$\varepsilon_s = \frac{\varepsilon}{4}, \qquad \varepsilon_p = \frac{3\varepsilon}{4}$$

としている．SPAS は，過去に公開されたノイズ付きヒストグラムの変化から，現在時刻 i から始まる長さ w のウィンドウ

$$\{H_i, H_{i+1}, \ldots, H_{i+w-1}\}$$

において，何回のデータ公開を行うことが望ましいかを推定する．この推定値を最適公開回数 C_i^* とする．SPAS で導出される近似式は，

$$C_i^* = \left\lceil \frac{\varepsilon_p}{6\Delta_p} \sqrt{3 \operatorname{Var}(\widetilde{E}_{\mathrm{dis}})} \right\rceil$$

である．ここで，$\operatorname{Var}(\widetilde{E}_{\mathrm{dis}})$ は，過去に公開された隣接するノイズ付きヒストグラム間の変化から計算される分散であり，データストリームの変動の大きさを表す．

C_i^* が大きい場合には，今後のウィンドウ内で多くのデータを公開する必要があると判断され，一回の公開に割り当てるプライバシー予算は小さくなる．逆に C_i^* が小さい場合には，公開回数を少なくする代わりに，一回の公開へより大きな予算を割り当てることができる．

時刻 i における一回の公開に対する基準予算を

$$\varepsilon_{p,i} = \frac{\varepsilon_p}{C_i^*}$$

© 2026 Information Processing Society of Japan

とする．これにより SPAS は，データストリームの変動に応じて公開回数と一回当たりのプライバシー予算を適応的に調整する．

なお，本稿の評価で用いる公開コード互換実装では，公開コードの処理に合わせ，C_i^* の計算結果を整数化し，下限を 1 としている．

2.4 Weighted SVT による公開判定

SPAS では，各時刻において現在のデータを新たに公開するか，直前の公開結果を再利用するかを weighted Sparse Vector Technique（weighted SVT）により判定する．

時刻 i において，現在の真のヒストグラム H_i と，既に差分プライバシーを満たして公開されている直前の公開値 $\widehat{H}_{i-1}$ との平均絶対距離を

$$q_i^{\mathrm{SPAS}}(H_i) = \frac{1}{d}\sum_{j=1}^{d}\left|H_i[j] - \widehat{H}_{i-1}[j]\right|$$

と定義する．SPAS では，この値を「現在のデータが直前の公開値からどの程度変化したか」を表すスカラー値として weighted SVT の判定に用いる．以下ではこれを距離クエリと呼ぶ．

ここで，$\widehat{H}_{i-1}$ は既に公開された値であるため，時刻 i の現在値 H_i を変化させたときには固定された値として扱うことができる．したがって，隣接する二つのヒストグラム H_i, H_i' に対する距離クエリの変化は，三角不等式より

$$\begin{aligned}&\left|q_i^{\mathrm{SPAS}}(H_i) - q_i^{\mathrm{SPAS}}(H_i')\right| \\ &\quad\le \frac{1}{d}\|H_i - H_i'\|_1 \le \frac{1}{d} \le 1.\end{aligned}$$

よって，この距離クエリの感度は 1 以下である．本稿の評価では SPAS の公開実装と同じく，保守的な値として $\Delta_s = 1$ を用いる．公開判定に用いる予算 ε_s を $\varepsilon_1 = \frac{\varepsilon_s}{2}$，$\varepsilon_2 = \frac{\varepsilon_s}{2}$ に分割する．また，時刻 i の判定しきい値を

$$T_i = \frac{C_i^*\Delta_p}{\varepsilon_p}$$

とする．

weighted SVT では，しきい値に加えるノイズを

$$\rho \sim \mathrm{Lap}\left(\frac{\Delta_s}{\varepsilon_1}\right)$$

とし，距離クエリに加えるノイズを

$$\nu_i \sim \mathrm{Lap}\left(\frac{2C_i^*\Delta_s}{\varepsilon_2}\right)$$

として生成する．時刻 i において，

$$q_i^{\mathrm{SPAS}}(H_i) + \nu_i > T_i + \rho$$

を満たし，かつ現在のスライディングウィンドウ内に十分な公開予算が残されている場合，現在のヒストグラム H_i を新たに公開する．このとき公開値は，

$$\widehat{H}_i = H_i + \left\langle \mathrm{Lap}\left(\frac{\Delta_p}{\varepsilon'_{p,i}}\right)\right\rangle^d$$

である．

ここで，$\varepsilon'_{p,i}$ は時刻 i の公開に割り当てるプライバシー予算であり，非公開時には 0 とする．SPAS [8] と同様に，任意の長さ w のウィンドウについて

$$\sum_{j=\max\{1,i-w+1\}}^{i}\varepsilon'_{p,j} \le \varepsilon_p \tag{1}$$

を満たすように決定する．

weighted SVT による公開判定が負の場合には，$\widehat{H}_i = \widehat{H}_{i-1}$ として直前の公開値を再利用する．公開判定が正であっても十分な公開予算が残されていない場合には，新たな公開を行わず，直前の公開値を再利用する．また，残りの時刻に公開用の残余予算を割り当てるために公開が必要な場合は，weighted SVT の判定を省略し，$\varepsilon'_{p,i}$ を用いてノイズ付き公開を行う（Forced Release）．

3. 提案手法

3.1 基本方針

提案方式 PredictionSPAS では, SPAS の Weighted SVT, 公開間隔 C_i^* の更新, 残余予算管理および強制公開機構を維持したまま，Micro Predictor による予測値を公開判定および非公開時刻の出力に利用する．さらに，Macro Predictor により予測した未来ウィンドウの分散に基づいて公開間隔 C_i^* を適応的に制御することで，追加のプライバシー予算を消費することなく公開精度の向上を図る．

時刻 i における予測値を

$$\widetilde{H}_i = F_i\left(\widehat{H}_1, \widehat{H}_2, \ldots, \widehat{H}_{i-1}\right)$$

とする．予測器 F_i は，真の過去データではなく，既に差分プライバシーを満たして公開された値のみを利用する．したがって，$\widetilde{H}_i$ の生成は差分プライバシーの後処理に相当し，追加のプライバシー予算を消費しない．

Macro Predictor は，過去の公開データから生成した特徴量を入力とし，将来の一定区間におけるデータの分散を予測する．予測された分散は SPAS の公開間隔更新式へ入力され，データ変動が大きいと予測される場合には公開間隔を短く，変動が小さい場合には公開間隔を長く設定する．これにより，将来の変動を考慮した適応的な公開制御を実現する．

3.2 予測残差

現在値と予測値の平均絶対距離を

© 2026 Information Processing Society of Japan

表 1　SPAS と PredictionSPAS の相違点

項目	SPAS	PredictionSPAS
公開間隔	過去の変動分散から算出	未来の分散予測から算出
判定距離	$\|H_i - \widehat{H}_{i-1}\|_1/d$	$\|H_i - \widetilde{H}_i\|_1/d$
非公開時	$\widehat{H}_{i-1}$	$\widetilde{H}_i$

$$q_i(H_i) = \frac{1}{d}\sum_{j=1}^{d}\left|H_i[j] - \widetilde{H}_i[j]\right|$$

と定義する．二つの近傍ヒストグラム H_i, H_i' に対して，予測値 $\widetilde{H}_i$ は現在値に依存しないため，q_i の感度は

$$\begin{aligned}\Delta_q &= \max_{H_i \sim H_i'} |q_i(H_i) - q_i(H_i')| \\ &\leq \frac{1}{d}\|H_i - H_i'\|_1 \\ &\leq \frac{1}{d} \leq 1\end{aligned}$$

となる．したがって，SPAS 公開実装と同じ保守的な感度 $\Delta_s = 1$ を用いることができる．

PredictionSPAS は，現在値を予測する Micro Predictor と，将来の変動を予測する Macro Predictor を組み合わせることで，公開精度とプライバシー予算利用効率の両立を図る．

3.3　Weighted SVT を用いた予測残差判定

PredictionSPAS では，SPAS のクエリ d_i^{SPAS} を予測残差 $q_i(H_i)$ に置き換える．すなわち，$q_i(H_i) + \nu_i > T_i + \rho$ を満たし，かつ残余予算が十分にある場合に，現在値をノイズ付きで補正公開する．

補正公開を行う場合は，SPAS と同じラプラス機構および予算管理を用いる．一方，公開判定が負の場合は，直前値を再利用するのではなく，$\widehat{H}_i = \widetilde{H}_i$ として予測値を公開する．したがって，SPAS と PredictionSPAS の差は表 1 の通りである．Weighted SVT による公開判定，プライバシー予算管理，および強制公開の仕組みは SPAS と同一であり，本研究では公開判定の参照値，非公開時刻の出力，および公開間隔の決定方法のみを変更した．

3.4　処理手順

PredictionSPAS の処理手順を以下に示す．

(1) 過去の公開データから Macro Predictor により未来ウィンドウの分散を予測し，公開回数 C_i^* を更新する．
(2) 過去の公開データから Micro Predictor により，現在値の予測値 $\widetilde{H}_i$ を計算する．
(3) 現在値 H_i と予測値 $\widetilde{H}_i$ との予測残差を算出する．
(4) Weighted SVT により予測残差を判定する．
(5) Weighted SVT の判定が正であり，かつ現在のスライディングウィンドウ内に補正公開に必要なプライバシー予算が残されている場合，現在値 H_i にラプラスノイズを付加して公開する．また，強制公開条件を満たす場合には，Weighted SVT の判定によらず補正公開を行う．
(6) Weighted SVT の判定が正であっても，スライディングウィンドウ内の残余予算が不足している場合には，補正公開を行わず，予測値 $\widetilde{H}_i$ を公開値として出力する．
(7) Weighted SVT の判定が負の場合にも，補正公開を行わず，予測値 $\widetilde{H}_i$ を公開値として出力する．
(8) 公開結果を履歴に反映し，次時刻の予測に利用する．

3.5　プライバシーに関する考察

PredictionSPAS が SPAS から変更するのは，weighted SVT に入力する残差クエリと，新たなデータを公開しない時刻に出力する値である．一方，weighted SVT のプライバシー予算配分，Forced Release を含む公開用予算のスライディングウィンドウ会計，および公開時に用いる Laplace 機構は SPAS [8] から変更しない．

予測値 $\widetilde{H}_i$ は過去の公開値のみから計算される後処理であり，追加のプライバシー予算を消費しない．また，残差クエリの感度は $\Delta_q \leq 1$ であり，Forced Release を含む任意の長さ w のウィンドウにおける公開用予算の総和は ε_p 以下に制限される．

以上より，PredictionSPAS における変更は，SPAS と同じ $\varepsilon_s + \varepsilon_p = \varepsilon$ の予算配分と整合する．ただし，予測値を用いた残差クエリ，Forced Release，およびスライディングウィンドウ上の予算合成を含む方式全体の形式的なプライバシー証明は，今後の課題とする．

4.　評価

4.1　使用データ

実験には，UCI Machine Learning Repository で公開されている Bike Sharing Dataset の時間別データを用いた [5]．各時刻 t における一般利用者数と登録利用者数を要素とするカウントベクトル

$$H_t = \left(H_t^{\mathrm{casual}}, H_t^{\mathrm{registered}}\right)$$

を，各時刻 t の真のデータとして扱った．

2011 年 1 月 1 日から始まる 2160 時間分を使用した．欠落している時刻については，時系列を 1 時間間隔に再配置し，利用件数を 0 として補完した．

4.2　比較方式

以下の 4 方式を比較した．

Uniform　全時刻でノイズ付きヒストグラムを公開する．任意の長さ w のウィンドウにおける合計予算が ε となるよう，各時刻へ均等に予算を割り当てる．

FixedSample　6 時間間隔でノイズ付き公開を行い，それ以外の時刻では直前値を再利用する．

© 2026 Information Processing Society of Japan

OfficialSPAS　SPAS の公開コードを参照した独立再実装である．ウォームアップ，C_i^* の適応的更新，weighted SVT，残余予算に基づく強制公開，およびスライディングウィンドウ予算管理を含む．

PredictionSPAS　OfficialSPAS と同一の Weighted SVT および予算管理を維持し，Macro Predictor により公開間隔を適応的に決定する．また，判定対象を予測残差とし，非公開時には予測値を出力する．

4.3　予測モデル

PredictionSPAS では，現在値の予測に Micro Predictor，将来のデータ変動の予測に Macro Predictor を用いる．

Micro Predictor では，線形トレンドと 24 時間の日周期を用いて時刻 t の各次元を予測する．各次元 j $(j = 1, \ldots, d)$ について，予測値を

$$\widetilde{H}_t[j] = \beta_0^{(j)} + \beta_1^{(j)} t + \sum_{k=1}^{3} \left(a_k^{(j)} \sin \frac{2\pi k t}{24} + b_k^{(j)} \cos \frac{2\pi k t}{24} \right)$$

とする．係数はリッジ回帰によって推定した．正則化係数は $\alpha = 1.0$ とし，学習には直近 168 時間（7 日間）の公開データを用いた．モデルは新たな補正公開が得られるたびに更新し，各ヒストグラム次元ごとに独立した回帰モデルを学習した．また，予測値が負となった場合は，ヒストグラムの非負性を保つため 0 に切り上げた．

Macro Predictor では，過去の公開データから生成した直近 3，6，12，24 ステップの平均・中央値，指数移動平均，直近の変化量，変動の急激さなどの特徴量を入力として，将来ウィンドウの分散を LightGBM により予測する．予測された分散は公開間隔 C_i^* の更新に利用され，将来の変動が大きい場合には公開間隔を短く，小さい場合には長く設定することで，適応的な公開制御を実現する．

4.4　実験設定

実験設定を表 2 に示す．評価には UCI Bike Sharing Dataset を用い，ストリーム長は 2160 時間，ヒストグラム次元は $d = 2$，スライディングウィンドウ長は $w = 24$ とした．プライバシー予算は $\varepsilon = 1.0$ を基本設定とし，さらに提案手法の有効性を確認するため，$\varepsilon = 0.5$ および $\varepsilon = 2.0$ についても評価を行った．各条件について 10 試行を行い，平均値を評価結果として用いた．

公開コードではウォームアップ処理を含む実装をそのまま再現した．そのため，一部のウィンドウでは記録される公開予算が理論上の上限を超える場合があるが，本研究では公開コードとの互換性を優先し，この挙動を変更せず評価を行った．

表 2　実験設定

項目	設定値
ストリーム長	2160 時間
ヒストグラム次元 d	2
ウィンドウ長 w	24
プライバシー予算 ε	1.0
weighted SVT 用予算 ε_s	0.25
公開用予算 ε_p	0.75
距離クエリ感度 Δ_s	1
公開感度 Δ_p	1
ウォームアップウィンドウ数	1
分散推定ウィンドウ数	2
日周期／高調波数	24 時間／ 3
固定サンプリング間隔	6 時間
リッジ回帰正則化係数	1.0
Micro Predictor 学習ウィンドウ長	168 時間
Micro Predictor 更新間隔	補正公開時
負値予測の処理	0 へクリップ
試行回数	10

4.5　評価指標

平均二乗誤差（MSE）を

$$\mathrm{MSE} = \frac{1}{Td} \sum_{t=1}^{T} \sum_{j=1}^{d} \left(H_t[j] - \widehat{H}_t[j] \right)^2$$

とする．平均絶対誤差（MAE）を

$$\mathrm{MAE} = \frac{1}{Td} \sum_{t=1}^{T} \sum_{j=1}^{d} \left| H_t[j] - \widehat{H}_t[j] \right|$$

とする．公開回数を N_{pub} として，公開率を

$$R_{\mathrm{pub}} = \frac{N_{\mathrm{pub}}}{T}$$

とする．また，SPAS では各スライディングウィンドウにおいて，残りの時刻数と残余予算を考慮し，このままではウィンドウ内で必要な公開を実現できない場合に強制公開（Forced Release）を行う．本稿では，この強制公開の回数も評価指標とした．

4.6　実験結果

各条件について 10 試行を行い，平均値および標準偏差を示す．$\varepsilon = 1.0$ の比較結果を表 3 に，異なるプライバシー予算での結果を表 4 に示す．表 3 より，$\varepsilon = 1.0$ では PredictionSPAS は OfficialSPAS と比較して，MSE を 27.6%，MAE を 16.9% 低減し，公開率を 64.8%，強制公開回数を 163.0 回から 6.7 回へ削減した．また，表 4 より，$\varepsilon = 0.5, 1.0, 2.0$ のすべての条件で MSE，MAE，公開率および強制公開回数の改善が確認された．

図 1 に公開結果の例を示す．OfficialSPAS では非公開時刻に直前の公開値を再利用するため，出力が階段状に推移している．一方，PredictionSPAS では非公開時刻にも予

© 2026 Information Processing Society of Japan

表 3　$\varepsilon = 1.0$ における各手法の比較

Method	MSE	MAE	Release Rate	Forced
Uniform	$\mathbf{1137.15 \pm 50.31}$	23.86 ± 0.39	1.000 ± 0.000	0.0 ± 0.0
FixedSample	2092.28 ± 17.38	$\mathbf{23.65 \pm 0.14}$	0.167 ± 0.000	0.0 ± 0.0
OfficialSPAS	2678.66 ± 367.91	30.04 ± 2.24	0.159 ± 0.015	163.0 ± 27.6
PredictionSPAS	1938.63 ± 1325.29	24.97 ± 2.28	$\mathbf{0.056 \pm 0.020}$	$\mathbf{6.7 \pm 5.8}$

表 4　異なるプライバシー予算における評価結果

ε	Method	MSE	MAE	Release Rate	Forced
0.5	OfficialSPAS	2699.98 ± 161.81	31.68 ± 1.21	0.069 ± 0.007	26.6 ± 6.1
0.5	PredictionSPAS	$\mathbf{1578.14 \pm 392.72}$	$\mathbf{23.96 \pm 1.74}$	$\mathbf{0.041 \pm 0.006}$	$\mathbf{0.0 \pm 0.0}$
1.0	OfficialSPAS	2678.66 ± 367.91	30.04 ± 2.24	0.159 ± 0.015	163.0 ± 27.6
1.0	PredictionSPAS	$\mathbf{1938.63 \pm 1325.29}$	$\mathbf{24.97 \pm 2.28}$	$\mathbf{0.056 \pm 0.020}$	$\mathbf{6.7 \pm 5.8}$
2.0	OfficialSPAS	1936.74 ± 516.96	23.71 ± 2.53	0.275 ± 0.024	374.8 ± 53.7
2.0	PredictionSPAS	$\mathbf{1345.01 \pm 314.25}$	$\mathbf{21.25 \pm 1.91}$	$\mathbf{0.085 \pm 0.013}$	$\mathbf{45.6 \pm 10.2}$

測値を出力するため，出力が更新され，真値の変動を反映した波形となっている．

4.7　考察

OfficialSPAS では，補正公開が行われない期間に直前の公開値を再利用するため，周期的に変動する Bike Sharing Dataset では上昇・下降局面で再利用誤差が大きくなる．

これに対し PredictionSPAS では，次データ予測により非公開時刻の値を推定し，Macro Predictor により公開間隔を適応的に制御する．その結果，OfficialSPAS と比較して MSE および MAE を改善するとともに，公開率と強制公開回数も削減できた．$\varepsilon = 1.0$ では，公開率は 0.159 から 0.056，強制公開回数は 163.0 回から 6.7 回に減少した．

一方，PredictionSPAS では試行間の MSE のばらつきが残った．これは，予測に利用する公開値がノイズを含むことや，初期の公開タイミングが予測モデルに影響するためと考えられる．今後は，予測不確実性や急激な変動を考慮した公開・補正機構が課題である．

5.　おわりに

本稿では，w-event differential privacy の下で，過去の差分プライバシー公開値から現在値を予測し，予測残差を weighted SVT で判定する PredictionSPAS を提案した．Micro Predictor による現在値予測と，未来ウィンドウの分散を教師信号とする Macro Predictor による公開間隔 C_i^* の適応制御を組み合わせ，SPAS の weighted SVT および予算管理機構を維持した．

UCI Bike Sharing Dataset を用いた評価では，$\varepsilon = 1.0$ において OfficialSPAS と比較して，MSE を約 27.6%，MAE を約 16.9% 改善し，公開率を約 64.8% 削減した．また，強制公開回数も 163.0 回から 6.7 回へ減少した．$\varepsilon = 0.5$ および 2.0 においても，MSE，MAE および公開率の改善傾向を確認した．

一方，Uniform は全時刻で公開するため，MSE では PredictionSPAS より小さい誤差を示した．PredictionSPAS は，公開率を大幅に抑制しながら OfficialSPAS より高い精度を達成しており，公開頻度と予測精度のトレードオフを改善できる可能性が示された．

今後は，プライバシー会計の形式的検証，複数データセットによる評価，ε および w の感度分析，未知周期への対応，ならびに急激なバーストに対する予測・補正機構の検討が課題である．

謝辞　本研究は JST CREST JPMJCR21M1 の助成を受けたものです．

参考文献

[1] Y. Chen, A. Machanavajjhala, M. Hay, and G. Miklau, “PeGaSus: Data-Adaptive Differentially Private Stream Processing,” in *Proc. ACM SIGSAC Conference on Computer and Communications Security (CCS)*, pp. 1375–1388, 2017.

[2] C. Dwork, F. McSherry, K. Nissim, and A. D. Smith, “Calibrating Noise to Sensitivity in Private Data Analysis,” in *Proc. Theory of Cryptography Conference (TCC)*, pp. 265–284, 2006.

[3] C. Dwork, M. Naor, T. Pitassi, and G. N. Rothblum, “Differential Privacy under Continual Observation,” in *Proc. 42nd ACM Symposium on Theory of Computing (STOC)*, pp. 715–724, 2010.

[4] C. Dwork and A. Roth, “The Algorithmic Foundations of Differential Privacy,” *Foundations and Trends in Theoretical Computer Science*, Vol. 9, Nos. 3–4, pp. 211–407, 2014.

[5] H. Fanaee-T and J. Gama, “Bike Sharing Dataset,” UCI Machine Learning Repository, DOI: 10.24432/C5W894, 2013.

[6] G. Kellaris, S. Papadopoulos, X. Xiao, and D. Papadias, “Differentially Private Event Sequences over Infinite Streams,” *Proceedings of the VLDB Endowment*, Vol. 7, No. 12, pp. 1155–1166, 2014.

[7] H. Li, L. Xiong, X. Jiang, and J. Liu, “Differentially Private Histogram Publication for Dynamic Datasets: an Adaptive Sampling Approach,” in *Proc. 24th ACM International Conference on Information and Knowledge*

© 2026 Information Processing Society of Japan

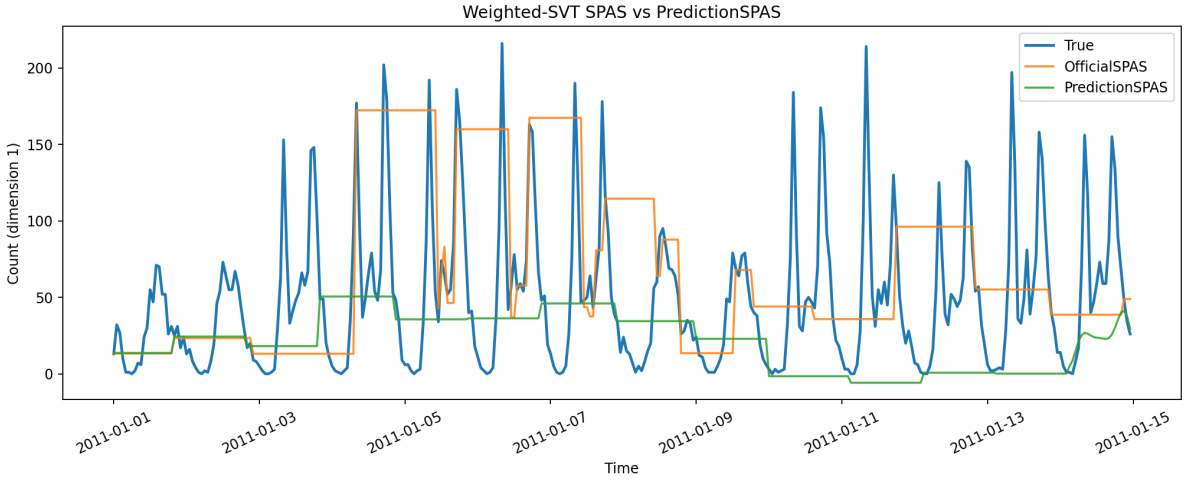


図 1 weighted SVT を用いた OfficialSPAS と PredictionSPAS の公開結果の例

Management (CIKM), pp. 1001–1010, 2015.

[8] X. Li, T. Li, Y. Cheng, C. Gong, K. Ren, Z. Qin, and T. Wang, "SPAS: Continuous Release of Data Streams under w-Event Differential Privacy," *Proceedings of the ACM on Management of Data*, Vol. 3, No. 1, Article 78, 2025.

[9] C. Schäler, T. Hütter, and M. Schäler, "Benchmarking the Utility of w-event Differential Privacy Mechanisms – When Baselines Become Mighty Competitors," *Proceedings of the VLDB Endowment*, Vol. 16, No. 8, pp. 1830–1842, 2023.

[10] Q. Wang, Y. Zhang, X. Lu, Z. Wang, Z. Qin, and K. Ren, "RescueDP: Real-time Spatio-temporal Crowdsourced Data Publishing with Differential Privacy," in *Proc. IEEE INFOCOM*, pp. 1–9, 2016.

[11] Q. Wang, X. Lu, Y. Zhang, Z. Wang, Z. Qin, and K. Ren, "SecWeb: Privacy-Preserving Web Browsing Monitoring with w-Event Differential Privacy," in *Proc. SecureComm*, pp. 454–474, 2016.

[12] T. Wang, X. Yang, X. Ren, J. Zhao, and K.-Y. Lam, "Adaptive Differentially Private Data Stream Publishing in Spatio-temporal Monitoring of IoT," in *Proc. IEEE International Performance Computing and Communications Conference (IPCCC)*, pp. 1–8, 2019.

[13] T. Wang, J. Q. Chen, Z. Zhang, D. Su, Y. Cheng, Z. Li, N. Li, and S. Jha, "Continuous Release of Data Streams under both Centralized and Local Differential Privacy," in *Proc. ACM SIGSAC Conference on Computer and Communications Security (CCS)*, pp. 1237–1253, 2021.

[14] XiaochenLi-w, "Sliding-window-data-release-revision," GitHub repository, `https://github.com/XiaochenLi-w/Sliding-window-data-release-revision`, accessed July 16, 2026.

© 2026 Information Processing Society of Japan