Agentic Searchを用いた匿名化医療情報の再識別リスク測定評価手法の提案

井上 歩紀 [1,a)]　齋田 衛[2]　村上 あさひ[3]　横山 輝明[4]　井上 博之[5]　猪俣 敦夫[6]

概要：医療分野における AI 利用の発展には医療情報の共有が必要であるため，データのプライバシー保護と有用性担保の両立が必要不可欠である．既存の匿名化手法は，特定健康情報（PHI）における個人を特定する識別子やそれに付随した補助情報を想定した攻撃モデルを用いて評価されてきた．しかしながら，Web 検索等を用いて動的に多段階で推論する AI エージェントの登場により，新たな脅威が生じている．具体的には，プロフィールや活動記録，生活習慣といった単体では非識別的な文脈を公開情報の手掛かりとして人物の再識別が可能となる．本論文では，検索型 AI エージェントによる情報探索と照合プロセスを組み込んだ匿名化医療情報の再識別リスクに関する評価手法を提案する．本手法では，匿名化医療情報を AI エージェントに与え，探索した外部情報と照合させることにより，AI エージェントが対象人物を推定する測定手法とリスク評価の手段を構築した．実験の結果から，PHI が除去された文章から AI エージェントによって再識別が可能であることが示された．

キーワード：再識別リスク，匿名化，大規模言語モデル，医療情報

Measurement Evaluation Method for Re-identification Risk of Anonymized Medical Data using Agentic Search

Ibuki Inoue[1,a)]　Mamoru Saita[2]　Asahi Murakami[3]　Teruaki Yokoyama[4]　Hiroyuki Inoue[5]
Atsuo Inomata[6]

Abstract: The advancement of artificial intelligence (AI) in healthcare depends on the sharing of healthcare information, making it essential to preserve both data privacy and utility. Existing re-identification methods have primarily been evaluated using attack models that assume access to personal identifiers and associated auxiliary information contained in Protected Health Information (PHI). However, the emergence of AI agents capable of dynamic, multi-step reasoning through web searches and other information-retrieval mechanisms introduces new privacy threats. For example, contextual information that is not individually identifying—such as profiles, activity logs, lifestyle descriptions concerning culture—may provide clues that enable individuals to be re-identified through publicly available information. In this paper, we proposed a method for measuring and evaluating the re-identification risk of medical information by incorporating the information retrieval and record linkage processes of search-enabled AI agents. Consequently, the proposed method provides de-identified medical information to an AI agent. It assesses whether the agent can infer the subject's identity by retrieving and matching relevant external information. Our experiments show that AI agents pose a high risk of re-identifying individuals, even from de-identified PHI-redacted text.

Keywords: Re-identification Risk, Anonymization, Large Language Models, Medical data

[1] 東京農工大学
Tokyo University of Agriculture and Technology
[2] 日本電気株式会社 セキュアシステムプラットフォーム研究所
Secure System Platform Research Laboratories NEC Corporation
[3] SecHack365 アシスタント
SecHack365 Assistant
[4] 国立研究開発法人情報通信研究機構

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

1. はじめに

人工知能（Artificial Intelligence; AI）は，医療分野において健康上の成果向上に寄与することが期待される [1]．こうした AI の開発には大量の医療データが必要となるため，施設を越えたデータ共有が求められる [2]．このような医療機関が保有する医療データの外部提供においては，患者のプライバシーに配慮し，データを適切に扱う必要がある．これは，医療データには単独で個人を特定できる情報（直接識別子）だけでなく，勤務先，家族関係，既往歴，受診時期，居住地域など，組み合わせることで個人を特定できる情報（準識別子）も多く含まれるためである．したがって，患者のプライバシーを保護するために，データから患者の識別リスクを低減することが不可欠である．

匿名化は代表的なプライバシー保護手法である．医療文章の匿名化では，一般に個人健康情報（Protected / Personal Health Information; PHI）や個人識別情報（Personally Identifiable Information; PII）に該当する表現を検出したのち，削除や別の表現へ置換する．従来の匿名化処理の評価指標には，PHI ／ PII の検出・除去性能を示す適合率や再現率が用いられてきた [3]．

しかしながら，AI エージェントの登場により，外部ツールやアプリケーションを利用して複数段階のタスクを自律的に遂行可能になった [4–6]．このような AI エージェントの能力により，直接的に関連のない情報をつなぎ合わせて目的の情報を横断的に探すことができる [7]．そのため，このような能力を情報探索に用いた場合，匿名化された文章に残るイベントへの参加記録や，組織内での担当役割といった，単体では特定できない手掛かりから，対象人物の候補を段階的に絞り込むことが可能となる．したがって，匿名化処理の評価手法として広く用いられてきた検出率による評価だけでなく，外部情報を横断・結合して対象者を特定する再識別リスクを評価する必要がある．

そこで本研究では，AI エージェントによる再識別リスクを評価するため，公開情報と匿名化済み文章を照合する評価手法を提案する．具体的には，データ作成時に日本の統計情報を反映した合成ペルソナデータを複数のカテゴリの文章になるようにデータを作成し，評価対象手法を用いて匿名化をさせ，データを横断して AI エージェントによって再特定させ，匿名化における精度の評価手法を提案する．提案手法を用いることで，種類の異なるテキストを横断して再識別されるリスクを定量的に評価が可能になる．

National Institute of Information and Communications Technology
[5] 京都産業大学
Kyoto Sangyo University
[6] 大阪大学
The University of Osaka
[a)] inoue23@sip.tuat.ac.jp

本研究の主な貢献は，以下の 3 点である．

- AI エージェントによる情報の自律的検索と情報統合を含む脅威モデルを定義し，匿名化文章の再識別ベンチマークを構築した．
- 匿名化文章に対して人物特定を試みる評価プロトコルを整備し，手法間の再識別リスクを比較可能にした．
- PHI ／ PII ベースの評価と人物単位の再識別評価との関係から，AI エージェント時代の文章匿名化における準識別子の組み合わせよる特定のリスクを明確化した．

2. 関連研究

2.1 固有表現抽出を用いた匿名化評価の限界

文章の匿名化は，文章に含まれる個人情報を編集し，特定の人物への帰属を防ぐ手法である．Lison らは，従来の文章匿名化研究を，定義済みの個人情報カテゴリを系列ラベリングにより検出する自然言語処理のアプローチと，情報開示リスクを形式的にモデル化するプライバシー保護データ公開の 2 つに分類した [8]．同研究では，意味的推論への対処，開示リスクと有用性の両立および匿名化結果の評価を課題として挙げている．

Stubbs と Uzuner は患者の医療記録に PHI のカテゴリを付与したデータセットを構築した [9]．このデータセットは HIPAA ガイドラインに基づいて，患者の医療記録に年齢，職業，識別番号などの注釈がつけられており，その検出率で評価がされる．しかし，固有表現抽出（Named Entity Recognition; NER）ベースの評価に重点が置かれていているため，この研究では再識別リスクを低減できているかという観点で評価できていない．

これに対し，Pilán らの Text Anonymization Benchmark（TAB）は，特定の種類のテキストに注釈をつけるのではなく，準識別子や文脈依存の判断へと拡張した [10]．TAB では，欧州人権裁判所の英語判例に対して，個人情報の意味カテゴリ，直接・準識別子，共参照およびマスキング要否が付与され，プライバシー保護と文章の有用性を測る指標が提案されている．これは特定の種類以外の識別に必要な情報のマスク率を評価できる．しかし，注釈者による評価にとどまっているため，匿名化後の文章を起点として，AI エージェントが外部情報を探索した場合の，対象人物の特定可能性を評価していない．

2.2 AI エージェントによる再識別リスク

大規模言語モデル（Large Language Models; LLMs）および AIAgent の登場により、これらを用いた再識別リスクが研究されている．Li は，Anthropic Interviewer Dataset の参加者に関するインタビューを対象に，エージェント型 LLM による再識別を評価した [11]．この研究では，匿名化された発話に含まれる研究内容や経歴上の手掛かりを外部情報と照合することで，参加者の再識別リスクを評価し

© 2026 Information Processing Society of Japan

た．また，Lermen らは，Hacker News，LinkedIn，Reddit および Anthropic Interviewer Dataset などのテキストを対象に，識別に有用な特徴の抽出，候補検索，LLM による照合を組み合わせた攻撃パイプラインを構築した [12]．その結果，仮名化されたテキストからの大規模な再識別が可能であることを示している．

さらに Ko らは，単体では特定できない弱い手掛かり（WeakCues）と公開情報から身元を復元する inference-driven linkage を定式化した [13]．同研究では古典的なリンケージ設定，手掛かりの種類，タスクの提示方法，攻撃者の事前知識を変化させる InferLink，およびテキストリッチな現代的データを用いて，LLM エージェントの再識別能力を評価した．これに対し，Li らは，Web 検索エージェントによる再識別を脅威とし，プライバシーに関係する範囲を特定した上で，分析に必要な文脈を再構成する匿名化手法 AURA を提案した [14]．同研究では，AURA の攻撃耐性と有用性のトレードオフが評価されている．

以上の研究は，インタビューやソーシャル・ネットワーキング・サービスの記録を対象としているため，文章における弱い文脈的手掛かりが，AI エージェントによる検索と情報統合を通じて再識別に利用され得ることを示している．しかし，インタビュー記録などと異なり，医療文章には希少疾患名や臨床経過といった再識別の手がかりになりうる情報が高密度で含有されているという特異性がある．そのため，対象とされてきた文章と比較すると，AI エージェントが紐づける単語のカテゴリが異なるため，同様の手法を用いて十分な匿名化を実現していても，再識別のリスクが異なると考えられる．これに対し本研究は，対象を臨床テキストに拡張することで，医療文章特有の識別子が引き起こす再識別リスクについても評価する．具体的には，電子カルテを標的とした AI エージェントによる再識別リスクの評価基盤を構築することによって，医療文章における匿名化の十分性を定量的に評価する手法を確立する．

3. 提案手法

本研究では，匿名化された日本語医療文章と公開文章の照合による再識別リスクの評価手法を構築する．提案手法は，図 1 に示すように，次の手順で再識別評価する．

(1) ペルソナデータベースから電子カルテとそれに付随する文章を生成
(2) 生成された医療文章を匿名化
(3) 候補者集合に含まれる公開文章を検索・閲覧しながら，対象人物を順位付きで推定

PII/PHI スパンの検出精度やマスク率を用いた評価に対し，匿名化後文章における人物の特定攻撃の成功率を測定する．これにより，匿名化手法をどの識別子を除去したかではなく，残存情報から人物が特定される可能性から評価することができる．

3.1 Step1：評価用データセットの設計方針

本手法では，日本語の合成医療ペルソナデータセットから対象者の医療文章と，それに付随する複数種類の公開文章を生成し，評価コーパスを構築する．公開文章の作成では，各ペルソナに対して，公開プロフィール，公開活動記録，公開生活習慣の計 3 種類をそれぞれ作成する．公開プロフィールでは，名前や年齢，性別，住所などの基本属性をペルソナデータセットから抽出する．また，公開活動記録では，同居状況や通勤手段，社会的支援などの情報を抽出する．さらに，公開生活習慣では，喫煙や飲酒，食生活などの情報を抽出する．一方電子カルテは，LLM を用いて，年齢や食生活に加え医学的情報や検査・治療情報を入力として生成する．医療文章の生成時には，氏名プレースホルダーを含む文章を生成した後に，氏名を挿入する．

3.2 Step2：作成したデータセットに対する匿名化処理

再識別による評価実験のため，匿名化した文章と参照する公開文章を用意する．医療 AI 開発におけるデータ共有時には電子カルテは個人を識別できないようになっていることが望まれるため，作成した電子カルテは匿名化する．一方で，公開文章については Web 上に公開されている文章を想定しているため，匿名化処理をせずそのままの状態で保持する．

3.3 Step3：Agentic Search による段階的再識別評価

本研究の主要な再識別手法として，検索・閲覧・回答を段階的に実施する Agentic Search（攻撃器）を設計した．図 2 に示すように，攻撃器には匿名化済みの電子カルテ 1 件を入力として与える．攻撃器は，公開文章集合に対して，クエリ検索，選択文章の全文閲覧，順位付き人物候補の提案の 3 操作を逐次的に選択して探索を進める．本設定は，攻撃者がコーパス全体を一括で閲覧するのではなく，検索結果の情報を確認しながら段階的に対象者を絞り込む閲覧・検索行動を模している．

4. 実験

提案手法の有効性を検証するために，PHI/PII の NER をベースとする評価指標と比較をした．日本語の合成医療ペルソナデータセットを入力として，電子カルテと公開文章を生成した．電子カルテに対して，複数の手法で匿名化をしたのち，その文章から人物の再識別のリスクを評価した．匿名化した文章のマスク率や再識別攻撃のヒット率，再識別時の参照文章数の観点から評価した．

4.1 実験設定

4.1.1 評価用データセットの構築

公的統計を中心とする日本の統計資料および公開データに基づいて作成された合成患者ペルソナデータセットであ

© 2026 Information Processing Society of Japan

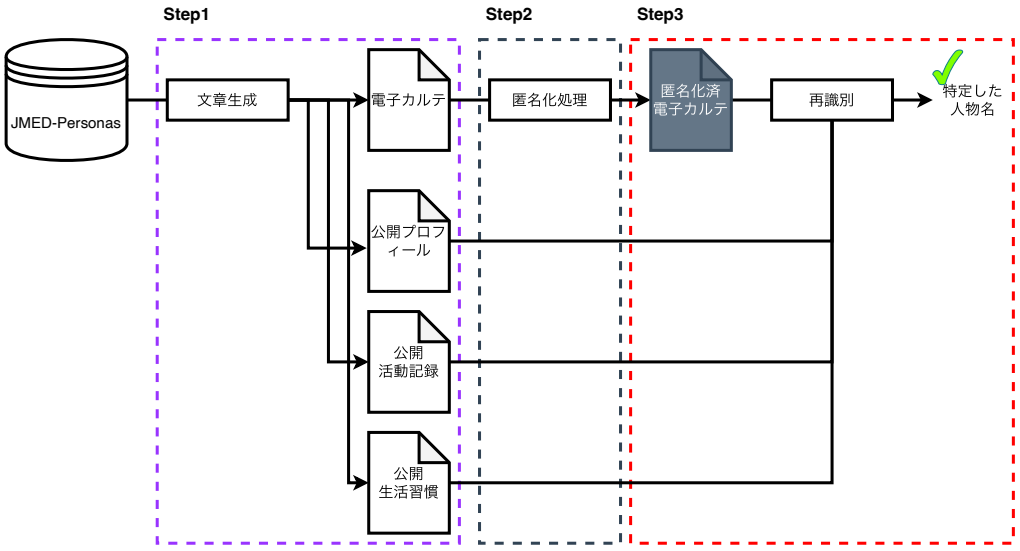


図 1　提案手法の概要

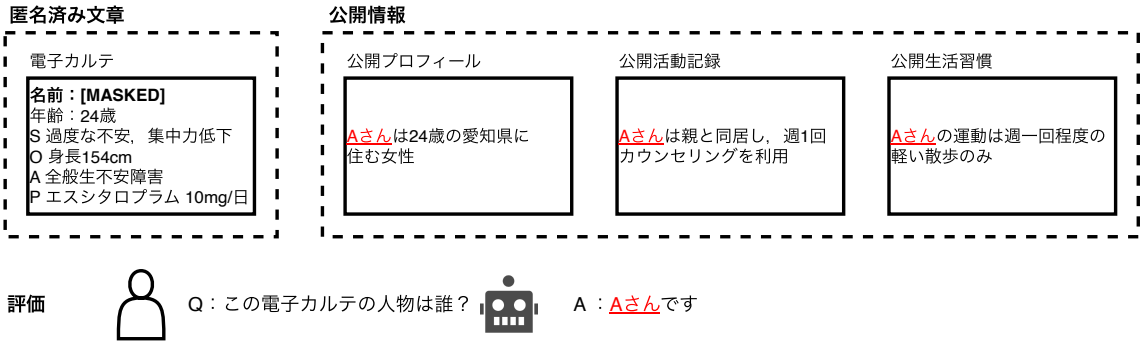


図 2　提案手法の評価手順.

る `sociocom/JMED-Personas` [15] を用いた．再現性を確保するため，Hugging Face 上の revision を固定した．また，`parquet` config の `train` split を使用した．本データセットは 100,000 件の合成患者レコードから構成され，患者 ID，複数種類のペルソナ文章，基本属性，生活背景，生活習慣，医療関連属性を含む．本研究では，計算リソースの制限により，1,000 人を無作為に抽出して公開文章と電子カルテを作成した．

具体的には，各候補者について，公開情報として 3 種類の文章を作成した．公開文章は LLM で新たに要約・言い換えせず，JMED-Personas に収録された文章をそのまま使用した．最終的に，1,000 人について 1 人 3 件，合計 3,000 件の公開文章を作成した．

1,000 人中から 100 人を無作為に抽出したのち，それぞれについて 1 件，計 100 件の SOAP 形式の電子カルテを生成した．SOAP とは Subject（主観的情報），Object（客観的情報），Assessment（評価），Plan（計画）の順に診療や治療計画を記載する方法である．入力には，JMED-Personas の構造化項目から患者基本情報，主訴，現病歴，症状，既往歴，生活背景，身体所見，検査，診断，処方，治療方針などを含めた．電子カルテの文章化には `gpt-4o-mini-2024-07-18` [16] を用い，temperature を 0.0 に固定した．ハルシネーションを防止するため，入力にない病名，薬剤，数値，日付，施設名を追加しないこと，入力値を省略・要約しないこと，SOAP 見出しを維持することを要求した．

4.2　評価に使用した匿名化手法

評価時の匿名化手法として，表 1 に示す 4 種類の手法に加えてポジティブコントロールとして無処理文章を用いて実験した．

正規表現手法は文章構造と周辺文脈に基づくルールベースで設計した．氏名は属性ラベル直後の値，空白区切りの漢字姓名＋敬称/助詞/句読点，敬称直前の漢字列の 3 パターンで抽出した．一般語の過剰マスクを防ぐため，ラベル・空白・敬称を伴わない連続漢字列は除外した．住所や連絡先，患者 ID 等は表記構造や属性ラベルから検出した．準識別子条件では，年齢，性別，地域，職業，完全年月日等を追加でマスクした．なお，臨床経過の解釈可

© 2026 Information Processing Society of Japan

表 1 匿名化手法の概要

手法名	種別	主な検出対象	役割・特徴
未処理	ベースライン	なし（原文のまま）	精度の上限確認（Control）
直接正規表現	ルールベース	氏名，住所，生年月日，患者 ID 等	直接識別子の除去
直接＋準正規表現	ルールベース	上記＋年齢，性別，地域，職業等	強い準識別子除去
GLiNER-ja [17]	NER モデル	`person`, `address`, `email`, `phone`, `date` 等	日本語 PII 抽出モデル
Privacy Filter [18]	ツール	`person`, `address`, `email`, `phone`, `date` 等	最新のマスキングモデル

能性（データ有用性）を維持するため，相対時間表現はマスク対象外とした．GLiNER-ja は，日本語 PII 検出モデル `DataSign/gliner-ja-pii-v1` を用いる NER ベース手法である．検出対象は，person name，phone number，address，email address，date，URL，account number，secret である．検出された span は型付きマスクへ置換した．Privacy Filter は，OpenAI の `privacy-filter` [18] を用いる PII マスク手法である．検出対象は，person，address，email，phone，URL，date，account number，secret であり，検出 span を同様に型付きマスクへ置換した．いずれの手法も，正解対応表や評価用氏名の一覧にはアクセスしない．

4.3 評価に使用した再識別手法

再識別性能の評価実験では，候補者コーパス全体を対象とした同定手法として表 2 に示す 5 種類の手法を比較した．LLM 攻撃器には Gemma 4 31B [19]（temperature=0.0）を用い，観測した公開文章に現れる人物から上位最大 3 名を順位付きで回答させた．非棄権回答には SOAP および公開文章からの逐語引用を要求し，入力文章中に存在することを機械的に検証した．

BM25 では，候補者ごとに公開文章 3 件を連結してプロフィールを作成し，SOAP 全文とともに NFKC 正規化および空白除去を行った上で文字 3-gram へ分割してスコア（$k_1 = 1.5, b = 0.75$）を算出した．BGE-M3 profile retrieval では，連結プロフィールと SOAP 全文をそれぞれ L2 正規化された BGE-M3 埋め込みへ変換し，そのコサイン類似度に基づいて順位付けた．RAG および Agentic Search では，文章を連結せず個々の公開文章を BGE-M3 で埋め込んでコサインインデックスへ登録し，同一人物の複数文章を除外する人物単位の重複排除を行った．Vector RAG では SOAP 全文をクエリとして上位 6 人分の文章を取得した．Reasoned-query RAG では，LLM が SOAP から抽出した特徴的属性に基づくクエリ 1 件を生成し，それを用いて上位 6 人分の文章を取得した．Agentic Search では，LLM が `search`，`open_documents`，`submit` の 3 操作から次の行動を逐次選択した．探索は最大 10 step とし，検索は最大 2 回（1 回につき人物単位で上位 3 人，先頭 240 文字スニペットとコサイン距離を提示），文章露出および全文閲覧（検索済み文章限定）はそれぞれ最大 6 件に制限した．文章露出では各テキストの先頭 70 文字のみを閲覧し，全文閲覧するテキストを選択した．先頭 70 文字に限定することで，公開文章の 86.4%が全文が閲覧できない問題設定にしている．

4.3.1 評価指標

再識別性能の主指標はヒット率（Hit@K）とした．評価ケース数を n，ケース i の正解人物を y_i，攻撃器が出力した候補列における y_i の予測順位（1 から始まる順位）を $\mathrm{rank}(y_i)$ とする．このとき，Hit@K は次式で定義される：

$$\mathrm{Hit@}K = \frac{1}{n}\sum_{i=1}^{n} \mathbb{1}_{\{\mathrm{rank}(y_i)\le K\}}. \tag{1}$$

ここで，$\mathbb{1}_{\{\cdot\}}$ は条件が真のとき 1，偽のとき 0 を返す指示関数である．

Hit@1 は正解人物を第 1 候補として回答した割合であり，Hit@3 は正解人物が上位 3 候補に含まれた割合である．候補者数は 1,000 人であるため，無作為回答の期待値は Hit@1 で 0.1%である．氏名比較では Unicode 正規化，空白除去，大文字小文字を正規化した．また，攻撃コストとして，再識別にあたってモデルが参照した公開文章数を測定した．

4.4 結果

4.4.1 直接識別子検出結果

匿名化前の電子カルテに，直接識別子のアノテーションを付与し，匿名化処理後のテキストにおけるマスク率を評価した．氏名，郵便番号，住所，電話番号，メールアドレス，生年月日，患者 ID などの一意な識別番号を目視で確認し，アノテーションをした．匿名化処理後のテキストにおいて，ラベルがついている単語がマスクされているかを完全一致基準で評価した．直接識別子のマスク率を適合率と再現率，F1 で評価したものを表 3 に示す．適合率は匿名化処理でマスクされたもののうち，マスクするべき単語の割合である．再現率はラベルが付いている単語が，マスクされたサンプルの割合である．F1 はそのバランススコアである．

直接正規表現，準識別正規表現，Privacy Filter は 90%前後の再現率を記録しているため，従来の評価指標である再現率では，匿名化できていることが分かる．

4.4.2 再識別結果

評価対象は 100 ケース，候補集合は各ケース 1,000 人で

© 2026 Information Processing Society of Japan

表 2　再識別手法の概要

手法名	カテゴリ	文章構造	提示範囲	主な特徴
BM25	語彙検索	3 件連結	全件スコアリング	文字列の出現頻度に基づく点数付け
BGE-M3 profile	密集ベクトル検索	3 件連結	全件スコアリング	埋め込みベクトルの類似度で順位付け
Vector RAG	RAG（固定クエリ）	個別文章	上位 6 人分のみ提示	全文をクエリとし上位を LLM へ提示
Reasoned-query RAG	RAG（思考クエリ）	個別文章	上位 6 人分のみ提示	LLM が生成したクエリで取得・提示
Agentic Search	エージェント	個別文章	最大 6 件まで閲覧	検索・閲覧・回答を自律的に実施

表 3　各匿名化処理後の電子カルテにおける直接識別子のマスク率

匿名化手法	適合率	再現率	F1
直接正規表現	0.7253	0.9565	0.8250
準識別正規表現	0.2865	0.9565	0.4410
GLiNER-ja	0.1314	0.5362	0.2110
Privacy Filter	0.5750	0.8889	0.6983

ある．表 4 に Hit@1，表 5 に Hit@3 を示す．単位はいずれも%である．

無処理条件では，Vector RAG，Reasoned-query RAG，Agentic Search がほぼ 100%の Hit@1 を示した．この結果から，作成した文章集合には同一人物をリンクできる情報が十分に含まれていることを確認した．直接識別子を削除した後も，Reasoned-query RAG は 93%，Agentic Search は 90%の Hit@1 を示した．また，GLiNER-ja 適用後もそれぞれ 90%，80%であり，Privacy Filter 適用後も 83%，76%であった．最も再識別率を低下させたのは準識別子正規表現であり，Reasoned-query RAG で 16%，Agentic Search で 10%まで低下した．ただし，候補者 1,000 人に対するチャンスレベルである Hit@1 の 0.1%と比較すると，依然として高い値である．

各匿名化条件における再識別手法間の性能差が単なる標本変動によるものではないことを検証するため，統計的検定をした．McNemar 検定を実施後，Holm 補正を適用している．直接識別子正規表現，GLiNER-ja，Privacy Filter の 3 条件において，Reasoned-query RAG および Agentic Search は Vector RAG を有意に上回る再識別率を示した（補正後 $p < 0.05$）．これに対し，準識別子正規表現を適用した条件では，すべての手法の再識別率が著しく低下し，手法間に統計的有意差は認められなくなった．また，Reasoned-query RAG と Agentic Search の比較においては，全匿名化条件で有意差はなかった（補正後 $p > 0.05$）．

Hit@1 と Hit@3 の結果を比較すると，LLM を用いた再識別手法のスコアはほぼ同等であることがわかる．この結果は，同手法が正解人物を候補集合に含めた場合，その人物をほぼ常に第 1 候補として選択できたことを示している．BM25 では Hit@3 が Hit@1 より 15–23 ポイント高く，BGE-M3 でも同様に 2–11 ポイント高かった．このことは，検索スコアのみに基づく手法では，正解人物を第 1 候補として特定できなくとも，上位 3 候補には含まれる事例が一定数存在することが明らかとなった．

4.4.3　参照した文章数

表 6 に，成功ケースにおいて最終回答までにモデルが参照した公開文章数を示す．BM25，BGE-M3 profile retrieval は，全候補者の公開文章または抽出属性をアルゴリズムが一括でスコアリングする方式である．これらの方法では全テキストを閲覧しているため，参照文章数は全公開テキストの数に該当する．また，これらの手法では，LLM によって段階的に露出された文章数として比較できないため，表から除外した．そのため，LLM へ文章本文または snippet を提示する Vector RAG，Reasoned-query RAG，Agentic Search の 3 手法のみを対象とした．

Vector RAG と Reasoned-query RAG は，上位 6 文章を一括して LLM へ提示するため，露出文章数は常に 6 件であった．これに対し，Agentic Search は成功ケースにおいて平均 3.0–3.5 件の snippet を観測して回答した．全文閲覧数は条件別平均 0.5–1 件であり，多くのケースでは検索結果の短い snippet だけで候補を絞り込んでいた．Agentic Search は Reasoned-query RAG より少ない文章露出で近い再識別性能を達成した．

5.　考察

本実験では，公開文章との照合により，1,000 人の候補者から対象人物を特定できた．氏名などの直接識別子を除去しても再識別率は高かったが，準識別子まで除去すると大幅に低下した．また，単純な検索より，人物照合に有効な属性から検索クエリを組み立てる手法の方が高い性能を示した．以下では，匿名化後に残る情報と攻撃者の検索能力に焦点を当てる．

5.1　既存の匿名化評価指標と実際の再識別リスクの乖離

本研究の実験結果は，匿名化ツールにおける PII の適合率や再現率が良好であっても，再識別リスクを防げない可能性があることを示唆している．直接正規表現や Privacy Filter を用いた匿名化処理は，直接識別子に対して 90%前後の高い再現率を達成しているため，これらの手法は対象テキストから氏名などの直接識別子を十分に検出し，マスキングできていると評価される．しかし，RAG や Agentic Search による再識別結果が示すように，マスキング性能の高さは，再識別リスクが低いことを保証するものではない．Scaiano らも，臨床文章の匿名化で一般に用いられる評価

© 2026 Information Processing Society of Japan

表 4 匿名化条件ごとの Hit@1．最も良いスコアを太字，次に良いスコアを下線にしている．

再識別手法	無処理	直接正規表現	準識別子正規表現	GLiNER-ja	Privacy Filter
BM25	35	23	<u>14</u>	17	21
BGE-M3	83	12	2	5	15
Vector RAG	98	6	5	4	16
Reasoned-query RAG	<u>99</u>	**93**	**16**	**90**	**83**
Agentic Search	**100**	<u>90</u>	10	<u>80</u>	<u>76</u>

表 5 匿名化条件ごとの Hit@3．最も良いスコアを太字，次に良いスコアを下線にしている．

再識別手法	無処理	直接正規表現	準識別子正規表現	GLiNER-ja	Privacy Filter
BM25	57	44	**29**	38	44
BGE-M3	94	19	4	14	23
Vector RAG	98	6	5	4	16
Reasoned-query RAG	<u>99</u>	**93**	<u>17</u>	**91**	**83**
Agentic Search	**100**	<u>90</u>	11	<u>80</u>	<u>76</u>

表 6 成功ケースにおいてモデルが参照した公開文章数

条件	Vector RAG	Reasoned-query RAG	Agentic Search
無処理	6.00	6.00	3.00
直接正規表現	6.00	6.00	3.33
準識別子正規表現	6.00	6.00	3.50
GLiNER-ja	6.00	6.00	3.18
Privacy Filter	6.00	6.00	3.39

指標と，実際の再識別リスクを区別する必要があると指摘している [20]．

直接正規表現や Privacy Filter を適用したテキストに対して，BM25 や BGE-M3 といった検索手法や単純な Vector RAG では再識別率（Hit@1）が低く抑えられた一方，Reasoned-query RAG や Agentic Search を用いた場合には，高い再識別率が観察された．この結果は，氏名などの直接識別子を除去しても，年齢，居住地域，職業，家族構成，生活習慣などの情報を組み合わせることで人物を再識別できるという本研究の仮説を支持する．LLM を用いた手法は，診療記録と公開情報の双方に残存する属性を関連付けることで，既存の指標では安全とみなされるテキストからも対象者を特定した．

さらに，準識別子まで正規表現で除去した条件でも，LLM を用いた検索手法はチャンスレベル（0.1%）を大幅に上回る再識別率を示した．これは，本研究で定義した固定的なパターンの対象外に残った情報や，個別には弱い複数の手掛かりの組合せが，人物照合に寄与することを示唆する．

本研究は，この人物単位の再識別評価を日本語医療文書へ拡張し，医療情報を含む SOAP と非医療の公開文書との照合として評価した．医療文書では，年齢，職業，生活環境，家族や支援の状況などが診療上必要な情報である一方，公開情報との照合に利用可能な準識別子にもなり得る．したがって，医療文書の匿名化では，固定された識別項目の検出性能だけでなく，想定される公開情報と候補者集合の下で，文書全体から人物リンクが成立するかを評価する必要がある．

5.2 検索・推論能力を考慮した脅威モデル

本研究では，検索システムと推論能力を組み合わせた手法が，単純なキーワード検索やベクトルの類似度検索よりも高い再識別性能を示すという仮説を立てた．直接識別子を除去した条件において，Reasoned-query RAG および Agentic Search の再識別率が既存手法を大幅に上回った結果は，この仮説を支持している．先行研究では，通常の RAG 手法が個人情報に関する問いに対して正確に回答できない可能性が指摘されている [21]．しかし，本実験において高性能を示した手法は，公開情報との照合に最も適した属性を能動的に選択していた．これは，表現形式や記述スタイルが異なるテキスト間であっても，LLM が文脈から意味的な手がかりを抽出し，検索結果と高度に統合できる推論能力を有することを示している．

Agentic Search がモデルへ提示した公開文章は約 3 件にとどまり，すべての公開文章を入力せずとも対象人物の特定が可能であった．この事実は，検索システムと LLM を組み合わせた攻撃が，膨大なコンテキストを必要とせず，極めて少ない情報量で成立する現実的かつ効率的な脅威であることを示している．ただし，実際の再識別リスクは，公開情報の量や攻撃者の技術力のみならず，臨床文章へのアクセス環境にも大きく依存する．Ford らは，単なるデータ処理としての匿名化だけでなく，安全な閲覧環境の整備や組織的なガバナンスを組み合わせることで，臨床自由記述からの再識別リスクを十分に低減できると論じている [22]．したがって，本研究の結果は匿名化技術そのものの否定を意図するものではなく，テキストからの識別子削除という単一の技術的アプローチだけに安全性を過度に委ねることの限界を提起するものである．

5.3 制限

本研究で使用した公開文章と電子カルテは，同じペルソナから合成したデータである．そのため，実世界の情報源より，属性間の結合性が高く，組み合わせによる再識別が

© 2026 Information Processing Society of Japan

容易であった可能性がある．また，対象者に付き 4 件のファイルをほかのペルソナとは独立に生成している点も，複数人の情報が混在している実世界の文章とは乖離が認められる．また，正解人物が必ず候補者集合に含まれる閉じた条件で評価している．実世界では，対象人物に対応する公開情報が存在しない場合もある．今後は正解人物が存在しない条件を加え，誤同定と棄権を評価する必要がある．

評価対象は 100 人に限定されており，文章の生成モデル，再識別モデル，プロンプトも固定されている．必ずしも対象人数やモーダルを増加させることが，再識別の難易度に影響を与えるわけではない．しかし，3 種類の文章の他にも，公開情報の量や質，検索エンジンの種類，LLM の能力など，さまざまな条件で再識別性能は変化する可能性はある．したがって，今後はより多様なドメインの文章での評価が必要である．

6. まとめ

本研究では，AI エージェントによる人物単位の再識別評価を日本語医療文書へ拡張し，匿名化済み電子カルテと公開情報を組み合わせた評価手法を構築した．特に，AI エージェントによる再識別の脅威に注目し，Agentic Search を用いて匿名化済み文章と公開情報を組み合わせた匿名化の評価方法を提案，評価した．単純な単語一致や類似度検索では再識別困難な条件でもクエリベースの RAG や Agentic Search によって人物の特定が可能であることを示した．また，Agentic Search は，少ない文章を参照して再識別可能であることがわかった．今後は，実臨床に近い長期診療記録や臨床情報の保持を考慮した評価へ拡張する．実装したコードは GitHub リポジトリ[*1]で公開している．

謝辞 本研究の一部は，国立研究開発法人情報通信研究機構が実施するセキュリティイノベーター育成プログラム SecHack365[*2]における研究開発の成果である．

参考文献

[1] Fleming, K. A. et al.: The *Lancet* Commission on Diagnostics: Transforming Access to Diagnostics, *The Lancet*, Vol. 398, No. 10315, pp. 1997–2050 (online), DOI: 10.1016/S0140-6736(21)00673-5 (2021).

[2] Warnat-Herresthal, S. et al.: Swarm Learning for Decentralized and Confidential Clinical Machine Learning, *Nature*, Vol. 594, No. 7862, pp. 265–270 (online), DOI: 10.1038/s41586-021-03583-3 (2021).

[3] Jha, P.: PIIBench: A unified multi-source benchmark corpus for personally identifiable information detection, *arXiv preprint arXiv:2604.15776* (2026).

[4] Li, Y. et al.: Personal LLM Agents: Insights and Survey about the Capability, Efficiency and Security (2024).

[5] Trivedi, H. et al.: AppWorld: A Controllable World of Apps and People for Benchmarking Interactive Coding Agents (2024).

[6] Yao, S. et al.: τ-Bench: A Benchmark for Tool-Agent-User Interaction in Real-World Domains (2024).

[7] Palmieri, E. A. et al.: A Framework for Embedding Generative and Agentic AI in Open Source Intelligence, *2025 7th International Conference on Blockchain Computing and Applications (BCCA)*, pp. 838–844 (online), DOI: 10.1109/BCCA66705.2025.11229637 (2025).

[8] Lison, P. et al.: Anonymisation Models for Text Data: State of the Art, Challenges and Future Directions, *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)* (Zong, C. et al., eds.), Association for Computational Linguistics, pp. 4188–4203 (online), DOI: 10.18653/v1/2021.acl-long.323 (2021).

[9] Stubbs, A. and Uzuner, Ö.: Annotating longitudinal clinical narratives for de-identification: The 2014 i2b2/UTHealth corpus, *Journal of biomedical informatics*, Vol. 58, pp. S20–S29 (2015).

[10] Pilán, I. et al.: The Text Anonymization Benchmark (TAB): A Dedicated Corpus and Evaluation Framework for Text Anonymization, *Computational Linguistics*, Vol. 48, No. 4, pp. 1053–1101 (online), DOI: 10.1162/coli_a_00458 (2022).

[11] Li, T.: Agentic LLMs as Powerful Deanonymizers: Re-identification of Participants in the Anthropic Interviewer Dataset (2026).

[12] Lermen, S. et al.: Large-Scale Online Deanonymization with LLMs (2026).

[13] Ko, M. et al.: From Weak Cues to Real Identities: Evaluating Inference-Driven De-Anonymization in LLM Agents (2026).

[14] Li, Z. et al.: LLM Anonymization Against Agentic Re-Identification (2026).

[15] Social Computing Lab, NAIST: JMED-Personas: A Dataset of Synthetic Patient Profiles reflecting Statistical Data from Japan, https://huggingface.co/datasets/sociocom/JMED-Personas (2026). Accessed: 2026-07-31.

[16] Achiam, J. et al.: Gpt-4 technical report, *arXiv preprint arXiv:2303.08774* (2023).

[17] Zaratiana, U. et al.: GLiNER: Generalist Model for Named Entity Recognition Using Bidirectional Transformer, *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)* (Duh, K. et al., eds.), Association for Computational Linguistics, pp. 5364–5376 (online), DOI: 10.18653/v1/2024.naacl-long.300 (2024).

[18] OpenAI: OpenAI Privacy Filter.

[19] Team, G. et al.: Gemma 4 technical report, *arXiv preprint arXiv:2607.02770* (2026).

[20] Scaiano, M. et al.: A unified framework for evaluating the risk of re-identification of text de-identification tools, *Journal of biomedical informatics*, Vol. 63, pp. 174–183 (2016).

[21] Tan, J. et al.: PersonaBench: Evaluating AI Models on Understanding Personal Information through Accessing (Synthetic) Private User Data (2025).

[22] Ford, E. et al.: What is the patient re-identification risk from using de-identified clinical free text data for health research?, *AI and Ethics*, Vol. 5, No. 5, pp. 4441–4454 (2025).

[*1] https://github.com/hoki621/agentic-reid-eval
[*2] https://sechack365.nict.go.jp/

© 2026 Information Processing Society of Japan