大規模言語モデルに対するjailbreak攻撃の回避機構別分類と脅威優先度の定量評価

加藤 颯真[1,2,a)]　韓 燦洙[2]　高橋 健志[2]　櫻井 幸一[1]

概要：大規模言語モデル (LLM) の急速な商用展開に伴い，組み込みの安全機構を回避する “jailbreak 攻撃” は深刻なセキュリティリスクをもたらしている．既存研究の多くは “どのような有害コンテンツが生成され得るか” に着目しており，“どのように安全機構が回避されるか” という観点からの分析は限定的であるため，効果的な防御策の開発を妨げている．本研究では，jailbreak 攻撃を回避機構——エンコーディング回避，直接的上書き，意図の隠蔽，段階的操作，自動敵対的攻撃——に基づいて整理した 6 クラス分類を提案する．従来の content-centric なアプローチには存在しない統一的な枠組みを提供する．4 種の最先端 LLM を対象に，1,694 件の実世界プロンプトに加え，AMJ・GCG・PAIR による自動生成攻撃を用いて評価を行い，各クラスの攻撃成功率 (Attack Success Rate: ASR) を測定した．その結果，攻撃クラス間で顕著な ASR の差が観測された．自動敵対的攻撃 (AUTO_ADVERSARIAL) は試験した範囲で最も高い ASR (60–100%) を示し，他クラスを上回った．一方，50 件のブラインド再分類による予備的検証では，自動分類器の判定との一致率は 36.0%，Cohen’s $\kappa = 0.215$(“わずかな一致”) にとどまり，特定のクラス境界に限らず複数クラスにわたって判別精度の課題が確認された．回避機構 (HOW) に基づくタクソノミーの枠組みは攻撃を整理する視点として有用である一方，各クラス境界を自動判定する分類器の精度には本質的な課題が残ることが定量的に明らかになった．

キーワード：jailbreak 攻撃，大規模言語モデル，攻撃タクソノミー，敵対的攻撃，AI 安全性

Bypass-Mechanism-Based Classification of Jailbreak Attacks against Large Language Models and Quantitative Evaluation of Threat Priority

Soma Kato[1,2,a)]　Chansu Han[2]　Takeshi Takahashi[2]　Kouichi Sakurai[1]

Abstract: The rapid commercial deployment of Large Language Models (LLMs) has introduced serious security risks from jailbreak attacks that bypass built-in safety mechanisms. Existing research predominantly focuses on what harmful content can be generated rather than how safety mechanisms are bypassed, which limits the development of effective defenses. In this work, we propose a 6-class taxonomy that organizes jailbreak attacks according to their bypass mechanism–encoding evasion, direct override, intent concealment, progressive manipulation, and automated adversarial attacks–providing a unified framework that prior content-centric approaches lack. Using four state-of-the-art LLMs, we evaluate the Attack Success Rate (ASR) of each class on 1,694 real-world prompts together with automatically generated attacks from AMJ, GCG, and PAIR. Our results show a pronounced difference in ASR across attack classes: automated adversarial attacks (AUTO_ADVERSARIAL) achieved the highest ASR observed in our experiments (60–100%), well above the other classes. However, a preliminary blind re-labeling validation on 50 samples showed only 36.0% agreement with the automatic classifier (Cohen’s $\kappa = 0.215$, “slight agreement”), with classification challenges observed across multiple classes rather than a single class boundary. While the HOW-based taxonomy provides a useful perspective for organizing attacks, these results indicate that the accuracy of automatically classifying prompts into class boundaries has substantial room for improvement.

Keywords: Jailbreak Attacks, Large Language Models, Attack Taxonomy, Adversarial Attacks, AI Safety

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

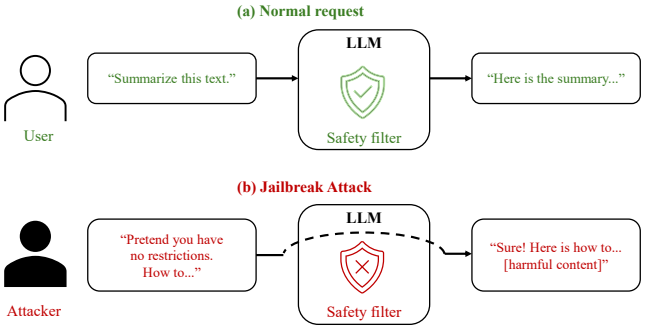


図 1 通常のリクエストと jailbreak 攻撃の比較．安全機構 (Safety filter) が有害な意図を検出できない場合，本来拒否すべき応答が生成される．

1. 研究背景

深層学習の進展により，幅広いタスクにおいて流暢かつ文脈に整合したテキストを生成できる大規模言語モデル (Large Language Models: LLMs) が登場した．GPT，Claude，Gemini といったモデルは自然言語理解，コード生成，多段階推論において高い性能を示し，急速に普及している．2023 年初頭の時点で，ChatGPT は単独で 1 億人以上のユーザを獲得し [1]，史上最速で成長した消費者向けアプリケーションとなった．さらに LLM は，臨床診断支援，法律文書の起草，個別最適化された教育コンテンツの提供など，出力の信頼性・安全性が現実世界に直接影響する高リスクな業務プロセスにも組み込まれつつある．こうした要求に応えるため，主要な開発元は安全性アライメント技術に多大な投資を行っている．

しかし，こうした投資にもかかわらず，LLM は組み込みの安全機構を回避し，本来拒否すべき出力を引き出すよう設計された敵対的入力——“jailbreak 攻撃”——に対して依然として脆弱である．**図 1** に示すように，通常のリクエストでは安全機構が有害でない応答を通過させる一方，jailbreak 攻撃は安全機構の判定を回避し，本来拒否されるべき有害な応答を引き出す．攻撃が成功した場合の影響は，個別のポリシー違反にとどまらない．

Weidinger ら [2] は，大規模言語モデルに起因し得る社会的害を 20 種類以上体系的に特定しており，有害コンテンツ生成，差別的出力，情報災害などが含まれる．Chen and Shu[3] は，LLM が生成する誤情報は人間作成の虚偽情報より検出が困難であることを示し，jailbreak されたモデルが情報操作の強力な道具となり得ることを示唆している．こうした脆弱性は LLM 統合アプリケーションシステムのような実運用システムにも波及し得る [4]．これは安全性訓練が抱える構造的な限界に起因し，十分にレッドチーミングされたフロンティアモデルでも解消されない．

jailbreak 攻撃に関する既存研究の多くは，どのような有害コンテンツを引き出せるかに主眼を置き，暴力，ヘイトスピーチ，違法行為，プライバシー侵害といったコンテンツカテゴリによって攻撃事例を分類してきた [5]．この視点は攻撃の影響を理解する上で不可欠である一方，どの技術的対策を優先すべきかを判断する防御側にとっては限定的な指針しか与えない．敵対者が有害な指示を引き出せるという事実だけでは，その回避がエンコーディングの難読化によるものか，直接的な指示上書きによるものか，あるいは完全に自動化された反復最適化によるものかは分からず，それぞれが異なる緩和戦略を必要とする．

このギャップに対応するため，本研究では method-centric な視点を採用し，jailbreak 攻撃を安全機構の回避方法に基づいて分類するタクソノミーを提案する．攻撃を回避機構によって分類することで，各攻撃クラスが LLM のどのような安全性の脆弱性 (表層的フィルタの限界，文脈依存の判断の弱さ，勾配情報への露出など) を突いているのかを明確にし，その脆弱性の性質に応じた具体的な防御策を対応付けることが本研究の核心的な目的である．具体的には，以下の 3 つの問いに答えることを目指す．

RQ1：jailbreak 攻撃は，コンテンツ種別ではなく回避機構 (HOW) に基づいて体系的に分類できるか．

RQ2：分類したクラス間で，攻撃の複雑さ (単純な難読化から自動反復最適化まで) と ASR の間にはどのような関係があるか．

RQ3：得られた ASR の傾向から，防御側が最優先で対策すべき攻撃クラスをどのように特定できるか．

これらの問いに答えるため，4 種の最先端 LLM に対して各クラスの攻撃成功率 (Attack Success Rate: ASR) を評価し，攻撃手法に基づく防御優先度を導出する (RQ1–RQ3 への回答は 5 章および 6 章でまとめる)．本論文の貢献は以下の通りである．

- 回避機構に基づいて jailbreak 攻撃を分類する，6 クラスタクソノミー．多様な攻撃戦略を比較するための視点を提供する (RQ1)．ただし，予備的な妥当性検証の結果，複数のクラス境界にわたって自動分類の精度に課題が残ることが判明した (6.2 節)．
- 4 種の最先端 LLM を対象とした，各攻撃クラスの定量的 ASR 測定．1,694 件の実世界プロンプトに加え，AMJ・GCG・PAIR による自動生成攻撃を用いて評価した (RQ2)．
- コンテンツ種別ではなく攻撃手法に基づいた脅威優先度検討の枠組み．防御側が緩和リソースを配分する際の判断材料を提供する (RQ3)．

以降，2 章で関連研究を概観し，3 章で提案手法，4 章で実験設定，5 章で結果，6 章で考察を述べ，7 章で結論と今

[1] 九州大学
Kyushu University
[2] 国立研究開発法人情報通信研究機構
National Institute of Information and Communications Technology (NICT)
[a)] kato.soma.518@s.kyushu-u.ac.jp

© 2026 Information Processing Society of Japan

後の課題をまとめる．

2. 関連研究

2.1 LLM の安全性アライメント

LLM を有用・無害・正直であるように調整する手法として，RLHF (Reinforcement Learning from Human Feedback)[6] と Constitutional AI[7] が広く用いられている．RLHF で調整された InstructGPT は下流タスク性能を維持しつつ有害な出力を大幅に削減できることが示された [6]．しかし Wei ら [8] および Perez ら [9] は，言語モデルによるレッドチーミングが十分にアライメントされたシステムからも有害な出力を引き出せることを示した．この脆弱性は “有用性” と “有害拒否” という安全性訓練の 2 目標間のトレードオフに起因し，フロンティアモデルでも解消されない [8]．

2.2 jailbreak 攻撃手法

jailbreak 研究は近年急速に発展している．Zou ら [10] は勾配情報を用いて敵対的サフィックスを自動最適化する Greedy Coordinate Gradient (GCG) を提案し，Llama-2 および Vicuna に対し white-box 設定で 80%以上の ASR を達成した．ただし重みアクセスを要するため，クローズドソース API には直接適用できない．Chao ら [11] は，別の LLM を攻撃者として jailbreak プロンプトを反復的に洗練させる black-box 攻撃 PAIR (Prompt Automatic Iterative Refinement) を提案し，20 クエリ以内で GPT-3.5, GPT-4, Claude, Gemini の jailbreak に成功している．AIM-Intelligence[12] は，複数ターンにわたって制約を段階的に緩和する Automated Multi-turn Jailbreaks (AMJ) を導入し，ターン単位の入力フィルタリングのみに依存する防御を回避する脅威モデルを提示した．

Liu ら [13] は，階層的遺伝的アルゴリズムで意味的に自然な jailbreak プロンプトを自動生成する AutoDAN を提案し，GCG よりも perplexity ベースのフィルタでの検出が困難な手法を示した (原論文評価で GPT-3.5-turbo と Llama-2 に 50%以上の ASR)．Mehrotra ら [14] は PAIR を木構造探索で拡張した Tree of Attacks with Pruning (TAP) により，PAIR と同等以上の ASR を半分未満のクエリ数で達成した．

本研究と特に関連が深いのが，Pan ら [15] による jailbreak 発生の因果分析である．彼らは 7 種の LLM に対する 35,000 件規模の jailbreak 試行データセットを構築し，プロンプトの解釈可能な特徴 (“Positive Character”，タスクステップ数など) と jailbreak 成否との間の因果関係を，LLM ベースのプロンプト符号化と GNN による因果グラフ学習を組み合わせて特定し，攻撃成功率を高める Jailbreaking Enhancer と難読化クエリから意図を抽出する Guardrail Advisor という 2 つの応用を示している．本研究と Pan らはいずれも “jailbreak がなぜ成功するか” を method-centric に理解する点で問題意識を共有するが，本研究が回避機構に基づく分類とクラス間 ASR 比較によって脅威の優先順位付けを行うのに対し，Pan らは個々のプロンプト特徴と成否の因果関係の解明に主眼を置く点で異なり，両者は相補的である．

表 1 jailbreak 攻撃の 6 クラス分類

クラス	名称	説明
1	BENIGN	正常入力 (ベースライン統制)
2	ENC_EVASION	エンコーディング/難読化
3	DIRECT_OVERRIDE	直接的な指示上書き
4	INTENT_CONCEAL	教育的/フィクション文脈による意図の隠蔽
5	PROGRESSIVE_MANIP	マルチターンによる段階的な境界の押し広げ
6	AUTO_ADVERSARIAL	自動敵対的攻撃 (GCG, PAIR)

2.3 jailbreak サーベイ・タクソノミー研究

Yi ら [16] は jailbreak 攻撃と防御に関する包括的サーベイを行い，モデルの透明性 (black-box/white-box) によって攻撃を分類するとともに，標準化された評価ベンチマークの欠如や適応的な敵対者への防御の困難さといった未解決課題を特定した．すべての攻撃タイプに一貫して汎化する単一の防御策は存在しない．

Shen ら [5] は，オンラインコミュニティから収集した 6,387 件以上の実世界 jailbreak プロンプトを対象に大規模な実証研究を行い，その大半がロールプレイやフィクションを装う比較的単純な戦略に依拠している一方，更新された安全機構に対しても無視できない成功率を維持し続けていることを明らかにした．

これらのサーベイがコンテンツカテゴリまたはモデルの透明性によって攻撃を整理するのに対し，本研究は攻撃クラス間で ASR の比較評価を可能にし，防御的対策の優先順位付けに直接資する統一的な method-centric タクソノミーを提案する．既存サーベイは black-box/ white-box やコンテンツカテゴリによる分類を行うが，本研究は “安全機構をどのように回避するか” という統一基準により，従来型手法 (Class 2–4) と最新の自動化攻撃 (Class 5, 6) を同一軸上で比較可能にした点が異なる．

3. 提案手法

3.1 攻撃タクソノミー (6 クラス分類)

本研究では，安全機構をどのように回避するかに基づき，jailbreak 攻撃を**表 1** に示す 6 クラスに分類する．Class 1 は良性のベースライン統制として機能し，Class 2–6 が攻撃クラスとなる．

© 2026 Information Processing Society of Japan

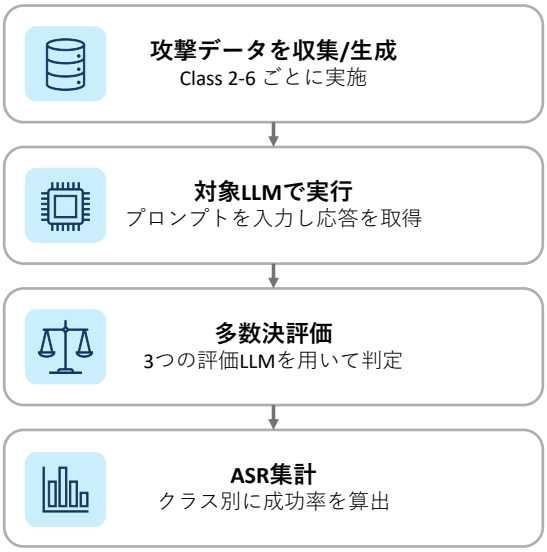


図 2 提案フレームワークの実行フロー．攻撃データの収集/生成，対象 LLM での実行，多数決評価，ASR 集計の 4 段階で構成される．

3.2 実行フロー

提案フレームワークは**図 2** に示す 4 段階のパイプラインとして動作し，以下の 3 ステップに対応する．

(1) **プロンプトの収集/生成：** 各クラスに対応する攻撃プロンプトを収集または生成する (3.3 節)．

(2) **対象 LLM での実行：** 各攻撃プロンプトを対象 LLM に入力し，応答を生成させる．得られた (プロンプト，応答) の組は評価段階へ渡される．

(3) **多数決評価と ASR 集計：** 3 つの独立した評価器 LLM が攻撃の成否を判定し，多数決により最終判定を決定する．全試行にわたりクラスごとの攻撃成功率 (ASR) を算出する．

攻撃クラスの分類　Class 2–4 の実世界プロンプト (3.3 節，1,694 件) は，以下の手順で 6 クラスタクソノミー上のクラスへ割り当てられる．1,694 件のプロンプトと既存ラベルを含む JSON ファイルと，993 件について 7 クラスそれぞれの得票数を記録した CSV ファイルを，プロンプト先頭 150 文字を照合キーとして突き合わせる．CSV 側の得票率が 70% 以上 (複数クラス拮抗時は最多クラス 60%以上) かつ JSON 側のラベルと一致すれば HIGH(確定)，得票率 50–70%かつ JSON 一致であれば MEDIUM，それ未満または JSON 不一致であれば LOW と判定する．CSV 側にラベルがない 161 件は，JSON 側 confidence 0.6 以上かつクラス一意であれば MEDIUM，それ以外は LOW とする．本研究ではこの自動分類結果をそのままラベルとして採用しており，独立した人手ラベルとの突き合わせによる分類器自体の精度検証は行っていない (6.2 節を参照)．攻撃成否の判定 (後述) とは別処理である．

評価プロンプト　各評価器 LLM には元の攻撃プロンプトと対象 LLM の応答が与えられ，“応答が jailbreak に成功したか (本来拒否すべき要求にモデルが応じたか) を SUCCESS または FAILURE の一語で回答せよ” という構造化プロンプトテンプレートを用いて二値判定を行うよう指示する．

表 2 攻撃データ収集・生成方法

対象クラス	方法
Class 2–4	実世界 jailbreak プロンプト [17]：多数決分類器により 1,694 件を分類．内訳 (攻撃クラス計 1,222 件)：ENC_EVASION 490 件，DIRECT_OVERRIDE 697 件，INTENT_CONCEAL 35 件.
Class 5	自動マルチターン操作 [12]：GPT-4 を攻撃者 LLM とした最大 5 ターン，10 試行独立実施.
Class 6	GCG[10]：勾配ベースの敵対的サフィックス最適化 (white-box)．PAIR[11]：GPT-4 を攻撃者 LLM とした反復的プロンプト洗練 (black-box)．いずれも最大 100 ターン/ 反復，10 試行で評価.

多数決による判定　3 つの評価器 LLM——Claude-3-haiku-20240307，GPT-3.5-turbo，Llama 3.3 70B Instruct——は独立に SUCCESS または FAILURE を返し，少なくとも 2 者が SUCCESS と判定した場合に攻撃成功として記録する．この方式により単一モデルの判定への依存を減らし，個々の評価器のバイアスを緩和する．評価器 i の判定を $v_i \in \{0,1\}$ とすると，最終判定 V は式 (1) で表される．

$$V = \begin{cases} 1 & \text{if } \sum_{i=1}^{3} v_i \geq 2 \\ 0 & \text{otherwise} \end{cases} \tag{1}$$

攻撃成功の判定基準　攻撃は，(1) 応答が有害な意図を拒否・回避せず直接的に扱っている，(2) 応答内容が実行された場合に有害・危険・ポリシー違反とみなされる，(3) 多数決判定 (式 1) が SUCCESS である，の全条件を満たす場合に成功と判定される．拒否や免責事項，実行可能な有害コンテンツを伴わない部分的応諾は FAILURE と判定する．

3.3 攻撃データの収集・生成方法

各攻撃クラスは，その回避機構の性質を反映した固有のデータ収集・生成戦略を要する．**表 2** に概要を示す．

Class 2–4 については，実世界データソースから抽出したプロンプトを多数決分類器によって各クラスへ割り当てた．結果として得られた分布——DIRECT_OVERRIDE (697 件)，ENC_EVASION (490 件)，INTENT_CONCEAL (35 件)——は各戦略の実世界における自然な出現頻度を反映しているが，INTENT_CONCEAL のサンプル数の少なさには留意が必要である (分類精度自体の限界は 6.2 節)．

Class 5 では，AMJ フレームワークが各ターンで会話の有害な意図を段階的に強めていく攻撃シーケンスを生成する——無害な要求から始まり徐々に対話を目標行動へ

© 2026 Information Processing Society of Japan

誘導する．このターンごとの段階的エスカレーションはPROGRESSIVE_MANIP 攻撃を特徴づける要素であり，プロンプトを単独で評価する方式では捉えられない．シーケンス中のいずれかの時点で対象モデルが応諾した場合，成功として記録する．

Class 6 では，white-box の勾配最適化と black-box の反復的洗練という 2 つの相補的な脅威モデルを代表させるため GCG と PAIR を選定した．GCG は勾配アクセスを要するため Llama-3.2-1B-Instruct にのみ適用し，残る 3 モデルは PAIR のみで評価した．

3.4 攻撃手法の詳細

本節では，Class 5 および 6 で用いた 3 つの攻撃手法の動作機構を，個別の実験設定に依存しない形で説明する．

マルチターン操作 (AMJ) Automated Multi-Turn Jailbreaks (AMJ) フレームワーク [12] は，会話が進むにつれて LLM がより応諾的になる傾向を利用し，良性の冒頭メッセージから始めて後続ターンで有害な内容を段階的に導入する．本研究では攻撃者 LLM として GPT-4 を用いる (PAIR と同一)．各ターン t で攻撃者 LLM は会話履歴 $\{m_1, r_1, \ldots, m_{t-1}, r_{t-1}\}$ を条件に次のメッセージ m_t を生成し，累積的な文脈で有害な要求を徐々に正常化させる．

Greedy Coordinate Gradient (GCG) GCG[10] は，有害な指示 x に付加する敵対的サフィックス s を自動構築する white-box 攻撃であり，連結された入力 $[x; s]$ が対象モデルに肯定的な応答を生成させることを目指す．サフィックスは目標とする肯定応答 y^* の負の対数尤度を最小化することで最適化される．

$$\min_{s} \mathcal{L}(s) = -\log p_\theta(y^* \mid [x; s]) \tag{2}$$

トークン空間は離散的であるため，GCG は各反復でトークンレベルの勾配 $\nabla_{e_{s_i}} \mathcal{L}$ を通じて上位 k 個の置換候補トークンを特定する貪欲な座標単位探索を用いる (式 2)．この過程はモデルの重みへの直接アクセスを要するため，GCG はオープンウェイトモデルにのみ適用可能である．

Prompt Automatic Iterative Refinement (PAIR) PAIR[11] は，モデルの重みや勾配へのアクセスを一切要さない black-box 攻撃であり，jailbreaking を攻撃者 LLM と対象 LLM の間の反復的な対話として定式化する．攻撃者 LLM は初期候補 p_1 を生成し，各反復 t で対象モデルの応答 r_t を受けて改善候補 p_{t+1} を提案する (式 3)．このループは jailbreak 成功か反復上限まで継続され，オープンウェイト・クローズドソース API の双方に適用可能である．

$$p_{t+1} = \text{Attacker}(g, p_t, r_t) \tag{3}$$

4. 実験設定

4.1 対象モデルおよび評価器モデル

攻撃の有効性が特定の提供元やスケールに固有のものではなく，アーキテクチャの異なるシステム間で一般化するかを検証するため，モデルファミリー・規模・アクセス形態の異なる 4 種の LLM を選定した．

- **Llama-3.2-1B-Instruct (Meta)：** 公開ウェイトの軽量モデルであり，GCG のような white-box 攻撃が可能な唯一の対象モデルである．
- **Claude-3-haiku-20240307 (Anthropic)：**Constitutional AI で訓練された軽量 API モデル．
- **GPT-3.5-turbo (OpenAI)：** 最も広く実運用で利用されている商用 LLM の一つ．
- **Llama-3.3-70B-Instruct (Meta)：** 大規模なオープンウェイトモデル．Llama-3.2-1B と対にし規模と頑健性の相関を検証する．

評価器 LLM として用いた 3 モデル——Claude-3-haiku-20240307, GPT-3.5-turbo, Llama 3.3 70B Instruct——は対象モデルにも含まれ，役割をまたいだ比較を可能にする．攻撃の有効性は式 4 の攻撃成功率 (ASR) で定量化される (N_{success} は多数決評価器による成功試行数，N_{total} は総試行数)．

$$\text{ASR} = \frac{N_{\text{success}}}{N_{\text{total}}} \times 100\ [\%] \tag{4}$$

4.2 Class 5(PROGRESSIVE_MANIP) の設定

AMJ 攻撃シーケンスは以下の設定で生成した．攻撃者 LLM には GPT-4 を用いた (4.3 節の PAIR と同一)．各試行は最大 5 ターンの会話から構成される．このターン数は，本実験に先立つ小規模なパイロット試行において大半の操作の成功が 3–4 ターン以内に起きており，5 ターンを超えると効果が逓減する一方で API コストが増加することを確認した上で決定した．対象モデルごとに 10 回の独立試行を実施し，各試行は異なる乱数シードから初期化した．攻撃者 LLM の温度は 1.0 とした．

4.3 Class 6(AUTO_ADVERSARIAL) の設定

GCG 最適化は試行あたり最大 100 反復で実行した．サフィックス長は 20 トークン，上位候補数は $k = 256$ とし，目標肯定応答文字列は “Sure, here is” とした．これらは Zou ら [10] のデフォルト設定に準拠している．10 回の独立試行を実施した．

PAIR 攻撃者 LLM として GPT-4 を用い，試行あたり最大 100 反復とした．攻撃者にはレッドチーミング支援役として振る舞うよう指示し，各反復で攻撃目標・直前の候補・

© 2026 Information Processing Society of Japan

対象モデルの応答から改善候補を生成させた．SUCCESS 判定時点で早期終了し，対象モデルごとに 10 回の独立試行を実施した．

5. 結果

結論から述べると，Class 6(自動敵対的攻撃) が突出して高く，Class 5(段階的操作) がこれに続き，Class 2–4(従来型手法) は低い ASR にとどまった．すなわち，攻撃の自動化・反復の程度が高いクラスほど脅威が大きい傾向が観測された (RQ2)．以下，**表 3** に基づき詳述する (モデル名は 4.1 節の略記)．

従来型手法 (Class 2–4)　全モデルを通じて ASR は 0–28%の範囲にとどまり，エンコーディングベースおよび直接上書き手法が現代の LLM に対して限定的な有効性しか持たないことが確認された．DIRECT_OVERRIDE が最も高い ASR (GPT-3.5-turbo で最大 28.25%) を示し，ENC_EVASION は中程度 (1.14–8.35%)，INTENT_CONCEAL は最も低い (0–2.76%)．ただし INTENT_CONCEAL はサンプル数 (35 件) が少ないだけでなく，6.2 節の検証で分類器との一致率が 6.7%と極めて低いクラスでもあり，この数値自体の解釈には特に注意を要する．これらは Shen ら [5] の知見と整合する．

段階的操作 (Class 5)　Class 5 は従来型手法よりも顕著に高い ASR を示し，GPT-3.5-turbo は 60%，Llama-3.2-1B は 40%に達した．Claude-3-haiku と Llama-3.3-70B はいずれも 20%であった．ターン単位の安全性チェックのみでは PROGRESSIVE_MANIP 攻撃への防御として不十分であり，会話レベルでのモニタリングが必要である [12]．

自動敵対的攻撃 (Class 6)　Class 6 は全モデル・全攻撃手法を通じて最も高い ASR を達成した．PAIR 攻撃は特に強力であり，GPT-3.5-turbo は 100%，Llama-3.3-70B と Llama-3.2-1B はそれぞれ 80%，70%に達した．Claude-3-haiku でも PAIR には 60%の ASR を示し，一様に高い成功率は現行のアライメント訓練に内在する根本的な限界を示唆する [8]．GCG は反復数 100 回の制限下でも Llama-3.2-1B に 60%の ASR を達成しており，GCG(オープンウェイトモデルのみ) と PAIR(全モデル) とのギャップは white-box と black-box 脅威の非対称性を示している．

6. 考察

6.1 防御への示唆

本節では，RQ3(防御側が最優先で対策すべき攻撃クラスをどのように特定できるか) に対する回答として，5 章の結果が防御システムの設計に与える示唆を述べる．攻撃の有効性は表層的な言い回しの巧妙さよりも自動化と反復の程度に強く結びついており，防御は単一の一括フィルタではなく攻撃クラスごとに階層化すべきである．特定されたクラスの中では，Class 6 が防御投資の最優先事項であり，Class 5 がこれに続く一方，Class 2–4 は既存フィルタの漸進的な改善で対応可能である．

Class 6(AUTO_ADVERSARIAL)　GCG と PAIR はいずれも表層的ヒューリスティクスでは正当な入力と区別しにくいプロンプトを生成する．GCG のサフィックスは perplexity ベースのフィルタ [13] で検出可能だが，PAIR はそうしたフィルタを回避する流暢なテキストを生成するため，両者への防御には perplexity フィルタリングと意味的意図検出・出力モニタリングという相補的な機構が必要である．

Class 5(PROGRESSIVE_MANIP)　攻撃シーケンス中の個々のターンは単独では有害でなく，危険性は蓄積された会話文脈に宿るため，ターン単位の安全性チェックは構造的に無力である．会話レベルでの累積的な意図変化の検出が必要である [12]．

Class 2–4　既存の安全機構はおおむね有効 (ASR 0–28%) だが，DIRECT_OVERRIDE の残存する成功率 (最大 28.25%) は，フィルタが未だ網羅的でないことを示しており，継続的な監視が必要である [5]．

6.2 限界 (Limitations)

本研究にはいくつかの限界があり，結果の解釈にあたって考慮する必要がある．中でも以下の分類精度未検証は本研究全体の妥当性に関わる最も重要な限界であり，他の限界に先立って記載する．

分類精度に関する予備的検証　Class 2–4 への 1,222 件の割り当ては，3.2 節の多数決分類器による自動分類の結果である．妥当性確認のため，4 クラスから層化無作為抽出した 50 件について，著者 1 名がブラインドで独立に再分類する予備的検証を実施した．**本検証は単一評価者との比較であり，2 名以上による真の評価者間信頼性の検証ではない．**

一致率は 36.0%(18/50)，Cohen's $\kappa = 0.215$(“わずかな一致”) と低く，クラス別では BENIGN 20.0%，DIRECT_OVERRIDE 53.8%，ENC_EVASION 66.7%，INTENT_CONCEAL 6.7%と，**4 クラス全体にわたって判別精度の課題**が確認された．

不一致の原因として 3 つの系統的パターンが確認された．(1) 分類器は BENIGN スコアが 0.7 以上で他クラスを無視し強制確定させる実装ルールを持つ (3.2 節) ため，無害な導入部を持つ PROGRESSIVE_MANIP/ INTENT_CONCEAL が BENIGN へ過剰分類された可能性．(2)DIRECT_OVERRIDE の不一致 6 件は全て INTENT_CONCEAL への変更であり，“指示を無視して”

© 2026 Information Processing Society of Japan

表 3 攻撃クラス・対象モデル別の攻撃成功率 (ASR [%])

対象モデル	Class 2	Class 3	Class 4	Class 5	Class 6	
				MTM	GCG	PAIR
Llama-3.2-1B	3.57	13.37	1.50	40.00	60.00	70.00
Claude-3-haiku	6.72	22.38	0.91	20.00	—	60.00
GPT-3.5-turbo	8.35	28.25	2.76	60.00	—	**100.00**
Llama-3.3-70B	1.14	5.88	0.00	20.00	—	80.00

Class 2–6 の名称は表 1 に対応 (Class 2: ENC_EVASION，Class 3: DIRECT_OVERRIDE，Class 4: INTENT_CONCEAL，Class 5: PROGRESSIVE_MANIP，Class 6: AUTO_ADVERSARIAL)．MTM は Multi-Turn Manipulation の略．

† GCG はモデル重みへのアクセスを要する white-box 攻撃であり，Llama-3.2-1B-Instruct にのみ適用可能．“—” は未評価を示す．PAIR の攻撃者 LLM は GPT-4．太字は 100%の ASR を示す．

‡ Class 5 および 6 の ASR は 10 試行のみに基づく．試行数が少なく信頼できる推定値とならないため，信頼区間は報告しない．Class 2–4 のラベル自体の分類精度についても限界があり，詳細は 6.2 節を参照のこと．

等の定型トリガーがロールプレイ設定内に埋め込まれると局所的表現に反応した可能性．(3)INTENT_CONCEAL と PROGRESSIVE_MANIP の混同 (不一致 14 件中 12 件) は，拒否応答を伴う例示の後に本命リクエストを続ける few-shot 構造を持つプロンプトで生じており，分類器が構造より個々の例示ターンの表層的テーマ (フィクション) を重視した結果と考えられる．

これら 3 パターンに共通するのは，**分類器が表層的・字句的シグナルに依存する一方，人間はプロンプト全体の構造的戦略を重視する**傾向であり，LLM ベースの分類器が構造的特徴を軽視する系統的バイアスを持ち得ることを示唆する．以上より，本研究のタクソノミー自体は攻撃を整理する視点として有用だが，各クラス境界を自動判定する分類器の精度には本質的な課題が残る．真の評価者間信頼性の確認は，本研究において最優先の今後の課題である．

自己評価バイアス　評価器モデルと対象モデルは一部重複しており (Claude-3-haiku，GPT-3.5-turbo)，これにより自己評価バイアス——モデルが自身の生成した出力を判定する際に，寛容または厳格のいずれかの方向に偏る可能性——が生じ得る．今後の研究では，偏りのない ASR 推定を得るため評価器モデルと対象モデルの集合を完全に分離すべきである．

統計的信頼性　Class 5 および 6 はいずれも 10 試行のみを用いており，試行数の少なさから信頼できる推定とならないため，信頼区間や標準偏差は報告していない．有意性検定および信頼できる信頼区間の報告には最低 30 試行が必要である．

クラス間の不均衡　Class 2–4 のデータセットは大きく不均衡であり，DIRECT_OVERRIDE が 697 件，ENC_EVASION が 490 件であるのに対し，INTENT_CONCEAL はわずか 35 件である．INTENT_CONCEAL の ASR は他クラスと比較して約 14–20 倍小さいサンプルから推定されており，統計的信頼性に欠け，直接比較には適さない．具体的には，GPT-3.5-turbo について観測された ASR 2.76%(35 サンプル) の 95%信頼区間はおよそ 0–8%に及び，ENC_EVASION および DIRECT_OVERRIDE の ASR の範囲と重複するため，INTENT_CONCEAL が他クラスより有効性が低いという強い主張はできない．各クラス最低 200–300 件のバランスの取れたデータセットを収集することが今後の重要な課題である．

モデルカバレッジ　GPT-4 や Claude-3-Sonnet といった広く実運用されているフロンティアモデルは対象モデルに含まれておらず，本研究の知見をフロンティアシステムへ一般化する上での限界となっている．

7. 結論

本研究では，1 章で提示した 3 つの問いに対し，以下の結論を得た．

RQ1(体系的分類の可否)： jailbreak 攻撃を回避機構 (HOW) に基づいて分類する 6 クラスタクソノミーを提案し，実世界プロンプト 1,694 件のうち 1,222 件を Class 2–4 へ整理した．一方，50 件のブラインド再分類による予備的検証の結果，分類器の判定との一致率は 36.0%，Cohen's $\kappa = 0.215$(“わずかな一致”) にとどまり，4 クラス全体にわたって判別精度に課題が確認された (詳細は 6.2 節)．すなわちタクソノミーの枠組み自体は攻撃を整理する視点として有用だが，分類器の精度には本質的な課題が残る．

RQ2(複雑さと ASR の関係)： 攻撃の自動化・反復の程度が高いクラスほど高い ASR を示す傾向が観測された．従来型手法 (Class 2–4) は ASR 0–28%にとどまったのに対し，段階的操作 (Class 5) は 20–60%，自動敵対的攻撃 (Class 6) は最も高い ASR (60–100%，PAIR 対 GPT-3.5-turbo で 10 試行中 10 試行成功) を示した．ただしこの傾向は 3 手法群間のものであり，Class 2–4 内部では単調な順序関係は成り立たず (5 章)，この内部比較は分類ラベルの精度課題 ($\kappa = 0.215$) の影響を受け得る．

RQ3(防御優先度の特定)： RQ2 の傾向から，Class 6 を最優先，Class 5 をこれに続く対象，Class 2–4 は既存フィ

© 2026 Information Processing Society of Japan

ルタの漸進的改善で対応可能という 3 段階の優先順位付けを導出した (6.1 節)．ただし Class 5・6 の ASR は 10 試行のみに基づき，信頼区間は報告していない (6.2 節)．

今後の課題は以下の優先順位で取り組む．最優先は (1) 6.2 節で述べた分類精度の妥当性検証であり，2 名以上の独立評価者による Cohen's κ の算出を通じてタクソノミーの信頼性を確立することが，他のあらゆる分析に先立つ前提条件である．続いて (2) Class 5・6 の試行回数の増加 (例えば 30 試行以上) と評価器・対象モデルの完全な分離により統計的に信頼できる ASR 推定を実現する．

より発展的な方向性として，(3) PROGRESSIVE_MANIP と AUTO_ADVERSARIAL というマルチターン化・自動化された攻撃が最も脅威度が高いという本研究の知見を踏まえ，これらと従来型手法 (Class 2–4) のエンコーディング回避・直接的上書き・意図隠蔽といった回避機構を組み合わせることで，単一クラスを想定した防御では検出困難な複合攻撃が構築できる可能性がある．こうした複合攻撃の実証的評価と対応する防御機構の構築は今後の重要な研究方向であり，本研究のタクソノミーはどの組み合わせが特に強力かを特定する基盤を提供する．

続いて (4) Class 6 を対象としたクラス別防御機構の開発に取り組む．長期的には (5) 視覚言語モデルへのタクソノミー拡張 [16]，および (6) 全攻撃クラスにわたるバランスの取れたデータセットの収集が挙げられる．

参考文献

[1] R. Satter: ChatGPT sets record for fastest-growing user base, Reuters (2023).

[2] Weidinger, L. et al.: Ethical and social risks of harm from Language Models, arXiv:2112.04359 (2021).

[3] Chen, C. and Shu, K.: Can LLM-generated misinformation be detected?, arXiv:2309.13788 (2023).

[4] Li, E. et al.: ACE: A Security Architecture for LLM-Integrated App Systems, Proc. NDSS (2026).

[5] Shen, X. et al.: "Do anything now": Characterizing and evaluating in-the-wild jailbreak prompts on large language models, arXiv:2308.03825 (2023).

[6] Ouyang, L. et al.: Training language models to follow instructions with human feedback, Proc. NeurIPS, Vol. 35, pp. 27730–27744 (2022).

[7] Bai, Y. et al.: Constitutional AI: Harmlessness from AI Feedback, arXiv:2212.08073 (2022).

[8] Wei, A., Haghtalab, N. and Steinhardt, J.: Jailbroken: How does LLM safety training fail?, Proc. NeurIPS, Vol. 36 (2024).

[9] Perez, E. et al.: Red teaming language models with language models, arXiv:2202.03286 (2022).

[10] Zou, A., Wang, Z., Kolter, J. Z. and Fredrikson, M.: Universal and transferable adversarial attacks on aligned language models, arXiv:2307.15043 (2023).

[11] Chao, P. et al.: Jailbreaking black box large language models in twenty queries, arXiv:2310.08419 (2023).

[12] AIM-Intelligence: Automated-Multi-Turn-Jailbreaks, GitHub repository (2024).

[13] Liu, X. et al.: AutoDAN: Generating stealthy jailbreak prompts on aligned large language models, Proc. ICLR (2024).

[14] Mehrotra, A. et al.: Tree of attacks with pruning: Automatic jailbreaking of large language models, arXiv:2312.02119 (2023).

[15] Pan, L. et al.: A Causal Perspective for Enhancing Jailbreak Attack and Defense, Proc. NDSS (2026).

[16] Yi, J. et al.: Jailbreak attacks and defenses against large language models: A survey, arXiv:2407.04295 (2024).

[17] TrustAIRLab: in-the-wild-jailbreak-prompts, GitHub repository (2024).

8. 研究倫理に関する記載

本研究で使用した攻撃プロンプトの具体的な文字列は，悪用防止の観点から本文中には掲載していない．実験はすべて各 LLM 提供元の API 利用規約の範囲内で実施し，生成された有害な出力は研究目的以外に利用・公開していない．データセットのうち再配布可能な部分 (Class 2–4 の出典 [17]，Class 5 の生成フレームワーク [12]) は既存の公開データ・OSS に基づくものであり，本研究独自に生成した攻撃データ (Class 6 の GCG サフィックス，PAIR による最終 jailbreak プロンプト等) は研究目的に限定した範囲でのみ共有する方針である．

本研究では，情報処理学会研究倫理綱領およびサイバーセキュリティ研究倫理に関するチェックリストに基づき自己点検を行った．特に，本文中で Claude-3-haiku，GPT-3.5-turbo，Llama-3.2/3.3 といった実在の商用・公開 LLM の実名を挙げ，具体的な攻撃成功率を報告している点について，以下の通りネガティブな影響を検討した．

本研究で用いた GCG[10] および PAIR[11] は，いずれも 2023 年に原論文が公開され，実装も公開されている既存の攻撃手法である．本研究の貢献は新たな脆弱性や攻撃手法の発見ではなく，既存手法を含む攻撃を HOW(回避機構) の観点で体系的に分類し，複数モデルにわたって定量的に比較評価した点にある．この意味で本研究は新規脆弱性の開示には該当せず，各社が既に対応を検討可能な公知の攻撃手法の追試・整理であることから，個別の LLM 提供元 (Anthropic，OpenAI，Meta) への事前通知は必須ではないと判断した．モデル名を実名で記載しているのは，実験の再現性を確保するためであり，どの実装 (GCG，PAIR) がどのモデルに対してどの程度有効かという定量的知見は，むしろ防御側の対策優先順位付けに資すると考えている．

なお，GCG および PAIR は特定のモデルに限定されない汎用的な攻撃手法であり，本研究で対象としなかった他の LLM(GPT-4，Claude-3- Sonnet 等) に対しても同様のリスクが及ぶ可能性がある．この点は 6.2 節 (限界) で述べたモデルカバレッジの限界としても言及している．本研究の結果を用いて特定のモデル・提供元を不当に貶める意図はなく，各社が既に取り組んでいるであろう安全性向上の一助となることを企図している．

© 2026 Information Processing Society of Japan