ControlNetを用いたトレースに対する敵対的摂動手法の提案

立原 晴樹[1,a)]　野島 良[1]

概要：近年、Stable Diffusion などのローカル環境で動作する画像生成 AI の普及に伴い、ControlNet 等を用いた既存画像の無断トレース（構造抽出に基づく模倣生成）が著作権侵害のリスクとして問題視されている。本研究では、このトレース行為を根源から防ぐことを目的とし、元画像からの構造抽出プロセスを阻害する敵対的摂動（Adversarial Example）の付与手法を提案する。従来の FGSM（Fast Gradient Sign Method）系ノイズは、HED や DeepLab 等の深層学習ベースの抽出モデルに対しては構造の消失を、Canny 法に対しては大幅な過剰検出を引き起こすことが確認された。一方で、局所的な輝度勾配を用いる古典的アルゴリズムである LSD（Line Segment Detector）に対しては、有効な阻害効果を示さなかった。そこで本稿では、LSD に対するピクセル単位の幾何学的勾配ノイズと、HED に対する NI-FGSM（Nesterov-Accelerated Iterative FGSM）を併用するハイブリッド攻撃を提案する。実験の結果、付与するノイズの総量を固定したまま最適化ステップを分割し、2 種のノイズを交互に付与することで、HED に対する Softedge 抽出の阻害効果（構造の消失）と、LSD に対する直線抽出の阻害効果を同時に高められることを確認した。

キーワード：敵対的摂動，著作権保護，画像生成 AI，構造抽出阻害，stable diffusion, controlnet

Proposal of Adversarial Perturbation Methods Against Tracing Using ControlNet

Haruki Tachihara[1,a)]　Ryo Nojima[1]

Abstract: With the recent proliferation of local image generation AIs such as Stable Diffusion, the unauthorized tracing of existing images using tools like ControlNet has emerged as a significant copyright infringement risk. To fundamentally prevent this behavior, this study proposes a method for applying adversarial perturbations to inhibit the structural extraction process from original images. Conventional Fast Gradient Sign Method (FGSM)-based noise has been shown to cause structural loss against deep learning-based extraction models such as HED and DeepLab, and severe over-detection against the Canny edge detector. However, it failed to demonstrate an effective inhibitory effect against the Line Segment Detector (LSD), a classic algorithm based on local luminance gradients. Therefore, this paper proposes a hybrid attack combining pixel-wise geometric gradient noise against LSD and Nesterov-Accelerated Iterative FGSM (NI-FGSM) against HED. Experimental results demonstrated that by partitioning the optimization steps and alternately applying the two types of noise while keeping the total noise budget fixed, our method simultaneously enhances both the structural loss in soft-edge extraction against HED and the inhibition of line extraction against LSD.

Keywords: Adversarial perturbation, Copyright protection, Image generation AI, Structural extraction inhibition, Stable Diffusion, ControlNet

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

1. 序論

深層学習技術の発展により、テキストから高品質な画像を生成する AI 技術が急速に普及している。中でも、Stable Diffusion[1] をはじめとするオープンソースの画像生成モデルは、ローカル環境で容易に実行可能である。これに加え、ControlNet のような空間的条件付け技術の登場により、ユーザーは入力画像のエッジや直線構造を抽出し、その構図や線画を正確に維持したまま新たな画像を生成することが可能となった。

この技術はクリエイティブな制作活動を支援する一方で、既存のイラストや写真などの著作物から無断で構造を抽出し、画風だけを変更して出力する「トレース」と呼ばれる悪用が散見されている。クリエイターの権利を保護するためには、画像生成モデル側での制約や電子透かしといった受動的な対策だけでなく、画像データそのものに能動的な保護処理を施すアプローチが不可欠である。

画像データを保護する技術として、敵対的摂動（Adversarial Example）を用いた手法が近年注目を集めている。しかし、FGSM（Fast Gradient Sign Method）等に基づく既存の攻撃手法は、HED（Holistically-Nested Edge Detection）のような深層学習ベースの抽出モデルに対しては有効に機能するものの、ピクセル間の局所的な輝度勾配を用いる LSD（Line Segment Detector）等の古典的アルゴリズムに対しては、十分な構造破壊効果を発揮できないという課題がある。

そこで本研究は、ControlNet 等で広く用いられる前処理（プリプロセッサ）による構造抽出を根源から無効化することを目的とする。具体的には、深層学習モデルに対する NI-FGSM（Nesterov-Accelerated Iterative FGSM）と、古典的アルゴリズムに対するピクセル単位の幾何学的勾配ノイズを併用するハイブリッド攻撃を提案する。両者のノイズを最適化ループ内で交互に付与することで、画像への総摂動量（視覚的劣化）を抑えつつ、アーキテクチャの異なる複数の抽出器を同時に機能不全に陥らせる手法の有効性を検証する。

2. 関連研究と課題

2.1 スタイル保護と構造保護のアプローチの違い

画像生成 AI の進展に伴い、クリエイターの著作物を保護するための能動的な防衛技術が複数提案されている。代表的な手法として、Glaze[9] や Mist[11] といったフレームワークが挙げられる。これらの既存手法は、主に「画風（スタイル）」の無断学習や模倣を防ぐことを目的としている。具体的には、特定の作家の画風を学習するモデル（LoRA や Fine-tuning など）の目的関数を阻害するように微小な敵対的摂動を付与し、AI の潜在空間（Latent Space）において対象画像を全く異なるスタイルとして認識させるアプローチをとっている。

しかし、これらの手法はモデルの学習フェーズにおける高次特徴（スタイル）の抽出阻害をターゲットとしているため、「構図や線画（構造）」の直接的な抽出に対しては十分な防御機能を持たない。ControlNet 等を用いた画像生成では、HED や LSD、Canny 法といった前処理（プリプロセッサ）によって、元画像から輪郭線や深度情報といった幾何学的構造が抽出され、それを条件として新たな画像が生成される。スタイル保護用の摂動が付与されていても、ピクセル間の局所的な輝度勾配やエッジといった低次から中次の視覚的特徴は保持されていることが多いため、構造抽出をベースとした模倣生成を阻止することは困難である。

これに対し、本研究で提案する手法は、「構図や線画（構造）」の抽出プロセスそのものを標的として破綻させる「構造保護」のアプローチをとる。本手法は、画風の学習を防ぐのではなく、ControlNet 等で多用される抽出アルゴリズムの挙動を物理的・数学的に無効化することに特化している。したがって、本手法は既存のスタイル保護ツールと競合するものではなく、トレースという異なる脅威に対して、既存手法を補完する新たな防御レイヤーを提供するものである。

2.2 ControlNet のメカニズムと構造抽出アルゴリズムの多様性

ControlNet[5] は、Stable Diffusion に代表される大規模な事前学習済みテキスト条件付き画像生成モデルに対して、空間的な条件付け制御（Spatial Conditioning Control）を追加するためのニューラルネットワーク拡張アーキテクチャである。拡散モデルは元来、テキストプロンプトからの生成において高い表現力を持つ一方で、構図やポーズといった空間的な詳細を厳密に制御することが困難であった。ControlNet は、元の拡散モデルの重みをフリーズして事前学習の知識を保護しつつ、ゼロ畳み込み（Zero Convolutions）を用いた学習可能なエンコーダのコピーを並列に接続することでこの課題を解決した。これにより、モデルが元々持っている高品質な画像生成能力を一切損なうことなく、外部から与えられた画像特徴を生成プロセスにおける強力な空間的ガイドとして強制することが可能となった。

現在、クリエイターの権利侵害として問題視されている「トレース（模倣生成）」のプロセスでは、元のイラストや写真から構図や線画のみを精緻に抽出するため、入力画像に対して専用の前処理（プリプロセッサ）が適用される。ここで抽出・生成された条件マップ（エッジマップ、深度

[1] 立命館大学　〒 567–8570 大阪府茨木市岩倉町 2-150
2-150 Iwakura-cho, Ibaraki, Osaka 567-8570 JAPAN
[a)] is0676fx@ed.ritsumei.ac.jp

© 2026 Information Processing Society of Japan

マップ、線画など）が ControlNet に入力され、新たな画像を生成する際の不変の骨格として機能する。この前処理には、抽出目的の特性に応じてアーキテクチャの全く異なる多様なアルゴリズムが用意されている。代表的な深層学習ベースの手法として、VGG16 等のネットワークを基盤とし、マルチスケールの特徴マップを統合することで画像の輪郭を柔らかく抽出する HED（Holistically-Nested Edge Detection）[2] による Softedge 抽出や、DeepLab を用いたセマンティックセグメンテーションなどが挙げられる。

一方で、深層学習に依存しない古典的な画像処理手法も依然として強力なツールとして利用されている。例えば、ガウシアンフィルタによる平滑化と Sobel フィルタによる輝度勾配計算を経てエッジを検出する Canny 法 [13] や、直線を高精度かつ決定論的に検出する LSD（Line Segment Detector）[3] などが広く活用されている。特に LSD は、建築物や人工物などの直線構造を抽出する目的で MLSD（Mobile Line Segment Detector）等のモデルと併用されることが多く、トレースにおける強力な構造抽出手段となっている。

2.3 既存の敵対的摂動とその限界

画像生成 AI の悪用を防ぐため、入力画像に知覚困難な微小ノイズ（敵対的摂動）を加え、前処理段階の構造抽出を妨害する Adversarial Examples の応用が試みられている。しかし、基本的な勾配ベースの攻撃手法である FGSM[7] 等を用いた単一の摂動では、抽出アルゴリズムの内部構造に起因して防御効果に著しい偏りが生じることが確認されている。

具体的には、HED 等の深層学習モデルは微分可能であるため、勾配情報を用いて意図的に特徴空間を操作することで、出力される構造を効果的に消失させることが可能である。また、単純な輝度勾配の閾値処理に基づく Canny 法に対しても、高周波ノイズが局所勾配を増幅させて過剰検出を引き起こし、構図の抽出を阻害できる。

一方で、古典的直線検出アルゴリズムである LSD に対しては、従来の勾配ベースのノイズ付与は有効な阻害効果を示さなかった。LSD は隣接ピクセルの勾配方向の連続性を評価し、領域拡張法（Region Growing）を用いて幾何学的な直線を形成する解析的かつ非微分なアルゴリズムである。そのため、FGSM が生成するピクセル単位の微小な変動では直線の連続性を破断できず、ノイズの影響がアルゴリズムの頑健性に吸収されてしまう。

トレースを行う攻撃者が特性の異なる複数の抽出手法を組み合わせて利用する可能性を考慮すると、深層学習モデル向けの勾配操作だけでは不十分である。したがって、限られた摂動量の中で、連続的な特徴空間を持つ深層学習ベースの抽出器と、離散的・幾何学的なロジックを持つ古典的抽出器の双方に同時に機能不全を引き起こす防御手法が必要である。

3. 提案手法

本研究では、深層学習ベースの抽出モデル（HED）と、幾何学的アプローチに基づく古典的抽出アルゴリズム（LSD）の双方を同時に無効化するため、特性の異なる 2 種類の摂動を同一の最適化プロセス内で重畳するハイブリッド攻撃を提案する。

3.1 LSD 抽出の阻害：ピクセル単位の高周波幾何学ノイズ設計

LSD（Line Segment Detector）は、局所的な画素の輝度勾配（Gradient magnitude and level-line angle）を計算し、類似した勾配方向を持つピクセル群を領域拡張（Region Growing）によって結合することで直線を検出する。この抽出プロセスを根本から破綻させるためには、画像全域において人為的かつ急激な輝度勾配をピクセル単位で発生させ、領域拡張の連続性判定を強制的に分断する必要がある。

本提案手法では、極めて高い空間周波数を持つ 2 種類のパターンを合成したベースノイズ P_{lsd} を生成する。画像空間上のグリッド座標を (x, y) としたとき、市松模様（Checkerboard）成分 $C(x, y)$ および、正弦波によるハッチング（Hatching）成分 $H(x, y)$ を以下のように定義する。

$$C(x, y) = ((x + y) \bmod 2) \times 2.0 - 1.0 \tag{1}$$

$$H(x, y) = \sin(\omega x + \omega y) \tag{2}$$

ここで、ω は空間周波数を決定する係数であり、本実装では $\omega = 1.0$ としている。最終的な LSD 阻害用のベースノイズ $P_{\text{lsd}}(x, y)$ は、これら 2 つの成分を等しい重みで合成して生成される。

$$P_{\text{lsd}}(x, y) = 0.5 \cdot C(x, y) + 0.5 \cdot H(x, y) \tag{3}$$

このノイズパターンは、隣接するピクセル間で輝度が激しく反転する特性を持つため、微小な付与量であっても LSD の勾配計算に致命的な干渉を与え、直線の誤検出（ノイズとしての分散）や検出不能な状態を引き起こす。

3.2 HED 抽出の阻害：L1 正規化を伴う NI-FGSM の適用

HED モデルに対する摂動は、出力されるエッジマップを消失させることを目的とした標的型攻撃（Targeted Attack）として定式化する。損失関数 $\mathcal{L}_{\text{BCE}}$ には、モデル出力とゼロテンソル $\mathbf{0}$ との間の二値交差エントロピー損失（Binary Cross Entropy Loss）を用いる。

最適化手法としては、Nesterov の加速勾配法を導入した

© 2026 Information Processing Society of Japan

NI-FGSM[12] をベースに用いる。さらに、各ステップでの勾配爆発や消失を防ぎ、空間的な摂動の分散を安定させるため、チャネルおよび空間次元全体における勾配の L1 ノルムを用いた正規化機構を導入する。反復ステップ t における画像 x_t に対する更新則は以下のように定義される。

まず、モメンタム m_t と減衰係数 μ（本研究では $\mu = 1.0$）を用いて、Nesterov の先読み（Look-ahead）画像 x_{nesterov} を計算する。

$$x_{\text{nesterov}} = x_t + \mu \cdot \alpha_{\text{hed}} \cdot m_t \tag{4}$$

次に、先読み位置での勾配 ∇_{nesterov} を取得し、L1 ノルム $\|\cdot\|_1$ で除算することで正規化された勾配 g_t を得る（分母の 10^{-12} はゼロ除算を防ぐための微小定数である）。

$$g_t = \frac{\nabla_{\text{nesterov}}}{\|\nabla_{\text{nesterov}}\|_1 + 10^{-12}} \tag{5}$$

この空間的に正規化された勾配を用いてモメンタムを更新し、対象画像を更新する。

$$m_{t+1} = \mu \cdot m_t + g_t \tag{6}$$

$$x_{t+1} = x_t - \alpha_{\text{hed}} \cdot \text{sign}(m_{t+1}) \tag{7}$$

ここで、損失を最小化する方向へ向かうため、更新式の符号は負（−）となっている。また、1 ステップあたりの更新幅 α_{hed} は、設定された最大摂動量 ϵ_{hed} と総反復回数 N を用いて $\alpha_{\text{hed}} = (\epsilon_{\text{hed}}/N) \times 1.5$ と設定している。係数 1.5 を乗算することで探索範囲に余裕を持たせ、反復回数内で確実に決定境界に到達するよう最適化の効率を高めている。

3.3 ステップ分割交互付与（Interleaving）

上述した 2 種類のノイズ（HED 向け勾配ノイズと LSD 向け幾何学ノイズ）を個別に加算するのではなく、単一の最適化ループ内に統合し、相互に作用させながら画像を更新するプロセスが本提案手法の核心である。

実際のモデル入力時には、ImageNet データセットの統計量（平均値と標準偏差 $\sigma_{\text{imgnet}} = [0.229, 0.224, 0.225]$）による正規化が行われる。これを考慮し、1 ステップあたりの LSD 向けノイズ S_{lsd} は、更新幅 $\alpha_{\text{lsd}} = \epsilon_{\text{lsd}}/N$ を用いて以下のように標準偏差によるスケーリングを適用して算出する。

$$S_{\text{lsd}} = \frac{P_{\text{lsd}} \cdot \alpha_{\text{lsd}}}{\sigma_{\text{imgnet}}} \tag{8}$$

反復ループの内部プロセスは以下の手順で実行される。

(1) **先読みと LSD ノイズの重畳:** Nesterov の先読み画像 x_{nesterov} に対して、ステップごとの LSD 阻害ノイズ S_{lsd} を加算し、重畳画像 $x'_{\text{nesterov}} = x_{\text{nesterov}} + S_{\text{lsd}}$ を生成する。

(2) **HED の勾配計算:** 重畳画像 x'_{nesterov} を入力として HED モデルの順伝播を行い、誤差逆伝播によって勾配 ∇_{nesterov} を計算する。この処理により、LSD 用の幾何学ノイズが HED の勾配計算に対する動的な正則化（Spatial Regularization）として機能する。

(3) **更新とクリッピング:** 算出した勾配を用いて画像を更新した後、元画像 x_0 との差分 δ を計算する。最終的な摂動が視覚的破綻を引き起こさないよう、δ を許容上限 $\pm(\epsilon_{\text{hed}} + \epsilon_{\text{lsd}})/\sigma_{\text{imgnet}}$ の範囲内にクリッピング（Clamp 処理）し、次ステップの入力画像 x_{t+1} とする。

この交互付与プロセスにより、全体のノイズ上限（ϵ_{total}）を増大させることなく、深層学習モデルと幾何学的アルゴリズムの双方に対する抽出阻害性能を両立させている。

4. 評価実験

4.1 実験環境と評価条件

提案手法の有効性を定量的に評価するため、以下の条件で実験を行った。

- **対象モデル:** HED モデル（PyTorch 実装、学習済み重み (network-bsds500.pth) を使用）、および OpenCV 実装の LSD（cv2.createLineSegmentDetector）。
- **摂動の最大許容量 (ϵ):** 画質への影響を一定に保つため、HED 向けの最大摂動量 ϵ_{hed} を 144/255、LSD 向けの最大摂動量 ϵ_{lsd} を 24/255 に固定した。
- **パラメータ設定:** 全体のステップ数 N を $1, 10, 20, 30, 40, 50$ の 6 段階に変化させ、分割回数が阻害効果に与える影響を比較評価した。
- **損失関数:** HED の評価には、出力エッジとターゲット（ゼロテンソル）との間の二値交差エントロピー損失（BCE Loss）を用いた。
- **評価データ:** 実験用画像として、東北ずん子・ずんだもんプロジェクトの公式イラストデータセット [10] を使用した。

4.2 評価指標

防護効果の測定には以下の指標を用いた。

(1) **HED Structural Residual (BCE Loss):** HED によるエッジ抽出結果と、完全にエッジが消失した理想状態（黒画像）との誤差。値が小さいほどエッジの消失に成功していることを示す。

(2) **Detected Line Pixels (Count):** LSD によって検出され、描画された直線群の総ピクセル数。正常時の抽出ピクセル数から大きく乖離（特に幾何学ノイズの干渉に伴う偽エッジの過剰検出による増加）しているほど、元画像の構造抽出の阻害に成功していることを示す。

© 2026 Information Processing Society of Japan

5. 実験結果と考察

5.1 ステップ分割数の増加に伴う阻害効果の向上

実験の結果、図 1 に示すように、ステップ数 N を増加させることで、総ノイズ量（ϵ_{total}）は固定のままであるにも関わらず、防護効果が劇的に向上することが確認された。

- **HED に対する効果:** ノイズなしのクリーン画像におけるベースライン BCE Loss と比較し、ステップ数が増加するにつれて BCE Loss の対数値は単調に減少し、エッジの消失効果が高まった。これは、分割ステップを増やすことでモメンタムによる勾配降下がより精緻に行われ、HED の受容野全体に対する効果的な破壊パターンが形成されたためと考えられる。
- **LSD に対する効果:** LSD による抽出ピクセル数においても、クリーン画像からのベースラインと比較して明確な変動が確認された。特に $N = 10$ 以降では抽出ピクセル数がベースラインの約 2 倍に急増しており、高周波ノイズを微小ステップで分割付与することで、HED の最適化プロセスと干渉することなく局所的な輝度勾配の連続性を効果的に破断し、無数のノイズを直線として誤検出させる（分散させる）ことに成功していることが示唆された。

また、$N = 1$ の条件は、実質的に 2 種類のノイズを単一の大きなステップで一度に順次付与しただけの「単純な直列付与」に相当する。図 1 が示す通り、$N = 1$ では LSD の抽出ピクセル数がベースラインを下回るなど、意図した阻害効果（過剰検出）が得られていない。しかし、限られたノイズ総量を微小なステップに分割し、最適化ループの中で相互に干渉させながら交互に付与（Interleaving）していくことで、両者の阻害効果が同時に、かつ大幅に引き上げられることが明らかとなった。これは、単なる複数ノイズの足し合わせではなく、「分割交互付与」というアプローチ自体が、アーキテクチャの異なる複数モデルに対する同時攻撃を成立させる上で、極めて重要な役割を果たしていることを示している。

5.2 定性的な視覚評価

定量的な評価に加え、提案手法による構造抽出阻害の過程を視覚的に確認するため、図 2 に各ステップ分割数（N）における HED および LSD の抽出結果を示す。

図 2 の「ノイズ無し」における抽出結果では、HED および LSD の双方において、デジタルイラストのキャラクターの輪郭や細部の構造が明確に捉えられている。

しかし、$N = 1$（単一ステップでの直列付与）の条件では、HED の出力には幾何学的なノイズパターンが重畳しているもののキャラクターの輪郭は依然として強く残存しており、LSD に対しても構造を完全に隠蔽するほどの過剰検出には至っていない。これは図 1 における定量評価の推移と視覚的に完全に一致する挙動である。

一方、ステップを分割した $N = 10$ 以降の出力では、阻害効果が劇的に向上していることが一目でわかる。HED の出力は対象の輪郭がほぼ完全に消失して黒化へと向かい、同時に LSD の出力は空間全体にわたって無数の短い直線（偽エッジ）が過剰に検出され、元の構図を視認することは事実上不可能となっている。

この視覚的な結果は、提案する「分割交互付与」が、全く異なる特性を持つ抽出アルゴリズムを同時に、かつ元画像の視覚的劣化を最小限に抑えながら機能不全に陥らせる上で、極めて有効であることを強力に裏付けている。

5.3 相乗効果

本手法のように、異なる特性を持つノイズを交互に付与しつつ全体の最適化を回すアプローチは、一方の防御が他方の防御を打ち消すトレードオフを克服できる点で非常に有用である。LSD 阻害用のノイズが HED にとっての追加の摂動（正則化）として機能し、NI-FGSM が局所解に陥るのを防ぐ役割を果たしていると推測される。

6. 結論

本研究では、ローカル環境の画像生成 AI によるトレースを防ぐため、深層学習モデル（HED）と古典的アルゴリズム（LSD）の両方の構造抽出を阻害するハイブリッド攻撃を提案した。ピクセル単位の幾何学ノイズと NI-FGSM による最適化ノイズを組み合わせ、単なる直列付与ではなく、それらをステップ分割して交互に付与するアプローチにより、総ノイズ付与量を増加させることなく、双方のアルゴリズムに対する抽出阻害効果を同時に、かつ大幅に向上させることに成功した。

実用化に向けた今後の課題として、第一に元画像の視覚的品質のさらなる保持が挙げられる。クリエイターの意図した本来の画作りを損なうことなく著作物を保護するためには、抽出阻害効果を完全に維持しつつ、人間の視覚では認識できない理想的なノイズの生成が不可欠である。今後は人間の視覚に基づく知覚的損失や周波数マスキング技術を最適化ループに組み込み、視覚的な品質劣化を抑制するアルゴリズムを目指す。さらに、実際の悪用シナリオでは攻撃者が複数の抽出プリプロセッサを組み合わせて用いる可能性が高いため、MLSD や、MiDaS 等を用いた Depth（深度マップ）抽出、OpenPose 等による骨格抽出など、より多様なアルゴリズムに対しても同時に機能不全を引き起こす包括的な防御手法への拡張が求められる。

加えて、SNS 等のプラットフォーム上での作品流通を想定した場合、JPEG 圧縮やリサイズ、ノイズ除去フィルタといった一般的な画像加工に対する摂動の頑健性（Robust-

© 2026 Information Processing Society of Japan

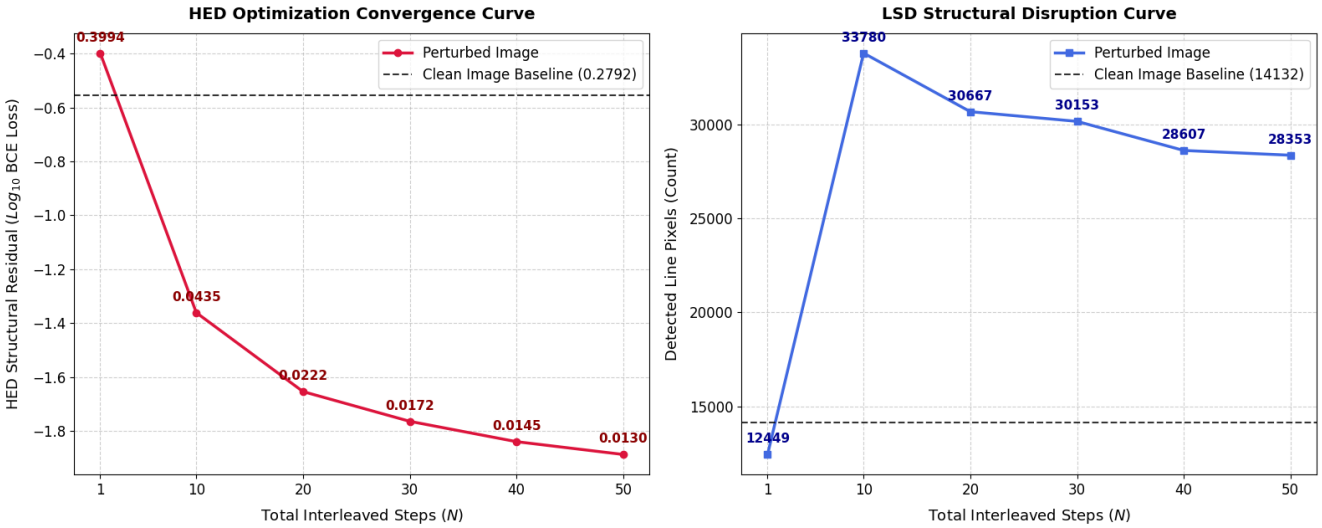


図 1 ステップ分割数（N）の増加に伴う抽出阻害効果の推移。左図は HED に対する BCE Loss の収束曲線（エッジ消失効果）、右図は LSD に対する直線検出ピクセル数の推移（過剰検出効果）を示す。

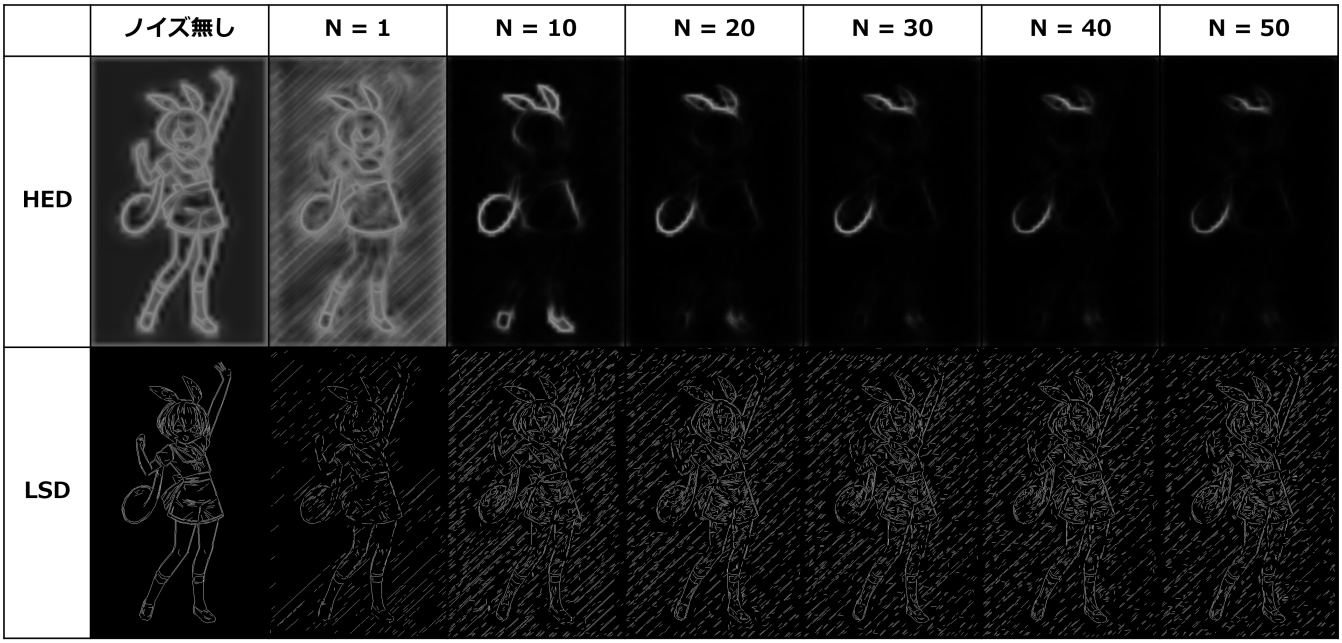


図 2 ステップ分割数（N）の違いによる構造抽出結果の視覚的比較。上段は HED による Softedge 抽出、下段は LSD による直線抽出結果を示す。「ノイズ無し」ではキャラクターの輪郭が明確に抽出されているのに対し、N が増加するにつれて HED は消失（黒化）し、LSD は幾何学ノイズによる過剰検出で構造が完全に破壊されていることが確認できる。

ness）の担保も不可欠な課題である。これに対処するため、今後は最適化プロセスに多様な画像変換（Expectation Over Transformation: EoT）を組み込む手法の検討を進める。最終的には、本研究で確立する「構造保護」の技術を、Glaze や Mist といった既存の「画風（スタイル）保護」技術と統合し、クリエイターの権利を多角的に守る防御システムの実現を目指していく。

謝辞　本研究は AMED の課題管理番号 JP256f0137007 の支援を受けた.

参考文献

[1] Rombach, R., Blattmann, A., Lorenz, D., Esser, P., and Ommer, B.: High-resolution image synthesis with latent diffusion models, *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 10684–10695 (2022).

[2] Xie, S. and Tu, Z.: Holistically-nested edge detection, *Proceedings of the IEEE International Conference on*

© 2026 Information Processing Society of Japan

Computer Vision, pp. 1395–1403 (2015).

[3] Von Gioi, R. G., Jakubowicz, J., Morel, J. M., and Randall, G.: LSD: A fast line segment detector with a false detection control, *IEEE Transactions on Pattern Analysis and Machine Intelligence*, Vol. 32, No. 4, pp. 722–732 (2010).

[4] Dong, Y., Liao, F., Pang, T., Su, H., Zhu, J., Hu, X., and Li, J.: Boosting adversarial attacks with momentum, *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 9185–9193 (2018).

[5] Zhang, L., Rao, A., and Agrawala, M.: Adding conditional control to text-to-image diffusion models, *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp. 3836–3847 (2023).

[6] Hu, E. J., et al.: LoRA: Low-rank adaptation of large language models, *International Conference on Learning Representations* (2022).

[7] Goodfellow, I. J., Shlens, J., and Szegedy, C.: Explaining and harnessing adversarial examples, *International Conference on Learning Representations* (2015).

[8] Cosgrove, C. and Yuille, A. L.: Adversarial examples for edge detection: They exist, and they transfer, *IEEE Winter Conference on Applications of Computer Vision* (2020).

[9] Shan, S., et al.: Glaze: Protecting artists from style mimicry by text-to-image models, *32nd USENIX Security Symposium* (2023).

[10] Tohoku Zunko and Zundamon Project: Training Dataset, `https://zunko.jp/con_illust.html` (Accessed on September 10, 2025).

[11] Liang, C., et al.: Adversarial example does good: Preventing painting imitation from diffusion models via adversarial examples, *International Conference on Machine Learning* (2023).

[12] Lin, J., et al.: Nesterov accelerated gradient and scale invariance for adversarial attacks, *International Conference on Learning Representations* (2020).

[13] Canny, J.: A computational approach to edge detection, *IEEE Transactions on Pattern Analysis and Machine Intelligence*, Vol. 8, No. 6, pp. 679–698 (1986).

© 2026 Information Processing Society of Japan