機械学習の堅牢性のための汎用的なテストツールの設計と表形式データ特有の問題点の考察

大橋 賢人[1]　趙 振江[1]　戸田 貴久[1,a)]

概要：本論文では，機械学習モデル向けの汎用的な堅牢性テストツールを提案する．特に，特徴量間の相関や多様なモデルアーキテクチャを持つヘテロジニアスな表形式データの処理に焦点を当てている．本手法は，ソフトウェア工学における Targeted Property-Based Testing（TPBT）を活用しており，`Hypothesis` ライブラリを用いて実装されている．機械学習の堅牢性テストに対処するため，本研究では TPBT 向けに 2 つの効用関数を導入する．1 つは確率スコアの順位変化に基づくもの（`order-tpbt`），もう 1 つは確率スコアのトップからの差に基づくもの（`score-tpbt`）である．また，表形式データでは特徴量間に相関が存在することが多く，この相関を無視した摂動は現実のデータ分布から逸脱した非現実的な例を生成する可能性がある．そこで，Erdemir らが提案した Mahalanobis 距離に基づく非均一な摂動集合の枠組みを参考に，特徴量間の相関を考慮した非均一な摂動を生成できるよう `Hypothesis` の入力生成制約を拡張することを検討している．GBDT および MLP モデルを用いた Bank データセット上での予備実験では，最大摂動の閾値が与えられた状態で敵対的例を探索する場合，`score-tpbt` が実行時間および成功率の点で，基本的な PBT や `order-tpbt` よりも優れた性能を示すことが実証された．

キーワード：Targeted Property-Based Testing（TPBT），敵対的堅牢性，表形式データ，Hypothesis

Designing a General-Purpose Testing Tool for Machine Learning Robustness and Examining Issues Specific to Tabular Data

Kento Ohashi[1]　Zhenjiang Zhao[1]　Takahisa Toda[1,a)]

Abstract: This paper proposes a general-purpose robustness testing tool for machine learning models, particularly focusing on handling heterogeneous tabular data with feature correlations and diverse model architectures. The method utilizes Targeted Property-Based Testing (TPBT) from software engineering, implemented using the `Hypothesis` library. To address robustness testing in machine learning, we introduce two utility functions for TPBT: one based on the rank change of probability scores (`order-tpbt`) and another on the difference from the top probability score (`score-tpbt`). Furthermore, in tabular data, there is often correlation among features, and perturbations that ignore this correlation may generate unrealistic examples that deviate from the actual data distribution. Therefore, drawing on the framework for heterogeneous perturbation sets based on Mahalanobis distance presented in the prior work, we investigate extending the input generation constraints of `Hypothesis` to enable the generation of heterogeneous perturbations that account for correlations among features. Preliminary experiments on the Bank dataset using GBDT and MLP models demonstrate that the `score-tpbt` utility function outperforms basic `pbt`and `order-tpbt` in terms of execution time and success rate when searching for adversarial examples given maximum perturbation thresholds.

Keywords: Targeted Property-Based Testing (TPBT), Adversarial Robustness, Tabular Data, Hypothesis

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

1. はじめに

機械学習における**堅牢性**とは，モデルが悪意のある攻撃者によってわずかに改変された入力に対しても，正確な予測結果を維持し続ける能力を指す．従来の機械学習アルゴリズムでは，モデルへの入力例が訓練に使われたデータと同じ統計的性質を持つことを前提に開発されており，この前提が満たされる限りモデルは正確な予測結果を出力する．しかし，悪意のある攻撃者は，この入力例に人間にはほとんど見分けがつかないわずかなノイズ（**摂動**）を加えた**敵対的例**を生成することで，モデルに誤ったクラスを予測させることができる [1]．これを**回避攻撃**と呼び，機械学習の堅牢性の確保はこのような攻撃からモデルを守るために不可欠である．このように，人間の目には知覚できない摂動を加えるだけで，モデルの予測結果を意図的に誤ったクラスに誘導できるため，AI への信頼性が損なわれる恐れがある．

また，回避攻撃は，既存の機械学習モデルの脆弱性を把握するために使われるだけでなく，生成した敵対的例と元の訓練データを利用してモデルを訓練し，堅牢性を向上させる手段（Adversarial Hardening[2]）としても活用される．

堅牢性の研究は，これまでは画像や自然言語処理などデータが単一の種類の特徴量からなり，特徴量同士は独立に扱うことができるホモジニアスドメインを対象にしたものが主流であったが，近年では，マルウェア検知 [3]，クレジットカード不正利用検知 [4]，与信リスク予測 [5]，ネットワーク不正侵入検知 [6] などの応用において，表形式データを対象とした研究が始められている．表形式データは，数値特徴量やカテゴリカル特徴量など異種の特徴量から構成され，特徴量間の相関関係やドメイン固有の制約が存在するなど，従来のホモジニアスドメインを対象にした研究とは本質的に異なる難しさがあり，従来の研究結果をそのまま適用することはできない [7] [8]．

表形式データにおける回避攻撃の最大の特徴は，敵対的例が現実的であることが求められる点にある．すなわち，画像データでは，閾値の範囲内ですべての特徴量が均一に扱われる摂動（均一な摂動）が許されていたが，表形式データでは各特徴量が非均一に扱われる摂動（**非均一な摂動**）でなければ現実的ではない例，すなわち訓練データの分布から逸脱した例になることがある．ここで，非均一な摂動とは，たとえば，特定の特徴量は値が不変であることや，複数の特徴量の間に何らかの相関が成り立つことを考慮した摂動を意味する．それゆえ，このような条件を考慮しない現実的ではない例は，現実の攻撃者が生成する敵対的例とは乖離があるため，攻撃としては役に立たない．また，現実的ではない例によって再訓練したモデルは現実の敵対的例に対する堅牢性を保証できず，攻撃に対する適切な防御機構の研究を阻害しうる．そこで，現実のデータ分布を考慮した摂動を用いた回避攻撃手法 [9] が提案されるなど，現実的な敵対的例を生成する研究がある．

また，ヘテロジニアスドメインでは，データ間の距離に関しても注意が必要である．なぜならば，堅牢性の研究では L_p ノルムの摂動が典型的に使われるが，カテゴリカル特徴量も含む表形式データにそのまま適用してしまうと問題が生じる．例えば，カテゴリカル特徴量の値を別の値に変更するとき，ワンホット符号の場合では L_2 ノルムにおいて大きな摂動になってしまう．カテゴリカル特徴量と数値特徴量を混在して扱う際の距離尺度の問題から，表形式データでは異種の特徴量を統一的に扱うことが困難である [10] [11]．

データの種類だけでなく，機械学習手法の種類についても最近新しい研究がなされている．Borisov ら [12] が示したように，伝統的な深層ニューラルネットワークは XGBoost などのような浅い機械学習手法と比較すると，表形式データに対して性能が劣る傾向がある．また，実践的にも多くの応用で決定木ベースのモデルが活用されている．これらに動機づけられて，表形式データに対する決定木ベースモデルの攻撃手法が提案されている [13][14]．これらの手法では，決定境界の離散的な性質を活用して，決定木アンサンブルへの回避攻撃を最大クリーク問題として定式化し解いている．一方，RLN や TabNet などの最近のアプローチは，いくつかの設定において浅いモデルの性能を凌駕しており，深層ニューラルネットワークに対する回避攻撃手法の重要性も認識されている．たとえば，[15][16] により，勾配降下法にペナルティ項を加えたアプローチなどが提案されている．

以上に述べたように，回避攻撃という同じ分類の中にも，対象にするデータやモデルの種類に応じて様々な小分類がなされ，分野としての広がりが進んでいる．同じ堅牢性の研究であっても，扱うデータの種類や予測モデルの種類に応じて異なる回避攻撃手法が必要とされることから，データや予測モデルごとに特化した堅牢性テストツールが数多く提案されている．また，それらの中には一般に公開されていないものも多く，一般のユーザにとって大きな障壁となっている．基礎研究レベルでは，特定の種類のデータやモデルに対して仕立て上げられた攻撃手法が数多く発表される一方で，現実の応用の観点からは，データやモデルの種類の違いに柔軟に対応でき，幅広く適用できるような汎用的な堅牢性テストツールがあることが望ましい．

そこで本研究は，この目標に向けて，ソフトウェア工学分野において知られているテスト手法 TPBT[17]，およびその基本機能をサポートする Python 言語のテストフレームワーク `Hypothesis` [18] を活用して，機械学習の堅牢性

[1] 電気通信大学
The University of Electro-Communications
[a)] toda@disc.lab.uec.ac.jp

© 2026 Information Processing Society of Japan

テストツールの開発を行う最初の研究である．データや予測モデルの種類に応じて特化した堅牢性テストツールが数多く提案される一方で，Zeroth Order Optimization[19] や Multi-Objective Adversarial Attack[20] など，モデルの種類に依らないブラックボックス攻撃手法もいくつも提案されている．しかし，これらの手法は主に画像や自然言語処理などのホモジニアスなドメイン，すなわち特定の種類のデータのみを想定したドメインを対象にしたものである．そのため，表形式データのようなヘテロジニアスなドメイン，すなわちデータの種類の違いに伴う特徴量間の相関や距離尺度の問題に対応する必要があるドメインを意識したものはない．

本研究の背景には，ブラックボックス手法の汎用性と，データやモデル固有の性質を活かす手法の効果とを両立させたいというモチベーションがある．具体的には，基本的にはデータやモデルを問わず適用可能なツールを目指しつつ，generator や効用関数といった調整可能な部分を変更をするだけで，データやモデル固有の性質も活かせるように設計する．

本研究は，特徴量間の相関を含むデータの多様性とモデルの多様性の両方に対応可能な汎用的な堅牢性テストツールの開発を目指す点において，これまでの研究とは一線を画する．具体的には，機械学習の堅牢性評価に適した効用関数の設計に加え，`Hypothesis` の入力生成制約を特徴量間の相関を考慮した非均一な摂動生成制約へ拡張することで，表形式データに適した堅牢性テストの実現を目指す．

2. 準備

本節では，機械学習の堅牢性に関する基本的な用語や定義をまとめる．次に，ソフトウェア工学におけるテスト手法 PBT およびその発展形 TPBT を解説する．最後に，非均一な摂動制約に関する先行研究を簡単に紹介する．

2.1 機械学習分類器の堅牢性

機械学習分類器への入力データ（あるいは入力例）が属する集合を**入力空間**と呼び，X と表す．入力空間の次元（特徴量の種類数）を d とすると，X は $\mathbb{R}^d$ の部分集合をなす．分類器が出力するラベルの集合を**クラス集合**と呼び，Y と表す．機械学習分類器 h は入力 $\boldsymbol{x} \in X$ に対しクラス $c \in Y$ に属する確率スコア $h_c(\boldsymbol{x})$ を計算し，最大スコアのクラスのラベル $h(\boldsymbol{x}) = \underset{c \in Y}{argmax}\ h_c(\boldsymbol{x})$ を出力する関数である．

入力例 $\boldsymbol{x} \in X$ に対して許容される**摂動**の集合を $\Delta \subseteq \mathbb{R}^d$ とするとき，**回避攻撃**は，与えられた入力例の正しいラベル $h(\boldsymbol{x})$ に対し，h を誤分類させるような摂動，すなわち $h(\boldsymbol{x}+\delta) \neq h(\boldsymbol{x})$ を満たす摂動 δ を Δ の中から見つける計算問題である．

入力： 分類器 h，入力例 $\boldsymbol{x}$，摂動集合 Δ
出力： 摂動 $\delta \in \Delta$　s.t.　$h(\boldsymbol{x}+\delta) \neq h(\boldsymbol{x})$

より詳しくは，誤分類させる目標のクラスが指定される場合と指定されない場合があり，本研究は目標クラスが指定されない場合の問題を想定している．本論文では攻撃対象の入力はあらかじめ定められた特徴量により実ベクトルとして表現され，そのような実ベクトルへの摂動に基づく攻撃を想定している．一方，入力そのもの（例えば，画像，音声など）に対して摂動を行う攻撃手法もある．前者を *feature-space attack*，後者を *problem-space attack* と呼び区別することがある [2].

2.2 性質に基づくソフトウェアテスト

ソフトウェアに対するテストでは，そのソフトウェアへの入力例とその正しい結果の対をいくつか指定することがよく行われる．これは**例に基づくテスト**（Example-Based Testing: EBT）と呼ばれる．これと対照的に，**性質に基づくテスト**（Property-Based Testing: PBT）は，テスト対象のソフトウェアにランダムな入力を繰り返し与え，動作させた結果，期待される性質が満たされるか否かを確認する手法である．EBT と比較して，PBT は以下の 2 つの特徴がある．第 1 に，ソフトウェアが満たすべき性質を一般的な条件式で記述する．第 2 に，入力データをランダムに生成する．

EBT ではテストを通過しないバグを想定して例を与えるのに対して，PBT ではランダムなデータ生成の結果，条件式をテストすることにより，人間が想定しにくい境界条件や例外的なケースをあぶりだすことができる．`Hypothesis` [18] [*1]は Python 言語向けの定評のある PBT テストライブラリであり，整数型，文字列型，リスト型などの基本的な種類のデータ型に対するランダムな入力データ生成をデフォルトでサポートしている．特定の構造を持つ複雑なデータやシステム固有の条件を満たすデータについては，ユーザが入力データ生成の手続きを個別に記述して，柔軟に拡張する仕組みも用意されている．

PBT は広く活用されている一方で，いくつかの課題が指摘されている．そのひとつは，入力データの単純なランダム生成戦略の限界である．すなわち，性質に違反する（プログラムのバグを引き起こす）入力データが入力空間の中でそれ程ありふれて存在しない場合，単純なランダムサンプリングだけでは，テスト実行回数を増やしてもバグをなかなか発見できないということである．この課題に対処するために従来の PBT を拡張した枠組みが *TPBT* (Targeted Property-Based Testing）[17] である．TPBT の最大の特徴は，テスト対象のソフトウェアのバグをより効率的に発見することを目的として，入力データの生成に探索的なア

[*1] `https://github.com/HypothesisWorks/hypothesis`

© 2026 Information Processing Society of Japan

プローチを導入することである．

具体的には TPBT を利用するときには**効用関数**，**近傍**，**探索アルゴリズム**の設計が必要になる．効用関数は，現在の入力から実際にバグを引き起こす入力への近さを定量的に評価する関数である．効用関数の値が大きければ，それだけバグに近いことを表す．近傍は，現在の入力から次の入力を求めるために加えることができる摂動を表す．TPBT では，探索アルゴリズムは山登り法や焼きなまし法などの代表的なヒューリスティックスから選択できる一般的な枠組みとして提案されている．TPBT の重要な利点は，ユーザが個々の問題に適合させるために設計する必要があるのは，効用関数，近傍，探索アルゴリズムだけであり，それらだけを適切に設計すれば問題個別の特徴を捉えた効率的なテストを実現できることである．ただ，本研究の実験で用いる `Hypothesis`（version 6.113.0）では，近傍と探索アルゴリズムは焼きなまし法（の変種）に基づくものに固定されており，他の探索アルゴリズムへの変更には対応できないようである．`Hypothesis` は一般に公開されているため，ユーザは公開されたフレームワーク上で変更可能な一部の箇所だけを実装すればよく，ユーザにとっては実装の複雑さを最小限に抑えつつ，バグ検出の効率を向上させることが可能になる．

2.3 非均一な摂動と特徴量間の相関

1 節で述べたように，表形式データでは特徴量ごとに意味が異なり，かつ特徴量間に相関が存在することが多い．たとえば与信スコアリングにおいて，年齢と扶養家族数には自然な相関が存在する．標準的な Adversarial Training では，l_p ノルム制約 $\|\delta\|_p \leq \epsilon$ のもとですべての特徴量を均一に扱って摂動 δ を生成する．しかし，このような特徴量間の相関を無視した摂動は，データの分布から逸脱した非現実的なサンプルを生成してしまう可能性がある．

この問題に対して，特徴量が非均一に扱われる摂動集合が [9] で提案された．具体的には，変換行列 $\Omega \in \mathbb{R}^{d\times d}$ を導入し，摂動 δ に対する制約を

$$\tilde{\Delta}_{\epsilon,p} = \{\delta \in \mathbb{R}^d \mid \|\Omega\delta\|_p \leq \epsilon\}$$

と定義する．

Ω の選び方によって，特徴量間の相関や重要度などの知識を反映した摂動集合を表現できる．例えば，Ω を対角行列とし，各特徴量とラベルとの Pearson 相関係数や Shapley 値の逆数を対角成分にすることで，予測結果への影響が大きい特徴量ほど大きな摂動を許可するといった，特徴量の重要度に基づく非均一な摂動も実現できる．一方，特徴量間の相関を反映する定式化として，Mahalanobis 距離に基づく方法がある．訓練データの共分散行列を Σ とし，$\Omega = U^T$（ただし $U^TU = \Sigma^{-1}$）と選ぶことで，摂動 δ に対する制約は，

$$\sqrt{\delta^T\Sigma^{-1}\delta} \leq \epsilon$$

と表される．これは，データの分布において相関構造に沿った変化への摂動は許容しやすく，逆に相関構造を崩すような変化への摂動は抑制する，という性質を持つ．すなわち，$\Sigma = I$（特徴量間に相関がなく，かつ等分散）の場合には通常のユークリッド距離に一致する一方，特徴量間に相関がある場合には，その相関を反映した非均一な摂動が得られる．

たとえば，与信スコアリングのユースケースでは，年齢 f_{age} と扶養家族数 $f_{dependents}$ の間に相関があるとする．特徴量を均一に扱う摂動では，f_{age} のみを大きく変化させ，$f_{dependents}$ を変化させない，といった相関に反する摂動も許容されてしまう．一方，Mahalanobis 距離に基づく制約のもとでは，f_{age} を変化させる摂動には，データの相関に応じて $f_{dependents}$ にも対応する変化が伴うように誘導され，より現実的なサンプルが生成される．実際，Erdemir ら [9] は，生成された摂動がデータ分布に対してどれだけ尤もらしいかを表す指標 γ-consistency を導入し，摂動の Mahalanobis 距離が小さいほどこの指標が高くなること，すなわちより現実的な敵対的例が得られることを理論的に示している．また，Erdemir らは，マルウェア検知や与信リスク予測，スパム検出といった応用において，このような非均一な摂動を用いた Adversarial Training が，均一な摂動を用いた場合よりも高い防御性能を示すことを実験的に確認している．

この知見は，特徴量間の相関を考慮することでより妥当性の高い敵対的例を生成できるという点で，本研究が目指す `Hypothesis` の入力生成制約の拡張に理論的な裏付けを与える．

3. 本研究

3.1 概要

1 節で述べたように，回避攻撃には，対象にするデータやモデルの種類などといった設定ごとに考慮すべきことが大きく異なり，特定の種類のデータやモデルに対して仕立て上げられた攻撃手法が数多く発表されている．一方で，現実の応用の観点からは，データやモデルの種類の違いに柔軟に対応でき，幅広く適用できるような汎用的な堅牢性テストツールがあることが望ましい．そこで，本節では，この目標に向けて，ソフトウェア工学分野において知られているテスト手法 TPBT[17] を活用して，機械学習の堅牢性テストを実現する手法を提案する．

2 節で述べたように，TPBT を個々の問題に適用するためには，効用関数，近傍，探索アルゴリズムの設計が必要である．本研究の実験では `Hypothesis`（version 6.113.0）を使用するため，近傍と探索アルゴリズムは焼きなまし法に基づく組み込みの方法に固定されている．効用関数に関

© 2026 Information Processing Society of Japan

しては，機械学習の堅牢性評価に適した 2 つの方法を提案する．併せて，Hypothesis の入力生成制約を拡張する必要性について述べる．

3.2 確率スコアの順位に基づく効用関数

多クラス分類モデルの出力の確率スコアの順位変化に着目した効用関数を定義する．この関数は，摂動によって元の順位が高いクラスほど，その順位が変化した際に大きい効用を持つように設計されている．

多クラス分類モデルの出力から得られる確率ベクトルを以下のように表す．ここで，ベクトルの各次元の値は，その次元に対応するクラスの確率スコアを表す．ベクトル $\boldsymbol{x}$ は回避攻撃の入力として与えられる入力例であり，攻撃の間，固定されている．

- 元の入力 $\boldsymbol{x}$ の確率ベクトル：$\boldsymbol{y} = (y_1, y_2, ..., y_n)$
- 摂動後の入力 $\boldsymbol{x'}$ の確率ベクトル：$\boldsymbol{y'} = (y'_1, y'_2, ..., y'_n)$

次に，確率ベクトルに対応する順位ベクトルを定義する．上の $\boldsymbol{y}$ に対する順位ベクトル $\boldsymbol{z} = (z_1, z_2, ..., z_n)$ は，各 z_i は確率スコア y_i の全スコア中の順位を表す．例えば，$\boldsymbol{y} = (0.6, 0.1, 0.3)$ のとき $\boldsymbol{z} = (1, 3, 2)$ となる．摂動後の $\boldsymbol{y'}$ に対する順位ベクトル $\boldsymbol{z'}$ も同様に定める．

このとき，順位ベクトルを二進数とみなして（元の入力 $\boldsymbol{x}$ を基準にして）現在の入力 $\boldsymbol{x'}$ の効用を次のように定義する．

$$f_{\boldsymbol{x}}(\boldsymbol{x'}) := \sum_{i=1}^{n} 2^{n-z_i} \Big(1 - \delta\left(z_i, z'_i\right)\Big)$$

ここで，$\delta(z_i, z'_i)$ はクロネッカーのデルタ関数である．よって $\sum_{i=1}^{n} 2^{n-z_i} \Big(1 - \delta\left(z_i, z'_i\right)\Big)$ は $\boldsymbol{z}$ と $\boldsymbol{z'}$ を二進数と見たときの整数値を表現している．これは $\boldsymbol{z}$ と $\boldsymbol{z'}$ の不一致度を上位桁ほど重視する二進数表現ともいえる．すなわち，桁が高いほど（i が小さいほど）z_i と z'_i の違いの影響が大きく現れる．

特に敵対的例が発見されるときは，ちょうど $\boldsymbol{z}$ を基準にしてトップの順位が $\boldsymbol{z'}$ において入れ替わるときである．ゆえに，効用関数の値が 2^{n-1} 以上になれば必ず敵対的例になる（そしてその逆も成り立つ）．

ただ，この効用関数は，順位だけしかみないので，$\boldsymbol{y}$ と $\boldsymbol{y'}$ は異なるベクトルだったとしても順位ベクトルが一致するならば効用関数の値はゼロとなり，両者を区別できない．たとえば，$\boldsymbol{y} = (0.6, 0.1, 0.3)$ に対して $\boldsymbol{y'} = (0.5, 0.1, 0.4)$ の場合と $\boldsymbol{y'} = (0.9, 0, 0.1)$ の場合はどちらも同じ順位ベクトルとなり，どちらも効用関数の値はゼロである．しかし，前者の $\boldsymbol{y'}$ はトップが入れ替わりそうになっているのに対して，後者はトップと他との確率値の差がより顕著になっている．このように，今の効用関数では，トップの確率値が入れ替わること（すなわち，敵対的例を求められること）を十分に考慮できていない．さらにいえば，2 クラス分類のときには，効用関数が 0 か否かで敵対的例を判定していることになり，実質的に PBT と変わらない．

3.3 確率スコアのトップからの差に基づく効用関数

先ほどの効用関数の課題を解決するために，確率スコアのトップからの差に着目した効用関数を定義する．ここでも 3.2 節で導入した記法 $\boldsymbol{y}$ および $\boldsymbol{y'}$ を引き続き用いる．

元の入力 $\boldsymbol{x}$ の確率ベクトル $\boldsymbol{y}$ において，最も大きい確率値を持つクラスのラベルを m と定義する．

$$m := \underset{1 \le i \le n}{argmax}\ y_i$$

m 番目の確率値が変化するときが敵対的例が発見されたときであるから，摂動後の確率ベクトル $\boldsymbol{y'}$ において，m 番以外の確率値から m 番の確率値の差をとり，その最大値を効用関数の値にする．

$$f_{\boldsymbol{x}}(\boldsymbol{x'}) := \max\{y'_i - y'_m \mid 1 \le i \le n, i \ne m\}$$

もし摂動により確率値のトップが依然 m 番のまま（敵対的例でない）ならば，すべてのクラス i に対して $y'_i - y'_m \le 0$ である．よって $f_{\boldsymbol{x}}(\boldsymbol{x'}) \le 0$ である．逆に，摂動により確率値のトップが入れ替わる（敵対的例である）ならば，$y'_i - y'_m$ を最大化する i がそのクラスになり，$f_{\boldsymbol{x}}(\boldsymbol{x'}) > 0$ である．

3.4 Hypothesis の機能拡張に向けた検討

Hypothesis では，generator が生成する入力ベクトル（摂動）の成分は独立な制約のもと生成される（すなわち L_∞ ノルムに関する摂動）．これは，Hypothesis の基本的な戦略（strategy）が特定のドメインを前提としない汎用的なデータ型（整数型，リスト型など）を対象に設計されており，特徴量間の相関のような問題固有の知識を組み込む仕組みを持たないためである．そのため，特徴量間の相関を考慮しない摂動となり，訓練データの分布から逸脱した非現実的な例を生成する可能性がある．この問題に対して，特徴量間の相関を考慮した非均一な摂動集合 [9] を実現するため，Hypothesis の入力生成制約を特徴量間の相関を考慮した摂動生成制約へ拡張することを検討している．

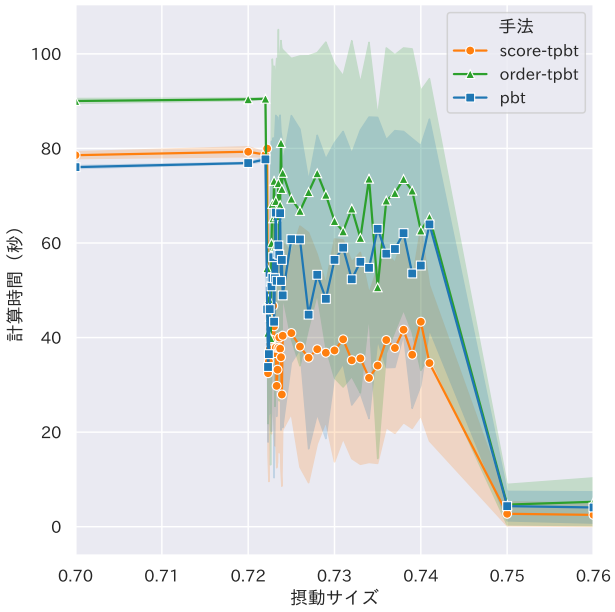
4. 評価実験

本節の目的は，提案された効用関数の有用性を実験的に検証することである．以降では，確率スコアの順位に基づく効用関数を用いた TPBT を `order-tpbt`，確率スコアの差に基づく効用関数を用いた TPBT を `score-tpbt` と記す．効用関数を導入しない PBT を `pbt` とする．いずれの手法も入力サンプルの L_∞ ノルムに関する摂動であり，3.4 節で述べたような特徴量間の相関を考慮した摂動には対応していない．

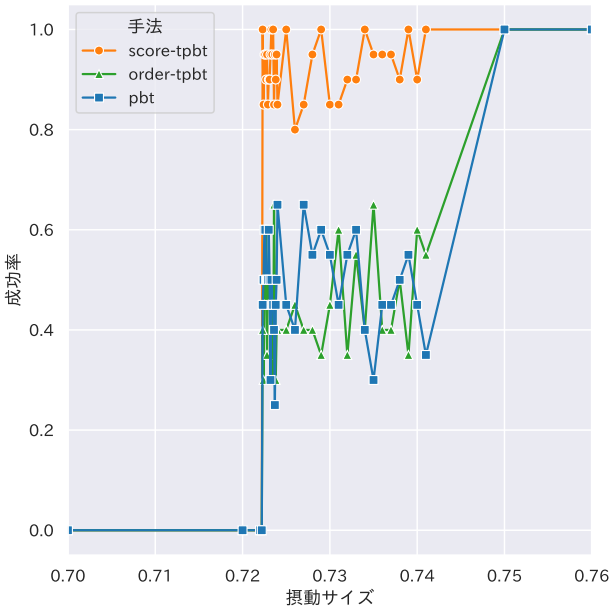
4.1 実験設定

データセット：本実験では，Bank データセットを用い

© 2026 Information Processing Society of Japan



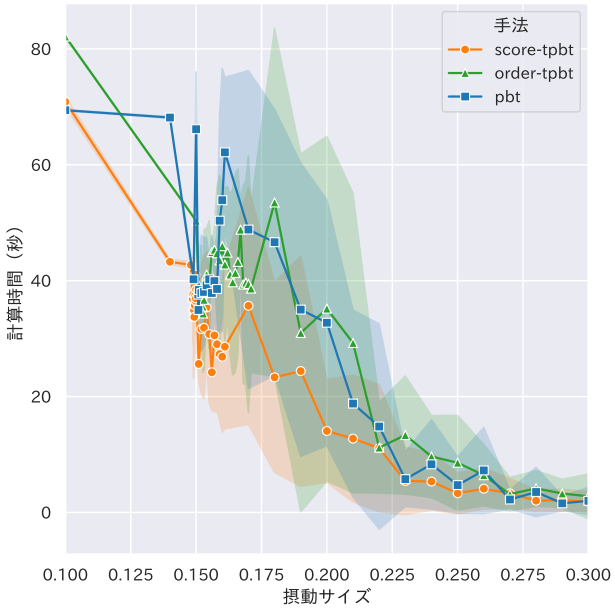
(a) 摂動に対する実行時間の推移



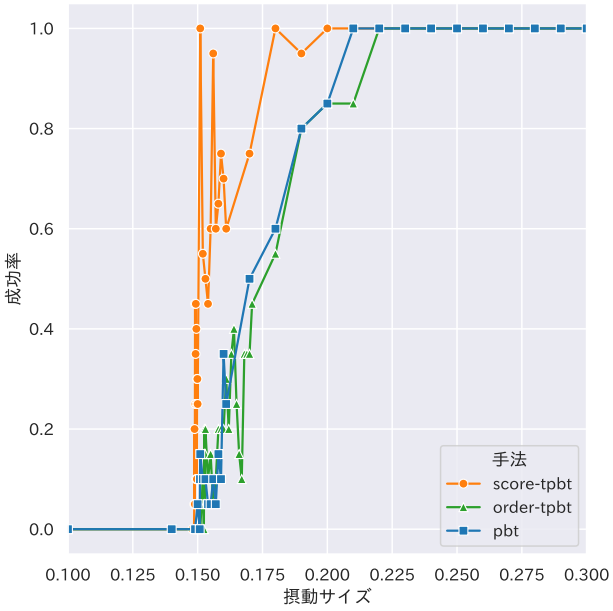
(b) 摂動に対する成功率の推移

図 1: GBDT の実験結果

Fig. 1 Results of GBDT



(a) 摂動に対する実行時間の推移



(b) 摂動に対する成功率の推移

図 2: MLP の実験結果

Fig. 2 Results of MLP

る．Bank データセットは，ポルトガルの銀行におけるダイレクトマーケティングキャンペーンから得られた 45,211 サンプルから構成されるデータセットである．各サンプルは 16 個の特徴量を持つ．タスクは，顧客が定期預金へ加入するか否かを予測する二値分類である．

モデル：Bank データセットにおいて非カテゴリカル特徴量は正規化した上で**多層パーセプトロン** *(Multi-Layer Perceptron: MLP)* と**勾配ブースティング決定木** *(Gradient Boosting Decision Trees: GBDT)* を訓練する．モデルの学習には scikit-learn を用いる．ハイパーパラメータについては，GBDT の木の数を 100 に設定し，その他の設定はデフォルト値を用いる．MLP については，$(64, 32, 16, 8, 4, 2)$ の 6 層の隠れ層を有し，活性化関数は ReLU とする．

摂動対象の特徴量：なお，本研究の現段階では，カテゴ

© 2026 Information Processing Society of Japan

リカル特徴量に対する摂動の生成には対応していない．数値特徴量であれば，たとえば年収に対して± 100 万円の範囲で値を変化させるというように，摂動の大きさ（距離）を自然に定義することができる．一方，性別のようなカテゴリカル特徴量に対しては，値を変更する際の摂動の大きさをどのように定量化すべきかが自明ではなく，適切な距離尺度を設計することが難しい [10] [11]．そのため，本実験では，カテゴリカル特徴量を除いた残りの特徴量に対してのみ摂動を加えている．カテゴリカル特徴量に対する摂動の実現は今後の課題である．

実験方法：堅牢性テストを実施するためには，目標サンプル $\boldsymbol{x}$ および摂動 δ を入力として与える必要がある．本研究では，Bank データセットに含まれる先頭 5 サンプルを目標サンプルとして選択する．各サンプル $\boldsymbol{x}$ に対しては，敵対的例を生じさせる最小摂動 δ^* が定まる．本実験では δ^* の近傍での挙動を観察する．δ^* より小さい摂動では敵対的例が存在しないため，各手法間の性能の差がない．一方で，δ^* を十分に上回る摂動では敵対的例が容易に見つかるため，手法間の差が小さくなる．δ^* の近傍を見つけるために，まず 0.01 の刻みで摂動サイズを下げていきながら，各サイズにおけるテストを実施する．その結果，成功率が 0 になったとき δ^* の大まかな値が特定される．次に，δ^* に向けて摂動サイズから 0.0001 の刻みでサイズを下げていきながら，δ^* の近傍をより細かく観察する．各テストでは `order-tpbt`，`score-tpbt`，`pbt` の最大 10,000 個のテストケースを生成し，敵対的例が発見された時点で探索を停止し，その時点の実行時間を記録した．ランダム性の影響を避けるため，各テストは 20 回繰り返して実施した．

実験環境：すべての実験は，以下の計算環境で実行した．Intel(R) Xeon(R) Silver 4210 CPU @ 2.20 GHz (20 CPU), メモリ 32 GB, Ubuntu 20.04.6 LTS, Python 3.8.20, scikit-learn 1.3.1.

4.2 実験結果

図 1 は GBDT モデルに対する第 2 サンプルの実験結果であり，図 2 は MLP モデルに対する第 5 サンプルの実験結果である．図 1(a) と図 2(a) は摂動 δ の変化に伴う各手法の実行時間の推移を示したものである．図中の点は 20 回の試行の平均値を表し，陰影部分は標準偏差の範囲を示す．実行時間が短いほど手法の性能が高いことを意味する．図 1(b) と図 2(b) は摂動 δ の変化に伴う各手法の成功率の推移を示す．成功率とは，20 回の試行のうち敵対的例を発見できた回数の割合であり，値が高いほど敵対的例を発見する可能性が高いことを表す．

GBDT モデルに対する第 2 サンプルでは敵対的例を生じさせる最小摂動 δ^* は約 0.722 であり，MLP モデルに対する第 5 サンプルでは約 0.150 であることが分かる．大きな値から δ^* に近づけていくにつれて，各手法の実行時間は増加し，成功率は減少する．これは摂動が小さくなるほど敵対的例の発見が困難になることを示している．さらに，摂動が δ^* 以下の領域では敵対的例が存在しないため，各手法の実行時間は一定となり，成功率は 0 になる．また，摂動が大きな値から δ^* に近づく領域においては，`score-tpbt` が実行時間，成功率のいずれにおいても `order-tpbt` および `pbt` より優れた性能を示した．これは，確率スコアの差に基づく効用関数が探索方向をより効果的に誘導できることを示唆している．本研究で示していない他のサンプルにおいても同様の傾向が観察された．

一方で，`order-tpbt` と `pbt` の性能には有意な差異は観察されていない．これは Bank データセットが二値分類であり，二値分類においては確率スコアの順位に基づく効用関数が `pbt` と同様の挙動を示すためである．多クラス分類データセットを用いた実験が今後の課題である．

5. 今後の課題

今後の課題は 3 つ挙げられる．第 1 に，3 節で述べたように，表形式データにおける特徴量間の相関を扱うために，`Hypothesis` の入力生成制約を拡張することが挙げられる．具体的には，2.3 節で紹介した Mahalanobis 距離に基づく非均一な摂動集合を参考に，訓練データの共分散構造を反映した摂動制約を generator に組み込むことで，特徴量間の相関を保った摂動を生成する仕組みを実現することが考えられる．第 2 に，本研究の評価実験は二値分類の Bank データセットに限られており，提案手法の汎用性を示すためには，多クラス分類や他ドメインのデータセットでの検証が必要である．第 3 に，カテゴリカル特徴量に対しても摂動を生成できるよう，適切な距離尺度を検討し対応することが挙げられる．

6. まとめ

本研究では，テスト手法 TPBT とその Python 実装である `Hypothesis` を活用し，汎用的な堅牢性テストフレームワークの構築に向けた提案を行った．確率スコアの順位およびトップからの差に基づく 2 種類の効用関数を設計し，Bank データセットでの評価実験により，確率スコアの差に基づく効用関数（`score-tpbt`）が既存の PBT（`pbt`）や順位に基づく効用関数（`order-tpbt`）と比較して，敵対的例発見に要する実行時間で優れることを確認した．また，特徴量間の相関を考慮した非均一な摂動に関する先行研究 [9] を踏まえ，表形式データに適した現実的な敵対的例を生成するために，`Hypothesis` の入力生成制約を特徴量間の相関を考慮した形へ拡張する方向性を示した．

参考文献

[1] Goodfellow, I., McDaniel, P. and Papernot, N.: Making machine learning robust against adversarial inputs,

© 2026 Information Processing Society of Japan

Commun. ACM, Vol. 61, No. 7, p. 56–66 (online), DOI: 10.1145/3134599 (2018).

[2] Dyrmishi, S., Ghamizi, S., Simonetto, T., Traon, Y. L. and Cordy, M.: On The Empirical Effectiveness of Unrealistic Adversarial Hardening Against Realistic Adversarial Attacks, *2023 IEEE Symposium on Security and Privacy (SP)*, pp. 1384–1400 (online), DOI: 10.1109/SP46215.2023.10179316 (2023).

[3] Li, D. and Li, Q.: Adversarial Deep Ensemble: Evasion Attacks and Defenses for Malware Detection, *IEEE Transactions on Information Forensics and Security*, Vol. 15, pp. 3886–3900 (online), DOI: 10.1109/TIFS.2020.3003571 (2020).

[4] Agarwal, A. and Ratha, N. K.: Black-Box Adversarial Entry in Finance through Credit Card Fraud Detection, *Proceedings of the CIKM 2021 Workshops co-located with 30th ACM International Conference on Information and Knowledge Management (CIKM 2021), Gold Coast, Queensland, Australia, November 1-5, 2021* (Cong, G. and Ramanath, M., eds.), CEUR Workshop Proceedings, Vol. 3052, CEUR-WS.org, (online), available from ⟨https://ceur-ws.org/Vol-3052/paper1.pdf⟩ (2021).

[5] Ghamizi, S., Cordy, M., Gubri, M., Papadakis, M., Boystov, A., Le Traon, Y. and Goujon, A.: Search-based adversarial testing and improvement of constrained credit scoring systems, *Proceedings of the 28th ACM Joint Meeting on European Software Engineering Conference and Symposium on the Foundations of Software Engineering*, ESEC/FSE 2020, New York, NY, USA, Association for Computing Machinery, p. 1089–1100 (online), DOI: 10.1145/3368089.3409739 (2020).

[6] Teuffenbach, M., Piatkowska, E. and Smith, P.: Subverting Network Intrusion Detection: Crafting Adversarial Examples Accounting for Domain-Specific Constraints, *Machine Learning and Knowledge Extraction* (Holzinger, A., Kieseberg, P., Tjoa, A. M. and Weippl, E., eds.), Cham, Springer International Publishing, pp. 301–320 (2020).

[7] Dyrmishi, S., Djilani, M., Simonetto, T., Ghamizi, S. and Cordy, M.: Insights on Adversarial Attacks for Tabular Machine Learning via a Systematic Literature Review (2025).

[8] Mathov, Y., Levy, E., Katzir, Z., Shabtai, A. and Elovici, Y.: Not all datasets are born equal: On heterogeneous tabular data and adversarial examples, *Knowledge-Based Systems*, Vol. 242, p. 108377 (online), DOI: https://doi.org/10.1016/j.knosys.2022.108377 (2022).

[9] Erdemir, E., Bickford, J., Melis, L. and Aydore, S.: Adversarial Robustness with Non-uniform Perturbations, *Advances in Neural Information Processing Systems* (Ranzato, M., Beygelzimer, A., Dauphin, Y., Liang, P. and Vaughan, J. W., eds.), Vol. 34, Curran Associates, Inc., pp. 19147–19159 (online), available from ⟨`https://proceedings.neurips.cc/paper_files/paper/2021/file/9fd98f856d3ca2086168f264a117ed7c-Paper.pdf`⟩ (2021).

[10] He, Z., Ouyang, C., Alzubaidi, L., Barros, A. and Moreira, C.: Investigating imperceptibility of adversarial attacks on tabular data: An empirical analysis, *Intelligent Systems with Applications*, Vol. 25, p. 200461 (online), DOI: https://doi.org/10.1016/j.iswa.2024.200461 (2025).

[11] Kireev, K., Kulynych, B. and Troncoso, C.: Adversarial Robustness for Tabular Data through Cost and Utility Awareness, *30th Annual Network and Distributed System Security Symposium, NDSS 2023, San Diego, California, USA, February 27 - March 3, 2023*, The Internet Society, (online), available from ⟨https://www.ndss-symposium.org/ndss-paper/adversarial-robustness-for-tabular-data-through-cost-and-utility-awareness/⟩ (2023).

[12] Borisov, V., Leemann, T., Seßler, K., Haug, J., Pawelczyk, M. and Kasneci, G.: Deep Neural Networks and Tabular Data: A Survey, *IEEE Transactions on Neural Networks and Learning Systems*, Vol. 35, No. 6, pp. 7499–7519 (online), DOI: 10.1109/TNNLS.2022.3229161 (2024).

[13] Chen, H., Zhang, H., Si, S., Li, Y., Boning, D. and Hsieh, C.-J.: Robustness Verification of Tree-based Models, *Advances in Neural Information Processing Systems* (Wallach, H., Larochelle, H., Beygelzimer, A., d'Alché-Buc, F., Fox, E. and Garnett, R., eds.), Vol. 32, Curran Associates, Inc., (online), available from ⟨`https://proceedings.neurips.cc/paper_files/paper/2019/file/cd9508fdaa5c1390e9cc329001cf1459-Paper.pdf`⟩ (2019).

[14] Zhang, C., Zhang, H. and Hsieh, C.-J.: An efficient adversarial attack for tree ensembles, *Proceedings of the 34th International Conference on Neural Information Processing Systems*, NIPS '20, Red Hook, NY, USA, Curran Associates Inc. (2020).

[15] Simonetto, T., Dyrmishi, S., Ghamizi, S., Cordy, M. and Le Traon, Y.: A Unified Framework for Adversarial Attack and Defense in Constrained Feature Space, *Proceedings of the Thirty-First International Joint Conference on Artificial Intelligence, IJCAI-22* (Raedt, L. D., ed.), International Joint Conferences on Artificial Intelligence Organization, pp. 1313–1319 (online), DOI: 10.24963/ijcai.2022/183 (2022). Main Track.

[16] Simonetto, T., Ghamizi, S. and Cordy, M.: Constrained Adaptive Attack: Effective Adversarial Attack Against Deep Neural Networks for Tabular Data, *Advances in Neural Information Processing Systems* (Globerson, A., Mackey, L., Belgrave, D., Fan, A., Paquet, U., Tomczak, J. and Zhang, C., eds.), Vol. 37, Curran Associates, Inc., pp. 27817–27849 (online), DOI: 10.52202/079017-0873 (2024).

[17] Löscher, A. and Sagonas, K.: Targeted property-based testing, *Proceedings of the 26th ACM SIGSOFT International Symposium on Software Testing and Analysis*, ISSTA 2017, New York, NY, USA, Association for Computing Machinery, p. 46–56 (online), DOI: 10.1145/3092703.3092711 (2017).

[18] MacIver, D. R., Hatfield-Dodds, Z. and Contributors, M. O.: Hypothesis: A new approach to property-based testing, *Journal of Open Source Software*, Vol. 4, No. 43, p. 1891 (online), DOI: 10.21105/joss.01891 (2019).

[19] Chen, P.-Y., Zhang, H., Sharma, Y., Yi, J. and Hsieh, C.-J.: ZOO: Zeroth Order Optimization Based Black-box Attacks to Deep Neural Networks without Training Substitute Models, *Proceedings of the 10th ACM Workshop on Artificial Intelligence and Security*, AISec '17, New York, NY, USA, Association for Computing Machinery, p. 15–26 (online), DOI: 10.1145/3128572.3140448 (2017).

[20] Zhou, S., Huang, M., Sun, Y. and Li, K.: Evolutionary Multi-objective Optimization for Contextual Adversarial Example Generation, *Proc. ACM Softw. Eng.*, Vol. 1, No. FSE (online), DOI: 10.1145/3660808 (2024).

© 2026 Information Processing Society of Japan