# 局所敵対的摂動による音楽記号認識の選択的妨害に基づく楽譜保護手法

狩野 花奈[1,a)]　西垣 正勝[1,,]　大木 哲史[1,,]

**概要**：近年，生成 AI の発展に伴い，著作物が著作者の許諾なく AI の学習データとして利用されることへの懸念が高まっている．特に楽譜は創作者の音楽的表現を含む著作物であり，光学音楽認識（Optical Music Recognition：OMR）の高性能化によって，公開された楽譜画像から音楽情報が容易に抽出される可能性がある．本研究では，AI による情報抽出を困難にしつつ，楽譜本来の用途である閲覧・演奏に必要な視認性を維持することを目的として，楽譜画像に敵対的摂動を付与する手法を提案する．しかし，単純に誤認識率を最大化する攻撃を OMR に適用した場合，音楽的な重要度の低い記号に誤認識が集中する傾向がある．そこで，摂動付与可能範囲を音符周辺に限定するとともに，音符への誤認識を優先的に誘発する攻撃手法を提案する．評価実験の結果，提案手法は楽譜の視認性を維持しつつ，音符情報の抽出を妨害できることを示した．

**キーワード**：敵対的サンプル，Optical Music Recognition(OMR)，著作物保護

# Sheet Music Protection Based on Selective Disruption of Musical Symbols Using Localized Adversarial Perturbations

Haruna Kano[1,a)]　Masakatsu Nishigaki[1,,]　Tetsushi Ohki[1,,]

***Abstract:*** Recent advances in generative artificial intelligence have raised concerns that copyrighted works may be used as training data without the permission of copyright holders. Musical scores, in particular, are copyrighted works that embody the creators' musical expression, and recent improvements in Optical Music Recognition (OMR) have made it possible to extract musical information from publicly available score images with high accuracy. This study proposes an adversarial perturbation method for musical score images that hinders AI-based information extraction while preserving the readability required for their original purpose of human viewing and performance. However, directly applying conventional attacks that simply maximize the misrecognition rate to OMR tends to concentrate recognition errors on musically less important symbols. To address this issue, we propose an attack method that restricts perturbations to the vicinity of note symbols while preferentially inducing misrecognition of notes. Experimental results demonstrate that the proposed method can prevent the extraction of note information while preserving the readability of musical scores.

***Keywords:*** Adversarial Examples，Optical Music Recognition (OMR)，Copyright Protection

## 1. はじめに

近年，人工知能（AI）技術は急速な発展を遂げ，さまざまな分野で利用が拡大している．その一方で，著作者の意思にかかわらず，著作物が生成 AI の学習データとして利用されることに対する懸念が高まっており，著作物の利用における倫理的・法的問題が顕在化している [1].

日本においては，著作権法第 30 条の 4 に基づき，営利目的であるか否かにかかわらず，著作物に表現された思想又は感情の享受を目的としない情報解析については，著作権者の利益を不当に害しないことなどを条件として，著作

[1] 静岡大学
Shizuoka University
[a)] kano@sec.inf.shizuoka.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

者の許諾なく著作物を利用することが認められている [2]．このため，現行の著作権制度では，著作者が個々の著作物について AI 学習への利用を自らの意思のみで一律に制御することは困難である．そこで，著作者の意思を AI による著作物の利用に反映し，その利用を技術的に制御するための仕組みが求められる．

AI による学習対象は文書や画像にとどまらず，音楽コンテンツにも及ぶ．音楽情報の代表的な形式の一つである楽譜には，創作者の音楽的表現力や創造性が色濃く反映されており，その内容が許諾なく模倣・使用されることは，経済的損失に加え，創作活動そのものへの深刻な侵害となり得る．また，深層学習技術の進展に伴い，楽譜の欠損部分を AI が補完・推論する手法が既存研究において報告されている [3]．このことから，一部が隠蔽されたオンライン購入前のサンプル楽譜であっても，公開部分から音楽情報を抽出し，抽出された情報を用いて隠蔽部分を含む楽譜全体の内容が推論・補完されるおそれがある．

楽譜画像から音楽情報を抽出する手法として，光学音楽認識（Optical Music Recognition：以下，OMR）が挙げられる．OMR とは，楽譜のデジタル保存や音楽情報検索等を目的として，楽譜画像に記された音楽記号をコンピュータによって解析し，その内容をデジタル形式の音楽情報へ変換する技術である [4]．深層学習技術の発展により精度が大きく向上しており，End-to-End の OMR モデルを提案する研究 [5][6] も行われている．

楽譜販売者および楽曲制作者の権利を保護するためには，AI による楽譜情報の抽出・利用を制御することが重要である．本研究では，このような楽譜保護を実現する手段として，機械学習モデルに誤認識を誘発する敵対的摂動 [7] に着目する．敵対的摂動とは，人間には知覚困難な微小な摂動によって機械学習モデルに認識結果を変化させる手法であり，近年では，著作物や画像の視認性を維持しつつ，AI による情報の抽出・利用を妨害する目的でも利用されている [8][9][10]．

ただし，OMR を対象とした楽譜保護においては，単に誤認識数を増加させるだけでは十分ではない．楽譜を構成する記号には小節線やタイのように他の記号との関係によって機能が定まるものがあり，これらの誤認識は楽譜の構造や他の記号との関係を利用した処理によって補正・復元される可能性がある．一方，音符は音高や音価などの楽曲内容を構成する主要な情報を担うため，その誤認識は曲の表現や特徴に直接影響し得る．そこで本研究では，楽譜画像の視認性を維持しつつ，音符情報の抽出を優先的に妨害する敵対的摂動生成手法を提案する．さらに，摂動付与領域を音符周辺に限定する Local Mask を導入し，妨害性能と元画像との知覚的類似性の両立を図る．

本研究の主な貢献は，以下の二点である．第一に，音符記号の特性を Selective Untargeted Evasion Attack[11] に組み込み，音符情報の抽出を選択的に妨害する敵対的摂動生成手法を設計した．第二に，摂動可能領域を音符周辺に限定する Local Mask を導入し，攻撃性能と元画像との知覚的類似性とのトレードオフを考慮した摂動生成を実現した．以上により，Selective Untargeted Evasion Attack と Local Mask を組み合わせた提案手法は楽譜画像の知覚的類似性を維持しながら，OMR による音符情報の抽出を選択的に妨害できることを示した．

## 2. 関連研究

### 2.1 著作権保護を目的とした楽譜保護手法

楽譜の不正利用を防止するため，これまでにも電子透かしや Digital Rights Management（以下，DRM）が検討されてきた．電子透かし [12] は楽譜画像に識別情報を埋め込むことで，著作権情報の付与や不正利用の追跡などを可能にする手法である．DRM[13] はデジタルコンテンツへのアクセス権限を管理することで，許可されていない利用や複製を制限する手法である．これらの手法は，主として著作権情報の管理や不正な複製・配布の抑止を目的としており，楽譜画像から音楽情報が抽出されること自体を防止するものではない．そのため，楽譜画像が閲覧可能な状態で公開されている場合，これらの手法のみでは，OMR を利用した楽譜情報の抽出を防止することは困難である．

### 2.2 敵対的攻撃

敵対的攻撃とは，入力データに微小な変化を加えることで，機械学習モデルの予測結果を意図的に誤らせる攻撃手法である．入力データに加える微小な変化を敵対的摂動と呼ぶ．敵対的攻撃は，攻撃者が対象モデルの内部情報を利用できるか否かによって，ホワイトボックス攻撃とブラックボックス攻撃に大別される．ホワイトボックス攻撃では，対象モデルに関する完全な情報を利用して敵対的摂動を生成する．一方，ブラックボックス攻撃では，対象モデルの内部情報を利用せず，モデルから得られる予測確率や予測結果などの出力情報を利用して攻撃を行う [14]．損失関数に対する入力の勾配を用いて，モデルの予測を意図した方向へ変化させる摂動を生成する代表的な手法として，Fast Gradient Sign Method（FGSM）[7] や Projected Gradient Descent（PGD）[15] が挙げられる．FGSM は，損失関数の勾配の符号に基づいて入力を一度更新することで敵対的摂動を生成するのに対し，PGD は，摂動量に制約を設けながら勾配に基づく更新を反復することで，より強力な敵対的摂動を探索する．これらの手法は画像分類をはじめとする様々な認識モデルに対する攻撃に用いられている．本研究では，画像全体を摂動対象とする PGD をベースライン手法として採用する．

© 2026 Information Processing Society of Japan

### 2.3 AI による情報抽出・利用の妨害を目的とした敵対的摂動

著作物を AI による利用から保護する目的で敵対的摂動を利用する研究も行われている．Shan ら [8] は，アーティストの画風模倣を防ぐことを目的として，保護対象の作品の特徴表現を別の画風へ変化させる敵対的摂動を付与する Glaze を提案した．例えば，水彩画の作品に対して，油絵の表現に対応する潜在的特徴を摂動として付与し，元の作品とは異なる表現での生成を誘導する．また，Van ら [9] は，Text-to-Image モデルである DreamBooth に対する防御手法を提案した．学習画像に敵対的摂動を付与することで，生成画像の画質低下・顔検出の失敗・対象人物との顔の不一致等を生じさせ，ディープフェイク画像の生成を妨害する．Xu ら [10] は情報のプライバシー保護を目的として，看板や標識などの画像に含まれる文字を認識する Scene Text Recognition（STR）[16] を対象とした敵対的攻撃手法を提案した．Xu らの手法では，対象モデルの出力のみを利用するブラックボックス環境において，少数の画素に限定して摂動を付与し，画像への影響を抑えつつ，STR による文字情報の認識を妨害する．

### 2.4 Optical Music Recognition（OMR）

OMR とは楽譜画像に記された音楽記号をコンピュータによって解析し，その内容をデジタル形式の音楽情報へ変換する技術である [4]．楽譜画像を OMR に入力すると，楽譜画像に含まれる音楽記号情報がテキストデータとして出力される．従来の OMR は，前処理，音楽記号の検出・認識，記譜構造の復元，符号化などの複数段階からなるパイプラインとして構築されてきた．近年では，深層学習の発展に伴い，これらの処理を統合した End-to-End の OMR が研究されており，楽譜画像から音楽情報を直接認識する手法も提案されている [5]．OMR の系列認識には，Connectionist Temporal Classification（CTC）[17] が用いられる．CTC を用いることで，楽譜画像中の各記号の位置を事前に与えることなく，正解となる記号系列のみを用いてモデルを学習できる．OMR モデルは，入力された楽譜画像から時系列の特徴を抽出し，各時刻において音楽記号の各クラスおよび記号が存在しないことを表す blank クラスの確率を予測する．ここで，各時刻における予測単位をフレームと呼ぶ．得られたフレームごとの予測に CTC の規則を適用することで，blank や連続して出力された同一記号を処理し，最終的な音楽記号系列を得る．

### 2.5 本研究の位置付け

関連研究から，AI による著作物の情報抽出・利用を妨害するために敵対的摂動を利用する手法が提案されているものの，その対象は主として画像生成モデルや文字認識モデルであり，楽譜画像から音楽情報を抽出する OMR を対象とした著作物保護については著者らの知る限り十分に検討されていない．そこで，本研究では，OMR を対象として音符情報の重要性を考慮した敵対的摂動生成手法を設計し，AI による音楽情報の抽出を妨害する手法を提案する．

## 3. 提案手法

本研究では，対象となる OMR モデルの内部構造および勾配情報に完全にアクセス可能であるホワイトボックス環境を前提とする．提案手法の処理の流れを図 1 に示す．まず事前準備として，(1) 入力画像に対して OMR モデルによる推論を行い，認識結果に基づき音符が存在すると推定されるフレームを特定し，摂動の付与領域を音符周辺に限定するための Local Mask を決定する．次に，(2) 各音符フレームに対して回避クラスを設定し，反復的な最適化プロセスへと移行する．最適化の各反復ステップでは，Kwon ら [11] の Selective Untargeted Evasion Attack（以下，SUEA）と Carlini ら [18] のマージン制約の考え方に基づき，回避クラスへの誤認識を抑制する Margin Loss を計算する．最後に，(3) 損失関数から得られる画像勾配を Local Mask で制限し，限定された領域の摂動のみを更新する．

以上の処理を繰り返すことで，知覚的差異を抑えつつ，音符情報の誤認識を誘発する敵対的摂動を生成する．以降では，(1)〜(3) それぞれの処理の詳細について述べる．

### 3.1 音符フレームの特定と Local Mask の決定

本研究では，摂動付与前後における画像間の知覚的な差異の低減を目的として摂動付与領域を限定する Local Mask（$M$）を導入する．また，摂動付与領域を限定しつつ音符情報の抽出を優先的に妨害するには音符周辺の領域が重要であると考え，音符周辺の画像領域を考慮して $M$ を設計する．

第一に，音符が存在すると推定される位置を示すフレームマスク $M_{\text{note}}$ を生成する．入力画像 $x_0$ に対して OMR モデルによる推論を行い，各フレームにおける対数確率を取得する．音符の予測確率が最大となるフレームを $f_{\text{note}}$ とする．モデル特有の予測遅延を考慮し，音符の出力位置 $f_{\text{note}}$ から，その 2 フレーム前の $f_{\text{note}} - 2$ までの 3 フレーム区間を 1，それ以外を 0 とする二値マスク $M_{\text{note}}$ を生成する．

第二に，インク周辺マスク $M_{\text{space}}$ を生成する．元の楽譜画像におけるインク描画ピクセルに対してモルフォロジー膨張処理を適用し，周囲 $\pm 3$ ピクセルの範囲のみを 1 とする二値マスク $M_{\text{space}}$ を生成する．

最終的に，2 つのマスクの要素ごとの積 $M = M_{\text{note}} \odot M_{\text{space}}$ を算出し，$M$ を決定する．

© 2026 Information Processing Society of Japan

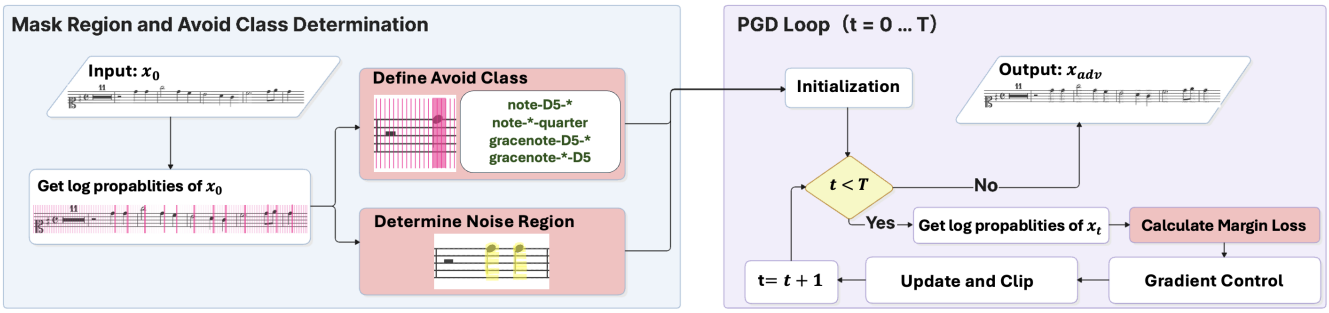



図 1: 提案手法のフローチャート

### 3.2 回避クラスの設定と Margin Loss の設計

PGD による CTC 損失の最大化では，誤認識量を増加させることを目的として最適化を行うため，誤認識させる記号の種類を直接制御することはできない．そこで，特定のクラスへの誤認識を回避しつつ，それ以外のクラスへの誤認識を誘発する SUEA の考え方を導入する．

楽曲の主要な要素である音符の誤認識を優先的に誘発させるため，回避クラス集合 $C_{\text{avoid}}$ に「元の音符と音高または音価が一致する音符・装飾音符」を，非回避クラス集合 $C_{\text{other}}$ に $C_{\text{avoid}}$ に含まれないクラスをそれぞれ設定する．

選択的な誤認識を実現し，回避クラスと非回避クラスの出力に一定のマージンを設けるため，マージン損失（$\mathcal{L}_{\text{margin}}$）を導入する．各フレーム毎に設定した回避クラスの出力を抑制するための $\mathcal{L}_{\text{margin}}$ は (1) 式のように定義される．

$$\mathcal{L}_{\text{margin}} = \max\left(0,\ \max_{c \in C_{\text{avoid}}} z_c^{(f)} + \kappa - \max_{c \in C_{\text{other}}} z_c^{(f)}\right) \tag{1}$$

また，CTC 損失の計算に用いるフレーム単位の対数確率と整合させるため，softmax 後の確率ではなく，log-softmax から得られる対数確率に基づいてマージンを定義する．$\kappa$ はクラス間の対数確率の差を決定するマージンパラメータであり，対応する確率の比は $e^{\kappa}$ となる．本損失を最小化することで，非回避クラスの最大対数確率が，回避クラスの最大対数確率を $\kappa$ 以上上回るように最適化される．

### 3.3 Local Mask を用いた摂動更新

決定した $M$ を用いて，反復的な PGD ループ（$t = 0 \ldots T$）により敵対的摂動を最適化する．

初期摂動 $\delta_1$ は，一様分布 $\mathcal{U}(-\epsilon, \epsilon)$ からサンプリングして生成する．ここで，$\epsilon$ は画素値変更許容量を示す．

反復ステップ $t$ における敵対的摂動の更新則は，勾配計算，勾配マスキング，および更新とクリッピングを統合した式 (2) で表される．

$$\delta_{t+1} = \Pi_{\mathcal{S}}\left(\delta_t - \alpha \cdot \left(\operatorname{sgn}\left(\nabla_{\delta_t} \mathcal{L}_{\text{margin}}(x + \delta_t)\right) \odot M\right)\right) \tag{2}$$

ここで，$\alpha$ はステップサイズであり，$\nabla_{\delta_t} \mathcal{L}_{\text{margin}}$ は反復ステップ $t$ における摂動 $\delta_t$ に関する Margin Loss の勾配である．勾配の符号関数 sgn に対して $M$ を要素ごとに乗算することで，音符フレームにおけるインク周辺にのみ局所的に摂動を適用する．また，$\Pi_{\mathcal{S}}$ は，更新された摂動を実行可能集合 $\mathcal{S}$ へ投影する関数を表す．この集合 $\mathcal{S}$ は，$L_\infty$ ノルムに基づく摂動の上限制約（$\|\delta\|_\infty \leq \epsilon$）を満たしつつ，摂動を付与した画像 $x + \delta$ の各画素値が妥当な範囲 $[0, 1]^d$ 内に収まるように定義される．所定のステップ数 $T$ 回の反復後，最終的な敵対的画像は $x_{adv} = x + \delta_T$ として生成される．

## 4. 提案手法の評価

本稿では，提案手法の有効性および信頼性を，(1)SUEA によって音符情報を選択的に妨害できるか，(2)Local Mask によって知覚的差異を低減できるか，(3) 両者を組み合わせることで音符情報の抽出妨害と元画像との知覚的類似性を両立できるか，の 3 つの観点から検証する．

### 4.1 実験条件

**妨害対象 OMR モデルとデータセット**

妨害対象 OMR は Yu ら [6] によって提案された Multi-level Cascade Residual Recognition（MCRR）である．本モデルは，加法ホワイトガウスノイズ，加法パーリンノイズ，弾性変形等のデータ拡張に加え，5 層の残差畳み込みネットワークおよびマルチレベルのカスケード融合を導入している．原論文におけるモデルの音高と音価の両方が一致した音符の割合を示す Note Accuracy は 94.445%であり，本研究の再現実験では 99.919%となった．元論文ではデータ拡張の対象割合や拡張処理のパラメータが詳細に記載されていなかったため，本研究ではこれらを推定して設定しており，このようなデータ拡張条件の差異が再現実験の結果に影響した可能性がある．

また，データセットには MCRR の学習に用いられた Printed Images of Music Staves（PrIMuS）[19] を用いる．PrIMuS には，87,687 件の単旋律楽譜が含まれており，楽譜画像と音楽情報を表現するテキストデータから構成される．音楽情報テキストデータは，MEI 形式，semantic 形式，agnostic 形式等で記述されている．MCRR の学習条件

© 2026 Information Processing Society of Japan

表 1: 各 Case の妨害設定と位置付け

| | Mask | Loss | 位置付け |
|---|---|---|---|
| Case1 | Global | CTC | ベースライン |
| Case2 | Local | CTC | Local Mask の効果 |
| Case3 | Global | Margin | SUEA の効果 |
| Case4 | Local | Margin | 提案手法 |

を再現するため，楽譜画像と semantic 形式データを学習に用いる．各楽譜に含まれる音符数は平均 15.5 個，小節数は平均 4.2 小節である．データセットは学習用，検証用，テスト用に 8：1：1 の割合で分割する．攻撃対象には，テストデータのうち，正解記号系列と OMR モデルの予測記号系列が完全に一致し，かつ音符を含むデータを選定する．これらの条件を満たす攻撃対象データは 7,881 件である．

**妨害条件の組合せ**

提案手法を構成する SUEA と Local Mask が妨害性能および知覚的差異に与える影響を検証するため，摂動付与領域（Mask）と損失関数（Loss）の 2 要因を設定する．Mask には画像全域に摂動を付与する Global Mask（Global）と，音符周辺領域に摂動を付与する Local Mask（Local）を，Loss には CTC 損失を単純に最大化する条件（CTC）と回避クラスの出力を抑制する Margin Loss を用いる条件（Margin）を設定する．4 つの妨害設定を表 1 に示す．

**パラメータ設定**

敵対的摂動の画素値変更許容量 $\epsilon$ を 0.2，1 反復あたりの更新ステップサイズ $\alpha$ を 0.02 に設定した．また，Margin Loss におけるマージンパラメータ $\kappa$ の最適値を Optuna を用いて探索した．Optuna の目的関数には，Margin Loss の算出対象となる各フレームにおいて所定のマージン差を達成した割合を表すマージン達成率を用い，その最大化を図った．$\kappa$ の探索範囲は 0.0〜5.0，試行回数は 100 回，探索対象の画像は 100 枚とした．Global Mask と Local Mask の摂動付与領域の違いを考慮しつつ，妨害性能を最大化することを目的として，$\kappa$ は Case ごとに独立して最適化した．探索の結果，Case3 では $\kappa = 4.607$，Case4 では $\kappa = 0.114$ が得られた．

**評価指標**

音符情報の抽出妨害性能の評価には，Pitch Discrepancy Rate（PDR），Type Discrepancy Rate（TDR），Both Discrepancy Rate（BDR）を用いる．これらは，妨害後の予測記号列と正解記号列をレーベンシュタイン距離に基づいてアラインメントし，正解記号列に含まれる音符を基準として算出する．すなわち，正解側の各音符について，対応する予測結果が存在する場合は音高および音価の一致，削除または音符以外の記号への置換が生じた場合は不一致として判定する．PDR，TDR，BDR はそれぞれ音高，音価，音高と音価の両方が不一致となった音符の割合を示し，(3)(4)(5) 式で定義する．

$$\mathrm{PDR} = \frac{N_{\mathrm{pitch}}}{N_{\mathrm{note}}} \tag{3}$$

$$\mathrm{TDR} = \frac{N_{\mathrm{type}}}{N_{\mathrm{note}}} \tag{4}$$

$$\mathrm{BDR} = \frac{N_{\mathrm{both}}}{N_{\mathrm{note}}} \tag{5}$$

ここで，$N_{\mathrm{note}}$ は正解記号列に含まれる音符数，$N_{\mathrm{pitch}}$，$N_{\mathrm{type}}$，$N_{\mathrm{both}}$ は，それぞれ音高，音価，音高と音価の両方が不一致となった音符数を表す．各指標の値が高いほど，音符情報の抽出に対する妨害性能が高いことを示す．

また，OMR における認識性能の評価指標として，Symbol Error Rate（SyER）および Sequence Error Rate（SeqER）を用いる．SyER は，予測記号列を正解記号列に一致させるために必要な削除，置換，挿入の操作数を正解記号列の総記号数で正規化した値であり，(6) 式で定義する．

$$\mathrm{SyER} = \frac{D + S + I}{N} \tag{6}$$

ここで，$D$，$S$，$I$ はそれぞれ削除，置換，挿入の操作数，$N$ は正解記号列の総記号数を表す．SyER が高いほど，予測記号列に含まれる誤認識量が多いことを示す．

SeqER は，評価対象となる記号列のうち，予測記号列と正解記号列が一致しない記号列の割合であり，(7) 式で定義する．

$$\mathrm{SeqER} = \frac{N_{\mathrm{error_seq}}}{N_{\mathrm{seq}}} \tag{7}$$

ここで，$N_{\mathrm{error_seq}}$ は予測記号列と正解記号列が一致しない記号列数，$N_{\mathrm{seq}}$ は評価対象とした記号列の総数を表す．

また，敵対的摂動付与前後の画像間における知覚的差異を評価するため，LPIPS（Learned Perceptual Image Patch Similarity）[20] を用いる．LPIPS は，深層ニューラルネットワークから抽出した画像特徴量の距離に基づき，画像間の知覚的類似性を評価する指標であり，値が低いほど画像間の知覚的差異が小さいことを示す．摂動付与前後の楽譜画像に対して LPIPS を算出し，摂動による知覚的差異の大きさを評価する．

### 4.2 回避クラス設定による妨害性能の比較

SUEA による音符情報の抽出妨害性能を評価するため，同一の摂動付与範囲において CTC 損失を用いる条件と Margin Loss を用いる条件を比較した．具体的には，Global Mask では Case1 と Case3，Local Mask では Case2 と Case4 を比較した．各指標による評価結果をまとめたものを表 2 に示す．

Case1 と Case3 を比較すると，Case1 では SyER が 97.074%と高い値を示した一方，BDR は 64.141%にとどまった．これに対し，Case3 では SyER が 66.702%に低下

© 2026 Information Processing Society of Japan

表 2: 各防御手法と評価

| | △ PDR（%） | △ TDR（%） | △ BDR（%） | △ SyER | △ SeqER（%） | ▼ Time（sec） | ▼ LPIPS |
|---|---|---|---|---|---|---|---|
| Case1 | 91.479 | 66.252 | 64.141 | **97.074** | **100** | **1.501** | 0.398 |
| Case2 | 36.019 | 40.882 | 23.220 | 37.882 | 99.949 | 1.816 | 0.115 |
| Case3 | **99.585** | **99.350** | **99.063** | 66.702 | **100** | 3.510 | 0.362 |
| Case4 | 82.780 | 84.290 | 80.705 | 55.093 | 99.975 | 3.697 | **0.106** |

したものの，BDR は 99.063%に達した．また，Case4 は Case2 と比較して，BDR および SyER の両方で高い値を示した．

一方，Time は敵対的摂動の最適化に要した時間（sec）を示す．Case3 および Case4 では，Case1 および Case2 と比較して，敵対的摂動の生成時間が約 2 倍に増加した．

### 4.3 摂動付与範囲の制御による知覚的類似性の比較

Local Mask による知覚的差異の低減効果を評価するため，同一の損失関数を用いる条件間で Global Mask と Local Mask を比較した．具体的には CTC 条件では Case1 と Case2，Margin Loss 条件では Case3 と Case4 を比較した．図 2 に各条件における敵対的摂動付与後の楽譜画像を示す．Local Mask を適用した Case2 および Case4 の LPIPS はそれぞれ 0.115，0.106 であったのに対し，Global Mask を適用した Case1 および Case3 ではそれぞれ 0.398，0.362 であった．Local Mask の導入により，摂動付与前後の画像間の知覚的差異が低減されたことが分かる．

### 4.4 提案手法の総合評価

提案手法が音符情報の抽出妨害性能と知覚的差異の抑制を両立できるかを評価するため，提案手法である Case4 をベースラインの Case1 および SUEA のみを用いる Case3 と比較した．表 2 に示すように，提案手法 Case4 の BDR は 80.705%であり，Case1 の 64.141%を上回った．一方，Case3 と比較すると，BDR は 99.063%から低下したものの，LPIPS は Case3 の 0.362 から Case4 の 0.106 へと減少し，知覚的差異が大きく抑制された．また，SeqER は，Case3 の 100%に対して Case4 では 99.975%であり，同等の値を示した．

以上より，提案手法では，SUEA により音符情報の誤認識を優先的に誘発し，Local Mask によって摂動付与領域を音符周辺に限定することで，音符情報抽出に対する妨害性能を維持しつつ，摂動付与による知覚的差異を抑制できることが示された．

## 5. 議論

### 5.1 Margin Loss 設計による誤認識傾向の変化

Case1 は Case3 と比較して SyER が 30.372 ポイント高く，記号列全体に対する誤認識が多く生じた一方，BDR は 34.922 ポイント低かった．この結果から，単純な CTC 損失の最大化は記号全体の誤認識量を増加させることができるものの，音符情報の抽出を優先的に妨害することは困難であることが示唆される．

図 3 は，各条件における削除の誤認識のうち，出現数が多い上位 10 種類を示す．Case1 と Case2 では小節線，Case3 と Case4 では音符の削除誤認識が多く生じた．また，図 4 は，各条件における置換誤認識のうち，出現数が多い上位 10 種類を示す．Case1 では音符から小節線への置換，Case2 では音高は一致するものの音価が異なる音符への置換，Case3 と Case4 では音符から全休符や 2 分休符への置換が多く生じた．また，挿入誤認識については，Case1 では小節線が 6,456 件，タイが 1,469 件，Case2 では小節線が 1,467 件，タイが 386 件生じたのに対し，Case3 および Case4 では挿入誤認識自体がほとんど生じなかった．

CTC では blank の出力確率が高く，非 blank シンボルの出力が一部のフレームに集中する傾向が知られている [21]．Case3 および Case4 では，音符が存在すると推定されたフレームを対象として Margin Loss を最適化している．このため，対象フレームにおける音符クラスの出力が抑制され，blank の出力による音符の削除や，休符等の異なるへの誤認識が生じやすくなったと考えられる．一方，音符以外の記号が存在するフレームは Margin Loss の最適化対象外であるため，小節線やタイなどの挿入誤認識は生じにくくなったと考えられる．

### 5.2 摂動付与領域の限定による誤認識傾向の変化

Local Mask の導入により，画像全域に摂動を付与した場合と比較して LPIPS が大幅に低下し，摂動付与前後の画像間の知覚的差異が抑制された．ただし，Case2 は Case1 と比較して，SyER が 59.192 ポイント，BDR が 40.921 ポイント低下し，Case4 は Case3 と比較し，SyER が 11.609 ポイント，BDR が 18.358 ポイント低下した．

よって，摂動付与領域を音符周辺に限定することで，誤認識量および音符情報の抽出妨害性能が低下することが示された．

### 5.3 回避クラスの設定と摂動付与領域の限定による誤認識傾向と妨害性能

Case1 および Case2 では，回避クラスを設定した Case3

© 2026 Information Processing Society of Japan




図 2: 各 Case の敵対的摂動付与後の楽譜画像

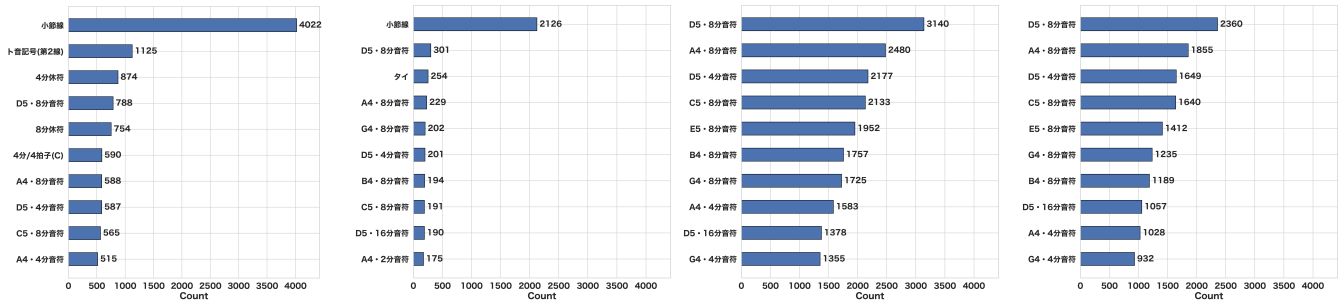



図 3: 各 Case における削除誤認識上位 10 種類

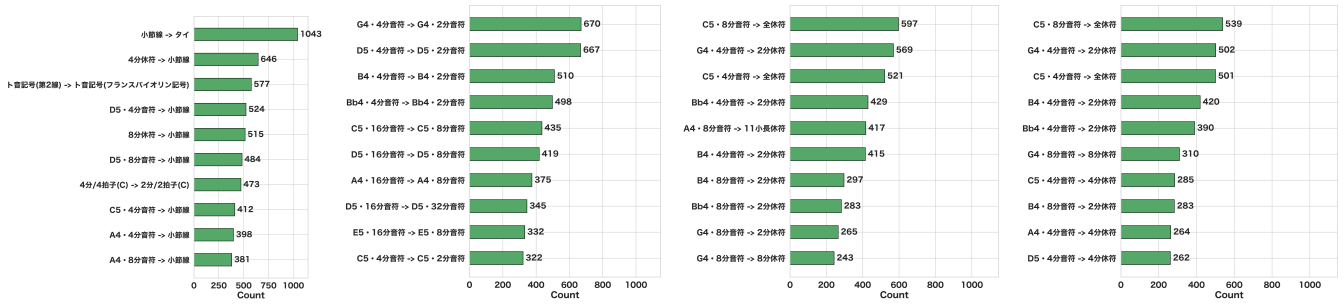



図 4: 各 Case における置換誤認識上位 10 種類

および Case4 と比較して，音符情報抽出妨害性能が低い結果となった．

Case4 では Case3 と比較して音符情報の抽出妨害性能が低下したものの，知覚的差異は抑制された．さらに，5.1 節で示したように，Case3 と Case4 では誤認識の傾向が概ね一致している．

以上の結果から，SUEA の導入によって音符情報に対する妨害性能が向上する一方，Local Mask を適用した場合には妨害性能が低下する．また今回設定した回避クラスの下では，Global Mask と同様の誤認識傾向を維持しながら，知覚的差異を抑制できることが示唆された．

## 6. 終わりに

本研究では，光学音楽認識（OMR）モデルによる楽譜情報の取得を妨害することを目的として，誤認識の対象を制御する Selective Untargeted Evasion Attack と，摂動の空間的範囲を制御する Local Mask を組み合わせた楽譜保護手法を提案した．

評価実験の結果，単純な CTC 損失の最大化では記号全般の誤認識量が増加するものの，楽曲内容を構成する主要な記号である音符を優先的に妨害することは困難であることが確認された．一方，Selective Untargeted Evasion Attack を用いることで，音符情報の抽出を優先的に妨害できることが示された．さらに Local Mask を組み合わせることで，攻撃対象の選択性を維持したまま摂動範囲を限定し，妨害性能と入力楽譜との知覚的類似性を両立できることが示された．

本研究は，人間による楽譜の閲覧可能性を保ちながら，AI による音楽情報の抽出を技術的に制御するための基礎的知見を提供するものである．これにより，著作者の意思を反映した音楽コンテンツの公開・流通を支援し，生成 AI 時代における音楽著作物の保護に寄与することが期待される．

今後の課題として，異なる OMR モデルに対する転移性

© 2026 Information Processing Society of Japan

の評価，人間による楽譜可読性の評価，摂動量の削減および攻撃成功率の向上が挙げられる．また，摂動位置と誤認識結果の関係を詳細に分析し，知覚的変化を抑制する攻撃手法について検討する．

## 参考文献


[1] Pamela Samuelson. Generative ai meets copyright. *Science*, Vol. 381, No. 6654, pp. 158–161, 2023.

[2] 文化庁. 著作権法の一部を改正する法律（平成 30 年法律第 30 号）について. `https://www.bunka.go.jp/seisaku/chosakuken/hokaisei/h30_hokaisei/`. 2026 年 8 月 19 日閲覧.

[3] Mauricio Araneda-Hernandez, Felipe Bravo-Marquez, Denis Parra, and Rodrigo F Cádiz. Musib: musical score inpainting benchmark. *EURASIP Journal on Audio, Speech, and Music Processing*, Vol. 2023, No. 1, p. 19, 2023.

[4] Jorge Calvo-Zaragoza, Jan Hajič Jr, and Alexander Pacha. Understanding optical music recognition. *ACM Computing Surveys (CSUR)*, Vol. 53, No. 4, pp. 1–35, 2020.

[5] Jorge Calvo-Zaragoza and David Rizo. End-to-end neural optical music recognition of monophonic scores. *Applied Sciences*, Vol. 8, No. 4, p. 606, 2018.

[6] Ping Yu and Hailing Chen. Deep multilevel cascade residual recurrent framework (mcrr) for sheet music recognition. *IEEE Access*, Vol. 12, pp. 6941–6960, 2024.

[7] Ian J Goodfellow, Jonathon Shlens, and Christian Szegedy. Explaining and harnessing adversarial examples. *arXiv preprint arXiv:1412.6572*, 2014.

[8] Shawn Shan, Jenna Cryan, Emily Wenger, Haitao Zheng, Rana Hanocka, and Ben Y Zhao. Glaze: Protecting artists from style mimicry by {Text-to-Image} models. In *32nd USENIX Security Symposium (USENIX Security 23)*, pp. 2187–2204, 2023.

[9] Thanh Van Le, Hao Phung, Thuan Hoang Nguyen, Quan Dao, Ngoc N Tran, and Anh Tran. Anti-dreambooth: Protecting users from personalized text-to-image synthesis. In *2023 IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 2116–2127. IEEE, 2023.

[10] Yikun Xu, Pengwen Dai, Zekun Li, Hongjun Wang, and Xiaochun Cao. The best protection is attack: Fooling scene text recognition with minimal pixels. *IEEE Transactions on Information Forensics and Security*, Vol. 18, pp. 1580–1595, 2023.

[11] Hyun Kwon, Yongchul Kim, Hyunsoo Yoon, and Daeseon Choi. Selective untargeted evasion attack: An adversarial example that will not be classified as certain avoided classes. *IEEE Access*, Vol. 7, pp. 73493–73503, 2019.

[12] Qizheng Huang, Jiayi Zhu, Yuanjie Xian, and Jiyou Peng. Music score copyright protection based on mixed low-order quaternion franklin moments. *Plos one*, Vol. 20, No. 8, p. e0323447, 2025.

[13] SR Subramanya and Byung K Yi. Digital rights management. *IEEE potentials*, Vol. 25, No. 2, pp. 31–34, 2006.

[14] Sicong Han, Chenhao Lin, Chao Shen, Qian Wang, and Xiaohong Guan. Interpreting adversarial examples in deep learning: A review. *ACM Computing Surveys*, Vol. 55, No. 14s, pp. 1–38, 2023.

[15] Aleksander Madry, Aleksandar Makelov, Ludwig Schmidt, Dimitris Tsipras, and Adrian Vladu. Towards deep learning models resistant to adversarial attacks. *arXiv preprint arXiv:1706.06083*, 2017.

[16] Kai Wang, Boris Babenko, and Serge Belongie. End-to-end scene text recognition. In *2011 International conference on computer vision*, pp. 1457–1464. IEEE, 2011.

[17] Alex Graves, Santiago Fernández, Faustino Gomez, and Jürgen Schmidhuber. Connectionist temporal classification: labelling unsegmented sequence data with recurrent neural networks. In *Proceedings of the 23rd international conference on Machine learning*, pp. 369–376, 2006.

[18] Nicholas Carlini and David Wagner. Towards evaluating the robustness of neural networks. In *2017 ieee symposium on security and privacy (sp)*, pp. 39–57. Ieee, 2017.

[19] PrIMuS. `https://grfia.dlsi.ua.es/primus/`.

[20] Richard Zhang, Phillip Isola, Alexei A Efros, Eli Shechtman, and Oliver Wang. The unreasonable effectiveness of deep features as a perceptual metric. In *2018 IEEE/CVF conference on computer vision and pattern recognition*, pp. 586–595. IEEE, 2018.

[21] Ruizhe Huang, Xiaohui Zhang, Zhaoheng Ni, Li Sun, Moto Hira, Jeff Hwang, Vimal Manohar, Vineel Pratap, Matthew Wiesner, Shinji Watanabe, et al. Less peaky and more accurate ctc forced alignment by label priors. In *ICASSP 2024-2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pp. 11831–11835. IEEE, 2024.


© 2026 Information Processing Society of Japan