敵対的摂動型ビジュアルプロンプトインジェクションにおける視覚言語モデルの内部状態の分析

熊谷 瞭[1,a)]　竹本 修[2]　野崎 佑典[2]　吉川 雅弥[2]

概要：敵対的摂動を用いたビジュアルプロンプトインジェクションは，元画像の主要な意味内容を保持しつつ，視覚言語モデルの出力を特定の方向へ誘導するが，この攻撃の成立過程は十分に明らかではない．本稿では，視覚エンコーダの層別観察，残差ストリーム解析，logit lens，activation patching を組み合わせ，敵対的画像と通常画像の内部表現の差を追跡する．解析の結果，敵対的摂動に由来する表現差は視覚経路で形成される一方，その表現差が標的語彙として線形に読み出せるようになるのはさらに後段の層であり，敵対的摂動の影響が生成位置に到達する段階と，その影響が特定の標的語彙に対応する表現へ変換される段階は一致しないことを確認した．さらに，logit lens で標的語彙の読み出しが急激に強まる層域と，activation patching により画像トークン表現を復元しても攻撃状態を除去できなくなる層域が近接していた．

キーワード：視覚言語モデル，プロンプトインジェクション，敵対的摂動，logit lens，activation patching

Analysis of Internal States for Perturbation-Based Visual Prompt Injection in Vision-Language Models

Ryo Kumagai[1,a)]　Shu Takemoto[2]　Yusuke Nozaki[2]　Masaya Yoshikawa[2]

Abstract: Visual prompt injection based on adversarial perturbations can steer the outputs of vision-language models while largely preserving the perceptual content of an input image. However, the process by which this attack is carried out has not been sufficiently clarified. This study analyzes these internal dynamics by combining layer-wise observations of the vision encoder, residual stream analysis, the logit lens, and activation patching. The results show that perturbation-induced representation differences are formed in the visual pathway and subsequently propagate to the generation position, whereas they become readable as the target vocabulary only in later decoder layers. Moreover, the decoder region in which the target vocabulary becomes readable is close to the region in which restoring clean image-token activations no longer removes the adversarial prediction.

Keywords: vision-language model, prompt injection, adversarial perturbation, logit lens, activation patching

1. はじめに

大規模言語モデル（large language model: LLM）は，Transformer [1] に基づく自己回帰的な次トークン予測によって，多様な自然言語処理タスクを単一モデルで実行できる．さらに，画像や動画を扱う視覚エンコーダと LLM を接続した視覚言語モデル（vision-language model: VLM）は，画像キャプション生成，視覚的質疑応答，文書解析などへ利用範囲を広げている [2], [3]．VLM では視覚情報が言語トークンと同じ生成過程に取り込まれるため，画像の内容は単なる補助情報ではなく，次トークン分布そのもの

[1] 名城大学大学院理工学研究科
Graduate School of Science and Technology
[2] 名城大学情報工学部
Faculty of Information Engineering, Meijo University
[a)] 243441501@ccmailg.meijo-u.ac.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

を変化させる入力となる．

LLM に対し悪意ある命令を入力し，本来の指示や制約から逸脱した出力を生成させる攻撃はプロンプトインジェクションと呼ばれる [4]．VLM に対しては，攻撃命令を画像中に埋め込むビジュアルプロンプトインジェクション（visual prompt injection: VPI）が可能である．FigStep [5] は有害な命令をタイポグラフィとして画像化することで安全機構を回避し，Con Instruction [6] は非テキストモダリティの敵対的入力を最適化して有害な指示を伝達できることを示した．これらの研究は，視覚入力を介してモデルの命令解釈や生成過程を操作できることを示している．

敵対的摂動を用いて VLM の次トークン予測を標的系列へ直接誘導する VPI も提案されている [7]．この手法では，可読な命令文を画像上に配置する代わりに，標的トークンに対する予測損失を画像へ逆伝搬し，PGD によって微小な摂動を最適化する．従来の VPI が画像内の内容を命令として解釈させる攻撃であるのに対し，敵対的摂動型 VPI は語彙分布に対する目的関数から画像を直接最適化するため，モデル内部で入力摂動に由来する表現差がどのように処理されるかは自明でない．

そこで本研究では，敵対的摂動型 VPI を対象として，視覚入力から最終語彙分布までの内部状態を層ごとに追跡する．視覚エンコーダでは通常画像と敵対的画像の表現差を観察し，言語デコーダでは残差ストリーム [9] によって画像位置と生成位置の変化を追跡する．さらに，logit lens [10] によって標的語彙方向の形成過程を読み出し，activation patching [11], [12] によって画像トークン表現を介入的に置換する．これらを同一の画像対と層軸上で比較し，敵対的表現差の形成，伝播，語彙予測への変換を分離して分析する．

本研究の貢献は，敵対的摂動型 VPI による出力誘導の成立過程を複数の内部解析手法により層ごとに分離して示した点にある．さらに，標的語彙の読み出しが急激に強まる層域と，画像トークンの置換による回復効果が失われる層域が近接することを明らかにした．

2. 準備

2.1 LLM および VLM

LLM は，離散的なテキストトークン列を連続ベクトルへ埋め込み，多層 Transformer を通して次トークンの条件付き確率分布を推定する自己回帰モデルである．入力トークン列を $x_{1:T}$，語彙集合を $\mathcal{V}$ とすると，次トークン x_{T+1} は

$$p(x_{T+1} \mid x_{1:T}) = \mathrm{softmax}(z_T) \qquad (1)$$

で表される語彙分布から生成される．ここで $z_T \in \mathbb{R}^{|\mathcal{V}|}$ は最終隠れ状態を語彙空間へ射影した logit である．生成されたトークンを入力列の末尾へ追加し，同じ処理を繰り返すことで文章を自己回帰的に生成する．

Transformer では，各トークン位置が self-attention を通して他の位置を参照し，MLP による変換と residual connection を重ねながら表現を更新する [1]．次トークン予測では入力列の最終位置の隠れ状態が最終正規化と語彙射影を通って logit へ変換されるため，本稿ではこの位置を生成位置と呼ぶ．

VLM は，言語トークンに加えて画像や動画の特徴を同一の生成モデルへ入力するマルチモーダルモデルである．代表的な構成では，画像を ViT [2] 等の視覚エンコーダによりパッチ単位の特徴へ変換し，projector や merger を介して LLM が扱える画像トークン列へ写像する．その後，画像トークンと言語トークンを一つの系列として言語デコーダへ入力し，両モダリティを条件とする次トークン分布を生成する．

本稿で対象とする Qwen2.5-VL は，動的解像度処理を備えた ViT を視覚エンコーダとして用い，画像解像度に応じた視覚トークン列を言語モデルへ接続する VLM である [3]．視覚エンコーダの出力は merger で集約・変換された後，入力系列中の画像トークン位置に配置される．

2.2 プロンプトインジェクション

プロンプトインジェクションは，攻撃者が入力に悪意ある命令を混入させることで，システムが本来想定した指示や制約より攻撃者の指示を優先させる攻撃である [4]．ユーザが直接悪意ある文字列を入力する直接型に加え，Web ページ，文書，画像等の外部コンテンツをモデルが読み取ることで攻撃命令が取り込まれる間接型が存在する．後者では，システムが信頼して取り込んだ外部情報と，実行すべき命令との境界がモデル内部で曖昧であることが攻撃の成立要因となる．

VLM において画像経由で不正な指示や表現を与える攻撃は VPI と呼ばれる．FigStep は，有害な要求を画像中のタイポグラフィへ変換することで，視覚モダリティを経由して安全機構を回避できることを示した [5]．この種の攻撃では，画像中に存在する文字列をモデルが OCR 的に読み取り，その内容を命令として扱うことによって生成結果が変化する．そのため，人間や OCR からも攻撃内容を観測できる場合がある．

非テキストの入力自体を最適化する VPI も存在する．Con Instruction は，非テキストモダリティの埋め込みを標的指示へ近付ける敵対的最適化により，画像や音声から悪意ある指示を伝達できることを示している [6]．この場合，可読な命令文がなくても内部表現を介して出力が変化し，VLM の開発者により設計された安全機構が回避される等の脅威が発生し得る．

2.3 敵対的摂動を用いた VPI

敵対的摂動を利用した VPI [7] では，元画像 X に L_p ノ

© 2026 Information Processing Society of Japan

ルム制約下の摂動を加え，標的トークン列 $t = (t_1, \ldots, t_K)$ の生成確率が高くなるよう画像を更新する．標的系列の各位置で得られる交差エントロピー損失を $\mathcal{L}_k$ とすると，全体損失は

$$E(X) = \sum_{k=1}^{K} \mathcal{L}_k \tag{2}$$

で定義される．画像に関する勾配 $\nabla_X E$ を計算し，PGD [8] により

$$X^{(n+1)} = \Pi_{X^{(0)}+\epsilon}\left(X^{(n)} - \alpha \operatorname{sign}(\nabla_X E)\right) \tag{3}$$

のように更新する．Π は元画像を中心とする半径 ϵ の許容集合への投影である．

同手法の標的は 1 つ以上の任意のトークン列として設定できる．したがって，同手法による VPI は，視覚入力を通じてモデルの出力を任意の内容に誘導することが可能であり，下流の意思決定やツール利用を伴うシステムでは，誤った生成を誘発する潜在的な脅威となり得る．さらに，従来のような肉眼や OCR による検知・防御が困難であると指摘されている．

3. 提案手法

3.1 解析方針

通常画像を入力した実行を clean run，その画像から生成した敵対的画像を入力した実行を adversarial run とする．両実行では画像以外の入力条件と生成条件を固定し，同じ系列位置と層に対応する内部表現を比較する．解析は，視覚エンコーダで生じる表現差，言語デコーダ内での位置間伝播，標的語彙方向の形成，画像トークン表現の因果的寄与という複数の観点から行う．

clean/adversarial の比較では，入力 token id，系列長，画像トークン位置の一致を確認し，同一元画像の対応する画像トークン位置と生成位置を比較する．これにより，動的解像度に伴う系列構成の差と摂動による表現差を分離する．

3.2 表現距離

clean 側のベクトルを h^{c}，adversarial 側を h^{a} とし，層表現の方向差をコサイン類似度

$$C(h^{\mathrm{c}}, h^{\mathrm{a}}) = \frac{\langle h^{\mathrm{c}}, h^{\mathrm{a}} \rangle}{\|h^{\mathrm{c}}\|_2 \|h^{\mathrm{a}}\|_2} \tag{4}$$

で評価する．C が 1 に近いほど両表現の方向が一致し，値が低下するほど clean/adversarial の表現方向が異なる．

表現変化の大きさには相対 L_2 距離

$$D(h^{\mathrm{c}}, h^{\mathrm{a}}) = \frac{\|h^{\mathrm{a}} - h^{\mathrm{c}}\|_2}{\|h^{\mathrm{c}}\|_2} \tag{5}$$

を用いる．コサイン類似度で表現方向を，相対 L_2 距離でノルム変化を含む差を評価する．

複数の画像対を解析する場合，各指標は画像ごとに計算した後に層単位で平均する．平均値の不確かさは，標本標準偏差 s，標本数 N に対する $1.96s/\sqrt{N}$ を用いて 95%信頼区間として表示する．個々の画像で異なるトークン数を単純に連結して平均するのではなく，画像対ごとにまず代表値を計算してから集約する．

3.3 視覚エンコーダにおける特徴の追跡

視覚エンコーダの各 Transformer block と，LLM へ画像特徴を渡す merger の出力を forward hook により取得する．各段階の出力が複数の視覚トークンを含む場合，全トークンの平均ベクトルをその段階の代表表現 v_l とし，clean/adversarial 間の C と D を算出する．この解析は，画素摂動が視覚特徴抽出の過程でどの程度異なる内部表現へ写像されるかを観察するために用いる．

merger は視覚特徴を言語デコーダへ受け渡す境界であるため，vision block とは別の stage として記録し，decoder 入力の画像トークンと対応付ける．

3.4 残差ストリーム解析

Transformer で各 block の出力が residual connection を介して加算される経路は残差ストリーム（residual stream）と呼ばれる [9]．VLM の言語デコーダでは画像トークンと言語トークンが同じ系列上にあるため，この経路を通じた位置間の表現変化を観察できる．

本手法では，decoder layer 0 への入力，各 decoder layer 通過後，および最終正規化後の表現を residual stage として取得する．各 stage において，画像トークン位置の平均ベクトル r_l^{img} と，最初の生成トークンを予測する直前の生成位置 r_l^{gen} を取り出す．それぞれについて clean/adversarial 間のコサイン類似度と相対 L_2 距離を算出する．画像位置と生成位置を分けて測定することで，入力画像に由来する差がどの位置に存在するかを追跡する．

3.5 logit lens

logit lens は，中間層の隠れ状態を最終語彙射影へ直接入力し，各層に潜在する次トークン予測を可視化する手法である [10]．residual stage l における生成位置の表現 r_l^{gen} に最終正規化 LN_f と出力行列 W_U を適用し，

$$z_l = W_U \, \mathrm{LN}_f(r_l^{\mathrm{gen}}) \tag{6}$$

を得る．最終正規化後の stage については追加の正規化を行わない．

各 stage の z_l から標的トークン t の logit，確率，語彙内順位，top-1 token を求め，clean/adversarial の標的 logit 差

$$\Delta z_l(t) = z_l^{\mathrm{a}}(t) - z_l^{\mathrm{c}}(t) \tag{7}$$

を計算する．これにより，生成位置の表現差が標的トーク

© 2026 Information Processing Society of Japan

ンとして読み出せる時点を追跡する．

3.6 activation patching

activation patching は，ある入力で得られた中間 activation を別の実行へ注入し，出力変化からその activation の因果的役割を評価する介入法である [11], [12]．本手法では，adversarial run の decoder layer l 出力のうち画像トークン位置を，同一元画像に対する clean run の activation へ置換し，その後の forward を継続する．置換する層だけを変え，他の入力および生成条件は固定する．

評価指標として，clean run で本来 top-1 となるトークン c と攻撃標的 t の logit 差

$$M(z) = z(c) - z(t) \tag{8}$$

を用いる．clean，adversarial，patched run の値をそれぞれ M_{c}，M_{a}，$M_{\mathrm{p},l}$ とし，正規化回復率を

$$R_l = \frac{M_{\mathrm{p},l} - M_{\mathrm{a}}}{M_{\mathrm{c}} - M_{\mathrm{a}}} \tag{9}$$

と定義する．$R_l \simeq 1$ は当該層で画像トークンを clean 側へ戻すことで予測が clean に近く回復すること，$R_l \simeq 0$ は置換後も敵対的な予測が維持されることを表す．この正規化は値を $[0, 1]$ へ切り詰めないため，patch によって clean より強く回復した場合には 1 を超え，逆方向へ変化した場合には負値を取り得る．

4. 評価実験

4.1 実験条件

解析対象は Qwen/Qwen2.5-VL-3B-Instruct [3] とする．モデルは 32 個の vision block と 36 個の decoder layer を持ち，計算精度は bfloat16 である．100 枚の通常 PNG 画像と，それぞれを元に敵対的摂動による VPI 手法 [7] で生成した 100 枚の敵対的画像を対応付けて分析する．敵対的画像の L_∞ 摂動上限は 8 bit 画素値で $\epsilon = 32$ とし，生成した全 100 枚における敵対的摂動の L_∞ は 32 であった．平均 PSNR は 25.61 dB であった．

標的は単一トークン “cat”（token id 4616）のみとし，EOS トークンは攻撃目的に含めていない．また，ユーザプロンプトは与えず，画像のみを入力した．本稿では攻撃成功を「最初の生成トークンが `cat` であること」と定義する．生成は greedy decoding で最大 8 トークンまで行う．activation patching は 100 組すべてに対して全 36 decoder layer で実行し，置換位置は画像トークンのみとする．主要な実験条件を表 1 に示す．

解析には Python 3.12.3，PyTorch 2.9.1+cu130，Transformers 5.12.1 を用いる．表 2 に入力系列と摂動の統計量を示す．Qwen2.5-VL の動的解像度処理により画像トークン数は画像ごとに異なり，平均 234.34，最小 12，最大 324 であった．入力系列長は平均 255.34，最小 33，最大 345 であった．activation patching では各画像に対応する画像トークン位置を個別に取得し，その全位置を同一画像の clean activation で置換する．

表 1 実験条件

項目	設定
VLM	Qwen2.5-VL-3B-Instruct
通常 / 敵対的画像	100 組
ユーザプロンプト	なし
標的トークン	`cat`（id 4616）
EOS 最適化	なし
摂動制約	L_∞, $\epsilon = 32/255$
計算精度	bfloat16
decoder layer	36
vision block	32
activation patch	画像トークン位置

表 2 入力の統計量

指標	平均	最小	最大
L_∞（8 bit 画素値）	32.00	32.00	32.00
RMS 画素差	0.0524	0.0481	0.0539
PSNR [dB]	25.61	25.37	26.36
入力系列長	255.34	33	345
画像トークン数	234.34	12	324

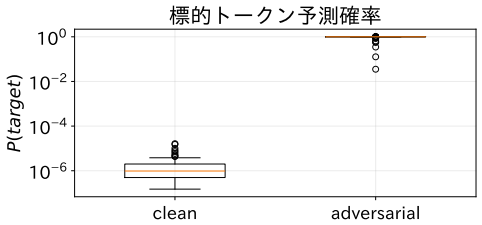


図 1 最終層における標的トークン `cat` の予測確率の分布．

4.2 標的トークンへの誘導結果

100 枚中 98 枚で最初の生成トークンが `cat` となり，次トークンを標的とする攻撃の成功率は 98%であった．残る 2 枚の top-1 token は `Here` と `I` であり，それぞれの `cat` の順位は 4 位と 3 位，確率は 0.0353 と 0.1266 であった．図 1 に最終層での標的トークン確率の分布を示す．

表 3 に標的トークンの最終予測を示す．clean run では `cat` の平均確率は 1.83×10^{-6}，順位中央値は 2949 位であり，top-1 となった画像は 0 枚であった．adversarial run では平均確率 0.9586，中央値 0.99996，順位中央値 1 位であった．標的 logit の adversarial-clean 差は平均 14.77，中央値 15.41 であった．

4.3 視覚エンコーダの表現

図 2 に，各 vision block および merger 出力の clean/adversarial 表現を比較した結果を示す．block 0 の平均コサイン類似度は 0.943，相対 L_2 距離は 0.386 であっ

© 2026 Information Processing Society of Japan

表 3　最終層における標的トークン cat の予測

指標	clean	adversarial
次トークン top-1 率	0%	98%
平均 $P(\text{cat})$	1.83×10^{-6}	0.9586
中央値 $P(\text{cat})$	9.70×10^{-7}	0.99996
順位中央値	2949	1
平均標的 logit	12.80	27.57

た．block 8 のコサイン類似度は 0.879，block 12 では 0.803 であり，block 16 の相対 L_2 距離は 0.650 であった．

block 17 以降では平均コサイン類似度が 0.98 以上となる stage が多く，block 31 では 0.9998 であった．一方，merger 出力では平均コサイン類似度 0.707，相対 L_2 距離 0.695 であった．merger 出力の平均値は，言語デコーダ入力の画像トークン平均に対して計算した stage 0 の値と一致した．

4.4　残差ストリームにおける表現差

図 3 に言語デコーダの残差ストリームを示す．decoder 入力の stage 0 では，画像トークン平均のコサイン類似度は 0.707，生成位置のコサイン類似度は 1.000 であった．生成位置の類似度は stage 8 で 0.933，stage 12 で 0.882，stage 24 で 0.862，stage 28 で 0.780，stage 30 で 0.725 となった．最終正規化後の stage 36 では 0.648 であった．

画像トークン平均の類似度は stage 0 の 0.707 から，stage 28 で 0.881，stage 30 で 0.911，stage 34 で 0.940，stage 35 で 0.942 となった．生成位置の相対 L_2 距離は stage 0 の 0 から，stage 8 で 0.347，stage 24 で 0.503，stage 30 で 0.689 となり，最終正規化後には 0.793 であった．

4.5　logit lens による標的トークンの読み出し

図 4 に logit lens の結果を示す．adversarial run の標的確率は stage 30 で平均 1.46×10^{-6}，stage 31 で 1.22×10^{-5}，stage 32 で 2.99×10^{-4}，stage 33 で 0.0167，stage 34 で 0.645，stage 35 で 0.721，最終 stage 36 で 0.959 であった．標的が top-1 となる割合は stage 30–32 で 0%，stage 33 で 17%，stage 34 で 91%，stage 35 で 96%，stage 36 で 98% であった．

clean との差を標的 logit で比較すると，平均 $\Delta z(\text{cat})$ は stage 27 で -0.823, stage 28 で -0.532, stage 29 で -0.266 であった．stage 30 では+1.58，stage 31 では+2.93，stage 32 では+5.36，stage 33 では+8.23，stage 34 では+15.24 となった．stage 35 では+11.81，最終 stage 36 では+14.77 であった．後段 stage の数値を表 4 に示す．

4.6　activation patching による介入結果

図 5 に，各 decoder layer の画像トークン activation を clean 側へ置換した場合の正規化回復率を示す．平均 R_l は layer 0 で 0.999，layer 10 で 0.970，layer 20 で 0.914，layer 24 で 0.815，layer 27 で 0.711 であった．後段では layer 30 で 0.614，layer 31 で 0.461，layer 32 で 0.252，layer 33 で 0.0185，layer 34 で 0.0127，layer 35 で 0 となった．

表 4　decoder 後段における logit lens の標的予測

stage	平均 $P(\text{cat})$	top-1 率	平均 $\Delta z(\text{cat})$
30	1.46×10^{-6}	0%	1.58
31	1.22×10^{-5}	0%	2.93
32	2.99×10^{-4}	0%	5.36
33	0.0167	17%	8.23
34	0.645	91%	15.24
35	0.721	96%	11.81
36	0.959	98%	14.77

patch 後に cat が top-1 であった割合は，layer 0–27 で 0%，layer 28–30 で 1%，layer 31 で 41%，layer 32 で 87%，layer 33–35 で 98%であった．patch 後の標的確率の平均は layer 30 で 0.0134，layer 31 で 0.244，layer 32 で 0.760，layer 33 で 0.950，layer 35 で 0.959 であった．

5.　考察

5.1　攻撃の有効性

本実験では，敵対的画像 100 枚中 98 枚で最初の生成トークンを cat へ誘導した．clean での標的順位中央値が 2949 位であったのに対し，adversarial では 1 位となり，標的確率の中央値も 9.70×10^{-7} から 0.99996 へ変化した．したがって，成功した多くの画像では候補間の小さな順位反転ではなく，最終語彙分布が標的トークンへ強く集中する状態が形成されていると考えられる．

5.2　視覚経路における表現差

視覚エンコーダでは block 0 から clean/adversarial 間の差が存在し，merger 出力ではコサイン類似度 0.707，相対 L_2 距離 0.695 となった．decoder 入力の画像トークン平均でも同一の値が得られているため，merger 出力が言語デコーダ入力の画像トークン表現として保持されていることと整合する．この結果は，標的予測に至る変化の起点がデコーダ内部だけではなく，デコーダへ入力される視覚表現の段階に存在することを示す．

vision block 17 以降ではトークン平均のコサイン類似度が高い一方，merger で再び大きな差が観測されたため，視覚経路の差は層深度に対して単調ではない．Qwen2.5-VL において，merger は複数の視覚トークンを集約し，学習済みの非線形射影を介してデコーダに入力される視覚表現へ変換する構造である．したがって，視覚エンコーダ内部では平均化により顕在化しなかった敵対的な特徴差が，merger による局所特徴の結合や表現空間への射影を通じて強く表れた可能性がある．あるいは，ViT 内部で大きな差を生じさせる方向ではなく，merger を介してデコーダの予測に強く作用する方向へ摂動が形成された可能性も考えられる．

© 2026 Information Processing Society of Japan

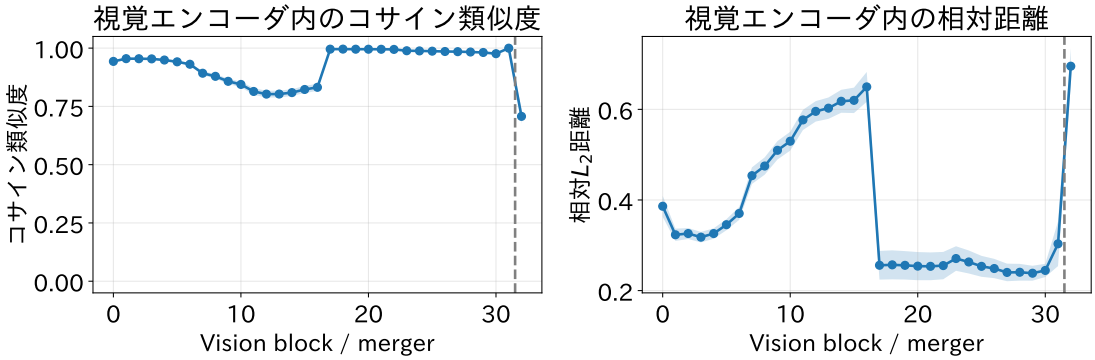


図 2 視覚エンコーダの層別比較．各 vision block と merger における clean/adversarial の平均表現について，コサイン類似度（左）と相対 L_2 距離（右）を示す．破線は merger，帯は 95%信頼区間である．

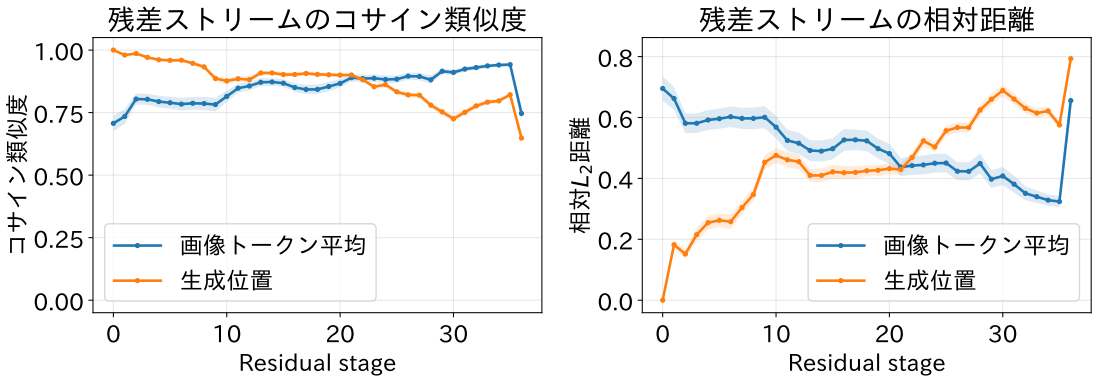


図 3 残差ストリームの層別比較．画像トークン平均と生成位置について，clean/adversarial のコサイン類似度（左）と相対 L_2 距離（右）を示す．

5.3 画像位置から生成位置への情報伝播

residual stage 0 では画像トークン平均のコサイン類似度が 0.707 である一方，生成位置では 1.000 であった．clean/adversarial で画像以外の入力を固定しているため，デコーダ入口では敵対的な差が画像位置に局在している．その後，生成位置の類似度は層を進むにつれて低下し，stage 30 で 0.725，最終正規化後で 0.648 となった．これは，画像位置に存在していた表現差が Transformer の層計算を通じて生成位置の残差ストリームへ取り込まれたことと整合する．

画像トークン平均の類似度が後段で 0.94 付近まで上昇する一方，生成位置には大きな差が残る．この対照は，攻撃に関係する情報が画像位置だけに保持されず，他位置へ取り込まれて利用されることを示唆する．

5.4 Decoder 後段における標的語彙方向の形成

生成位置の表現差は中盤以前から観測されるが，logit lens で読み出した `cat` 確率は stage 30 までほぼ増加していない．stage 31 から 34 にかけて平均標的 logit 差が+2.93, +5.36, +8.23, +15.24 と急増し，top-1 率も stage 33 の 17%から stage 34 の 91%へ変化した．したがって，生成位置に敵対的な差が到達することと，その差が特定の語彙として読み出せることは同じ時点ではない．

この層方向のずれは，中盤までに生じた生成位置の表現差が，後段で LM head の `cat` 方向へ強く射影される表現へ変換される過程を示唆する．logit lens による stage 32 の平均 $P(\text{cat})$ が 2.99×10^{-4} であるのに対し最終値は 0.959 であり，標的語彙の順位が高くなる位置は最終数層に集中している．

5.5 residual stream と activation patching の対応

activation patching では layer 0 の平均回復率が 0.999，layer 20 でも 0.914 である一方，layer 31, 32, 33 では 0.461, 0.252, 0.0185 へ低下した．patch 後の `cat` top-1 率も同じ 3 層で 41%，87%，98%へ増加するため，後段では画像位置だけを clean へ戻しても攻撃予測を取り除けなくなる．

これは，早い layer の patch は後続する位置間伝播に影響するのに対し，遅い layer ではそれ以前に生成位置や他位置へ取り込まれた情報が残るためであると考えられる．したがって，回復率の急減は画像位置のみの修復が有効

© 2026 Information Processing Society of Japan

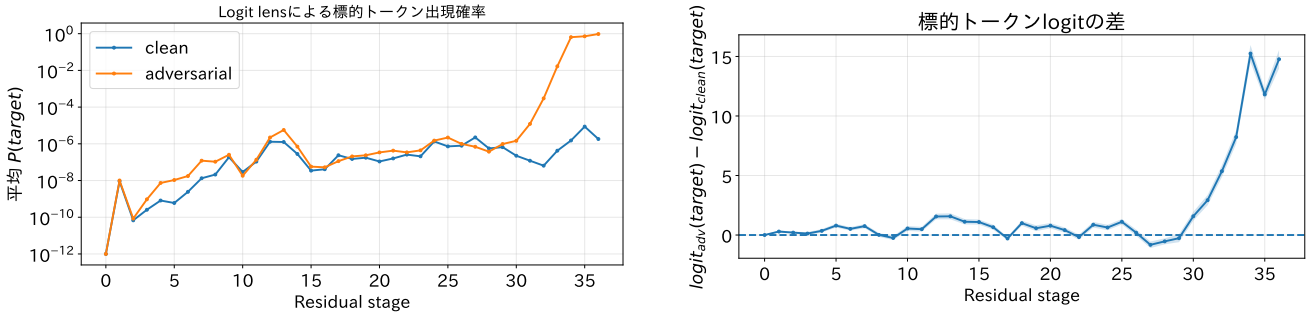


図 4 Logit lens の結果．左は生成位置から読み出した標的トークン確率，右は標的 logit の adversarial-clean 差を示す．

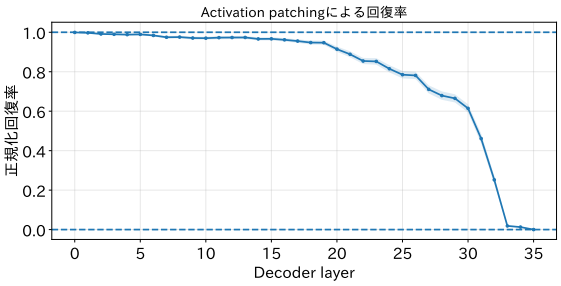


図 5 Activation patching の結果．adversarial run の各 decoder layer 出力において，画像トークン位置を clean activation へ置換したときの正規化回復率を示す．

でなくなる時点を表す．logit lens で標的 logit が急増する stage 31–34 と，activation patching で回復率が急減する layer 31–33 は近接していることから，この層域では画像由来の敵対的情報が生成位置に保持されるだけでなく，最終的な標的語彙予測へ利用可能な状態へ移行していると考えられる．

5.6 攻撃機構の考察

以上から，攻撃過程は，視覚経路での表現差の形成，画像位置から生成位置への伝播，decoder 後段での標的語彙 logit の上昇という三段階として整理できる．この結果は，視覚側で形成された攻撃依存の特徴がマルチモーダル生成計算を通じて統合され，後段で語彙予測に適した方向へ変換されることを示す．

5.7 防御手法の検討

タイポグラフィ型 VPI では，OCR による文字抽出や画像中の命令文の検査が防御候補となる．しかし，敵対的摂動型 VPI では可読な命令文ではなく画素摂動によって内部表現が変化するため，文字列検出のような表層特徴の検査だけでは攻撃経路を捉えられない．

これに対し，本研究の実験により，merger 出力，生成位置の residual stream，後段の標的 logit という複数の内部信号において段階的な変化が観測された．すなわち，視覚 merger での表現逸脱，生成位置への影響，decoder 後段の logit 増幅は，それぞれ異なる段階の検出信号となり得る．例えば，通常の画像に対する内部表現の統計を基準として merger 出力の逸脱を検査し，その後に生成位置の表現変化や特定語彙への急激な logit 集中を確認する等の多段の監視が考えられる．

介入箇所という観点においては，layer 30 以前の patching で高い回復率が得られたことから，敵対的情報が生成位置へ十分に取り込まれる前の処理が候補となる．視覚と言語の境界表現の正規化，画像トークンの過大な寄与を抑える処理，後段 logit の監視を組み合わせることで，画素レベルの検査だけに依存しない防御設計を検討できる．

6. まとめ

本稿では，敵対的摂動による VPI が VLM 内部でどのように標的トークン予測へ至るかを分析するため，視覚エンコーダの層別表現比較，残差ストリーム解析，logit lens，activation patching を組み合わせた．

オープンウェイト VLM に対し，単一標的トークン `cat` のみを最適化した 100 枚の敵対的画像を評価した結果，98 枚で最初の生成トークンを `cat` へ誘導した．また，clean では低かった標的確率と順位が adversarial では大きく変化し，単一トークンを対象とする次トークン誘導が高い割合で成立した．

内部状態では，視覚 merger で通常画像と敵対的画像の表現差が観測され，言語デコーダを進むにつれてその差が画像位置から生成位置へ伝播した．一方，logit lens で標的トークンが強く読み出されるのは decoder 後段であり，activation patching でも同じ層域を境に画像トークンの clean 置換による回復効果が失われた．これらの結果は，敵対的摂動による表現差の形成，生成位置への伝播，標的語彙 logit の増加を区別して捉えることが攻撃機構の理解ならびに防御手法の検討を行う上で有効であることを示している．

今後の課題として，視覚エンコーダ内部における表現差の空間的分布の分析，画像トークンに加えて生成位置およ

© 2026 Information Processing Society of Japan

び全トークンを対象とした patching や，attention head および MLP 単位の介入を decoder 後段へ適用し，視覚情報から標的語彙へ至る計算経路をより細粒度に同定することを検討する．また，異なる標的トークン，複数トークン系列，モデル規模およびプロンプト条件で同様の内部遷移が現れるかを比較する．さらに，攻撃条件が変化しても共通して現れる内部指標を抽出し，特定の脅威シナリオに依存しない敵対的摂動型 VPI の検出・緩和手法を検討する．

謝辞　本研究の一部は JSPS 科研費 JP24KJ2132 の助成を受けたものです．

参考文献

[1] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, “Attention Is All You Need,” Advances in Neural Information Processing Systems 30, 2017.

[2] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby, “An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale,” Proc. ICLR, 2021.

[3] S. Bai, K. Chen, X. Liu, J. Wang, W. Ge, S. Song, K. Dang, P. Wang, S. Wang, J. Tang, et al., “Qwen2.5-VL Technical Report,” arXiv:2502.13923, 2025.

[4] F. Perez and I. Ribeiro, “Ignore Previous Prompt: Attack Techniques for Language Models,” NeurIPS ML Safety Workshop, 2022.

[5] Y. Gong, D. Ran, J. Liu, C. Wang, T. Cong, A. Wang, S. Duan, and X. Wang, “FigStep: Jailbreaking Large Vision-Language Models via Typographic Visual Prompts,” Proc. AAAI, Vol. 39, No. 22, pp. 23951–23959, 2025.

[6] J. Geng, T. T. Tran, P. Nakov, and I. Gurevych, “Con Instruction: Universal Jailbreaking of Multimodal Large Language Models via Non-Textual Modalities,” Proc. ACL 2025, pp. 2917–2933, 2025.

[7] 熊谷 瞭，竹本 修，野崎 佑典，吉川 雅弥，「敵対的摂動を用いたビジュアルプロンプトインジェクションによる出力の誘導」，2026 年暗号と情報セキュリティシンポジウム（SCIS 2026），2026.

[8] A. Madry, A. Makelov, L. Schmidt, D. Tsipras, and A. Vladu, “Towards Deep Learning Models Resistant to Adversarial Attacks,” Proc. ICLR, 2018.

[9] N. Elhage, N. Nanda, C. Olsson, T. Henighan, N. Joseph, B. Mann, A. Askell, Y. Bai, A. Chen, T. Conerly, et al., “A Mathematical Framework for Transformer Circuits,” Transformer Circuits Thread, 2021.

[10] N. Belrose, Z. Furman, L. Smith, D. Halawi, I. Ostrovsky, L. McKinney, S. Biderman, and J. Steinhardt, “Eliciting Latent Predictions from Transformers with the Tuned Lens,” arXiv:2303.08112, 2023.

[11] K. Meng, D. Bau, A. Andonian, and Y. Belinkov, “Locating and Editing Factual Associations in GPT,” Advances in Neural Information Processing Systems 35, pp. 17359–17372, 2022.

[12] F. Zhang and N. Nanda, “Towards Best Practices of Activation Patching in Language Models: Metrics and Methods,” arXiv:2309.16042, 2023.

© 2026 Information Processing Society of Japan