選択的に開示可能な生成 AI 向けウォーターマーク

藤田 祐輝[1,2,a)]　原 啓祐[3,2,b)]

概要：本研究では生成 AI に対する選択的に開示可能な暗号学的ウォーターマークを提案する。近年の機械学習の発展に伴い、ディープフェイクの作成など生成 AI の悪用も発生しており、AI が作成したデータと人間が作成したデータを見分ける必要性が生じている。この問題に対し、AI がコンテンツを生成する際にデジタル署名を応用したウォーターマークを埋め込むアプローチが提案されている。しかし、誰でも検証可能なウォーターマークは、悪意を持つユーザが AI を用いてコンテンツを作成する過程で除去される危険性が高い。そこで、本稿では指定したパーティにだけ検証権限を与えるウォーターマークの理論的構成と安全性を議論する。

キーワード：暗号理論, ウォーターマーク, デジタル署名, ステガノグラフィ, AI セキュリティ

Cryptographic Watermarks for Generative AI with Selective Disclosability

Yuuki Fujita[1,2,a)]　Keisuke Hara[3,2,b)]

Abstract: This study proposes cryptographic watermarks for generative AI with selective disclosability. With the advancement of machine learning, the misuse of generative AI, such as deepfakes, has emerged, creating a need to distinguish between AI-generated and human-generated data. To tackle this problem, several papers proposed the way to embed watermarks during the content generation process. However, watermarks that are publicly verifiable carry a high risk of being removed by malicious users. Therefore, this study discusses the theoretical construction and security properties of watermarks that can be verified by only designated parties.

Keywords: Cryptography, Watermark, Digital Signature, Steganography, AI Security

1. はじめに

1.1 背景

生成 AI の発展に伴い、コンテンツが AI によって生成されたか人間の手で作られたかを判別する必要が生じている。AI によって生成されたことを告げず、本当の音声・写真・映像に見せかけたものはディープフェイクと呼ばれ、いたずらや詐

[1] 京都大学
Kyoto University
[2] 国立研究開発法人産業技術総合研究所
National Institute of Advanced Industrial Science and Technology
[3] 大阪大学
The University of Osaka
[a)] fujita.yuki.67f@st.kyoto-u.ac.jp
[b)] hara-keisuke@ist.osaka-u.ac.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

欺などを目的に用いられるが、AI によって生成されていることが分かれば混乱や金銭的被害を防ぐことができる。また、AI が生成したコンテンツそのままでは著作権を認めないとする法解釈を採用する国が多い為、著作権の有無という議論でも AI によって生成されたかが焦点となっている。また、AI の使用を禁止するレポートやコンテスト等において、ルール違反が無いかを調べる必要がある。

このような要請に基づき、コンテンツが AI によって生成されたかを判別するため、AI が作ったコンテンツにウォーターマークを埋め込むというアプローチを採用するサービスもある。Google は SynthID と呼ばれる独自のウォーターマーク技術を開発し、当初は画像生成サービス Imagen で [1]、のちに Gemini でも採用を公表している [2]。また、Anthropic 社も Claude で生成したテキストにウォーターマークを採用することを公表した [3]。

現在主流のウォーターマークはヒューリスティクスを用いたものであるが、暗号学的に除去や検出の困難さを保証するウォーターマークの構成も先行研究で示されている。Christ ら [4] は共通鍵方式のウォーターマークの構成を示し、Fairoze ら [5] は公開鍵による検証が可能なウォーターマークを提案している。更に Lin ら [6] は安全性を強化したウォーターマークの構成を示した。これらの方式では、主に堅牢性、健全性または偽造不可能性、検出不可能性という三つの安全性を考慮している。堅牢性は、生成されたコンテンツにある程度変更が加わっていても、ウォーターマークを検出できるという性質である。健全性または偽造不可能性は、対応する秘密鍵無しでは有効なウォーターマークを埋め込めないことである。検出不可能性は、対応する鍵無しではウォーターマークが埋め込んであるのかわからないことである。

1.2 動機

本研究では、既存方式の安全性では不十分なシナリオとして、裁判の証拠としてディープフェイクが提出されるという場合を考える。まず、悪意のある原告が生成 AI を用いて無罪の被告が建物内に侵入する監視カメラの映像を生成し、これを証拠として裁判所に提出して告訴する。当然ながら被告は証拠が捏造されていたものだと主張する。裁判所は、AI サービスの提供者に協力を要請しつつ、この証拠が本物であるかを判定しなければならない。

このシナリオにおいて、既存のウォーターマークは次のような弱点を持つ。共通鍵方式のウォーターマークでは、AI サービスの運営者しかディープフェイクであることを判定できず、そのことを裁判所に証明することができない。公開鍵方式のウォーターマークでは、ウォーターマークが埋め込まれていることが悪意のある原告にも判別できる為、裁判所に証拠を提出する前に、ウォーターマークを検出できなくなるまでコンテンツを修正できてしまう。当然、暗号学的な安全性を持たないウォーターマークは、除去も容易であり、本物の映像を AI 生成と判定してしまう可能性もあるので、裁判の証拠としては不十分である。

1.3 本研究の貢献

そこで本研究では選択的に開示可能なウォーターマークを提案する。提案方式は、ロバスト署名 [6]、ステガノグラフィ [7]、コミットメント、非対話ゼロ知識証明という暗号プリミティブを用いて構成される。この方式は、通常時は共通鍵方式のような性質を持つが、個別のコンテンツに対して検証権限を発行することができ、発行した情報を用いてウォーターマークの有無を検証できる。裁判所がディープフェイクであるかを判別する必要に迫られた場合、AI サービスの提供者は裁判所に協力を要請されてから検証権限を発行することで、悪意ある原告がディープフェイクを提出する前に検証権限を与えることなく、更にウォーターマークの有無を第三者に開示することも可能となる。

本稿で提案する選択的に開示可能なウォーターマークでは、堅牢性、偽造不可能性、選択的検出不可能性に加え、不正な検証権限の発行による偽陽性を防ぐことを保証する。本稿で提案する方式では、検証権限の発行というステップを挟む為、ウォーターマークを埋め込んでいないコンテンツに対し、不正な方法で検証権限を発行し、ウォーターマークを検出させるという攻撃を考慮する必要がある。この攻撃は、裁判所に証拠として提出された監視カメラの映像が本物であるが、被告がこれをディープフェイクであると主張し、被告と結託した AI サービス提供者が裁判所に偽の情

© 2026 Information Processing Society of Japan

報を与え、ウォーターマークを検出させて捏造されたものだと認めさせるというシナリオに相当する。

本研究で提案するウォーターマークは、裁判の証拠としてディープフェイクが用いられるシナリオに加え、禁止されている AI の使用の検出、著作権の帰属の決定というシナリオにも適用することができる。AI の使用を禁止するレポートやコンテストなどにおいて AI を使う者は、AI 使用の証拠を消そうとするかも知れないが、開示されていないコンテンツに対するウォーターマークの有無が判別できないので、AI 使用の痕跡を消すことが困難になっている。また、AI 生成したコンテンツを殆どそのまま使用して著作権を主張する場合も、本人の創作性を反映させず、機械的な処理とチェックだけでウォーターマークだけを消すのが難しくなっている。

2. 準備

本節では表記と用いる暗号プリミティブについて整理する。本稿では紙面の都合で証明を省略する為、帰着先となる暗号プリミティブの安全性定義も省略する。

確率的多項式時間を PPT と表す。セキュリティパラメタを λ と表す。$negl(\lambda)$ を λ における無視可能な関数とする。PPT アルゴリズム $\mathcal{A}$ に対し、入力 x とランダムテープ r が与えられたときの出力を $\mathcal{A}(x;r)$ と表す。ビット列 ζ に対して、i 番目のビットを $\zeta[i]$、j 番目から k 番目までのビットを切り出して得られるビット列を $\zeta[j:k]$ と表す。関数 $Blocks_n$ を、与えられたビットをそれぞれ n ビット毎のセグメントに分割する関数とする。

2.1 言語モデル

先行研究 [4], [6], [7] に従い、言語モデルを以下のように定式化する。

Definition 1 (言語モデル)**.** 言語モデル $Q : \{0,1\}^* \to [0,1]$ はビット列 $(x_1, \ldots, x_t)$ を受け取り、次のビットが 1 である確率を出力する。

プロンプト $x \in \{0,1\}^*$ が与えられたとき、x で初期化された自己回帰サンプリングによって応答 $u \leftarrow \overline{Q}(x)$ が得られる。ここで、$u[i] \leftarrow Q(x, u[1:i-1])$ である。自然数 $n \in N$ に対して、次の n ビットを自己回帰的にサンプリングすることによって得られる分布を $\overline{Q}_n(x)$ と書く。

2.2 ロバスト署名

本稿の構成では、[6] で提案されたロバスト署名を使用する。ロバスト署名は、メッセージがある程度変更された場合であっても、そのメッセージに対して有効となる署名である。

Definition 2 (ロバスト署名)**.** ロバスト署名 Σ は、以下の四つのアルゴリズムから構成される。

- $\mathsf{KeyGen}(1^\lambda) \to (\mathsf{vk}, \mathsf{sk})$*:* セキュリティパラメタ 1^λ を入力として、検証鍵と署名鍵の組 $(\mathsf{vk}, \mathsf{sk})$ を出力する。
- $\mathsf{Sign}(\mathsf{sk}, \mathsf{m}) \to \sigma$*:* 署名鍵 sk、メッセージ m を入力として、署名 σ を出力する。
- $\mathsf{Ver}(\zeta, \sigma) \to 1/0$*:* メッセージ ζ、および署名 σ を入力として、1（受理）または 0（拒否）を出力する。

ロバスト署名 SIG は、堅牢性と強偽造不可能性の二つの性質を満たす必要がある。

2.3 ブロックステガノグラフィ

Definition 3 (ブロックステガノグラフィ)**.** ブロックステガノグラフィ方式 STG は、以下の三つのアルゴリズムから構成される。

- $\mathsf{Gen} \to (\mathsf{ek}, \mathsf{dk})$:
  セキュリティパラメタ λ を入力として、鍵ペア $(\mathsf{ek}, \mathsf{dk})$ を出力する。STG が対称鍵方式である場合、$\mathsf{vk} = \mathsf{sk}$ となる。
- $\mathsf{Emb}(\mathsf{ek}, \mathsf{m}, \pi) \to y$:
  埋め込み鍵 ek、文脈 $\pi \in \{0,1\}^*$、およびメッセージ $\mathsf{m} \in \{0,1\}^k$ を入力として、ブロック $y \in \{0,1\}^n$ を出力する。
- $\mathsf{Dec}(\mathsf{dk}, \zeta) \to \pi$:
  デコード鍵 vk とテキスト $\zeta \in \{0,1\}^n$ を入力として、復号されたメッセージまたは失敗記号 $\mathsf{m} \in \{0,1\}^k \cup \{\perp\}$ を出力する。

ブロックステガノグラフィ方式 STG は、検知不可能性とブロック堅牢性の二つの性質を満たす必要がある。

ステガノグラフィ方式の堅牢性について議論するため、近接述語 $\Phi : \{0,1\}^* \times \{0,1\}^* \to \{0,1\}$ を導入する。これは二つのデータが互いに近いとはどういうことかを定義している。近接述語 Φ の実際の内容は、ブロックステガノグラフィ方式の具体的な構成に依存する。

© 2026 Information Processing Society of Japan

2.4 非対話ゼロ知識証明

Definition 4 (非対話ゼロ知識証明)**.** ステートメント x と証拠 w の間の多項式時間で識別可能な関係 $\mathcal{R}$、および x を受理する NP 言語 $\mathcal{L}$ に対して、非対話ゼロ知識証明 NIZK は以下の三つのアルゴリズムから構成される：

$\mathsf{Setup}(1^\lambda) \to \mathsf{crs}$*:* セキュリティパラメタ 1^λ を入力として、共通参照文字列 crs を出力する。

$\mathsf{Prove}(\mathsf{crs}, x, w) \to \pi$*:* 共通参照文字列 crs、ステートメント x、および証拠 w を入力として、証明 π を出力する。

$\mathsf{Ver}(\mathsf{crs}, x, \pi) \to \{0,1\}$*:* 共通参照文字列 crs、ステートメント x、および証明 π を入力として、1（受理）または 0（棄却)）を出力する。

非対話ゼロ知識証明 NIZK は完全性、ゼロ知識性、健全性、知識健全性の四つの安全性を満たす必要がある。

2.5 コミットメント

Definition 5. コミットメント方式 COM は、以下のアルゴリズムから構成される。

$\mathsf{Commit}(\mathsf{m}; r) \to com$*:* メッセージ m と乱数 r を入力として、コミットメント com を出力する。

コミットメント方式 COM は、秘匿性と拘束性の二つの性質を満たす必要がある。

3. 選択的開示可能性を備えたウォーターマーク

本節では、選択的開示可能性を備えたウォーターマークのシンタクスと安全性定義について議論する。

Definition 6 (選択的開示可能性を備えたウォーターマーク)**.** 選択的開示可能性を備えたウォーターマークは、以下の五つのアルゴリズムから構成される。

$\mathsf{Setup}(1^\lambda) \to \mathsf{pp}$: セキュリティパラメタ λ を入力として、公開パラメタ pp を出力する。以降 pp は暗黙に全てのアルゴリズムに与えられるものとする。

$\mathsf{KeyGen}(1^\lambda) \to (\mathsf{pk}, \mathsf{sk})$: セキュリティパラメタ λ を入力として、鍵ペア $(\mathsf{pk}, \mathsf{sk})$ を出力する。

$\mathsf{Wat}(\mathsf{sk}, x) \to y$: 秘密鍵 sk とプロンプト x を入力として、応答 y を出力する。

$\mathsf{Disclose}(\mathsf{sk}, \mathsf{pk}, y) \to \alpha$: 秘密鍵 sk、公開鍵 pk、および y を入力として、ビット列 α を出力する。

$\mathsf{Ver}(\mathsf{pk}, \alpha, \zeta) \to 0/1$: 公開鍵 pk、ビット列 α、およびテキスト ζ を入力として、0（拒否）または 1（受理）を出力する。

3.1 堅牢性

まず、ウォーターマーク方式は堅牢であること、すなわち、ウォーターマーク入りのコンテンツが元のものからある程度変更されていたとしても、指定された検証者がウォーターマークを検出できることが求められる。定義において堅牢性は、近接述語 Φ が 1 を出力する限り、改変されたコンテンツからウォーターマークが検出されることを要求している。これは、ユーザーが創意工夫を加えることなく AI によって生成されたコンテンツをわずかに修正できること、およびそのようなコンテンツからウォーターマークが検出されるべきであることを捉えている。

ウォーターマーク方式の堅牢性について議論するため、まず先行研究 [6] に従い、ブロック近接 EBC という概念を導入する。

Definition 7. 二つのビット列 ζ^* と y、および近接述語 $\Phi : \{0,1\}^* \times \{0,1\}^* \to \{0,1\}$ が与えられたとき、$\mathsf{EBC}[\Phi, n](\zeta^*, y)$ は ζ^* と y を $(\zeta_1^*, \ldots, \zeta_r^*) = Blocks_n(\zeta^*)$ および $(y_1, \ldots, y_{\lceil |y|/n \rceil}) = Blocks_n(y)$ にパースし、$(\exists r \in \mathbb{N}, |\zeta^*| = rn) \wedge (\exists t \in \mathbb{N}, \forall j \in [r], \Phi(\zeta_j^*, y_{t+j-1}) = 1)$ であれば 1 を出力し、そうでなければ 0 を出力する。

Definition 8 (堅牢性)**.** ウォーターマーク方式 Π が $(\mathsf{EBC}[\Phi, n], kn)$-堅牢性を満たすとは、任意の PPT アルゴリズム $\mathcal{A}$ に対して、$\mathsf{Adv}^{\mathsf{Rob}}_{\Pi,\mathcal{A}}(\lambda) := \Pr[\mathsf{Game}^{(\mathsf{EBC}[\Phi,n],kn)-\mathsf{Rob}}_{\Pi,\mathcal{A}}(\lambda) = 1] \leq negl(\lambda)$ が成り立つことである。ここで $\mathsf{Game}^{(\mathsf{EBC}[\Phi,n],kn)-\mathsf{Rob}}_{\Pi,\mathcal{A}}(\lambda)$ は以下のように定義される：

© 2026 Information Processing Society of Japan

$\mathsf{Game}^{(\mathsf{EBC}[\Phi,n],kn)-\mathsf{Rob}}_{\Pi,\mathcal{A}}(\lambda)$

$\mathsf{pp} \leftarrow \mathsf{Setup}(1^\lambda)$
$(\mathsf{sk},\mathsf{pk}) \leftarrow \mathsf{KeyGen}(1^\lambda)$
$\mathcal{A}^{\mathsf{Wat}_{\mathsf{sk}}(\cdot),\mathsf{Disclose}_{\mathsf{sk},\mathsf{pk}}(\cdot)}(\mathsf{pp},\mathsf{pk}) \to \zeta$
$\mathsf{Disclose}(\mathsf{pp},\mathsf{sk},\mathsf{pk},\zeta) \to \alpha$
Output 1 if $\exists y \in \mathsf{L}_{\mathrm{wat}}, \exists \zeta^* \subset \zeta,$
$\zeta^* = |kn| \wedge \mathsf{EBC}[\Phi,n](\zeta^*,y) = 1$
$\wedge\, \mathsf{Ver}(\mathsf{pp},\mathsf{pk},\zeta,\alpha) = 0$
else Output 0

上記のゲームで利用可能なオラクルは以下のように定義される。透かし埋め込みオラクル $\mathsf{Wat}_{\mathsf{sk}}(\cdot)$ はプロンプト x を受け取り、$y \leftarrow \mathsf{Wat}(\mathsf{sk},x)$ を返し、リストを $\mathsf{L}_{\mathrm{sig}} := \mathsf{L}_{\mathrm{sig}} \cup \{x\}$ と更新する。開示オラクル $\mathsf{Disclose}_{\mathsf{sk},\mathsf{pk}}(\cdot)$ はまずビット列 ζ を受け取り、$\mathsf{EBC}[\Phi,n](y,\zeta)$ となる $y \in \mathsf{L}_{\mathrm{sig}}$ が存在する場合、$\alpha \leftarrow \mathsf{Disclose}(\mathsf{sk},\mathsf{pk},\zeta)$ を返し、$\mathsf{L}_{\mathrm{dis}} := \mathsf{L}_{\mathrm{dis}} \cup \{x\}$ を更新し、それ以外の場合は $\perp$ を出力する。

3.2 偽造不可能性

ウォーターマーク方式においては、コンテンツ作成者が意図したかどうかにかかわらず、AI によって作成されていないコンテンツがウォーターマーク入りとして検知されてはならない。このことをウォーターマークにとっての偽造不可能性として定式化する。偽造不可能性はロバスト署名の場合と同様に、秘密鍵がなければ、観測した AI 生成コンテンツから大きく離れたウォーターマーク入りコンテンツを作成できないことを意味する。この安全性は現実のシナリオにおける以下の二つのケースを防ぐことを目的としている。第一に、善意の人間によって生成されたコンテンツが、偶然誤ってウォーターマーク入りコンテンツとして検出されることである。第二に、悪意のあるユーザが有害なコンテンツを作成し、これを生成 AI が作成したと偽証して、AI サービス提供者の評判を毀損することである。どちらのケースにおいても、ユーザーは生成 AI とやり取りを行い、ウォーターマークを埋め込んだコンテンツを得られる為、ゲーム中の攻撃者は透かし埋め込みオラクルを利用できるようになっている。さらに、指定された検証者であっても透かし入りコンテンツを作成できないようにするため、ゲームは攻撃者に開示オラクルも与えている。

Definition 9 (偽造不可能性)**.** ウォーターマーク方式 Π が偽造不可能性を満たすとは、任意の PPT アルゴリズム $\mathcal{A}$ に対して、$\mathsf{Adv}^{\mathsf{Unf}}_{\Pi,\mathcal{A}}(\lambda) := \Pr[\mathsf{Game}^{\mathsf{Unf}}_{\Pi,\mathcal{A}}(\lambda) = 1] \leq negl(\lambda)$ が成り立つことである。ここで $\mathsf{Game}^{\mathsf{Unf}}_{\Pi,\mathcal{A}}(\lambda)$ は以下のように定義される：

$\mathsf{Game}^{\mathsf{Unf}}_{\Pi,\mathcal{A}}(\lambda)$

$\mathsf{pp} \leftarrow \mathsf{Setup}(1^\lambda)$
$(\mathsf{sk},\mathsf{pk}) \leftarrow \mathsf{KeyGen}(1^\lambda);$
$\mathcal{A}^{\mathsf{Wat}_{\mathsf{sk}}(\cdot),\mathsf{Disclose}_{\mathsf{sk},\mathsf{pk}}(\cdot)}(\mathsf{pp},\mathsf{pk}) \to \zeta$
$\mathsf{Disclose}(\mathsf{pk},\mathsf{sk},\zeta) \to \alpha$
Output 1 if $\mathsf{Ver}(\mathsf{pk},\zeta,\alpha) = 1$
$\wedge(\forall y \in \mathsf{L}_{\mathrm{wat}}, \forall \zeta^* \in \zeta,$
$\Phi(\zeta^*,y) = 0 \vee |\zeta^*| \neq n)$
else Output 0

3.3 検知不可能性

次に、検証のための情報を提供された検証者を除き、コンテンツ中のウォーターマークの有無を区別できてはならない。これを非権限者に対する検知不可能性として定式化する。この性質の定義では、多項式個の AI 生成コンテンツが与えられたとき、どのような PPT 攻撃者もそれらに透かしが入っているかどうかを区別できないことを要求する。これは、AI 生成コンテンツからウォーターマークを除去しようとするユーザが、改変したコンテンツからウォーターマークが検出されるかを確認しようとするシナリオを捉えている。

Definition 10 (非権限者に対する検知不可能性 (Undetectability for Unauthorized Users))**.** ウォーターマーク方式 Π が非権限者に対する検知不可能性を満たすとは、任意の PPT アルゴリズム $\mathcal{A}$ に対して、$\mathsf{Adv}^{\mathsf{Und}}_{\Pi,\mathcal{A}}(\lambda) := |\Pr[\mathsf{Game}^{\mathsf{Und}}_{\Pi,\mathcal{A}}(\lambda) = 1] - \frac{1}{2}| \leq negl(\lambda)$ が成り立つことである。ここで $\mathsf{Game}^{\mathsf{Und}}_{\Pi,\mathcal{A}}(\lambda)$ は以下のように定義される：

$\mathsf{Game}^{\mathsf{Und}}_{\Pi,\mathcal{A}}(\lambda)$

$\mathsf{Setup}(1^\lambda) \to \mathsf{pp}$
$\mathsf{KeyGen}(\mathsf{pp}) \to (\mathsf{sk},\mathsf{pk})$
$b \leftarrow \{0,1\}$
$\mathcal{A}(\mathsf{pk})^{Q,\mathcal{O}_{\mathrm{cha}}(b,\mathsf{sk},\cdot)} \to b'$
Output 1 if $b = b'$
Otherwise Output 0

ここで、チャレンジオラクル $\mathcal{O}_{\mathrm{cha}}$ はプロンプト x を受け取り、$b = 0$ の場合は $Q(x)$ を返し、

© 2026 Information Processing Society of Japan

$b = 1$ の場合は $\mathsf{Wat}(\mathsf{sk}, x)$ を返す。

また、上記定義の優位性 $\mathsf{Adv}^{\mathsf{Und}}_{\Pi,\mathcal{A}}(\lambda)$ は以下の定義と同等である。

$$
\begin{aligned}
&|\Pr[\mathcal{A}^{Q,\overline{Q}(\cdot)}(\mathsf{pk}) = 1| \\
&\quad \mathsf{pp} \leftarrow \mathsf{Setup}(1^\lambda), (\mathsf{sk}, \mathsf{pk}) \leftarrow \mathsf{KeyGen}(\mathsf{pp})] \\
&\qquad - \Pr[\mathcal{A}^{Q,\mathsf{Wat}_{\mathsf{sk}}(\cdot)}(\mathsf{pk}) = 1| \\
&\quad \mathsf{pp} \leftarrow \mathsf{Setup}(1^\lambda), (\mathsf{sk}, \mathsf{pk}) \leftarrow \mathsf{KeyGen}(\mathsf{pp})]|
\end{aligned}
$$

3.4 偽陽性開示の不可能性

また、悪意のある AI プロバイダが不正な検証者向け情報を発行し、ウォーターマークを本来埋め込んでいないコンテンツから、ウォーターマークを検出してしまう事態が発生してはならない。これを偽陽性開示の不可能性として定式化する。定義では、プロトコル通りに検証者向け情報を発行した場合にはウォーターマークが検出されない一方で、不正な検証者向け情報を用いるとコンテンツからウォーターマークが検出される、そのようなコンテンツと不正な検証者向け情報のペアを作れないことを要求している。これはユーザーと AI プロバイダの共謀を捉えている。例えば、ある人が実際の防犯カメラの映像に基づいて告訴された際、犯人と共謀している AI プロバイダがその証拠は AI によって生成されたものであると偽証しようとする場合を想定している。

Definition 11 (偽陽性開示の不可能性)**.** ウォーターマーク方式 Π が *No False-Positive* を満たすとは、任意の *PPT* アルゴリズム $\mathcal{A}$ に対して、$\mathsf{Adv}^{\mathsf{NFP}}_{\Pi,\mathcal{A}}(\lambda) := \Pr[\mathsf{Game}^{\mathsf{NFP}}_{\Pi,\mathcal{A}}(\lambda) = 1] \leq negl(\lambda)$ が成り立つことである。

$\mathsf{Game}^{\mathsf{NFP}}_{\Pi,\mathcal{A}}(\lambda)$

$\mathsf{pp} \leftarrow \mathsf{Setup}(1^\lambda)$
$\mathcal{A}^{\mathsf{KeyGen}(\mathsf{pp},\cdot)}(\mathsf{pp}) \rightarrow (\mathsf{pk}, \zeta, \alpha)$
$\mathsf{sk} := \mathsf{L}_{\mathrm{key}}[\mathsf{pk}]$
$\mathsf{Disclose}(\mathsf{sk}, \mathsf{pk}, \zeta) \rightarrow \beta$
Output 1 if $\mathsf{Ver}(\mathsf{pk}, \zeta, \beta) = 0 \wedge \mathsf{Ver}(\mathsf{pk}, \zeta, \alpha) = 1$
Otherwise Output 0

ここで鍵生成オラクル $\mathsf{KeyGen}(\mathsf{pp}; \cdot)$ はランダムテープ r を受け取り、鍵対 $(\mathsf{sk}, \mathsf{pk}) \leftarrow \mathsf{KeyGen}(\mathsf{pp}; r)$ を生成し、リスト $\mathsf{L}_{\mathrm{key}} := \mathsf{L}_{\mathrm{key}} \cup \{(\mathsf{pk}, \mathsf{sk})\}$ を更新し、攻撃者に $(\mathsf{sk}, \mathsf{pk})$ を返す。

4. 提案方式

本節では、提案する方式の構成を示し、前節で議論した安全性を満たすことを証明する。

4.1 構成

まず、提案するウォーターマーク方式 Π の構成を示す。構成にはロバスト署名 SIG、共通鍵ステガノグラフィ STG、コミットメント COM、および非対話ゼロ知識証明 NIZK を使用する。直感的には、提案するウォーターマークは通常時は共通鍵方式として機能している。コンテンツの各ブロックを作成する際、生成 AI は前のブロックに対するロバスト署名を生成し、その署名を次に作成するブロックに埋め込む。ウォーターマークが埋め込まれたコンテンツを開示する場合、サービスプロバイダはコンテンツから署名を抽出し、NIZK を用いてどのブロックから署名を抽出できるかを伝える。また、サービスプロバイダは自身のステガノグラフィ鍵にコミットし、そのコミットメントを公開しておくことで、偽陽性エラーの発生を防ぐ。このシンプルな構成により、議論された全ての安全性定義を満たすことができる。

$\mathsf{Setup}(1^\lambda) \rightarrow \mathsf{pp}$

$\mathsf{NIZK}.\mathsf{Setup}(1^\lambda) \rightarrow \mathsf{crs}$
$\mathsf{pp} := \mathsf{crs}$

$\mathsf{KeyGen}(\mathsf{pp}) \rightarrow (\mathsf{pk}, \mathsf{sk})$

$\mathsf{SIG}.\mathsf{KeyGen}(1^\lambda) \rightarrow (\mathsf{sk}_{\mathsf{SIG}}, \mathsf{pk}_{\mathsf{SIG}})$
$\mathsf{STG}.\mathsf{KeyGen}(1^\lambda) \rightarrow \mathsf{k}$
$\mathsf{com} := \mathsf{COM}.\mathsf{Commit}(\mathsf{k}; r)$
$\mathsf{sk} := (\mathsf{sk}_{\mathsf{SIG}}, \mathsf{k}, r)$
$\mathsf{pk} := (\mathsf{pk}_{\mathsf{SIG}}, \mathsf{com}, \mathsf{crs})$

セットアップアルゴリズム Setup は信頼できる第三者によって実行される必要がある。採用されている NIZK が transparent な場合、このアルゴリズムは鍵生成アルゴリズム KeyGen の中に統合することができる。その場合、KeyGen は公開パラメタ pp の代わりにセキュリティパラメタ 1^λ を入力として受け取り、まず $\mathsf{Setup}(1^\lambda)$ を実行して pp を pk に含め、それ以外は同様の処理を行う。

© 2026 Information Processing Society of Japan

$\mathsf{Wat}(\mathsf{pp}, \mathsf{sk}, x) \to y$

$y_1 \leftarrow \overline{Q}_n(x)$
for $i = 2$ to t
  $\sigma_{i-1} \leftarrow \mathsf{SIG}.\mathsf{Sign}(\mathsf{sk}_{\mathsf{SIG}}, y_{i-1})$
  $y_i \leftarrow \mathsf{STG}.\mathsf{Emb}(\mathsf{k}, (x, y_1, \ldots, y_{i-1}), \sigma_{i-1})$
$y := y_1 || \ldots || y_t$

開示アルゴリズム Disclose は以下の言語 $L := \{(\mathsf{com}, \zeta, \sigma) | \sigma = \mathsf{STG}.\mathsf{Dec}(\mathsf{k}, \zeta) \wedge \mathsf{com} = \mathsf{Commit}(\mathsf{k}; r)\}$ の証明を生成し、検証アルゴリズム Ver はそれを検証する。ここで証拠は (k, r) である。

$\mathsf{Disclose}(\mathsf{pp}, \mathsf{sk}, \mathsf{pk}, \zeta) \to \alpha$

for $i = 1$ to $|\zeta| - 2n + 1$
  $\sigma_i \leftarrow \mathsf{STG}.\mathsf{Dec}(\mathsf{k}, \zeta[i + n : i + 2n - 1])$
  if $\mathsf{SIG}.\mathsf{Ver}(\mathsf{pk}_{\mathsf{SIG}}, \zeta[i : i + n - 1], \sigma_i) = 1$
    $x := (\mathsf{com}, \zeta[i + n : i + 2n - 1], \sigma_i)$
    $\mathsf{NIZK}.\mathsf{Prove}(\mathsf{crs}, x, (\mathsf{k}, r)) \to \pi$
    Output $\alpha := (i, \pi, \sigma_i)$

$\mathsf{Ver}(\mathsf{pp}, \mathsf{pk}, \alpha, \zeta) \to 0/1$

$(i, \pi, \sigma_i) := \alpha$
$x := (\mathsf{com}, \zeta[i + n : i + 2n - 1], \sigma_i)$
if $\mathsf{NIZK}.\mathsf{Ver}(\mathsf{crs}, x, \pi) = 0$
    Output 0
if $\mathsf{SIG}.\mathsf{Ver}(\mathsf{pk}_{\mathsf{SIG}}, \zeta[i : i + n - 1], \sigma_i) = 1$
    Output 1
Otherwise
    Output 0

4.2 安全性の直感

本節では、四つの安全性、すなわち堅牢性、偽造不可能性、非権限者に対する検知不可能性、および偽陽性開示の不可能性に関する定理を述べる。紙面の都合上、正式な証明は省略し、直感的な証明スケッチのみを与える。

Theorem 1 (堅牢性)**.** Π の $(\mathsf{EBC}[\Phi, n], 2n)$-堅牢性は、SIG の堅牢性、STG のブロック堅牢性、COM の秘匿性、および NIZK のゼロ知識性と完全性から導かれる。

Proof. 攻撃者の出力する ζ は、その内の連続する $2n$ ビットのブロック ζ^* が、AI の生成したコンテンツと似ていると仮定する。この時、STG の堅牢性によって、ζ^* の後半 n ビットのブロックからロバスト署名 σ を抽出することができ、このことに対する証明は NIZK の完全性から受理される。更に、この署名 σ は SIG の堅牢性より ζ^* の前半 n ビットのブロックに対して有効なはずである。また、公開鍵に含まれるコミットメント $\mathsf{com} \in \mathsf{pk}$ や開示オラクル $\mathsf{Disclose}_{\mathsf{sk},\mathsf{pk}}(\cdot)$ の返答から情報が漏れないことも必要な為、COM の秘匿性と NIZK のゼロ知識性も帰着に必要となる。 □

Theorem 2 (偽造不可能性)**.** Π の偽造不可能性は SIG の偽造不可能性から導かれる。

Proof. ウォーターマーク方式 Π の偽造不可能性を破ろうとすると、少なくとも、ロバスト署名の秘密鍵 $\mathsf{sk}_{\mathsf{SIG}} \in \mathsf{pk}$ を知らず、$\mathsf{SIG}.\mathsf{Ver}(\mathsf{pk}_{\mathsf{SIG}}, \zeta[i : i + n - 1], \sigma_i) = 1$ を満たす署名を作る必要がある。これはロバスト署名の偽造に相当する。 □

Theorem 3 (非権限者に対する検知不可能性)**.** Π の検知不可能性は、COM の秘匿性と STG の検知不可能性から導かれる。

Proof. もし検知不可能性ゲームに勝利する攻撃者が存在するとしたら、コミットメント com から STG の鍵 k の情報を得たか、あるいは STG の鍵 k を知らずに STG による埋め込みを検知したかのどちらかである。よって、コミットメント COM の秘匿性と STG の検知不可能性に帰着できる。 □

Theorem 4 (偽陽性開示の不可能性)**.** Π の偽陽性開示の不可能性は、NIZK の知識健全性と COM の拘束性から導かれる。

Proof. プロトコル通りに $\mathsf{Disclose}(\mathsf{sk}, \mathsf{pk}, \zeta) \to \beta$ とすると $\mathsf{Ver}(\mathsf{pk}, \zeta, \beta) = 0$ となって検証で受理されないのに、$\mathsf{Ver}(\mathsf{pk}, \zeta, \alpha) = 1$ となるような $(\mathsf{pk}, \zeta, \alpha = (i, \pi, \sigma_i))$ を攻撃者 $\mathcal{A}$ が作れると仮定する。この時、$(\mathsf{com}, \zeta[i + n : i + 2n - 1], \sigma_i)$ が言語 L に含まれるのかを考える。まず、言語 L に含まれないのだとしたら NIZK の健全性を破っている。もし、言語 L に含まれるのだとしたら、知識健全性から $\mathsf{com} = \mathsf{COM}.\mathsf{Commit}(\mathsf{k}', r')$ となる (k', r') を抽出することができるが、もしこれが $(\mathsf{k}, r) \in \mathsf{sk}$ と等しいのであれば、$\mathsf{Ver}(\mathsf{pk}, \zeta, \alpha) = 1$ にはならない。よって COM の拘束性を破っている。 □

© 2026 Information Processing Society of Japan

5. おわりに

本稿では、悪意を持つユーザがウォーターマークの除去を試行する中、AI サービス提供者はウォーターマークの有無を第三者に開示したいというシナリオで、ウォーターマークの安全性を論じ、新たな構成を提案した。このシナリオの下では既存方式のウォーターマークが不十分なことを議論し、この問題の解決策として、選択的に開示可能なウォーターマークを提案した。

本稿で提案したウォーターマークは安全性に限界がある為、今後の研究の課題として、より強い安全性を証明できる構成に取り組みたい。まず、本稿で議論した検知不可能性は、検証権限を与えられていない者に対する保証であったが、本来必要なのは開示していないコンテンツに関する検知不可能性である為、これを保証したい。更に、本稿の構成ではウォーターマークの有無の開示をプロトコル通りに実行したことが保証されず、AI サービス提供者がウォーターマークを検出したにも拘わらず、検出できなかったと嘘を吐くことができてしまう。このような偽陰性を防ぐことも必要であると考えている。

謝辞 本研究は、JSPS KAKENHI JP24K20776、JST CREST JPMJCR22M1、AC7261400035 の助成を受けたものである。

参考文献

[1] Sven Gowal and Pushmeet Kohli. Identifying AI-generated images with SynthID.

[2] Google DeepMind. Watermarking ai-generated text and video with synthid, May 2024. Accessed: 2026-08-13.

[3] Anthropic. How claude marks ai-generated content, 2026.

[4] Miranda Christ, Sam Gunn, and Or Zamir. Undetectable watermarks for language models. In Shipra Agrawal and Aaron Roth, editors, *Proceedings of Thirty Seventh Conference on Learning Theory*, volume 247 of *Proceedings of Machine Learning Research*, pages 1125–1139. PMLR, 30 Jun–03 Jul 2024.

[5] Jaiden Fairoze, Sanjam Garg, Somesh Jha, Saeed Mahloujifar, Mohammad Mahmoody, and Mingyuan Wang. Publicly-detectable watermarking for language models. *IACR Communications in Cryptology*, 1(4), 2025.

[6] Huijia Lin, Kameron Shahabi, and Min Jae Song. Unforgeable watermarks for language models via robust signatures. In Nadia Heninger and Mike Rosulek, editors, *Advances in Cryptology – CRYPTO 2026*, pages 99–131, Cham, 2026. Springer Nature Switzerland.

[7] Miranda Christ and Sam Gunn. Pseudorandom error-correcting codes. pages 325–347.

© 2026 Information Processing Society of Japan