家庭内IoTネットワークにおけるスマートスピーカーを対象としたDDoS検知に関する研究

伊藤 希竜[1,a)]　成田 匡輝[2]

概要：近年, 家庭内においてスマートスピーカーやネットワーク家電などの IoT 機器が急速に普及している. 一方で,IoT 機器はパソコンのようにセキュリティソフトや管理ツールを導入することが困難であり, サイバー攻撃の標的となる危険性が高まっている. そこで本研究では, 家庭内 IoT ネットワークにおけるスマートスピーカー（Amazon Echo）を対象とした DDoS 検知手法を提案する. 家庭内ネットワークに設置した Raspberry Pi を用いて通信を取得し， パケットデータをフロー特徴量へ変換した後，攻撃ログ，Amazon Echo 宛て通信の有無，および正常通信から算出した単位時間当たりのパケット数の分位点を用いて， BENIGN，DDoS，UNKNOWN の 3 値ラベルを付与した．作成したデータセットを用いて Random Forest および XGBoost による分類モデルを構築し, 学習および閾値調整に使用していないテストデータで評価を行った. その結果, 両モデルとも Recall 98.88 %を達成し,DDoS 通信 268 件中 265 件を正しく検知した. また,FPR は約 0.03 %を達成し, 本研究の目標である低誤検知な DDoS 検知を実現した.

キーワード：家庭内 IoT，スマートスピーカー，フラッド攻撃，異常検知，機械学習

A Study on DDoS Detection Targeting Smart Speakers in Home IoT Networks

Kiryu Ito[1,a)]　Masaki Narita[2]

Abstract: In recent years, IoT devices such as smart speakers and network-connected home appliances have rapidly become widespread in households. However, unlike personal computers, it is difficult to install security software or management tools on IoT devices, increasing the risk of them becoming targets of cyber-attacks. Therefore, this study proposes a DDoS detection method targeting smart speakers (Amazon Echo) in home IoT networks. We used a Raspberry Pi installed on the home network to capture communications; after converting the captured packets into flow features, we assigned one of three labels—BENIGN, DDoS, or UNKNOWN— based on the attack periods, whether the traffic was directed to the Amazon Echo, and a packet-rate threshold derived from normal traffic. Using the created dataset, we built classification models using Random Forest and XGBoost and evaluated them using test data that had not been used for training or threshold adjustment. As a result, both models achieved a recall of 98.88% and correctly detected 265 out of 268 DDoS communications. Furthermore, the FPR was approximately 0.03%, achieving the goal of this study: low-false-positive DDoS detection.

Keywords: Home IoT, Smart Speaker, Flood Attack, Anomaly Detection, Machine Learning

[1] 岩手県立大学大学院ソフトウェア情報学研究科
Graduate School of Software and Information Science, Iwate Prefectural University
[2] 岩手県立大学
Iwate Prefectural University
[a)] s231x002@s.iwate-pu.ac.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

1. はじめに

近年，スマートスピーカーやネットワーク家電などのIoT（Internet of Things）機器が家庭内に普及している．これらの機器はネットワークに常時接続され，音声操作やクラウドサービスとの通信など，さまざまな機能を提供している．図 1 に IP アドレス当たりの年間総観測パケット

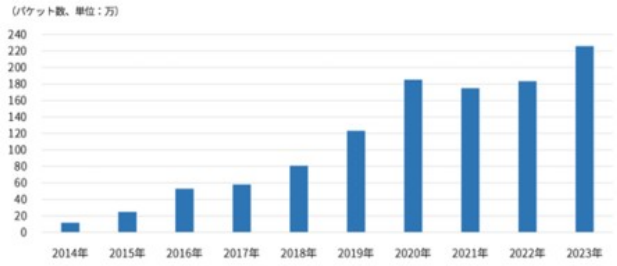


図 1 IP アドレス当たりの年間総観測パケット数 (過去 10 年間)

数 (過去 10 年間) を示す．
図 1 から，2014 年から 2023 年にかけて観測パケット数が増加傾向にあることが分かる．

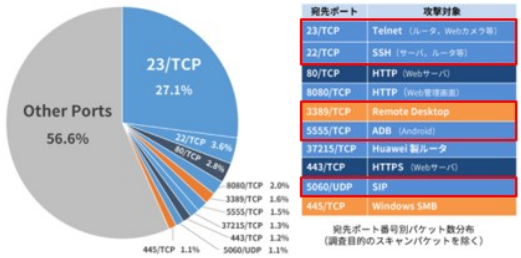


図 2 宛先ポート番号別パケット数分布 (調査目的のスキャンパケットを除く)

図 2 に, 調査目的のスキャンパケットを除いた宛先ポート番号別の観測パケット数分布を示す．図中の赤枠は，IoT 機器に関連する代表的なポート番号を示している．

図 1 および図 2 から, ネットワーク上で観測される通信が増加するとともに，IoT 機器に関連する通信も継続的に観測されていることが分かる. このような IoT 機器の普及に伴い，IoT 機器を標的とする攻撃への対策が重要となっている [1]．公的機関や企業組織といった大規模な環境では, セキュリティの専門家がフレームワークを構築し運用することで IoT デバイスの安全性が確保されている．しかし,IoT デバイスはパソコンやスマートフォンのように管理ツールやウイルス対策ソフトをインストールできるような機能を持ち合わせていない事が多い. 機器の性能が限られ適切なセキュリティ対策を構築することは困難である. また, 家庭内といった小規模な環境で IoT デバイスを安全に用いるとしても, 人的資源が少なさやセキュリティシステムの導入するためのコスト等の問題点から, 管理, 運用していくことは容易ではない. これらの理由から, サイバー攻撃の脅威にさらされることが多くその対策強化の必要性が指摘されている．

IoT 機器に対する脅威の一つとして，短時間に大量のパケットを送信するフラッド攻撃が挙げられる．フラッド攻撃を受けた機器では，通信帯域や処理資源が消費されることにより，サービスの応答遅延や停止が発生する可能性がある．特に，スマートスピーカーのようにネットワークへ常時接続される家庭内 IoT 機器では，機器内部の状態を利用者が直接確認することが 難しい．このため，家庭内ネットワーク上で通信を取得し，パケット数，通信量およびパケット到着間隔などの変化から，攻撃通信を検知する方法が考えられる．

これまで，IoT ネットワークを対象として，機械学習や深層学習を用いた攻撃検知手法が提案されている．例えば，公開データセットを用いた未知攻撃の検知や，フロー特徴量を用いた侵入検知手法が検討されている．しかし，公開データセットを用いた評価では，実際の家庭内環境における機器固有の通信特性や，利用状況に伴う正常通信の変化が，十分に反映されていない可能性がある．また，正常通信が攻撃通信よりも大幅に多い不均衡データでは，Accuracy が高い場合でも，正常通信を攻撃と判定する誤検知や，少数の攻撃通信に対する見逃しを十分に評価できない場合がある．したがって，家庭内環境で実際に取得した通信を用い，誤検知率を考慮して攻撃検知性能を評価する必要がある．そこで本研究では，家庭内 IoT ネットワークに設置したスマートスピーカーを対象として，フロー特徴量と機械学習を用いたフラッド攻撃検知手法を検討する． 家庭内ネットワーク内で取得したパケットデータを一定時間ごとのフローに集約し，フロー内のパケット数，通信量，継続時間およびパケット到着間隔などの特徴量を生成する．さらに，実験時に記録した攻撃時間，Amazon Echo 宛て通信の有無，および正常通信から算出した単位時間当たりのパケット数の分位点に基づいてラベルを付与し，Random Forest および XGBoost を用いて分類モデルを構築する．本研究では，学習および判定閾値の調整に使用していないテストデータを用いて評価を行う．正常通信を誤って攻撃と判定する割合である FPR（False Positive Rate）を考慮して判定閾値を決定し，その条件における Recall，Precision および F1-score を評価する．これにより，正常通信が大部分を占める家庭内ネットワークにおいて，誤検知を抑えながらフラッド攻撃を検知できるかを明らかにする．

本研究の目的は，家庭内ネットワークで取得したスマートスピーカーのフロー特徴量を用いて，DDoS 攻撃で利用されるフラッド通信を検知し，学習時とは異なるデータに対して，低い誤検知率を維持しながら攻撃を検知できるか

© 2026 Information Processing Society of Japan

を明らかにすることである．

なお，本研究では DDoS 攻撃で利用される通信パターンを検知対象とするが，現段階の実験では単一の攻撃端末から攻撃通信を発生させている．したがって，本稿では単一送信元によるフラッド攻撃環境で基礎評価を行い，複数の攻撃元を用いた DDoS 環境への拡張を今後の課題とする．

本研究の主な内容を以下に示す．

- 家庭内ネットワークにおいて，スマートスピーカーの正常通信と フラッド攻撃通信を複数日にわたって取得する．
- 取得したパケットからフロー特徴量を生成し，攻撃時間，通信対象および正常通信のパケット数分布に基づくラベルを付与した機械学習用データセットを構築する．
- Random Forest と XGBoost を用いて分類モデルを構築し，学習および閾値調整に使用していないデータに対して， Recall と FPR を中心に評価する．

2. 関連研究

2.1 IoT ネットワークにおける未知攻撃検知

Hairab ら [2] は，IoT ネットワークを対象として，CNN と正則化を組み合わせた未知攻撃検知手法を提案している．同研究では，Bot-IoT データセットに含まれる正常通信と DoS 通信を用いてモデルを学習し，学習時に含まれていない DDoS，OS Fingerprint および Service Scan を用いて検知性能を評価している．入力には，情報利得に基づいて選択された 9 個の特徴量を使用し，これらを 3×3 の行列に変換して CNN へ入力している．また，モデルの過学習を抑制するため，標準的な CNN に加えて L1 および L2 正則化を適用した CNN を比較している．評価の結果，L2 正則化を適用した CNN の Accuracy は，DDoS に対して 99.98%，OS Fingerprint に対して 98.49%，Service Scan に対して 90.75%となった．この結果から，正則化による過学習の抑制が，未学習の攻撃に対する検知性能の向上に有効であることが示されている．一方で，同研究では公開データセットを使用しており，特定の家庭内 IoT 機器から実際に取得した通信を用いた評価は行われていない．

2.2 フロー特徴量を用いた異常検知データセット

Dehlaghi-Ghadim ら [3] は，産業制御システムにおける機械学習型 IDS の評価を目的として，ICS-Flow データセットを構築している．同研究では，ボトル充填工場を模擬したテストベッド上で，Reconnaissance，DDoS，Replay および MitM による偽データ注入を実施し，正常時および攻撃時のネットワーク通信を取得している．また，PCAP 形式のパケットデータからフロー特徴量を生成する ICS-FlowGenerator を開発している．同研究では，500 ms の時間区間内に存在する，送信元アドレス，宛先アドレスおよびプロトコルが共通するパケットをフローとして集約している．生成されたデータセットには，フローに関する特徴量，一般的な統計特徴量および TCP ヘッダに関する特徴量が含まれる．ラベル付けには，攻撃時間内の通信を異常とする Injection Timing 方式と，攻撃端末を送信元または宛先とする通信を異常とする Network Security Tools 方式の 2 種類を採用している．この結果，攻撃時間だけで判定する場合と比較して，通信端点を考慮する方式では，攻撃と判定されるフローが限定されることを示している．さらに，Decision Tree，Random Forest および Artificial Neural Network を用いて評価した結果，二値の攻撃検知では Random Forest が 99.5%の Accuracy を示している．一方，同研究の対象は産業制御システムであり，家庭内 IoT 機器の通信特性を対象としたものではない．また，主としてデータセットの構築と有用性の評価を目的としており，家庭内環境において誤検知率を制約した場合の 攻撃検知性能については検討されていない．

2.3 本研究の位置付け

関連研究と本研究の比較を表 1 に示す．表 1 では，対象環境，対象データ，主な目的，使用モデルおよび評価の観点を比較している．表 1 から， 本研究は実際の家庭内環境で取得した Amazon Echo の通信を対象とし， 別日のデータに対する性能と FPR を重視している点に特徴がある．以上の研究から，学習時とは異なるデータを用いた汎化性能の評価，フロー特徴量の生成，および攻撃ログと通信端点を考慮したラベル設計が重要であると分かる．また, 特定の家庭内環境で取得したスマートスピーカーの通信を用いた評価は行われていない．そこで本研究では，家庭内ネットワークに設置したスマートスピーカーを対象として，実際に取得した正常通信およびフラッド攻撃通信からフロー特徴量データセットを構築する．さらに，学習および判定閾値の決定に使用していない別日の通信を用いて Random Forest と XGBoost を評価し，FPR を低く抑えた条件における攻撃検知性能を明らかにする．

3. 提案手法

3.1 提案手法の概要

本研究では，家庭内ネットワークに設置したスマートスピーカーを対象として，ネットワークフロー特徴量と機械学習を用いたフラッド攻撃検知手法を提案する．まず，家庭内ネットワークを流れるパケットを Raspberry Pi 上の tcpdump によって取得し，PCAP 形式で保存する．次に，取得したパケットを一定時間ごとに集約し，通信端点およびプロトコルが共通するパケットからフローを生成する．生成した各フローに対して，パケット数，通信量，フロー継続時間およびパケット到着間隔などの特徴量を算出する．さらに，実験時に記録した攻撃開始時刻および攻撃

© 2026 Information Processing Society of Japan

表 1　関連研究と本研究の比較
Table 1　Comparison of related studies and this study

項目	Hairab ら	Dehlaghi-Ghadim ら	本研究
対象	IoT ネットワーク	産業制御システム	家庭内 IoT
対象データ	Bot-IoT	ICS-Flow	実測した Echo 通信
主な目的	未知攻撃検知	データセット構築	フラッド攻撃検知
モデル	CNN 等	RF，DT，ANN	RF，XG-Boost
評価の観点	未知攻撃への汎化	攻撃検知・識別	別日データと FPR

終了時刻，Amazon Echo 宛て通信の有無，ならびに正常通信から算出した Window Packets/s の分位点に基づき，各フローに BENIGN，DDoS または UNKNOWN のラベルを付与する．その後，作成したデータセットを用いて Random Forest および XGBoost を学習し，各フローが攻撃通信である予測確率を算出する．最後に，検証データを用いて決定した判定閾値に基づき，正常通信と攻撃通信を分類する．

3.2　フロー生成

本研究では，取得したパケットをそのまま分類するのではなく，一定時間内に観測されたパケットをフロー単位に集約する． 各パケットについて，IP アドレスとポート番号の組から送信元端点および宛先端点を生成する．通信方向が逆の場合でも同一の通信ペアとして扱うため，送信元端点と宛先端点を一定の順序で並べ替え，これらとトランスポート層プロトコルの組を双方向フロー識別子として使用する．したがって，同一時間窓内において，送信元と宛先を入れ替えたパケットも同一の双方向フローに集約される．パケット p の送信元端点および宛先端点を，それぞれ $e_{\mathrm{s}}(p)$ および $e_{\mathrm{d}}(p)$ とし，次式で定義する．

$$e_{\mathrm{s}}(p) = (IP_{\mathrm{s}}(p), Port_{\mathrm{s}}(p)) \tag{1}$$

$$e_{\mathrm{d}}(p) = (IP_{\mathrm{d}}(p), Port_{\mathrm{d}}(p)) \tag{2}$$

2 つの端点を一定の順序で並べ替えた双方向フロー識別子 $k_{\mathrm{bi}}(p)$ を次式で定義する．

$$k_{\mathrm{bi}}(p) = \left(\min\left\{e_{\mathrm{s}}(p), e_{\mathrm{d}}(p)\right\}, \max\left\{e_{\mathrm{s}}(p), e_{\mathrm{d}}(p)\right\}, \mathrm{Proto}(p)\right) \tag{3}$$

パケット集合を P，時間窓幅を Δt とする． 時刻 t から $t+\Delta t$ までの時間窓に含まれ， 双方向フロー識別子が一致するパケット集合を， フロー $f_{t,k}$ として次式で定義する．

$$f_{t,k} = \{p \in P \mid t \le t_p < t + \Delta t,\, k_{\mathrm{bi}}(p) = k\} \tag{4}$$

ここで，t_p はパケット p の取得時刻を表す．本研究では時間窓幅 Δt を 1 秒とする．TCP および UDP ではポート番号を使用し，ポート番号を持たない ICMP では，送信元ポート番号および宛先ポート番号を 0 として処理する．本識別子は，送信元 IP アドレス，宛先 IP アドレス，送信元ポート番号，宛先ポート番号およびプロトコルからなる 5 タプル相当の情報を使用するが，通信方向を区別しないように 2 つの端点の順序を正規化している．本研究では，往路と復路を同一の双方向フローに集約し， 両方向のパケットをまとめてフロー統計量を算出した． なお，送信方向別および受信方向別の特徴量は生成していない．

3.3　ラベル付与

正常通信として取得したフローは BENIGN とした．攻撃実験中に取得したフローについては，攻撃実施区間との重なり，Amazon Echo 宛て通信の有無，および正常通信から算出した Window Packets/s の 99.5 パーセンタイルに基づいてラベルを付与した．攻撃時間内かつ Amazon Echo 宛てであり，Window Packets/s が閾値以上のフローを DDoS，閾値未満のフローを UNKNOWN とした．それ以外のフローは BENIGN とした．UNKNOWN は二値分類の学習，検証および評価から除外した．

3.4　特徴量生成と前処理

フラッド攻撃では，正常通信と比較して，短時間に多数のパケットが送信される．そのため，各双方向フローから，パケット数，総通信量，通信レート，フロー継続時間，パケット到着間隔およびパケット長に関する特徴量を生成した．フロー f に含まれるパケット数を n_f，各パケットの長さを l_i，時間窓幅を Δt とすると，単位時間当たりのパケット数 PPS_f および単位時間当たりの通信量 BPS_f を次式で定義する．

$$PPS_f = \frac{n_f}{\Delta t} \tag{5}$$

$$BPS_f = \frac{\sum_{i=1}^{n_f} l_i}{\Delta t} \tag{6}$$

また，フロー内のパケットを取得時刻順に並べ， 連続するパケット間の到着間隔 IAT_i を次式で定義する．

$$IAT_i = t_i - t_{i-1} \tag{7}$$

各フローについて，IAT の平均値，最大値および標準偏差を算出した．また，パケット長の平均値，最大値，標準偏差および分散を算出した．さらに，通信種別を表す数値特徴量として，宛先ポート番号および IP プロトコル番号を使用した．各基本特徴量について，値が欠損していることを表す Missing Flag を追加し，その後，欠損値を 0 で補完した．送信元 IP アドレス，宛先 IP アドレス，攻撃時間情

© 2026 Information Processing Society of Japan

表 2　分類モデルに使用するフロー特徴量
Table 2　Flow features used in the classification model

分類	特徴量
フロー規模	Flow Packets，Total Bytes
レート	Flow Bytes/s
継続時間	Flow Duration
到着間隔	Flow IAT Mean，Flow IAT Std，Flow IAT Ma
パケット長	Packet Length Mean，Packet Length Std， Packet Length Max，Packet Length Variance
通信種別	Destination Port，IP Protocol
品質情報	各基本特徴量の Missing Flag

報，攻撃種別およびラベルは分類モデルへの入力から除外した．Destination Port については，フロー内に Amazon Echo 宛てのパケットが存在する場合，当該パケット群における宛先ポート番号の最頻値を使用した．Amazon Echo 宛てのパケットが存在しない場合は，フロー内の全パケットにおける宛先ポート番号の最頻値を使用した．

分類モデルへの入力に使用したフロー特徴量を表 2 に示す．表 2 に示すように，フロー規模，通信レート，継続時間，到着間隔， パケット長，通信種別および欠損情報に関する特徴量を使用した．数値変換後に含まれる正の無限大および負の無限大は欠損値へ置換した．なお，Window Packets/s はラベル生成時の判定に使用しているため，通常の学習では分類モデルの入力特徴量から除外した．これにより，ラベル付与に直接使用した値を分類モデルへそのまま入力することを避けた．

3.5　分類モデルと判定閾値

本研究では，フロー特徴量を入力とする分類モデルとして，Random Forest および XGBoost を使用する．両モデルは決定木を基礎とし，複数の数値特徴量からなる表形式データを扱うことができる．また，特徴量重要度を算出できるため，どの通信特徴量が攻撃検知に寄与したかを分析できる．Random Forest は，学習データと特徴量をランダムに選択して複数の決定木を構築し，各決定木の出力を統合して分類する．一方，XGBoost は，前段の決定木における誤分類を後段の決定木が補正する勾配ブースティング手法である．各モデルは，入力フロー f が攻撃通信である確率 $\hat{p}_f$ を出力する．判定閾値を θ としたとき，予測ラベル $\hat{y}_f$ を次式で定義する．

$$\hat{y}_f = \begin{cases} 1 & (\hat{p}_f \geq \theta) \\ 0 & (\hat{p}_f < \theta) \end{cases} \tag{8}$$

4.　実験環境とデータセット

4.1　実験環境

本研究で構築した実験環境を図 3 に示す．図 3 に示すように，Amazon Echo，攻撃端末，パケット取得用の Raspberry Pi 3，中継機および分析用 PC によって実験環境を構成した．家庭内 IoT 機器としてスマートスピーカーである

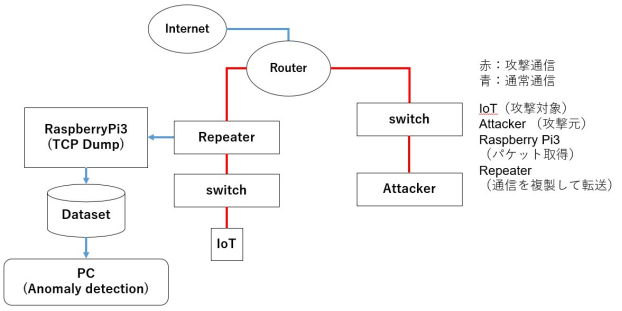


図 3　本研究の実験環境

る Amazon Echo を使用し，同一の家庭内ネットワークに攻撃端末およびパケット取得用の Raspberry Pi 3 を設置した．攻撃端末は，家庭内の PC がマルウェアに感染し，同一 LAN 上の IoT 機器に対して攻撃通信を送信する状況を模擬するために使用した．攻撃端末から Amazon Echo へ送信される通信と，Amazon Echo が通常利用時に送受信する通信を， Raspberry Pi 3 上で動作させた tcpdump によって取得した．取得した通信は PCAP 形式で保存し，分析用 PC へ転送した後，フロー特徴量の生成，ラベル付与および機械学習モデルによる分類を行った．パケット取得用の Raspberry Pi 3 は，Amazon Echo 周辺の通信を取得できる位置に配置した．また，中継機を介して対象機器の通信が Raspberry Pi 3 を通過するようにネットワークを構成した．これにより，Amazon Echo が送受信する正常通信と，攻撃端末から Amazon Echo へ送信される攻撃通信の両方を取得した．

4.2　通信データの取得

本研究では，Amazon Echo の正常時および攻撃時の通信特性を取得するため，正常通信と攻撃通信を異なる条件で収集した．正常通信は 7 日間，攻撃通信は 3 日間にわたって取得した．ネットワーク通信は Raspberry Pi 3 上の tcpdump を用いて取得し，日付または実験セッションごとに PCAP ファイルとして保存した．正常通信は，Amazon Echo の待機状態に加え， 音声操作，天気情報などの情報取得および 音楽再生を行った状態で取得した．

4.3　攻撃通信の取得条件

本研究では，短時間に多数のパケットが送信されるフラッド攻撃を検知対象とする． 実験では，攻撃端末から Amazon Echo に対して，SYN flood，UDP flood および ICMP flood の 3 種類の攻撃通信を送信した．各攻撃について，攻撃開始時刻，終了時刻および対象プロトコルを記録した．このうち，攻撃開始時刻および終了時刻は，フローと

© 2026 Information Processing Society of Japan

攻撃実施区間との重なりを判定するために使用した．SYN flood では，TCP の SYN フラグを設定したパケットを短時間に連続して送信した．UDP flood では，UDP データグラムを対象機器へ連続して送信した．ICMP flood では，ICMP パケットを短時間に連続して送信した．これらの攻撃によって生じる，単位時間当たりのパケット数，通信量およびパケット到着間隔の変化を検知対象とした．なお，本実験における攻撃元は 1 台であるため，実験構成としては単一送信元による DoS に相当する．本研究では，DDoS 攻撃で使用される SYN flood，UDP flood および ICMP flood の通信パターンを対象とした基礎評価として本実験を位置付ける．複数の攻撃元を用いた DDoS 環境での評価は，今後の課題とする．

4.4 データセットの生成

取得した PCAP ファイルから，パケット取得時刻，送信元 IP アドレス，宛先 IP アドレス，TCP または UDP の送信元ポート番号および宛先ポート番号，IP プロトコル番号，ならびにパケット長を抽出した．次に，抽出したパケットを 1 秒間の固定時間窓に分割した．各パケットの送信元端点と宛先端点を一定の順序で並べ替え，2 つの端点およびプロトコルが共通するパケットを 一つの双方向フローとして集約した．このため，送信元と宛先が逆転した応答方向のパケットも，同一時間窓内では同一のフローに含まれる．ICMP はポート番号を持たないため，送信元ポート番号および宛先ポート番号を 0 として処理した．

4.5 ラベル設計

3.3 節に示したラベル付与条件を，攻撃実験中に取得したフロー f について次式で表す．

$$y_f = \begin{cases} 1, & C_{\text{time}}(f) \wedge C_{\text{iot}}(f) \wedge C_{\text{pps}}(f) \\ 0, & \neg C_{\text{time}}(f) \vee \neg C_{\text{iot}}(f) \\ -1, & C_{\text{time}}(f) \wedge C_{\text{iot}}(f) \wedge \neg C_{\text{pps}}(f) \end{cases} \tag{9}$$

ここで，$C_{\text{time}}(f)$ はフロー f が攻撃実施区間と重なること，$C_{\text{iot}}(f)$ は Amazon Echo 宛てのパケットを含むこと，$C_{\text{pps}}(f)$ は Window Packets/s が正常通信から算出した閾値以上であることを表す．また，$y_f = 1$ は DDoS，$y_f = 0$ は BENIGN，$y_f = -1$ は UNKNOWN を表す．外部テストデータのクラス構成については，5.1 節で示す．

4.6 学習・検証・テストデータへの分割

作成したデータセットから，指定した取得日のデータを外部テストデータとして事前に分離した．外部テストデータを除いた開発用データについて，BENIGN と DDoS のクラス比率を維持する層化ランダム分割を行い，学習データと検証データを作成した．学習データは Random Forest および XGBoost の学習に使用し，検証データは各モデルの判定閾値の決定に使用した．判定閾値は，検証データにおいて FPR が目標値以下となる候補のうち，Recall が最大となる値を選択した．外部テストデータは，モデルの学習および判定閾値の決定には使用していない．外部テスト時にはモデルを再学習せず，検証データで決定した判定閾値を変更せずに適用した．これにより，学習および閾値調整に使用していない取得日の通信に対する検知性能を評価した．

表 3 テストデータのクラス構成
Table 3 Class distribution of the test dataset

クラス	フロー数	割合
BENIGN	256,597	99.896%
ATTACK	268	0.104%
合計	256,865	100.000%

表 4 各モデルの混同行列
Table 4 Confusion matrices of the evaluated models

モデル	TN	FP	FN	TP
XGBoost	256,521	76	3	265
Random Forest	256,523	74	3	265

5. 評価結果

5.1 テストデータの構成

学習および判定閾値の決定に使用していない 外部テストデータを用いて，Random Forest と XGBoost の攻撃検知性能を評価した．テストデータのクラス構成を表 3 に示す．テストデータは合計 256,865 フローであり，そのうち BENIGN が 256,597 フロー，ATTACK が 268 フローであった．ATTACK がテストデータ全体に占める割合は約 0.104%であり，BENIGN が大部分を占める不均衡データである．本テストデータに対して，すべてのフローを BENIGN と判定した場合でも，Accuracy は約 99.896%となる．したがって，高い Accuracy のみから攻撃検知性能が高いとは判断できない．そこで本研究では，Accuracy に加えて，Recall，FPR，Precision，F1-score，ROC-AUC および PR-AUC を用いて評価した．特に，攻撃通信の検知率を表す Recall と，正常通信の誤検知率を表す FPR を重視する．

5.2 分類結果

各モデルが出力する攻撃確率に対し，検証データを用いて決定した判定閾値を適用した．XGBoost の判定閾値は 0.068898，Random Forest の判定閾値は 0.075966 である．これらの閾値は，テストデータに対する評価中には変更していない．各モデルの混同行列を表 4 に示す．XGBoost と Random Forest はいずれも，268 件の攻撃通信のうち 265

© 2026 Information Processing Society of Japan

件を正しく検知し，3 件を BENIGN と誤判定した．したがって，両モデルの TP は 265 件，FN は 3 件となった．一方，BENIGN を ATTACK と誤判定した FP は，XGBoost が 76 件，Random Forest が 74 件であった．正常通信を正しく BENIGN と判定した TN は，XGBoost が 256,521 件，Random Forest が 256,523 件であった．テストデータに対する各モデルの評価結果を表 5 に示す． 両モデルの Recall は 98.88%であり，攻撃通信 268 件のうち 265 件を検知した．一方，攻撃通信を BENIGN と誤判定した FN は両モデルとも 3 件であった．この結果から，本テストデータに含まれる攻撃通信の大部分を検知できたことが分かる． XGBoost の FPR は 0.0296%，Random Forest の FPR は 0.0288%であった．正常通信 256,597 件に対する誤検知数は， XGBoost が 76 件，Random Forest が 74 件である．したがって，両モデルとも正常通信の 99.97%以上を正しく BENIGN と判定した．誤検知および見逃しの要因については，6.3 節で考察する．

5.3 不均衡データにおける評価

本テストデータでは，ATTACK が全体に占める割合は約 0.104%である．このような不均衡データでは，正常通信の件数が非常に多いため，Accuracy および ROC-AUC だけでは少数クラスである攻撃通信に対する性能を十分に評価できない場合がある．ROC 曲線で用いられる FPR は，多数存在する BENIGN を分母として計算される．そのため，一定数の誤検知が発生した場合でも，正常通信の件数が多い場合には FPR が小さく表示される可能性がある．一方，Precision-Recall 曲線は，少数クラスである ATTACK の検知性能と，攻撃判定に含まれる誤検知の影響を反映する．そのため，本研究では ROC-AUC に加えて PR-AUC を評価した．両モデルの Recall は 98.88%と高かった一方で，Precision は XGBoost が 77.71%，Random Forest が 78.17%であった．これは，ATTACK の検知数 265 件に対して，74 件または 76 件の正常通信が攻撃として誤検知されたためである．例えば，XGBoost が ATTACK と判定したフローは，TP の 265 件と FP の 76 件を合わせた 341 件である．このうち正しく攻撃を検知したものが 265 件であるため，Precision は 77.71%となった．FPR 自体は約 0.03%と低いが， ATTACK が 268 件しか存在しないため，少数の誤検知であっても Precision に与える影響は大きい．このことから，不均衡な家庭内通信に対しては，FPR だけでなく，FP の実件数，Precision および PR-AUC を併せて確認する必要がある．

6. 考察

6.1 フラッド攻撃に対する検知性能

XGBoost と Random Forest は，いずれもテストデータに含まれる 268 件の攻撃フローのうち 265 件を正しく検知し，Recall は 98.88%となった．テストデータはモデルの学習および判定閾値の決定に使用していないため，本実験条件では，学習時とは異なるデータに対しても大部分の攻撃フローを検知できたといえる．フラッド攻撃では，短時間に多数のパケットが送信されるため，単位時間当たりのパケット数，通信量およびパケット到着間隔などに正常通信との差が現れたと考えられる．本研究で使用した Flow Packets，Flow Bytes/s，Flow Duration および IAT に関する特徴量が，このような通信パターンの変化を捉えた可能性がある．ただし，現在の結果だけでは，個々の特徴量が検知結果にどの程度寄与したかは判断できない．今後，各モデルの特徴量重要度を確認するとともに，通信量に関する特徴量のみを使用した場合，時間に関する特徴量のみを使用した場合，および全特徴量を使用した場合を比較する必要がある．

6.2 Random Forest と XGBoost の比較

固定閾値において，両モデルの TP は 265 件，FN は 3 件であり，Recall はともに 98.88%となった．一方，FP は XGBoost が 76 件，Random Forest が 74 件であり，Random Forest が誤検知を 2 件少なく抑えた．ただし，正常通信 256,597 件に対する差は小さいため，今回の結果だけからモデル間に明確な性能差があるとはいえない．ROC-AUC および PR-AUC は XGBoost が高く，固定閾値における Precision および F1-score は Random Forest がわずかに高かった．これは，AUC が予測スコア全体の順位付け性能を評価するのに対し，Precision および F1-score は選択した閾値に依存するためである．今後は，複数の取得日を用いて結果の再現性を確認するとともに，独立した検証データ上で Recall をそろえた条件における FPR と Precision を比較する必要がある．

6.3 誤検知および見逃しの分析

両モデルで 3 件の FN が発生した．1 秒間の固定時間窓の境界付近で攻撃パケットが隣接窓に分割され，Flow Packets や Flow Bytes/s の変化が小さくなった可能性がある．一方，FP は音楽再生やクラウド接続など，短時間に通信量が増加する正常動作によって発生した可能性がある．ただし，現段階では誤分類フローを個別に確認していないため，今後，取得時刻，利用状態，プロトコルおよび特徴量を分析する． また，時間窓幅を変更した評価や TCP フラグ特徴量の導入を行う．

6.4 家庭内ネットワークへの適用可能性

両モデルの FPR は約 0.03%であり，本研究で設定した FPR5%以下という目標を満たした．しかし，家庭内ネットワークでは長時間にわたって多数のフローが発生するため，FPR が低い場合でも，実際の誤警報数が利用者にとっ

© 2026 Information Processing Society of Japan

表 5　テストデータに対する分類性能
Table 5　Classification performance on the test dataset

モデル	閾値	Accuracy	Precision	Recall	FPR	F1	ROC-AUC	PR-AUC
XGBoost	0.068898	99.9692%	77.71%	98.88%	0.0296%	87.03%	0.999918	0.897959
Random Forest	0.075966	99.9700%	78.17%	98.88%	0.0288%	87.31%	0.996035	0.890316

て無視できない可能性がある．今回の評価では，XGBoost で 76 件，Random Forest で 74 件の誤検知が発生した．ただし，これらの誤検知がどの程度の期間内に発生したかを考慮しなければ，家庭内で許容可能な警報数であるかは判断できない．そのため，今後はテストデータの総取得時間を基に，1 時間または 1 日当たりの誤警報数を算出する必要がある．また，同一種類の正常通信から連続して警報が発生した場合，フロー単位では複数の FP であっても，運用上は一つの警報イベントとして統合できる可能性がある．実運用を想定する場合には，連続する攻撃判定を一つのイベントとして集約する方式や，複数の時間窓で連続して攻撃と判定された場合のみ 警報を出す方式についても検討する必要がある．単位時間当たりのパケット数など，分類モデルへ入力する特徴量と 同一または類似する指標をラベルの判定条件として使用した場合，モデルが攻撃の特徴を学習するのではなく，ラベル付け規則を再現するだけになる可能性がある．本研究では，攻撃時間および通信対象に加えて，正常通信から算出した Window Packets/s の分位点をラベル付与条件として使用している．一方，Flow Packets や Flow Bytes/s などの通信量に関する特徴量は，ラベル判定に使用した Window Packets/s と強く相関する可能性がある．そのため，分類モデルが攻撃通信の一般的な特徴ではなく，ラベル付与規則と類似した規則を学習している可能性を完全には排除できない．今後は，攻撃元 IP アドレス，攻撃対象 IP アドレス，攻撃時間およびプロトコルなど，通信量とは独立した 攻撃ログ情報のみを用いて正解ラベルを作成し，本手法との比較を行う必要がある．

6.5　本研究の制約

本研究には四つの制約がある．第一に，攻撃端末が 1 台であるため，複数の攻撃元が協調する DDoS 環境を再現した評価ではない．第二に，評価対象が一つの家庭内ネットワークに設置した一機種の Amazon Echo に限られており，他の機器や環境に同じ閾値および検知性能を適用できるとは限らない．第三に，評価対象は SYN flood，UDP flood および ICMP flood に限定され，攻撃フローも 268 件であるため，異なる攻撃強度や低レート攻撃に対する性能は未評価である．第四に，取得済み PCAP を用いたオフライン評価であり，リアルタイム処理における処理時間，検知遅延および計算資源の使用量を評価していない．今後は，攻撃元，IoT 機器，家庭内環境および攻撃条件を拡張するとともに，オンライン環境での処理性能と単位時間当たりの誤警報数を評価する．

7.　おわりに

本研究では，家庭内ネットワーク上の Amazon Echo を対象に，双方向フロー特徴量と機械学習を用いたフラッド攻撃検知手法を検討した．取得パケットを 1 秒間の固定時間窓ごとに双方向フローへ集約し，生成した特徴量を用いて Random Forest および XGBoost を学習した．外部テストデータによる評価では，両モデルとも 268 件中 265 件の攻撃フローを検知し，Recall は 98.88%となった．FPR は XGBoost が 0.0296%，Random Forest が 0.0288%であり，本実験条件では誤検知を抑えながら大部分の攻撃を検知できた．今後は，攻撃端末，IoT 機器，攻撃強度および時間窓幅を拡張して評価する．

参考文献

[1] 情報通信研究機構．NICTER 観測レポート 2023 の公開．`https://www.nict.go.jp/press/2024/02/13-1.html`, 2024. 参照 2026-08-21.

[2] Belal Ibrahim Hairab, Mahmoud Said Elsayed, Anca D. Jurcut, and Marianne A. Azer. Anomaly detection based on CNN and regularization techniques against zero-day attacks in IoT networks. *IEEE Access*, Vol. 10, pp. 98427–98440, 2022.

[3] Alireza Dehlaghi-Ghadim, Mahshid Helali Moghadam, Ali Balador, and Hans Hansson. Anomaly detection dataset for industrial control systems. *IEEE Access*, Vol. 11, pp. 107982–107996, 2023.

© 2026 Information Processing Society of Japan