深層距離学習による 新種検知が可能なマルウェアの系統樹の作成

首藤 朗[1,a)]　中川 恒[2]　茂木 裕貴[2]　押場 博光[2]　市野 将嗣[1]

概要：マルウェアの多様化に伴い，新規検体と既知検体の関係を把握し，新種を早期に検知することが課題となっている．本研究では，ファミリと TTP を反映した検体間距離を学習し，新種検知と Concept Drift の可視化を可能にする系統樹を提案する．提案モデル M-STRAINER は，表層情報に対して距離ベースの学習によるファミリ・TTP 分類と階層・共起関係の補正を行う．評価では，系統樹として比較モデルと比べ良い精度を示し，新種の検知および Concept Drift においても有効性を示した．

キーワード：マルウェア解析，深層距離学習，系統樹，新種検知

Constructing a Malware Lineage with Novel Malware Detection Using Deep Metric Learning

Akira Shuto[1,a)]　Koh Nakagawa[2]　Yuki Mogi[2]　Hiromitsu Oshiba[2]　Masatsugu Ichino[1]

Abstract: As malware diversifies, relating new samples to known ones and detecting novel malware early have become important challenges. We propose a lineage that learns inter-sample distances reflecting malware families and TTPs to support novel-malware detection and concept-drift visualization. M-STRAINER applies distance-based family and TTP classification and corrections based on hierarchical and co-occurrence relationships to static features. The evaluation demonstrated better lineage accuracy and effectiveness in novel-malware detection and concept-drift analysis.

Keywords: malware analysis, deep metric learning, lineage, novel malware detection

1. はじめに

近年，サイバー攻撃に用いられるマルウェアは増加し，攻撃の組織化や生成 AI・自動化技術の利用に伴う手法の高度化も進む．新種を含む大量かつ多様な検体の出現により，詳細解析の負担が増大している．

この負担を軽減する方法の一つとして，マルウェア間の関係を系統樹で可視化し，検体の近接関係から類似性を把握する方法がある．詳細解析前に，検体を実行せず高速・安全に抽出できる表層情報 [1] から検体群の関係を把握できれば，その後の解析に役立つ．さらに，学習時に存在しなかった種類の検体を既知検体群から分離できれば，大量の検体から未知脅威の候補を絞り込み，限られた解析資源を優先投入できる．また，既知検体群の位置関係を継続的に捉えることで，既存のモデルが実態に合わなくなる兆候を早期に把握し，再学習や更新の判断につなげられる．

マルウェア系統樹は既に複数報告されている [2], [3], [4], [5], [6], [7], [8], [9], [10] が，いずれも既知検体の関係を体系的に示すことが目的で，新種検知や既知検体群の傾向変化（Concept Drift）を同一の系統樹上で扱うことは想定されていない．

そこで本稿では，M-STRAINER を提案する．M-STRAINER は，ファミリと TTP の両方をラベルとして反映する検体間距離を学習することで，距離をファミリ

[1] 電気通信大学
The University of Electro-Communications
[2] 株式会社 FFRI セキュリティ
FFRI Security, Inc.
[a)] akira.shuto@uec.ac.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

同士・TTP 同士の関係として直接解釈可能にする．これにより，既知検体から離れた検体を新種として検知することや，進化に伴う TTP の変化を配置・近傍関係の変化として捉え，分布変化（Concept Drift）を系統樹上で追うことが可能となる．以上により，未知脅威の優先調査と検知モデルの更新判断を支援するとともに，近接する既知検体から詳細解析の手掛かりを提供し，解析者の負担軽減を目指す．

本研究の貢献は以下の通りである．

- 既知検体との関係から新種候補を分離・検知する系統樹作成手法を提案する．
- 定量・定性評価により，未知脅威の優先調査と Concept Drift に応じたモデル更新判断への有効性を示す．

2. 関連研究

2.1 ファミリ表現に基づいた系統樹

Karim ら [2] は，n-grams に基づく n-perms 特徴量で，関連の有無によるファミリ類似度を評価した．Cozzi ら [3] は，大規模 IoT マルウェアデータセットに，コードベースのクラスタリングと HNSW による近似近傍探索を用い，検体間の類似性と各ファミリの系統を抽出した．He ら [4] は，一部検体のみ NCD 距離を計算し，IoT マルウェアの系統樹を高速に作成する手法を提案した．Jang ら [5] は，バイナリから系統を自動推論する ILINE と，グラフ構造・編集距離で品質を評価する IEVAL を提案した．Haq ら [6] は，命令ログとメモリスナップショットから実攻撃のマルウェア系統を有向グラフとして推論した．

2.2 機能表現に基づいた系統樹

Lindorfer ら [7] は，動的解析の振る舞いから，ファミリの機能変化を時系列で追跡する BEAGLE を提案した．Liu ら [8] は，動的解析ログから機能変化を表す系統樹を作成した．Wang ら [9] は，記事から抽出した振る舞いとハニーポット検体の解析結果を組み合わせ，機能に基づく系統樹を作成した．池澤ら [10] は，表層情報からファミリ分類と TTP 推定を同時に学習し，線形 Auto Encoder と HDBSCAN でファミリと機能の双方を表す系統樹を作成した．

2.3 マルウェアと距離学習

Park ら [11] は，表層・動的解析特徴量で同一ファミリ内検体をクラスタリングし，バージョンを識別した．Chai ら [12] は，マルウェア画像の特徴表現を固定し，クラスプロトタイプと Graph Attention Network により，少数検体から新規マルウェアクラスを逐次追加した．Vitale ら [13] は，11 種の静的類似特徴でファミリ単位にクラスタリングし，異なるファミリの混在原因と各特徴の適合率を評価した．Wang ら [14] は，マルウェアを画像化して，Triplet Loss，ArcFace Loss，Memory Bank による表現学習で，長尾分布下の少数派ファミリの分類性能を改善した．

2.4 マルウェアの新種検知

Guo ら [15] は，GAN で未知ファミリの特徴を模倣し，既知ファミリ分類と未知ファミリ検知を行う Open-Set Recognition 手法 CNSNet を提案した．Białczak ら [16] は，動的解析ログの HTTP リクエストから特徴を抽出し，W-SVM，OSSVM，EVM で未知ファミリを検知した．

2.5 本研究の位置づけ

本研究の新規性は，ファミリと TTP の両方を反映する検体間距離を学習し，既知検体の系統関係を表す距離空間を作成することで，新種検知や進化に伴う分布変化（Concept Drift）を把握できる系統樹を作成する点にある．

コードやファミリに基づく系統樹 [2], [3], [4], [5], [6] と，機能変化に基づく系統樹 [7], [8], [9] は，既知検体間の派生関係や機能変化の復元・可視化が主目的で，未知検体の投入や新種判定・Concept Drift の分析は行わない．池澤らの手法 [10] は，表層情報のマルチタスク学習でファミリと TTP を学習する点で本研究に最も近いが，分類結果による系統樹作成であり，検体間距離自体は学習対象としない．また，未知検体と近隣の既知検体との関係は示唆するが，新種判定や Concept Drift 分析は行わない．距離学習を用いる研究 [11], [12], [13], [14] はファミリ分類やクラスタリングを，Open-Set Recognition[15], [16] は未知ファミリの判定を目的とし，いずれもファミリと TTP を反映した系統樹上で新種候補と Concept Drift を扱わない．その他，系統樹上で新種検知や Concept Drift を直接扱う研究は，我々の調査では確認できなかった．

本研究は，既知検体間の関係を復元する従来の系統樹を，未知検体と時間的分布変化の分析へ拡張するものである．

3. 提案手法

3.1 提案手法の概要

本研究では，ファミリと TTP を反映した検体間距離を学習し，新種検知と Concept Drift の把握に用いる系統樹を作成する手法として M-STRAINER（**M**alware Lineage from **S**trains and **T**echniques with **R**elationship-aware **A**ngular Metric Learning for **I**dentification of **N**ovelty and **E**volutionary **R**epresentation）を提案する．M-STRAINER の特徴は次の 2 点である．

- ファミリと TTP の両方を反映する距離空間を学習する．これにより，検体間距離が系統・機能的な関係を直接反映するため，既知検体と機能的に異なる新種の検知や，進化に伴う TTP の変化を配置・近傍関係の変化として捉えた Concept Drift の把握が可能となる．
- TTP の階層関係とファミリ–TTP の共起関係で距離

© 2026 Information Processing Society of Japan

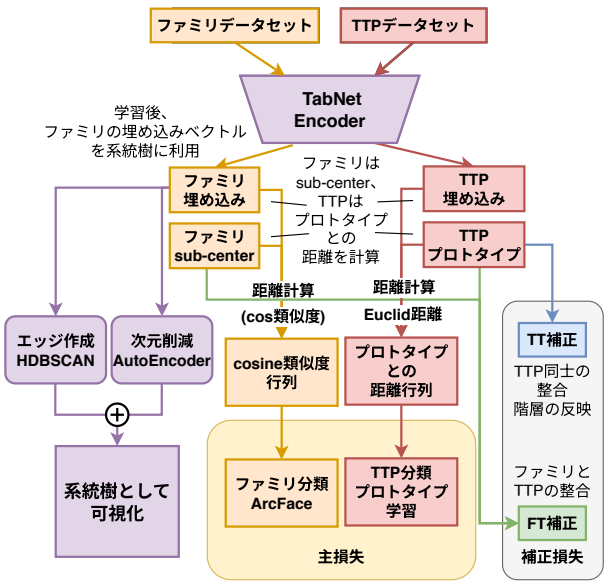


図 1　M-STRAINER の概要
Fig. 1　Overview of M-STRAINER.

空間を補正する．これにより，既知検体の大域的な系統・機能の意味的整合性を強め，より自然に解釈できる系統樹を実現する．

図 1 に全体像を示す．表層情報を共有 TabNet Encoder へ入力し，ArcFace のファミリ分類とプロトタイプ学習の TTP 分類を同時に行い，補正損失でファミリと TTP の sub-center および sub-prototype の関係を補正する．学習後，共有 Encoder の出力（以後「埋め込み」）を 3 次元へ圧縮し，近接関係をエッジとする系統樹を構成する．

3.2　マルチタスク学習

マルチタスク学習で，ファミリの系統的まとまりと TTP の機能的まとまりを一つの検体間距離へ統合する．これにより，未知検体が既知ファミリから離れているかだけでなく，どの既知機能に近いかも同じ系統樹上で確認できる．学習には，ファミリ・TTP ラベルを持つファミリデータセット，および TTP ラベルを持つ TTP データセットを用いる．

損失関数の全体は次式で表される．

$$\mathcal{L}_{\text{all}} = \alpha_{\mathcal{F}}\mathcal{L}_{\mathcal{F}} + \alpha_{\mathcal{T}}\mathcal{L}_{\mathcal{T}} + \alpha_{\text{TT}}\mathcal{L}_{\text{TT}} + \alpha_{\text{FT}}\mathcal{L}_{\text{FT}} - \lambda_{\text{sp}}^{\mathcal{F}} M_{\mathcal{F}} - \lambda_{\text{sp}}^{\mathcal{T}} M_{\mathcal{T}}. \tag{1}$$

ここで，$\mathcal{L}_{\mathcal{F}}$ と $\mathcal{L}_{\mathcal{T}}$ はファミリと TTP の分類損失，$\mathcal{L}_{\text{TT}}$ と $\mathcal{L}_{\text{FT}}$ は後述する補正損失，α は各損失の重みである．$M_{\mathcal{F}}, M_{\mathcal{T}}$ は TabNet の疎な特徴選択を促す項であり，λ_{sp} はその重みである．

3.3　深層距離学習による主損失

主損失は，ファミリ・TTP 分類の損失である．共有 Encoder の埋め込み，ファミリの sub-center，TTP の sub-prototype を最適化し，ファミリと TTP の両方を反映した距離空間を形成する．図 2 の左にファミリ分類，右に TTP 分類を示す．

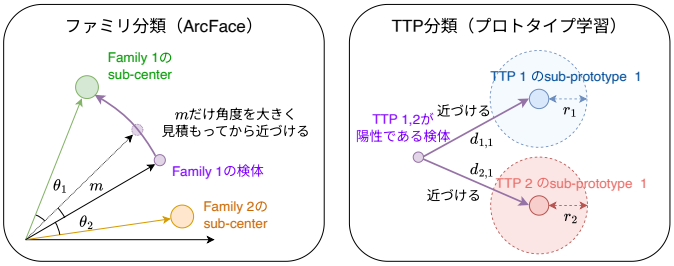


図 2　主損失によるファミリ分類（左）と TTP 分類（右）
Fig. 2　Family and TTP classification by the main loss.

3.3.1　ArcFace によるファミリ分類

ファミリ分類には Sub-center ArcFace を用いる [17], [18]．図 2 左に ArcFace の仕組みを示す．検体と正解ファミリで最も類似する sub-center との角度 θ_1 にマージン m を加え，見かけの角度を $\theta_1 + m$ へ広げる．この条件でも正解となるよう検体を sub-center へ近づけ，同一ファミリを凝集する．各ファミリの複数 sub-center により，亜種，バージョン，難読化方法などのファミリ内小集団も保持する．検体 i とファミリ c の類似度を $q_{i,c} = \max_h \hat{z}_i^{\mathcal{F}\top} \hat{W}_{c,h}^{\mathcal{F}}$ とする．正解クラスのロジットを $g_{i,y_i} = s\cos(\arccos q_{i,y_i} + m)$，その他を $g_{i,c} = s q_{i,c}$ として，分類損失を次式とする．

$$\mathcal{L}_{\mathcal{F}} = -\frac{1}{N_{\mathcal{F}}} \sum_{i=1}^{N_{\mathcal{F}}} \log \frac{\exp(g_{i,y_i})}{\sum_{c=1}^{C} \exp(g_{i,c})}. \tag{2}$$

ここで，$N_{\mathcal{F}}$ は検体数，y_i は正解ファミリ，$\hat{z}_i^{\mathcal{F}}$ は正規化した埋め込み，$\hat{W}_{c,h}^{\mathcal{F}}$ はファミリ c の h 番目の正規化済み sub-center，s はスケール係数である．

3.3.2　プロトタイプ学習による TTP 分類

TTP(Techniques) 分類には，代表点を基準とするプロトタイプ学習 [19] をマルチラベル問題へ適用する．図 2 右にプロトタイプ学習の仕組みを示す．TTP ごとに複数の sub-prototype を設け，同一機能の API や実装方法の違いを表現する．各 TTP $1, 2, \cdots$ に sub-prototype 中心の判定半径 $r_1, r_2, \cdots$ を設け，検体を各保有 TTP に対応する判定半径内へ近づける．検体 j と TTP t の距離を $d_{j,t} = \min_k \|\hat{z}_j^{\mathcal{T}} - \hat{W}_{t,k}^{\mathcal{T}}\|_2$，保有確率を $p_{j,t} = \sigma(\rho(r_t - d_{j,t}))$ とし，損失を次式とする．

$$\mathcal{L}_{\mathcal{T}} = -\frac{1}{N_{\mathcal{T}} T} \sum_{j=1}^{N_{\mathcal{T}}} \sum_{t=1}^{T} \big[y_{j,t} \log p_{j,t} + (1 - y_{j,t}) \log(1 - p_{j,t}) \big]. \tag{3}$$

ここで，$N_{\mathcal{T}}$ は検体数，T は TTP 数，$y_{j,t}$ は TTP の有無，$\hat{z}_j^{\mathcal{T}}$ は正規化した埋め込み，$\hat{W}_{t,k}^{\mathcal{T}}$ は TTP t の k 番目の正規化済み sub-prototype，r_t は判定半径，ρ はスケール係数，σ は Sigmoid 関数である．

© 2026 Information Processing Society of Japan

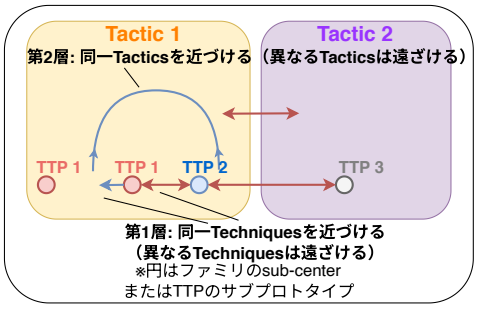


図 3 HMCE による TT 補正
Fig. 3 TT correction using HMCE.

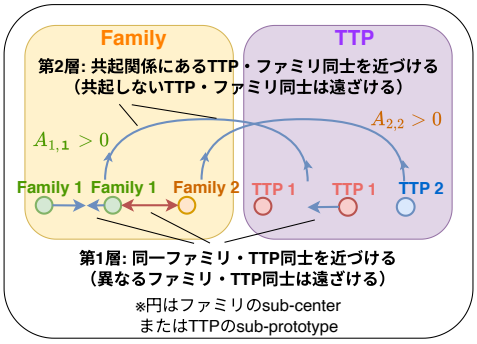


図 4 HMCE による FT 補正
Fig. 4 HMCE FT correction.

3.4 HMCE によるファミリ分類と TTP 分類の補正

主損失だけでは，分類が正しくても TTP 間の意味的な近さやファミリ–TTP の対応が距離へ反映されるとは限らない．そこで，第 1 層（強い関係）を包含する第 2 層（弱い関係）より優先する HMCE（Hierarchical Multi-label Constraint Enforcing）[20] を TT・FT 補正に用い，分類精度を保って既知知識に沿う空間へ補正する．

正規化済み sub-center と sub-prototype，二値マスク M から求める温度 τ の教師あり対照損失を $\mathcal{C}(M;\tau)$ とし，二層の HMCE を次式で表す．

$$\mathcal{H}(M^{(1)}, M^{(2)}) = \frac{1}{2}\sum_{\ell=1}^{2} 2^{1/\ell} \max_{1\le q\le \ell} \mathcal{C}(M^{(q)};\tau). \qquad (4)$$

ここで，$M^{(1)}, M^{(2)}$ は関係の第 1，第 2 層を表す二値マスクで，$M^{(2)}$ は $M^{(1)}$ を包含し，τ は温度係数である．$\mathcal{C}$ は同じマスクで結ばれた sub-center または sub-prototype を近づけ，それ以外を遠ざける．内側の最大値により，強い関係の損失を弱い関係の下限とする．

3.4.1 TTP ラベル間の補正（TT 補正）

TT 補正は，TTP 間の関係性を「同一 TTP」と「共通の攻撃目的」の階層で表現する．図 3 の第 1 層の強い関係では同じ TTP の sub-prototype 同士を近づけ，第 2 層の弱い関係では共通 Tactic に属する TTP 同士を加える．複数 Tactic を持つ TTP には全所属関係を用いる．階層化により TTP の差と共通の攻撃目的を距離へ反映し，既知 TTP と一致しない未知検体も近傍から攻撃目的を推測しやすくする．二層のマスクを $M_{\mathcal{T}}^{(1)}, M_{\mathcal{T}}^{(2)}$ として，損失を

$$\mathcal{L}_{\mathrm{TT}} = \mathcal{H}\left(M_{\mathcal{T}}^{(1)}, M_{\mathcal{T}}^{(2)}\right) \qquad (5)$$

とする．$M_{\mathcal{T}}^{(1)}$ は同一 TTP，$M_{\mathcal{T}}^{(2)}$ は同一 TTP または共通 Tactic を表すマスクである．

3.4.2 ファミリと TTP の空間同期補正（FT 補正）

FT 補正は，別々のデータセットで学習するファミリと TTP の関係を同期する．図 4 の第 1 層の強い関係では，同一ファミリの sub-center 同士と同一 TTP の sub-prototype 同士を近づける．ここで，ファミリ c に属する検体集合を $\mathcal{I}_c = \{i \mid y_i^{\mathcal{F}} = c\}$，検体 i に TTP t が付与されているとき 1 となる二値ラベルを $a_{i,t}^{\mathcal{F}}$ とし，共起率を $A_{c,t} = |\mathcal{I}_c|^{-1}\sum_{i\in\mathcal{I}_c} a_{i,t}^{\mathcal{F}} \in [0,1]$ と定義する．第 2 層の弱い関係では，$A_{c,t} > 0$，すなわち一度以上共起したファミリ c–TTP t を加える．これにより TTP をファミリの機能的特徴として結びつけ，機能の変化・共有を系統樹上の距離で把握できる．二層のマスクを $M_{\mathcal{FT}}^{(1)}, M_{\mathcal{FT}}^{(2)}$ として，損失を

$$\mathcal{L}_{\mathrm{FT}} = \mathcal{H}\left(M_{\mathcal{FT}}^{(1)}, M_{\mathcal{FT}}^{(2)}\right) \qquad (6)$$

とする．$M_{\mathcal{FT}}^{(1)}$ は同種かつ同一ラベル，$M_{\mathcal{FT}}^{(2)}$ はその関係または共起するファミリ–TTP を表すマスクである．

3.5 次元削減およびクラスタリング

学習した埋め込みを，検体間関係を保つ線形 Auto Encoder で 3 次元化し，HDBSCAN で密度クラスタを抽出する [10], [21]．HDBSCAN はクラスタ数の事前指定が不要で，既知群に属しにくい検体をノイズとして扱えるため，ファミリ数が未知で新種を含む分析に適する．最後に，HDBSCAN の階層的な隣接関係に基づき検体間へエッジを張り，3 次元の系統樹として可視化する．

4. 系統樹の基本性能の評価

本章では，新規検体の分析に用いる系統樹の基本性能として，近傍関係にファミリと TTP の情報が反映されるか，既知検体が解釈可能なまとまりを形成するかを評価する．前者は分類性能とアブレーション，後者は系統樹のクラスタ構造と既知ラベルとの対応から検証する．

4.1 実験に用いるデータセット

FFRI Malware Family and Version Dataset（FMFV Dataset）と，MWS Datasets に含まれる Soliton Dataset を用いた [10], [22]．入力は数値，文字列中の単語出現回数，配列の長さ・平均値・標準偏差・最大値・最小値からなる共通の 3,027 次元表層特徴量とした．

© 2026 Information Processing Society of Japan

ファミリデータセットには，ファミリ・バージョン・TTP の各ラベルを持つ FMFV Dataset を用いた．ファミリ・バージョンラベルは手動で付与し，TTP ラベルは各検体から CAPA で収集した．対象は Agent Tesla，Emotet，Petya，Xloader など 19 ファミリ 2,102 検体である．TTP データセットには Soliton Dataset の 2020–2022 年分を用い，Cuckoo Sandbox の動的解析ログから抽出した 35 種の Technique の有無を 35 次元のマルチラベルで表した．

4.2 評価方法

系統樹上の近傍から系譜・機能の類似性を読み取るには，埋め込み近傍に同一ファミリまたは同一 TTP の検体が必要である．そこで，ファミリデータセットの層化 10 分割交差検証を行い，埋め込みの k 近傍法によるファミリ・TTP 分類の Precision，Recall，F1 score の Micro 平均と Macro 平均を算出した．

アブレーションでは，ファミリまたは TTP のシングルタスク，両分類損失によるマルチタスク，これに TT または FT 補正を加えたモデル，両補正を加えた M-STRAINER を比較した．距離学習の効果は，以下のベースラインとも比較した．

4.2.1 ベースラインモデル

ベースラインでは，検体間の距離を直接制約する距離学習は用いない．ファミリ分類損失を Softmax 交差エントロピー，TTP 分類損失をロジットの二値交差エントロピーへ置き換え，TT・FT 補正を削除した．その他のハイパーパラメータは同一とし，埋め込み空間上の k 近傍法で評価した．

4.3 分類性能とアブレーション実験

表 1 に 10 分割交差検証の平均性能を示す．太字は各指標の最大値で，F1，R，P は F1 score，Recall，Precision を表す．単一ラベルのファミリ分類では Micro Recall と Micro Precision が Micro F1 と同値のため省略した．

M-STRAINER は 10 指標中 7 指標で最大だった．他のファミリ Macro F1・Recall と TTP Macro Recall はマルチタスク+FT が最大だが，差は 0.006–0.010 に留まり，全アブレーションに対して包括的に高かった．ベースラインにはすべての指標で上回った．ファミリ・TTP の Micro F1 は 0.801・0.702 で，ベースラインを 0.043・0.042 上回った．距離学習と階層的補正により，近傍から系譜と機能の両方を読み取れる距離空間が形成されたと考えられる．

4.4 出力された系統樹

10 分割交差検証の第 1 分割で学習した M-STRAINER へ，ファミリデータセットの学習データを入力して得た系統樹を図 5 に示す．

新規検体の接続先から系譜・機能の候補を得て，既知群に属するかを判断するには，基盤となる既知検体の近傍関係がクラスタとして整理されている必要がある．そこで，既知検体がクラスタとして接続され，まとまりとして分離されているかを基本統計から確認する．表 2 に全 1,891 検体の HDBSCAN 統計を示す．クラスタ数・平均サイズは分割粒度，ノイズ率は既存クラスタへの未接続検体率，シルエット係数は凝集・分離性を −1 から 1 で表し，後者は 1 に近いほどよい．クラスタ数・平均サイズだけでは良否を決められないが，M-STRAINER はノイズ率を 0.225 から 0.144 へ抑え，シルエット係数を 0.641 から 0.749 へ高めた．平均サイズも大きく，より多くの既知検体を凝集・分離性のあるまとまりとして接続できた．

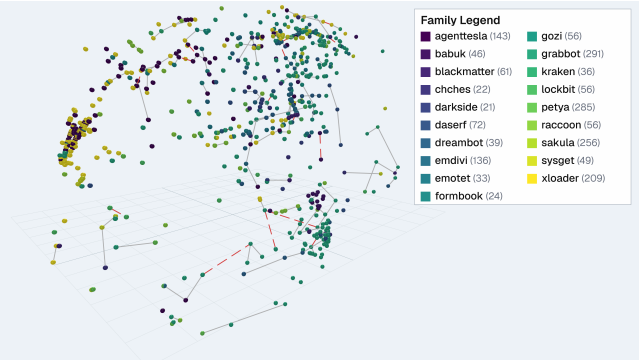


図 5 M-STRAINER で出力された系統樹
Fig. 5 Lineage tree output by M-STRAINER.

次に，形成されたまとまりが系譜として解釈できるかを，既知ラベルとの対応から評価した．各ノイズ点を単独クラスタとした結果を表 3 に示す．V-measure は均質性・完全性の調和平均，ARI は偶然補正後のラベル一致度，FMI は検体対の適合率・再現率の幾何平均で，いずれも大きいほど既知ラベルと整合する．

M-STRAINER は両粒度の全指標でベースラインを上回り，クラスタが既知のファミリおよびバージョンとより整合した．基本統計と合わせると，多くの既知検体を解釈可能なまとまりへ接続しつつ，ファミリ内の細かな系統も保持している．したがって，新規検体の接続有無と接続先を系譜・機能の観点から解釈するための基盤となる系統樹を形成できた．

5. 系統樹の活用

本章では，系統樹に配置した新規検体の未知ファミリ検出と TTP 除外時の検知傾向，時間経過に伴う特徴量重要度・近傍関係の変化を分析し，初期トリアージと Concept Drift 把握への活用を検討する．

5.1 新種検知

5.1.1 評価方法

M-STRAINER の HDBSCAN による近似予測で，新規

© 2026 Information Processing Society of Japan

表 1　ファミリおよび TTP 分類性能の 10 分割交差検証平均
Table 1　10-fold CV means for family and TTP classification.

モデル	ファミリ分類				TTP 分類					
	$F1_{micro}$	$F1_{macro}$	R_{macro}	P_{macro}	$F1_{micro}$	R_{micro}	P_{micro}	$F1_{macro}$	R_{macro}	P_{macro}
ファミリシングルタスク	0.747	0.647	0.651	0.673	0.638	0.623	0.664	0.417	0.421	0.450
TTP シングルタスク	0.757	0.656	0.661	0.692	0.666	0.621	0.718	0.448	0.414	0.516
マルチタスク	0.793	0.728	0.738	0.749	0.684	0.645	0.730	0.464	0.438	0.528
マルチタスク+TT	0.775	0.707	0.711	0.741	0.688	0.650	0.734	0.457	0.428	0.524
マルチタスク+FT	0.793	**0.734**	**0.740**	0.758	0.682	0.651	0.719	0.472	**0.450**	0.526
M-STRAINER（TT+FT，提案法）	**0.801**	0.728	0.730	**0.763**	**0.702**	**0.656**	**0.757**	**0.474**	0.443	**0.542**
ベースライン	0.758	0.675	0.682	0.702	0.660	0.612	0.717	0.442	0.407	0.516

表 2　各モデルのクラスタリングに関する基本統計
Table 2　Basic clustering statistics for each model.

モデル	クラスタ数	ノイズ率	平均サイズ	シルエット係数
M-STRAINER	**202**	**0.144**	**8.010**	**0.749**
ベースライン	249	0.225	5.888	0.641

表 3　既知ラベルに対するクラスタリングの外部評価
Table 3　External clustering evaluation against known labels.

モデル	ファミリ			ファミリ／バージョン		
	V-measure	ARI	FMI	V-measure	ARI	FMI
M-STRAINER	**0.619**	**0.354**	**0.476**	**0.749**	**0.606**	**0.648**
ベースライン	0.574	0.163	0.305	0.726	0.323	0.430

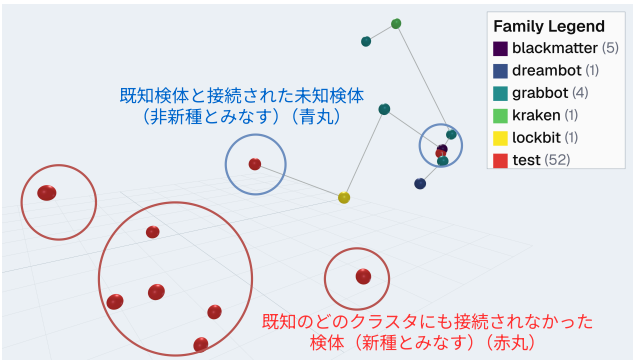


図 6　M-STRAINER で出力された系統樹における新種検知の例
Fig. 6　Novelty detection on an M-STRAINER lineage tree.

検体を学習済み系統樹へ投入し，既存クラスタに接続しないものを新種とした．

図 6 に新種検知の例を示す．青い囲い円の検体は既知検体と接続するため新種でないとみなし，既知クラスタに接続せず孤立する赤い囲い円の検体を新種とみなす．

新種の単位は，ファミリ評価ではファミリ，TTP 評価では TTP ラベルの組み合わせとした．前者では全 19 ファミリを 1 つずつ除外し，残る 18 ファミリで学習した．後者では全 1,356 検体をラベル構成で集約し，評価対象 TTP が学習データに残らないよう検体を除外した．除外後も 600 検体以上で学習できる 34 組，計 69 検体を評価した．以後，後者を「TTP グループ評価」と呼ぶ．

5.1.2　ファミリ別の検知傾向

表 4 に示すように，ファミリでは 2,102 検体中 1,312 検体を新種と判定し，Micro・Micro 平均共に 60%を超えた．

表 4　未知ファミリおよび未知 TTP の新種検知率
Table 4　Novelty detection rates for unknown families and TTPs.

対象	新種数/検体数	Macro 平均	Micro 平均
ファミリ	1,312/2,102	65.8%	62.4%
TTP グループ	50/69	70.1%	72.5%

表 5　ファミリ別の新種検知率
Table 5　Novelty detection rates by malware family.

ファミリ	検知率	ファミリ	検知率	ファミリ	検知率
agenttesla	45.9%	emdivi	80.1%	lockbit	63.5%
babuk	96.2%	emotet	70.3%	petya	32.6%
blackmatter	65.7%	formbook	14.8%	raccoon	90.3%
chches	76.0%	gozi	56.5%	sakula	90.9%
darkside	95.7%	grabbot	64.1%	sysget	77.8%
daserf	26.3%	kraken	80.0%	xloader	55.4%
dreambot	67.4%				

表 6　新種と判定されなかった主要ファミリ検体の主な接続先
Table 6　Major destinations for family samples not detected as novel.

ファミリ	接続先ファミリ	接続数	割合
AgentTesla	XLoader	72	83.7%
	Kraken	7	8.14%
	FormBook	6	6.98%
BlackMatter	DarkSide	22	95.7%
	Grabbot	1	4.35%
FormBook	XLoader	23	100%
Petya	Grabbot	213	100%

ファミリ別の新種検知率を表 5 に示す．Babuk は 96.2%，DarkSide は 95.7%，Sakula は 90.9%と高く，大部分が既知ファミリから分離された．一方，FormBook は 14.8%，Daserf は 26.3%，Petya は 32.6%と低く，ファミリ間で検知傾向が異なる．

表 6 に，非新種判定された評価検体の接続先を示す．FormBook の全 23 検体は，後継でコード・情報窃取機能も類似する XLoader へ接続した [23], [24]．BlackMatter も 23 検体中 22 検体が，技術的に類似する DarkSide へ接続した [25]．AgentTesla も 83.7%が XLoader，6.98%が FormBook へ接続し，いずれも情報窃取型である [23]．よって検知率は 6 割程度でも，非新種判定から妥当な解析の手掛かりを得られる．一方，Petya の既知接続 213 検体はす

© 2026 Information Processing Society of Japan

表 7　代表的な TTP グループの新種検知率と主な接続先

Table 7　Novelty detection rates and major destinations for representative TTP groups.

グループ	主な TTP 構成	新種数/検体数	検知率	主な接続先（割合）
01	T1053 等 5 種	11/11	100%	–
02	T1129，T1083，T1057	8/8	100%	–
03	T1057	3/6	50.0%	Software Packing（100%）
04	T1129 等 10 種	0/4	0.00%	Software Packing（100%）
07	T1031 等 10 種	3/3	100%	–
08	T1053	3/3	100%	–
09	T1129	1/3	33.3%	Software Packing（100%）

べて目的が異なる Grabbot へ接続された [26], [27]．したがって接続先を系譜関係と断定せず，解析初期の候補として扱う必要がある．

5.1.3　TTP グループ別の検知傾向

表 4 に示すように，TTP グループでは 69 検体中 50 検体を新種と判定し，Macro・Micro 平均共に 70%を超えた．検体数が多い，または比較上重要なグループの検知率・接続先を表 7 に示す．TTP 構成は Technique ID で略記する．

グループ 01，02 の全 19 検体と，グループ 07，Scheduled Task のみの 08 を全検知した．したがって，TTP 数によらず新種を検知できると考えられる．

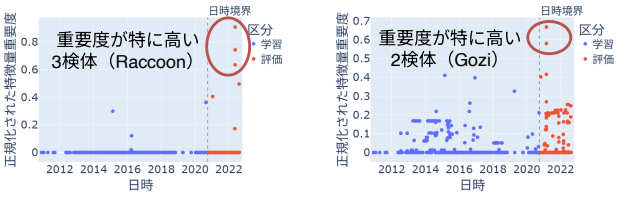
グループ 04 と 07 は 10 種中 9 種の TTP が共通するが，04 だけが Execution through Module Load，07 だけが Modify Existing Service を含み，検知率は 0.00%と 100%であった．共通 9 種だけでなく，異なる TTP を含む構成全体が距離空間へ反映され，類似グループ間の差を捉えた可能性がある．

非新種判定されたグループ 03，04，09 の接続先を既知側から分析すると，すべて Software Packing を持っていた．評価群に同 TTP はないが，Packing と共通・相関する実装特徴が近傍形成に影響した可能性があり，既知の接続先が共通実装特徴を調べる手掛かりとなる．

5.2　Concept Drift

本稿では Concept Drift を，攻撃者が時間とともにマルウェアの実装や機能を変化させ，分類の判断根拠や既知検体との系統的・機能的な関連性が学習時から変わる現象とする．共有 Encoder に用いている TabNet は，疎な特徴選択マスクから，各検体の判断で重視した入力特徴をローカル特徴量重要度として出力できる（以下，重要度）[28]．重要度の時間変化から兆候を抽出し，該当検体の配置・近傍関係を系統樹上で確認して，複数検体に共通する変化を捉える．

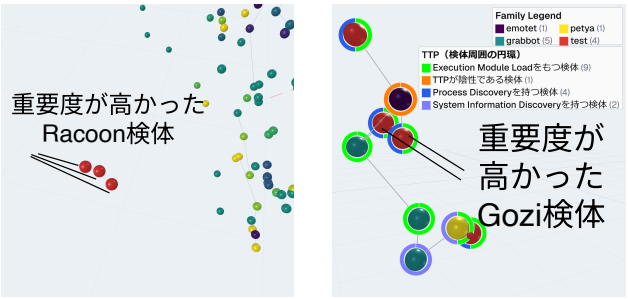
VirusTotal の初観測日時に基づき，2020 年 10 月 1 日より前を学習，同日以降を評価データとした．ファミリデータセットは学習 1,403 検体・評価 699 検体，TTP データセットは学習 956 検体・評価 402 検体である．以下では，ファミリデータセットで学習した TabNet の重要度を検体ごとに正規化し，判断根拠の時間変化を観察する．



(c) relocation 情報の要素数　　(d) マニフェスト情報

図 7　代表的な特徴量における正規化ローカル重要度の時間変化

Fig. 7　Temporal changes in normalized local importance of representative features.



(a) Raccoon 検体の分布　　(b) Gozi 検体を含むクラスタ

図 8　高い重要度を示した検体の系統樹上の分布

Fig. 8　Lineage distributions of samples with high local importance.

図 7 に，Concept Drift が疑われた特徴量の重要度推移を示す．マニフェスト情報や relocation 情報の要素数を示す特徴量で高い重要度が現れた．学習期間と評価期間でモデルが重視する特徴の違いから，Concept Drift の発生が示唆される．

relocation 情報の要素数で重要度が高い Raccoon 3 検体は，図 8(a) のように互いに近接し，既存群から離れてまとまった．評価期間に共通する構造変化が重要度と検体間距離に反映され，判断根拠と系統樹上の配置が整合した可能性がある．3 検体はいずれも Raccoon v2.0 で，2022 年 5 月 19 日前後に VirusTotal へ初めて投稿された．Gen Digital も同年 5 月から新検体を観測し，v2 は従来版より小型で簡素と報告した [29]．本結果は v2 の実装変化を捉えた可能性がある．

マニフェスト情報で高重要度の Gozi 2 検体は図 8(b) の同一クラスタに属する．本クラスタの TTP を分析すると，Execution through Module Load が学習・評価期間の全検体に共通する一方，Process Discovery は評価検体にのみ観測された．共通機能を持つクラスタ内で評価期間の検体に Process Discovery が集中し，機能変化を捉えた可能性がある．以上より，重要度の時間変化と系統樹上の配置・近傍関係から，時間に伴う実装・機能変化を発見できる可能性が示された．

© 2026 Information Processing Society of Japan

6. おわりに

本稿では，ファミリと TTP を反映した検体間距離を学習し，新種検知と Concept Drift の把握を可能にする系統樹作成手法 M-STRAINER を提案した．評価では，未知検体を既知検体から分離し，近隣検体から系譜や機能の類似性を解釈できた．また，時系列の分布変化を系統樹上で可視化できる可能性を示した．今後は，接続関係の解釈性を高め，異なる収集時期へ評価を拡張し詳細な検証へ繋げる．

参考文献

[1] Monnappa K A. **初めてのマルウェア解析**. 株式会社オライリージャパン, 2020. 石川 朝久 訳, 北原 憲, 中津留 勇 技術監修.

[2] Md Karim et al. Malware phylogeny generation using permutations of code. *Journal in Computer Virology*, 1:13–23, 11 2005.

[3] Emanuele Cozzi et al. The tangled genealogy of iot malware. In *Proceedings of the 36th Annual Computer Security Applications Conference*, ACSAC '20, page 1–16, New York, NY, USA, 2020. Association for Computing Machinery.

[4] Tianxiang He et al. Scalable and fast algorithm for constructing phylogenetic trees with application to iot malware clustering. *IEEE Access*, 11:8240–8253, 2023.

[5] Jiyong Jang et al. Towards automatic software lineage inference. In *22nd USENIX Security Symposium (USENIX Security 13)*, pages 81–96, Washington, D.C., August 2013. USENIX Association.

[6] Irfan Ul Haq et al. Malware lineage in the wild. *Computers & Security*, 78:347–363, 2018.

[7] Martina Lindorfer et al. Lines of malicious code: Insights into the malicious software industry. In *Proceedings of the 28th Annual Computer Security Applications Conference*, ACSAC '12, page 349–358, New York, NY, USA, 2012. Association for Computing Machinery.

[8] Jing Liu et al. Having an insight into malware phylogeny: Building persistent phylogeny tree of families. *IEICE TRANSACTIONS on Information and Systems*, 101(4):1199–1202, 2018.

[9] Huanran Wang et al. An evolutionary study of iot malware. *IEEE Internet of Things Journal*, 8(20):15422–15440, 2021.

[10] 池澤 隆人 ほか. マルチタスク学習による表層情報を軸としたマルウェアの系統樹の作成手法の提案. In **コンピュータセキュリティシンポジウム** *2023* **論文集**, pages 49–56, oct 2023.

[11] Leo Hyun Park et al. Birds of a feature: Intrafamily clustering for version identification of packed malware. *IEEE Systems Journal*, 14(3):4545–4556, 2020.

[12] Yuhan Chai et al. Malfscil: A few-shot class-incremental learning approach for malware detection. *IEEE Transactions on Information Forensics and Security*, 20:2999–3014, 2025.

[13] Antonino Vitale et al. Family ties: A close look at the influence of static features on the precision of malware family clustering. In *2025 APWG Symposium on Electronic Crime Research (eCrime)*, page 1–13, November 2025. ISSN: 2159-1245.

[14] Liuting Wang et al. Rl4mal: Representation learning-based malware classification under long-tailed distribution. In *Proceedings of the 2025 2nd International Conference on Computer Network and Cloud Computing*, CNCC '25, page 41–51, New York, NY, USA, 2025. Association for Computing Machinery.

[15] Jingcai Guo et al. Conservative novelty synthesizing network for malware recognition in an open-set scenario. *IEEE Transactions on Neural Networks and Learning Systems*, 34(2):662–676, 2023.

[16] Piotr Białczak et al. Malware classification using open set recognition and http protocol requests. In Gene Tsudik, Mauro Conti, Kaitai Liang, and Georgios Smaragdakis, editors, *Computer Security – ESORICS 2023*, pages 235–254, Cham, 2024. Springer Nature Switzerland.

[17] Jiankang Deng et al. Arcface: Additive angular margin loss for deep face recognition. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 44(10):5962–5979, October 2022.

[18] Jiankang Deng et al. Sub-center arcface: Boosting face recognition by large-scale noisy web faces. In Andrea Vedaldi, Horst Bischof, Thomas Brox, and Jan-Michael Frahm, editors, *Computer Vision – ECCV 2020*, pages 741–757, Cham, 2020. Springer International Publishing.

[19] Jake Snell et al. Prototypical networks for few-shot learning. In *Advances in Neural Information Processing Systems*, volume 30, pages 4077–4087, 2017.

[20] Shu Zhang et al. Use all the labels: A hierarchical multi-label contrastive learning framework. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 16660–16669, 2022.

[21] Leland McInnes et al. hdbscan: Hierarchical density based clustering. *Journal of Open Source Software*, 2(11):205, 2017.

[22] 寺田 真敏 ほか. マルウェア対策のための研究用データセット mws datasets ～コミュニティへの貢献とその課題～. In **研究報告情報基礎とアクセス技術** *(IFAT)*，*Vol. 2020, No. 8*, pages 1–6, 2020.

[23] LAC サイバー救急センター. AgentTesla の解析. `https://www.lac.co.jp/lacwatch/report/20220307_002893.html`. (Accessed: 2025-08-06).

[24] Check Point Research. Stealth is never enough, or revealing formbook successor's c&c infrastructure, 2021. `https://research.checkpoint.com/2021/stealth-is-never-enough-or-revealing-formbook-successors-cc-infrastructure/` (Accessed: 2026-08-03).

[25] Mark Loman. Blackmatter ransomware emerges from the shadow of darkside, 2021. `https://www.sophos.com/en-us/blog/blackmatter-ransomware-emerges-from-the-shadow-of-darkside` (Accessed: 2026-08-03).

[26] Proofpoint. Petya と NotPetya. `https://www.proofpoint.com/jp/threat-reference/petya`. (Accessed: 2025-08-06).

[27] David Wang et al. Grabbot is back to nab your data, 2017. `https://www.fortinet.com/blog/threat-research/grabbot-is-back-to-nab-your-data` (Accessed: 2026-08-10).

[28] Sercan O. Arik et al. Tabnet: Attentive interpretable tabular learning. *Proceedings of the AAAI Conference on Artificial Intelligence*, 35(8):6679–6687, 2021.

[29] Gen Digital Threat Research Team. Avast q2/2022 threat report. `https://www.gendigital.com/blog/insights/reports/avast-q22022-threat-report`, 2022. (Accessed: 2026-08-17).

© 2026 Information Processing Society of Japan