NPU搭載エッジデバイスによるマルウェア検知と分布外データ検出

野木 一利[1,a)]　満保 雅浩[1]

概要：クラウドサービスやリモートワークの普及によりネットワーク境界が曖昧化し，従来の境界型防御のみでは十分な対策が困難となり，エンドポイントでのマルウェア検知の重要性が高まっている．機械学習によるオンデバイスマルウェア検知では，未知ファミリへの対応と，限られた計算資源での高速かつ省電力な推論が求められる．本論文では，Neural Processing Unit（NPU）による量子化推論と分布外（OOD）データ検出を組み合わせたマルウェア検知を評価する．MaleVis の 20 種類のマルウェアファミリと良性クラスを分布内データ（ID），5 種類のファミリを OOD データとし，VGG16，ResNet50，MobileNetV2 の CPU による FP32 推論と NPU による INT8 推論を比較するとともに，MSP，GEN，KNN，NNGuide の量子化耐性を検証する．その結果，VGG16 と ResNet50 は量子化後も分類性能をほぼ維持し，KNN は最も一貫した OOD 検出性能を示す．さらに，量子化 VGG16 と KNN による ID/OOD 混在環境では，正解率 0.8260，マクロ F1 0.7835 を達成し，CPU 実行比で推論を約 15.3 倍高速化し，エネルギー消費量を 91.2%削減できることを示す．以上より，適切な量子化モデルと OOD 検出手法の選択により，NPU 搭載デバイス上で未知クラスを考慮したマルウェア検知を効率的に実行可能である．

キーワード：マルウェア検知，ニューラル・プロセッシング・ユニット，分布外データ検出，量子化

Malware Classification and Out-of-Distribution Detection on Edge Devices Equipped with NPU

Kazutoshi Nogi[1,a)]　Masahiro Mambo[1]

Abstract: Cloud services and remote work have blurred network boundaries, reducing the effectiveness of perimeter-based security. On-device malware detection requires detection of unseen families and fast, energy-efficient inference with limited resources. This paper evaluates on-device malware detection combining quantized inference on a Neural Processing Unit (NPU) with out-of-distribution (OOD) detection. Using MaleVis, 20 malware families and a benign class are used as in-distribution (ID) data and five families as OOD data. We compare CPU FP32 and NPU INT8 inference for VGG16, ResNet50, and MobileNetV2, and evaluate the quantization robustness of MSP, GEN, KNN, and NNGuide. VGG16 and ResNet50 mostly maintain classification performance after quantization, while KNN shows the most consistent OOD performance. In a mixed ID/OOD setting, quantized VGG16 with KNN achieves 0.8260 accuracy and 0.7835 macro-F1, with 15.3 × faster inference and 91.2% lower energy consumption than CPU inference. These results show that suitable quantized models and OOD detection methods enable efficient malware detection of unknown classes using an NPU-assisted configuration.

Keywords: malware detection, neural processing unit, out-of-distribution detection, quantization

1. はじめに

クラウドサービスやリモートワークの普及によりネット

[1] 金沢大学
Kanazawa University
[a)] n-kazutoshi@stu.kanazawa-u.ac.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

ワーク境界が曖昧化し，従来の境界型防御のみでは十分なセキュリティ対策が困難となっている．そのため，攻撃の侵入先となるエンドポイント端末において脅威を検知し，防御することの重要性が高まっている．特に，マルウェアによる被害を防ぐためには，エンドポイント端末上で迅速かつ高精度にマルウェアを検知することが求められる．従来のシグネチャベース手法は既知の検体には有効であるが，未知検体の検知には限界があるため，特徴パターンを学習する機械学習ベースの手法が有用である．

一方，機械学習ベースのマルウェア検知を実環境で運用する上では二つの課題がある．第一の課題は，未知のマルウェアファミリの識別である．多くの分類器は，入力が学習済みクラスのいずれかに属するクローズドセット分類を前提とするため，学習時に観測されていない分布外（Out-of-Distribution: OOD）データも既知クラスに分類する可能性がある．そこで，既知ファミリに属する分布内（In-Distribution: ID）データと OOD データを識別し，未知の入力を既知クラスへ分類する前に棄却する OOD データ検出が必要となる．

第二の課題は，推論の実行環境である．深層学習モデルを遠隔サーバー上で実行する場合，通信遅延，データ送信に伴うプライバシー上のリスク，およびネットワーク接続への依存が生じる．そのため，エンドポイント端末上で推論を完結させることが望ましく，AI 推論に特化した Neural Processing Unit（NPU）は有望な実行基盤となる．産業界でも，Intel Threat Detection Technology における NPU の活用 [1] や，CrowdStrike と Intel の協業 [2] が進められている．

また，エンドポイント端末上のモデルは常に迅速に更新されるとは限らず，新たなマルウェアファミリを正しく検知できない可能性がある．OOD データ検出は，モデルを再学習する前に未知の入力を検出し，隔離または警告の対象とする手段となる．

さらに，バッテリー駆動の端末では消費エネルギーも重要となる．モデル量子化は，オンデバイス推論の計算量とメモリ使用量を削減できる一方，既知クラスの分類性能および OOD データ検出性能を低下させる可能性がある．

したがって，実用的なオンデバイスマルウェア検知には，NPU による効率的な推論，OOD データ検出による未知ファミリの識別，および量子化後の性能維持が必要である．本論文では，NPU を搭載したエッジデバイス上で OOD データ検出を組み合わせたマルウェア検知を実装し，検知性能と実行性能を評価する．本論文の主な貢献は以下のとおりである．

(1) CPU および NPU 上でのマルウェア検知について，検知性能，推論速度，およびエネルギー消費量を比較する．
(2) 複数の事後（post-hoc）OOD データ検出手法について，未知のマルウェアファミリに対する検出性能を評価する．
(3) 訓練後量子化（Post-Training Quantization: PTQ）が，マルウェア分類と OOD データ検出の双方に与える影響を定量的に評価する．

2. 関連研究

2.1 画像ベースのマルウェア分類

Nataraj ら [3] は，25 種類のマルウェアファミリのバイナリデータを符号なし 8 ビット整数として解釈し，二次元グレースケール画像へ変換したうえで，視覚的特徴量と k 近傍法分類器を用いて分類する画像ベースのマルウェア分類手法を提案している．この研究により，バイナリファイルに含まれる構造的なパターンを画像として表現し，機械学習を用いた画像分類手法を適用できることが示されている．

また，マルウェアの訓練データが限られている場合に分類性能を向上させるには転移学習が有効である．Shafai ら [4] は，ImageNet で事前学習された 8 種類の畳み込みニューラルネットワーク（Convolutional Neural Network: CNN）を，画像化したマルウェアデータセットを用いてファインチューニングする．彼らが評価したモデルの中では，VGG16 が最高となる 99.97%の分類精度を達成している．これらの研究により，画像ベースのマルウェア分類において事前学習済み CNN の有効性が示されている．一方で，その多くは，すべてのテストサンプルが学習時に観測されたクラスのいずれかに属することを前提としたクローズドセット分類を対象としている．

2.2 分布外データ検出

2.2.1 事後（Post-hoc）OOD データ検出

事後 OOD データ検出手法は，訓練済みのモデルを再学習することなく適用できる手法であり，分類部の出力値を用いるものや，中間層の特徴抽出部の値を用いるものなどがある．

分類器の出力値を用いる手法として，Hendrycks らは，ソフトマックス確率の最大値を ID 確信度とする Maximum Softmax Probability （MSP）を提案している [5]．また，Liu らの Generalized Entropy score（GEN）は，上位 M クラスの予測確率から一般化エントロピーに基づく確信度を算出する [6]．

中間特徴量を用いる手法として，Sun らは，入力の特徴量と ID 訓練データから構築した特徴量バンクとの第 k 近傍距離に基づく KNN を提案している [7]．さらに，Park らの Nearest Neighbor Guidance（NNGuide）は，分類部の出力から得られる基本確信度と中間特徴量との近傍類似度を組み合わせることで確信度を補正する [8]．

各手法により分類器出力や中間特徴量といった利用する

© 2026 Information Processing Society of Japan

値が異なるため，モデル量子化が OOD データ検出性能に与える影響も異なる可能性がある．

2.2.2 画像化マルウェア分類における OOD データ検出

従来のクローズドセット型のマルウェア分類は，入力が学習時に観測されていないファミリに属する場合であっても，既知ファミリのいずれかへ分類する．この問題に対して Sheneamer ら [9] は，ImageNet で事前学習させた MobileNetV2 を画像化したマルウェアデータでファインチューニングし，ソフトマックス層の確率値に対して閾値を設定して未知のマルウェアファミリを検出する手法を検討している．この研究は，CNN を用いた画像化したマルウェア分類に MSP による事後 OOD データ検出を組み合わせた事例である．しかし，この論文では MSP による検証しか行われていないため，他の事後 OOD データ検出手法との比較は行われていない．

2.3 オンデバイス AI でのマルウェア検知

エッジ端末上で深層学習モデルを効率的に実行する方法の一つにモデル量子化がある．量子化は，モデルの重みや活性化値を FP32 から INT8 などの低ビット表現へ変換することで，メモリ使用量と演算負荷を削減する．量子化には，訓練時に量子化誤差を考慮する量子化意識訓練（Quantization-Aware Training, QAT）と，学習済みモデルへ適用する訓練後量子化（Post-Training Quantization, PTQ）がある．PTQ は再学習を必要としない一方，量子化誤差によってモデル性能が低下する可能性がある [10]．

マルウェア検知への適用例として，Chaudhary らの RealMalSol は，特徴量削減と INT8 PTQ を組み合わせ，Android 端末上で 96.40%の分類精度を維持しながら，CPU 消費電力と処理時間を削減している [11]．ただし，その評価は既知クラスの分類を対象としており，量子化が未知マルウェアの検出性能に与える影響は検証されていない．

さらに，NPU は行列演算や畳み込み演算に特化したアクセラレータであり，エッジ端末上での低遅延かつ省電力な AI 推論に利用できる．Agada らは，Qualcomm Snapdragon 8 Gen 2 の NPU 上で INT8 量子化 ResNet で画像ベースのマルウェア分類を実行し，モデル容量を約 75%削減するとともに，97.47%の分類精度と 1 ms の推論レイテンシを達成している [12]．一方，この研究は Windows マルウェアを画像化したデータを Android 端末上で評価しており，未知クラスを含む環境や量子化後の OOD データ検出性能は対象としていない．

以上の研究は，PTQ および NPU によるオンデバイスマルウェア分類の効率化を示しているが，量子化が既知クラスの分類と OOD データ検出の双方に与える影響や，両者を組み合わせたマルウェア検知システムの性能は十分に明らかにされていない．

2.4 本研究の位置付け

既存研究では，画像ベースのマルウェア分類への OOD データ検出の導入や，PTQ および NPU によるオンデバイス推論の効率化が個別に検討されている．しかし，マルウェア分類における OOD データ検出の研究は MSP など一部の手法に限られており，量子化が分類器出力および中間特徴量を用いる各手法の検出性能に与える影響は十分に明らかにされていない．また，従来のオンデバイスマルウェア検知は主に既知クラスの分類を対象としており，未知クラスを含む環境での検知性能や実行速度およびエネルギー消費量を統合的に評価した例は限られている．

そこで本論文では，画像ベースのマルウェア検知において，CNN モデルの FP32 モデルと INT8 PTQ モデルを比較するとともに，MSP，GEN，KNN，および NNGuide の量子化前後の OOD データ検出性能を評価する．さらに，量子化 CNN と OOD データ検出を組み合わせたマルウェア検知システムを構築し，ID/OOD 混在データに対する検知性能と，CPU・NPU 実行時の速度およびエネルギー消費量を評価する．

3. 検証方法

本論文では，NPU を用いた画像ベースのマルウェア検知に OOD データ検出を組み込んだシステムの有効性を評価するために以下の 3 つの検証を行う．

検証 1 NPU 実行時と CPU 実行時の通常マルウェア分類性能の比較

検証 2 量子化モデルに対して各 OOD データ検出手法を適用した場合の未知マルウェアファミリ検出性能の比較

検証 3 量子化モデルによるマルウェア分類と OOD データ検出を組み合わせた未知クラスを考慮したマルウェア検知システムの評価

3.1 マルウェア分類モデル

本論文で使用する CNN モデルは，関連研究で使用されていたアーキテクチャ（VGG，ResNet，MobileNet）である．VGG16 は 3×3 畳み込み層を積み重ねた規則的な構造を持ち [13]，ResNet50 は深層化を容易にする残差接続を採用している [14]．MobileNetV2 は，Depthwise Separable Convolution, Inverted Residual, および Linear Bottleneck を用いて計算量を削減したモバイル端末向けの軽量モデルである [15]．

これらすべてのモデルについて，元の最終分類層を独自の分類ヘッドに置き換える．この分類ヘッドには，過学習を抑制するためにバッチ正規化層およびドロップアウト層を導入し，512 次元の中間層を設ける．大規模自然画像データセットで事前学習された重みで初期化し，各モデルの全層を対象とするファインチューニングを実行し，正解

© 2026 Information Processing Society of Japan

率が最も高いエポックの重みを保存する．

3.2 モデル量子化

本論文では，訓練済みの FP32 モデルに対して，INT8 の PTQ を適用する．PTQ は，モデルを再訓練することなく，重みおよび活性化値を FP32 から INT8 へ変換する．量子化には，訓練用 ID データから抽出したキャリブレーションデータを用いる．

量子化前後のモデルを比較することで，INT8 変換が既知クラスの分類性能および OOD データ検出性能に与える影響を評価する．また，CPU 上で実行する FP32 モデルと，NPU 上で実行する INT8 モデルを比較し，推論時間と消費エネルギーを評価する．

3.3 OOD データ検出手法

本論文では，事後 OOD データ検出手法として，MSP，GEN，KNN，および NNGuide を比較する．各手法について ID データに対する確信度を表すスコアを算出し，スコアが閾値を下回る入力を OOD データと判定する．

MSP では，分類部が出力するソフトマックス確率の最大値を ID 確信度スコアとして使用する．

GEN では，ソフトマックス確率が大きい上位 M クラスを選択し，パラメータ γ を用いた一般化エントロピーに基づいて ID 確信度スコアを算出する．

KNN では，ID 訓練データから抽出した中間特徴量を L_2 正規化して特徴量バンクを構築する．推論時には，入力の中間特徴量と特徴量バンクとの二乗ユークリッド距離を計算し，第 k 近傍への距離の負値を ID 確信度スコアとする．

NNGuide では，ID 訓練データから抽出した中間特徴量を L_2 正規化した後，Energy スコアで重み付けして特徴量バンクを構築する．ここで Energy スコアとは，分類部のソフトマックスに入る前の値（ロジット）を LogSumExp によって集約した値である．推論時には，特徴量バンクの上位 k 近傍との平均類似度と入力自身の Energy スコアを乗算し，NNGuide スコアを算出する．

MSP と GEN は分類器が出力する確率を用いるのに対し，KNN は中間特徴量のみを使用する．NNGuide は中間特徴量とロジットから得られる Energy ベースの確信度の両方を使用する．いずれの手法も，スコアが大きいほど ID データである可能性が高いとして評価する．

3.4 ID/OOD 混在データにおけるマルウェア検知

本論文では，ID クラスの分類と OOD データ検出を組み合わせた ID/OOD 混在データにおけるマルウェア検知の評価をする．入力画像に対して，CNN は 21 個の ID クラスに対する予測結果と，分類部直前の中間特徴量を出力する．分類部が出力する確率分布または中間特徴量からスコアを算出し，あらかじめ設定した閾値以上の場合は CNN による既知クラスの予測を採用する．一方，スコアが閾値を下回る場合は，入力を OOD データと判定する．

マルウェア検知システムとしての総合性能を評価するため，CNN が出力する 20 種類の既知マルウェアファミリを「既知マルウェア」，マルウェアではない良性クラスを「良性」，OOD データとして判定したものを「未知マルウェア」として集約し，3 クラス分類として評価する．したがって，既知マルウェアファミリ間の誤分類は，3 クラス評価では既知マルウェアとして正しい判定に集約される．

INT8 モデルによる CNN 推論は NPU 上で実行する．一方，特徴量の正規化，中間特徴量の近傍探索，および閾値に基づく OOD 判定は CPU 上で実行する．したがって，システム全体が NPU 上で動作するわけではない．NPU は CNN 推論の効率を向上させるためのアクセラレータとして利用する．

4. 実験設定

4.1 共通実験設定

4.1.1 データセットと ID/OOD 分割

本論文では，MaleVis（Malware Evaluation with Vision）データセット [16] の事前に生成された 224×224 の RGB 画像を使用する．MaleVis は，25 種類のマルウェアファミリと 1 種類の良性クラスからなる合計 26 クラスで構成される．マルウェアファミリのサンプル数は各クラス約 500 サンプルで，良性クラスは 1,832 サンプルである．他の既存データセットはサンプル数がクラス不均衡であったり，良性クラスのデータがないことが多いが，MaleVis は各ファミリ約 500 サンプルで均衡であり，良性クラスのサンプル数が各マルウェアファミリクラスのサンプル数より多いので，より現実世界に近い構成である．この 25 のファミリの内，無作為に選んだ 5 つのファミリ（Allaple，Dinwod，Hlux，Neshta，VBA）を OOD クラス，それ以外の 20 ファミリと良性クラスの計 21 クラスを ID クラスとして分割する．さらに，ID クラスについては 7 割を訓練用，3 割を評価用として使用する．この分割により訓練データは 8,225 サンプル，評価データは 3,527 サンプルとなる．訓練時には，データ拡張としてランダムなアフィン変換を適用する．具体的には，最大 10° の回転および各方向に最大 10%の平行移動を行う．

4.1.2 モデルの学習条件

VGG16，ResNet50，および MobileNetV2 について，ImageNet-1k で事前学習された重みを用いて初期化する．各モデルの全層を対象として，Adam オプティマイザ，学習率 10^{-4}，重み付き交差エントロピー損失を用い，30 エポックのファインチューニングを 1 回実施する．30 エポック以降では過学習により評価精度が低下する傾向があるため，学習エポック数を 30 としている．学習および検証のいずれにおいても，バッチサイズを 32，データロード用の

© 2026 Information Processing Society of Japan

ワーカ数を 4 とする．

4.1.3 量子化条件

CNN モデルの量子化には，AMD Quark [17] を使用し，INT8 の PTQ を適用し，QDQ 形式の ONNX モデルを生成する．重みは符号あり 8 ビット整数（INT8）に，活性化値は符号なし 8 ビット整数（UINT8）に設定する．量子化方式には，2 のべき乗スケーリングを用いたテンソル単位の対称量子化を採用する．

量子化範囲の決定には MinMSE を用いる．MinMSE は，観測されたテンソル値の最小値および最大値を量子化範囲として用いる MinMax とは異なり，量子化前後のテンソル間の平均二乗誤差が最小となるクリッピング閾値を探索する手法である．キャリブレーションデータには，ID 訓練データから各クラス 5%を選択して使用する．選択したキャリブレーションデータは，元の訓練データとの RGB 分布の差が最小となるようにサンプルを抽出する．

4.1.4 OOD データ検出条件

事後 OOD データ検出の実装には，OpenOOD [18] を参照し，量子化後の ONNX モデルに適用可能な形で実装する．OpenOOD は，本論文で使用する手法だけでなく，各種 OOD データ検出手法の実装と標準化された評価プロトコルを提供している [18].

そして，各 OOD データ検出手法における設定は以下のようにする．GEN のパラメータは $\gamma = 0.1$，$M = 5$ とする．KNN および NNGuide の近傍数は $k = 5$ とし，特徴量バンクには ID 訓練データの $\alpha = 0.1$ に相当する 822 件を使用する．バンクサンプルは無作為抽出し，乱数シードを 42 とする．両手法における近傍探索には FAISS（faiss-cpu：1.13.0）の IndexFlatL2 および IndexFlatIP を用いて実行する．

4.1.5 ハードウェアおよびソフトウェア

モデル学習は，Intel Xeon Silver 4215R CPU および NVIDIA RTX A4500 GPU を搭載した Ubuntu 22.04 環境で実施する．量子化および検証は，AMD Ryzen 7 8840HS プロセッサと統合型 Ryzen AI NPU を搭載した Windows 11 端末上で実施する．NPU へのアクセスには，Ryzen AI Software 1.5.1 に内包されている ONNX Runtime および Vitis AI Execution Provider を使用する．

4.2 検証 1: 画像ベースのマルウェア分類の CPU・NPU 実行の比較

各 CNN モデルについて，ID 評価セットを用いて分類性能および実行性能を評価する．CPU 実行時は FP32 モデル，NPU 実行時は INT8 モデルで検証する．性能評価には，予測ラベルと正解ラベルに基づき正解率（Accuracy），適合率（Precision），再現率（Recall），マクロ F1 スコアを用いる．さらに，平均推論遅延，総実行時間，およびモデルサイズを比較する．平均推論遅延は，データ読み込み時間を除き，モデルへ入力を与えてからソフトマックス確率を取得するまでに要した計算時間の平均として定義する．総実行時間は，データ読み込み時間を含め，すべてのサンプルに対する推論が完了するまでに要した時間として計測する．

4.3 検証 2: 量子化前後の OOD データ検出性能の比較

量子化が OOD データ検出性能に与える影響を評価するため，FP32 モデルと INT8 モデルのそれぞれに MSP, GEN, KNN, および NNGuide を適用する．評価には，AUROC（Area Under the Receiver Operating Characteristic curve），AUPR（Area Under the Precision-Recall curve），FPR@95TPR（False Positive Rate at 95% True Positive Rate）を用いる．AUROC は，真陽性率と偽陽性率の関係を示す ROC 曲線の下側面積である．閾値を変化させた際の全体的な検知性能を示し，値が大きいほど高性能である．AUPR は，適合率と再現率の関係を示す PR 曲線の下側面積である．ID データと OOD データの数が不均衡の場合の検知性能を示し，値が大きいほど高性能である．FPR@95TPR は，真陽性率が 95%に達した時点における偽陽性率を指し，値が小さいほど高性能である．本論文では，OpenOOD の評価パイプラインに基づき，FPR@95TPR の定義を OOD データが 95%検出するように閾値を設定したときの ID データを OOD データと誤判定する確率と定義する．

4.4 検証 3: ID/OOD 混在データでのマルウェア検知の設定

先行する検証結果に基づき，分類モデルには VGG16，OOD データ検出手法には KNN を採用する．FP32 モデルを CPU 上で実行する構成と，INT8 モデルの CNN 推論を NPU 上で実行する構成を比較し，両構成の KNN には検証 2 と同じパラメータを用いる．

OOD 判定の閾値は，ID 評価データ 3,527 件から各クラスの 30%を乱数シード 42 で抽出した 1,053 件を用い，その 95%を ID として受理する値に設定する．閾値決定には OOD データを使用せず，既知データの誤検知抑制を優先する．残りの ID データ 2,474 件と OOD データ 2,474 件から，合計 4,948 件のテストデータを構成する．検知性能は `malware`，`benign`，`ood` の 3 クラス分類における正解率およびマクロ F1 により評価し，実行性能は平均推論レイテンシ，総実行時間，平均消費電力，および総エネルギー消費量により評価する．

消費電力は，AMD RyzenAI-SW の測定方法 [19] に従い，HWiNFO64 [20] から 500 ms 間隔で取得した `CPU Package Power` を APU 全体の消費電力として測定する．総エネルギー消費量は，推論中の電力値を台形則で時間積分して算出する．測定では，モデル読み込みと特徴量バンクの構築，

© 2026 Information Processing Society of Japan

表 1　INT8 PTQ 適用前後のクローズドセット分類性能
Table 1　Closed-set performance before and after INT8 PTQ.

Model	Config.	Acc.	Prec.	Recall	macro-F1
VGG16	FP32/CPU	0.9561	0.9660	0.9558	0.9603
	INT8/NPU	0.9521	0.9625	0.9506	0.9560
ResNet50	FP32/CPU	0.9575	0.9718	0.9552	0.9628
	INT8/NPU	0.9580	0.9734	0.9553	0.9636
MobileNetV2	FP32/CPU	0.9617	0.9683	0.9648	0.9662
	INT8/NPU	0.1160	0.0597	0.0914	0.0448

表 2　FP32 モデルの CPU 実行と INT8 モデルの NPU 実行の性能比較
Table 2　FP32 CPU and INT8 NPU execution performance.

Model	Config.	Avg. latency [ms]	Total time [s]	Size [MB]
VGG16	FP32/CPU	96.79	357.80	105.19
	INT8/NPU	6.19	31.17	26.33
ResNet50	FP32/CPU	26.19	105.46	93.65
	INT8/NPU	4.21	23.36	23.52
MobileNetV2	FP32/CPU	3.02	22.89	11.01
	INT8/NPU	1.96	14.77	2.87

および閾値決定を除外し，すべての実験を満充電状態かつ AC 電源接続下で実施する．

5. 実験結果

5.1 検証 1: 画像ベースのマルウェア分類の CPU・NPU 実行の比較

表 1 に FP32 モデルの CPU 実行と INT8 モデルの NPU 実行の分類性能の比較を示す．VGG16 は量子化後も高い頑健性を示した．正解率は 0.9561 から 0.9521 へ，マクロ F1 は 0.9603 から 0.9560 へ低下したが，その低下幅はそれぞれ 0.40 ポイントおよび 0.43 ポイントにとどまった．ResNet50 についても量子化前後で安定した性能を示した．量子化後の正解率は 0.9575 から 0.9580 へ，マクロ F1 は 0.9628 から 0.9636 へとわずかに向上した．一方，MobileNetV2 は量子化の影響を大きく受けた．正解率は FP32 の 0.9617 から INT8 では 0.1160 まで低下し，マクロ F1 も 0.9662 から 0.0448 まで大幅に低下した．

次に，**表 2** に実行パフォーマンスを示す．VGG16 では，平均レイテンシが 96.79 ms から 6.19 ms へ短縮され，約 15.6 倍の高速化が得られた．ResNet50 では，平均レイテンシが 26.19 ms から 4.21 ms へ短縮され，約 6.2 倍の高速化が得られた．MobileNetV2 は引き続き最も小規模かつ高速なモデルであったが，FP32 時点ですでに軽量であったため，レイテンシの改善幅は限定的であった．

5.2 検証 2: 量子化前後の OOD データ検出性能の比較

表 3 に INT8 PTQ 適用前後の OOD データ検出性能を示す．VGG16 では，PTQ 適用後も AUROC および AUPR は概ね維持された．一方，FPR@95TPR はすべての手法で増加した．INT8 モデルの中では，KNN が最も高い AUROC である 0.9336 を達成し，GEN が最も高い AUPR である 0.8237 を示した．また，KNN は AUROC を 0.9336 に維持するとともに，FPR@95TPR についても最も低い 0.2435 を達成した．MSP，GEN，NNGuide では量子化後に AUROC がわずかに低下したのに対し，KNN ではほとんど変化が見られなかった．

表 3　INT8 PTQ 適用前後の OOD データ検出性能
Table 3　OOD detection before and after INT8 PTQ.

CNN	Method	AUROC ↑ FP32/INT8	AUPR ↑ FP32/INT8	FPR95 ↓ FP32/INT8
VGG 16	MSP	0.9174/0.9103	0.8021/0.8100	0.4423/0.5798
	GEN	0.9309/0.9217	0.8281/0.8237	0.3734/0.4658
	KNN	0.9346/0.9336	0.8113/0.8110	0.2373/0.2435
	NNGuide	0.9112/0.9050	0.8091/0.8032	0.5770/0.6328
ResNet 50	MSP	0.8366/0.8376	0.7222/0.7396	0.6907/0.6958
	GEN	0.8491/0.8530	0.7381/0.7659	0.6583/0.6450
	KNN	0.9264/0.9322	0.8123/0.8198	0.1934/0.1956
	NNGuide	0.8613/0.8493	0.7468/0.7309	0.5506/0.5520
Mobile NetV2	MSP	0.8786/0.6016	0.8008/0.4526	0.7513/0.9765
	GEN	0.8887/0.5176	0.8223/0.5085	0.6771/0.9773
	KNN	0.9432/0.7721	0.8498/0.5711	0.2039/0.5688
	NNGuide	0.8495/0.5786	0.7463/0.4201	0.7071/0.9773

ResNet50 では，量子化の影響は手法および評価指標によって異なった．INT8 モデルの中では，KNN が AUROC および AUPR の両方で最も高い性能を示した．AUROC は 0.9264 から 0.9322 へ，AUPR は 0.8123 から 0.8198 へ向上した．一方，FPR@95TPR は 0.1934 から 0.1956 へわずかに増加した．GEN では 3 つの評価指標すべてが改善したのに対し，MSP では指標ごとに改善と低下が混在し，NNGuide では 3 つの指標すべてで性能が低下した．

MobileNetV2 では，検証 1 の分類結果と同様に，量子化後に最も大きな性能低下が確認された．KNN についても性能は低下したものの，INT8 モデルにおける MobileNetV2 の各手法の中では最も高い性能を維持し，AUROC は 0.7721，AUPR は 0.5711，FPR@95TPR は 0.5688 であった．

以上より，いずれの CNN においても，KNN は量子化後において最も一貫して高い OOD 検出性能を示した．

5.3 検証 3: ID/OOD 混在データでのマルウェア検知

表 4 に ID/OOD 混在環境におけるマルウェア検知の総合性能を示す．INT8 PTQ の VGG16 と KNN を用いた OOD データ検出を組み合わせ，マルウェア，良性，OOD の 3 クラス分類として評価した．

NPU 実行では，正解率が 0.8321 から 0.8260 へ，マクロ F1 が 0.7920 から 0.7835 へ低下し，その低下幅はそれぞれ 0.61 ポイントおよび 0.85 ポイントであった．

一方，平均レイテンシは 95.98 ms から 6.29 ms へ短縮

© 2026 Information Processing Society of Japan

表 4　ID/OOD 混在環境におけるマルウェア検知の総合性能
Table 4　Malware Detection Performance in Mixed ID/OOD Environments.

Exec.	Acc.	M-F1	Lat. (ms)	Time (s)	Pwr. (W)	Energy (J)
FP32 CPU	0.8321	0.7920	95.98	495.61	15.00	7435
INT8 NPU	0.8260	0.7835	6.29	43.81	15.00	657

され，総実行時間も 495.61 s から 43.81 s へ短縮された．これらはそれぞれ約 15.3 倍および 11.3 倍の高速化に相当する．

APU パッケージの平均消費電力は，両条件とも 15.00 W で同一であった．これは，使用したプラットフォームにおいて STAPM の電力上限が 15 W に設定されており，負荷時に取得したサンプルの 94%がこの上限に達していたためである．したがって，平均消費電力のみでは両実行方式の差を評価することが難しく，エネルギー消費量に基づいて比較する必要がある．総 APU エネルギー消費量は 7,435 J から 657 J へ減少し，91.2%の削減となった．このような電力制限下のプラットフォームでは，エネルギー削減は動作時の消費電力低下によるものではなく，実行時間の短縮によって得られる．

以上の結果から，NPU 実行により，ID/OOD 混合データの分類性能を概ね維持しながら，実行時間およびエネルギー効率を大幅に改善できることが確認された．ただし，NPU は CNN 推論のみに使用され，特徴量の正規化や KNN による近傍探索，および閾値に基づく最終判定はホスト CPU 上で実行される．

6. 考察

6.1 量子化が分類性能に与える影響

検証 1 の結果から，INT8 PTQ の影響は，すべてのモデルで同一ではないことが確認された．VGG16 および ResNet50 では ID データの分類性能がほぼ維持された一方，MobileNetV2 では大幅な性能低下が見られた．この要因について，文献 [21] によれば，MobileNet などで用いられる Depthwise Separable Convolution では，各チャネルの重みのダイナミックレンジと層全体のテンソルのダイナミックレンジとの間に大きな差が生じる場合がある．このような状態でテンソル単位の量子化を適用すると，ダイナミックレンジの狭いチャネルの情報が失われ，モデル性能が低下する可能性がある．したがって，量子化後の性能にはモデルアーキテクチャ固有の特性が大きく影響すると考えられる．本論文では，共通のベースライン PTQ 設定の下でネットワークアーキテクチャの影響を明確に比較するため，Cross-Layer Equalization や Adaptive Rounding などの最適化手法は意図的に適用しなかった．これらの手法を用いた MobileNetV2 の性能回復については，今後の課題とする．

6.2 OOD データ検出手法の量子化耐性

検証 2 の結果から，量子化後の OOD 検出では，KNN が最も一貫した性能を示した．その理由の一つとして，分類器の出力に基づく手法は量子化によって生じる出力の変化に影響されやすい一方，中間特徴量のみを利用する手法はその影響を比較的受けにくく，量子化に対して頑健である可能性が考えられる．ただし，本論文では量子化前後における特徴空間の変化や歪みを直接測定していない．そのため，この説明は現時点では仮説にとどまる．

6.3 オンデバイス展開への示唆

検証 3 の結果から，量子化 CNN を用いた最終的な ID/OOD データ混在のマルウェア検出システムでは，量子化による 3 クラス分類の正解率およびマクロ F1 の低下を 1 ポイント未満に抑えながら，NPU 実行により平均レイテンシを約 15.3 倍高速化するとともに，APU の総エネルギー消費量を 91.2%削減した．このことから，学習時に含まれていない新しいマルウェアファミリを分類器が正しく分類できない場合であっても，OOD データ検出を導入することで，未知マルウェアが既知クラス，特に良性として誤って受理される可能性の低減が期待される．

6.4 検証の制約と今後の課題

本検証には一般化可能性に関していくつかの制約がある．使用したデータセットは事前生成された一つのマルウェア画像データセットに限定され，アクセラレータプラットフォームも Ryzen AI の 1 種類のみであり，学習も単一の実行結果に基づいている．また，各クラスのデータ数が均衡な既存のマルウェア画像データセットが限られているため，異なるデータセットを ID および OOD として用いるのではなく，単一のデータセットを ID クラスと OOD クラスに分割して評価した．そして，評価した OOD データ検出手法の数も限定的であり，中間特徴量に基づく他の事後 OOD データ検出手法や，異なる種類の OOD データ検出手法については評価していない．加えて，評価対象は 3 種類の CNN アーキテクチャに限定されており，その他の CNN や非 CNN アーキテクチャについても検証していない．今後は，追加のマルウェアデータセットおよびモデルアーキテクチャを用いた評価を行うとともに，PTQ が学習済み特徴空間に与える変化を定量的に分析する必要がある．

7. おわりに

本論文では，オンデバイス AI による Windows マルウェア検出に NPU を活用した．PTQ を用いて INT8 量子化した CNN モデルを対象に，画像ベースのマルウェア分類性能および事後 OOD データ検出性能を評価した．さらに，

© 2026 Information Processing Society of Japan

量子化モデルと OOD データ検出を組み合わせた統合マルウェア検出システムについて ID/OOD 混在データを用いて評価を行った．

モデル量子化の結果，VGG16 および ResNet50 は量子化に対して高い頑健性を示した一方，MobileNetV2 では大幅な性能低下が確認された．量子化モデルに対する事後 OOD データ検出では，中間特徴量のみを用いる KNN が最も一貫した性能を示した．

最終的な統合マルウェア検知では，約 15.3 倍の高速化を達成するとともに，APU の総エネルギー消費量を 91.2% 削減した．一方，マルウェア・良性・OOD の 3 クラス分類における量子化による正解率およびマクロ F1 の低下はいずれも 1 ポイント未満に抑えられた．

以上の結果から，エンドポイント端末のマルウェア検知において NPU による AI 推論の効率化と OOD データ検出手法を組み合わせることで未知のマルウェアファミリを検出しながら高精度かつ高速・低エネルギー消費な検知が可能であることが示唆された．

参考文献

[1] Intel Corporation: Intel vPro Platform Brief with Intel Core Ultra Processors (Series 1) (2024). Product Brief. Accessed: 2026-01-28.

[2] Dalcher, G.: CrowdStrike and Intel Research Collaborate to Advance Endpoint Security Through AI and NPU Acceleration (2024). Accessed: 2026-01-28.

[3] Nataraj, L., Karthikeyan, S., Jacob, G. and Manjunath, B. S.: Malware images: visualization and automatic classification, *Proceedings of the 8th International Symposium on Visualization for Cyber Security*, VizSec '11, New York, NY, USA, Association for Computing Machinery, (online), DOI: 10.1145/2016904.2016908 (2011).

[4] El-Shafai, W., Almomani, I. and AlKhayer, A.: Visualized Malware Multi-Classification Framework Using Fine-Tuned CNN-Based Transfer Learning Models, *Applied Sciences*, Vol. 11, No. 14, p. 6446 (online), DOI: 10.3390/app11146446 (2021).

[5] Hendrycks, D. and Gimpel, K.: A Baseline for Detecting Misclassified and Out-of-Distribution Examples in Neural Networks., *International Conference on Learning Representations ICLR (Poster)*, OpenReview.net (2017).

[6] Liu, X., Lochman, Y. and Christopher, Z.: GEN: Pushing the Limits of Softmax-Based Out-of-Distribution Detection, *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* (2023). Accessed 2026-01-06.

[7] Sun, Y., Ming, Y., Zhu, X. and Li, Y.: Out-of-distribution Detection with Deep Nearest Neighbors, *International Conference on Machine Learning* (2022).

[8] Park, J., Jung, Y. G. and Teoh, A. B. J.: Nearest Neighbor Guidance for Out-of-Distribution Detection (2023). Accessed 2026-01-06.

[9] Sheneamer, A.: *Zero-Day Malware Detection Using Fine-Tuned MobileNetV2 and Open-Set Classification*, pp. 46–58 (online), DOI: 10.1007/978-3-031-89063-5_5, Springer (2025).

[10] Gholami, A., Kim, S., Zhen, D., Yao, Z., Mahoney, M. and Keutzer, K.: *A Survey of Quantization Methods for Efficient Neural Network Inference*, pp. 291–326 (online), DOI: 10.1201/9781003162810-13, Chapman and Hall/CRC (2022).

[11] Chaudhary, M. and Masood, A.: RealMalSol: real-time optimized model for Android malware detection using efficient neural networks and model quantization, *Neural Computing and Applications*, Vol. 35, No. 15, pp. 11373–11388 (online), DOI: 10.1007/s00521-023-08303-8 (2023).

[12] Agada, O. C.: From Training to Edge Inference: A Transfer Learning Pipeline for Low-Latency Malware Classification on Snapdragon-Enabled Samsung Galaxy S23 Ultra (Android 13), *Journal of Scientific Reports*, Vol. 11, No. 1, pp. 51–64 (online), DOI: 10.58970/JSR.1135 (2025).

[13] Simonyan, K. and Zisserman, A.: Very Deep Convolutional Networks for Large-Scale Image Recognition, *International Conference on Learning Representations (ICLR)* (2015).

[14] He, K., Zhang, X., Ren, S. and Sun, J.: Deep Residual Learning for Image Recognition, *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 770–778 (2016).

[15] Sandler, M., Howard, A., Zhu, M., Zhmoginov, A. and Chen, L.-C.: MobileNetV2: Inverted Residuals and Linear Bottlenecks, *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 4510–4520 (2018).

[16] Bozkir, A. S., Cankaya, A. O. and Aydos, M.: Utilization and Comparision of Convolutional Neural Networks in Malware Recognition, *2019 27th Signal Processing and Communications Applications Conference (SIU)*, pp. 1–4 (online), DOI: 10.1109/SIU.2019.8806511 (2019).

[17] Advanced Micro Devices, Inc.: Quark for Ryzen AI NPU, AMD Quark Documentation (2025). Last updated on Sep 26, 2025. Accessed: 2026-01-12.

[18] Yang, J., Wang, P., Zou, D., Zhou, Z., Ding, K., Peng, W., Wang, H., Chen, G., Li, B., Sun, Y., Du, X., Zhou, K., Zhang, W., Hendrycks, D., Li, Y. and Liu, Z.: OpenOOD: Benchmarking Generalized Out-of-Distribution Detection, *Advances in Neural Information Processing Systems, Datasets and Benchmarks Track* (2022).

[19] Advanced Micro Devices, Inc.: RyzenAI-SW: ONNX Benchmark Utilities, GitHub repository, version 1.5.0 (2025). Power measurement utility for HWiNFO64 and AMD Graphics Manager, Accessed: 2026-01-28.

[20] Martin Malik and REALiX: HWiNFO - Free System Information, Monitoring and Diagnostics, Version 8.34-5870 (2025). Accessed: 2026-01-26.

[21] Yun, S. and Wong, A.: Do All MobileNets Quantize Poorly? Gaining Insights into the Effect of Quantization on Depthwise Separable Convolutional Networks Through the Eyes of Multi-scale Distributional Dynamics , *2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, Los Alamitos, CA, USA, IEEE Computer Society, pp. 2447–2456 (online), DOI: 10.1109/CVPRW53098.2021.00277 (2021).

© 2026 Information Processing Society of Japan