個人識別情報保護に向けた正規表現ルールとローカルLLMによる軽量な事前検出手法

朝比奈 睦郎[1,a)]　原 賢太[2]　塚原 健太郎[2]　三澤 匠[2]　西川 智章[2]　栗林 稔[3]

概要：文章中のメールアドレスや氏名，住所などの個人識別情報（Personally Identifiable Information: PII）を外部システムへ送信する前に検出・マスキングすることは，プライバシー保護の観点から重要である．一方，形式が定まった情報と表記ゆれの大きい情報が混在する文章では，処理速度を保ちながら見逃しや誤検出を抑えることは容易ではない．本研究では，正規表現，固定辞書，日本語 NER（Named Entity Recognition）で PII 候補を軽量に抽出し，判定が難しい候補だけをローカル LLM で補正する事前検出手法を提案する．高信頼な定型情報は正規表現で処理し，local part に非 ASCII 文字を含む EMAIL では Recall を優先して広めの候補を生成し，LLM が候補内部の正しい範囲へ補正する．開発用データと重複しない日本語 500 文書を用いたホールドアウト評価では，提案手法は Exact F1=0.454，Relaxed F1=0.790 となり，LLM を用いない Regex+Dict+GiNZA の 0.356，0.672 を上回った．また，同一のローカル LLM を文章全体に適用する LLM-only ベースラインの平均処理時間 38.76 秒/文書に対し，提案手法は 11.97 秒/文書で約 3.24 倍高速であり，評価パイプライン上の LLM 推論失敗は提案手法で 0 件，LLM-only で 21 件であった．

キーワード：個人情報保護，PII 検出，正規表現，固有表現抽出，ローカル LLM

A Lightweight Pre-Detection Method for Personally Identifiable Information Using Regular Expression Rules and Local LLM

Tokio Asahina[1,a)]　Kenta Hara[2]　Kentaro Tsukahara[2]　Takumi Misawa[2]　Tomoaki Nishikawa[2]
Minoru Kuribayashi[3]

Abstract: Detecting and masking personally identifiable information (PII), such as email addresses, names, and addresses, before text is sent to an external system is important for privacy protection. However, practical text contains both structured information, whose format can be described explicitly, and less structured information with large variations in expression. It is therefore difficult to reduce both missed detections and false positives while maintaining processing speed. In this study, we propose a lightweight, candidate-constrained pre-detection method that combines regular expression rules, a fixed dictionary, Japanese named entity recognition (NER), and a local large language model (LLM). High-confidence structured PII is detected mainly by regular expressions, while the dictionary and NER are used to generate candidates for less structured PII. The local LLM is applied only to ambiguous candidates in order to remove false positives or correct their boundaries. FFor email addresses containing non-ASCII characters in the local part, the method first generates a recall-oriented broad candidate and then lets the LLM refine it to the appropriate internal span. The LLM is not allowed to search for new PII outside the supplied candidates. On a held-out set of 500 Japanese documents disjoint from the development data, the proposed method achieved an Exact F1 of 0.454 and a Relaxed F1 of 0.790, outperforming the Regex+Dict+GiNZA baseline without LLM refinement, which achieved 0.356 and 0.672, respectively. In addition, compared with an LLM-only baseline that applies the same local LLM to the entire input text, the proposed method reduced the mean processing time from 38.76 to 11.97 seconds per document, corresponding to a 3.24-fold speedup. No LLM inference failures were observed for the proposed method, whereas 21 requests were recorded as inference failures for the LLM-only baseline.

Keywords: PII detection, privacy protection, regular expression, named entity recognition, local LLM

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

1. はじめに

個人情報保護の重要性が高まる中，文章中に含まれるメールアドレスや氏名，住所等の個人識別情報（Personally Identifiable Information: PII）を自動的に検出・マスキングする技術へのニーズも高まっている．特に生成 AI や大規模言語モデル（Large Language Model: LLM）を業務システムへ組み込む場合，利用者が入力した PII を外部クラウドや後段システムへそのまま送信することは避ける必要がある．本研究では，このような PII を外部へ送信する前にローカル環境で検出し，マスキングする利用形態を想定する．

PII には，メールアドレスや電話番号，カード番号のように形式が比較的明確な情報と，氏名や住所のように表記ゆれや文脈依存性が大きい情報が混在する．正規表現やルールベースの手法は前者を高速に処理できる一方，日本語の氏名や住所は漢字，ひらがな，カタカナ，ローマ字，空白，敬称等によって表記が変化するため，単純なルールだけでは十分に対応しにくい [1], [4].

一方，LLM は周辺文脈を踏まえて柔軟に判断できるため，ルールだけでは扱いにくい表現にも対応できる可能性がある [3]．しかし，文章全体を LLM へ入力して PII を探索させる場合，特にローカル環境では推論時間が大きくなりやすく，大量の文章を継続的に処理する用途では負担となる．

そこで本研究では，高速に処理可能な正規表現，固定辞書，日本語 NER（Named Entity Recognition）を用いて PII 候補を先に抽出し，判定が難しい候補のみに絞ってローカル LLM を適用する．つまり，形式が明確な候補はそのまま採用し，氏名や住所等の曖昧な候補では LLM が誤検出の除去や境界の補正を行う二段階構成の処理となっている．また，local part に非 ASCII 文字を含む EMAIL のように境界を正規表現だけで決めにくい場合には，Recall を優先して広めの候補を作り，LLM に候補内部の正しい範囲へ修正させる．これにより，LLM の文脈理解能力を利用しつつ，文章全体を LLM で処理する方式よりも処理対象を限定する．なお，本稿でいう「軽量」とは，LLM 自体のパラメータ数が小さいことを意味するのではなく，正規表現・辞書・NER によって候補を限定し，全文から PII を探索する LLM-only 方式と比べて LLM が判定する範囲を縮小する設計を指す．

本稿の構成は以下の通りである．2 章で関連研究を整理し，3 章で提案手法の詳細を述べる．4 章で評価実験の設定と結果を示し，5 章でまとめと今後の課題を述べる．

[1] 愛媛大学
Ehime University
[2] AI Librarium 株式会社
AI Librarium Corporation
[3] 東北大学データ駆動科学・AI 教育研究センター
Center for Data-driven Science and Artificial Intelligence, Tohoku University
[a)] chaobinaimulang@gmail.com

2. 関連研究

PII 検出に関する既存手法は，大きく正規表現・ルールベース手法，NER 等の機械学習ベース手法，LLM を用いた手法に分けられる．

正規表現やルールベースの手法は，メールアドレスや電話番号のように形式が定まった情報を高速かつ安定して検出できる．一方，氏名や住所のような非定型情報では，表記ゆれに対応するために多数のルールや辞書が必要となり，管理が複雑になりやすい．Kajiyama らは日本語電子カルテの自由記述を対象として，ルールベース，CRF，LSTM による de-identification を比較している [1]．Mishra らは金融文書を対象に，ルールベース NLP（Natural Language Processing）と機械学習・NER を組み合わせた PII 検出・匿名化方式を提案している [2].

NER 等の機械学習ベース手法は，ルールだけでは扱いにくい氏名や地名等の抽出に有効である．本研究では日本語 NER として GiNZA[5] を利用する．GiNZA は Universal Dependencies に基づく日本語解析系であり，形態素解析や依存構造解析に加えて固有表現抽出を提供する．本研究では GiNZA を最終的な PII 判定器として用いるのではなく，辞書だけでは抽出しにくい候補を補うために利用する．具体的には，GiNZA による固有表現抽出結果を本研究で定義する PII 種別へ対応付け，辞書だけでは抽出しにくい候補を補完する．具体的なラベル対応については 3.3 節で述べる．

近年では LLM を用いた匿名化も研究されている．Pissarra らは臨床テキスト匿名化において LLM と従来方式を比較し，LLM を匿名化へ利用する可能性を検討している [3]．LLM は文脈を利用して柔軟に判断できる一方，全文から PII を探索させる方式では推論コストやレイテンシが大きくなりやすい．本研究は，ルールと NER による候補抽出の速度と，LLM の文脈理解能力を組み合わせるハイブリッド方式として位置付けられる．

また，Minamoto らは日本語 LLM の事前学習コーパスに含まれる要配慮個人情報の検出を扱っており，日本語データにおける機密情報検出の重要性を示している [4]．商用サービスでは Amazon Bedrock Guardrails が PII 検出や Custom Regex によるパターン検出を提供している [6], [7]. ただし，本研究は生の PII を外部クラウドへ送信する前にローカルで検出することを目的としているため，Bedrock Guardrails は同一条件の比較方式ではなく，関連する商用サービスとして位置付ける．

© 2026 Information Processing Society of Japan

3. 提案手法

3.1 全体構成

提案手法は，正規表現，固定辞書，日本語 NER である GiNZA，およびローカル LLM を組み合わせた PII 事前検出パイプラインである．図 1 に提案手法の全体構成を示す．入力文章に対して，まず正規表現，固定辞書，GiNZA を用いて PII 候補を抽出し，候補の重複を整理する．その後，判定が難しい候補のみをローカル LLM へ入力し，候補の採否や境界を補正する．最終的に PII と判定された範囲をプレースホルダへ置換し，マスキング済みテキストを出力する．

本研究では，評価対象とする PII を以下の 5 種類とする．

- PERSON：氏名
- EMAIL：メールアドレス
- PHONE：電話番号
- ADDRESS：住所
- CREDIT_CARD：クレジットカード番号

本稿では，本研究で定義する PII 種別を PERSON，EMAIL，PHONE，ADDRESS，CREDIT_CARD のように大文字で表記する．一方，GiNZA が出力する固有表現ラベルについては，Person，Province，City 等の GiNZA で定義された表記を用いる．さらに，マスキング後のプレースホルダは [PERSON]，[ADDRESS] 等のように角括弧を付して表記する．

また，本稿では，一つの PII に対応する文字列とその PII 種別・文字位置の組を PII エンティティ（entity）と呼ぶ．文章中におけるエンティティの開始位置から終了位置までの文字範囲を span と呼ぶ．例えば，「山田太郎」を人物名として検出した場合，PERSON が PII 種別であり，「山田太郎」に対応する文字範囲が span となる．

これらの名称は処理内部で用いる PII 種別ラベルである．例えば，人物名として検出された範囲には PERSON，住所として検出された範囲には ADDRESS を付与する．最終的なマスキング時には，それぞれ [PERSON]，[ADDRESS] 等のプレースホルダへ置換する．

入力文章を x，一つの PII 候補を $c = (t, s, e)$ とする．ここで t は PII 種別，s, e はそれぞれ span の開始・終了位置である．正規表現（Regex: R），固定辞書（Dict: D），GiNZA（G）による候補抽出器をそれぞれ E_R, E_D, E_G とし，各抽出器が返す候補集合を

$$C_m(x) = E_m(x), \qquad m \in \{R, D, G\}$$

と表す．また，本研究で用いる評価データには，local part に非 ASCII 文字を含み，domain 部が ASCII 形式で表される EMAIL が含まれる．このような EMAIL では，本文と local part の境界を文字種のみから厳密に決定することが

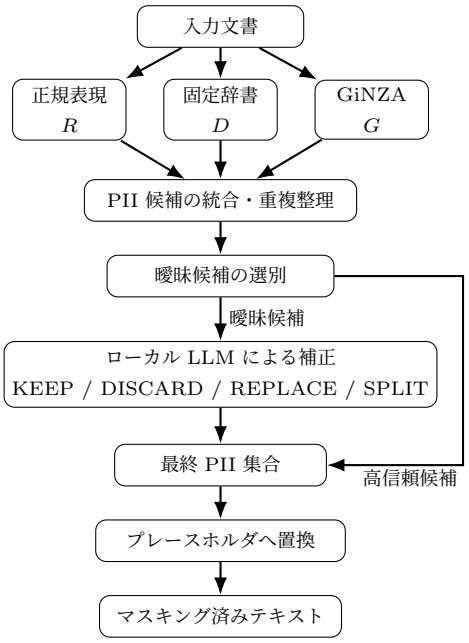


図 1 提案手法の全体構成

難しい場合がある．そこで提案手法では，見逃しを抑えるために local part 側を広めに取得する Recall 優先 EMAIL 候補生成器を E_U とし，その候補集合を $C_U(x) = E_U(x)$ とする．

任意の構成要素集合 $S \subseteq \{R, D, G, U\}$ に対して，前段で得られる候補集合を

$$C_S(x) = \mathrm{Dedup}\left(\bigcup_{m \in S} C_m(x)\right)$$

と定義する．ここで Dedup は，同一 PII 種別かつ同一の開始・終了位置を持つ候補を一つに統合する決定的処理である．この表記を用いると，比較方式 R+D+G と提案手法の LLM 入力前の候補集合はそれぞれ

$$C_{\mathrm{R+D+G}}(x) = C_{\{R,D,G\}}(x),$$
$$C_{\mathrm{prop}}(x) = C_{\{R,D,G,U\}}(x)$$

となる．したがって，提案手法における R，D，G の候補抽出処理自体は比較方式 R+D+G と同一であり，前段における提案手法固有の差分は U による Recall 優先 EMAIL 候補生成である．

次に，$C_{\mathrm{prop}}(x)$ のうち，高信頼候補を $H(x)$，LLM による判定・補正を必要とする曖昧候補を $A(x)$ とする．主な振り分けとして，高信頼な正規表現一致で得られる ASCII EMAIL，PHONE，CREDIT_CARD 等は $H(x)$ として LLM を経由せず採用する．一方，辞書・GiNZA から得られる PERSON や ADDRESS の候補，および Recall 優先 EMAIL 候補のうち，文脈や境界の確認が必要なものを $A(x)$ として LLM へ送る．ローカル LLM による候補補正関数を f_{LLM} とすると，最終的な PII 集合は

$$\hat{Y}(x) = \mathrm{Dedup}\left(H(x) \cup f_{\mathrm{LLM}}\big(x, A(x)\big)\right)$$

© 2026 Information Processing Society of Japan

と表せる．ただし $A(x) = \emptyset$ の場合には LLM を呼び出さず，$\hat{Y}(x) = \mathrm{Dedup}(H(x))$ とする．また，曖昧候補が存在する場合も候補一覧を一つの要求にまとめるため，1 文書あたりの LLM 呼び出し回数は最大 1 回である．

3.2 正規表現ルールによる定型 PII の検出

EMAIL, PHONE, CREDIT_CARD 等, 形式を比較的明確に記述できる PII には正規表現を用いる．通常の ASCII 形式のメールアドレスや電話番号，カード番号等で高信頼な一致が得られた場合は，後段の LLM を使わずそのまま採用する．これにより，形式だけで十分に判断できる情報に対する余分な推論を避ける．

一方, local part に非 ASCII 文字を含む EMAIL（例えば，国際化メールアドレス Email Address Internationalization: EAI）では，本文と local part の境界を文字種のみから厳密に決定することが難しい場合がある．そこで提案手法では，通常の ASCII 形式の EMAIL として高信頼に検出できない場合，まず ASCII 形式の domain 部を検出し，“@” の左側を Recall 優先で広めに取得する．具体的には，文字，結合文字，数字，および local part で利用され得る記号が連続する範囲を左方向へ探索し，EMAIL 候補を生成する．

この処理では見逃しを避けることを優先するため，候補に本文の一部が含まれることを許容する．その後，候補をローカル LLM へ入力し，候補内部から実際の EMAIL に対応する範囲のみを残すよう境界を補正する．なお，比較実験で用いる LLM 非使用のアブレーション 3 方式（R, R+D, R+D+G）では，この Recall 優先 EMAIL 候補生成は行わない．

3.3 辞書と GiNZA による非定型 PII 候補の抽出

氏名や住所のように，文字列の形式だけでは判定しにくい PII については，固定辞書および日本語 NER を用いて候補を抽出する．固定辞書には 47 都道府県名および一般的な日本人姓を登録している．さらに，「氏名：」「担当者：」等の前置表現や，「様」「氏」「殿」等の敬称，ローマ字姓名の表記パターンを利用して人物名候補を補完する．これらの辞書および表記パターンは，本稿の評価に用いる 500 文書から学習・生成したものではなく，あらかじめ設定した固定的なルールとして使用し，評価文書固有の例外規則は追加していない．

一方，固定辞書や表記パターンのみでは，辞書に登録されていない氏名や地名を十分に抽出できない．そこで本研究では，日本語自然言語処理ライブラリ GiNZA[5] の日本語解析モデル `ja_ginza` を用いる．実験環境では GiNZA 5.2.0，spaCy 3.7.5 を使用し，推論時は `tok2vec` と `ner` を有効化して固有表現抽出結果を PII 候補として利用した．GiNZA は Universal Dependencies に基づく日本語解析系であり，本研究では固有表現抽出結果によって固定辞書では抽出しにくい PII 候補を補完する．

ここで，GiNZA が出力する固有表現ラベルと，本研究で用いる PII 種別ラベルを区別する．GiNZA の出力ラベルは `Person`，`Province`，`City` 等のように GiNZA で定義された表記を用い，本研究で扱う PII 種別は `PERSON`，`ADDRESS` 等のように大文字で表記する．具体的には，GiNZA が出力した `Person` を `PERSON` へ，`Province`，`City`，`County`，`Road`，`Postal_Address` を `ADDRESS` へ対応付ける．また，`Email` を `EMAIL` へ，`Phone_Number` を `PHONE` へ対応付ける．

正規表現，固定辞書，GiNZA の複数の抽出方法から，同一の PII 種別かつ同一範囲の候補が得られた場合には，これらを重複候補として統合する．また，一つの `PERSON` 候補に複数人の氏名が読点やカンマ等の明示的な区切り文字によって連結されている場合には，後段の LLM へ入力する前に個別の候補へ機械的に分割する．以上の処理により，固定辞書による候補抽出と GiNZA による辞書外表現の補完を組み合わせ，後段の LLM で判定・補正する PII 候補集合を構成する．

3.4 ローカル LLM による文脈補正

正規表現，固定辞書，NER によって抽出された候補には，周辺文脈によっては PII ではない表現が含まれたり，実際の PII より広い文字範囲が候補として抽出されたりする場合がある．本手法では，このように文字列の形式だけでは採否や境界を決定しにくい曖昧な候補のみをローカル LLM による補正対象とする．一方，電話番号やクレジットカード番号等，正規表現によって高信頼に検出できる定型 PII については LLM へ入力せず，そのまま最終候補として採用する．1 文書中に曖昧候補が一つ以上存在する場合，入力文章とその文書から抽出された曖昧候補の一覧を一度の LLM 要求として与える．LLM には，各候補について `KEEP`，`DISCARD`，`REPLACE`，`SPLIT` のいずれかの操作を JSON 形式で出力させる．`KEEP` は抽出された候補をそのまま保持する操作，`DISCARD` は文脈上 PII ではない候補を除外する操作，`REPLACE` は候補内部から実際の PII に対応する文字範囲へ境界を修正する操作，`SPLIT` は一つの候補に複数の同種 PII が含まれている場合に，それらを複数の候補へ分割する操作である．例えば，姓として辞書に登録された文字列が文章中で一般名詞や地名の一部として使用されていた場合，辞書との文字列一致だけでは `PERSON` 候補として抽出される可能性がある．この場合，LLM は候補周辺の文脈を参照し，人物名ではないと判断すれば `DISCARD` によって候補を除外する．また，local part に非 ASCII 文字を含む EMAIL では，Recall を優先した候補生成によって実際のメールアドレスより広い範囲が抽出される場合がある．例えば，評価データには「ご参加には市石@hotmail.com をご確認ください。」のように，local part に非 ASCII 文字を含む EMAIL が存在する．このと

© 2026 Information Processing Society of Japan

き，Recall を優先して “@” の左側を探索すると，日本語本文と local part の境界を文字種のみでは判別できず，「ご参加には市石@hotmail.com」のように実際の EMAIL より広い範囲が候補として生成される場合がある．LLM は候補周辺の文脈を参照し，候補内部の「市石@hotmail.com」のみが EMAIL であると判断すると，REPLACE によってその範囲へ候補境界を補正する．なお，本手法における LLM の役割は，前段で抽出された候補の判定および補正に限定される．LLM が REPLACE または SPLIT を行う場合も，出力する文字範囲は元の候補内部に制限する．したがって，正規表現，固定辞書，NER 等の前段処理で候補として抽出されなかった PII を，LLM が文章全体から新たに探索して追加することはできない．また，LLM 要求が評価パイプライン上で有効な結果を返さず推論失敗として記録された場合には補正前の候補を保持し，前段ですでに検出された候補が失われないようにする．

3.5 実装条件

検出前には Unicode NFKC 正規化を行う．ただし，正規化によって文字列長が変化し，元文章との文字位置の対応が失われる場合には元の文字列を使用する．これにより，検出した PII の開始位置および終了位置と，実際にマスキングする位置との対応を保持する．ローカル LLM には Ollama 経由の gpt-oss:20b を使用した．評価時は temperature=0.0，reasoning effort=low，context length=4096，timeout=180 秒に固定した．正規表現，辞書，GiNZA のラベル対応，local part に非 ASCII 文字を含む EMAIL，LLM へ送る候補の条件，LLM 出力の適用方法はコードとして明示的に管理している．

4. 実験・評価

4.1 評価データ

定量評価には Ai4Privacy が公開する OpenPII 1.5M を使用した [8]．本研究では，提案パイプラインのために GiNZA やローカル LLM を追加学習・ファインチューニングしていない．したがって，本節でいう「方式開発用」の文書はモデルの訓練用データではなく，正規表現ルール，固定辞書・表記パターン，GiNZA のラベル対応，Recall 優先 EMAIL 候補生成，LLM 補正 prompt および推論条件を設計・調整するために参照した文書を意味する．同データセットの日本語データ 20,754 文書から，方式開発用として乱数シード 42 で 500 文書を固定抽出した．最終評価では，この開発用 500 文書および事前動作確認に用いた 5 文書を候補から除外した上で，乱数シード 20260817 を用いて別の 500 文書をホールドアウト評価用として抽出した．開発用集合と評価用集合について，文書 ID および元データセット上の source index の双方で重複がないことを確認した．また，固定辞書・表記パターンはホールドアウト 500 文書から生成したものではなく，評価文書固有の例外規則も追加していない．正規表現，辞書，GiNZA のラベル対応，Recall 優先 EMAIL 候補生成，LLM 補正 prompt および推論条件はホールドアウト評価の開始前に固定し，評価結果を用いた再調整は行っていない．本稿では，PERSON，EMAIL，PHONE，ADDRESS，CREDIT_CARD の 5 種類を評価対象とする．

OpenPII 1.5M では，本研究よりも細かな単位で PII 種別が付与されているため，評価時には元データセットのラベルを本研究の PII 種別へ変換した．具体的には，元データセットの GIVENNAME および SURNAME を PERSON へ，STREET，CITY，ZIPCODE，BUILDINGNUM を ADDRESS へ統合した．また，EMAIL を EMAIL へ，TELEPHONENUM を PHONE へ，CREDITCARDNUMBER を CREDIT_CARD へ対応付けた．

ここで，元データセットでは，一つの人物名や住所が複数の annotation（PII 種別と span が付与された正解ラベル）に分割されている場合がある．例えば，「山田 太郎」に対して姓「山田」が SURNAME，名「太郎」が GIVENNAME として別々に付与されている場合，両者を PERSON へ変換した後も別々のエンティティとして扱うと，本研究の検出単位と正解データの単位が一致しない．そこで，同一の PII 種別へ変換された隣接 annotation について，両者の span 間が空白，読点，カンマ，中点，ピリオド，またはハイフン類のみで構成されている場合には，一つの PII エンティティとして結合した．住所についても同様に，隣接する市区町村，番地，建物番号等が ADDRESS へ変換された場合には，一つの住所エンティティとして扱う．異なる PII 種別や，離れた位置に存在する annotation は結合しない．

一方，本研究では PII となり得るすべての情報を評価対象としているわけではない．年齢を表す AGE および運転免許証番号を表す DRIVER_ID は評価データ中に存在するが，現行の提案手法では対応する検出処理を実装していないため，本稿の比較評価から除外した．また，BANK_ACCOUNT および IBAN については検出ルールを実装しているものの，本稿で用いる評価データ変換では正解ラベルを評価対象として構成していないため，定量評価から除外した．これらが PII に該当しないという意味ではなく，本稿における評価範囲を前述の 5 種類に限定したものである．

4.2 比較方式と評価指標

比較方式として，Regex（R），Regex+Dict（R+D），Regex+Dict+GiNZA（R+D+G），提案手法（Proposed），LLM-only を用いる．各方式の構成要素を表 1 に示す．R，R+D，R+D+G は前段の候補抽出器の寄与を確認するためのアブレーションであり，R+D+G を LLM 非使用の主要ベースライン，LLM-only を全文 LLM 方式のベースラインとして位置付ける．以降，本文と表では短縮表記 R，R+D，R+D+G を用いる．Amazon Bedrock Guardrails

© 2026 Information Processing Society of Japan

表 1 比較方式と構成要素

Method	R	D	G	U	LLM
R	yes	–	–	–	–
R+D	yes	yes	–	–	–
R+D+G	yes	yes	yes	–	–
Proposed	yes	yes	yes	yes	候補
LLM-only	–	–	–	–	全文

は実行環境およびデータ送信条件が異なるため，本節の定量比較には含めない．

ここで R, D, G はそれぞれ正規表現, 固定辞書, GiNZA, U は提案手法固有の Recall 優先 EMAIL 候補生成を表す．提案手法で使用する R, D, G の実装は比較方式 R+D+G と同一である．したがって, 提案手法は単純な $(R+D+G)$+LLM ではなく，R+D+G による候補抽出に U を追加し，そのうち曖昧候補だけを LLM で判定・補正する構成である．比較方式 R+D+G では U も LLM 補正も使用しない．一方，LLM-only は正規表現，辞書，GiNZA による候補制約を用いず，入力文章全体から PII を抽出する方式である．

提案手法と LLM-only では，同一のローカル LLM である `gpt-oss:20b` を使用し，temperature=0.0，reasoning effort=`low`，context length=4096，timeout=180 秒に統一した．ローカル方式の処理時間は，Windows，NVIDIA GeForce RTX 4060 8GB，メインメモリ 16GB の PC 上で計測した．

評価では，全評価文書・対象 PII 種別の真陽性（True Positive: TP），偽陽性（False Positive: FP），偽陰性（False Negative: FN）を合算し，micro-average の Precision，Recall，F1 を算出する．PII 種別ごとの F1 は，各種別内で同様に TP，FP，FN を集計して算出する．Exact 一致では，PII 種別，span の開始位置，終了位置がすべて正解データと一致した場合のみ TP とする．Relaxed 一致では，PII 種別が一致し，正解 span と予測 span が 1 文字以上重複しており，さらに Unicode NFKC 正規化後の正解文字列と予測文字列の一方が他方を包含する場合を一致とする．複数の正解エンティティと予測エンティティが重なる場合には，一つの予測と一つの正解を重複使用しない one-to-one matching を行う．

F1 の 95%信頼区間は，文書単位のブートストラップ法を用いて算出する．具体的には，評価対象の文書集合から元の文書数と同数の文書を復元抽出し，その標本に対する F1 を計算する処理を 2,000 回繰り返す．乱数シードは 42 に固定し，得られた F1 分布の 2.5 パーセンタイルおよび 97.5 パーセンタイルを 95%信頼区間とする．

さらに，R+D+G と提案手法の性能差を評価するため，文書単位の対応付きブートストラップ（paired bootstrap）を行う．各反復では，同一の文書インデックスを用いて R+D+G と提案手法の双方の結果を復元抽出し，それぞれ

表 2 日本語ホールドアウト 500 文書における評価結果．ただし，LLM は LLM 呼び出し率を表す．LLM 推論失敗は Proposed で 0 件，LLM-only で 21 件であった．

Method	Exact F1	Relaxed F1	Mean [s]	LLM [%]
R	0.350	0.504	0.00009	0.0
R+D	0.338	0.579	0.00029	0.0
R+D+G	0.356	0.672	0.02617	0.0
Proposed	**0.454**	**0.790**	11.966	85.2
LLM-only	0.412	0.625	38.757	100.0

の F1 を算出した後，

$$\Delta F1 = F1_{\text{Proposed}} - F1_{\text{R+D+G}}$$

を求める．ここで，$F1_{\text{Proposed}}$ は提案手法，$F1_{\text{R+D+G}}$ は R+D+G の F1 を表す．同一文書を対応付けて再標本化することで，文書ごとの難易度の違いを保ったまま二方式の性能差を評価できる．この処理を 2,000 回行い，得られた $\Delta F1$ 分布の 2.5 パーセンタイルと 97.5 パーセンタイルを性能差の 95%信頼区間とする．

4.3 検出精度の評価結果

表 2 に主要な評価結果を示す．R+D+G を基本とする候補抽出に，Recall 優先 EMAIL 候補生成と LLM 補正を導入した提案手法では, Exact F1 は 0.356 から 0.454 へ, Relaxed F1 は 0.672 から 0.790 へ向上した．対応付きブートストラップによる F1 差は Exact で+0.0980（95% CI=[0.0864, 0.1095]），Relaxed で+0.1179（95% CI=[0.1053, 0.1301]）であり，いずれも信頼区間は 0 を跨がなかった．

また，LLM-only は Exact F1=0.412，Relaxed F1=0.625 であり，提案手法は同じホールドアウト 500 文書上でこれを上回った．LLM-only に対する対応付きブートストラップによる F1 差は, Exact で+0.0418（95% CI=[0.0003, 0.0847]），Relaxed で+0.1654（95% CI=[0.1237, 0.2074]）であり，いずれも信頼区間は 0 を跨がなかった．

4.4 PII 種別ごとの結果

表 3 に，R+D+G，Proposed，LLM-only の PII 種別ごとの F1 を示す．最も大きな改善が見られたのは EMAIL である．Exact F1 は 0.309 から 0.733 へ，Relaxed F1 は 0.558 から 0.971 へ向上した．F1 差の 95% CI は Exact で [0.3665, 0.4852]，Relaxed で [0.3557, 0.4721] であり，いずれも 0 を跨がなかった．これは，local part に非 ASCII 文字を含む EMAIL を最初から厳密に切り出そうとするのではなく，まず広めに候補化し，その後 LLM が `REPLACE` で正しい範囲へ補正する構成全体が未見データでも有効に働いた結果と考えられる．ただし，提案手法では Recall 優先候補生成と LLM 境界補正を同時に導入しているため，本実験から両者の寄与を分離することはできず，EMAIL の改善を LLM 補正単独の効果とは解釈しない．

© 2026 Information Processing Society of Japan

表 3　PII 種別ごとの F1

	Exact F1			Relaxed F1		
Type	R+D+G	Proposed	LLM-only	R+D+G	Proposed	LLM-only
ADDRESS	0.356	**0.357**	0.220	**0.672**	0.666	0.475
CREDIT_CARD	**1.000**	0.996	0.543	**1.000**	0.996	0.543
EMAIL	0.309	**0.733**	0.712	0.558	**0.971**	0.755
PERSON	0.228	0.296	**0.324**	0.581	**0.745**	0.705
PHONE	0.403	0.400	**0.632**	**0.860**	0.859	0.672

表 4　Proposed と LLM-only の実行時間 [s] の比較．Proposed では 500 文書中 426 文書で LLM を使用し，74 文書では使用しなかった．LLM 推論失敗は Proposed で 0 件，LLM-only で 21 件であった．

Method	Mean	p50	p95	LLM/call
Proposed	11.966	11.539	23.320	13.997
LLM-only	38.757	32.980	103.919	38.757

PERSON でも Exact F1 は 0.228 から 0.296 へ，Relaxed F1 は 0.581 から 0.745 へ向上した．F1 差の 95% CI は Exact で [0.0490, 0.0879]，Relaxed で [0.1395, 0.1889] であり，候補の選別や境界補正に LLM を用いる効果が確認できた．

一方，ADDRESS では Exact F1 の差は+0.0002，Relaxed F1 の差は-0.0064 であり，95% CI はいずれも 0 を跨いだ．PHONE でも Exact および Relaxed の差はそれぞれ-0.0029，-0.0007 と小さく，信頼区間は 0 を跨いだ．CREDIT_CARD は R+D+G の F1=1.000 に対して提案手法では 0.996 となり，わずかな低下が見られた．したがって，提案手法の改善は全 PII 種別で一様ではなく，主として EMAIL および PERSON で得られている．

4.5　処理速度の評価結果

表 4 に Proposed と LLM-only の実行特性を示す．提案手法の平均処理時間は 11.97 秒/文書で，LLM-only の 38.76 秒/文書に対して約 3.24 倍高速であった．p95 も 103.92 秒から 23.32 秒へ低下した．また，LLM-only では 500 文書中 21 件の要求が評価パイプライン上で推論失敗として記録されたのに対し，提案手法では 426 回の LLM 呼び出しで失敗は 0 件であった．ここで推論失敗とは，LLM 要求から評価処理へ渡せる有効な結果を得られなかった要求を指す．失敗原因の内訳は本評価では集計していないため，原因別の比較は行わない．

提案手法では 500 文書中 74 文書（14.8%）で曖昧候補が存在せず LLM を呼び出さずに処理が完了し，426 文書（85.2%）では 1 文書につき 1 回 LLM を呼び出した．LLM を使用した 426 回について，LLM 推論時間は 1 回あたり平均 13.997 秒であった．一方，全文から PII を抽出する LLM-only は全 500 文書で LLM を使用し，平均 38.76 秒/文書であった．また，LLM を使用しない R+D+G の平均処理時間は 0.02617 秒/文書であり，前段の候補抽出処理自体は LLM 推論に比べて十分小さい．なお，Proposed で LLM を使用しなかった 74 文書だけの平均処理時間は今回の集計では分離して保存していないため，その値は示さない．したがって，速度差を単純に「LLM を呼ばない文書が多いから」と説明することはできず，LLM を呼び出した場合でも候補の判定と境界補正に処理を限定したことが実行時間短縮に寄与したと考えられる．ただし，本実験では prompt token 数と出力 token 数を保存していないため，時間差の要因を token 数や reasoning 量まで分解することはできない．

4.6　考察

以上の結果から，PII の種類によって適した処理が異なることが分かる．EMAIL と PERSON では候補制約型の補正を含む提案構成で性能向上が見られ，特に local part に非 ASCII 文字を含む EMAIL では，候補生成では Recall を優先し，後段で範囲を絞る構成が未見データでも有効であった．ただし，EMAIL では候補生成と LLM 補正の寄与を分離していない．一方，ADDRESS と PHONE では R+D+G との差は小さく，CREDIT_CARD ではわずかな低下が見られたことから，すべての PII 種別で LLM 補正が同じように有効とは限らない．

一方，本手法では LLM に候補外の PII を探索させないため，前段で候補として拾えなかった情報を後から回復することはできない．したがって，候補生成器の Recall が最終的な性能の上限になる．

開発用データと重複しないホールドアウト 500 文書でも，提案手法は R+D+G に対して Exact および Relaxed の双方で改善し，対応付きブートストラップによる F1 差の 95% 信頼区間も 0 を跨がなかった．また，全体の Exact/Relaxed F1 の点推定値では LLM-only を上回りながら平均処理時間を短縮し，推論失敗も 0 件であった．一方，種別別では PERSON と PHONE の Exact F1 など LLM-only が上回る項目もあり，すべての PII 種別で提案手法が優れるわけではない．これらの結果は，正規表現・辞書・NER で候補を作り，LLM の役割を候補補正に限定する構成の有効性を未見データ上でも支持する．

5.　おわりに

本研究では，正規表現，固定辞書，日本語 NER を用いて PII 候補を抽出し，判定が難しい候補だけをローカル

© 2026 Information Processing Society of Japan

LLM で補正する PII 事前検出手法を提案した．形式が明確な情報は正規表現で高速に処理し，氏名や住所等の非定型情報は辞書と NER で候補を補う．また，local part に非 ASCII 文字を含む EMAIL では Recall を優先した候補生成と LLM による境界補正を組み合わせることで，正規表現だけでは扱いにくい表現にも対応した．

開発用データと重複しない日本語 500 文書を用いたホールドアウト評価では，提案手法は Exact F1=0.454，Relaxed F1=0.790 となり，R+D+G の 0.356，0.672 を上回った．特に EMAIL と PERSON で明確な改善が見られた．また，全文を同じローカル LLM で処理する LLM-only の平均 38.76 秒/文書に対し，提案手法は 11.97 秒/文書で約 3.24 倍高速であった．提案手法では 500 文書中 74 文書で LLM を使用せず，426 文書では 1 回だけ LLM を呼び出し，評価パイプライン上の LLM 推論失敗は 0 件であったのに対し，LLM-only では 21 件であった．

一方，本手法では前段で候補化できなかった PII を後段 LLM が新たに見つけることはできない．また，ADDRESS や PHONE では LLM 補正による明確な改善が確認されず，EMAIL についても候補生成と LLM 補正の個別寄与は本実験では分離していない．今後は候補生成 Recall の改善，各構成要素の個別アブレーション，対応する PII 種別の拡張，異なるデータセットや実運用文書での検証，推論 token 数を含む計算コストの詳細な分析を進める予定である．

参考文献

[1] K. Kajiyama, H. Horiguchi, T. Okumura, M. Morita, and Y. Kano, “De-identifying Free Text of Japanese Electronic Health Records,” *Journal of Biomedical Semantics*, vol. 11, no. 11, pp.65—70, 2020.

[2] K. Mishra, H. Pagare, and K. Sharma, “A Hybrid Rule-based NLP and Machine Learning Approach for PII Detection and Anonymization in Financial Documents,” *Scientific Reports*, vol. 15, no. 22729, 2025.

[3] D. Pissarra, I. Curioso, J. Alveira, D. Pereira, B. Ribeiro, T. Souper, V. Gomes, A. Carreiro, and V. Rolla, “Unlocking the Potential of Large Language Models for Clinical Text Anonymization: A Comparative Study,” in *Proceedings of the Fifth Workshop on Privacy in Natural Language Processing*, pp. 74–84, 2024.

[4] R. Minamoto, Y. Oda, and D. Kawahara, “Detecting Sensitive Personal Information in Japanese Pre-Training Corpora for Large Language Models,” in *Findings of the Association for Computational Linguistics: ACL 2026*, pp. 13341–13354, 2026.

[5] H. Matsuda, “GiNZA - Practical Japanese NLP based on Universal Dependencies,” *Journal of Natural Language Processing*, vol. 27, no. 3, pp. 695–701, 2020.

[6] Amazon Web Services, “Remove PII from Conversations by Using Sensitive Information Filters,” *Amazon Bedrock User Guide*. https://docs.aws.amazon.com/bedrock/latest/userguide/guardrails-sensitive-filters.html Accessed Aug. 14, 2026.

[7] Amazon Web Services, “Languages Supported by Amazon Bedrock Guardrails,” *Amazon Bedrock User Guide*. https://docs.aws.amazon.com/bedrock/latest/userguide/guardrails-supported-languages.html Accessed Aug. 14, 2026.

[8] Ai4Privacy, “OpenPII 1.5M: Multilingual PII Masking Dataset with Asia Pacific Extension,” Hugging Face, 2026. https://huggingface.co/datasets/ai4privacy/pii-masking-openpii-1.5m

© 2026 Information Processing Society of Japan