連合学習における複数通信ラウンドのモデル更新を用いた解析的データ再構成攻撃

山﨑雄輔[1,a)]　三浦 尭之[1]　伊東 燦[2]　岩花 一輝[1]　山下 智也[1]　芝原 俊樹[1]　磯貝 奈穂[1]　深見 匠[1]
田中 政志[1]

概要：連合学習では，各クライアントが手元のデータで計算したモデル更新を複数通信ラウンドにわたって繰り返し共有しモデルを学習する．解析的データ再構成攻撃 SPEAR++は，共有されるモデル更新を観測するだけでデータを厳密に再構成できるが，単一通信ラウンドのモデル更新から再構成できるデータ数は限られ，再構成リスクが小さく見える場合がある．本研究では，同一クライアントが複数通信ラウンドで同じデータを繰り返し用いると，各通信ラウンドのモデル更新が相補的な情報を与えることに着目し，複数通信ラウンドのモデル更新を一つの再構成問題として統合する Multi-Round SPEAR++を提案する．CIFAR-10 を用いた実験では，クライアント当たり 128 件のデータを用いる設定において，単一通信ラウンドのモデル更新のみを用いる既存手法では全件を再構成できるクライアントがほぼ存在しないのに対し，複数通信ラウンドのモデル更新を用いる提案手法では約 82% のクライアントで全件を再構成し，単一通信ラウンドの攻撃に基づく評価が再構成リスクを過小評価し得ることを示した．

キーワード：連合学習，データ再構成攻撃

Analytical Data Reconstruction Attack from Multi-Round Model Updates in Federated Learning

Yusuke Yamasaki[1,a)]　Takayuki Miura[1]　Akira Ito[2]　Kazuki Iwahana[1]　Tomoya Yamashita[1]
Toshiki Shibahara[1]　Naho Isogai[1]　Takumi Fukami[1]　Masashi Tanaka[1]

Abstract: Federated learning trains a model through repeated communication rounds, in which each client shares model updates computed on its local data. SPEAR++, an analytical data reconstruction attack, can exactly reconstruct data from an observed model update alone, but only a limited number of samples can be reconstructed from a single communication round, making the attack appear less effective. We observe that model updates across multiple rounds can provide complementary information when the same client repeatedly uses the same local data, and propose Multi-Round SPEAR++, which integrates multi-round model updates into a single reconstruction problem. On CIFAR-10, with 128 samples per client, single-round SPEAR++ reconstructs all 128 samples for almost no clients, whereas our method does so for approximately 82% of clients, showing that evaluations based on single-round attacks can underestimate reconstruction risk.

Keywords: Federated Learning, Data Reconstruction Attack

1. はじめに

連合学習 [1] は，分散して保持されるデータを共有せずに機械学習モデルを協調的に学習する枠組みであり，機微なデータを外部に出せない場面での活用が期待されている．データを外部に出さずに学習するために，連合学習では，データを保持する各クライアントが配布されたモデルと手元のデータから計算したモデル更新を共有し，サーバ

[1] NTT 株式会社
[2] 東北大学
[a)] yusuke.yamasaki@ntt.com

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

がこれを集約する通信ラウンドを繰り返す．しかし，各クライアントが保持する学習データが，共有されるモデル更新から再構成できることが指摘されている [2]．連合学習の再構成リスクを過小評価しないためには，強力なデータ再構成攻撃による評価が必要である．

近年，モデル更新を観測するだけの攻撃者を想定し，単一のモデル更新からデータを解析的に再構成する手法が提案されている．SPEAR [3] は複数データの厳密な再構成を初めて示し，SPEAR++ [4] はこれをより多くのデータへ拡張した．SPEAR++は，第一層が全結合層と ReLU からなるネットワークにおいて，重み更新をデータとそのデータに対応する勾配を並べた二つの行列の積に分解してデータを再構成する．この分解は一意でないが，真の分解に対応する勾配列は ReLU によりゼロ成分が多く，誤った分解に対応する勾配列は複数の真の勾配列の線形結合となってゼロ成分が少なくなると期待される．そこで SPEAR++は，ゼロ成分の多さを利用した最適化を反復的に解いて真の分解の候補を探索し，得られた候補から真の分解を同定する．SPEAR++が再構成できるデータ数は，第一層の出力幅に経験的に依存することが知られている [4]．

この出力幅は攻撃者には変えられないため，単一通信ラウンドの SPEAR++では再構成できるデータ数が限られ再構成リスクが小さく見える場合がある．一方で，攻撃者は，同一クライアントが複数通信ラウンドで同じ手元のデータを用いる場合，同じデータでも勾配のゼロ成分の位置がラウンドごとに異なり得るので，複数通信ラウンドのモデル更新から相補的な情報を得られる．しかし，既存の SPEAR++はこの複数通信ラウンドのモデル更新を利用しないため，再構成リスクを過小評価している可能性がある．

この可能性に動機づけられ，本研究では，より多数のデータを再構成するために複数通信ラウンドの重み更新を行方向に連結し，一つの再構成問題として解く Multi-Round SPEAR++を提案する．同一クライアントが複数通信ラウンドで共通のデータを用いる場合に着目し，各通信ラウンドの重み更新を共通の入力データに対する分解として表すことで，連結後の重み更新も SPEAR++と同じ形の再構成問題として定式化できる．さらに，単一通信ラウンドの SPEAR++と Multi-Round SPEAR++に共通する候補探索に用いる最適化問題に着目し，真の候補が狭義局所最小解となる条件を解析することで，複数通信ラウンドの追加観測が候補探索に与える効果を分析する．本論文の貢献は次の通りである．

複数通信ラウンドを用いた再構成攻撃（3 節）．複数通信ラウンドの重み更新を共通の入力データに対する分解として表し，一つの再構成問題として扱う Multi-Round SPEAR++を定式化し，再構成アルゴリズムを与える．その際，候補探索への各通信ラウンドの寄与の偏りを抑えるため，各通信ラウンドのモデル更新を正規化する．

候補探索における狭義局所最小条件の解析（4 節）．単一通信ラウンドの SPEAR++と Multi-Round SPEAR++に共通する候補探索問題に着目し，真の候補が狭義局所最小解となるための必要十分条件を導出する．さらに，この条件の成立を実験的に評価するための指標を定める．

複数通信ラウンドによる再構成リスクの評価（5 節）．Multi-Round SPEAR++が単一通信ラウンドの SPEAR++に対し，同じ出力幅のモデル更新からより多くの入力データを再構成し，単一通信ラウンドの攻撃だけでは再構成リスクを過小評価し得ることを実験的に示す．

2. 準備

本節では，2.1 節で記法，2.2 節で連合学習の設定，2.3 節で脅威モデルと既存のデータ再構成攻撃を導入する．

2.1 記法

自然数 k に対し $[k] \coloneqq \{1, \dots, k\}$ とする．ベクトル同士の要素積を $\odot$，またベクトルの要素ごとに適用する指示関数を $I[\cdot]$ で表す．ベクトルの ℓ_p ノルム（$p \in \{1, 2\}$）を $\|\boldsymbol{x}\|_p$，ゼロでない成分の数を $\|\boldsymbol{x}\|_0$ と書き，行列の Frobenius ノルムを $\|\boldsymbol{A}\|_F$ とする．$\boldsymbol{A}$ と行の添字集合 S に対し，$\boldsymbol{A}_S$ を $\boldsymbol{A}$ から S に対応する行を抜き出した部分行列，$\boldsymbol{x}_S$ を $\boldsymbol{x}$ から S に対応する成分を抜き出したベクトルとする．$d-1$ 次元単位球面を $\mathbb{S}^{d-1} \coloneqq \{\boldsymbol{q} \in \mathbb{R}^d : \|\boldsymbol{q}\|_2 = 1\}$ とする．

2.2 連合学習の設定

連合学習では，C 個のクライアント $c \in [C]$ がそれぞれ，入力データ $\boldsymbol{x} \in \mathbb{R}^n$ とラベル y からなるサンプル $(\boldsymbol{x}, y)$ の集合を自身のデータ $\mathcal{D}_c$ として保持し，クライアント間で各自のデータを共有せずに下記の目的関数を最小化する．

$$\min_{\boldsymbol{\theta}} \left[F(\boldsymbol{\theta}) \coloneqq \frac{1}{C} \sum_{c=1}^{C} F_c(\boldsymbol{\theta}) \right], \tag{1}$$

$$F_c(\boldsymbol{\theta}) \coloneqq \frac{1}{|\mathcal{D}_c|} \sum_{(\boldsymbol{x}, y) \in \mathcal{D}_c} \varphi\big(f(\boldsymbol{x}; \boldsymbol{\theta}), y\big).$$

φ はサンプルごとの損失関数，$f(\boldsymbol{x}; \boldsymbol{\theta})$ は $\boldsymbol{\theta}$ でパラメータ化したモデル出力，F_c はクライアント c の目的関数である．

(1) の最小化には，Federated Averaging (FedAvg) [1] が標準的に用いられる．FedAvg は，サーバによるモデルの配布，全クライアントによるモデル更新，サーバによるモデルの集約からなる通信ラウンドを繰り返しモデルの学習を行う．各通信ラウンド $t \in [T]$ の更新則は下記である．

$$\text{Client } c\text{:}\quad \boldsymbol{\theta}_c^{(t,k)} = \boldsymbol{\theta}_c^{(t,k-1)} - \eta^{(t)} \nabla \hat{F}_c(\boldsymbol{\theta}_c^{(t,k-1)}), \tag{2}$$

$$\Delta \boldsymbol{\theta}_c^{(t)} = \boldsymbol{\theta}_c^{(t,K)} - \boldsymbol{\theta}^{(t)}, \tag{3}$$

$$\text{Server:}\quad \boldsymbol{\theta}^{(t+1)} = \boldsymbol{\theta}^{(t)} + \frac{1}{C} \sum_{c=1}^{C} \Delta \boldsymbol{\theta}_c^{(t)}.$$

© 2026 Information Processing Society of Japan

$k \in [K]$ は更新ステップ，$\eta^{(t)}$ は通信ラウンド t の学習率である．$\nabla \hat{F}_c$ は更新ステップ k のサイズ b のミニバッチ $\mathcal{B}_c^{(t,k)} \subseteq \mathcal{D}_c$ 上で計算した勾配であり，下記で表される．

$$\nabla \hat{F}_c(\boldsymbol{\theta}_c^{(t,k-1)}) = \frac{1}{b} \sum_{(\boldsymbol{x},y)\in\mathcal{B}_c^{(t,k)}} \nabla_{\boldsymbol{\theta}} \varphi\big(f(\boldsymbol{x};\boldsymbol{\theta}_c^{(t,k-1)}), y\big).$$

(2),(3) に示す通り，各クライアントは初期値 $\boldsymbol{\theta}_c^{(t,0)} = \boldsymbol{\theta}^{(t)}$ から K 回更新を行い，得られたモデル更新 $\Delta\boldsymbol{\theta}_c^{(t)}$ をサーバに共有する．しかし，共有された $\Delta\boldsymbol{\theta}_c^{(t)}$ から，そのモデル更新に用いられたデータを再構成できることが実験的に確認されている [2]．

2.3 連合学習における解析的データ再構成攻撃

データ再構成攻撃は，クライアントが共有するモデル更新から，サンプルのうち特に入力データ $\boldsymbol{x}$ を再構成する[*1]．この攻撃で一般に想定される脅威モデルは，モデル構造や更新則に介入せず，集約前のモデル更新 $\Delta\boldsymbol{\theta}_c^{(t)}$ と対応するモデル $\boldsymbol{\theta}^{(t)}$ を 1 つ以上の通信ラウンドで観測する攻撃者であり，サーバや通信路上の盗聴者がこれに当たる．この設定は検知されにくく実運用でも成立しやすいため [7]，本稿もこれを対象とする．

この脅威モデルの下でモデル更新から入力データを厳密に再構成する解析的手法は従来単一データの再構成のみに限られていた [8] が，SPEAR [3] は複数データの再構成を初めて示し，SPEAR++ [4] はこれを経験的により多くのデータへ拡張した．以下では，このうち SPEAR++の再構成手続きとその限界を述べる．

SPEAR++は，第一層が重み $\boldsymbol{W} \in \mathbb{R}^{m\times n}$，バイアス $\boldsymbol{b} \in \mathbb{R}^m$ からなるアフィン層 $\boldsymbol{z} = \boldsymbol{W}\boldsymbol{x} + \boldsymbol{b}$ とそれに続く ReLU 活性化 $\boldsymbol{a} = \mathrm{ReLU}(\boldsymbol{z})$ であるモデルを想定し，重みの更新 $\Delta\boldsymbol{W}$ が下記のように分解できることを活用する．各ミニバッチが互いに素であると仮定すると，(2), (3) より下記の分解を得る．

$$\begin{aligned}
\Delta\boldsymbol{W}_c^{(t)} &= -\eta^{(t)} \sum_{k=1}^{K} \nabla_{\boldsymbol{W}} \hat{F}_c(\boldsymbol{\theta}_c^{(t,k-1)}) \\
&= \sum_{k=1}^{K} \sum_{(\boldsymbol{x},y)\in\mathcal{B}_c^{(t,k)}} \underbrace{\Big(-\tfrac{\eta^{(t)}}{b}(\nabla_{\boldsymbol{a}}\varphi) \odot I[\boldsymbol{z}>0]\Big)}_{=:\boldsymbol{g}} \boldsymbol{x}^\top \\
&=: \boldsymbol{G}^{(t)} \boldsymbol{X}^{(t)\top}, \qquad (4) \\
\Delta\boldsymbol{b}_c^{(t)} &= -\eta^{(t)} \sum_{k=1}^{K} \nabla_{\boldsymbol{b}} \hat{F}_c(\boldsymbol{\theta}_c^{(t,k-1)}) = \boldsymbol{G}^{(t)}\mathbf{1}. \qquad (5)
\end{aligned}$$

ここで $B = bK$ は用いた入力データの総数である．(4) の各項の入力データ $\boldsymbol{x}$ と対応する勾配 $\boldsymbol{g}$ をそれぞれ列に並べた行列が，入力データ行列 $\boldsymbol{X}^{(t)} \in \mathbb{R}^{n\times B}$ と勾配行列 $\boldsymbol{G}^{(t)} \in \mathbb{R}^{m\times B}$ である．特に，$\boldsymbol{G}^{(t)}$ は，指示関数 $I[\boldsymbol{z}>0]$ により，各列でゼロ成分が多く疎な行列となる．以降，クライアントおよび通信ラウンドの添え字は，文脈上明らかな場合に省略する．

分解 $\boldsymbol{G}\boldsymbol{X}^\top$ は入力データ $\boldsymbol{X}$ を含むため，真の分解が得られれば $\boldsymbol{X}$ を再構成できる．しかし $\Delta\boldsymbol{W}$ の分解は一意でない．そこで SPEAR++は，まず特異値分解 $\Delta\boldsymbol{W} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^\top$ から一つの分解 $\boldsymbol{L} := \boldsymbol{U} \in \mathbb{R}^{m\times B}$，$\boldsymbol{R} := \boldsymbol{\Sigma}\boldsymbol{V}^\top \in \mathbb{R}^{B\times n}$ を定める．$\boldsymbol{G}$ と $\boldsymbol{X}$ がともに列フルランクならば，$\boldsymbol{L}$ と真の $\boldsymbol{G}$ はともに $\Delta\boldsymbol{W}$ の列空間を張るため，真の $\boldsymbol{G}$ は $\boldsymbol{L}$ を正則変換 $\boldsymbol{Q} \in \mathbb{R}^{B\times B}$ で移したものとして下記のように一意に表せる [3]．

$$\boldsymbol{G} = \boldsymbol{L}\boldsymbol{Q}, \qquad \boldsymbol{X}^\top = \boldsymbol{Q}^{-1}\boldsymbol{R}.$$

よって，入力データ $\boldsymbol{X}$ の再構成は，$\boldsymbol{L}$ をゼロ成分の多い真の $\boldsymbol{G}$ へ移す変換 $\boldsymbol{Q}$ の同定に帰着される．

$\boldsymbol{Q}$ を同定するために，SPEAR++はまずその各列 $\boldsymbol{q} \in \mathbb{R}^B$ を求める．(4) より $\boldsymbol{G}$ は各列でゼロ成分が多く $\boldsymbol{G} = \boldsymbol{L}\boldsymbol{Q}$ だから，各 $\boldsymbol{q}$ は $\boldsymbol{L}\boldsymbol{q}$ のゼロ成分を多くするベクトルである．そこで，経験的な目的関数として下記をおく．

$$\min_{\boldsymbol{q}\in\mathbb{S}^{B-1}} \|\boldsymbol{L}\boldsymbol{q}\|_1. \qquad (6)$$

これを異なる初期値から反復的に解いて B 本以上の候補集合 $\mathcal{C}$ を得る [4]．$\mathcal{C}$ には，真の $\boldsymbol{q}$ のほかに偽の候補も混じる．偽の候補では $\boldsymbol{L}\boldsymbol{q}$ が真の複数列の線形結合となり，列ごとにゼロの位置が重なりづらいため，真の $\boldsymbol{q}$ に比べて $\boldsymbol{L}\boldsymbol{q}$ のゼロ成分が少なくなることが期待される．そこで，$\boldsymbol{L}\boldsymbol{q}$ のゼロ成分数が τm 未満のものを棄却する疎性フィルタを適用する．閾値 τ は，各 ReLU が独立に確率 1/2 で非活性となる仮定の下で，真の $\boldsymbol{q}$ を誤って棄却する確率が小さくなるように定める．

そのうえで，SPEAR++は，$\boldsymbol{L}\tilde{\boldsymbol{q}}$ のゼロ成分が多い候補から順に，線形独立性を保ちながらマスク整合度が最大となるように B 本を貪欲に選ぶ．選んだ候補を並べた行列を $\hat{\boldsymbol{Q}}_{\mathrm{d}} = [\hat{\boldsymbol{q}}_1, \ldots, \hat{\boldsymbol{q}}_B]$ とし，スケールと符号 $\boldsymbol{s}$ を，バイアス更新 (5) から得られる線形方程式 $\Delta\boldsymbol{b} = \boldsymbol{L}\hat{\boldsymbol{Q}}_{\mathrm{d}}\boldsymbol{s}$ を解いて復元して $\hat{\boldsymbol{Q}} = \hat{\boldsymbol{Q}}_{\mathrm{d}}\,\mathrm{diag}(\boldsymbol{s})$ を定めると，入力データは $\hat{\boldsymbol{X}}^\top = \hat{\boldsymbol{Q}}^{-1}\boldsymbol{R}$ として再構成される．マスク整合度は，その各列 $\hat{\boldsymbol{x}}_j$ について観測した $\boldsymbol{W}$ と $\boldsymbol{b}$ から求めた $\boldsymbol{W}\hat{\boldsymbol{x}}_j + \boldsymbol{b}$ の正の成分の位置が，候補列 $\boldsymbol{L}\hat{\boldsymbol{q}}_j$ のゼロでない成分の位置と一致する程度で測る[*2]．

このように，SPEAR++は，$\boldsymbol{Q}$ の同定を連続最適化で行うことで，組合せ探索に頼り再構成できる入力データ数が $B = 25$ までに限られる SPEAR よりも多くの入力データを厳密に再構成できる．具体的には，再構成できる入力データ数 B は第一層の出力幅 m とともに増える．$m = 4000$

[*1] ラベルの推定は入力データの再構成とは独立した問題であり，バッチに対しても専用手法が確立している [5,6]．

[*2] $K = 1$ ではこの照合は厳密だが，$K > 1$ では途中の更新ステップのモデルが観測した $\boldsymbol{W}$ と異なるため近似となる [3]．

© 2026 Information Processing Society of Japan

では $B = 210$ に達する一方，$m = 200$ では B は 25 程度にとどまることが経験的に確認されている [4] が，その仕組みは理論的には明らかになっていない．

この出力幅は攻撃対象のモデルで決まり攻撃者には変えられないため，幅の小さいモデルでは再構成リスクが小さく見える．一方，各クライアントが同じデータを繰り返し用いる連合学習では，学習が進んでモデルが更新されるにつれ，同じデータでも勾配 $\boldsymbol{G}$ のゼロ成分の位置がラウンド間で変化する．そのため，攻撃者が観測し得る複数通信ラウンドのモデル更新は単一ラウンドにないゼロ成分の情報を与えうるが，単一ラウンドの SPEAR++はこれを活かせておらず，単一ラウンドだけに基づく評価は再構成リスクを過小評価しかねない．そこで次節では，複数通信ラウンドのモデル更新を用いた再構成問題を定式化する．

3. 提案手法: Multi-Round SPEAR++

本節では，同一クライアントが複数通信ラウンドで共通の入力データ集合を用いる設定を対象に，Multi-Round SPEAR++を提案する．この設定では，各通信ラウンドの重み更新を共通の入力データに対する分解として表し，行方向に連結することで，SPEAR++と同型の一つの再構成問題として扱える．3.1 節で再構成問題を定式化し，3.2 節で再構成アルゴリズムを与える．

3.1 複数通信ラウンドのモデル更新を用いた再構成問題の定式化

Multi-Round SPEAR++では，通信ラウンドが異なると同じ入力データでも勾配のゼロ成分の位置が異なり得ることに着目する．複数通信ラウンドで得られるゼロ成分の情報を併せて再構成に用いるため，各通信ラウンドのモデル更新を共通の入力データ行列 $\boldsymbol{X}$ に対する分解として表し，一つの再構成問題として定式化する．この定式化のためには，再構成に用いる各通信ラウンドのモデル更新が，共通の入力データ集合を用いて計算されている必要がある．この条件を，再構成に用いる通信ラウンドの集合 $\mathcal{T} = \{t_1, \dots, t_{|\mathcal{T}|}\}$ に対して次のように仮定する．

仮定 1. 各 $t \in \mathcal{T}$ で (3) の計算に用いた入力データ行列 $\boldsymbol{X}^{(t)}$ は，共通の入力データ行列 $\boldsymbol{X} = [\boldsymbol{x}_1, \dots, \boldsymbol{x}_B] \in \mathbb{R}^{n \times B}$ を並べ替えたものであり，ある置換行列 $\boldsymbol{P}^{(t)} \in \mathbb{R}^{B \times B}$ により $\boldsymbol{X}^{(t)} = \boldsymbol{X}\boldsymbol{P}^{(t)}$ と書ける．

この仮定は，各クライアントが固定したローカルデータを保持し，各通信ラウンドでその全体を並べ替えて順に勾配更新に用いる標準的な設定で成り立つ．一方，各通信ラウンドで異なる部分集合を抽出する場合やデータ拡張を行う場合など，通信ラウンドごとに用いるデータ集合全体が変わる設定では成り立たない．

各通信ラウンド t の勾配行列を 2.3 節と同様に $\boldsymbol{G}^{(t)} \in \mathbb{R}^{m \times B}$ とする．仮定 1 と (4) より，第一層の重み更新は下記のように表される．

$$\Delta \boldsymbol{W}^{(t)} = \boldsymbol{G}^{(t)} \boldsymbol{X}^{(t)\top} = \boldsymbol{G}^{(t)} \boldsymbol{P}^{(t)\top} \boldsymbol{X}^\top = \overline{\boldsymbol{G}}^{(t)} \boldsymbol{X}^\top.$$

ここで $\overline{\boldsymbol{G}}^{(t)} := \boldsymbol{G}^{(t)} \boldsymbol{P}^{(t)\top}$ は $\boldsymbol{G}^{(t)}$ の列を並べ替えた行列である．したがって，(4) と同様に，各列が ReLU によりゼロ成分が多い疎な勾配行列と，共通の入力データ行列 $\boldsymbol{X}$ の積として表される．

ここで，各通信ラウンドの重み更新 $\{\Delta \boldsymbol{W}^{(t)}\}_{t \in \mathcal{T}}$ とバイアス更新 $\{\Delta \boldsymbol{b}^{(t)}\}_{t \in \mathcal{T}}$ を行方向に連結すると，下記の分解を得る．

$$\Delta \boldsymbol{W}^{(\mathcal{T})} := \begin{bmatrix} \Delta \boldsymbol{W}^{(t_1)} \\ \vdots \\ \Delta \boldsymbol{W}^{(t_{|\mathcal{T}|})} \end{bmatrix} = \underbrace{\begin{bmatrix} \overline{\boldsymbol{G}}^{(t_1)} \\ \vdots \\ \overline{\boldsymbol{G}}^{(t_{|\mathcal{T}|})} \end{bmatrix}}_{\boldsymbol{G}^{(\mathcal{T})} \in \mathbb{R}^{|\mathcal{T}| m \times B}} \boldsymbol{X}^\top = \boldsymbol{G}^{(\mathcal{T})} \boldsymbol{X}^\top,$$

$$\Delta \boldsymbol{b}^{(\mathcal{T})} = \boldsymbol{G}^{(\mathcal{T})} \mathbf{1}.$$

行数が m から $|\mathcal{T}|m$ へ増える点を除いて，この分解は (4) の単一通信ラウンドの $\boldsymbol{G}\boldsymbol{X}^\top$ と同じ形をもつ．したがって，$\boldsymbol{G}^{(\mathcal{T})}$ と $\boldsymbol{X}$ がともに列フルランクであれば，2.3 節と同様に，$\Delta \boldsymbol{W}^{(\mathcal{T})}$ の特異値分解 $\Delta \boldsymbol{W}^{(\mathcal{T})} = \boldsymbol{L}^{(\mathcal{T})} \boldsymbol{R}^{(\mathcal{T})}$ で得た左特異行列 $\boldsymbol{L}^{(\mathcal{T})}$ に対し，$\boldsymbol{G}^{(\mathcal{T})} = \boldsymbol{L}^{(\mathcal{T})} \boldsymbol{Q}$ を満たす変換 $\boldsymbol{Q}$ を同定する問題として定式化できる．

ただし，各通信ラウンドの重み更新をそのまま連結すると，通信ラウンド間の重み更新の大きさの違いが $\boldsymbol{Q}$ の候補探索における ℓ_1 最小化に影響する．この影響を明らかにするため，目的関数を下記のように変形する．

$$\min_{\|\boldsymbol{q}\|_2 = 1} \|\boldsymbol{L}^{(\mathcal{T})} \boldsymbol{q}\|_1 = \min_{\boldsymbol{h}:\, \Delta \boldsymbol{W}^{(\mathcal{T})} \boldsymbol{h} \neq \mathbf{0}} \left[\frac{\sum_{t \in \mathcal{T}} \|\Delta \boldsymbol{W}^{(t)} \boldsymbol{h}\|_1}{\left(\sum_{t \in \mathcal{T}} \|\Delta \boldsymbol{W}^{(t)} \boldsymbol{h}\|_2^2 \right)^{\frac{1}{2}}} \right].$$

この変形は，$\boldsymbol{R}^{(\mathcal{T})}$ が行フルランクであること，$\boldsymbol{L}^{(\mathcal{T})}$ の列が正規直交することから従う．導出の詳細は A.1 節に示す．上式から，モデル更新の大きさ $\|\Delta \boldsymbol{W}^{(t)}\|_F$ が通信ラウンド間で異なれば，候補探索の目的関数に対する各通信ラウンドの相対的な寄与が変化することが分かる．そのため，モデル更新のスケールが大きい通信ラウンドの影響が相対的に強く，小さい通信ラウンドの影響が弱くなり，各通信ラウンドから得られる情報を均等に候補探索へ反映できない．そこで，通信ラウンド間のモデル更新の大きさの違いによる目的関数値への寄与の偏りを抑えるため，各通信ラウンドのモデル更新を重み更新の Frobenius ノルムで正規化し，そのスケールを揃える．

$$\widetilde{\Delta \boldsymbol{W}}^{(t)} := \frac{\Delta \boldsymbol{W}^{(t)}}{\alpha^{(t)}}, \qquad \widetilde{\Delta \boldsymbol{b}}^{(t)} := \frac{\Delta \boldsymbol{b}^{(t)}}{\alpha^{(t)}}. \tag{7}$$

ここで，$\alpha^{(t)} := \|\Delta \boldsymbol{W}^{(t)}\|_F$ とし $\widetilde{\boldsymbol{G}}^{(\mathcal{T})} := [\overline{\boldsymbol{G}}^{(t_1)}/\alpha^{(t_1)}, \dots, \overline{\boldsymbol{G}}^{t_{|\mathcal{T}|}}/\alpha^{(t_{|\mathcal{T}|})}]^\top$ とおいて，正規化し

© 2026 Information Processing Society of Japan

Algorithm 1 Multi-Round SPEAR++

入力: $\{\Delta \boldsymbol{W}^{(t)}, \Delta \boldsymbol{b}^{(t)}, \boldsymbol{W}^{(t)}, \boldsymbol{b}^{(t)}\}_{t\in\mathcal{T}}$, B, τ, $\varepsilon_{\mathrm{dup}}$, N_{init}
出力: $\hat{\boldsymbol{X}}$

1: **for** $t \in \mathcal{T}$ **do** ▷ 通信ラウンドごとの正規化 (7)
2: $\alpha^{(t)} \leftarrow \|\Delta \boldsymbol{W}^{(t)}\|_F$
3: $\widetilde{\Delta \boldsymbol{W}}^{(t)} \leftarrow \Delta \boldsymbol{W}^{(t)}/\alpha^{(t)}$, $\widetilde{\Delta \boldsymbol{b}}^{(t)} \leftarrow \Delta \boldsymbol{b}^{(t)}/\alpha^{(t)}$
4: **end for**
5: (8) により $\widetilde{\Delta \boldsymbol{W}}^{(\mathcal{T})}, \widetilde{\Delta \boldsymbol{b}}^{(\mathcal{T})}$ へ連結
6: $\widetilde{\boldsymbol{L}}^{(\mathcal{T})}, \widetilde{\boldsymbol{R}}^{(\mathcal{T})} \leftarrow \mathrm{SVD}(\widetilde{\Delta \boldsymbol{W}}^{(\mathcal{T})}, B)$
7: $\mathcal{C} \leftarrow \emptyset$
8: **for** $r = 1, \ldots, N_{\mathrm{init}}$ **do**
9: (9) をランダムな初期値から解き，候補 $\boldsymbol{q}$ を得る
10: **if** $\max_{t\in\mathcal{T}} \big\|(\widetilde{\boldsymbol{L}}^{(\mathcal{T})}\boldsymbol{q})_{\mathcal{I}_t}\big\|_0 \le (1-\tau)m \ \wedge \ \max_{\tilde{\boldsymbol{q}}\in\mathcal{C}} |\tilde{\boldsymbol{q}}^\top \boldsymbol{q}| < 1-\varepsilon_{\mathrm{dup}}$ **then** ▷ ブロックごとの疎性フィルタ
11: $\mathcal{C} \leftarrow \mathcal{C} \cup \{\boldsymbol{q}\}$
12: **end if**
13: **end for**
14: $\hat{\boldsymbol{Q}} \leftarrow \textsc{GreedyFilter}(\mathcal{C}, \mathrm{Score}_{\mathcal{T}})$
15: **return** $\hat{\boldsymbol{X}}$ s.t. $\hat{\boldsymbol{X}}^\top = \hat{\boldsymbol{Q}}^{-1}\widetilde{\boldsymbol{R}}^{(\mathcal{T})}$

たモデル更新を連結することで下記を得る．

$$\widetilde{\Delta \boldsymbol{W}}^{(\mathcal{T})} = \widetilde{\boldsymbol{G}}^{(\mathcal{T})}\boldsymbol{X}^\top, \qquad \widetilde{\Delta \boldsymbol{b}}^{(\mathcal{T})} = \widetilde{\boldsymbol{G}}^{(\mathcal{T})}\mathbf{1}. \tag{8}$$

この正規化は各ラウンドの勾配行列を同じ係数でスケールするだけであり，共通の入力データ行列 $\boldsymbol{X}$ に対する分解構造は保たれる．したがって，正規化後の重み更新についても 2.3 節と同様の再構成手続きにより，入力データを再構成できる．次節では，この正規化後の再構成問題を解く Multi-Round SPEAR++のアルゴリズムを与える．

3.2 Multi-Round SPEAR++の再構成アルゴリズム

(8) で得た正規化後の重み更新から，$\widetilde{\Delta \boldsymbol{W}}^{(\mathcal{T})}$ に対し，rank-B の特異値分解 $\widetilde{\Delta \boldsymbol{W}}^{(\mathcal{T})} = \widetilde{\boldsymbol{L}}^{(\mathcal{T})}\widetilde{\boldsymbol{R}}^{(\mathcal{T})}$ を求める．2.3 節と同様に，$\widetilde{\boldsymbol{G}}^{(\mathcal{T})} = \widetilde{\boldsymbol{L}}^{(\mathcal{T})}\boldsymbol{Q}$ を満たす変換 $\boldsymbol{Q}$ を同定するために，まず，$\boldsymbol{Q}$ の各列 $\boldsymbol{q}$ の候補を，次の球面上の ℓ_1 最小化により探索する．

$$\min_{\boldsymbol{q}\in\mathbb{S}^{B-1}} \|\widetilde{\boldsymbol{L}}^{(\mathcal{T})}\boldsymbol{q}\|_1. \tag{9}$$

最適化により得られた候補には，真の $\boldsymbol{q}$ のほかに偽の候補も混じるため，2.3 節と同様に，候補が真の勾配に対応するかを判定するために疎性フィルタと，マスク整合度を用いる．ただし，真の $\boldsymbol{q}$ に対する $\widetilde{\boldsymbol{L}}^{(\mathcal{T})}\boldsymbol{q}$ は，各通信ラウンドにおける同一入力データの勾配を行方向に連結したベクトルとなるので，各通信ラウンドに対応する行ブロックごとに，判別を行う．通信ラウンド t に対応する m 行の添字集合を $\mathcal{I}_t$ とする．

Multi-Round SPEAR++の再構成アルゴリズムの全体像をアルゴリズム 1 に示す．通信ラウンドごとの正規化（2–3 行目），重み更新の連結（5 行目），ブロックごとの疎性フィルタ（10 行目）が SPEAR++からの主な差分である．GreedyFilter の詳細は A.3 節に示す．

4. 解析

前節では，Multi-Round SPEAR++が，複数通信ラウンドのモデル更新を正規化して連結することで，SPEAR++と同じ形の球面上の ℓ_1 最小化 (9) による候補探索として扱えることを示した．SPEAR++と Multi-Round SPEAR++はいずれも，この球面上の ℓ_1 最小化を異なる初期値から反復的に解いて，真の変換 $\boldsymbol{Q}$ の各列に対応する候補 $\boldsymbol{q}_i$ を探索する．本節では，真の候補がこの最適化問題の狭義局所最小解となるための必要十分条件を導出し，その成立を評価する量を定める．

単一通信ラウンドの (6) と Multi-Round の (9) に共通する候補探索の目的関数を，列正規直交行列 $\boldsymbol{L} \in \mathbb{R}^{M\times B}$ を用いて下記で表す．

$$\Psi_{\boldsymbol{L}}(\boldsymbol{q}) \coloneqq \|\boldsymbol{L}\boldsymbol{q}\|_1, \qquad \boldsymbol{q} \in \mathbb{S}^{B-1}.$$

ここで $\boldsymbol{L}$ は，単一通信ラウンドの SPEAR++では $\boldsymbol{L}^{(t)}$，Multi-Round SPEAR++では $\widetilde{\boldsymbol{L}}^{(\mathcal{T})}$ に当たる左特異行列であり，行数 M はそれぞれ m，$|\mathcal{T}|m$ である．$\Psi_{\boldsymbol{L}}$ の狭義局所最小性について，次の必要十分条件を得る．

命題 1 (局所最小の必要十分条件)**.** $\boldsymbol{q}$ が $\Psi_{\boldsymbol{L}}$ の狭義局所最小解であることは，下記を満たす $(\boldsymbol{u}, \lambda)$ が存在することと同値である．

$$\mathrm{rank}(\boldsymbol{L}_A) = B - 1, \tag{10}$$

$$\boldsymbol{L}_{A^c}^\top \mathrm{sign}(\boldsymbol{L}_{A^c}\boldsymbol{q}) + \boldsymbol{L}_A^\top \boldsymbol{u} + \lambda \boldsymbol{q} = \mathbf{0}, \tag{11}$$

$$\|\boldsymbol{u}\|_\infty < 1. \tag{12}$$

ここで，$A = \{j \in [M] \mid (\boldsymbol{L}\boldsymbol{q})_j = 0\}$，$A^c \coloneqq [M] \setminus A$ とした．

証明は A.2 節に示す．以下では，命題 1 を真の変換 $\boldsymbol{Q}$ の各列に対応する単位方向 $\boldsymbol{q}_i$ に適用し，二つの条件が候補探索において何を意味するかを解釈する．

真の勾配行列は $\boldsymbol{G} = \boldsymbol{L}\boldsymbol{Q}$ であり，$\boldsymbol{Q}$ は正則であるから，$A_i = \{j \in [M] \mid (\boldsymbol{L}\boldsymbol{q}_i)_j = 0\}$ とすると $\mathrm{rank}(\boldsymbol{G}_{A_i}) = \mathrm{rank}(\boldsymbol{L}_{A_i})$ が成り立つ．したがって，(10) は $\mathrm{rank}(\boldsymbol{G}_{A_i}) = B - 1$ と等価である．$\boldsymbol{G}_{A_i}$ ではサンプル i に対応する列がゼロであるから，この条件は，サンプル i の勾配がゼロとなるニューロンにおいて，残りの $B-1$ サンプルの勾配列が線形独立であることを意味する．したがって，候補探索に用いる行が追加されても，$\boldsymbol{G}_{A_i}$ のランクを増加させなければこの条件の成立には寄与しない．

一方，(11)–(12) の成立は，(11) を制約として $\|\boldsymbol{u}\|_\infty$ を最小化した最適値から判定できる．真の候補 $\boldsymbol{q}_i$ に対して双対マージンを下記で定める．

$$\gamma_i \coloneqq 1 - \min_{\boldsymbol{u},\lambda} \|\boldsymbol{u}\|_\infty \tag{13}$$
$$\text{s.t.} \quad \boldsymbol{L}_{A_i^c}^\top \mathrm{sign}(\boldsymbol{L}_{A_i^c}\boldsymbol{q}_i) + \boldsymbol{L}_{A_i}^\top \boldsymbol{u} + \lambda \boldsymbol{q}_i = \mathbf{0}.$$

© 2026 Information Processing Society of Japan

ここで実行可能解が存在しない場合は $\gamma_i := -\infty$ とする．このとき，(11)–(12) の成立は $\gamma_i > 0$ と同値である．

以上より，真の候補 $\boldsymbol{q}_i$ が狭義局所最小解であることは，ランク条件 $\mathrm{rank}(\boldsymbol{L}_{A_i}) = B-1$ と双対マージン条件 $\gamma_i > 0$ の成立と同値である．一方，狭義局所最小解であっても，有限回の最適化でその候補が発見されるとは限らない．そこで，5.3 節では，この二条件の成立と候補探索結果を用いて，再構成に至らない要因を段階的に分析する．

5. 実験

本節では，Multi-Round SPEAR++が，単一通信ラウンドの SPEAR++より同じ出力幅のモデルから多くの入力データを再構成し，単一ラウンドの攻撃だけでは再構成リスクを過小評価し得ることを実験的に示す．さらに，4 節の解析を用いて複数ラウンドによる再構成性能の向上の要因を分析する．

5.1 実験設定

データセット．データセットには CIFAR-10 [9] を用いた．各画像を平坦化して入力次元 $n = 3072$ のベクトル $\boldsymbol{x}$ とし，データセットの平均・標準偏差を用いて正規化した．各クライアントでクラスラベルの分布が均等になるよう訓練データを分割し，ローカルデータ $\mathcal{D}_c$ を構成した．

モデル．攻撃対象のモデルには，第一層が 2.3 節のアフィン層と ReLU 活性化からなる 4 層の全結合 ReLU ネットワークを用いた．第一層を含む 3 つの中間層の出力幅を m，最終層の出力幅を 10 とした．単一通信ラウンドの SPEAR++では再構成できるデータ数が第一層の出力幅に依存するため，異なる出力幅における提案手法の効果を評価する目的で，$m \in \{200, 500, 1000\}$ とした．重みは He 初期化 [10] により，各成分をその層の入力次元 n_{in} を用いて $\mathcal{N}(0, 2/n_{\mathrm{in}})$ から独立に取り，バイアスは $\mathbf{0}$ とした．

連合学習の設定．クライアント数を $C = 128$ とし，FedAvg により学習した．再構成可能なデータ数の限界を評価するため，各クライアントのローカルデータ数を $B = |\mathcal{D}_c| \in \{32, 48, 64, 80, 96, 112, 128, 160, 192\}$ とし，各通信ラウンドで $\mathcal{D}_c$ 全体をモデル更新に用いた．また，複数回のローカル更新を行う場合にも提案手法の効果を確認するため，各クライアントの更新回数は $K \in \{1, 4\}$ とした．$K = 1$ では $\mathcal{D}_c$ 全体を一度に勾配計算に用いる一方で，$K = 4$ では，各通信ラウンドで $\mathcal{D}_c$ 全体を並べ替え，互いに素な K 個のミニバッチに分割して各データを一度ずつ用いた．このときミニバッチサイズは $b = B/K$ であり，各通信ラウンドで用いる入力データ集合は共通であるため仮定 1 を満たす．学習率は全ての通信ラウンドで一定とし，$K = 1$ で $\eta = 0.05$，$K = 4$ で $\eta = 0.025$ とした．

比較手法．最初の通信ラウンドのモデル更新のみを用いる SPEAR++ [4], および各クライアントの最初の $|\mathcal{T}| = 10$ 通信ラウンドのモデル更新を用いる提案法 Multi-Round SPEAR++を比較した．

再構成の設定．比較する全手法で候補探索の設定を共通とした．SPEAR++ [4] と同様に，単一通信ラウンドの手法では (6)，提案手法では (9) をそれぞれランダムな初期値から Riemannian Adam [11] で解いて候補を生成した．各手法を公平に評価するため，2×10^5 回の初期値を与えた．その他の実装詳細は [4] に倣った．

評価指標．原画像と再構成画像の画素値を $[0, 1]$ の範囲に戻し，平均二乗誤差に基づく PSNR で評価する．主指標には，ローカルデータ B 個すべての PSNR が閾値を超えたクライアントの割合である完全再構成率 (Full recovery rate) を用い，以下で定義する．

$$\text{(Full recovery rate)} := \frac{1}{|\mathcal{E}|}\left|\left\{ c \in \mathcal{E} : \min_{\boldsymbol{x} \in \mathcal{D}_c} \mathrm{PSNR}(\boldsymbol{x}, \hat{\boldsymbol{x}}) > 80 \right\}\right|.$$

ここで $\mathcal{E} \subseteq [C]$ はクライアント集合，$\boldsymbol{x}$ と $\hat{\boldsymbol{x}}$ は原データと対応する再構成データであり，対応は PSNR に基づくハンガリアンマッチングで求める．閾値 80 は，PSNR 分布が 80 付近で明確に分離したことに基づき定めた．各乱数シードで 32 クライアントを評価し，3 シードの平均と標準偏差を示す．

5.2 提案法による再構成可能なデータ数の拡大

図 1 に，第一層の出力幅 m とローカルデータ数 B を変えたときの完全再構成率を示す．$K = 1$ では，すべての出力幅 m において，Multi-Round SPEAR++は単一通信ラウンドの SPEAR++より大きな B まで高い完全再構成率を示す．特に $m = 1000$, $B = 128$ では，単一通信ラウンドの SPEAR++がほとんど完全再構成できないのに対し，Multi-Round SPEAR++は約 0.82 の完全再構成率を示す．また，出力幅の小さい $m = 200$ でも，単一通信ラウンドの SPEAR++が $B = 32$ でほとんど完全再構成できないのに対し，Multi-Round SPEAR++は約 0.97 の完全再構成率を示す．さらに，$K = 4$ でも，Multi-Round SPEAR++が単一通信ラウンドの SPEAR++を一貫して上回る傾向は維持される．これらの結果は，複数通信ラウンドのモデル更新を用いることで，より大きなローカルデータ数 B まで完全再構成が可能となり，単一通信ラウンドのモデル更新のみに基づく攻撃評価が再構成リスクを過小評価し得ることを示している．

また，図 2 に，(7) に示す通信ラウンドごとの正規化の有無による Multi-Round SPEAR++の SPEAR++に対する完全再構成率の改善量を示す．正規化ありは正規化なしと同等以上の改善量を示し，特に $m = 1000$, $B \geq 96$ では差が大きい．この結果から，(7) に示す正規化が再構成性

© 2026 Information Processing Society of Japan

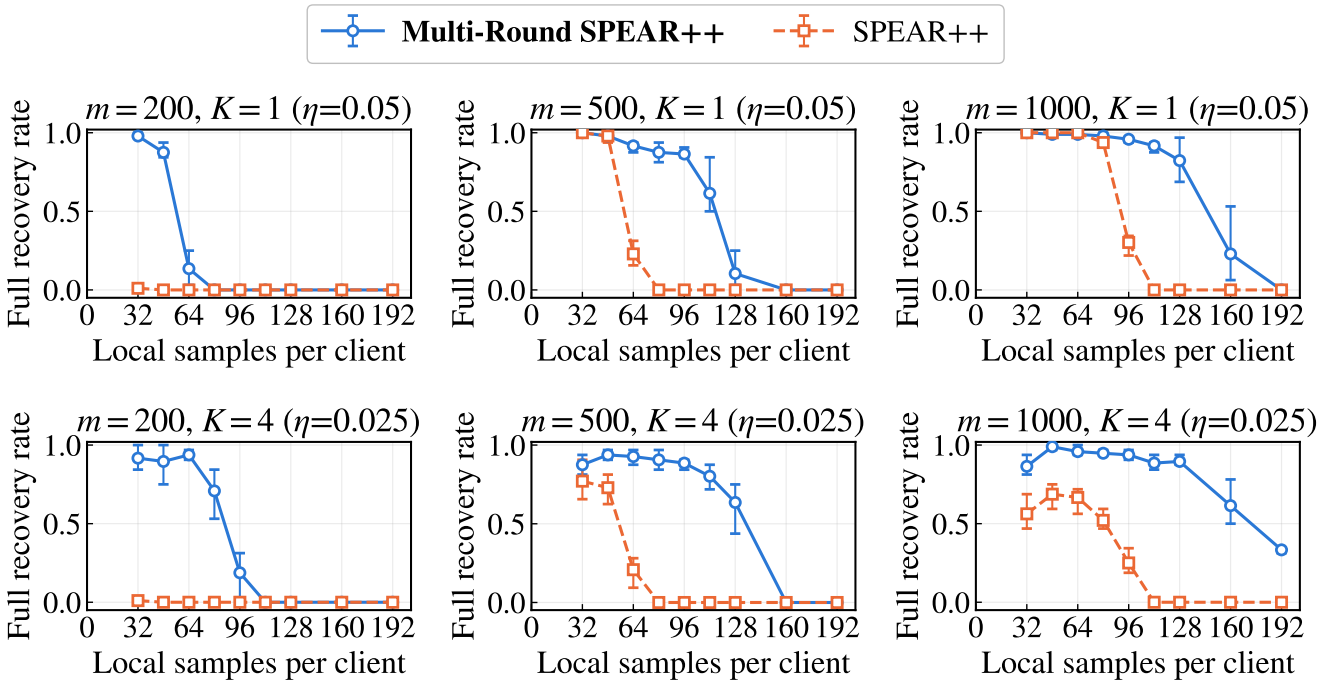


図 1　第一層の出力幅 m ごとの，ローカルデータ数 B に対する完全再構成率 (Full recovery rate)．Multi-Round SPEAR++ は $|\mathcal{T}| = 10$ の通信ラウンドのモデル更新を用いる．

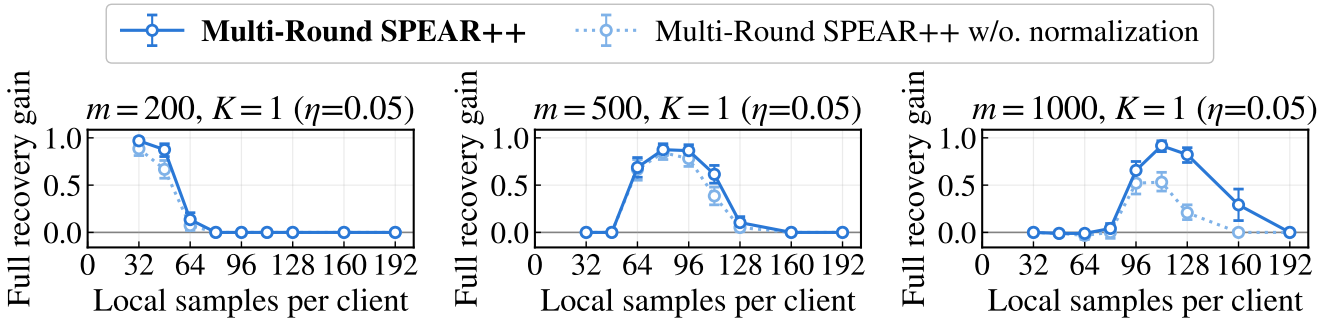


図 2　Multi-Round SPEAR++における通信ラウンドごとの正規化の有無による，単一通信ラウンドの SPEAR++に対する完全再構成率の改善量 (Full recovery gain) の比較．

能の向上に寄与することを確認した．

5.3　複数通信ラウンドが再構成可能性に与える効果の分析

5.2 節で示した Multi-Round SPEAR++の再構成性能の向上を，命題 1 で導出した候補探索問題の狭義局所最小解の必要十分条件に基づいて分析する．さらに，この向上が複数通信ラウンドの連結による行数の増加だけで説明できるかを調べるため，候補探索に用いる行数を揃えた単一通信ラウンドの SPEAR++と比較する．図 3 に，ローカルデータ数 B ごとに，各真の候補 $\boldsymbol{q}_i$ を再構成に成功した場合 (S) と再構成過程で最初に失敗した段階 (F1)–(F4) に分類した割合を示す．各段階への分類は，真の勾配行列 $\boldsymbol{G}$ から各 $\boldsymbol{q}_i$ について，(10) と (13) の成立を評価した上で，実際の候補探索において $\boldsymbol{q}_i$ が発見されたか，および再構成に必要な候補がすべて得られたかに基づいて行う．

$B \geq 96$ では，単一通信ラウンドの SPEAR++において (F1) のランク条件を満たさない候補が支配的となるのに対し，Multi-Round SPEAR++ではすべての真の候補でランク条件が成立する．命題 1 より，この結果は，複数通信ラウンドの連結により追加される行が $\boldsymbol{G}_{A_i}$ のランクを増加させ，単一通信ラウンドで成立しなかったランク条件を満たすことを示す．また，$B = 48$ では，単一通信ラウンドでみられた (F2) の双対マージン条件の不成立が Multi-Round SPEAR++ではみられず，複数通信ラウンドが双対マージン条件の成立も改善し得ることが分かる．

$B \geq 96$ でみられたランク条件の改善と，候補探索に用いる行数の増加との関係を調べるため，第一層の出力幅を $m = 2000$ に拡張し，$m = 200$, $|\mathcal{T}| = 10$ の Multi-Round SPEAR++と行数を揃えた単一通信ラウンドの SPEAR++と比較する．幅を拡張した単一通信ラウンドの SPEAR++

© 2026 Information Processing Society of Japan

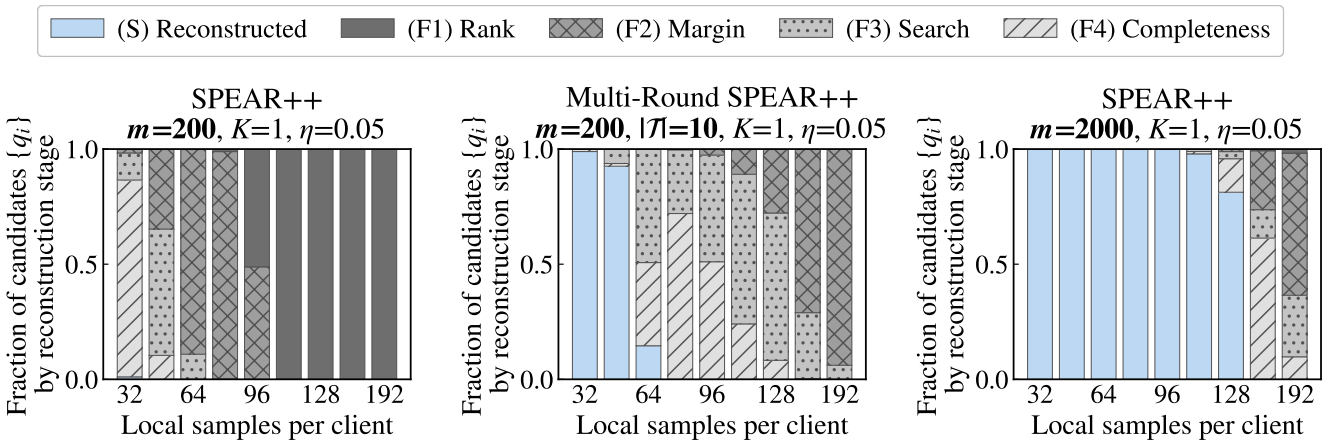


図 3　真の候補ごとの再構成結果の分類．データ数 B ごとに，各真の候補を再構成に成功した場合 (S) と，再構成過程で最初に失敗した段階 (F1)–(F4) に分類した割合を示す．(F1) はランク条件 (10) の不成立，(F2) は双対マージン条件 (13) の不成立，(F3) は両条件を満たすが Riemannian Adam による候補探索で未発見，(F4) は候補自身は発見されたが同一クライアントの他のデータに対応する候補が揃わず完全再構成に至らないことを表す．左は単一通信ラウンドの SPEAR++，中央は $m = 200$, $|\mathcal{T}| = 10$ の Multi-Round SPEAR++，右は候補探索に用いる行数を中央図と揃えるため第一層の出力幅を $m = 2000$ とした単一通信ラウンドの SPEAR++である．

でも $B \geq 96$ では (F1) がみられず，ランク条件については Multi-Round SPEAR++と同様の改善が得られる．一方，$B = 160, 192$ では，同じ行数であっても (F2) の割合に差がみられる．したがって，双対マージン条件については，行数を揃えても Multi-Round SPEAR++と幅を拡張した SPEAR++で異なる性質を示す．

なお，図 3 では (F4) が大きな割合を占める場合があり，多くの真の候補を発見できても，一部のローカルデータに対応する候補が得られず完全再構成に至らないことを示す．

6. おわりに

本論文では，解析的データ再構成攻撃 SPEAR++を複数通信ラウンドへ拡張し，同一クライアントの複数通信ラウンドのモデル更新から入力データを厳密に再構成する Multi-Round SPEAR++を提案した．同一クライアントが各通信ラウンドで共通の入力データ集合を用いる場合に着目し，各重み更新を共通の入力データに対する分解として表し，正規化して行方向に連結することで，複数ラウンドの重み更新を SPEAR++と同じ形の一つの再構成問題として扱えることを示した．また，SPEAR++と Multi-Round SPEAR++に共通する最適化問題を解析し，真の候補が狭義局所最小解となるための必要十分条件として，ランク条件と双対マージン条件を導出した．実験では，Multi-Round SPEAR++が，第一層の出力幅を固定した単一通信ラウンドの SPEAR++よりも大きなローカルデータ数まで高い完全再構成率を示し，特にローカルデータ数 $B = 128$ では約 82% のクライアントで 128 件すべてを再構成した．さらに，第一層の出力幅を拡張して候補探索に用いる行数を揃えた単一通信ラウンドの SPEAR++との比較では，ランク条件は同様に改善する一方，双対マージン条件には差がみられた．これらの結果は，単一通信ラウンドの SPEAR++による評価が，連合学習における再構成リスクを過小評価し得ることを示している．今後の課題として，クライアントのローカルデータが非独立同分布に従う場合の評価，および観測する通信ラウンド数 $|\mathcal{T}|$ と再構成可能なデータ数の関係の理論的解析が挙げられる．

参考文献

[1] McMahan, B. et al.: Communication-efficient learning of deep networks from decentralized data, *in Proc. AISTATS* (2017).
[2] Zhu, L. et al.: Deep leakage from gradients, *in Proc. NeurIPS* (2019).
[3] Dimitrov, D. I. et al.: SPEAR: Exact gradient inversion of batches in federated learning, *in Proc. NeurIPS* (2024).
[4] Bakarsky, A. et al.: SPEAR++: Scaling gradient inversion via sparsely-used dictionary learning, *in Proc. NeurIPS Workshop on Regulatable ML* (2025).
[5] Wainakh, A. et al.: User-level label leakage from gradients in federated learning, *PoPETs* (2022).
[6] Ma, K. et al.: Instance-wise batch label restoration via gradients in federated learning, *in Proc. ICLR* (2023).
[7] Carletti, V. et al.: SoK: Gradient inversion attacks in federated learning, *in Proc. USENIX Security* (2025).
[8] Zhu, J. and Blaschko, M. B.: R-GAP: Recursive gradient attack on privacy, *in Proc. ICLR* (2021).
[9] Krizhevsky, A.: Learning multiple layers of features from tiny images, Technical report, University of Toronto (2009).
[10] He, K. et al.: Delving deep into rectifiers: Surpassing human-level performance on ImageNet classification, *in Proc. ICCV* (2015).
[11] Bécigneul, G. and Ganea, O.-E.: Riemannian adaptive optimization methods, *in Proc. ICLR* (2019).
[12] Gribonval, R. and Schnass, K.: Dictionary identification—sparse matrix-factorization via ℓ_1-minimization, *IEEE Trans. Inf. Theory* (2010).

© 2026 Information Processing Society of Japan

付　　録

A.1　3 節の目的関数の変形の導出

$$\begin{aligned}\min_{\|\boldsymbol{q}\|_2=1}\|\boldsymbol{L}^{(\mathcal{T})}\boldsymbol{q}\|_1 &= \min_{\boldsymbol{h}:\,\|\boldsymbol{R}^{(\mathcal{T})}\boldsymbol{h}\|_2=1}\|\boldsymbol{L}^{(\mathcal{T})}\boldsymbol{R}^{(\mathcal{T})}\boldsymbol{h}\|_1\\ &= \min_{\boldsymbol{h}:\,\|\Delta\boldsymbol{W}^{(\mathcal{T})}\boldsymbol{h}\|_2=1}\|\Delta\boldsymbol{W}^{(\mathcal{T})}\boldsymbol{h}\|_1\\ &= \min_{\boldsymbol{h}:\,\Delta\boldsymbol{W}^{(\mathcal{T})}\boldsymbol{h}\neq\boldsymbol{0}}\frac{\|\Delta\boldsymbol{W}^{(\mathcal{T})}\boldsymbol{h}\|_1}{\|\Delta\boldsymbol{W}^{(\mathcal{T})}\boldsymbol{h}\|_2}.\end{aligned}$$

一つ目の等式は, $\boldsymbol{R}^{(\mathcal{T})}\in\mathbb{R}^{B\times n}$ が行フルランクであり, 写像 $\boldsymbol{h}\mapsto\boldsymbol{R}^{(\mathcal{T})}\boldsymbol{h}$ が $\mathbb{R}^B$ 上への全射であることから従う．二つ目の等式は，$\Delta\boldsymbol{W}^{(\mathcal{T})}=\boldsymbol{L}^{(\mathcal{T})}\boldsymbol{R}^{(\mathcal{T})}$ であり，$\boldsymbol{L}^{(\mathcal{T})}\in\mathbb{R}^{|\mathcal{T}|m\times B}$ の列が正規直交するため，$\|\boldsymbol{R}^{(\mathcal{T})}\boldsymbol{h}\|_2=\|\Delta\boldsymbol{W}^{(\mathcal{T})}\boldsymbol{h}\|_2$ が成り立つことから従う．三つ目の等式は，任意の非零ベクトルをその ℓ_2 ノルムで割ることで単位ノルムに規格化できることと，$\Delta\boldsymbol{W}^{(\mathcal{T})}\boldsymbol{h}$ が $\boldsymbol{h}$ に対して線形であることから従う．

A.2　命題 1 の証明

A.2.1　数学的道具

本節では，証明で用いる定義と補題を導入する．

定義 1 (狭義局所最小解)**.** $f:\mathbb{R}^d\to\mathbb{R}$，実行可能集合を $\Omega\subseteq\mathbb{R}^d$ とする．点 $\boldsymbol{q}\in\Omega$ が Ω 上の f の狭義局所最小解であるとは，ある $\epsilon>0$ が存在して，ϵ 近傍 $B_\epsilon(\boldsymbol{q})=\{\boldsymbol{q}':\|\boldsymbol{q}'-\boldsymbol{q}\|_2<\epsilon\}$ 内の $\boldsymbol{q}$ と異なる任意の $\boldsymbol{q}'\in\Omega$ で $f(\boldsymbol{q})<f(\boldsymbol{q}')$ が成り立つことをいう．

定義 2 (劣勾配)**.** 凸関数 $f:\mathbb{R}^d\to\mathbb{R}$ の点 $\boldsymbol{x}$ における劣勾配とは，任意の $\boldsymbol{y}\in\mathbb{R}^d$ に対し $f(\boldsymbol{y})\geq f(\boldsymbol{x})+\langle\boldsymbol{g},\boldsymbol{y}-\boldsymbol{x}\rangle$ を満たす $\boldsymbol{g}\in\mathbb{R}^d$ をいう．とくに $\|\cdot\|_1$ の劣勾配は，$\boldsymbol{x}$ の全成分がゼロでなければ $\mathrm{sign}(\boldsymbol{x})$ ただ一つに定まる．

補題 1 (Hölder の不等式)**.** 任意のベクトル $\boldsymbol{x},\boldsymbol{y}\in\mathbb{R}^d$ について，下記が成り立つ．

$$|\langle\boldsymbol{x},\boldsymbol{y}\rangle|\leq\|\boldsymbol{x}\|_\infty\|\boldsymbol{y}\|_1.$$

補題 2 (ℓ_∞–ℓ_1 双対性 [12])**.** 行列 $\boldsymbol{H}$ とベクトル $\boldsymbol{c}\in\mathrm{range}(\boldsymbol{H}^\top)$ について，$\boldsymbol{H}^\top\boldsymbol{u}=\boldsymbol{c}$ かつ $\|\boldsymbol{u}\|_\infty<1$ を満たす $\boldsymbol{u}$ が存在することは，$\boldsymbol{H}\boldsymbol{w}\neq\boldsymbol{0}$ を満たす任意の $\boldsymbol{w}$ で $|\langle\boldsymbol{c},\boldsymbol{w}\rangle|<\|\boldsymbol{H}\boldsymbol{w}\|_1$ が成り立つことと同値である．

以下，これらを用いて命題 1 を示す．

十分性.

(10)–(12) を満たす $\boldsymbol{u},\lambda$ が存在すれば $\boldsymbol{q}$ が狭義局所最小解であることを示す．$\boldsymbol{q}$ 近傍の球面点 $\boldsymbol{q}'\in B_\epsilon(\boldsymbol{q})\cap\mathbb{S}^{B-1}$ を接空間へ直交分解する：$\boldsymbol{q}'=\alpha\boldsymbol{q}+\boldsymbol{v}$，ただし $\alpha=\boldsymbol{q}'^\top\boldsymbol{q}$，$\boldsymbol{v}=(\boldsymbol{I}-\boldsymbol{q}\boldsymbol{q}^\top)\boldsymbol{q}'\perp\boldsymbol{q}$．$\|\boldsymbol{q}'\|_2=1$ より $\alpha^2+\|\boldsymbol{v}\|_2^2=1$ であり，$\boldsymbol{q}'$ が $\boldsymbol{q}$ に十分近ければ $\alpha=\sqrt{1-\|\boldsymbol{v}\|_2^2}>0$ で，かつ $\boldsymbol{q}'\neq\boldsymbol{q}$ と $\boldsymbol{v}\neq\boldsymbol{0}$ は同値である．$\boldsymbol{L}_A\boldsymbol{q}=\boldsymbol{0}$ より $(\boldsymbol{L}\boldsymbol{q}')_A=\boldsymbol{L}_A\boldsymbol{v}$ だから，支持ごとに分けて

$$\|\boldsymbol{L}\boldsymbol{q}'\|_1=\big\|\alpha\boldsymbol{L}_{A^c}\boldsymbol{q}+\boldsymbol{L}_{A^c}\boldsymbol{v}\big\|_1+\|\boldsymbol{L}_A\boldsymbol{v}\|_1.$$

$\boldsymbol{L}_{A^c}\boldsymbol{q}$ は全成分がゼロでないゆえ，$\mathrm{sign}(\boldsymbol{L}_{A^c}\boldsymbol{q})$ は定義 2 より $\|\cdot\|_1$ の $\boldsymbol{L}_{A^c}\boldsymbol{q}$ における劣勾配である．劣勾配不等式と $\langle\mathrm{sign}(\boldsymbol{L}_{A^c}\boldsymbol{q}),\boldsymbol{L}_{A^c}\boldsymbol{q}\rangle=\|\boldsymbol{L}_{A^c}\boldsymbol{q}\|_1$ より

$$\big\|\alpha\boldsymbol{L}_{A^c}\boldsymbol{q}+\boldsymbol{L}_{A^c}\boldsymbol{v}\big\|_1\geq\alpha\|\boldsymbol{L}_{A^c}\boldsymbol{q}\|_1+\mathrm{sign}(\boldsymbol{L}_{A^c}\boldsymbol{q})^\top\boldsymbol{L}_{A^c}\boldsymbol{v}.$$

(11) に $\boldsymbol{v}$ を掛け，$\boldsymbol{q}^\top\boldsymbol{v}=0$ を用いると $\mathrm{sign}(\boldsymbol{L}_{A^c}\boldsymbol{q})^\top\boldsymbol{L}_{A^c}\boldsymbol{v}=-\boldsymbol{u}^\top\boldsymbol{L}_A\boldsymbol{v}$ であり，Hölder の不等式より $-\boldsymbol{u}^\top\boldsymbol{L}_A\boldsymbol{v}\geq-\|\boldsymbol{u}\|_\infty\|\boldsymbol{L}_A\boldsymbol{v}\|_1$．$\|\boldsymbol{L}\boldsymbol{q}\|_1=\|\boldsymbol{L}_{A^c}\boldsymbol{q}\|_1$ に注意して合わせると

$$\|\boldsymbol{L}\boldsymbol{q}'\|_1-\|\boldsymbol{L}\boldsymbol{q}\|_1\geq(\alpha-1)\|\boldsymbol{L}\boldsymbol{q}\|_1+(1-\|\boldsymbol{u}\|_\infty)\|\boldsymbol{L}_A\boldsymbol{v}\|_1. \tag{A.1}$$

(10) すなわち $\mathrm{rank}(\boldsymbol{L}_A)=B-1$ より，$\boldsymbol{L}_A\boldsymbol{q}=\boldsymbol{0}$ と合わせて $\ker(\boldsymbol{L}_A)=\mathrm{span}(\boldsymbol{q})$ である．よって $\boldsymbol{q}$ に直交する非零ベクトルは $\boldsymbol{L}_A$ の核に属さず，コンパクト集合 $\{\boldsymbol{v}':\boldsymbol{q}^\top\boldsymbol{v}'=0,\ \|\boldsymbol{v}'\|_2=1\}$ 上で $\boldsymbol{v}'\mapsto\|\boldsymbol{L}_A\boldsymbol{v}'\|_1$ は零点をもたないので，最小値 $\sigma:=\min_{\boldsymbol{v}'\perp\boldsymbol{q},\|\boldsymbol{v}'\|_2=1}\|\boldsymbol{L}_A\boldsymbol{v}'\|_1>0$ が存在し $\|\boldsymbol{L}_A\boldsymbol{v}\|_1\geq\sigma\|\boldsymbol{v}\|_2$．また $\alpha-1\geq-\|\boldsymbol{v}\|_2^2$ ゆえ $(\alpha-1)\|\boldsymbol{L}\boldsymbol{q}\|_1\geq-\|\boldsymbol{v}\|_2^2\|\boldsymbol{L}\boldsymbol{q}\|_1$．これらを (A.1) に代入して

$$\|\boldsymbol{L}\boldsymbol{q}'\|_1-\|\boldsymbol{L}\boldsymbol{q}\|_1\geq\|\boldsymbol{v}\|_2\big[(1-\|\boldsymbol{u}\|_\infty)\sigma-\|\boldsymbol{L}\boldsymbol{q}\|_1\|\boldsymbol{v}\|_2\big].$$

(12) より $(1-\|\boldsymbol{u}\|_\infty)\sigma>0$ なので，$\epsilon:=\min\{1,(1-\|\boldsymbol{u}\|_\infty)\sigma/(2\|\boldsymbol{L}\boldsymbol{q}\|_1)\}$ と選べば，$0<\|\boldsymbol{q}'-\boldsymbol{q}\|_2<\epsilon$ なる任意の $\boldsymbol{q}'$ で右辺は正となり，$\|\boldsymbol{L}\boldsymbol{q}'\|_1>\|\boldsymbol{L}\boldsymbol{q}\|_1$．よって $\boldsymbol{q}$ は $\Psi_{\boldsymbol{L}}$ の狭義局所最小解である．

必要性.

$\boldsymbol{q}$ が狭義局所最小解ならば，(10)–(12) を満たす $\boldsymbol{u},\lambda$ が存在することを示す．まず狭義局所最小性から (10) を示し，次にそこで得られる不等式と補題 2 を用いて $\boldsymbol{u},\lambda$ を構成する．$\boldsymbol{r}:=\boldsymbol{L}_{A^c}^\top\mathrm{sign}(\boldsymbol{L}_{A^c}\boldsymbol{q})$，$\boldsymbol{\Pi}:=\boldsymbol{I}-\boldsymbol{q}\boldsymbol{q}^\top$ とおく．

$\boldsymbol{q}$ の狭義局所最小性より，ある $\epsilon>0$ が存在して，$B_\epsilon(\boldsymbol{q})\cap\mathbb{S}^{B-1}$ 内の $\boldsymbol{q}$ と異なる任意の点で目的関数は $\boldsymbol{q}$ より大きい．任意の単位ベクトル $\boldsymbol{v}\perp\boldsymbol{q}$ を固定し，$\boldsymbol{q}(\xi):=\cos\xi\,\boldsymbol{q}+\sin\xi\,\boldsymbol{v}$ とおく．$\boldsymbol{q}(\xi)\to\boldsymbol{q}(\xi\to0^+)$ であり，かつ $\boldsymbol{L}_{A^c}\boldsymbol{q}$ の全ての成分が非ゼロであるため ξ を十分小さくとれば下記が同時に成り立つ．

$$\boldsymbol{q}(\xi)\in B_\epsilon(\boldsymbol{q})\cap\mathbb{S}^{B-1},\qquad\mathrm{sign}(\boldsymbol{L}_{A^c}\boldsymbol{q}(\xi))=\mathrm{sign}(\boldsymbol{L}_{A^c}\boldsymbol{q}).$$

以下，このように選んだ ξ を固定する．

© 2026 Information Processing Society of Japan

$$
\begin{aligned}
&\|\boldsymbol{L}\boldsymbol{q}(\xi)\|_1 - \|\boldsymbol{L}\boldsymbol{q}\|_1 \\
&= \|\boldsymbol{L}_A\boldsymbol{q}(\xi)\|_1 + \|\boldsymbol{L}_{A^c}\boldsymbol{q}(\xi)\|_1 - \|\boldsymbol{L}\boldsymbol{q}\|_1 \\
&= \sin\xi\,\|\boldsymbol{L}_A\boldsymbol{v}\|_1 + \langle \operatorname{sign}(\boldsymbol{L}_{A^c}\boldsymbol{q}), \boldsymbol{L}_{A^c}\boldsymbol{q}(\xi)\rangle - \|\boldsymbol{L}\boldsymbol{q}\|_1 \\
&= \sin\xi\,\|\boldsymbol{L}_A\boldsymbol{v}\|_1 + \cos\xi\,\langle \operatorname{sign}(\boldsymbol{L}_{A^c}\boldsymbol{q}), \boldsymbol{L}_{A^c}\boldsymbol{q}\rangle \\
&\qquad + \sin\xi\,\langle \operatorname{sign}(\boldsymbol{L}_{A^c}\boldsymbol{q}), \boldsymbol{L}_{A^c}\boldsymbol{v}\rangle - \|\boldsymbol{L}\boldsymbol{q}\|_1 \\
&= (\cos\xi - 1)\|\boldsymbol{L}\boldsymbol{q}\|_1 + \sin\xi\,[\langle \boldsymbol{r}, \boldsymbol{v}\rangle + \|\boldsymbol{L}_A\boldsymbol{v}\|_1] \\
&= (\cos\xi - 1)\|\boldsymbol{L}\boldsymbol{q}\|_1 + \sin\xi\,[\langle \boldsymbol{\Pi}\boldsymbol{r}, \boldsymbol{v}\rangle + \|\boldsymbol{L}_A\boldsymbol{v}\|_1]\,.
\end{aligned}
$$

一つ目の等式は，ℓ_1 ノルムを添字集合 A, A^c へ分けたことによる．二つ目は，$\boldsymbol{L}_A\boldsymbol{q} = \boldsymbol{0}$ より A 上で $\boldsymbol{L}_A\boldsymbol{q}(\xi) = \sin\xi\,\boldsymbol{L}_A\boldsymbol{v}$ となること，および ξ を上のように選ぶと A^c 上で符号が一定なため $\|\boldsymbol{L}_{A^c}\boldsymbol{q}(\xi)\|_1 = \langle \operatorname{sign}(\boldsymbol{L}_{A^c}\boldsymbol{q}), \boldsymbol{L}_{A^c}\boldsymbol{q}(\xi)\rangle$ となることによる．三つ目は，$\boldsymbol{q}(\xi) = \cos\xi\,\boldsymbol{q} + \sin\xi\,\boldsymbol{v}$ を内積に代入して展開したものである．四つ目は，$\langle \operatorname{sign}(\boldsymbol{L}_{A^c}\boldsymbol{q}), \boldsymbol{L}_{A^c}\boldsymbol{q}\rangle = \|\boldsymbol{L}\boldsymbol{q}\|_1$ および $\boldsymbol{r} = \boldsymbol{L}_{A^c}^\top \operatorname{sign}(\boldsymbol{L}_{A^c}\boldsymbol{q})$ の定義による．五つ目は，$\boldsymbol{v} \perp \boldsymbol{q}$ より $\boldsymbol{\Pi}\boldsymbol{v} = \boldsymbol{v}$ かつ $\boldsymbol{\Pi}$ が対称なため $\langle \boldsymbol{r}, \boldsymbol{v}\rangle = \langle \boldsymbol{\Pi}\boldsymbol{r}, \boldsymbol{v}\rangle$ となることによる．$\boldsymbol{q}$ の狭義局所最小性から左辺は正であるから下記を得る．

$$
(\cos\xi - 1)\|\boldsymbol{L}\boldsymbol{q}\|_1 + \sin\xi\,[\langle \boldsymbol{\Pi}\boldsymbol{r}, \boldsymbol{v}\rangle + \|\boldsymbol{L}_A\boldsymbol{v}\|_1] > 0.
$$

これを整理すると下記を得る．

$$
\langle \boldsymbol{\Pi}\boldsymbol{r}, \boldsymbol{v}\rangle + \|\boldsymbol{L}_A\boldsymbol{v}\|_1 > \frac{1 - \cos\xi}{\sin\xi}\|\boldsymbol{L}\boldsymbol{q}\|_1 \geq 0.
$$

二つ目の不等号は，$1 - \cos\xi \geq 0$，$\sin\xi > 0$，および $\|\boldsymbol{L}\boldsymbol{q}\|_1 \geq 0$ から従う．

$\boldsymbol{v}$ は任意の単位ベクトルであったため，同じ不等式は $-\boldsymbol{v}$ についても成り立ち，下記を得る．

$$
-\langle \boldsymbol{\Pi}\boldsymbol{r}, \boldsymbol{v}\rangle + \|\boldsymbol{L}_A\boldsymbol{v}\|_1 > 0
$$

この二つの不等式を合わせると任意の単位ベクトル $\boldsymbol{v} \perp \boldsymbol{q}$ について下記を得る．

$$
|\langle \boldsymbol{\Pi}\boldsymbol{r}, \boldsymbol{v}\rangle| < \|\boldsymbol{L}_A\boldsymbol{v}\|_1 \tag{A.2}
$$

まず，(A.2) から (10) を示す．非零な $\boldsymbol{z} \in \ker(\boldsymbol{L}_A) \cap \boldsymbol{q}^\perp$ が存在すると仮定し，$\boldsymbol{v} := \boldsymbol{z}/\|\boldsymbol{z}\|_2$ とおく．このとき $\boldsymbol{v}$ は $\boldsymbol{v} \perp \boldsymbol{q}$ かつ $\boldsymbol{L}_A\boldsymbol{v} = \boldsymbol{0}$ を満たす単位ベクトルであり，(A.2) の右辺 $\|\boldsymbol{L}_A\boldsymbol{v}\|_1$ が 0 となる．左辺は非負なので，これは矛盾である．したがって下記を得る．

$$
\ker(\boldsymbol{L}_A) \cap \boldsymbol{q}^\perp = \{\boldsymbol{0}\}
$$

$\boldsymbol{q} \in \ker(\boldsymbol{L}_A)$ と合わせると $\ker(\boldsymbol{L}_A) = \operatorname{span}(\boldsymbol{q})$，すなわち $\operatorname{rank}(\boldsymbol{L}_A) = B - 1$ を得る．これは (10) である．

次に，(A.2) と補題 2 から $\boldsymbol{u}$ を構成する．$\boldsymbol{L}_A\boldsymbol{w} \neq \boldsymbol{0}$ を満たす任意の $\boldsymbol{w}$ をとり，$\boldsymbol{z} := \boldsymbol{\Pi}\boldsymbol{w}$ とおく．$\boldsymbol{L}_A\boldsymbol{q} = \boldsymbol{0}$ より下記が成り立つ．

$$
\boldsymbol{L}_A\boldsymbol{z} = \boldsymbol{L}_A\boldsymbol{w} \neq \boldsymbol{0}
$$

とくに $\boldsymbol{z} \neq \boldsymbol{0}$ である．また $\boldsymbol{z} = \boldsymbol{\Pi}\boldsymbol{w} \perp \boldsymbol{q}$ であるから，$\boldsymbol{v} := \boldsymbol{z}/\|\boldsymbol{z}\|_2$ は $\boldsymbol{v} \perp \boldsymbol{q}$ を満たす単位ベクトルである．$\boldsymbol{z} = \|\boldsymbol{z}\|_2\,\boldsymbol{v}$ なので，(A.2) を $\boldsymbol{v}$ に適用して両辺に $\|\boldsymbol{z}\|_2$ を掛けると下記を得る．

$$
|\langle \boldsymbol{\Pi}\boldsymbol{r}, \boldsymbol{z}\rangle| < \|\boldsymbol{L}_A\boldsymbol{z}\|_1
$$

$\boldsymbol{\Pi}\boldsymbol{r} \perp \boldsymbol{q}$ と $\boldsymbol{z} = \boldsymbol{\Pi}\boldsymbol{w}$ より $\langle \boldsymbol{\Pi}\boldsymbol{r}, \boldsymbol{z}\rangle = \langle \boldsymbol{\Pi}\boldsymbol{r}, \boldsymbol{w}\rangle$ であり，$\boldsymbol{L}_A\boldsymbol{z} = \boldsymbol{L}_A\boldsymbol{w}$ であるから，下記が成り立つ．

$$
|\langle -\boldsymbol{\Pi}\boldsymbol{r}, \boldsymbol{w}\rangle| < \|\boldsymbol{L}_A\boldsymbol{w}\|_1
$$

これは $\boldsymbol{L}_A\boldsymbol{w} \neq \boldsymbol{0}$ を満たす任意の $\boldsymbol{w}$ で成り立つので，補題 2 を $\boldsymbol{H} = \boldsymbol{L}_A$，$\boldsymbol{c} = -\boldsymbol{\Pi}\boldsymbol{r}$ として適用でき，下記を満たす $\boldsymbol{u}$ が存在する．

$$
\boldsymbol{L}_A^\top\boldsymbol{u} = -\boldsymbol{\Pi}\boldsymbol{r}, \qquad \|\boldsymbol{u}\|_\infty < 1
$$

後者は (12) である．

最後に，λ を構成する．$\boldsymbol{r}$ の定義より下記が成り立つ．

$$
\boldsymbol{q}^\top\boldsymbol{r} = \operatorname{sign}(\boldsymbol{L}_{A^c}\boldsymbol{q})^\top\boldsymbol{L}_{A^c}\boldsymbol{q} = \|\boldsymbol{L}\boldsymbol{q}\|_1
$$

したがって $\boldsymbol{\Pi} = \boldsymbol{I} - \boldsymbol{q}\boldsymbol{q}^\top$ より下記を得る．

$$
-\boldsymbol{\Pi}\boldsymbol{r} = -\boldsymbol{r} + \|\boldsymbol{L}\boldsymbol{q}\|_1\boldsymbol{q}
$$

$\lambda := -\|\boldsymbol{L}\boldsymbol{q}\|_1$ とおき，これと $\boldsymbol{L}_A^\top\boldsymbol{u} = -\boldsymbol{\Pi}\boldsymbol{r}$ を用いると下記が成り立つ．

$$
\boldsymbol{r} + \boldsymbol{L}_A^\top\boldsymbol{u} + \lambda\boldsymbol{q} = \boldsymbol{0}
$$

$\boldsymbol{r} = \boldsymbol{L}_{A^c}^\top \operatorname{sign}(\boldsymbol{L}_{A^c}\boldsymbol{q})$ より，これは (11) にほかならない．以上より，(10)–(12) が成り立つ．

A.3 実装詳細

アルゴリズム 1 の GreedyFilter は，SPEAR++ [4] と同じ貪欲な候補選択であり，アルゴリズム 2 に示す．線形独立な B 本の候補から出発し，マスク整合度 $\text{Score}_{\mathcal{T}}$ が改善する限り，選択中の候補を未選択の候補と 1 本ずつ入れ替える．手続き自体は SPEAR++と共通であり，Multi-Round 固有なのは，マスク整合を各通信ラウンドの行ブロック $\mathcal{I}_t$ と観測モデル $\boldsymbol{W}^{(t)}, \boldsymbol{b}^{(t)}$ について判定して平均する点である．

$\text{Score}_{\mathcal{T}}$ は，各通信ラウンド t の行ブロック $\mathcal{I}_t$ について，前活性化 $\boldsymbol{W}^{(t)}\hat{\boldsymbol{x}}_j + \boldsymbol{b}^{(t)}$ の符号が定める ReLU マスクと候補列 $(\widetilde{\boldsymbol{L}}^{(\mathcal{T})}\hat{\boldsymbol{Q}})_{\mathcal{I}_t}$ のゼロ・非ゼロのパターンとが一致する成分の割合を測る．すなわち，前活性化が正かつ対応する成分が非ゼロ，または前活性化が非正かつ対応する成分がゼロとなる成分の個数を，全成分数で正規化する [3]．この判定をすべての通信ラウンドで課すため，連結全体では整合して見えても，ある通信ラウンドの ReLU マスクと矛盾する候補は整合度が下がり，選ばれにくくなる．

© 2026 Information Processing Society of Japan

Algorithm 2 候補選択

procedure GreedyFilter($\mathcal{C}, \mathrm{Score}_{\mathcal{T}}$)
  $\mathcal{S} \leftarrow \mathcal{C}$ の線形独立な B 列
  while $\mathrm{Score}_{\mathcal{T}}$ を改善する入替が存在する **do**
    $(o, i) \leftarrow \arg\max_{o \in \mathcal{S},\, i \in \mathcal{C} \setminus \mathcal{S}} \mathrm{Score}_{\mathcal{T}}\big([(\mathcal{S} \setminus \{o\}) \cup \{i\}]\big)$
    $\mathcal{S} \leftarrow (\mathcal{S} \setminus \{o\}) \cup \{i\}$
  end while
  $\hat{\boldsymbol{Q}}_{\mathrm{d}} \leftarrow [\mathcal{S}]$
  $\boldsymbol{s} \leftarrow (\widetilde{\boldsymbol{L}}^{(\mathcal{T})} \hat{\boldsymbol{Q}}_{\mathrm{d}})^{\dagger} \widetilde{\Delta \boldsymbol{b}}^{(\mathcal{T})}$ ▷ スケールと符号を求める
  return $\hat{\boldsymbol{Q}}_{\mathrm{d}} \,\mathrm{diag}(\boldsymbol{s})$
end procedure

procedure $\mathrm{Score}_{\mathcal{T}}(\hat{\boldsymbol{Q}}_{\mathrm{d}})$
  $\boldsymbol{s} \leftarrow (\widetilde{\boldsymbol{L}}^{(\mathcal{T})} \hat{\boldsymbol{Q}}_{\mathrm{d}})^{\dagger} \widetilde{\Delta \boldsymbol{b}}^{(\mathcal{T})}$, $\hat{\boldsymbol{Q}} \leftarrow \hat{\boldsymbol{Q}}_{\mathrm{d}} \,\mathrm{diag}(\boldsymbol{s})$, $\hat{\boldsymbol{X}}^{\top} \leftarrow \hat{\boldsymbol{Q}}^{-1} \widetilde{\boldsymbol{R}}^{(\mathcal{T})}$
  $\kappa \leftarrow 0$
  for $t \in \mathcal{T},\ j = 1, \ldots, B$ **do**
    $\hat{\boldsymbol{z}} \leftarrow \boldsymbol{W}^{(t)} \hat{\boldsymbol{x}}_j + \boldsymbol{b}^{(t)}$
    $\tilde{\boldsymbol{g}} \leftarrow [(\widetilde{\boldsymbol{L}}^{(\mathcal{T})} \hat{\boldsymbol{Q}})_{\mathcal{I}_t}]_{:,j}$ ▷ 候補列 (再構成した勾配)
    $\kappa^{-} \leftarrow \big|\{r \in [m] : \hat{\boldsymbol{z}}_r \le 0 \ \wedge\ \tilde{\boldsymbol{g}}_r = 0\}\big|$ ▷ 非活性かつゼロ
    $\kappa^{+} \leftarrow \big|\{r \in [m] : \hat{\boldsymbol{z}}_r > 0 \ \wedge\ \tilde{\boldsymbol{g}}_r \neq 0\}\big|$ ▷ 活性かつ非ゼロ
    $\kappa \leftarrow \kappa + (\kappa^{-} + \kappa^{+})/(|\mathcal{T}| m B)$ ▷ 整合する成分の割合
  end for
  return κ
end procedure

© 2026 Information Processing Society of Japan