差分プライバシー連合学習における分散主成分分析の適用と評価

ユン ミヌ[1,a)]　千田 浩司[2,b)]　面 和成[1,c)]

概要：学習結果のみを共有する連合学習に，ノイズの付加で個々のデータの影響を秘匿する差分プライバシーを適用することで，情報漏洩に対する理論的保証が得られる．しかし，保護を強めるほどノイズが増大して精度が低下し，通信と計算の負荷も大きく，いずれもパラメータ数に応じて増大する．この課題に対し，学習中の勾配を低次元空間へ射影する手法や，各クライアントの統計量から主成分を求める分散主成分分析が提案されている．前者は公開データを必要とし，医療分野など同種のデータが公開されない領域では用いることができない．後者は基底の算出で完結し，それを用いた学習は評価されていない．提案手法では，各クライアントが送信した統計量から中央サーバが主成分分析を行い，基底を配布する．各クライアントはこの基底で入力の次元を削減して差分プライバシーを適用した連合学習を行う．これによりパラメータ数が削減され，学習時のノイズ，通信量，計算量が減少する．保護の強度と削減次元を網羅的に変化させて評価した結果，保護の強度ごとに最適な削減次元が存在し，その次元において精度と処理コストがともに改善することを確認した．

Application and Evaluation of Distributed Principal Component Analysis in Differentially Private Federated Learning

Minwoo Youn[1,a)]　Koji Chida[2,b)]　Kazumasa Omote[1,c)]

Abstract: Applying differential privacy to federated learning degrades accuracy, and the noise, communication, and computation all grow with the number of model parameters. Existing gradient-projection methods require public data, which is unavailable in medical and other sensitive domains. Distributed principal component analysis needs no public data but stops at computing the basis, and the training that uses it has not been evaluated. In the proposed method, the server computes a principal component basis from the statistics each organization sends and distributes it. Each organization then reduces its input dimensionality before differentially private federated learning, cutting the parameter count and hence all three costs. We evaluate accuracy and processing cost while varying the privacy budget and the reduced dimensionality.

1. はじめに

医療機関や金融機関のように規制の下で機微なデータを扱うクライアントは，保有するデータを外部へ持ち出すことができない．一方で，単一のクライアントが保有するデータだけでは学習に十分な量を確保できず，クライアントをまたいだ共同学習の需要が生じる．連合学習（Federated Learning，FL）は，データを各クライアントに置いたままモデルの更新のみを共有することでこの需要に応える手法であり，中央サーバは各クライアントから受け取った更新を平均してモデルを更新する [1]．

しかし，共有されるのが更新だけであっても，勾配やモデルの更新から元のデータが復元されうることが知られている [2]．更新の共有それ自体が漏洩の経路となるため，更新に対して理論的な保証を伴う保護を与える必要があ

[1] 筑波大学
University of Tsukuba
[2] 群馬大学
Gunma University
[a)] s2320558@u.tsukuba.ac.jp
[b)] chida@gunma-u.ac.jp
[c)] omote@risk.tsukuba.ac.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

る．差分プライバシー（Differential Privacy，DP）は，出力の分布に対する制約として保護の強度を定量的に与える手法であり [3]，学習の各ステップで勾配にノイズを加える DP-SGD（Differentially Private Stochastic Gradient Descent）によって深層学習に適用できる [4]．

保護の単位には，参加するクライアントそのものを隠すクライアント単位と，各クライアントが保有する個々のレコードを隠すレコード単位の 2 つの取り方がある．少数のクライアントが継続して参加し，どのクライアントが参加しているかを秘匿しない本研究の設定では，保護の単位はレコード単位となる．

対象とする設定は，データの分布にも制約を課す．各クライアントはそれぞれの専門に応じたデータを蓄積するため，各クライアントのデータは特定のラベルに集中し，その構成はクライアント間で大きく異なる．さらに，共同学習の需要が生じるのは，希少疾患の症例や特定の類型の不正取引のように，1 クライアントあたりのデータが少ない場面である．すなわち，レコード単位の保護，偏った分布，1 クライアントあたりの小規模なデータという 3 つの条件は，個別に選択した設定ではなく，対象とする状況に必然的に伴うものである．

本論文では，この条件の下で，入力の次元を削減してから DP-SGD を行う二段階の手法を提案し，保護の強度と削減次元を網羅的に変化させて評価する．あわせて，前処理で送信する統計量にも DP を適用した場合の精度と処理コストを測定する．評価を通じて，次元削減が精度を改善する条件と改善しない条件を明らかにし，その境界が保護の強度と 1 クライアントあたりのデータ件数の関係として共通の式で整理できることを示す．

2. 課題

DP-SGD では，勾配のノルムを閾値でクリッピングした後，分散が閾値とノイズ倍率の積で定まる Gaussian ノイズを加える [4]．加えるノイズの総量はモデルのパラメータ数に比例して増大する．また，1 クライアントあたりのデータ件数が少ない設定では，学習の更新に対するノイズの影響が相対的に大きくなり，精度が低下しやすい [5]．すなわち，共同学習の需要が生じる条件と，保護による精度低下が大きくなる条件は一致する．

連合学習ではラウンド毎にモデルと同じ次元のベクトルを送受信するため，通信量はパラメータ数と学習ラウンド数の積に比例する [1]．またレコード単位の保護では勾配をレコードごとに保持してクリッピングするため，まとめて計算する場合に比べて計算量が増える．精度の低下，通信量，計算量の 3 つはいずれもパラメータ数とともに増大し，レコード単位の保護と小規模なデータという 2 つの条件が重なるとき同時に悪化する．

パラメータ数を削減すれば，加えるノイズの総量，通信量，計算量はいずれも減少する．一方で，入力の次元を削減すると，学習に使える情報も失われる．失われる情報がノイズの低減に見合うかは自明でなく，保護の強度と 1 クライアントあたりのデータ件数に依存して変わりうる．これを明らかにすることが本論文の課題である．

表 1 関連研究との比較
Table 1 Comparison with prior work.

	公開データ	連合	入力空間	学習評価
Yu ら [6]	要	×	×	○
Zhou ら [7]	要	×	×	○
Liang ら [8]	不要	○	○	×
Grammenos ら [9]	不要	○	○	×
Tramèr ら [10]	要	×	○	○
提案手法	不要	○	○	○

3. 関連研究

パラメータ数を削減する手法は，削減を行う空間によって 2 つに分かれる．

第一は，学習中の勾配を低次元空間へ射影する系統である．Yu ら [6] の GEP は，公開データから求めた基底に勾配を射影し，低次元の係数にノイズを加える．Zhou ら [7] の勾配の部分空間を同定する手法も同様に勾配の空間で射影を行う．これらは勾配の情報を保ったままノイズの次元を下げられる一方で，射影の基底を求めるために学習対象と同種の公開データを必要とする．医療分野のように同種のデータが公開されない領域では利用できない．

第二は，各クライアントが計算した統計量を中央サーバで集約して共通の主成分を求める分散主成分分析の系統である．Liang ら [8] は，後段のタスクの前処理として用いることを想定し，各クライアントの統計量を 1 度だけ集約して基底を得る手続きを与えた．Grammenos ら [9] は，多数の参加者を想定した逐次的な集約と DP の適用を扱っている．これらは公開データを必要としないが，評価は基底の推定精度で完結しており，得られた基底の上で DP を適用した学習を行った場合に精度と処理コストがどう変化するかは示されていない．

低次元の表現が DP 学習において有利になること自体は，中央集権の設定で報告されている．Tramèr ら [10] は，中程度の保護強度において低次元の特徴量による学習が深層モデルを上回ることを示した．ただし彼らの手法は基底を公開データから得ており，連合学習の設定も扱っていない．

各手法の位置づけを**表 1** にまとめる．以上より，連合学習，DP，分散主成分分析の 3 つが交わり，かつ基底の取得からその基底を用いた学習までを通して評価した研究は，我々の知る限り確認されていない．本論文はこの 3 つが交わる設定を扱う．

© 2026 Information Processing Society of Japan

4. 準備

4.1 連合学習と FedAvg

N 個のクライアントが参加し，クライアント c は n 件のレコードからなるデータ D_c を保有する．各ラウンドで，中央サーバは現在のモデル θ を全クライアントへ配布する．各クライアントは D_c を用いて局所的に学習し，得られたモデルを返す．中央サーバはこれらをデータ件数で重み付けして平均し，次のラウンドのモデルとする．この手続きを FedAvg（Federated Averaging）と呼ぶ [1]．

4.2 差分プライバシーと DP-SGD

1 件のレコードのみが異なる 2 つのデータセット D, D' について，任意の出力集合 S に対し

$$\Pr[\mathcal{M}(D) \in S] \le e^{\varepsilon} \Pr[\mathcal{M}(D') \in S] + \delta \tag{1}$$

が成り立つとき，アルゴリズム $\mathcal{M}$ は (ε, δ)-DP を満たす [3]．ε は 1 件のレコードの有無が出力の分布を変えうる度合いの上界であり，δ はこの制約が成り立たない確率の上界である．ε が小さいほど保護は強い．同じデータに複数の処理を適用すると保証は弱まり，逐次合成では各処理の ε の和が全体の ε となる．この意味で ε は各処理へ配分する量であり，プライバシーバジェットと呼ぶ．本論文で ε と書くとき，隣接するデータセットの定義はレコード単位である．

DP-SGD [4] は，抽出率 q で選んだレコードの集合について，レコード i の勾配 g_i をノルムが C を超えないように縮小し，

$$\bar{g} = \frac{1}{B}\Big(\sum_i \frac{g_i}{\max(1, \|g_i\|_2 / C)} + \mathcal{N}(0, \sigma^2 C^2 I_p)\Big) \tag{2}$$

を更新に用いる．ここで B は選ばれたレコードのデータ件数，p はパラメータ数である．クリッピングを 1 レコードごとに行う（per-sample）ため，1 件のレコードが総和に与える影響は C で抑えられ，これが感度の根拠となる．加えるノイズの 2 乗ノルムの期待値は $p\sigma^2 C^2$ であり，パラメータ数に比例する．繰り返しに対する ε のアカウンティングには Rényi 差分プライバシー [11] を用いる．

4.3 連合学習における差分プライバシー

連合学習に差分プライバシーを適用するとき，保護の単位には 2 つの取り方がある．クライアント単位の保護は，参加するクライアントの存在そのものを隠すもので，多数の端末が参加する設定を想定し，集約した更新に対してノイズを加える [12]．レコード単位の保護は，各クライアントが保有する個々のレコードを対象とするもので，少数のクライアントが継続して参加するクロスサイロ（cross-silo）の設定で標準的に用いられる [13]．本論文は後者を対象とする．各クライアントが局所の学習に DP-SGD を適用し，中央サーバは FedAvg で平均する．レコード単位の保証では，複数のレコードをまとめてからクリッピングすると 1 件のレコードが出力に与える影響の上界を保証できないため，クリッピングは per-sample に行う必要がある [4]．また，クライアント間でデータは重複しないため，各クライアントのアルゴリズムが (ε, δ)-DP を満たせば，全クライアントの出力を合わせても並列合成により (ε, δ)-DP が保たれる．

4.4 分散主成分分析

主成分分析（Principal Component Analysis，PCA）は，データの分散が大きい方向から順に正規直交の基底を求める手法であり，基底は共分散行列の固有ベクトルとして得られる．連合学習の環境では生データを 1 箇所に集められないため，統計量の集約によってこれを計算する．各レコード x に定数 1 を連結した $\tilde{x} = [x; 1]$ を用いて，クライアント c が $M_c = \sum_{x \in D_c} \tilde{x}\tilde{x}^{\top}$ を計算する．この $(d+1) \times (d+1)$ 行列は，2 次モーメント，総和，データ件数を 1 つにまとめた拡張モーメント統計量であり，中央サーバは $\sum_c M_c$ から全体の平均と中心化した共分散行列を復元できる．したがって中央サーバは，各クライアントから 1 度だけこの統計量を受け取れば，生のデータを見ることなく全体の主成分を計算できる [8]．この集約は線形であることから，クライアントごとのラベル分布が偏っていても，全体の共分散行列は偏りなく復元される．上位 k 個の主成分からなる基底 $V_k \in \mathbb{R}^{d \times k}$ を各クライアントへ配布すると，各クライアントは入力を $z = V_k^{\top}(x - \mu)$ により k 次元へ射影して以降の学習に用いることができる．

5. 提案手法

本章では，分散主成分分析で得た基底の上で DP-SGD を行う二段階の手法を提案する．提案手法では，各クライアントが送信した統計量から中央サーバが主成分の基底を求め，各クライアントはその基底で入力の次元を削減してから局所的に DP-SGD を行う．提案手法の全体像を**図 1** に示す．

5.1 構成要素と脅威モデル

本論文が想定する構成要素を以下に示す．

- **クライアント**：医療機関や金融機関など，規制の下で機微なデータを扱う N 個の主体である．各クライアント c は n 件のレコードからなるデータ D_c を保有し，これを外部へ出さない．専門に応じたデータを蓄積するため，D_c は特定のラベルに集中し，その構成はクライアント間で大きく異なる．クライアントどうしは結託しない．
- **中央サーバ**：統計量とモデル更新を集約する．手続き

© 2026 Information Processing Society of Japan

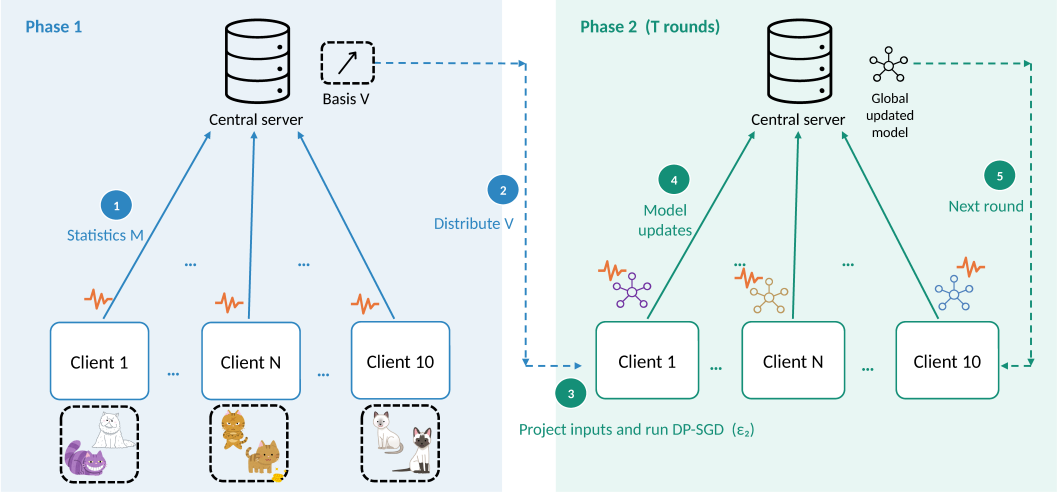


図 1　提案手法の全体図
Fig. 1　Overview of the proposed method.

には従うが，受け取った値から各クライアントのレコードを推測しようとする（honest-but-curious）．各クライアントが送信した統計量 M_c とモデル更新を，集約前の値として観測できる．

- **秘匿しない情報**：参加するクライアントの構成と，各クライアントが保有するデータ件数 n は秘匿しない．前者はクロスサイロの設定によるものであり，後者は FedAvg の重み付き平均に用いる時点で中央サーバに知られるためである．

保護の範囲は以下のとおりとする．

- **保護対象**：各クライアントが保有する個々のレコードであり，隣接するデータセットは 1 件のレコードのみが異なるものとする．どのクライアントが参加しているかは保護対象としない．
- **範囲外**：参加そのものの秘匿，クライアントの母集団の性質に関する推定，および中央サーバとクライアントの結託は本論文の範囲外とする．結託したクライアントは集約結果から自身の更新を差し引くことで非結託クライアントの更新を個別に絞り込めるが，各クライアントの学習は $(\varepsilon_2, \delta_2)$-DP を満たすため，レコード単位の保証は変わらない．統計量とモデル更新は平文で送信するものとし，秘匿集約などの暗号学的な保護は組み合わせない．

5.2　提案手法の構成

提案手法は 2 つの段階からなる．

Phase 1（前処理）． 各クライアントは 4.4 節の統計量 M_c を計算し，中央サーバへ 1 度だけ送信する．中央サーバはこれを集約して全体の主成分を求め，上位 k 個の主成分からなる基底 V_k を各クライアントへ配布する．各クライアントは保有するデータを $z = V_k^\top (x - \mu)$ により k 次元へ射影する．

Phase 2（学習）． 各クライアントは射影後のデータ上で DP-SGD を実行し，得られたモデルを中央サーバが FedAvg で平均する．モデルの入力次元は k であるから，パラメータ数は k に比例して減少する．

Phase 1 の集約は 4.4 節のとおり線形であることから，クライアントごとのラベル分布が偏っていても，得られる基底は原理的にその影響を受けない．分布の偏りの影響を受けるのは Phase 2 の FedAvg のみである．

提案手法が既存の連合学習に対して追加で必要とする通信は，Phase 1 における統計量 M_c の送信と基底 V_k の配布のみである．これらは学習を開始する前に 1 度だけ行われ，T 回繰り返す学習ラウンドには追加の通信を生じない．設計上の性質を 4 点挙げる．第一に，基底を参加クライアント自身のデータから求めるため，公開データを必要としない．第二に，追加の通信は上記のとおり学習ラウンド数に依存しない．第三に，Phase 1 の統計量にも DP を適用でき（5.3 節），その場合の全体の保証は逐次合成により $(\varepsilon_1 + \varepsilon_2, \delta_1 + \delta_2)$ と明示でき，以降 $\varepsilon_1 + \varepsilon_2$ を $\varepsilon_{\text{total}}$ と書く．第四に，削減後の次元 k は設計変数である．k を大きくすれば情報の損失は小さくなる一方でノイズと処理コストが増えるため，適切な k は保護の強度と 1 クライアントあたりのデータ件数に依存する．本論文はこの依存関係を評価によって与える．

5.3　Phase 1 への DP の適用

Phase 1 で送信する統計量そのものにも保護を与える場合は，各クライアントが送信前に行のノルムを C_1 で抑えたうえで，M_c に対称な Gaussian ノイズを 1 度だけ加える [3]．1 件のレコードの追加または削除が M_c に与える変化の Frobenius ノルムは $\|x\|^2 + 1 \le C_1^2 + 1$ で抑えられ，

© 2026 Information Processing Society of Japan

これが感度となる．このとき $\varepsilon_1 > 1$ では，分散を与える古典的な式が適用できないため，Balle らの手法 [14] を用いて $(\varepsilon_1, \delta_1)$ を満たす最小の分散を求める．中央サーバが行う正規化，中心化，固有値分解はいずれも後処理であり，ε を追加で消費しない．データ件数は保護の対象としないため，集約結果のうちデータ件数に対応する成分は用いない．

Phase 1 に DP を適用する場合も 4.3 節の並列合成がそのまま成り立ち，N 個の統計量を同時に公開しても保証は $(\varepsilon_1, \delta_1)$ のままである．一方で，各クライアントが独立にノイズを加えるため，集約後のノイズの大きさは信頼できる第三者が一度だけ加える場合の $\sqrt{N}$ 倍になる．これは信頼できる第三者を置かないことのコストであるが，クライアント数を増やしたときの総データ件数の増加のほうが速いため，基底の劣化はクライアント数とともに小さくなる．

6. 実装評価

6.1 評価の目的

評価の目的は 2 つある．第一に，保護の強度と削減次元の全域で提案手法と既存手法を比較し，次元削減が精度に寄与する条件を特定することである．第二に，通信量と計算量への影響を定量化することである．

6.2 評価環境と設定

データセットは MNIST を用い，画素値を $[0, 1]$ に正規化する．クライアント数は $N = 10$ とし，これはクロスサイロの連合学習で想定される規模である [13]．分割はラベル順に並べたデータを等分し，各クライアントへ 2 つの断片を割り当てる方式 [1] を用いる．クラスごとのデータ件数が等しくないため断片の境界がクラスの内側に落ちることがあり，その結果として各クライアントが保有するクラス数は 2 から 4 となった．クライアント間でデータの分布が不均衡な設定である．次元削減を行わない条件 2 では，主成分分析による中心化の代わりに，全画素に共通の平均と標準偏差による標準化を施す．いずれの条件も平均が 0 に近い入力を DP-SGD に与えることになり，条件間の違いは前処理の内容だけである．

1 クライアントあたりのデータ件数は $n = 100$ を主たる設定とし，比較のため $n = 6000$（全データを 10 分割した場合）も評価する．モデルは中間層の幅が 128 で ReLU を用いる多層パーセプトロンで，入力次元 k のときのパラメータ数は $p(k) = 128k + 1418$ である．学習は $T = 100$ ラウンド，各ラウンドのローカルエポック数は 1，学習率 0.01，クリッピング閾値 $C = 1.0$ とする．抽出率 $q = B/n$ と総更新回数 T_{steps} を設定間で保つため，バッチサイズは n に応じて変える（$n = 100$ では $B = 1$，$n = 6000$ では $B = 64$）[*1]．$\delta_2 = 10^{-5}$ とし，ε_2 からノイズ倍率への変換は Rényi 差分プライバシーによるアカウンティングで行う．各条件は独立に 3 回試行し，平均と標準偏差を示す．

表 2 評価する 4 条件
Table 2 The four conditions evaluated.

	Phase 1	Phase 2	保証（範囲）
条件 1	PCA（DP なし）	DP なし	—
条件 2	なし（$d = 784$）	DP-SGD	ε_2（全体）
条件 3	PCA（DP なし）	DP-SGD	ε_2（Phase 2）
条件 4	PCA（DP あり）	DP-SGD	$\varepsilon_1 + \varepsilon_2$（全体）

Phase 1 に DP を適用する場合は，行のノルムの閾値を $C_1 = 5.0$，$\delta_1 = 10^{-6}$ とする．画素値が $[0, 1]$ にあるため入力ノルムの典型値は 10 前後であり，C_1 をこれより小さく取ることで，感度 $C_1^2 + 1$ を抑えつつ，ほぼ全ての行を一様に縮小して方向の情報を保つ．ε_1 の設定は 6.3.3 節で述べる．

評価は**表 2** の 4 条件で行う．削減次元 k は 13 点 $\{5, 10, 15, 20, 25, 30, 40, 50, 75, 100, 200, 400, 784\}$，保護の強度 ε_2 は 8 点 $\{1, 2, 5, 10, 15, 20, 30, 50\}$ を用いる．条件 3 と 4 は同一のグリッド上で評価する．以降，各 ε_2 についてグリッド上で精度が最大となる削減次元を最良次元と呼ぶ．最良次元は測定後に選ぶため，条件間で比較する際は同一のグリッドを用い，あわせて削減次元を 25 に固定した場合の値も示す．

6.3 評価結果

6.3.1 1 クライアントあたりのデータが少ない場合

1 クライアントあたり 100 件の設定における 4 条件の比較を**図 2** に示す．各 ε_2 について，最良次元における値を示す．条件 3 の精度は，次元削減を行わない条件 2 を最大で 19 ポイント上回った．この差は評価した 8 点すべての ε_2 で標準偏差の 2 倍を超えた．差が最大となるのは ε_2 が 5 から 10 の範囲であり，保護を最も強めた点でも最も弱めた点でもない．最良次元は $\varepsilon_2 = 1$ で 5，$\varepsilon_2 \geq 15$ で 25 であり，保護を弱めるほど大きい側へ移る．

6.3.2 1 クライアントあたりのデータが十分な場合

1 クライアントあたり 6000 件の設定を**図 3** に示す．削減次元ごとの精度差は消え，最良次元は評価したすべての ε_2 で削減を行わない 784 となる．この設定で削減次元を 25 に固定したときの条件 2 に対する精度の低下は約 2 ポイントである．

境界の位置を確認するため，ε_2 を 0.03 まで広げた測定を**図 4** に示す．最良次元は $\varepsilon_2 = 0.187$ で 25，$\varepsilon_2 = 0.391$ で 784 となり，この区間で削減を行う側から行わない側へ移る．条件 2 に対する精度差は $\varepsilon_2 = 0.033$ で $+24.6$ ポイ

[*1] q は $n = 100$ で 0.0100，$n = 6000$ で 0.0107 とわずかに異なる．ノイズ倍率は各設定で目標の ε_2 を満たすようキャリブレーションしているため，設定間で保護の強度は等しい．

© 2026 Information Processing Society of Japan

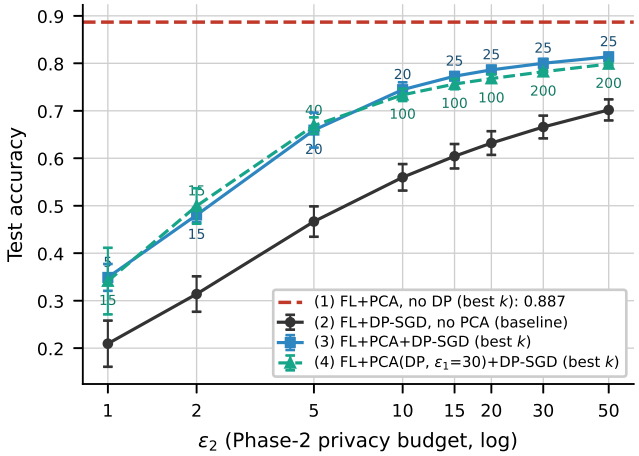


図 2　4 条件の精度比較（$n = 100$）

Fig. 2　Accuracy of the four conditions ($n = 100$).

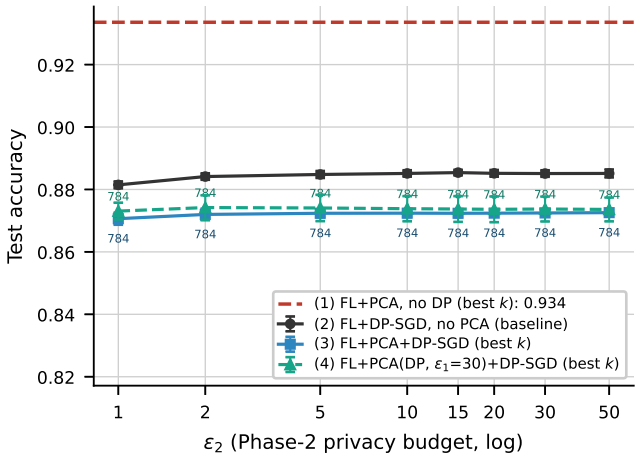


図 3　4 条件の精度比較（$n = 6000$）

Fig. 3　Accuracy of the four conditions ($n = 6000$).

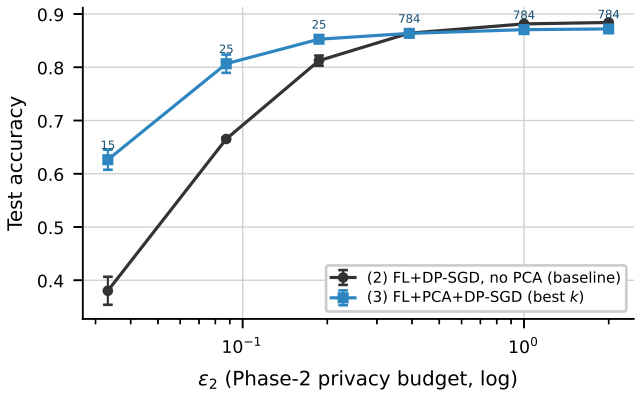


図 4　低い ε_2 における条件 2 と条件 3 の精度（$n = 6000$）

Fig. 4　Accuracy of conditions (2) and (3) in the low-budget regime ($n = 6000$).

ント，$\varepsilon_2 = 0.391$ で -0.04 ポイントである．

6.3.3　Phase 1 に DP を適用した場合

Phase 1 の統計量にも DP を適用する場合，必要な ε_1 は，付加するノイズが固有値に対して十分小さく抑えられる水準として定まり，1 クライアントあたりのデータ件数が少ないほど大きくなる．1 クライアントあたり 100 件の設定では同じ $\varepsilon_{\text{total}}$ における条件 2 との精度差が $\varepsilon_1 = 30$ で最大となる一方，6000 件の設定では ε_1 による差がほとんど現れないため，本評価では $\varepsilon_1 = 30$ を採用した．ε_1 を変えたときの精度は付録 A.1 に示す．同じ $\varepsilon_1 = 30$ を 1 クライアントあたり 6000 件の設定に適用した場合，条件 4 と条件 3 の差は評価した 8 点すべての ε_2 で $+0.1$ から $+0.2$ ポイントであり，いずれも標準偏差の 2 倍の範囲に収まる（図 3）．

$\varepsilon_1 = 30$ における削減次元と精度を**図 5** に，条件 2 に対する精度差と条件 4 の最良次元を**表 3** に示す（図中の星印は各 ε_2 における最大点を表す）．表 3 の条件 3− 条件 2 の列は削減次元を 25 に固定したときの差であり，他の列は最良次元における値である．なお，図 2 と図 3 の条件 4 は横軸を ε_2 に取っており，$\varepsilon_{\text{total}} = \varepsilon_2 + 30$ である．最良次元における精度は，統計量に保護を与えない条件 3 と 2 ポイント以内の差にとどまる一方，最良次元は $\varepsilon_2 = 1$ の 15 から $\varepsilon_2 = 50$ の 200 へと，条件 3 より大きい側へ移動した．

表 3　条件 4 の精度と最良次元（$n = 100$）

Table 3　Accuracy and best reduced dimension of condition (4) ($n = 100$).

ε_2	条件 3 − 条件 2	条件 4 の k^*	条件 4 の精度	条件 4 − 条件 2	条件 4 − 条件 3
1	+6.71	15	0.3413	+13.19	−0.77
2	+11.01	15	0.4995	+18.55	+1.90
5	+18.23	40	0.6689	+20.22	+0.96
10	+18.24	100	0.7336	+17.37	−1.10
15	+16.86	100	0.7563	+15.21	−1.65
20	+15.42	100	0.7679	+13.59	−1.84
30	+13.43	200	0.7822	+11.64	−1.79
50	+11.19	200	0.7985	+9.67	−1.52

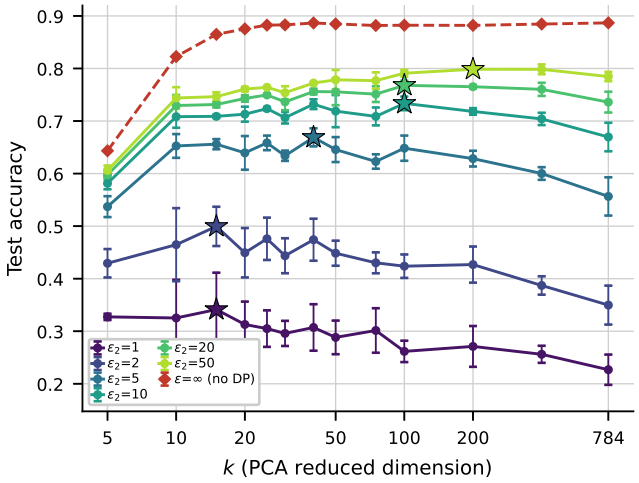


図 5　削減次元と精度の関係（条件 4，$\varepsilon_1 = 30$）

Fig. 5　Accuracy versus reduced dimension (condition (4), $\varepsilon_1 = 30$).

© 2026 Information Processing Society of Japan

表 4　削減次元ごとの通信量と計算時間

Table 4　Communication and computation cost by reduced dimension.

k	$p(k)$	通信 (MB)	削減	計算 (ms)	削減
25	4618	62.4	92.3%	141.9	87.8%
100	14218	141.5	82.6%	247.8	78.8%
200	27018	247.1	69.7%	384.2	67.1%
784	101770	814.2	—	1167.7	—

表 5　精度差の分解（$n = 100$）

Table 5　Decomposition of the accuracy difference ($n = 100$).

ε_2	条件 2	k^*	差 (pp)	トランケーション	前処理
1	0.2094	5	+13.96	+12.36	+1.60
2	0.3140	15	+16.65	+12.41	+4.23
5	0.4667	20	+19.26	+8.78	+10.49
10	0.5599	20	+18.47	+5.60	+12.87
15	0.6043	25	+16.86	+4.24	+12.62
20	0.6320	25	+15.42	+3.43	+11.99
30	0.6659	25	+13.43	+2.52	+10.90
50	0.7018	25	+11.19	+1.76	+9.44

6.3.4　処理コスト

削減次元ごとの通信量と計算時間を**表 4** に示す．通信量は Phase 1 の統計量の送信と基底の配布を含む双方向の総量（$T = 100$，$N = 10$）であり，計算時間は per-sample クリッピングを含む 1 ラウンドあたりの実測の中央値である．削減次元 25 では通信量が 92.3%，計算時間が 87.8%減少する．Phase 1 で追加される通信は 1 クライアントあたり 2.5MB であり，学習 4 ラウンド未満の通信削減で相殺される．また，per-sample の勾配の保持がもたらす DP-SGD の実行時間は，削減次元 25 では通常の SGD の 2.05 倍にとどまるのに対し，削減を行わない 784 次元では 5.97 倍に達する．条件 4 では最良次元が大きい側へ移るため，削減率は約 9 割から約 7 割に下がる．

7.　考察

7.1　精度改善の要因

条件 3 が条件 2 に対して示した精度改善は，2 つの要因に分解できる．削減次元を $k = 784$ とした条件は，主成分方向への回転を行うが次元のトランケーションを伴わない．この条件を基準に置くと，条件 2 との差は，主成分方向への回転を含む前処理による寄与と，トランケーションによる寄与に分離できる（**表 5**）．前処理の寄与には，回転に加えて，条件 2 で用いる全画素に共通の平均と標準偏差による標準化と，条件 3 の中心化との違いも含まれる．ε_2 が小さい側ではトランケーションの寄与が大きく，ε_2 が大きい側では前処理の寄与が大きい．したがって，保護を弱めた領域における精度改善は，その大半が次元削減ではなく前処理に由来すると考えられる．

7.2　効果が現れる条件と現れない条件

次元削減が精度を改善するかどうかは，付加するノイズの大きさと学習に用いる勾配の大きさの比で決まる．この比はノイズ倍率とパラメータ数の平方根に比例し，パラメータ数は削減次元に比例するため，比が大きい領域では次元の削減が精度を改善する．すなわち，データが少ない領域では，入力の情報を減らすことが，ノイズの低減を通じてかえって精度を向上させる．比が小さい領域では，トランケーションによる情報の損失だけが残る．

この比を保護の強度について解くと，改善が現れる境界は $\varepsilon \lesssim \sqrt{p \ln(1/\delta)}/n$ と表せる．ここで n は 1 クライアントあたりのデータ件数である．削減を行わない $k = 784$ を代入すると，境界は 100 件で約 11，6000 件で約 0.2 となり，前者は評価した ε_2 の範囲（1 から 50）の内側に，後者は外側にある．6.3.1 節と 6.3.2 節の違いはこの位置関係で説明でき，6.3.2 節で最良次元が移った区間（$\varepsilon_2 = 0.187$ から 0.391）は式の値の近傍にある．ただしこの式が与えるのは桁の目安であり，またこの境界は $k = 784$ に対してトランケーションが利得を生むかどうかを表すものであって，条件 2 と条件 3 の優劣とは対応しない．実際，100 件の設定では評価したすべての ε_2 で条件 3 が条件 2 を上回る．

なお，勾配をバッチ単位でまとめてクリッピングし，平均勾配にノイズを加える実装では，レコード単位の保護に必要な倍率よりバッチサイズの倍数だけ大きいノイズが実質的に加わる．この場合は上述の比が過大に見積もられ，データが十分な設定でも次元削減が有効に見える．

7.3　Phase 1 への DP 適用に伴うコスト

本評価で用いた $\varepsilon_1 = 30$ では，Phase 1 に保証を与えるコストは，精度ではなく処理コストの削減率に現れると考えられる．同じ ε_1 では，集約後の共分散に対するノイズの相対的な影響が総データ件数に反比例するため，6000 件では 100 件の設定の 60 分の 1 となり，精度と最良次元に影響が現れない．このコストが問題になるのは，次元削減が精度に寄与するのと同じ，データが少ない領域である．

7.4　限界

本評価は MNIST と多層パーセプトロンの組み合わせに限られる．医療や金融で想定される環境は，1 クライアントあたりのデータ件数と分割の偏りという条件に置き換えて評価しており，実データによる確認は行っていない．試行回数は 3 回であり，保護を強めた領域では試行間の差が大きい．統計量の保護に用いた ε_1 は，この値のみを取り出して見た場合には保護の水準として十分とはいえないと考えられる．

8.　おわりに

本論文では，クロスサイロの連合学習においてレコード

© 2026 Information Processing Society of Japan

単位の差分プライバシーを課す設定を対象に，公開データを用いず参加クライアント自身のデータから分散主成分分析で基底を求め，その上で DP-SGD を行う二段階の手法を提案し，保護の強度と削減次元を網羅的に変化させて評価した．1 クライアントあたりのデータが少ない環境では次元削減を行わない既存手法を最大 19 ポイント上回り，データが十分な環境では精度の低下を約 2 ポイントに抑えて通信量と計算量を約 9 割削減した．前処理にも保証を与える場合，削減率は約 7 割に下がる．次元削減が精度に寄与するのは $\varepsilon \lesssim \sqrt{p\ln(1/\delta)}/n$ の範囲であり，この式は効果が現れる条件と現れない条件の双方を説明する．今後の課題として，$\varepsilon_{\text{total}}$ を与えたときの ε_1 と ε_2 への配分や，パラメータ数がより大きい設定への拡張が必要である．ともに本手法の汎用性を高める上で不可欠な要素であり，今後は実データによる検証や，秘匿集約などの暗号学的な保護を Phase 1 に組み合わせる手法の構築が有効なアプローチとして考えられる．

謝辞　本研究は，JSPS 科研費 JP25H01106 の助成を受けたものである．

参考文献

[1] McMahan, H.B., Moore, E., Ramage, D., Hampson, S. and Agüera y Arcas, B.: Communication-Efficient Learning of Deep Networks from Decentralized Data, *Proc. Int'l Conf. on Artificial Intelligence and Statistics (AISTATS)*, PMLR, Vol.54, pp.1273–1282 (2017).

[2] Zhu, L., Liu, Z. and Han, S.: Deep Leakage from Gradients, *Advances in Neural Information Processing Systems (NeurIPS)*, Vol.32, pp.14747–14756 (2019).

[3] Dwork, C., Talwar, K., Thakurta, A. and Zhang, L.: Analyze Gauss: Optimal Bounds for Privacy-Preserving Principal Component Analysis, *Proc. ACM Symp. on Theory of Computing (STOC)*, pp.11–20 (2014).

[4] Abadi, M., Chu, A., Goodfellow, I., McMahan, H.B., Mironov, I., Talwar, K. and Zhang, L.: Deep Learning with Differential Privacy, *Proc. ACM SIGSAC Conf. on Computer and Communications Security (CCS)*, pp.308–318 (2016).

[5] Bassily, R., Smith, A. and Thakurta, A.: Private Empirical Risk Minimization: Efficient Algorithms and Tight Error Bounds, *Proc. IEEE Symp. on Foundations of Computer Science (FOCS)*, pp.464–473 (2014).

[6] Yu, D., Zhang, H., Chen, W. and Liu, T.-Y.: Do Not Let Privacy Overbill Utility: Gradient Embedding Perturbation for Private Learning, *Proc. Int'l Conf. on Learning Representations (ICLR)* (2021).

[7] Zhou, Y., Wu, Z.S. and Banerjee, A.: Bypassing the Ambient Dimension: Private SGD with Gradient Subspace Identification, *Proc. Int'l Conf. on Learning Representations (ICLR)* (2021).

[8] Liang, Y., Balcan, M.-F., Kanchanapally, V. and Woodruff, D.: Improved Distributed Principal Component Analysis, *Advances in Neural Information Processing Systems (NIPS)*, Vol.27, pp.3113–3121 (2014).

[9] Grammenos, A., Mendoza Smith, R., Crowcroft, J. and Mascolo, C.: Federated Principal Component Analysis, *Advances in Neural Information Processing Systems (NeurIPS)*, Vol.33, pp.6453–6464 (2020).

[10] Tramèr, F. and Boneh, D.: Differentially Private Learning Needs Better Features (or Much More Data), *Proc. Int'l Conf. on Learning Representations (ICLR)* (2021).

[11] Mironov, I.: Rényi Differential Privacy, *Proc. IEEE Computer Security Foundations Symp. (CSF)*, pp.263–275 (2017).

[12] McMahan, H.B., Ramage, D., Talwar, K. and Zhang, L.: Learning Differentially Private Recurrent Language Models, *Proc. Int'l Conf. on Learning Representations (ICLR)* (2018).

[13] Liu, K., Hu, S., Wu, S.Z. and Smith, V.: On Privacy and Personalization in Cross-Silo Federated Learning, *Advances in Neural Information Processing Systems (NeurIPS)*, Vol.35, pp.5925–5940 (2022).

[14] Balle, B. and Wang, Y.-X.: Improving the Gaussian Mechanism for Differential Privacy: Analytical Calibration and Optimal Denoising, *Proc. Int'l Conf. on Machine Learning (ICML)*, PMLR, Vol.80, pp.394–403 (2018).

付　　録

A.1　ε_1 の影響

$\varepsilon_2 = 10$ と削減次元 25 に固定し，ε_1 を 50 から 2 まで変えたときの精度を**表 A·1** と**表 A·2** に示す．各行には同じ $\varepsilon_{\text{total}} = \varepsilon_1 + \varepsilon_2$ における条件 2 を併記する．1 クライアントあたり 100 件では，ε_1 が 5 以下で精度が大きく低下する．

6000 件では，集約後の共分散に対するノイズの相対的な影響が総データ件数に反比例して小さくなるため，ε_1 を 50 から 2 まで変えても精度はほとんど変わらない．必要な ε_1 は 100 件の設定より大きく下がる．

表 A·1　ε_1 の掃引（$n = 100$，$k = 25$，$\varepsilon_2 = 10$）
Table A·1　Sweep over ε_1 ($n = 100$).

ε_1	$\varepsilon_{\text{total}}$	条件 2	条件 4	条件 4− 条件 2
50	60	0.7125	0.7201	+0.76
30	40	0.6867	0.7235	+3.68
20	30	0.6659	0.6985	+3.26
10	20	0.6320	0.6517	+1.97
5	15	0.6043	0.5432	−6.11
2	12	0.5806	0.4614	−11.92

表 A·2　ε_1 の掃引（$n = 6000$，$k = 25$，$\varepsilon_2 = 10$）
Table A·2　Sweep over ε_1 ($n = 6000$).

ε_1	$\varepsilon_{\text{total}}$	条件 2	条件 4	条件 4− 条件 2
50	60	0.8852	0.8585	−2.67
30	40	0.8851	0.8587	−2.64
20	30	0.8851	0.8592	−2.59
10	20	0.8852	0.8603	−2.49
5	15	0.8854	0.8608	−2.46
2	12	0.8853	0.8576	−2.77

© 2026 Information Processing Society of Japan