レコード再構築攻撃に対するプライバシーを考慮したLLMベース自然言語説明フレームワークの提案

當麻 僚太郎[1,a)]　菊池 浩明[1,b)]

概要：機械学習モデルは近年，様々な領域で活用されている．しかし，多くのモデルは複雑な内部構造を持ち，モデルの公平性や透明性を担保することが難しいブラックボックスモデルである．そこで，機械学習モデルの振舞いを説明する技術として，説明可能 AI（Explainable AI; XAI）技術が注目されている．しかし，SHAP や LIME といった XAI 手法は，入力値がモデル出力に与えた影響を定量的に評価する一方で，その影響の大きさや意味を解釈するには依然として専門知識を要するという課題がある．加えて，これらの XAI 手法には，説明ベクトルから本来秘匿される入力値を復元するレコード再構築攻撃のリスクがあることが知られている．そこで，本研究では，具体的な入力値と XAI による説明値を意味的に抽象化し，LLM による検証と修正を反復することで，レコード再構築リスクを低減する LLM ベース自然言語説明生成フレームワークを提案する．オープンデータセットを用いて実験を行い，既存の XAI による説明ベクトルおよび LLM ベース自然言語説明手法と比較して，提案手法がレコード再構築リスクを低減することを示した．

キーワード：説明可能 AI，レコード再構築攻撃，大規模言語モデル，SHAP，プライバシー保護 AI

A Privacy-Aware LLM Rewriting Framework for Model Explanations against Record Reconstruction Attacks

Ryotaro Toma[1,a)]　Hiroaki Kikuchi[1,b)]

Abstract: Machine-learning models have been used in a wide range of domains. However, many models have complex internal structures and operate as black boxes, making it difficult to ensure their fairness and transparency. Explainable AI (XAI) has therefore attracted attention for explaining the behavior of machine-learning models. Although XAI methods such as SHAP and LIME quantify the effects of input values on model outputs, interpreting the magnitude and meaning of these effects still requires specialized knowledge. Moreover, these methods are known to entail record reconstruction risks, in which private input values can be reconstructed from explanation vectors. We propose an LLM-based natural-language explanation framework that reduces record reconstruction risk by semantically abstracting specific input and explanation values and iteratively verifying and rewriting the generated explanations with an LLM. Experiments on the Adult dataset show that the proposed method reduces record reconstruction risk compared with conventional XAI explanation vectors and existing LLM-based natural-language explanation methods.

Keywords: explainable AI, record reconstruction attack, large language model, SHAP, privacy-preserving AI

1. はじめに

機械学習モデルは近年，金融 [1]，医療 [2]，E コマース [3] などの重要な用途で利用されている．一方，深層ニューラ

[1] 明治大学総合数理学部
School of Interdisciplinary Mathematical Sciences, Meiji University
[a)] rytaryu@meiji.ac.jp
[b)] kikn@meiji.ac.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

ルネットワークやアンサンブルモデルは複雑な内部構造を持つブラックボックスモデルであり，モデルがどのように意思決定したかを把握することは難しい．機械学習モデルを信頼性のあるシステムで利用するためには，入力特徴量とモデル出力との関係について透明性が必要である．そこで，モデルの振舞いを説明する説明可能 AI（Explainable AI; XAI）が注目されている [4], [5].

XAI は，入力特徴量がモデル出力へ与えた影響をモデル説明としてユーザーへ提供する．現在，多くの Machine-Learning-as-a-Service（MLaaS）プラットフォームで XAI が利用できる．特に, Shapley 値 [6] に基づく XAI 手法 [7], [8] は, Amazon Web Services [9], Google Cloud [10], Microsoft Azure [11] などで提供されている．

しかし，XAI にはプライバシー上の課題がある．例えば 2022 年に Luo ら [12] は，Shapley 値に基づく説明ベクトルから，本来秘匿される入力レコードを推定する攻撃を提案した．攻撃者は，同一分布に従う補助データセットをモデル説明サービスへ入力し，得られた説明ベクトルと元の入力レコードの対応から攻撃モデルを学習する．Luo らは，複数のデータセットとブラックボックスモデルを用いて，攻撃の実現可能性を示した．

Luo らが対象とした Shapley 値以外にも，LIME [13], Anchors [14]，DeepLIFT [15] など，多くの XAI 手法が知られている．しかしながら，これらの XAI 手法が提示する説明を非専門家が理解することは難しい．そこで，Paraschou ら [16] は，人間中心の XAI に向け，ドメイン知識とモデル説明に関する知識を LLM へ与えて自然言語説明を生成する枠組みを提案した．また，Mermigkis ら [17] は，根拠のない内容や重要情報の欠落などを検証・修正する Explainer–Verifier 方式を提案した．一方で，XAI のプライバシーリスクが知られているにもかかわらず，これら既存研究はプライバシーを考慮した説明生成を扱っていない．

そこで，本研究では，XAI からのレコード再構築リスクを考慮した自然言語説明生成フレームワークを提案する．LLM を用いて具体的な入力値や説明値を抽象化し，プライバシーを保護した自然言語説明を生成する．加えて，単一の LLM 生成に含まれるハルシネーションや制約への違反などを低減するため，検証と修正を反復して説明の忠実性や一貫性，プライバシーを改善する．実験では，UCI Adult [18] データセットと SHAP [7] を用いて，自然言語説明に対するレコード再構築攻撃を行う．加えて，既存の説明ベクトルに対する攻撃や Paraschou ら [16] に準拠した説明に対しても攻撃を行い，そのリスクについて比較する．本稿の主な貢献は次のとおりである．

- 入力レコード，説明ベクトル，予測結果およびモデル説明を参照し，入力値や説明値を公開せずに重要特徴と寄与方向を伝える自然言語説明方式を提案した．
- 既存の自然言語説明手法や提案手法に対する実験によって，自然言語説明によるレコード再構築リスクの低減効果を明らかにした．
- LLM を用いて検証と修正を反復するフレームワークによって，反復なしの説明と比較してより低いリスクを達成できることを示した．

2. 関連研究

2.1 XAI 手法

ブラックボックスモデルを説明する XAI 手法は，モデル全体の振舞いを示す大域的手法と，個々の入力に対する判断根拠を示す局所的手法に大別される．

例えば，2016 年に Ribeiro らが提案した LIME [13] は，特定の入力ベクトル周辺でのモデルの決定境界をより簡単なモデルで近似することで，局所的な説明を与える．加えて，DeepLIFT [15] や Grad-CAM [19]，Anchors [14] など，多くの局所的な説明手法が提案されている．

また，Shapley 値 [6] に基づいた手法として，2014 年に Strumbelj らが提案したサンプリング手法 [8] や，2017 年に Lundberg らが提案した，LIME のように局所的な説明モデルを用いて Shapley 値を近似する SHAP [7] がある．Lundberg らは，SHAP や LIME などの XAI 手法をまとめた Additive Feature Attribution Methods クラスを提案している．

Amazon SageMaker [9] や Microsoft Azure [11]，Google Cloud Platform [10] などの主要な MLaaS プラットフォームでは，多くの XAI 手法が提供されている．これらの MLaaS プラットフォームでは共通して SHAP が提供されている．

2.2 XAI のプライバシーリスク

XAI にはプライバシーリスクが存在する．例えば，2024 年に Liu ら [20] は，SHAP や LIME，Grad-CAM などの 7 種類の XAI に対してメンバーシップ推論攻撃を提案し，XAI が訓練データセットの情報を漏洩することを示している．同様に，Kuppa ら [21] や Shokri ら [22] も XAI からのメンバーシップ推論リスクを報告している．また，2023 年に Yan らは XAI-aware Model Extraction Attack（XaMEA）を提案 [23] し，XAI がモデルの情報を漏洩することを示している．この種類の攻撃はモデル抽出攻撃として整理され，他に Yan ら [24] や Olatunji ら [25] も同種のリスクを報告している．

さらに，Luo ら [12] は 2022 年に，Shapley 値を用いた属性推論攻撃を提案し，Shapley 値に基づくモデル説明のプライバシーリスクを明らかにしている．この種類の攻撃は，2015 年に Fredrikson ら [26] が提案した，モデル出力からモデルへの入力や訓練データを推定するモデル反転攻撃の XAI に対する拡張として整理される．また，2025 年

© 2026 Information Processing Society of Japan

表 1 既存研究に対する本研究の新規性
Table 1 Comparison of related works and ours

方式	プライバシー制約	反復修正	リスク評価
Paraschou ら [16]	なし	なし	なし
Mermigkis ら [17]	なし	あり	なし
本研究	あり	あり	あり

に著者ら [27] は Luo らの攻撃をレコード再構築攻撃として整理し，LIME に対しても同様のリスクがあることを指摘した．

一方で，XAI に対してプライバシー保護を行う手法も提案されている．例えば，Datta ら [28] は 2016 年に，Shapley 値を含むモデル説明を統合的に扱う手法 Qualitative Input Influence (QII) を提案し，QII に対して差分プライバシー [29] を適用した．また，2022 年に Patel ら [30] は LIME のような局所線形近似に基づくモデル説明に差分プライバシーを導入した．しかしながら，これらのプライバシー保護手法は加工によって有用性を落とし，正確でない値や説明を提供し得る．

2.3 LLM による自然言語説明

数値に基づくモデル説明は詳細な貢献度を提示する一方で，各属性が出力に与えた貢献度の大小や正負，それらが与える意味を解釈するためにはドメイン知識や専門知識を要する場合がある．そこで，XAI の出力やドメイン知識を LLM へ与え，LLM が解釈を行うことで人間にとってより理解しやすい自然言語文でモデル説明を生成する研究が行われている [16], [17], [31], [32]．例えば，2026 年に Paraschou ら [16] は，従来のモデル説明を非専門家が理解する難しさと，人間向けの後処理に要する資源を課題として挙げ，ドメイン知識とモデル説明に関する知識を LLM へ与えて自然言語説明を生成する枠組みを提案した．しかし，LLM による自然言語説明には，根拠のない特徴の追加や内容の欠落などの忠実性，一貫性，ハルシネーションなどの問題が生じ得る．そこで，2026 年に Mermigkis ら [17] は，二種類の LLM を Explainer と Verifier として用い，Verifier のフィードバックを Explainer へ戻して自然言語説明を反復的に修正する方式を提案した．

一方で，XAI によるプライバシーリスクが知られているにもかかわらず，これらの研究はプライバシーを考慮した自然言語説明を生成していない．そこで本研究ではプライバシー制約を加えた自然言語説明フレームワークを提案し，そのリスクを評価する． **表 1** に本研究と既存研究との比較を示す．

3. 問題設定

3.1 脅威モデル

予測サービスは，ユーザーの入力レコード $\boldsymbol{x} \in \mathcal{X}$ から予測 $y = f(\boldsymbol{x})$ と説明ベクトル $\boldsymbol{s} = \phi(\boldsymbol{x}; f)$ を計算する．ここで，f はサービスにデプロイされたブラックボックスモデル，ϕ は XAI 手法によって説明ベクトルを生成する写像である．サービスは XAI 手法を実行単位のコンテキストに固定し，信頼領域内の LLM に基づく公開用説明生成機構 $\mathcal{M}$ へ $\boldsymbol{x}, \boldsymbol{s}, y$ を渡し，自然言語説明 $T = \mathcal{M}(\boldsymbol{x}, \boldsymbol{s}, y)$ を生成する．ユーザーへは予測と T を返すが，$\boldsymbol{x}$，$\boldsymbol{s}$，生成途中の候補および検証結果は公開しない．入力そのものを LLM へ渡すため，LLM はローカルまたは信頼された実行環境にあるものとし，LLM 提供者への入力漏洩は本稿の対象外とする．

攻撃者は，ブラックボックスモデルの訓練データセットと同一の分布からなる補助データセットを事前知識として持ち，予測・モデル説明サービスへのブラックボックスアクセス権限を持つ．攻撃者は補助データセットの各レコード $\boldsymbol{x}^{(j)}$ から対応する公開された自然言語説明 $T^{(j)}$ を取得し，$T^{(j)}$ と $\boldsymbol{x}^{(j)}$ の組を用いて，$\hat{\boldsymbol{x}}^{(j)} = \psi(T^{(j)})$ となる攻撃モデル ψ を学習する．攻撃者の目的は，あるユーザーの入力レコード $\boldsymbol{x}$ に対する公開された自然言語説明 T から，入力レコード $\boldsymbol{x}$ を推定した再構築レコード $\hat{\boldsymbol{x}}$ を得ることである．

3.2 提案方式

入力レコード $\boldsymbol{x}$，説明ベクトル $\boldsymbol{s}$，モデル出力 y を入力として自然言語説明を生成する公開用説明生成機構 $\mathcal{M}$ を提案する．LLM に基づく Explainer を E，Rewriter を R とし，t 回目の反復における自然言語文 T_t，合否 a_t，修正文 T_{t+1} を

$$T_0 = E(\boldsymbol{x}, \boldsymbol{s}, y), \tag{1}$$

$$(a_t, T_{t+1}) = R(\boldsymbol{x}, \boldsymbol{s}, y, T_t) \tag{2}$$

と定義する．ここで，$0 \le t < 10$ とする．$a_t = \text{true}$ なら反復を終了し，false なら修正文を次回の入力とする．初回候補 T_0 を初回説明，反復終了時に保持された候補 T_N を最終説明とし，公開用説明生成機構の出力を $T = \mathcal{M}(\boldsymbol{x}, \boldsymbol{s}, y) = T_N$ とする．Rewriter は全レコードで最低 1 回，最大 10 回呼び出す．

one-hot encoding 後の特徴名にはカテゴリ値が含まれるため，そのまま LLM へ示すと値を漏洩する．そこで，前処理メタデータを用いて encoded 特徴を元特徴へ対応付ける．元特徴 i に対応する encoded 特徴の集合を G_i とし，集約後の説明値を $\bar{s}_i = \sum_{k \in G_i} s_k$ として求める．本実験では，Adult のカテゴリ特徴に one-hot encoding を適用した．結果として，各入力レコードは 14 個の元特徴から 119 次元のベクトルへ変換された．この特徴空間で計算した 119 次元の SHAP による説明ベクトルを，前処理メタデータに基づいて 14 個の元特徴へ集約した．Explainer は絶対寄与の大きい少数の元特徴を選び，予測クラスを支持または抑

© 2026 Information Processing Society of Japan

制する方向とレコード内での相対的重要性を説明する．

出力は英語の 3 から 5 文の平文段落とし，正確な数値入力，カテゴリ入力，説明値，予測確率，レコード識別子および数値のクラス識別子を禁止する．カテゴリ値は同義語へ置換せず特徴領域だけを示し，数値は境界を持たない広い表現へ一般化できない場合には特徴領域だけを示す．一方，使用した XAI 手法，予測結果，主要因および寄与方向は残す．例えば，年齢や婚姻状態の具体値を記さず，“age-related profile supported the outcome” や “marital-status information opposed it” のように表す．

3.3 プロンプト

Rewriter は，現在候補と $\boldsymbol{x}, \boldsymbol{s}, y$ を比較し，プライバシー，予測結果，入力および説明値との整合性，寄与方向，重要度，XAI 手法，未根拠内容，因果，相互作用，ステレオタイプ，自然さおよび形式を検証する．内部応答は合否と修正文を持つ JSON であり，公開するのは自然言語説明だけである．合格時は現在候補を変更せず，不合格時は検証で見つけた問題を修正するよう指示する．

実験で用いたプロンプトは英語で記述した．System メッセージには，Adult の領域，予測課題，クラス，14 個の特徴，SHAP 値の解釈および各役割の固定指示を記載した．レコードごとの User メッセージには，入力レコード $\boldsymbol{x}$，説明ベクトル $\boldsymbol{s}$ およびモデル出力 y を，それぞれ JSON の `x`, `s` および `y` フィールドとして挿入し，Rewriter ではこれらに現在候補を加えた．**表 2** に，実際に用いた System メッセージの固定文の抜粋と動的入力の形式を示す．Explainer には具体的な入力値と説明値の開示を禁止しつつ，予測結果，重要特徴，寄与方向および相対的重要性を保持するよう指示した．Rewriter には同じ情報と現在候補を与え，合否と修正文を定めた JSON 形式で返すよう指示した．

Rewriter の通信失敗や不正な JSON 構造の出力，または 10 回の上限到達時には，最後の非空候補を不合格のまま保持する．保持した候補は，レコード再構築攻撃と生成時間の集計に含める．

図 1 に，テストデータセットの同じレコードについて，14 個の元特徴へ集約した SHAP 値ベクトル，実際に生成された提案手法 T_N および Paraschou ら準拠方式の自然言語説明を示す．提案手法では具体的な入力値や説明値を含まない説明が生成される．

3.4 評価指標

レコード再構築リスクを評価するため，攻撃者の平均絶対誤差（MAE）と攻撃成功率（SR）の 2 つの指標を用いる．

3.4.1 攻撃者の MAE

MAE は絶対誤差の平均である．m 行 n 列の入力データセット X と，攻撃者が再構築したデータセット $\widehat{X}$ に対する MAE を

$$\mathrm{MAE}(\widehat{X}, X) = \frac{1}{mn} \sum_{j=1}^{m} \sum_{i=1}^{n} \left| \widehat{X}_i^{(j)} - X_i^{(j)} \right| \qquad (3)$$

と定義する．

3.4.2 攻撃成功率 SR

SR は，すべての入力特徴のうち正確に再構築できた特徴の比率を表す．カテゴリ特徴は one-hot encoding した特徴群から復号した値が元の値と一致しているとき，数値特徴は絶対誤差がテストデータセットにおける各特徴の値域の 5%以下であるとき，再構築に成功したと見なす．データセット X に対して再構築したデータセット $\widehat{X}$ の SR を

$$\mathrm{SR}(\widehat{X}, X) = \frac{\mathrm{success}(\widehat{X}, X)}{mn} \qquad (4)$$

と定義する．ここで，$\mathrm{success}(\widehat{X}, X)$ は正確に再構築された入力特徴の数である．

4. 実験

4.1 実験条件

UCI Adult データセット [18] と SHAP を用いた．使用した分割は，ブラックボックスモデルの学習に用いる訓練データセット 34,018 件，SHAP の計算に用いる説明データセット 100 件，攻撃者が持つ補助データセット 1,600 件，検証データセット 100 件，テストデータセット 1,000 件である．ブラックボックスモデルはテストデータセットに対して Accuracy 0.8110，F1 0.7848 であった．

本研究では，Explainer と Rewriter の双方にローカルの gpt-oss:20b [33] を用い，推論強度を low，temperature を 0，最大出力長を 2,048 トークンとした．実行環境は NVIDIA RTX 6000 Ada Generation，Ollama 0.31.2 である．補助データセット 1,600 件，検証データセット 100 件，テストデータセット 1,000 件の計 2,700 件について初回自然言語説明と最終自然言語説明を生成した．

レコード再構築攻撃では，SHAP による説明ベクトル，Paraschou ら準拠方式の自然言語説明，提案手法の初回説明 T_0，提案手法の最終説明 T_N を比較する．Paraschou ら準拠方式は，Paraschou ら [16] が公開したリポジトリの実装を Adult データセットに適用できるよう流用したものである．また，図には Luo ら [12] の RG-E と同一のランダム予測を参照条件として示す．RG-E では，各補助データセットの経験分布から入力レコード全体を重複ありで抽出する．

自然言語には，凍結した BGE-M3 [34] による L2 正規化済み 1,024 次元埋め込みを用いる．攻撃モデル ψ への入力は，SHAP 条件では 119 次元特徴空間で計算した説明ベクトル $\boldsymbol{s}$，自然言語説明条件では文章埋め込みである．攻撃モデル ψ は，これらを $512 \to 512 \to 119$ と変換する MLP である．二つの隠れ層には ReLU と dropout 0.2 を用い，単一の 119 次元出力層には Sigmoid を適用する．目的変数

© 2026 Information Processing Society of Japan

表 2 Explainer と Rewriter に実際に与えた System メッセージの抜粋と User メッセージの形式

Table 2 Excerpts from the actual system messages and formats of the user messages.

役割	種別	プロンプト
共通	**System**	`Dataset: Adult. Domain: census-derived demographic, education, and employment records. Each record describes one adult represented by demographic, education, work, and financial attributes. Target: annual income class. Predict whether the individual's annual income is above 50K or at or below 50K. Class 0: annual income at or below 50K. Class 1: annual income above 50K. Feature names: age, employment sector, census sampling weight, education level, education number, marital status, occupation, household relationship, race, sex, capital gain, capital loss, weekly working hours, and country of origin. Explain why the model assigned this individual to the predicted human-readable income class, using the local XAI evidence while avoiding causal claims and unnecessary disclosure of the record's concrete values.`
Explainer	**System**	`SHAP represents each feature's local attribution to the model output for class 1. Positive SHAP attributions move the output toward class 1, and negative SHAP attributions move it toward class 0. Absolute magnitude represents relative importance within this record. Encoded coordinates belonging to one raw feature have been added, preserving SHAP's additive accounting. Describe these quantities as SHAP attributions, not as causal effects or global feature importance. Explain why the model assigned this individual to the supplied human-readable outcome. Use X, S, y, and the supplied SHAP semantics internally, while preventing disclosure of concrete record values or local attribution values. Do not output or semantically disclose an exact numerical input value, categorical input value, local attribution value, attribution sign, prediction probability, record ID, or numeric class ID. Preserve qualitative within-record importance without printing ranks, coefficients, attribution magnitudes, or attribution signs. Write three to five connected sentences as one plain paragraph.`
	User	`{"X":{...},"S":{...},"y":"..."}`
Rewriter	**System**	`The draft is based on a SHAP explanation of class 1. Preserve the direction and qualitative within-record importance of its SHAP attributions while removing private concrete values. Do not reinterpret them as causal effects, interactions, or global feature importance. Verify current_explanation against authoritative X, S, y, and the supplied SHAP semantics. It is acceptable only when it is faithful, internally consistent, natural, privacy-preserving, and method-correct. Treat any exact numerical input value, categorical input value, local attribution value, attribution sign, prediction probability, record ID, or numeric class ID as a privacy issue. Reject invented features or facts, direction reversals, prediction reversals, incorrect primary-factor claims, unsupported causality or interactions, global claims, stereotypes, and moral justification. If it already satisfies every rule, set acceptable=true and copy it unchanged into revised_text. Otherwise set acceptable=false and return a complete corrected paragraph in revised_text. The revision must resolve every known problem; do not return the same unacceptable paragraph unchanged. Do not expose chain-of-thought, hidden reasoning, critiques, problem lists, or any fields other than acceptable and revised_text.`
	User	`{"X":{...},"S":{...},"y":"...","current_explanation":"..."}`

は入力と同じ 119 次元ベクトルとし，損失関数には二値交差エントロピーを用いた．AdamW の学習率を 10^{-3}，バッチサイズを 32，最大エポック数を 200，early stopping を 20 エポックに固定した．補助データセットの件数を 100, 200, 400, 800, 1,600 件と変え，同じテストデータセット 1,000 件を評価した．

4.2 結果 1：レコード再構築リスク

図 2 と**図 3** に，補助データセットの件数に対する MAE と SR を示す．図中の raw vector，Paraschou et al.，T_0，T_N，random guess は，それぞれ生の SHAP 値ベクトル，Paraschou ら準拠方式への攻撃，提案手法の初回説明 T_0，提案手法の最終説明 T_N，ランダム予測ベースラインを表す．提案手法 T_N は全条件で SHAP より MAE が高く，SR が低かった．SR の差は 0.1401 から 0.2469，MAE の差は 0.0450 から 0.0675 である．補助データセット 1,600 件では，SHAP の SR 0.8433 に対して提案手法 T_N は 0.5967 であり，差は 0.2466，相対低減率は 29.24%であった．

Paraschou ら準拠方式は全条件で提案手法より高い SR と低い MAE を示した．提案手法 T_N の SR は全条件で T_0 より低く，差は最大 0.0186，補助データセット 1,600 件では 0.0129 低かった．MAE は全条件で T_N の方が高かった．

4.3 結果 2：Rewriter による検証・修正

テストデータセット 1,000 件について，Rewriter が上限の反復回数 10 回までに受理した説明は 979 件（97.90%）であり，上限到達後も受理されなかった説明は 13 件（1.30%）あった．残りの 8 件（0.80%）では LLM が応答に失敗した．また，545 件（54.50%）のレコードは初回説明 T_0 が受理された．**図 4** に，Rewriter の反復回数に対する累積受

© 2026 Information Processing Society of Japan

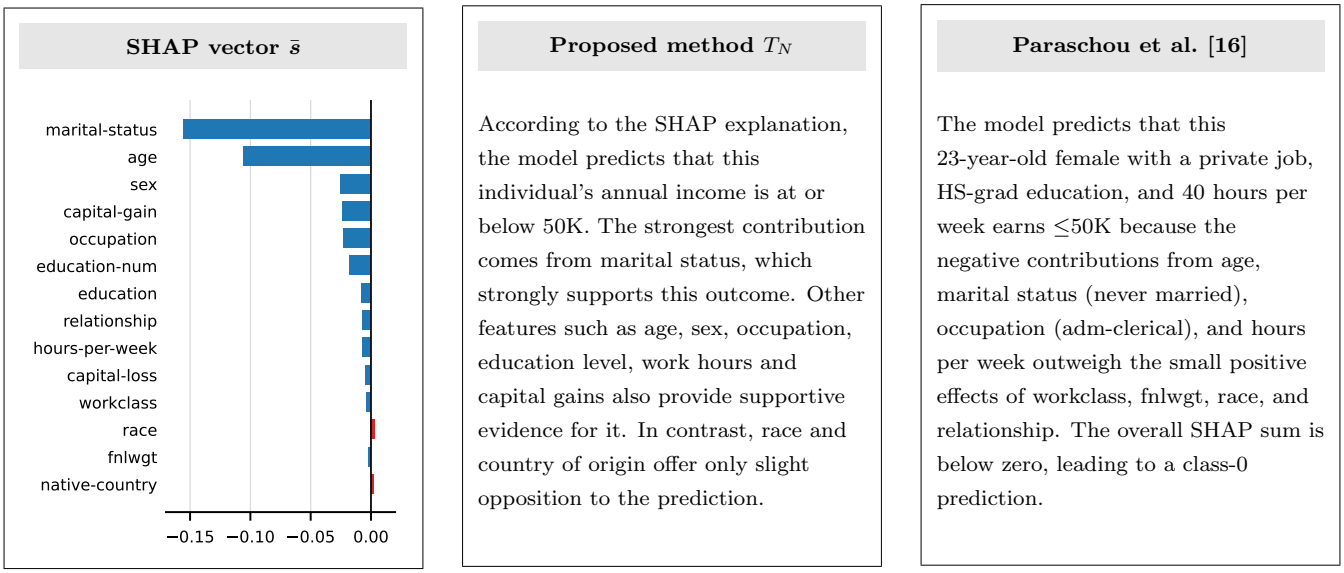


図 1 同一レコードに対する集約 SHAP 値ベクトルと自然言語説明の比較

Fig. 1 Aggregated SHAP vector and natural-language explanations for the same record.

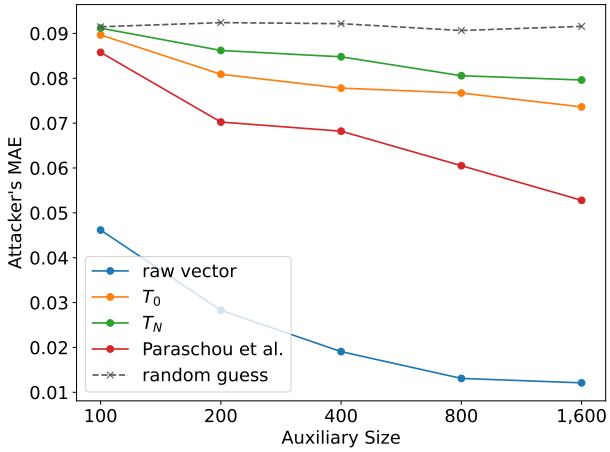


図 2 補助データセットの件数に対する攻撃者の MAE

Fig. 2 Attacker's MAE w.r.t. auxiliary dataset size.

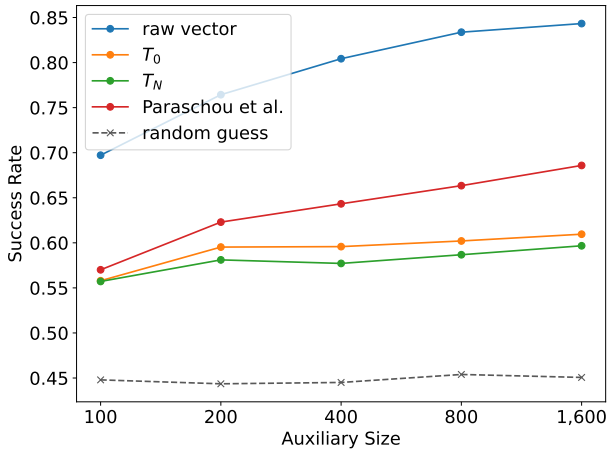


図 3 補助データセットの件数に対する攻撃成功率 SR

Fig. 3 Success rate w.r.t. auxiliary dataset size.

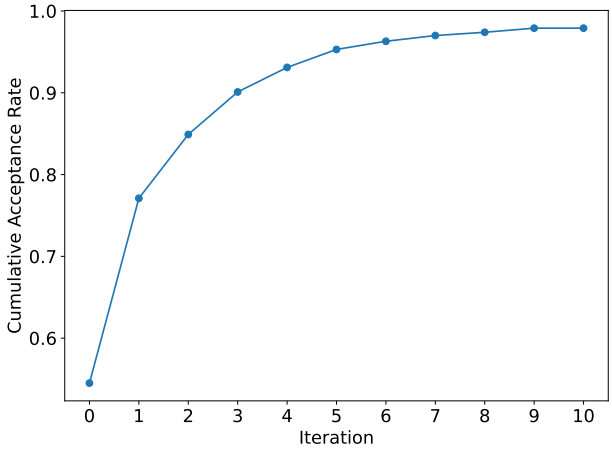


図 4 テストデータセット 1,000 件における Rewriter の反復回数に対する累積受理率

Fig. 4 Cumulative Rewriter acceptance rate over iterations for 1,000 test records.

理率を示す．

さらに，3 方式の説明がすべて得られたテストデータセット 997 件から無作為抽出した 100 件について，方式名を伏せ，表示順を無作為化して入力値の漏洩が含まれるかを手作業で判定した．実際の入力数値またはカテゴリ値が明示されるか，一意に特定できる場合を漏洩ありとし，元の値を特定できない定性的な範囲表現は漏洩に含めなかった．Paraschou ら準拠方式の漏洩率 86%に対して，提案手法 T_0 は 26%，T_N は 11%であり，具体値を出力しない制約と Rewriter によって漏洩が減少した．また，T_0 と T_N の判定のクロス集計を**表 3** に示す．T_0 で漏洩していた 26 件のうち 16 件は T_N で漏洩なしとなり，Rewriter によって Explainer が生成した時点では入力値が漏洩していた説明を修正できた．一方で，残りの 10 件には入力値漏洩が残

© 2026 Information Processing Society of Japan

表 3 手動評価 100 件における入力値漏洩のクロス集計表
Table 3 Cross-tabulation table of input-value leakage in 100 manually evaluated records.

		修正後 T_N	
		漏洩なし	漏洩あり
修正前 T_0	漏洩なし	73	1
	漏洩あり	16	10

表 4 100 件に対する生成時間
Table 4 Generation time for all 100 trials, including retained failures.

方式	成功/失敗	平均 [s]	中央値 [s]	平均呼び出し回数
Paraschou ら [16]	100/0	4.195	3.990	1.00
Mermigkis ら [17]	100/0	4.682	4.646	2.02
提案手法	99/1	8.556	6.578	2.69

り，T_0 で漏洩なしだった 74 件のうち 1 件は T_N で漏洩ありとなった．

4.4 結果 3：生成時間

テストデータセットから抽出した 100 件について生成時間を集計した．提案手法と Mermigkis らの方式は，5 件のウォームアップ後，レコードごとに実行順序を無作為化して計測した．Paraschou ら準拠方式は，同じ 100 件を同じ LLM と推論設定で生成した実行記録から集計した．いずれもモデル読込みを除く前処理と全 LLM 呼び出しの実時間を含む．

表 4 に，失敗を含む全 100 試行の生成時間を示す．提案手法の 1 件の保持失敗は Rewriter の応答失敗によるものだった．提案手法は Mermigkis らに対して平均で 1.83 倍，中央値で 1.42 倍の時間を要した．平均 LLM 呼び出し回数は Paraschou らが 1.00 回，Mermigkis らが 2.02 回，提案手法が 2.69 回であった．

5. 考察

5.1 提案手法のリスク低減効果と生成時間

提案手法は SHAP および Paraschou ら準拠方式のいずれに対してもより低い SR を示した．提案手法と Paraschou ら準拠方式はいずれも自然言語説明であり，両者の差にはプロンプトによるプライバシー制約が寄与したと考えられる．また，Paraschou ら準拠方式でも生の SHAP 値ベクトルと比べて攻撃成功率が低かったことから，自然言語説明の変換によって詳細な情報が失われ，結果として再構築リスクが低減されると考えられる．

初回の説明 T_0 と最終説明 T_N の SR 差は最大でも 0.0186 であり，54.80%の文章は変化しなかった．100 件の手動評価では，初回説明でプライバシー漏洩のあった説明 26 件のうち 16 件が Rewriter によって正しく修正された一方で，残りの 10 件では依然としてプライバシー漏洩が残った．これらは，プライバシーだけでなく忠実性や一貫性も含めて Rewriter にまとめて検証・修正させようとしたことが原因であると考えられる．

また，提案手法の平均 LLM 呼び出し回数は 2.69 回であり，Mermigkis らの 2.02 回より多かった．その結果，平均生成時間は Mermigkis らの 1.83 倍となった．

5.2 本研究の制約

本研究には次の制約がある．まず，本実験の対象は Adult と SHAP であり，他のデータセットや XAI 手法を用いた大規模な検証を行っていない．また，複数の乱数シードを用いた検証も行っておらず，実験を拡張する余地が残る．つぎに，SHAP は 119 次元ベクトル，文章条件は 1,024 次元埋め込みであり，第一層の入力次元とパラメータ数が異なる．表現形式や次元の大きさが結果に影響を与えると考えられるが，未だに評価されていない．加えて，攻撃モデル入力は公開モデル説明だけであり，予測ラベル，予測確率および事前分布を併用した攻撃の評価が残る．また，本実験では自然言語説明の正確性や有用性を評価しておらず，入力値漏洩の手動評価も 100 件に限られる．これらはユーザー実験などを通して評価する必要がある．これらの制約は今後の課題とする．

6. おわりに

本研究では，モデル説明に含まれる具体的な入力値と説明値を抽象化し，LLM で自然言語説明の検証と修正を反復するモデル説明方式を提案した．Adult データセットと SHAP による実験において，提案手法による自然言語説明は，SHAP による説明ベクトルおよび具体値を高頻度で含む既存方式に準拠した自然言語説明よりも低い攻撃成功率を示した．また，Rewriter による反復的な修正によってさらにリスクを低減できることを示した一方で，従来手法よりも生成時間が増加した．

参考文献

[1] Chen, X.-Q., Ma, C.-Q., Ren, Y.-S., Lei, Y.-T., Huynh, N. and Narayan, S.: Explainable Artificial Intelligence in Finance: A Bibliometric Review, *Finance Research Letters*, Vol. 56 (2023).

[2] Sakai, A., Komatsu, M., Komatsu, R., Matsuoka, R., Yasutomi, S., Dozen, A., Shozu, K., Arakaki, T., Machino, H., Asada, K., Kaneko, S., Sekizawa, A. and Hamamoto, R.: Medical Professional Enhancement Using Explainable Artificial Intelligence in Fetal Cardiac Ultrasound Screening, *Biomedicines*, Vol. 10, No. 3, pp. 1–21 (2022).

[3] Khrais, L. T.: Role of Artificial Intelligence in Shaping Consumer Demand in E-Commerce, *Future Internet*, Vol. 12, No. 12, pp. 1–14 (2020).

[4] Rudin, C.: Stop Explaining Black Box Machine Learning Models for High Stakes Decisions and Use Interpretable Models Instead, *Nature Machine Intelligence*, Vol. 1, No. 5, pp. 206–215 (2019).

[5] Chen, J., Song, L., Wainwright, M. J. and Jordan, M. I.:

© 2026 Information Processing Society of Japan

Learning to Explain: An Information-Theoretic Perspective on Model Interpretation, *Proceedings of the 35th International Conference on Machine Learning*, Proceedings of Machine Learning Research, Vol. 80, PMLR, pp. 883–892 (2018).

[6] Shapley, L. S.: A Value for n-Person Games, *Contributions to the Theory of Games, Vol. 2*, Princeton University Press, pp. 307–318 (1953).

[7] Lundberg, S. M. and Lee, S.-I.: A Unified Approach to Interpreting Model Predictions, *Advances in Neural Information Processing Systems 30*, pp. 4768–4777 (2017).

[8] Štrumbelj, E. and Kononenko, I.: Explaining Prediction Models and Individual Predictions with Feature Contributions, *Knowledge and Information Systems*, Vol. 41, No. 3, pp. 647–665 (2014).

[9] Amazon Web Services: Amazon SageMaker Documentation: Model Explainability, `https://docs.aws.amazon.com/sagemaker/latest/dg/clarify-model-explainability.html` (2024). Accessed April 19, 2024.

[10] Google Cloud: Introduction to Vertex Explainable AI, `https://cloud.google.com/vertex-ai/docs/explainable-ai/overview` (2024). Accessed April 19, 2024.

[11] Microsoft Azure: Azure Machine Learning Documentation: Model Explainability, `https://learn.microsoft.com/en-us/azure/machine-learning/how-to-machine-learning-interpretability` (2024). Accessed April 19, 2024.

[12] Luo, X., Jiang, Y. and Xiao, X.: Feature Inference Attack on Shapley Values, *Proceedings of the 2022 ACM SIGSAC Conference on Computer and Communications Security*, pp. 2233–2247 (2022).

[13] Ribeiro, M. T., Singh, S. and Guestrin, C.: "Why Should I Trust You?": Explaining the Predictions of Any Classifier, *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 1135–1144 (2016).

[14] Ribeiro, M. T., Singh, S. and Guestrin, C.: Anchors: High-Precision Model-Agnostic Explanations, *Proceedings of the 32nd AAAI Conference on Artificial Intelligence*, AAAI Press (2018).

[15] Shrikumar, A., Greenside, P. and Kundaje, A.: Learning Important Features through Propagating Activation Differences, *Proceedings of the 34th International Conference on Machine Learning*, Proceedings of Machine Learning Research, Vol. 70, PMLR, pp. 3145–3153 (2017).

[16] Paraschou, E., Arapakis, I., Yfantidou, S., Macaluso, S. and Vakali, A.: Mind the XAI Gap: A Human-Centered LLM Framework for Democratizing Explainable AI, *Explainable Artificial Intelligence: Third World Conference, xAI 2025, Proceedings, Part V*, Communications in Computer and Information Science, Vol. 2580, Springer, pp. 113–137 (2026).

[17] Mermigkis, G., Metaxakis, D., Tyrovolas, M., Sofotasios, A., Avgeris, N., Hadjidoukas, P. and Stylios, C.: A Two-Stage LLM Framework for Accessible and Verified XAI Explanations, *2026 IEEE World Congress on Computational Intelligence* (2026). (to be published).

[18] Becker, B. and Kohavi, R.: Adult, UCI Machine Learning Repository (1996).

[19] Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D. and Batra, D.: Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization, *2017 IEEE International Conference on Computer Vision*, pp. 618–626 (2017).

[20] Liu, H., Wu, Y., Yu, Z. and Zhang, N.: Please Tell Me More: Privacy Impact of Explainability through the Lens of Membership Inference Attack, *2024 IEEE Symposium on Security and Privacy*, pp. 4791–4809 (2024).

[21] Kuppa, A. and Le-Khac, N.-A.: Adversarial XAI Methods in Cybersecurity, *IEEE Transactions on Information Forensics and Security*, Vol. 16, pp. 4924–4938 (2021).

[22] Shokri, R., Strobel, M. and Zick, Y.: On the Privacy Risks of Model Explanations, *Proceedings of the 2021 AAAI/ACM Conference on AI, Ethics, and Society*, pp. 231–241 (2021).

[23] Yan, A., Huang, T., Ke, L., Liu, X., Chen, Q. and Dong, C.: Explanation Leaks: Explanation-Guided Model Extraction Attacks, *Information Sciences*, Vol. 632, pp. 269–284 (2023).

[24] Yan, A., Hou, R., Liu, X., Yan, H., Huang, T. and Wang, X.: Towards Explainable Model Extraction Attacks, *International Journal of Intelligent Systems*, Vol. 37, No. 11, pp. 9936–9956 (2022).

[25] Olatunji, I. E., Rathee, M., Funke, T. and Khosla, M.: Private Graph Extraction via Feature Explanations, *Proceedings on Privacy Enhancing Technologies*, Vol. 2023, No. 2, pp. 59–78 (2023).

[26] Fredrikson, M., Jha, S. and Ristenpart, T.: Model Inversion Attacks that Exploit Confidence Information and Basic Countermeasures, *Proceedings of the 22nd ACM SIGSAC Conference on Computer and Communications Security*, pp. 1322–1333 (2015).

[27] 當麻僚太郎，菊池浩明：AI モデルの説明可能性に対するレコード再構築リスク，情報処理学会論文誌，Vol. 66, No. 9, pp. 1310–1322 (2025).

[28] Datta, A., Sen, S. and Zick, Y.: Algorithmic Transparency via Quantitative Input Influence: Theory and Experiments with Learning Systems, *2016 IEEE Symposium on Security and Privacy (SP)*, pp. 598–617 (2016).

[29] Dwork, C.: Differential Privacy, *Automata, Languages and Programming*, Lecture Notes in Computer Science, Vol. 4052, Springer, pp. 1–12 (2006).

[30] Patel, N., Shokri, R. and Zick, Y.: Model Explanations with Differential Privacy, *Proceedings of the 2022 ACM Conference on Fairness, Accountability, and Transparency*, pp. 1895–1904 (2022).

[31] Vanbrabant, S., Eerlings, G., Rovelo Ruiz, G. and Vanacken, D.: ECHO: Enhancing Conversational Explainable AI through Tool-Augmented Language Models, *Proceedings of the ACM on Human-Computer Interaction*, Vol. 9, No. 4, pp. 1–33 (2025).

[32] Bello, M., Bello, R., García, M.-M., Nowé, A., Sevillano-García, I. and Herrera, F.: A Three-level Framework for LLM-enhanced Explainable AI: From Technical Explanations to Natural Language, Information Systems Frontiers (2025).

[33] Agarwal, S. et al.: gpt-oss-120b & gpt-oss-20b Model Card, arXiv:2508.10925 (2025).

[34] Chen, J., Xiao, S., Zhang, P., Luo, K., Lian, D. and Liu, Z.: M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation, *Findings of the Association for Computational Linguistics: ACL 2024*, Association for Computational Linguistics, pp. 2318–2335 (2024).

© 2026 Information Processing Society of Japan