PaDiMを用いたNIDSにおける ドメインシフトに対する汎化性能の検証

劉　耀楚[1,a)]　青木　茂樹[1]　宮本　貴朗[1]

概要：近年，機械学習を用いたネットワーク侵入検知システム（NIDS）において，未知攻撃を検知可能な異常検知技術が注目されている．特に，事前学習済み CNN 等を用いた画像異常検知手法を応用するアプローチに関心が集まっている．しかし，これらの手法が学習時とは異なるネットワーク環境（ドメインシフト）に直面した際，どの程度汎化性能を維持できるかは十分に検証されていない．そこで本研究では，トラフィックからフロー単位で抽出した特徴量を NCTD により画像形式へ変換し，過剰適合抑制と計算量削減を目的とした GAP（Global Average Pooling）を導入した PaDiM で異常検知を行う NIDS を構築して，ドメインシフトに対する汎化性能を実証的に検証する．具体的には，CICIDS2017 の正常通信を用いて学習したモデルに対し，同一のトラフィック生成手法により構築されたデータセット（CICIDS2018, CIC-DDoS2019）と，完全に異なるトラフィック生成手法で作成されたデータセット（TII-SSRC-23）を適用して比較・評価を行う．本研究では，ネットワーク環境の差異がモデルの検知性能に与える影響を分析し，実運用に向けた課題について検討する．

キーワード：侵入検知システム（NIDS），異常検知，PaDiM，ドメインシフト，汎化性能

Evaluating the Generalization Performance of PaDiM-based NIDS Against Domain Shift

Yoso Ryu[1,a)]　Shigeki Aoki[1]　Takao Miyamoto[1]

Abstract: In recent years, machine learning-based Network Intrusion Detection Systems (NIDS) capable of detecting unknown attacks have attracted significant attention. In particular, approaches applying image anomaly detection methods using pre-trained CNNs have received increasing interest. However, the extent to which these methods maintain generalization performance when facing network environment changes (domain shifts) remains insufficiently explored. Therefore, in this study, we construct an NIDS that converts flow-based traffic features into image format using NCTD and performs anomaly detection with PaDiM incorporated with Global Average Pooling (GAP) to suppress overfitting and reduce computational cost, empirically evaluating its generalization performance against domain shifts. Specifically, a model trained on normal traffic from CICIDS2017 is evaluated and compared on datasets constructed using the same traffic generation methodology (CICIDS2018 and CIC-DDoS2019) as well as a dataset created with a completely different traffic generation framework (TII-SSRC-23). In this study, we analyze the impact of network environment differences on model detection performance and discuss challenges toward practical deployment.

Keywords: Network Intrusion Detection System (NIDS), Anomaly Detection, PaDiM, Domain Shift, Generalization Performance

1. はじめに

近年，インターネットの普及に伴ってサイバー攻撃の被害が拡大しており，対策のために侵入検知システム（IDS）

[1] 大阪公立大学情報学研究科
Graduate School of Informatics, Osaka Metropolitan University
[a)] sp25560b@st.omu.ac.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

の重要性が高まっている．IDS はネットワークを監視し，様々な異常を検知するシステムであり，特に正常な通信パターンを基準として登録し，観測対象の通信が基準から逸脱している場合を異常として検知するアノマリ型 IDS に関する研究が盛んに行われている．アノマリ型 IDS は未知の攻撃を検知できる可能性を持つ反面，正常通信のゆらぎを過剰に検知しやすく，誤検知が多いことが課題となっていた．

文献 [1] では，2 つの教師なし異常検知手法と 2 つの教師あり学習手法を用いて攻撃の検知性能を比較している．その結果，未知の攻撃に対しては教師なし異常検知手法が有効である一方，既知の攻撃も含めた全体評価では教師あり学習手法の性能が上回ることが示されている．これは，従来の教師なし異常検知手法では複雑な正常通信のバリエーションを正確にモデル化できず，誤検知や検知漏れが生じやすいためである．そこで，正常通信の複雑な特徴パターンを高度に捉えて検知精度を改善するため，深層学習技術を応用する研究が盛んに行われている．文献 [2] では，パケットのペイロードに対して BERT（Bidirectional Encoder Representations for Transformers）を適用して特徴を抽出し，VAE（Variational Autoencoder）により異常を検知する手法を提案している．文献 [3] では，単位時間ごとに分割したトラフィックデータのパケットヘッダから抽出した特徴量を，LSTM（Long Short Term Memory）で学習し，異常を検知する手法を提案している．文献 [4] では，パケットヘッダをグレースケール画像に変換し，VAE で学習することにより異常を検知している．

しかし，これら従来のアノマリ型 IDS では，学習時と異なる未知のネットワーク環境（ドメインシフト）に直面した際に，検知性能が著しく低下する事例が報告されている．文献 [5] では，4 種の教師なし異常検知手法を用いたアノマリ型 IDS の汎化性能を評価しており，単一のデータセットでは高精度を示すモデルであっても，同一の分布および生成プロセスに基づいて作成された未学習の別データセットに適用した場合には，性能が大きく低下することを明らかにしている．この課題に対して文献 [6] では，汎化性能向上のために対照学習技術を取り入れた IDS を提案しているが，計算量やメモリ消費量が大きいという課題がある．

一方，画像処理分野では，大規模物体認識データを用いて事前学習された画像認識モデルを利用した研究が盛んに行われている．異常検知においても，事前学習モデルを用いる手法が多数研究されており，代表的な手法として PaDiM（Patch Distribution Modeling）[7] が提案されている．文献 [8] では，PaDiM をトラフィックのパケットデータに適用し，異常通信を検知する手法が提案されている．PaDiM は事前学習済みのパラメータを固定して利用する性質上，過剰適合を起こしにくいという利点を持つが，異なるデータセット間（ドメインシフト下）での汎化性能については十分に検証されていない．

そこで本研究では，PaDiM が未知のネットワーク環境に対しても高い汎化性能を発揮するという仮説のもと，文献 [8] で提案された手法に変更を加えたうえで，異なるデータセット間での汎化性能を実証的に検証する．具体的には，入力データ形式をパケットヘッダのバイナリ変換から Novel Algorithm for Convolving Tabular Data（NCTD）[9] を用いて画像化したフロー特徴量へ変更し，また過剰適合抑制と計算量削減を目的とした Global Average Pooling（GAP）を PaDiM に導入する．まず，抽出されたフロー特徴量（CSV ファイル）を NCTD により画像化し，正常通信の画像群を PaDiM に入力して特徴分布を求める．その後テストデータを入力し，正常データの特徴分布から逸脱したデータを異常，すなわちサイバー攻撃として検知する．実験では，CICIDS2017 [10]，CICIDS2018 [11]，CIC-DDoS2019 [12]，TII-SSRC-23 [13] の 4 種のデータセットを用いて，本手法の未知データに対する汎化性能を確認した．

以下，2 節で関連研究について述べ，3 節で提案手法を説明する．4 節では実験とその結果に対する考察を述べ，5 節でまとめる．

2. 関連研究

本研究に関連する従来研究として，深層学習技術を用いたアノマリ型 IDS に関する文献 [3,4] と，アノマリ型 IDS の汎化性能に関する文献 [5,6]，および事前学習済み画像認識モデルを応用した手法に関する文献 [8] について述べる．

文献 [3] は，トラフィックデータを単位時間ごとに分割し，分割区間内のパケットヘッダから IP アドレス，ポート番号，TCP フラグ等に関する 55 次元の特徴量を抽出した上で，LSTM を用いて異常を検知する手法を提案している．本手法では，正常データのみで学習した LSTM に対してテストデータを入力した際の予測誤差（入力ベクトルと予測ベクトルの差分）を異常度として定義し，異常度が大きいデータを異常と判定する．パケットヘッダのみから特徴量を抽出することで，暗号化通信への適用性や高い処理効率を実現しているが，異常検知精度には改善の余地が残されている．

文献 [4] は，トラフィックデータに含まれるパケットヘッダを画像に変換し，VAE により異常を検知する手法を提案している．本手法では，通信パケットを送信元および宛先 IP アドレスの組み合わせごとに分類し，64 パケットごとにヘッダ部分をグレースケール値に変換することで 64×64 画素の画像を生成する．この画像群を用いて VAE に正常パターンを学習させ，入力テストデータの再構成誤差を異常度として異常を検知する．本手法は複数種の攻撃に対して高い検知性能を実現しているが，モデルの学習に大量の画像を必要とし，学習コストが大きいという課題がある．

© 2026 Information Processing Society of Japan

文献 [5] は，Autoencoder，One-Class SVM，Isolation Forest，主成分分析の 4 つの代表的な教師なし異常検知手法を用い，CICIDS2017 および CICIDS2018 データセット相互間における汎化性能を評価している．実験の結果，単一データセット内では各モデルとも優れた精度を示すものの，学習元と異なるデータセットを適用したテストでは，分類精度（Accuracy）が平均で 25.63%，ROC-AUC が平均で 30.45%低下することを明らかにしている．

文献 [6] は，異なるデータセット間での汎化性能向上のため，自己教師あり対照学習を取り入れた SSCL-IDS を提案している．本手法は，対照学習により正常フローの頑健な特徴表現を学習することで，未知の複雑な攻撃に対しても高度な一般化能力を獲得できる．実験では 5 種のデータセットを用いて高い汎化性能を示したものの，対照学習の特性上，計算量やメモリ消費量が大きいという課題がある．

文献 [8] は，文献 [4] と同様の手法で画像化したパケットデータを，事前学習モデルを利用した異常検知手法である PaDiM に入力し，異常パケットを検知する手法を提案している．本手法では既存の教師なし異常検知手法と同等の検知精度が得られたものの，未知のデータセットに対する汎化性能については検証されていない．

3. 提案手法

本稿では，NCTD と PaDiM を IDS に応用した異常検知手法を提案し，ドメインシフトに対する汎化性能を検証する．図 1 に提案手法の概要を示す．

本手法の処理手順は学習フェーズとテストフェーズで構成される．まず前処理として，トラフィックデータからフロー単位で抽出された特徴量（CSV ファイル）を，NCTD を用いて画像形式へ変換する．学習フェーズでは，正常通信の画像群を事前学習済み CNN に入力し，中間層から抽出された特徴マップに対して Global Average Pooling（GAP）を適用することで，単一の C 次元特徴ベクトルへ集約する．この特徴ベクトルの平均ベクトルおよび共分散行列を算出することで，正常通信の特徴分布（多変量正規分布）をモデル化する．テストフェーズでは，テスト対象の通信画像を同様に処理して特徴ベクトルを得た後，正常分布とのマハラノビス距離を算出する．算出した距離（異常スコア）が設定した閾値を超えた場合に，該当フローを異常（サイバー攻撃）として検知する．

3.1 NCTD を用いた画像変換

本研究では，表形式データを画像形式へ変換する手法である NCTD を用いて，トラフィックフロー特徴量の画像変換を行う．

処理は表データの各サンプル（各行）に対して行われる．特徴量次元を N とした場合，まず特徴量配列を N 行分複製し，1 行ごとに 1 要素ずつ左シフトを行いながら縦に連結する．次にこの処理で生成された $N \times N$ の行列を複製して上下左右の 4 象限に並べることで，最終的に $2N \times 2N$ の行列へと変換する．特徴量のシフト，複製および連結を繰り返すことで，元データにおいて近接していなかった特徴量同士の相関パターンが増加し，CNN の畳み込みフィルタによる特徴抽出能力を最大限に活用することが可能となる．

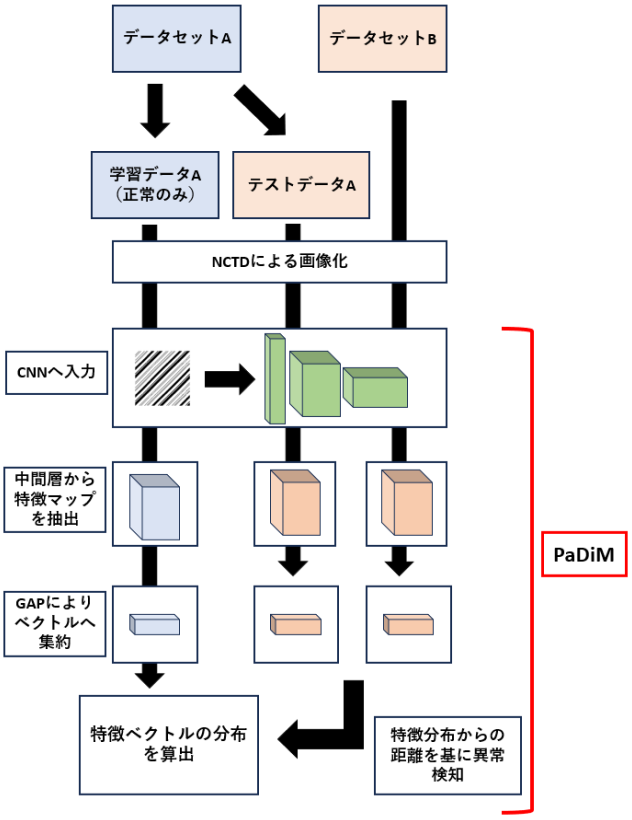


図 1 提案手法の概要
Fig. 1 Overview of the Proposed Method.

3.2 PaDiM による正常データの学習と異常検知

PaDiM は事前学習済み CNN の中間層の特徴マップを利用した教師なし異常検知手法である．通常の PaDiM では，事前学習済み CNN の複数の中間層から得られた特徴マップを連結し，画像内の各位置（パッチ）ごとに特徴ベクトルの多変量正規分布をモデル化する．テスト時にはパッチごとにマハラノビス距離を計算し，その最大値を画像全体の異常度として判定する．しかし，この位置依存の処理は特定のピクセル位置へ過剰適合しやすく，環境変化に弱いという問題がある．

そこで本手法では，過剰適合の抑制および計算量の削減を目的として，特徴抽出部に GAP を導入する．具体的には，中間層から抽出・連結された特徴マップ（チャネル数 C）に対して GAP を施し，各チャネルの空間領域を平均化することで，画像（1 フロー）全体を表現する C 次元の特徴ベクトル $\boldsymbol{x} \in \mathbf{R}^C$ へ集約する．学習時には，正常画

© 2026 Information Processing Society of Japan

像群から得られたこの C 次元特徴ベクトルから全体の平均ベクトル $\boldsymbol{\mu} \in \mathbf{R}^C$ および共分散行列 $\boldsymbol{\Sigma} \in \mathbf{R}^{C \times C}$ を算出し，正常通信の分布を学習する．

テスト時には，テスト画像の特徴ベクトル $\boldsymbol{x}$ と正常分布 $(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ とのマハラノビス距離 $d(\boldsymbol{x})$ を次式により算出する．

$$d(\boldsymbol{x}) = \sqrt{(\boldsymbol{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\boldsymbol{x} - \boldsymbol{\mu})} \qquad (1)$$

このマハラノビス距離をフローの異常スコアとして利用し，異常判定を行う．事前学習済み CNN のパラメータを固定して利用する特性に加え，GAP による空間情報の平滑化を行うことで，特定の局所パターンへの過剰適合を防ぎ，高い汎化性能が期待される．

4. 実験

本手法の有効性を確認するために，実験を行った．

4.1 実験条件

4.1.1 実験データセット

本実験では，学習データとして CICIDS2017 [10] を用い，テストデータとして CICIDS2017，CICIDS2018 [11]，CIC-DDoS2019 [12]，および TII-SSRC-23 [13] を使用した．これらは正常通信および各種攻撃通信を含む侵入検知精度評価用のトラフィックデータセットである．CICIDS2017，CICIDS2018，および CIC-DDoS2019 は共通のツールを用いて正常通信を生成しているため，通信プロファイルが類似していると考えられる．一方で，TII-SSRC-23 は異なる環境・ツールを用いて構築されており，音声・テキスト・映像のストリーミングといった独自の背景トラフィックが含まれる．

参考として，各データセットの正常通信に対して UMAP を適用し，2 次元空間へ圧縮して可視化した結果を図 2 に示す．これより，同一の通信生成手法に基づく 3 種のデータセット（CICIDS2017，CICIDS2018，および CIC-DDoS2019）は特徴空間上で互いに重なり合って分布するのに対し，TII-SSRC-23 はそれらから独立したクラスタを形成している割合が高いことが確認できる．

各データセットは CICFlowMeter [14] によって 5 タプル情報に基づきフロー単位で抽出された 80 次元の統計特徴量（CSV ファイル）として配布されている．CICIDS2017 については，学習データとしてランダムサンプリングした 50,000 件の正常データを使用し，テストデータにはランダムサンプリングした 200,000 件の正常データと全攻撃データを使用した．CICIDS2018 についてはランダムサンプリングした 500,000 件の正常データと全攻撃データを，TII-SSRC-23 については 1,289 件の全正常データと 5,000 件のランダムサンプリングした攻撃データをテストデータとして使用した．また，CIC-DDoS2019 については公式に分割されているテストデータ内の全正常データおよび全攻撃データを使用した．各データセットに含まれる攻撃種別の内訳を表 1 に示す．

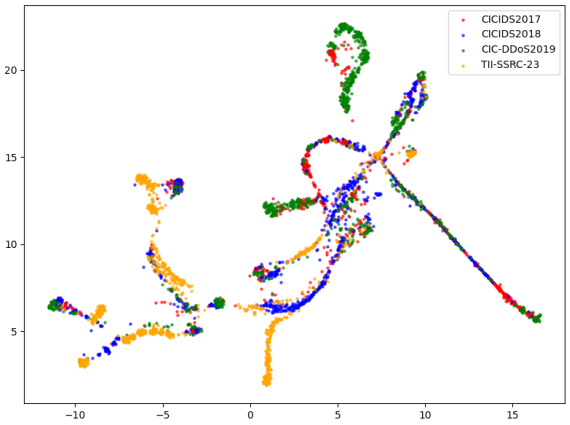


図 2 各データセットの可視化図
Fig. 2 Visualizations of Each Dataset.

表 1 各データセットに含まれる攻撃
Table 1 List of Attacks Included in Each Dataset.

Dataset	List of attacks
CICIDS2017	FTP-Patator, SSH-Patator, DoS slowloris, DoS Slowhttptest, DoS Hulk, DoS GoldenEye, Heartbleed, Brute Force, XSS, Sql Injection, Infiltration, Botnet, DDoS LOIT
CICIDS2018	FTP-Patator, SSH-Patator, DoS Hulk, DoS GoldenEye, DoS Slowloris, DoS SlowHTTPTest, DDoS LOIC-HTTP, DDoS LOIC-UDP, DDoS HOIC, Brute Force, SQL Injection, Bot, Infiltration
CIC-DDoS2019(test)	DDoS PortMap, DDoS NetBIOS, DDoS LDAP, DDoS MSSQL, DDoS UDP, DDoS UDP-Lag, DDoS SYN
TII-SSRC-23	Brute Force DNS, Brute Force FTP, Brute Force HTTP, Brute Force SSH, Brute Force Telnet, DoS ACK, DoS CWR, DoS ECN, DoS FIN, DoS HTTP, DoS ICMP, DoS MAC, DoS PSH, DoS RST, DoS SYN, DoS UDP, DoS URG, Info Gathering, Mirai Botnet

4.1.2 データセットの前処理

各データセットに対して以下の前処理を行う．なお，不要特徴量の特定および正規化パラメータの算出は，すべて学習データ（CICIDS2017）の統計量のみに基づいて決定し，すべてのテストデータへ一律に適用した．

- **不要特徴量（列）の削除**: IP アドレス，ポート番号，タイムスタンプ等のデータセット固有の識別情報，および学習データにおいて分散が 0 であった特徴量を削

© 2026 Information Processing Society of Japan

表 2　使用した特徴量
Table 2　Features Used in the Experiment.

Protocol	Flow Duration	Total Fwd Packets
Total Backward Packets	Fwd Packets Length Total	Bwd Packets Length Total
Fwd Packet Length Max	Fwd Packet Length Min	Fwd Packet Length Mean
Fwd Packet Length Std	Bwd Packet Length Max	Bwd Packet Length Min
Bwd Packet Length Mean	Bwd Packet Length Std	Flow Bytes/s
Flow Packets/s	Flow IAT Mean	Flow IAT Std
Flow IAT Max	Flow IAT Min	Fwd IAT Total
Fwd IAT Mean	Fwd IAT Std	Fwd IAT Max
Fwd IAT Min	Bwd IAT Total	Bwd IAT Mean
Bwd IAT Std	Bwd IAT Max	Bwd IAT Min
Fwd PSH Flags	Fwd Header Length	Bwd Header Length
Fwd Packets/s	Bwd Packets/s	Packet Length Min
Packet Length Max	Packet Length Mean	Packet Length Std
Packet Length Variance	FIN Flag Count	SYN Flag Count
RST Flag Count	PSH Flag Count	ACK Flag Count
URG Flag Count	ECE Flag Count	Down/Up Ratio
Avg Packet Size	Avg Fwd Segment Size	Avg Bwd Segment Size
Subflow Fwd Packets	Subflow Fwd Bytes	Subflow Bwd Packets
Subflow Bwd Bytes	Init Fwd Win Bytes	Init Bwd Win Bytes
Fwd Act Data Packets	Fwd Seg Size Min	Active Mean
Active Std	Active Max	Active Min
Idle Mean	Idle Std	Idle Max
Idle Min		

除した．これにより最終的に表 2 に示す 67 次元の特徴量を実験に使用した．

- **不要行の削除**: 欠損値や無限値が含まれる行，および重複が見られる行を削除した．
- **正規化**: 分位点変換（Quantile Transformation）を用いて，各特徴量を 0 ～ 1 の一様分布へ正規化した．

4.1.3　PaDiM の設定

事前学習 CNN モデルには EfficientNetV2 [15] を用いた．EfficientNetV2 は，高い認識精度を維持しつつパラメータ数と計算コストを大幅に削減したモデルであり，PaDiM における特徴抽出の効率化が期待できる．入力層の受容野サイズ（224×224）に適合させるため，前処理後の 67 次元の特徴量から NCTD により生成された画像（134×134）を 224×224 へリサイズして用いた．リサイズに伴う補間処理により特徴量空間の局所的な平滑化が生じるが，事前学習フィルタの適用に必要な前処理として一律に実施した．特徴マップの抽出には EfficientNetV2 の第 2 層，第 4 層，第 5 層を用い，これらに GAP を施して得られた C 次元の特徴ベクトルを異常検知に用いた．また，GAP 導入による過剰適合抑制効果を評価するため，GAP 非導入の通常の PaDiM との比較実験も実施した．

4.1.4　比較手法

比較手法として, 文献 [5] に準拠し, One-Class SVM（OC-SVM），Autoencoder（AE），および主成分分析（PCA）を用いた．これらは事前学習モデルを利用せず，対象データセットの数値特徴量から一からパラメータを学習する手法である．ハイパーパラメータ等の設定は文献 [5] の条件に準拠した．

4.1.5　評価指標

モデルの検知性能の評価指標として ROC-AUC（Receiver Operating Characteristic - Area Under the Curve）を用いた．ROC-AUC は，識別閾値を変化させた際の真陽性率（True Positive Rate）と偽陽性率（False Positive Rate）をプロットした ROC 曲線の下側面積であり，閾値の選択に依存しないモデルの全体的な識別能力を表す．ROC-AUC は 0 ～ 1 の値を取り，1 に近いほど高い検知性能を示す．

表 3　各データセットでの実験結果
Table 3　Experimental Results for Each Dataset.

Dataset	PaDiM(+GAP)	OC-SVM	AE	PCA
CICIDS2017	0.916	0.974	0.953	0.938
CICIDS2018	0.717	0.636	0.635	0.646
CIC-DDoS2019	0.862	0.553	0.571	0.643
TII-SSRC-23	0.583	0.479	0.585	0.690

表 4　GAP の有無による PaDiM の検知性能の比較結果
Table 4　Comparison of Detection Performance of PaDiM With and Without GAP.

Dataset	PaDiM(+GAP)	PaDiM(default)
CICIDS2017	0.916	0.942
CICIDS2018	0.717	0.659

4.2　実験結果

各データセットでテストした際の ROC-AUC 値を表 3 に示す．同一のトラフィック生成手法に基づく CICIDS2018 および CIC-DDoS2019 においては，PaDiM の検知性能が比較手法を上回っていた．一方で，独立した環境で構築された TII-SSRC-23 では，PaDiM は OC-SVM に次いで検知性能が低く，また学習に用いた CICIDS2017 においても最も低い性能であった．

次に，PaDiM に GAP を導入した場合と導入しなかった場合の比較実験の結果を表 4 に示す．GAP の導入により，CICIDS2017 での検知性能はやや低下するものの，未知環境である CICIDS2018 での検知性能が向上した．このように学習データへの適合度が抑えられた結果として未知データでの精度向上が得られたことは，GAP による空間情報の平滑化が過剰適合の抑制と汎化性能の獲得に有効に作用したことを示している．

4.3　考察

4.3.1　同一ドメインにおける適合度と情報損失

CICIDS2017 でのテスト結果より，学習データと同一のデータセット内では，PaDiM の検知性能が一般的な教師なし学習手法と比較して低いことが確認された．この主な要因は，モデルのパラメータ更新の有無にあると考えられる．比較手法は対象の学習データに合わせてパラメータを直接最適化するため，同一分布のデータに対して高い適合度を示す．一方，PaDiM は事前学習済み CNN のパラメータ

© 2026 Information Processing Society of Japan

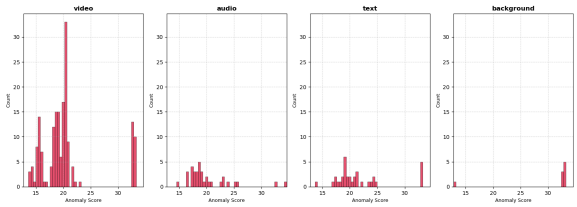


図 3 TII-SSRC-23 中の各種正常通信から算出した異常スコアのヒストグラム

Fig. 3 Histogram of Anomaly Scores Calculated from Various Normal Traffic in TII-SSRC-23.

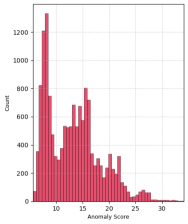


図 4 CIC-DDoS2019 中の正常通信から算出した異常スコアのヒストグラム

Fig. 4 Histogram of Anomaly Scores Calculated from Normal Traffic in CIC-DDoS2019.

表 5 各データセットにおける ‘Bwd IAT Total‘が 0 のデータ数

Table 5 The Number of Data Points where ‘Bwd IAT Total‘ is 0 in Each Dataset.

Dataset	該当データ数
CICIDS2017（学習データ全 50,000 件）	20,500
CICIDS2018 （テストデータ全 500,000 件）	204,215
CIC-DDoS2019 （テストデータ全 14,993 件）	2,822
TII-SSRC-23 （テストデータ全 1,289 件）	830

を固定して用いる性質上，特定の学習データの局所的な分布に対して十分に適合することができず，相対的に検知性能が低くなったと推測される．加えて，比較手法が元データの特徴量ベクトルを直接入力として扱うのに対し，提案手法はリサイズ処理や GAP による空間集約といった一連の変換プロセスを経るため，元の数値表現が持つ細かな局所情報が平滑化・損失したことも，同一ドメインでの適合度低下の一因として挙げられる．

4.3.2 類似ドメインにおける汎化性能

CICIDS2018 および CIC-DDoS2019 でのテスト結果より，学習データと通信プロファイルが類似したデータセットに対しては，PaDiM の汎化性能が比較手法を上回る結果が得られた．これら 2 つのデータセットは，学習データ（CICIDS2017）と共通のツールを用いて正常通信が生成されているため，環境が異なっていても正常通信の潜在的な特徴分布はある程度近似していると考えられる．そのうえで PaDiM が高い汎化性能を示した要因として，事前学習モデルおよび GAP による過剰適合抑制能力が挙げられる．比較手法はパラメータを一から学習する手法であるため，学習データ固有の微小な環境変動（セッション発生確率の差異等）に過剰適合しやすく，未知環境において誤検知が増加したことで性能が低下したと推測される．これに対し，提案手法は事前学習済み CNN のパラメータを固定して利用するため過剰適合を起こしにくく，通信の本質的な特徴表現を維持できる．さらに，通常の PaDiM は特定の位置情報へ過剰適合しやすい構造を持つが，GAP を導入してチャネル全体の空間統計量へ集約したことで位置依存の過剰適合が抑制され，優れた汎化性能がもたらされたと捉えられる．

4.3.3 異種ドメインにおける性能低下とその要因

独自の背景トラフィックを含む TII-SSRC-23 においては，PaDiM（ROC-AUC 0.583）のみならず OC-SVM や AE といった比較手法も ROC-AUC が 0.5 付近まで低下した．これは，これらの手法がいずれも学習データの正常通信が持つ特徴分布を基準として判定を行うため，音声や映像等の異なる通信プロファイルで構成される TII-SSRC-23 の正常通信パターン自体を未知の異常と判定し，誤検知が多発したことが要因である．

図 3 に TII-SSRC-23 に含まれる 4 種の正常通信カテゴリ（Video，Audio，Text，Background）から算出した異常スコアのヒストグラムを，図 4 に CIC-DDoS2019 の正常データから算出した異常スコアのヒストグラムを示す．図 3 より，TII-SSRC-23 では通信種別によらず高い異常スコア（30 以上）が算出される正常フローの割合が高いことが確認された．両データセットにおいて異常スコアが 30 以上となった正常フローを分析した結果，共通して ‘Bwd IAT Total’（逆方向のパケット到着間隔の合計）の値が 0 であることが判明した．

学習データと 3 種のテストデータに含まれる ‘Bwd IAT Total = 0’ のデータ数の内訳を表 5 に示す．表 5 より，学習データ（CICIDS2017）および CICIDS2018 では，単方向通信（‘Bwd IAT Total = 0’）の占める割合が約 4 割（それぞれ 41.0%，40.8%）存在し，TII-SSRC-23 では約 6.5 割（64.4%）に達している．学習データ内に同データが 41.0% 存在するにもかかわらず TII-SSRC-23 で過大な異常スコアが算出された要因は，単一特徴量の値だけでなく，動画や音声の保持通信等に起因するフロー持続時間やパケット長といった他の特徴量との複合的なパターンが，学習データ内の単方向通信と異なっていたためと考えられる．PaDiM は正常データ全体を単一の多変量正規分布でモデル化するため，このように他特徴量との相関構造が変化した通信群に対しては，分布の裾野（マハラノビス距離が大きい領域）へ位置づけてしまい，誤検知を多発させたことがドメインシフト下での性能低下を引き起こした要因であると捉えられる．

これに対し，表 3 に示す通り，PCA が比較手法の中で最

© 2026 Information Processing Society of Japan

も高い性能（ROC-AUC 0.690）を示した．PCA は特徴量の局所的なパターンに依存せず，データ全体の分散が最大となる軸へ直交投影を行う線形手法である．TII-SSRC-23 に含まれる攻撃データの約 9 割は DoS 攻撃で占められており，これらはパケット発生間隔やフロー長といった統計的特徴において，正常通信と大きな差が生じる．PCA は正常データの主要な変動パターン（主成分）を低次元空間でモデル化するため，このような正常通信の構造から大きく外れる大域的な特徴量の変化を，再構成誤差の増大として明瞭に捉えられたと考えられる．この結果は，PaDiM を実用的な NIDS へ適用する際には，ドメイン間で変動しやすい特定の通信パターン（単方向通信等）に対する事前フィルタリングや，特徴量選択の最適化が重要であることを示唆している．

5. おわりに

本研究では，NCTD により画像化したトラフィック特徴量を GAP を導入した PaDiM に入力するアノマリ型 NIDS を提案し，そのドメインシフトに対する汎化性能を実証的に検証した．CICIDS2017 の正常通信で学習したモデルによる評価の結果，同一の生成手法に基づく CICIDS2018 や CIC-DDoS2019 に対しては，従来手法を上回る高い汎化性能を示した．一方で，独自の通信内容を含む TII-SSRC-23 においては，ドメイン固有の通信プロファイルへの過剰反応が原因で誤検知が多発し，PCA を除く他手法と同様に精度が大きく低下するという実用上の限界も明らかとなった．今後は，ドメイン間で変動しやすい特徴量の排除や事前フィルタリング手法の検討，ならびにドメイン適応技術の導入を推進し，多様なネットワーク環境下でも安定して動作する実用的な NIDS の実現を目指す．

参考文献

[1] Xu, Z. and Liu, Y.: Robust Anomaly Detection in Network Traffic: Evaluating Machine Learning Models on CICIDS2017, *arXiv preprint arXiv:2506.19877* (2025).

[2] 高橋知克，山中友貴，南拓也，中嶋良彰：パケットペイロードを対象とした BERT による特徴抽出を用いた異常通信検知技術の有効性の検討，人工知能学会全国大会論文集，pp.1T5GS203-1T5GS203 (2023).

[3] 浦川侑之介，青木茂樹，宮本貴朗：LSTM によるネットワークの異常検出，情報処理学会論文誌，vol.61，No.7，pp.1249-1254，(2020).

[4] 中前諒哉，青木茂樹，宮本貴朗：VAE を用いたネットワークトラフィックの異常検出，コンピュータセキュリティシンポジウム 2021 論文集，pp.551-558，(2021).

[5] Verkerken, M., D'hooge, L., Wauters, T., Volckaert, B. and De Turck, F.: Towards Model Generalization for Intrusion Detection: Unsupervised Machine Learning Techniques, *Journal of Network and Systems Management*, Vol.30, No.12, p.102 (2022).

[6] Golchin, P., Rafiee, N., Hajizadeh, M., Khalil, A., Kundel, R. and Steinmetz, R.: SSCL-IDS: Enhancing Generalization of Intrusion Detection with Self-Supervised Contrastive Learning, *2024 IFIP Networking Conference (IFIP Networking)*, pp.404-412 (2024).

[7] Defard, T., Setkov, A., Loesch, A. and Audigier, R.: PaDiM: a Patch Distribution Modeling Framework for Anomaly Detection and Localization, *International Conference on Pattern Recognition (ICPR)*, pp.475-482 (2021).

[8] 劉耀楚，青木茂樹，宮本貴朗：PaDiM を用いたネットワーク異常検知，コンピュータセキュリティシンポジウム 2025 論文集，pp.1347-1352 (2025).

[9] Alenizy, H. A. and Berri, J.: Transforming tabular data into images via enhanced spatial relationships for CNN processing, *Scientific Reports*, Vol.15, Article No.17004 (2025).

[10] Sharafaldin, I., Lashkari, A. H. and Ghorbani, A. A.: Toward Generating a New Intrusion Detection Dataset and Intrusion Traffic Characterization, *4th International Conference on Information Systems Security and Privacy (ICISSP)*, pp.108-116 (2018).

[11] Canadian Institute for Cybersecurity: CSE-CIC-IDS2018, `https://www.unb.ca/cic/datasets/ids-2018.html` (参照 2026-08-14).

[12] Sharafaldin, I., Lashkari, A. H., Hakak, S. and Ghorbani, A. A.: Developing Realistic Distributed Denial of Service (DDoS) Attack Dataset and Taxonomy, *Proc. 53rd IEEE International Carnahan Conference on Security Technology (CCST)*, pp.1-8 (2019).

[13] Herzalla, D., Lunardi, W. T. and Andreoni, M.: TII-SSRC-23 Dataset: Typological Exploration of Diverse Traffic Patterns for Intrusion Detection, *IEEE Access*, Vol.11, pp.118577-118594 (2023).

[14] Canadian Institute for Cybersecurity: CICFlowMeter, `https://www.unb.ca/cic/research/applications.html` (参照 2026-08-14).

[15] Tan, M. and Le, Q. V.: EfficientNetV2: Smaller Models and Faster Training, *International Conference on Machine Learning (ICML)*, pp.10096-10106 (2021).

© 2026 Information Processing Society of Japan