深層学習型NIDSの軽量化による未観測攻撃カテゴリの検知性能への影響分析

犬飼 陽平[1,a)]　中村 徹[1,b)]

概要：IoT・エッジ環境向けに，深層学習を用いたネットワーク侵入検知システム（NIDS）を軽量化する研究が進められている．一方，通常のテストデータ上で性能が維持されても，導入後の通信や攻撃傾向が学習時と一致し続ける保証はない．本研究では，通常評価で確認された軽量化後の性能維持が，特定の攻撃カテゴリを学習データから除外した条件でも成立するかを検討した．DNN に特徴量選択，剪定，量子化を適用し，通常条件と Leave-One-Attack-Out（LOAO）条件で，主要評価指標と Unknown Recall を比較した．その結果，通常評価で性能が概ね維持された場合でも，一部の軽量化手法と攻撃カテゴリの組合せでは除外カテゴリ Recall が低下し，その影響は組合せによって異なることを確認した．以上より，通常評価では同等とみなされる軽量化手法であっても，攻撃カテゴリを除外した条件では性能差が生じる可能性が示された．

キーワード：ネットワーク侵入検知，深層学習，モデル軽量化，未観測攻撃，LOAO

Analysis of the Impact of Model Lightweighting on the Detection Performance of Deep Learning-Based NIDS for Unseen Attack Categories

Yohei Inukai[1,a)]　Toru Nakamura[1,b)]

Abstract: Research on lightweight deep learning-based network intrusion detection systems (NIDSs) for IoT and edge environments is growing. However, even when performance is preserved on conventional test data, traffic and attack patterns after deployment may differ from those seen during training. This study examines whether the performance retained after model compression under standard evaluation is also maintained when one attack category is excluded from training. Feature selection, pruning, and quantization were applied to a DNN, and major evaluation metrics and Unknown Recall were compared under standard and Leave-One-Attack-Out (LOAO) settings. Although overall performance was largely maintained under standard evaluation, recall for the excluded category decreased for some combinations of compression method and attack category. These results indicate that compression methods considered comparable under standard evaluation may exhibit different detection performance for attack categories not observed during training.

Keywords: network intrusion detection, deep learning, model compression, unseen attacks, leave-one-attack-out

1. はじめに

近年，ネットワークを介した攻撃の増加や高度化に伴い，ネットワーク通信を監視して攻撃を検知するネットワーク侵入検知システム（Network Intrusion Detection System:

[1] 東京都市大学大学院 総合理工学研究科 情報専攻
Division of Informatics, Graduate School of Integrative Science and Engineering,Tokyo City University
[a)] g2581407@tcu.ac.jp
[b)] tonakamu@tcu.ac.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

NIDS）の重要性が高まっている [1]．NIDS の検知性能を高める手法として，深層学習を用いた NIDS が広く研究されている [2]．一方，Internet of Things（IoT）やエッジ環境では利用可能な計算資源が限られるため，深層学習モデルをそのまま配置することは容易ではない．このため，特徴量選択，剪定，量子化などによって深層学習型 NIDS を軽量化する研究が進められている [3]．

軽量化モデルの評価では，Accuracy，F1-score，Balanced Accuracy などの集約的な分類指標と，モデルサイズなどの軽量化効果を比較し，元のモデルと同程度の分類性能が維持されるかを確認することが多い [3]．しかし，集約指標が維持されていることは，すべてのデータに対するモデルの挙動が同様に維持されていることを必ずしも意味しない．Hooker らは，剪定や量子化を施した深層学習モデルでは，全体的なテスト性能がほぼ維持される場合でも，一部のクラスが選択的に影響を受ける可能性を報告している [4]．したがって，通常条件における集約的な性能指標だけでは，軽量化による挙動の変化を十分に把握できない可能性がある．

また，NIDS の実運用では，学習時と同じ閉じた環境が維持されるとは限らない．Sommer らは，機械学習を用いた NIDS の評価において，学習時と運用時の環境が一致するという closed-world assumption に依存することの問題を指摘している [5]．さらに，端末構成，サービス，正常通信および攻撃通信の特徴は時間とともに変化する可能性があり，このような分布変化は NIDS の検知性能を低下させる要因となる [6]．以上から，通常条件で性能を維持した軽量化モデルであっても，学習時に観測していない攻撃（**未観測攻撃**）カテゴリに対しては，軽量化によって基準モデルより検知性能が低下する可能性があると考え，その影響を調査する．

Kaur らは，特定の攻撃カテゴリを学習データから除外して評価する Leave-One-Attack-Out（LOAO）を用い，未観測攻撃に対する検知性能を評価している [7]．

本稿では，UNSW-NB15 と全結合型 DNN を対象として，特徴量選択，剪定および量子化を適用する．まず，すべての攻撃カテゴリを学習に含む通常条件で，Accuracy，Balanced Accuracy，Attack Recall，Normal Recall および F1-score に基づいて軽量化条件を選定する．次に，選定した条件を LOAO 条件へ適用し，学習から除外した攻撃カテゴリを攻撃として検知できた割合を Unknown Recall として評価する．これにより，通常評価では性能維持と判断された軽量化モデルが，未観測攻撃カテゴリに対して基準モデルより検知性能が低下するかを確認するとともに，その影響が軽量化手法および攻撃カテゴリによってどのように異なるかを分析する．

本論文の構成は以下のとおりである．第 2 章では基準モデルの構成と軽量化手法を示す．第 3 章では通常条件および LOAO 条件における実験方法を述べ，第 4 章では実験結果を示す．第 5 章では得られた結果について考察し，第 6 章で本研究をまとめる．

表 1　基準モデルの構成

層	ユニット数	処理
入力	d	前処理後の特徴量
Dense 1	128	Batch Normalization，ReLU，Dropout 0.30
Dense 2	64	Batch Normalization，ReLU，Dropout 0.30
Dense 3	32	ReLU，Dropout 0.20
出力	1	Sigmoid

2. モデル構成と軽量化手法

本章では，本研究で用いる基準モデルの構成と，特徴量選択，剪定および量子化の各軽量化手法について述べる．

本研究では，軽量化を適用しない全結合型 DNN を基準モデルとし，これに対して特徴量選択，剪定および量子化を適用する．本研究の目的は DNN 構造自体の最適化ではないため，すべての実験で共通のモデル構成を用いる．

2.1 基準モデル

基準モデルの構成を**表 1** に示す．本研究の DNN は攻撃カテゴリを個別に識別する多クラス分類器ではなく，正常通信と攻撃通信を判定する二値分類器である．

入力次元 d は前処理後の特徴量数であり，特徴量選択を適用したモデルでは選択特徴量数に応じて変化する．隠れ層は 128，64，32 ユニットの 3 層とし，活性化関数には ReLU を用いる．また，Batch Normalization[8] および Dropout[9] を適用する．出力層は 1 ユニットとし，Sigmoid 関数によって攻撃である確率を出力する．

2.2 特徴量選択

特徴量選択には，Random Forest を用いた Permutation Importance を使用する [10]．Permutation Importance では，ある特徴量の値をランダムに並べ替えたときの分類性能の低下量から，その特徴量の重要度を評価する．特徴量 j の重要度 I_j を次式で定義する．

$$I_j = B(f, X) - \frac{1}{R}\sum_{r=1}^{R} B\left(f, \pi_j^{(r)}(X)\right), \qquad (1)$$

ここで，B は Balanced Accuracy，f は Random Forest，X は評価データ，$\pi_j^{(r)}$ は特徴量 j のみを第 r 回目にランダムに並べ替える操作，R は反復回数である．特徴量を並べ替えた際の Balanced Accuracy の低下が大きいほど，その特徴量の重要度が高いとみなす．得られた重要度に基づいて特徴量を順位付けし，上位 K 個の特徴量のみを入力と

© 2026 Information Processing Society of Japan

する DNN を学習する．

2.3 剪定

剪定には，3 つの隠れ Dense 層全体を対象とした Magnitude Pruning を用いる [11]．3 層の重みをまとめて扱い，絶対値の小さい重みから順にゼロへ置換する．対象となる重み数を N，ゼロ化した重み数を N_0 とすると，剪定率 S を次式で定義する．

$$S = \frac{N_0}{N}. \tag{2}$$

本手法では層ごとに個別の剪定率を設定するのではなく，対象とする 3 層の重み全体から，絶対値の小さい重みを選択して剪定する．剪定後は，ゼロ化した重みを維持した状態で追加学習を行う．

2.4 量子化

量子化には Post-Training Quantization（PTQ）を用いる [12]．学習済みの FP32 モデルを TensorFlow Lite 形式へ変換し，重み，演算，入力および出力を INT8 表現とする Full INT8 量子化を適用する．これにより，モデル内部で用いる数値表現を低ビット化し，モデルサイズを削減する．

3. 実験方法

本章では，通常条件における軽量化設定の選定と，LOAO 条件における未観測攻撃カテゴリの評価方法について述べる．LOAO とは，特定の攻撃カテゴリを学習データから除外し，除外したカテゴリをテスト時に未観測攻撃として評価する方法である．

3.1 実験の全体構成

本研究の実験は，通常条件における軽量化設定の選定と，LOAO 条件における未観測攻撃カテゴリの評価の 2 段階から構成される．

第 1 段階では，すべての攻撃カテゴリを学習に含む通常条件で，基準モデルと軽量化候補を比較する．特徴量選択と剪定については軽量化の強度を段階的に変更し，3 種類の乱数 seed すべてで性能維持基準に合格した候補のうち，最も軽量化の強い設定を選定する．量子化については Full INT8 PTQ を固定設定として用いる．

第 2 段階では，第 1 段階で選定した設定を固定し，攻撃カテゴリを一つずつ学習データから除外して LOAO 評価を行う．各条件で基準モデルと軽量化モデルに同一のデータ分割および乱数 seed を用い，未観測攻撃カテゴリの検知性能を比較する．

3.2 データセット

本研究では，ネットワーク侵入検知用データセットである UNSW-NB15[13] の公式 Training データおよび Test データを使用する．カテゴリ別のサンプル数を**表 2** に示す．Training データは 175,341 件，Test データは 82,332 件であり，正常通信と 9 種類の攻撃カテゴリから構成される．

表 2 UNSW-NB15 のカテゴリ別サンプル数

カテゴリ	Training	Test
Normal	56,000	37,000
Generic	40,000	18,871
Exploits	33,393	11,132
Fuzzers	18,184	6,062
DoS	12,264	4,089
Reconnaissance	10,491	3,496
Analysis	2,000	677
Backdoor	1,746	583
Shellcode	1,133	378
Worms	130	44
合計	175,341	82,332

カテゴリ間のサンプル数には大きな偏りがあるため，LOAO 評価では 9 条件の平均値に加えて，各攻撃カテゴリに対する結果も個別に確認する．

表 3 主な実験条件

項目	設定
乱数 seed	42，123，2024
データ分割	Fit 60%，Tuning 20%，Selection 20%
初期学習	最大 100 エポック，バッチサイズ 256
学習率	初期 10^{-3}，追加学習 10^{-4}
Early Stopping	Tuning loss，patience 8
特徴量重要度	Random Forest 150 本，最大 10,000 サンプル，3 反復
INT8 代表データ	最大 1,000 サンプル

3.3 データ分割と前処理

通常条件では，公式 Training データを Fit，Tuning，Selection の 3 集合へ 60%，20%，20%の比率で分割する．Fit データをモデル学習，Tuning データを Early Stopping や判定しきい値の決定，Selection データを軽量化候補の選定に使用する．

数値特徴量には欠損値補完と標準化を行い，カテゴリ特徴量には One-Hot Encoding を適用する．主な実験条件を**表 3** に示す．

3.4 評価指標

攻撃通信を正しく攻撃と判定した数を TP，攻撃通信を正常と誤判定した数を FN，正常通信を正しく正常と判定した数を TN，正常通信を攻撃と誤判定した数を FP とする．

Accuracy は全サンプルに対する正分類率であり，次式で定義する．

© 2026 Information Processing Society of Japan

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}. \quad (3)$$

Attack Recall（AR）および Normal Recall（NR）は，それぞれ攻撃通信および正常通信を正しく判定した割合であり，次式で定義する．

$$\text{AR} = \frac{TP}{TP + FN}, \quad (4)$$

$$\text{NR} = \frac{TN}{TN + FP}. \quad (5)$$

Balanced Accuracy（BA）は，Attack Recall と Normal Recall の平均として定義する．

$$\text{BA} = \frac{\text{AR} + \text{NR}}{2}. \quad (6)$$

攻撃クラスの Precision を P とすると，Precision および F1-score は次式で定義する．

$$P = \frac{TP}{TP + FP}, \quad (7)$$

$$F_1 = \frac{2P \cdot \text{AR}}{P + \text{AR}}. \quad (8)$$

通常条件では，Accuracy，BA，AR，NR および F1-score を軽量化候補の性能維持の判定に用いる．

LOAO 条件では，これらに加えて，学習から除外した攻撃カテゴリに対する Unknown Recall を評価する．カテゴリ c に属する Test データのサンプル数を N_c，そのうち攻撃として正しく検知したサンプル数を TP_c とすると，Unknown Recall UR_c を次式で定義する．

$$\text{UR}_c = \frac{TP_c}{N_c}. \quad (9)$$

Unknown Recall は未観測カテゴリを新しいクラスとして識別する能力ではなく，学習時に除外した攻撃カテゴリを二値分類モデルが攻撃として検知できた割合を表す．

軽量化効果は，入力次元，総パラメータ数，非ゼロパラメータ数，モデル全体のスパース率，重み表現および TensorFlow Lite 形式のモデルサイズを用いて評価する．

3.5 軽量化設定の選定

各軽量化候補を，同一の乱数 seed で学習した基準モデルと比較する．基準モデルの判定しきい値は，Tuning データにおける Balanced Accuracy が最大となる値とする．

軽量化によって出力確率の分布が変化する可能性があるため，軽量化モデルの判定しきい値は，Tuning データにおける False Positive Rate（FPR）が同一 seed の基準モデルに最も近くなるように決定する．ここで FPR は，正常通信を攻撃と誤って判定する割合 $FP/(FP + TN)$ である．これにより，正常通信に対する誤検知率を概ね揃えた状態で軽量化前後の性能を比較する．

性能維持の判定には Accuracy，Balanced Accuracy，Attack Recall，Normal Recall および F1-score を用いる．同一 seed の基準モデルから許容する性能低下を，Accuracy および Balanced Accuracy では 0.005，Attack Recall，Normal Recall および F1-score では 0.010 とする．これはそれぞれ 0.5 パーセントポイントおよび 1.0 パーセントポイントまでの性能低下を許容することに相当する．

特徴量選択では，入力特徴量数 K を 60，50，40，35，30，25，20，15，10 とした候補を評価する．3 種類の乱数 seed すべてで性能維持基準に合格した候補のうち，特徴量数が最も少ない設定を採用する．

剪定では，剪定率を 30%，35%，40%，45%，50%，60%，70%とした候補を評価する．3 種類の乱数 seed すべてで性能維持基準に合格した候補のうち，剪定率が最も高い設定を採用する．

量子化については量子化強度の探索を行わず，Full INT8 PTQ を固定設定として使用する．以上により選定した各軽量化設定を LOAO 評価に用いる．

3.6 LOAO 条件

LOAO 条件では，9 種類の攻撃カテゴリから 1 カテゴリを選び，そのカテゴリに属するサンプルを公式 Training データから除外する．正常通信と残り 8 種類の攻撃カテゴリを用いてモデルを学習し，公式 Test データに含まれる除外カテゴリのサンプルを，学習時に未観測の攻撃カテゴリとして評価する．この操作を 9 種類の攻撃カテゴリについて順に繰り返す．

各 LOAO 条件では，基準モデル，特徴量選択モデル，剪定モデルおよび量子化モデルに対して，同一の除外カテゴリ，データ分割および乱数 seed を用いる．特徴量数や剪定率などの軽量化設定には，通常条件で選定した設定をそのまま使用する．判定しきい値についても通常条件と同じ方針で決定する．これにより，通常条件で性能維持と判断された軽量化モデルが，学習時に観測していない攻撃カテゴリに対して基準モデルとどのように異なる検知性能を示すかを比較する．

4. 実験結果

本章では，通常条件における軽量化設定の選定結果と，LOAO 条件における未観測攻撃カテゴリの評価結果を示す．

4.1 通常条件における軽量化設定の選定

実験方法で示した条件に基づき，特徴量選択，剪定および量子化の設定を選定した．特徴量選択と剪定については，設定選定の境界を示すため，採用設定と，それより一段強く軽量化した候補の結果を示す．

4.1.1 特徴量選択の結果

特徴量選択における Selection データ上の結果を**表 4**

© 2026 Information Processing Society of Japan

に示す．表中の BA は Balanced Accuracy，AR は Attack Recall，NR は Normal Recall を表す．「合格」は，当該 seed についてすべての評価指標が性能維持基準を満たしたことを表す．太字は，同一 seed の基準モデルからの低下量が性能維持基準を超えた指標を表す．

Top-25 では，3 種類の乱数 seed すべてで性能維持基準に合格した．一方，Top-20 では seed 123 の Accuracy と Attack Recall が基準モデルからの許容低下量を超えた．したがって，性能維持基準に合格した候補のうち，特徴量数が最も少ない Top-25 を LOAO 評価に採用した．

4.1.2 剪定の結果

剪定における Selection データ上の結果を**表 5** に示す．

剪定率 45%では，3 種類の乱数 seed すべてで性能維持基準に合格した．一方，剪定率 50%では seed 42 の Accuracy，Balanced Accuracy および Attack Recall が性能維持基準を満たさなかった．したがって，性能維持基準に合格した候補のうち，剪定率が最も高い 45%を LOAO 評価に採用した．

4.1.3 INT8 量子化の結果

INT8 量子化では，基準モデルに Full INT8 PTQ を適用した．3 種類の乱数 seed すべてについて INT8 形式への変換および TensorFlow Lite Interpreter による推論が正常に完了し，性能維持基準にも合格した．

Selection データにおける 3 seed 平均の Accuracy は 0.9339，Balanced Accuracy は 0.9380，Attack Recall は 0.9266，Normal Recall は 0.9494，F1-score は 0.9503 であった．

以上より，LOAO 評価には，特徴量選択として Top-25，剪定として剪定率 45%，量子化として Full INT8 PTQ を使用する．

4.2 LOAO 条件における評価結果

通常条件で選定した Top-25, 剪定率 45%および Full INT8 PTQ を LOAO 条件で評価した．各 LOAO 条件について 3 種類の乱数 seed の平均値を求め，さらに全体傾向を確認するため，9 種類の LOAO 条件を同じ重みで平均した値（以下，9 条件平均）を用いて評価する．

4.2.1 主要評価指標の全体傾向

LOAO 全 9 条件における Accuracy, Balanced Accuracy, Attack Recall, Normal Recall および F1-score の平均を**表 6** に示す．

Top-25 では，Normal Recall は基準モデルと近い値であったが，Accuracy，Balanced Accuracy，Attack Recall および F1-score は基準モデルを下回った．特に Attack Recall は，基準モデルの 0.9362 に対して Top-25 では 0.9111 であった．剪定率 45%では，5 指標すべてで基準モデルと同程度，またはわずかに高い値を示した．INT8 PTQ では Normal Recall が 0.8260 となり基準モデルの 0.8200 を上回った一方，Attack Recall は 0.9276 となり基準モデルを下回った．

4.2.2 Unknown Recall のカテゴリ別結果

各 LOAO 条件における Unknown Recall の 3 seed 平均を**表 7** に示す．

Top-25 の Unknown Recall は全 9 条件平均で 0.8359 となり，基準モデルの 0.8812 を下回った．特に Analysis, Backdoor および Generic で低下が大きく，Generic では基準モデルの 0.5359 に対して 0.3929 となった．一方，Reconnaissance および Shellcode では基準モデルをわずかに上回った．

剪定率 45%の全 9 条件平均は 0.8843 であり，基準モデルと同程度であった．ただし LOAO 条件による傾向は一様ではなく，Generic では 0.6368 と基準モデルを上回った一方，Fuzzers では 0.4423 と基準モデルを下回った．

INT8 PTQ の全 9 条件平均は 0.8492 であった．特に Fuzzers では 0.2960 となり，基準モデルの 0.5168 を大きく下回った．一方，DoS および Shellcode では基準モデルを上回った．以上より，軽量化が Unknown Recall へ与える影響は，軽量化手法だけでなく，除外する攻撃カテゴリによっても異なった．

4.2.3 Generic および Fuzzers の詳細結果

Generic および Fuzzers では, 軽量化手法による Unknown Recall の違いが特に大きかった．そこで，両カテゴリについて LOAO 条件における seed 別の値を**表 8** に示す．

Generic では，Top-25 が 3 seed すべてで基準モデルを下回ったのに対し，剪定率 45%は 3 seed すべてで基準モデルを上回った．また，INT8 PTQ は 3 seed すべてで基準モデルを下回った．

Fuzzers では，Top-25 は seed 123 で基準モデルを上回ったが，seed 42 および 2024 では低下した．これに対して，剪定率 45%と INT8 PTQ は 3 seed すべてで基準モデルを下回った．特に INT8 PTQ は全 seed で Unknown Recall が 0.31 未満であり，Fuzzers に対する検知性能が一貫して低かった．

LOAO 条件で確認された低下が，攻撃カテゴリを学習時に観測していないことと関係するかを検討するため，Generic および Fuzzers が学習データに含まれる通常条件についても，カテゴリ別の Attack Recall を確認した．結果を**表 9** に示す．ここでの Attack Recall は，各カテゴリの Test サンプルのうち，攻撃として検知できた割合を表す．

Generic では，通常条件においてすべてのモデルおよび seed で Attack Recall が 0.998 以上となり，軽量化による差はほとんどみられなかった．一方，Fuzzers では Top-25 が 3 seed すべてで基準モデルを下回った．Pruning 45%は基準モデルと近い値を示し，INT8 PTQ では seed 42 で低下した一方，seed 123 では基準モデルを上回り，seed 2024 ではほぼ同等であった．

© 2026 Information Processing Society of Japan

表 4 特徴量選択における設定選定結果

設定	seed	Accuracy	BA	AR	NR	F1	判定
基準モデル	42	0.9339	0.9390	0.9249	0.9532	0.9502	–
	123	0.9377	0.9397	0.9342	0.9451	0.9534	–
	2024	0.9356	0.9396	0.9285	0.9507	0.9516	–
Top-25	42	0.9335	0.9392	0.9237	0.9547	0.9499	合格
	123	0.9364	0.9383	0.9330	0.9436	0.9524	合格
	2024	0.9333	0.9385	0.9241	0.9528	0.9497	合格
Top-20	42	0.9341	0.9400	0.9237	0.9562	0.9503	合格
	123	**0.9295**	0.9374	**0.9155**	0.9593	0.9465	不合格
	2024	0.9340	0.9393	0.9248	0.9538	0.9503	合格

表 5 剪定における設定選定結果

設定	seed	Accuracy	BA	AR	NR	F1	判定
基準モデル	42	0.9339	0.9390	0.9249	0.9532	0.9502	–
	123	0.9377	0.9397	0.9342	0.9451	0.9534	–
	2024	0.9356	0.9396	0.9285	0.9507	0.9516	–
Pruning 45%	42	0.9293	0.9364	0.9168	0.9559	0.9465	合格
	123	0.9348	0.9380	0.9293	0.9467	0.9511	合格
	2024	0.9319	0.9378	0.9215	0.9541	0.9486	合格
Pruning 50%	42	**0.9248**	**0.9333**	**0.9098**	0.9568	0.9428	不合格
	123	0.9327	0.9373	0.9248	0.9497	0.9494	合格
	2024	0.9316	0.9371	0.9219	0.9523	0.9484	合格

表 6 LOAO 全 9 条件における主要評価指標の平均

指標	基準モデル	Top-25	Pruning 45%	INT8 PTQ
Accuracy	0.8840	0.8695	0.8872	0.8820
Balanced Accuracy	0.8781	0.8648	0.8814	0.8768
Attack Recall	0.9362	0.9111	0.9380	0.9276
Normal Recall	0.8200	0.8184	0.8248	0.8260
F1-score	0.8982	0.8836	0.9011	0.8955

表 7 LOAO 条件別の平均 Unknown Recall

除外カテゴリ	基準モデル	Top-25	Pruning 45%	INT8 PTQ
Analysis	0.9956	0.9168	0.9936	0.9951
Backdoor	0.9954	0.8868	0.9954	0.9948
DoS	0.9892	0.9755	0.9942	0.9938
Exploits	0.9560	0.9468	0.9557	0.9224
Fuzzers	**0.5168**	**0.4836**	**0.4423**	**0.2960**
Generic	**0.5359**	**0.3929**	**0.6368**	**0.5021**
Reconnaissance	0.9690	0.9749	0.9654	0.9527
Shellcode	0.9727	0.9762	0.9753	0.9859
Worms	1.0000	0.9697	1.0000	1.0000
全 9 条件平均	0.8812	0.8359	0.8843	0.8492

表 8 Generic および Fuzzers に対する seed 別 Unknown Recall

カテゴリ	手法	seed 42	seed 123	seed 2024	平均
Generic	基準モデル	0.5480	0.5229	0.5366	0.5359
	Top-25	0.3660	0.3430	0.4699	0.3929
	Pruning 45%	0.6440	0.7243	0.5421	0.6368
	INT8 PTQ	0.5153	0.4960	0.4949	0.5021
Fuzzers	基準モデル	0.5299	0.4792	0.5414	0.5168
	Top-25	0.4429	0.5244	0.4833	0.4836
	Pruning 45%	0.4538	0.4563	0.4167	0.4423
	INT8 PTQ	0.2864	0.3091	0.2925	0.2960

© 2026 Information Processing Society of Japan

表 9 通常条件における Generic および Fuzzers の seed 別 Attack Recall

カテゴリ	手法	seed 42	seed 123	seed 2024	平均
Generic	基準モデル	0.9994	0.9996	0.9993	0.9994
	Top-25	0.9982	0.9983	0.9980	0.9982
	Pruning 45%	0.9995	0.9996	0.9993	0.9995
	INT8 PTQ	0.9993	0.9995	0.9991	0.9993
Fuzzers	基準モデル	0.6853	0.7420	0.6285	0.6853
	Top-25	0.6066	0.6463	0.5584	0.6038
	Pruning 45%	0.6737	0.7428	0.6300	0.6822
	INT8 PTQ	0.6229	0.7585	0.6274	0.6696

4.2.4 モデルの軽量化効果

LOAO 評価に用いた各モデルの軽量化効果を**表 10** に示す．モデルサイズは 3 seed の平均であり，削減率は基準モデルの TensorFlow Lite 形式のモデルサイズを基準として算出した．

Top-25 では，入力次元を 193 から 25 へ削減したことで，総パラメータ数が 35,777 から 14,273 へ減少し，TensorFlow Lite 形式のモデルサイズは 59.9%削減された．

剪定率 45%では，総パラメータ数自体は変化しないが，非ゼロパラメータ数は 20,052 となった．TensorFlow Lite 形式のモデルサイズは 29.1%削減された．

INT8 PTQ では，入力次元およびパラメータ数は変化しないが，重み表現を FP32 から INT8 へ変更したことで，モデルサイズは 69.1%削減され，評価対象の中で最も小さいモデルとなった．

5. 考察

本章では，LOAO 条件で得られた結果について，通常条件との比較を踏まえて考察する．

本研究では，通常評価で性能を維持した軽量化モデルであっても，未観測攻撃カテゴリに対しては，軽量化によって検知性能が低下すると予想した．実際に，Generic に対する Top-25 や，Fuzzers に対する Pruning 45%および INT8 PTQ では，通常条件と比較して LOAO 条件で軽量化の影響が大きく現れた．このことから，通常評価では把握しにくい軽量化の影響が，未観測攻撃カテゴリの検知において顕在化する場合があることを確認できた．一方，その影響は一様ではなく，軽量化手法や攻撃カテゴリによって異なる傾向がみられた．

特徴量選択では，Generic の Unknown Recall が基準モデルの 0.5359 から Top-25 では 0.3929 へ低下した．本研究の特徴量選択は通常条件における重要度に基づくため，通常条件では重要度が低いと判断された特徴量の中に，未観測攻撃の検知には有効な情報が含まれていた可能性がある．

剪定では，Fuzzers の Unknown Recall が 0.5168 から 0.4423 へ低下した一方，Generic では 0.5359 から 0.6368 へ上昇した．剪定による重みの削減が決定境界を変化させ，カテゴリによって未観測攻撃の検知に不利または有利に働いた可能性がある．

量子化では，Fuzzers の Unknown Recall が基準モデルの 0.5168 から INT8 PTQ では 0.2960 へ大きく低下した．一方，通常条件では基準モデル 0.6853 に対して 0.6696 であり，差は比較的小さかった．このことから，INT8 化による数値表現の変化が，観測済みカテゴリの検知よりも，未観測カテゴリへ一般化する際に大きく影響した可能性がある．

また，Generic と Fuzzers では，通常条件から LOAO 条件への性能変化にも異なる傾向がみられた．Generic は通常条件では基準モデルの Attack Recall が 0.9994 であり，軽量化後もほぼ同等の性能を維持していたが，LOAO 条件では基準モデル自体の Unknown Recall が 0.5359 まで低下し，Top-25 ではさらに 0.3929 まで低下した．一方，Fuzzers は通常条件においても基準モデルの Attack Recall が 0.6853 と比較的低く，LOAO 条件では 0.5168 となった．さらに，Pruning 45%や INT8 PTQ によって Unknown Recall が大きく低下した．このように，未観測化と軽量化による影響の現れ方は，攻撃カテゴリによって異なることが確認された．

以上より，本研究で予想したように，通常条件では性能が維持されていても，未観測攻撃カテゴリでは軽量化による性能低下が顕在化する場合があることを確認した．一方で，剪定後の Generic のように基準モデルを上回る場合も確認されたことから，軽量化が未観測攻撃カテゴリの検知性能を一様に低下させるとは結論付けられない．したがって，軽量化モデルを評価する際には，通常条件における集約性能だけでなく，未観測攻撃カテゴリに対する挙動についてもあわせて確認することが重要であると考えられる．

一方，本研究では各攻撃カテゴリの特徴量分布や，軽量化前後の出力確率，内部表現などを直接比較していない．そのため，観測された性能差がどのようなデータ特性やモデル内部の変化によって生じたかまでは明らかにできていない．今後は，カテゴリごとの特徴量分布や重要特徴量，軽量化前後の出力や決定境界を分析し，性能変化の要因をより詳細に検証する必要がある．

さらに，LOAO では除外する攻撃カテゴリによって

© 2026 Information Processing Society of Japan

表 10　LOAO 評価に用いたモデルの軽量化効果

手法	入力次元	総 Param.	非ゼロ Param.	重み表現	TFLite（MB）	削減率
基準モデル	193	35,777	35,777	FP32	0.1368	–
Top-25	25	14,273	14,273	FP32	0.0548	59.9%
Pruning 45%	193	35,777	20,052	FP32	0.0969	29.1%
INT8 PTQ	193	35,777	35,777	INT8	0.0422	69.1%

Training データから取り除かれるサンプル数が異なるため，観測された性能差には学習データ量の減少による影響も含まれる可能性がある．今後は，除外したサンプル数と同数をランダムに除外する条件などを用い，未観測化そのものの影響と学習データ量の影響を切り分けて検証する必要がある．

6. まとめ

本研究では，通常評価で性能を維持した軽量化モデルであっても，未観測攻撃カテゴリに対しては検知性能が低下する可能性に着目し，特徴量選択，剪定および量子化を適用した DNN を LOAO 条件で評価した．その結果，Generic に対する Top-25 や，Fuzzers に対する Pruning 45%および INT8 PTQ では，基準モデルと比較して Unknown Recall が低下した．このことから，通常評価では把握しにくい軽量化の影響が，未観測攻撃カテゴリの検知において顕在化する場合があることを確認した．

一方，剪定後の Generic のように基準モデルを上回る場合も確認されたことから，軽量化が未観測攻撃カテゴリの検知性能を一様に低下させるとは結論付けられない．したがって，軽量化モデルを評価する際には，通常条件における集約性能だけでなく，未観測攻撃カテゴリに対する挙動についても確認することが重要である．

今後は，カテゴリごとのデータ特性や重要特徴量，軽量化前後の出力や決定境界を分析し，性能変化の要因をより詳細に検証する必要がある．また，LOAO に伴う学習データ量の減少による影響を切り分けるため，同数のサンプルをランダムに除外する条件などについても検討する必要がある．

参考文献

[1] Buczak, A. L. and Guven, E.: A Survey of Data Mining and Machine Learning Methods for Cyber Security Intrusion Detection, IEEE Communications Surveys & Tutorials, Vol.18, No.2, pp.1153–1176 (2016).

[2] Shone, N., Tran, N. N., Phai, V. D., and Shi, Q.: A Deep Learning Approach to Network Intrusion Detection, IEEE Transactions on Emerging Topics in Computational Intelligence, Vol.2, No.1, pp.41–50 (2018).

[3] Islam, M. M., Salsabil, U., Nurmamatov, M., and Hossain, S.: Lightweight Intrusion Detection Systems for IoT–Edge Environments: A PRISMA-ScR Systematic Review of Deployability Evidence and a Unified Assessment Framework, Future Internet, Vol.18, No.6, 300 (2026).

[4] Hooker, S., Courville, A., Clark, G., Dauphin, Y., and Frome, A.: What Do Compressed Deep Neural Networks Forget?, arXiv preprint arXiv:1911.05248 (2019).

[5] Sommer, R. and Paxson, V.: Outside the Closed World: On Using Machine Learning for Network Intrusion Detection, Proc. IEEE Symposium on Security and Privacy, pp.305–316 (2010).

[6] Andresini, G., Pendlebury, F., Pierazzi, F., Loglisci, C., Appice, A., and Cavallaro, L.: INSOMNIA: Towards Concept-Drift Robustness in Network Intrusion Detection, Proc. 14th ACM Workshop on Artificial Intelligence and Security (AISec), pp.111–122 (2021).

[7] Kaur, B., Dadkhah, S., Xiong, P., Iqbal, S., Ray, S., and Ghorbani, A. A.: Verification Based Scheme to Restrict IoT Attacks, Proc. IEEE/ACM 8th International Conference on Big Data Computing, Applications and Technologies (BDCAT), pp.63–68 (2021).

[8] Ioffe, S. and Szegedy, C.: Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift, Proc. 32nd International Conference on Machine Learning (ICML), Vol.37, pp.448–456 (2015).

[9] Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., and Salakhutdinov, R.: Dropout: A Simple Way to Prevent Neural Networks from Overfitting, Journal of Machine Learning Research, Vol.15, pp.1929–1958 (2014).

[10] Breiman, L.: Random Forests, Machine Learning, Vol.45, No.1, pp.5–32 (2001).

[11] Han, S., Pool, J., Tran, J., and Dally, W. J.: Learning both Weights and Connections for Efficient Neural Network, Advances in Neural Information Processing Systems, Vol.28, pp.1135–1143 (2015).

[12] Jacob, B., Kligys, S., Chen, B., Zhu, M., Tang, M., Howard, A. G., Adam, H., and Kalenichenko, D.: Quantization and Training of Neural Networks for Efficient Integer-Arithmetic-Only Inference, Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp.2704–2713 (2018).

[13] Moustafa, N. and Slay, J.: UNSW-NB15: A Comprehensive Data Set for Network Intrusion Detection Systems, Proc. Military Communications and Information Systems Conference (MilCIS), pp.1–6 (2015).

© 2026 Information Processing Society of Japan