フロー系列の画像化表現における方向集約が教師なし異常検知の検出性能に与える影響

関根 弘晃[1,a)]　眞部 雄介[1,b)]

概要：ネットワークトラフィックのフロー系列を画像化し深層学習で異常検知を行う手法が近年提案されている．フロー統計特徴量においては，集約方向 (送信方向のみ／双方向) の選択が攻撃種別ごとに異なる形で検出性能へ影響することが報告されているが，この観点は一連の画像化表現にはこれまで取り入れられていない．本研究では，畳み込みオートエンコーダを固定した条件下で，フロー系列の集約方向 (送信方向のみ／双方向) を変化させ，CIC-IDS2017 データセットで攻撃ごとの AUROC を比較した．結果として送信方向のみでは Bot が高精度に検出される一方 DDoS は評価不能であったが，双方向表現では Bot の検出精度が大きく低下し DDoS が検出可能となる，表現依存の検出反転を確認した．この反転は seed 値によらず再現し，方向集約という設計選択が検出可能な攻撃クラスを構造的に決定することを示す．

キーワード：教師なし異常検知，フロー集約，侵入検知システム

Impact of Flow Direction Aggregation in Image-Based Representations on Unsupervised Network Anomaly Detection

Hiroaki Sekine[1,a)]　Yusuke Manabe[1,b)]

Abstract: Recently, methods have been proposed that transform flow-level packet sequences from network traffic into images for deep learning-based anomaly detection. In flow-based statistical features, the choice of aggregation direction (unidirectional/bidirectional) has been reported to affect detection performance differently depending on the attack type; however, this perspective has not yet been incorporated into image-based sequence representations. In this study, under a fixed Convolutional Autoencoder, we varied the aggregation direction of flow sequences (forward-only/bidirectional) and compared per-attack AUROC on the CIC-IDS2017 dataset. The results showed that Bot was detected with high accuracy under the forward-only representation, while DDoS could not be evaluated; conversely, under the bidirectional representation, detection accuracy for Bot dropped sharply while DDoS became detectable — a representation-dependent detection reversal. This reversal was reproducible across seed values, demonstrating that the choice of aggregation direction structurally determines which attack classes are detectable.

Keywords: Unsupervised Anomaly Detection, Flow Aggregation, Intrusion Detection System

1. はじめに

近年，IoT 機器やクラウド利用の拡大に伴って，ネットワークを介したサイバー攻撃の脅威は増加の一途をたどっており，ネットワークセキュリティの重要度がますます高まっている [1]．不正な攻撃を検知するシステムとして IDS(Intrusion Detection System) が存在する．IDS は大きくシグネチャ型とアノマリ型に分けることができる．シグネチャ型は既存の攻撃パターンに基づいて検知を行うという特徴があり，既知の攻撃には強いが，未知の攻撃を検知するのが難しいという課題がある．一方のアノマリ型は正常なトラフィックから外れたものを検知するため，未知の

[1] 千葉工業大学大学院情報科学研究科情報科学専攻
Graduate School of Information and Computer Science, Chiba Institute of Technology
[a)] s2232088xj@chibatech.ac.jp
[b)] yusuke.manabe@chibatech.ac.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

攻撃にも対応できるが，誤検知が多いという課題がある．そのような中で深層学習を用いた IDS の研究が進められている．

深層学習，特に畳み込みニューラルネットワーク (CNN) は画像認識の分野で高い性能を示しており，これをネットワークトラフィックの検知に応用する動きがある．2015 年の Black Hat USA において Wang は，TCP ペイロードのバイト列を画像の画素値とみなすことで，画像認識向けの深層学習手法をトラフィック識別に転用できることを示した [2]．以降，パケットのペイロードやヘッダ情報を画像として表現し，CNN 等の画像認識モデルに入力するという手法が数多く提案されてきた．Zhao らによる YaTC[3] はマスク付きオートエンコーダを用いた自己教師あり学習と組み合わせることで，バイト列ベースの画像化表現による分類性能をさらに高めている．教師なし異常検知の文脈でも，中前らはパケットヘッダのバイト列を画像化し VAE により異常検知を行う手法を提案している [4]．

一方，これらの多くはパケットやペイロードをそのまま画像化する方式が主流であり，パケット長や到着間隔といったフロー統計量の時系列を画像化するアプローチは少数に留まる．本研究はこの後者，すなわちパケット長系列を MTF(Markov Transition Field) 等の手法により画像化するアプローチに属する．関連する取り組みとして Joshi らは SDN 環境において，フロー統計量の時系列を MTF により画像化したうえで Transformer に入力する教師あり多クラス分類手法を提案している [5]．しかし同手法は既知の攻撃ラベルを用いた教師あり学習を前提としており，未知の攻撃を想定した教師なし異常検知への適用は扱われていない．

こうした画像化の中で，入力データをどのように構成するかという設計選択は，異常検知性能に直接影響する要素でありながら，その影響について検証が行われることは少ない．特に CICFlowMeter に代表される標準的なフロー計測ツールは双方向通信のパケットを 1 つのフローとして集約する方式を採用している．しかしこの双方向集約という選択が教師なし異常検知の検出性能，とりわけ攻撃クラスごとの検出可否にどのような影響を与えるのかは十分に検証されていない．

統計的特徴量を用いた検知においては Camacho らが集約方向の違いが検出性能に影響を与えることを報告している [6]．しかし，この観点を画像化された系列表現の文脈で扱った研究は見当たらず，方向集約という設計選択が画像ベースの教師なし異常検知に与える影響は未解明のままである．

そこで，本研究では畳み込みオートエンコーダ (Conv-AE) を固定した条件下で，CIC-IDS2017 データセットを用いる．データセット内のフロー系列の集約方法のみを変化させ，そのフローを MTF で画像に変換して教師なし学習を行い，攻撃クラスごとの検出性能を比較する．

本論文の構成は次のとおりである．2 節で関連研究を整理し，本研究の位置づけを明確にする．3 節で実験設計を述べる．4 節で実験結果を示す．5 節で検出反転の機構を考察し，6 節で本研究をまとめる．

2. 関連研究

本節では，本研究に関連する従来研究について述べる．2.1 節では，トラフィックを画像化し教師なし学習によって異常を検知する手法について，2.2 節では，フローの方向集約が検出性能に与える影響を扱った研究について整理し，本研究の位置づけを明確にする．

2.1 画像化を用いた教師なし異常検知に関する関連研究

中前ら [4] はパケットヘッダのバイト列を画像化し，VAE(Variational AutoEncoder) により異常検知を行う手法を提案している．VAE は正常なトラフィックデータのみを学習し，学習済みの分布から外れるものに対して再構成誤差が大きくなるという性質を利用して，正常か異常かの判断を行っている．ただし，同手法は正常／異常の二値分類に留まり，検知した異常がどの攻撃種別に該当するかを特定できない．また，攻撃クラスによって検出性能に大きな差があり，著者ら自身の実験でも一部の攻撃で AUC 値 0.7 程度に留まっている．画像化の対象としてパケットヘッダのバイト列を用いる設計自体が，攻撃クラスごとの検出可否を左右する一因である可能性を示唆しているが，この点についてフロー構成の設計選択 (集約方向など) の観点からの検証は行われていない．

本研究も同様に，画像化と教師なし異常検知を組み合わせる枠組みに属するが，パケットヘッダのバイト列ではなくパケット長系列を MTF により画像化する点，および入力フローの構成 (集約方向) という設計選択に着目する点で異なる．

2.2 フロー方向・集約に関する関連研究

トラフィックのフロー化において広く用いられる CICFlowMeter[7] は，最初のパケットの送信元と宛先に基づいて，通信を順方向と逆方向に区別したうえで，両方向のパケットを 1 つのフローとして双方向集約する設計を採用している．Camacho ら [6] は，統計的特徴量に基づいた教師なし異常検知について，NetFlow の単方向集約と双方向集約という 2 種類のフロー生成方式を比較している．実験の結果，全体的な AUC は単方向集約の方が高い値を示した (MSNM で AUC 0.93 対 0.88，OCSVM で AUC 0.93 対 0.87) が，この差は主に DoS 攻撃に起因しており，単方向集約では DoS 攻撃が送信元ポートの特徴のみで明瞭に特徴づけられたのに対し，双方向集約では宛先ポートの特徴によって特徴づけられ，分離がやや不明瞭であった．一方で，

© 2026 Information Processing Society of Japan

NERISBOTNET 攻撃については双方向集約の方がわずかに高い検出性能を示すことも報告されており，Camacho らは，どちらの集約方向が有利かは攻撃の種類に依存すると結論づけている．しかし，同研究では深層学習を用いた画像ベースの異常検知への一般化可能性が検証されていない．

Camacho らの知見は，本研究の核心的な観察と符合する．すなわち，方向集約の選択によって検出しやすい攻撃クラスが変化するという現象は，統計的特徴量の領域において既に観察されていたことになる．しかし，Camacho らの検証は NetFlow ベースの統計的特徴量を対象としたものであり，画像化された系列表現の文脈でこの現象を扱った研究は見当たらない．画像化を用いた教師なし異常検知 (2.1 節) においては，フロー構成の設計選択，とりわけ方向集約が検出性能に与える影響は未検証のままである．

3. 提案手法

本節では，本研究で用いる手法について述べる．まず 3.1 節でパケットからフローを構成する方法を示し，3.2 節で構成したフローを画像へ変換する手順を述べる．続いて 3.3 節で，変換した画像を用いて異常を検知するモデルの構成について説明する．

3.1 データセットとフローの抽出

本研究では，送信元 IP アドレス・宛先 IP アドレス・送信元ポート番号・宛先ポート番号・プロトコル番号の組 (5-tuple) が一致するパケット群を 1 つの通信単位として扱い，これをフローと呼ぶ．フローは，開始から終端までの一連のパケットをひとまとまりとして扱うことで，個々のパケットではなく通信全体の振る舞いを特徴づけることを可能にする．

実験には，CIC-IDS2017 データセット [8] の月曜日から金曜日の 5 日分すべてを使用する．フロー分割の手法は，Engelen ら [9] が指摘した CICFlowMeter の終端判定の不具合を踏まえ，TCP フローについては双方向の FIN 交換または RST パケットの受信をもって終端とし，1 つのフローとする．これに加えて，120 秒のタイムアウトによる分割をもう 1 つの条件として追加する．フロー系列の単位には，ペイロードを持つパケット (payload length > 0) のみを用いる．この定義により，3way handshake や応答確認のみの ACK パケットは，TCP フラグの個別判定を要することなく自動的に除外される．系列長の下限は M=2 とし，これは MTF が成立するために必要な最小値である．

3.2 画像への変換方法

抽出したフロー系列は，線形補間を用いて固定長 S=16 に正規化した後，MTF(Markov Transition Field) によって画像化する．

MTF は，Wang and Oates によって提案された時系列の画像化手法である [10]．系列の値そのものではなく，値の遷移パターンを画像として表現する．長さ S の系列 $x = (x_1, x_2, \ldots, x_S)$ に対して，まず値の範囲を Q 個の分位点に基づくビンに分割し，各時点での値を対応するビンに割り当てる．次に，隣接する時点間でどのビンからどのビンに移動するかを集計し，行方向に正規化することで，ビン間の遷移確率を表す $Q \times Q$ のマルコフ遷移行列を得る．最後にこの遷移確率をもとの並びに沿って $S \times S$ の行列に展開する．すなわち，行列の各要素には，対応する 2 時点がそれぞれ属するビン間の遷移確率が割り当てられる．こうして得られる $S \times S$ の行列を，そのまま画像として扱う．



(a) 双方向　　(b) 送信方向のみ

図 1 MTF 画像の例 ((a) 双方向，(b) 送信方向のみ)

Fig. 1 Examples of MTF images ((a) bidirectional, (b) forward-only).

形式的には，各時点 x_i を対応するビン q_i に割り当てた後，ビン q_k からビン q_l への遷移回数を n_{kl} とすると，マルコフ遷移行列 $W = (w_{kl})$ は

$$w_{kl} = \frac{n_{kl}}{\sum_l n_{kl}}$$

により定義される．MTF 画像 M は，各要素を

$$M_{ij} = w_{q_i q_j}$$

とする $S \times S$ の行列である．

本研究では，この画像化の入力となるフロー系列の構成方法として，双方向 (bidirectional：送受信両方向のパケットを 1 系列として集約) と送信方向のみ (forward-only：送信元から宛先への方向のパケットのみを用いる) の 2 条件を設ける．系列長 S を 16 に統一しているため，生成される画像サイズは双方向・送信方向のみの両条件で 16×16 画素に統一される．変換例を図 1 に示す．

3.3 モデル構成

異常検知のためのモデルには畳み込みオートエンコーダ (Conv-AE) を用いる．Conv-AE は，Encoder で入力画像を低次元の表現に圧縮して，Decoder でその表現から元の画像を再構成するモデルである．Encoder は，ストライド 2 の畳み込み層 (Conv2d) を 3 層重ねた構成で，空間サイズを $16 \to 8 \to 4 \to 2$ と縮小しながら，チャネル数を $1 \to 16 \to 32 \to 64$ と増加させる．その後，特徴マップを Flatten し，全結合層により 128 次元の潜在変数に写像する．Decoder はこれと対称な構成であり，全結合層で潜在変数を 256 次元 ($64 \times 2 \times 2$) に写像した後，転置畳み込み

© 2026 Information Processing Society of Japan

層 (ConvTranspose2d，カーネルサイズ 4，ストライド 2，パディング 1) を 3 層重ねて元の 16×16 画素まで復元し，最終層に Sigmoid 関数を適用する．

学習には BENIGN(正常) ラベルのフローのみを用いて，入力画像と再構成画像との平均二乗誤差を損失関数として最小化する．この学習によって，Conv-AE は正常な通信の画像を再構成する方法を獲得する．一方，学習時に見ていないパターンの画像が入力された場合，正常パターン向けに最適化された圧縮・復元の仕組みではその特徴をうまくとらえられないため，入力画像と再構成画像にズレが生じる．本研究では，この入力画像と再構成画像との再構成誤差の大きさを異常度として用い，異常検知時には，学習済みの Conv-AE にテスト用の画像を入力して得られる再構成誤差が大きいほど，異常である可能性が高いと判断する．

4. 実験

本節では，3 節で述べた手法を用いた実験について述べる．4.1 節で実験に用いたパラメータや評価方法などの条件を示し，4.2 節でフロー系列の集約方向を変化させた際の検出性能の比較結果を示す．

4.1 実験条件

Conv-AE の実装には PyTorch を用いた．最適化手法には Adam を用い，学習率 1.0×10^{-3}，バッチサイズ 32，エポック数 50 で学習を行う．損失関数には，入力画像と再構成画像との平均二乗誤差 (MSE) を用いる．学習データには BENIGN(正常) ラベルのフローのみを使用し，攻撃を含むフローは一切学習に用いない．

各クラスの評価サンプル数には上限を設け，正常 (BENIGN) フローは 2,000 件，各攻撃クラスのフローは 500 件までを使用する．この上限は，計算資源の制約およびクラス間のサンプル数の偏りを抑えることを目的として設定したものである．該当するフロー数がこの上限に満たない場合は，実際に得られた件数をそのまま使用する．そのため，送信方向のみの条件における Bot(n=46) や DoS Hulk(n=12〜15) のように，上限を大きく下回るクラスが存在する．これらのクラスの AUROC は，サンプル数が少ないことによる推定誤差を含む参考値として扱う必要がある．

実験は，フロー系列の集約方向 (送信方向のみ／双方向) と，タイムアウトによる分割の有無 (あり／なし) を組み合わせた 2×2 の実験マトリクスに基づいて行う．各条件について，CIC-IDS2017 に含まれる 14 の攻撃クラスそれぞれの AUROC を算出する．また，結果の再現性を検証するため，5 つの異なる seed 値 (42〜46) で実験を繰り返し，AUROC の平均値と標準偏差を報告する．ただし，双方向・タイムアウト分割ありの条件における seed=44 の試行は，学習が安定せず他の seed 値と大きく異なる結果を示したため，外れ値として平均および標準偏差の算出から除外した．

表 1 主要 4 クラスの AUROC(送信方向のみ，seed 平均 ± 標準偏差)

Table 1 AUROC for four key classes (forward-only, mean ± std over seeds).

クラス	timeout	no timeout
Bot*	0.914±0.006	0.911±0.004
DDoS*	—	0.729±0.016
GoldenEye	0.127±0.006	0.162±0.077
Hulk*	0.212±0.005	0.572±0.071

* 使用可能フロー数が上限を大きく下回るため参考値 (Bot: n=46, DDoS: n=3，Hulk: n=12〜15).

表 2 主要 4 クラスの AUROC(双方向，seed 平均 ± 標準偏差)

Table 2 AUROC for four key classes (bidirectional, mean ± std over seeds).

クラス	timeout	no timeout
Bot	0.543±0.013	0.425±0.016
DDoS	0.713±0.007	0.586±0.008
GoldenEye	0.652±0.008	0.534±0.010
Hulk	0.826±0.010	0.709±0.008

4.2 全体結果

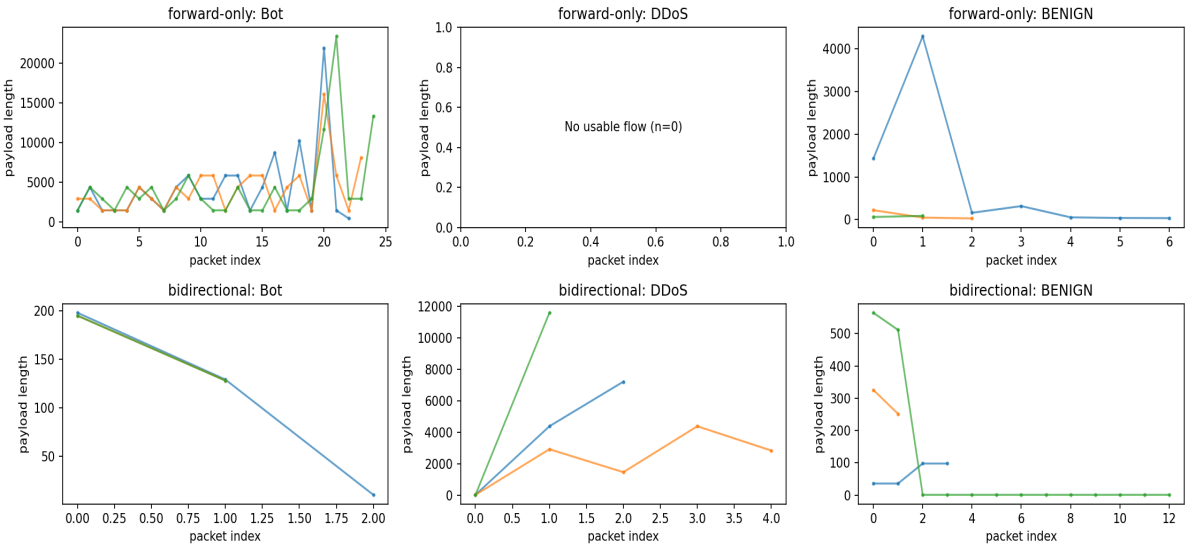
4.1 節で述べた 2×2 の実験マトリクスについて，各クラスの AUROC の平均値と標準偏差を算出した．14 の攻撃クラスすべてについて算出を行ったが，紙面の都合上，本節では方向集約による検出性能の差が顕著に現れた Bot，DDoS，DoS GoldenEye，DoS Hulk の 4 クラスに焦点を当てて結果を述べる．なお，PortScan は IP アドレスペア単位での集約が本質的に必要な攻撃であり，本研究のフロー単位の粒度では正当な評価が難しいため，本節の議論の対象からは除外する．

表 1 に送信方向のみ (forward-only)，表 2 に双方向 (bidirectional) の結果をそれぞれ示す．なお，表 1 の DDoS におけるタイムアウト分割ありの条件は，使用可能なフローが 0 件であったため測定不能であり，「—」と表記している．

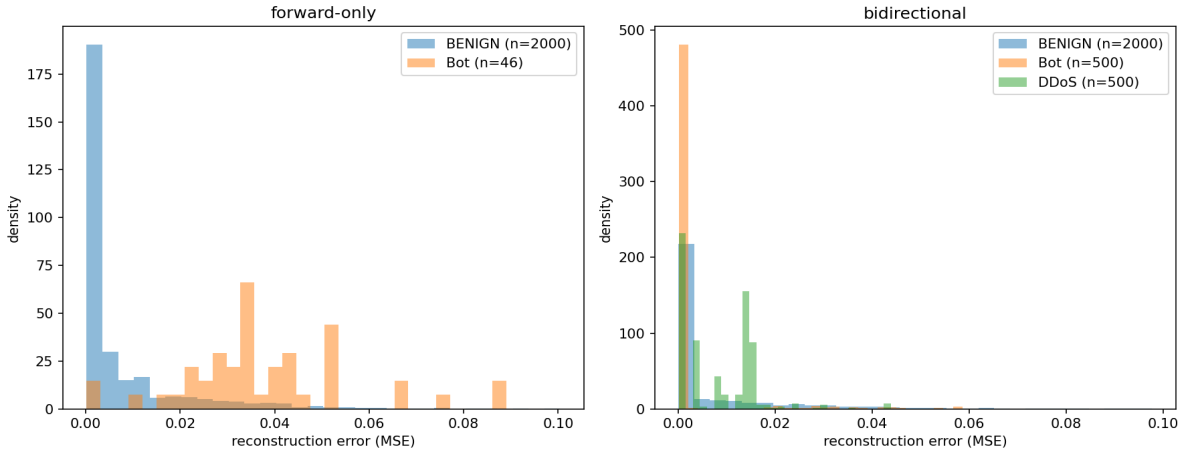
Bot は，送信方向のみの表現においてタイムアウトによる分割の有無によらず AUROC 0.91 前後の高い検出性能を示す一方，双方向表現では AUROC が 0.42〜0.54 まで低下する．これとは対照的に，DDoS は送信方向のみのタイムアウト分割条件では使用可能なフローが 0 件となり測定自体が不能であったのに対し，双方向表現では AUROC 0.59〜0.71 の検出性能を示した．

これと同様の傾向を示したのが DoS GoldenEye であり，送信方向のみでは AUROC 0.13〜0.16 と低い値に留まる一方，双方向表現では AUROC 0.53〜0.65 まで改善する．DoS Hulk は，送信方向のみの条件では使用可能なフロー数が極端に少なく (n=12〜15) 参考値に留まるのに対し，

© 2026 Information Processing Society of Japan



(a) 代表的な系列例



(b) 再構成誤差の分布

図 2 送信方向のみと双方向の比較 ((a) 代表的な系列例，(b) 再構成誤差の分布)

Fig. 2 Comparison between forward-only and bidirectional aggregation.

双方向表現では十分なフロー数 (n=500) のもとで AUROC 0.71〜0.83 という安定した検出性能が得られている．

以上より，フロー系列の集約方向によって，検出しやすい攻撃クラスが明確に入れ替わる現象が確認された．本稿では，集約方向の変更によって攻撃クラスごとの検出性能の優劣が入れ替わるこの現象を，総称して検出反転と呼ぶ．標準偏差はいずれのクラス・条件においても 0.02 未満 (GoldenEye の送信方向のみ・タイムアウト分割なしの条件のみ 0.077) であり，この反転が特定の乱数初期値に依存する偶然の結果ではないことを示している．また，この反転は Bot・DDoS という対照的な 2 クラスに限らず，GoldenEye や Hulk といった他の DoS 系攻撃クラスにも一貫して現れており，特定の攻撃ペアに限定された現象ではないことが確かめられた．

また，本実験のもう一方の軸であるタイムアウト分割の有無についても，検出性能に無視できない影響が認められた．特に DoS Hulk では，送信方向のみの条件において AUROC が 0.212(分割あり) から 0.572(分割なし) へと大きく変化しており，方向集約と同程度の影響を及ぼしている．この結果は，フローの境界をどこに定めるかという設計選択もまた，検出性能を左右する要因であることを示唆している．

5. 考察

本節では，4 節で得られた結果について考察する．5.1 節で検出反転が生じる機構を分析し，5.2 節で AUROC が 0.5 を下回る現象について述べる．続いて 5.3 節で送信方向のみの表現に付随する構造的な制約を，5.4 節で本研究の評価における制約をそれぞれ述べる．

5.1 検出反転について

4 節で述べた検出反転がなぜ生じるのかを，攻撃のパター

© 2026 Information Processing Society of Japan

ンとフロー構成の点から分析する．図 2(a) に，送信方向のみと双方向それぞれにおける Bot・DDoS・BENIGN の代表的な系列例を，図 2(b) に，両条件における再構成誤差の分布を示す．

Bot は C&C サーバへの定期的な小サイズの HTTP リクエストという，周期性の高い通信パターンを特徴とする．図 2(a) の送信方向のみの条件の Bot 系列では，値の増減を繰り返す規則的なジグザグパターンが確認できる．この周期的なリクエストの並びがそのままパケット長系列として保存されるため，正常な通信とは異なる特徴的な MTF 画像が生成される．図 2(b) 左図が示すように，送信方向のみの条件では正常 (BENIGN) と Bot の再構成誤差分布が明確に分離している．一方，双方向表現では，送信方向のリクエストに加えて応答方向のパケットが系列に混入している．図 2(a) の双方向条件の Bot 系列では，送信方向のみの条件で見られた周期性が失われ，短く単調な系列となっている．この結果，図 2(b) 右図に示すように，双方向条件では正常と Bot の誤差分布がほぼ重なり，区別が困難になっていることがわかる．

DDoS で用いられる LOIC ツールは，1 回のリクエストごとに新しいコネクションを確立するという特性を持つ．この結果，送信方向のみの表現では，大半の DDoS フローが単一パケットのみで構成される系列長 1 のフローとなる．図 2(a) の送信方向のみの条件の DDoS 欄が空欄であることは，この条件下で DDoS の使用可能なフローが 1 件も存在しなかったことを示している．本研究では，MTF が数学的に成立するための最小系列長を M=2 としているため，系列長 1 のフローはこの時点でフィルタにより除外され，学習・評価データとして利用できない．すなわち，送信方向のみの条件で DDoS が検出できないのは，画像上のパターンが不明瞭だからではなく，そもそも評価可能なフローが構造的に生成されないためである．

これに対し，双方向表現では，攻撃対象サーバからの応答パケットが系列に追加されるため，系列長が 2 以上となり，フィルタを通過できるようになる．図 2(a) の双方向条件の DDoS 系列では，複数パケットにわたる変動が確認できる．図 2(b) 右図においても，双方向条件では DDoS の誤差分布が正常から明確に分離しており，検出可能になっていることが確認できる．したがって，双方向表現において DDoS が検出可能になるのは，攻撃の特徴的なパターンが可視化されるためというよりも，評価可能なフローがそもそも存在するようになるという，より構造的な要因によるものと考えられる．

5.2 AUROC が 0.5 を下回る現象について

表 1 に示したとおり，送信方向のみの条件における DoS GoldenEye と DoS Hulk の AUROC は，それぞれ 0.13 前後および 0.21 前後と，ランダムな判定に相当する 0.5 を大きく下回っている．AUROC が 0.5 を下回ることは，単に検出性能が低いことを意味するのではなく，攻撃フローの再構成誤差が正常フローの再構成誤差よりも小さいという，異常度の逆転が生じていることを意味する．

この逆転は，これらの攻撃の通信パターンと MTF 画像の性質によって説明できる．GoldenEye や Hulk は，同一のリクエストを反復して送信することを特徴とする．送信方向のみの表現ではこの反復がそのまま系列に現れるため，値の変動に乏しい系列となり，変換後の MTF 画像も単調で規則的な構造をとる．一方，学習に用いた BENIGN は多様な通信を含んでおり，その MTF 画像は相対的に複雑である．その結果，Conv-AE は正常データよりもこれらの攻撃の画像をむしろ容易に再構成できてしまい，異常度が逆転したと考えられる．

この現象は，再構成誤差に基づく異常検知が学習データの複雑さと入力の複雑さの相対関係に依存することを示している．これは，表現の設計が検出可能性を左右するという本研究の主張をさらに裏付けるものである．

5.3 送信方向のみの表現におけるフロー終端の構造的制約

3.1 節で述べたフロー終端の定義 (双方向の FIN 交換または RST パケットの受信) は，双方向表現を前提とした定義である．送信方向のみの系列を扱う場合，応答方向のパケット (したがって応答方向の FIN) はそもそも観測されないため，送信方向のみのフローは，双方向の FIN 交換によって終端することが構造的にあり得ず，RST パケットの受信か，120 秒のタイムアウトによってのみ終端する．この制約は，送信方向のみの表現を採用した際に付随する構造的な性質である．すなわち，実装上の不具合ではなく，方向集約という設計選択そのものが持つ副次的な影響として理解すべきものである．

5.4 評価における制約

本研究の評価には，サンプル数に関する制約が存在する．集約方向の変更はフローの生成数そのものを変化させるため，同一の攻撃クラスであっても条件間で使用可能なフロー数が大きく異なる．例えば Bot は，送信方向のみの条件では n=46 であるのに対し，双方向条件では n=500 と 10 倍以上の差がある．

このサンプル数の変動自体は，実装上の不備によるものではなく，方向集約という設計選択が何を評価可能にするかという本研究の主題そのものの現れである．一方で，評価指標の信頼性という観点からは注意が必要である．本研究で報告した標準偏差は，seed 値の変動に対する結果の安定性を示すものであり，サンプル数の少なさに起因する推定誤差を反映したものではない．したがって，n=46 や n=12〜15 といった少数サンプルのクラスについては，より大規模な評価による確認が必要である．

© 2026 Information Processing Society of Japan

6. まとめと今後の課題

本節では，本研究で得られた結果をまとめるとともに，残された課題について述べる．

6.1 まとめ

本研究では，Conv-AE を用いてフロー系列の集約方向という表現上の設計選択のみを変化させ，CIC-IDS2017 データセットを用いて攻撃クラスごとの検出性能を比較した．実験の結果，送信方向のみの表現では Bot 攻撃が高精度で検出される反面，DDoS 攻撃は構造的に検出不能となった．一方，双方向表現ではこれが反転し，DDoS 攻撃が検出可能になる代わりに Bot の検出精度が大きく低下するという，表現依存の検出反転を確認した．この反転は 5 つの異なる seed 値にわたって再現性のある現象であり，GoldenEye や Hulk といった他の DoS 攻撃にも一貫して観察された．さらに，この反転の背後にある機構を分析し，Bot の検出反転が通信の周期性の希釈という質的な要因に起因する一方，DDoS の検出反転は LOIC ツールの通信特性に由来する系列長フィルタの構造的な通過可否という，より根本的な要因に起因することを明らかにした．これらの結果は，フロー系列の集約方向という設計選択が，単なる前処理上の些末な違いではなく，検出可能な攻撃クラスを構造的に決定する要因であることを示している．

6.2 今後の課題

本研究にはいくつかの課題が残されている．第一に，本研究では系列長を S=16 に固定しており，展開比 $r = S/L$(L は元の系列長) を系統的に変化させた場合に検出性能がどう変わるかは未検証である．第二に，本研究はパケット長系列のみを画像化の対象としており，到着間隔 (IAT) 等の他の特徴量や，MTF 以外の画像化手法 (GAF，RP 等) との組み合わせによる改善の余地が残されている．第三に，実験は CIC-IDS2017 データセットに限定されており，InSDN 等の異なるネットワーク環境のデータセットを用いて，本研究で確認された検出反転がより一般的な現象であるかを検証する必要がある．

参考文献

[1] 独立行政法人情報処理推進機構 (IPA)：情報セキュリティ 10 大脅威 2026(online), https://www.ipa.go.jp/security/10threats/10threats2026.html (2026.01.29).

[2] Wang, Z.: The Applications of Deep Learning on Traffic Identification, *Black Hat USA* (2015).

[3] Zhao, R., Zhan, M., Deng, X., Wang, Y., Wang, Y., Gui, G. and Xue, Z.: Yet Another Traffic Classifier: A Masked Autoencoder Based Traffic Transformer with Multi-Level Flow Representation, *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol.37, No.4, pp.5420–5427 (2023).

[4] 中前諒哉，青木茂樹，宮本貴朗：VAE を用いたネットワークトラフィックの異常検出，コンピュータセキュリティシンポジウム *2021* 論文集，pp.551–558 (2021).

[5] Joshi, P. and Kantarci, B.: Time Series Based Network Intrusion Detection using MTF-Aided Transformer, arXiv:2508.16035 (2025).

[6] Camacho, J., Wasielewska, K., Espinosa, P. and Fuentes-García, M.: Quality In / Quality Out: Data Quality More Relevant Than Model Choice in Anomaly Detection with the UGR'16, *NOMS 2023 IEEE/IFIP Network Operations and Management Symposium*, pp.1–5 (2023).

[7] Draper-Gil, G., Lashkari, A. H., Mamun, M. S. I. and Ghorbani, A. A.: Characterization of Encrypted and VPN Traffic using Time-related Features, *Proceedings of the 2nd International Conference on Information Systems Security and Privacy (ICISSP 2016)*, pp.407–414 (2016).

[8] Sharafaldin, I., Habibi Lashkari, A. and Ghorbani, A. A.: Toward Generating a New Intrusion Detection Dataset and Intrusion Traffic Characterization, *Proceedings of the 4th International Conference on Information Systems Security and Privacy (ICISSP 2018)*, pp.108–116 (2018).

[9] Engelen, G., Rimmer, V. and Joosen, W.: Troubleshooting an Intrusion Detection Dataset: the CICIDS2017 Case Study, *2021 IEEE Security and Privacy Workshops (SPW)*, pp.7–12 (2021).

[10] Wang, Z. and Oates, T.: Imaging Time-Series to Improve Classification and Imputation, *Proceedings of the 24th International Joint Conference on Artificial Intelligence (IJCAI 2015)*, pp.3939–3945 (2015).

© 2026 Information Processing Society of Japan