構造化パケット表現を用いた教師なし NIDS における Z-Score に基づく異常根拠の可視化

青木 茂樹[1,a)]　宮本 貴朗[1]

概要：本研究では，教師なし深層 NIDS においてアナリストの一次スクリーニング（Triage）を支援する異常根拠可視化手法を提案する．パケット属性を 32 パケット単位で構造化した特徴行列を入力とし，正常通信のみで学習した深層再構成モデル（AE，VAE，GM-VAE）の再構成誤差に基づき異常を検知する．さらに，正常トラフィックの誤差統計量による Z-Score 正規化とゼロクランプ処理により背景ノイズを消去し，異常発生タイミングおよび変調された属性を 2 次元ヒートマップとして可視化する．UNSW-NB15 データセットによる評価において，攻撃比率 4.77% の不均衡トラフィック下で PR-AUC 0.4290 を達成した．またプロファイル類似度解析により，単一時間窓の静的自動判定の限界を示すとともに，時間軸に沿った 2 次元可視化により過渡的な異常変調属性（Root Cause）を明示する本手法の有効性を実証した．

キーワード：ネットワーク侵入検知システム（NIDS），異常根拠の可視化，教師なし深層学習，Z-Score 正規化，説明可能 AI

Z-Score-Based Visualization of Anomaly Evidence for Unsupervised NIDS Using Structured Packet Representation

Shigeki Aoki[1,a)]　Takao Miyamoto[1]

Abstract: In this study, we propose an anomaly evidence visualization method for unsupervised deep Network Intrusion Detection Systems (NIDS) to support first-stage triage by security analysts. The proposed method inputs a structured feature matrix, created by chronologically arranging protocol attributes in 32-packet units, into reconstruction models (AE, VAE, GM-VAE) trained exclusively on benign traffic. By applying Z-score normalization to the reconstruction errors using benign error statistics and applying a zero-clamping operation to eliminate background noise, it visualizes anomaly occurrence timing and anomalous protocol attributes on 2D heatmaps. Evaluated on the UNSW-NB15 dataset, the proposed method achieved a PR-AUC of 0.4290 in a highly imbalanced traffic environment with a 4.77% attack ratio. Furthermore, profile similarity analysis demonstrated the limitations of static single-window classification, while highlighting the usefulness of the proposed framework in visually identifying transient anomaly attributes (root cause) along the time axis.

Keywords: Network Intrusion Detection System (NIDS), Visualization of Anomaly Evidence, Unsupervised Deep Learning, Z-Score Normalization, Explainable AI (xAI)

1. はじめに

近年，ネットワークトラフィックの爆発的な増加と通信プロトコルの複雑化に伴い，サイバー攻撃の技術も巧妙化の一途をたどっている．特に，従来のルールベースや署名（シグネチャ）に基づく侵入検知システム（NIDS: Network Intrusion Detection System）では対応が困難な未知の脅威（ゼロデイ攻撃）への対策として，機械学習および深層学習技術を応用した侵入検知システムの研究が盛んに行わ

[1] 大阪公立大学 大学院情報学研究科
Graduate School of Informatics, Osaka Metropolitan University
[a)] aoki@omu.ac.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

れている [1], [2]．なかでも，正常な通信トラフィックの挙動のみを学習し，そこからの逸脱を異常として検知する教師なし（Unsupervised）深層学習アプローチは，事前ラベルの付与が不要であり未知攻撃への追従性に優れる点から注目を集めている [3], [4].

しかしながら，Autoencoder（AE） [5] や変分オートエンコーダ（VAE: Variational Autoencoder） [6] などの深層再構成モデルを応用した従来の教師なし NIDS の多くは，入力データ全体に対して統合された 1 つの異常度スコア（再構成誤差など）を出力するのみであり，具体的な異常発生要因を明示できない点が課題となっている．このようなブラックボックス型の出力は，セキュリティ運用センター（SOC: Security Operations Center）等の実運用環境において，セキュリティアナリストに対して『なぜ異常と判定されたのか』『どのプロトコル属性にどのような変調が生じているのか』という判断根拠を提供できない.

侵入検知における説明可能 AI（xAI: Explainable AI）のアプローチとして，SHAP [7] や LIME [8] に代表されるモデル非依存の事後型（Post-hoc）説明手法の適用が検討されている．しかし，これらの手法は 1 サンプルの説明出力を得るために入力特徴量に対する多数回の摂動計算とモデル推論を反復要求し，計算コストが増大する [9] ため，ギガビット級のトラフィック処理が要求されるインライン NIDS 環境への適用は困難である [1], [2]．また，実運用の一次スクリーニング（First Triage）段階においては，不確実な攻撃種別の自動分類結果よりも，異常なヘッダー属性や発生時刻といった『異常発生根拠（Root Cause)』の迅速な可視化が強く求められている.

そこで本研究では，従来の Post-hoc 型 xAI 手法に代わり，追加の計算オーバーヘッドをほぼ発生させずに判断根拠を可視化する一次スクリーニング型 xAI アプローチを提案する．具体的には，パケットヘッダーの構造的属性を時系列配置した 32 パケット単位の構造化特徴行列（F_{feat32}）を入力とし，正常通信のみを学習した Autoencoder 系モデルの再構成誤差を対象とする Z-Score プロファイリング手法を構築する．本手法は，正常通信の統計量（平均 μ_j^{sum} および標準偏差 σ_j^{sum}）に基づいて再構成誤差を正規化し，定常通信に由来する誤差のゆらぎ（背景ノイズ）をクリッピング処理により消去（クランプ化）することで，異常発生のタイムライン（時間軸）と変調が生じたプロトコル属性（特徴量軸）を 2 次元ヒートマップとして可視化する.

UNSW-NB15 データセット [10] を用いた評価を通じて，本研究では以下の知見および成果を得た．まず，正常統計量 $(\mu_j^{\text{sum}}, \sigma_j^{\text{sum}})$ に基づく Z-Score プロファイルにより背景ノイズを消去することで，異常変調属性を特定可能な軽量な一次スクリーニング基盤を確立した．次に，Plain AE, Standard VAE, および Gaussian Mixture VAE (GM-VAE) [11] の 3 つの深層モデルにおいて高い異常検知性能を確認し，潜在空間や確率的定式化が異なる再構成モデル間においても一貫した Z-Score 根拠可視化が可能であることを実証した．さらに，プロファイル類似度解析から単一時間窓のみでは攻撃種別間の属性類似度が高く自動識別が困難であることを示した上で，1 行単位の静的判定ではなく，プロファイル列を時間軸方向へ展開した 2 次元ヒートマップにより過渡的な異常変調属性（Root Cause）をアナリストへ視覚提示する本手法の設計妥当性を実証した.

2. 関連研究

本研究の基盤となる教師なし深層 NIDS，侵入検知における説明可能 AI（xAI）の動向，および本研究の位置づけについて述べる.

2.1 教師なし深層学習に基づく侵入検知システム

ネットワークトラフィックにおける未知の脅威を検知するため，教師なし深層学習を用いた NIDS の研究が多数提案されている [3], [4]．これらには，多次元データや時系列の異常検知基盤として提案された Autoencoder（AE） [5]，Variational Autoencoder（VAE） [6]，およびガウス混合分布を潜在空間に導入した Gaussian Mixture VAE（GM-VAE） [11] などの深層再構成モデルを NIDS へ応用するアプローチが含まれる．これらの手法は，正常通信のみを入力として受け入れ，入力データを潜在空間へ圧縮・復元する過程で得られる再構成誤差（Reconstruction Error）を異常度スコアとして利用する.

しかし，従来の多くの手法は 1 パケットまたは集約されたフロー統計量を独立して扱うため，時間方向の細かな相関（パケットシーケンスとしてのバースト性や連続的な変調）を十分に獲得できない課題があった．これに対し本研究では，パケットヘッダーの構造的属性を 32 パケット単位の時系列行列として構成した構造化特徴表現 F_{feat32} を導入し，時間軸と特徴量軸の双方における相関構造を保持させた状態でモデルへ入力するアーキテクチャを採用する.

2.2 NIDS における説明可能 AI（xAI）の動向と課題

NIDS の出力に対する説明可能性（Explainability）を高めるため，xAI 手法を導入するアプローチが注目されている [9]．SHAP [7] や LIME [8] といったモデル非依存の事後型説明手法（Post-hoc xAI）は，モデルの内部構造に依存せず局所的な特徴量寄与度（Feature Attribution）を算出できるため，教師あり分類モデルの根拠提示として広く利用されてきた.

しかし，これらの事後型（Post-hoc）xAI 手法，および従来の再構成誤差に基づく可視化手法をリアルタイム NIDS へ適用するには，実運用上の課題が存在する．第一に，Post-hoc xAI 手法は 1 サンプルの寄与度計算のために数

© 2026 Information Processing Society of Japan

千回の推論処理を反復実行する必要があり，構造的に大きな推論遅延（Latency）が発生する点である [9]．これは，ミリ秒単位の極めて低い遅延が要求される高速なリアルタイムネットワーク監視環境においてボトルネックとなる [1], [2]．第二に，再構成誤差をそのまま出力する従来の可視化手法では，正常通信に由来する微小ノイズ（誤差のばらつき）が全特徴量へ広範に散乱するため，可視化における S/N 比（コントラスト）が著しく低下し，アナリストが真の変調属性を見極めにくくなる点である．

2.3 本研究の位置づけと独自性

本研究で提案する Z-Score xAI プロファイリングは，既存の事後型 xAI 手法および従来の再構成誤差可視化手法とは異なるアプローチを採用している．

具体的には，構造化特徴行列 $F_{\text{feat32}} \in \mathbb{R}^{32\times32}$ の各要素における再構成誤差 $e_{t,j} = |x_{t,j} - \hat{x}_{t,j}|$ を 32 パケット単位で属性 j ごとに集約した誤差総和 $E_{k,j} = \sum_{t=1}^{32} e_{t,j}$ に対し，正常学習データから事前に算出した属性 j ごとの平均 μ_j^{sum} および標準偏差 σ_j^{sum} を用いて Z-Score 正規化を行う．この処理は，正常時のゆらぎに由来する負の Z-Score 値を 0 へクランプ（Zero-Clamping）して背景ノイズを消去する．これにより，モデル推論後の事後的な反復計算を伴わず，追加の計算オーバーヘッドをほぼ発生させずに（Near-Zero Overhead），S/N 比の高い異常スパイクとして変調属性を視覚提示する．

本手法は事前の攻撃ラベルに依存した自動分類を行うものではなく，アナリストによる一次スクリーニング支援に特化している点が，従来の分類・可視化アプローチとは大きく異なる．

3. Z-Score プロファイリングによる異常根拠の可視化

Z-Score プロファイリングに基づく一次スクリーニング型 xAI 手法について述べる．図 1 に本手法の全体処理フローを示す．本手法は，パケットヘッダーの構造的属性を保持した構造化特徴行列 F_{feat32} の構築，正常通信のみを用いた教師なし深層モデルの学習，および正常統計量に基づく再構成誤差の Z-Score プロファイリングと 2 次元ヒートマップ生成の 3 つのフェーズから構成される．

3.1 構造化パケット表現 F_{feat32} の構築

本研究では，個別の通信フローが完結する前の初期段階において攻撃兆候を早期に捕捉することを目的とし，時間的な統計集約は行わず，PCAP データから監視対象の内部サーバーサブネットを宛先とする IPv4 の TCP および UDP パケットのみを抽出する．抽出後，送信元・宛先 IP アドレスの組み合わせ（ホストペア）ごとにパケット系列を分類し，時系列順に 32 パケットを 1 単位として 32×32

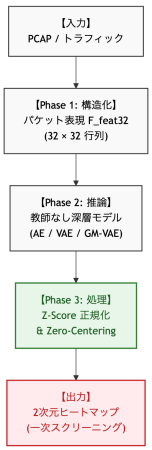


図 1: Z-Score プロファイリングに基づく一次スクリーニングの全体処理フロー．

Fig. 1 Overall pipeline of the proposed Z-Score profiling framework for first-stage screening.

の構造化特徴行列 $F_{\text{feat32}} \in \mathbb{R}^{32\times32}$ へマッピングする．実運用においては，ホストペアごとのパケット系列を 32 パケット単位で逐次特徴行列へ変換し，一次スクリーニング処理へ投入することを想定している．

時間軸方向の単位を 32 パケットに設定した理由は，通信初期の不審なバーストを低遅延で捕捉するリアルタイム性の確保，列方向（32 属性）と同スケールに設定することで時間遷移と属性相関の対等な学習を可能とする表現空間の平衡，および並列計算時のメモリ効率最適化（$2^5 = 32$）に基づく．

具体的には，L3（IPv4 IHL，全長，TTL，IP フラグ等），L4（プロトコル，宛先ポート，TCP フラグ，ウィンドウサイズ等），およびパケット間隔（IAT）やペイロード長等から構成される計 32 のデータ項目（表 1）を各パケットから抽出する．これらをドメイン知識に基づいて横方向（列属性 $j \in \{1,\ldots,32\}$）に配置し，これを時系列順に 32 パケット分（行インデックス $t \in \{1,\ldots,32\}$）並べることで，$F_{\text{feat32}} \in \mathbb{R}^{32\times32}$（各要素を $x_{t,j}$ とする）を構成する．F_{feat32} を導入することにより，モデルは単一パケットの属性値だけでなく，パケットシーケンス間の過渡的な状態変化とプロトコル属性間の相互依存関係を保持した状態で再構成学習を行うことが可能となる．

3.2 教師なし深層モデルによる再構成学習

構築した $F_{\text{feat32}} \in \mathbb{R}^{32\times32}$ を入力とし，正常通信トラフィックのみを用いてモデルの学習を行う．本研究では，提案手法の多様な再構成アーキテクチャに対する適用可能性を検証するため，以下の 3 つの教師なし深層モデルを対象とする．

Autoencoder (AE): Plain AE は，エンコーダ f_θ により入力 F_{feat32} を低次元の潜在ベクトル $z \in \mathbb{R}^k$

© 2026 Information Processing Society of Japan

表 1: 構造化特徴表現 F_{feat32} における抽出特徴量一覧（全 32 次元）
Table 1 List of extracted features in the structured feature representation F_{feat32} (32 dimensions in total).

列番号	特徴量名	抽出値・正規化処理 ($v[j]$)	列番号	特徴量名	抽出値・正規化処理 ($v[j]$)
0	IP IHL	$\min(60, \text{IHL})$	16	TCP Flag PSH	PSH フラグ: 255 / 0
1	IP Total Length	$\min(4095, \text{Length})/16$	17	TCP Flag URG	URG フラグ: 255 / 0
2	IP ToS	ToS $\in [0, 255]$	18	TCP Flag CWR/ECE	CWR/ECE フラグ: 255 / 0
3	IP TTL	TTL $\in [0, 255]$	19	Invalid Flags	不正フラグ結合: 255 / 0
4	IP Flag DF	Don't Fragment: 255 / 0	20	TCP Header Length	$\min(60, \text{Hlen})$
5	IP Flag MF	More Fragments: 255 / 0	21	TCP Option Length	$\min(40, \text{OptLen}) \times 6.3$
6	IP Fragment Offset	$\min(8191, \text{Offset})/32$	22	Urgent Pointer	$\min(65535, \text{UrgPtr})/257$
7	Protocol Number	プロトコル番号 (6, 17, 1 等)	23	SYN-ACK Flag	SYN+ACK 双方セット: 255 / 0
8	Destination Port	DstPort/256	24	Direction Flag	パケット送受信方向: 255 / 0
9	Frame Length	$\min(1600, \text{FrameLength})/6$	25	Inter-Arrival Time	$\min(6.0, \ln(1+\Delta t)) \times (255/6)$
10	Is TCP Flag	TCP 識別: 255 / 0	26	Payload Length	$\min(1500, \text{PayloadLen})/6$
11	Is UDP Flag	UDP 識別: 255 / 0	27	Small Payload Flag	小サイズ判別 ($<$ 32B): 255 / 0
12	TCP Flag SYN	SYN フラグ: 255 / 0	28	Large Payload Flag	大サイズ判別 ($>$ 512B): 255 / 0
13	TCP Flag ACK	ACK フラグ: 255 / 0	29	ACK Number LSB	ACK mod 256
14	TCP Flag FIN	FIN フラグ: 255 / 0	30	Window Size (Lin)	Win/257
15	TCP Flag RST	RST フラグ: 255 / 0	31	Window Size (Log)	$\min(12.0, \ln(1+\text{Win})) \times (255/12)$

($k \ll 32 \times 32$) へ圧縮したのち，デコーダ g_ϕ を用いて再構成表現 $\hat{F}_{\text{feat32}} = g_\phi(z)$ を生成する．学習は，入力と再構成像の間の平均二乗誤差（MSE）に基づく以下の損失関数 $\mathcal{L}_{\text{AE}}$ を最小化することで行う：

$$\mathcal{L}_{\text{AE}}(\theta, \phi) = \frac{1}{32 \times 32} \| F_{\text{feat32}} - \hat{F}_{\text{feat32}} \|_F^2 \tag{1}$$

ここで $\| \cdot \|_F$ はフロベニウスノルムを表し，全要素に対する二乗誤差和と同値である．

Variational Autoencoder (VAE): Standard VAE では，潜在空間に標準正規分布 $\mathcal{N}(0, I)$ の事前分布を仮定し，入力 $X = F_{\text{feat32}}$ に対する潜在変数 z の変分事後分布 $q_\phi(z|X)$ をモデル化する．損失関数は，再構成誤差項と Kullback-Leibler (KL) ダイバージェンス項の和で構成される変分下限（ELBO）の負値として次式で定義される：

$$\mathcal{L}_{\text{VAE}}(\theta, \phi) = \mathbb{E}_{q_\phi(z|X)} \left[\| X - \hat{X} \|_F^2 \right] + D_{\text{KL}}(q_\phi(z|X) \parallel p(z)) \tag{2}$$

Gaussian Mixture VAE (GM-VAE): 正常通信内に存在する多種多様なプロトコル挙動（HTTP, DNS, SSH 等のマルチモーダル性）を高精度に近似するため，GM-VAE では潜在空間に K 個のコンポーネントからなるガウス混合分布（GMM）を導入する．連続潜在変数 z に加え，クラスタ割当を表す離散潜在変数 $y \in \{1, \ldots, K\}$ を導入し，事前分布を $p(z, y) = p(z|y)p(y)$ と定式化する．損失関数 $\mathcal{L}_{\text{GM-VAE}}$ は以下のように評価される：

$$\begin{aligned} \mathcal{L}_{\text{GM-VAE}}(\theta, \phi) = \mathbb{E}_{q_\phi(z,y|X)} \left[\| X - \hat{X} \|_F^2 \right] \\ + D_{\text{KL}}(q_\phi(z, y|X) \parallel p(z, y)) \end{aligned} \tag{3}$$

これにより，潜在空間内での正常通信の多峰性分布を許容し，複雑な正常トラフィックに対する誤検知（偽陽性）の抑止を図る．

3.3 Z-Score 正規化に基づく異常根拠プロファイリング

テスト時において，入力 F_{feat32} に対するモデルの復元出力 $\hat{F}_{\text{feat32}}$ が与えられたとき，各要素 (t, j) ($t, j \in \{1, \ldots, 32\}$) における未加工の再構成誤差（Raw Reconstruction Error）$e_{t,j}$ を算出する：

$$e_{t,j} = |x_{t,j} - \hat{x}_{t,j}| \tag{4}$$

未加工の再構成誤差 $e_{t,j}$ をそのまま可視化した場合，正常通信であってもモデルの復元誤差（ゆらぎノイズ）が全属性に散乱し，アナリストによる真の変調属性の特定が困難となる．この課題を解決するため，1 画像ブロック（32 パケット）単位で属性 j ごとの誤差総和 $E_{k,j}$ を算出し，正常学習データから事前に算出した誤差総和の平均 μ_j^{sum} および標準偏差 σ_j^{sum} を用いて Z-Score 正規化を行う．

ブロック k における属性 j の集約誤差 $E_{k,j}$ を，

$$E_{k,j} = \sum_{t=1}^{32} e_{t,j} \tag{5}$$

と定義したとき，正常ゆらぎ領域（$E_{k,j} \leq \mu_j^{\text{sum}}$）を 0 へクリッピングする Z-Score 異常プロファイルスコア $Z_{k,j}$ を以下のように定式化する：

$$Z_{k,j} = \max\left(0, \frac{E_{k,j} - \mu_j^{\text{sum}}}{\sigma_j^{\text{sum}} + \epsilon}\right) \tag{6}$$

ここで $\epsilon = 10^{-8}$ はゼロ除算防止定数である．

式 (6) における $\max(0, \cdot)$ 演算（ReLU 型クリッピング）の導入は，教師なし再構成モデルにおける異常の性質に基づいている．正常通信のみを学習したモデルに異常通信（未学習のプロトコル変調）が入力された場合，再構成誤差の和 $E_{k,j}$ は正常時の平均 μ_j^{sum} を超過する方向（正の偏差: $E_{k,j} > \mu_j^{\text{sum}}$）へ伸長する．一方，$E_{k,j} \leq \mu_j^{\text{sum}}$ となる

© 2026 Information Processing Society of Japan

負の偏差領域（$Z_{k,j} = 0$）は，モデルが正常範囲内で入力の特徴を良好に復元できている状態を表しており，脅威を示唆しない．したがって，Z-Score 正規化およびクランプ処理により，背景ノイズを 0 へ抑制し，変調したプロトコル属性の異常スパイク（$+15\sigma \sim +30\sigma$ 等）のみを視覚的に強調することが可能となる．

3.4 時系列異常ヒートマップおよび 1D プロファイルの可視化

時系列順に抽出された k 番目の構造化特徴行列 $F_{\text{feat32}}^{(k)}$（以下，パケットブロック k）に対し，式 (6) により算出された 32 次元の集約 Z-Score ベクトル $\boldsymbol{Z}_k = [Z_{k,1}, Z_{k,2}, \ldots, Z_{k,32}]^\top \in \mathbb{R}^{32}$ を用いて，以下の 2 つの可視化表現を構築する．

2 次元時系列ヒートマップ: 連続する複数のパケットブロック $k = 1, 2, \ldots, M$ に対する Z-Score ベクトル $\boldsymbol{Z}_k$ を時間順に縦方向へ配列することで，横軸を構造化特徴量属性 j，縦軸を時間経過（ブロック単位）とする 2 次元時系列ヒートマップ $H \in \mathbb{R}^{M \times 32}$ を構築する．

1 次元 Z-Score プロファイル: 特定の時間ウィンドウに含まれる M 個のブロックに対し，各属性 j における平均 Z-Score $\bar{Z}_j = \frac{1}{M}\sum_{k=1}^{M} Z_{k,j}$（定常的背景レベル）および最大 Z-Score $Z_j^{\max} = \max_k Z_{k,j}$（最大インパクト）を算出し，同一グラフ上に重畳描画（ダブルプロット）する．これにより，時間窓分割に伴う異常シグナルの希釈化（Dilution）を防止し，アナリストによる変調属性の迅速な特定を支援する．

4. 評価実験

提案する Z-Score プロファイリングに基づく一次スクリーニング手法の有効性を検証するために実施した評価実験について述べる．実トラフィックに基づくベンチマークデータセットを用いて定量的・定性的な評価を行い，提案手法の検知性能および可視化プロファイルの有用性を実証する．

4.1 実験環境およびデータセット詳細

評価実験は，Intel Xeon W-1390P CPU，NVIDIA GeForce RTX 2080 Ti GPU（11 GB VRAM），128 GB DDR4 RAM を搭載した Ubuntu 24.04 LTS（Rootless Docker）環境上で，Python 3.12 および PyTorch 2.4.1（CUDA 12.4）を用いて実施した．

評価データセットには，UNSW-NB15 データセット [10] のうち，`pcaps 17-2-2015` ディレクトリに含まれる全 27 個の PCAP ファイル（`1.pcap` – `27.pcap`）およびアノテーション CSV を使用した．特徴行列 F_{feat32} の構築にあたっては，本データセットにおける被攻撃サーバー網である `149.171.126.0/24` を宛先とするすべての通信を処理対象として抽出した．

表 2: 選定された各モデルの最良ハイパーパラメータ
Table 2 Best hyperparameters for each model

パラメータ	Plain AE	Standard VAE	GM-VAE
隠れ層構成 (Encoder)	[2048, 1024]	[2048, 1024, 512, 256]	[2048, 1024]
潜在空間次元 (z)	32	16	8
ガウス混合成分数 (K)	—	—	2
KL 重み (β)	—	0.01	0.01
学習率 (Learning Rate)	1.48×10^{-4}	1.97×10^{-4}	1.69×10^{-4}
バッチサイズ (Batch Size)	768	768	256
最適化アルゴリズム	Adam	Adam	Adam

未知の時系列トラフィックに対する検知能力を厳密に評価するため，時間軸に基づく時系列ホールドアウト分割を適用した．前半の `1.pcap` – `10.pcap` から抽出した正常フロー（Pure Normal Flow）の出現順（時系列）のまま，前 80% を学習用データ（Train Set），後ろ 20% を検証用データ（Validation Set）として分割した．特徴ベクトルの生成にあたっては，学習データの各次元の平均・標準偏差による特徴量標準化（Standardization）を行い，外れ値抑制のため $[-5.0, 5.0]$ の範囲でハードクリッピング処理を施した．

一方，後半領域の `11.pcap` – `27.pcap` から抽出されたすべての通信（正常通信 747,637 サンプル，攻撃通信 37,451 サンプル，計 785,088 サンプル）をテスト用データ（Test Set）と定義し，未来の時間帯に対する評価を行った．

テスト時における再構成誤差 $e_{t,j}$ （式 (4)）および Z-Score プロファイルの算出基準には，L1 損失を採用した．予備実験において MSE（二乗誤差）に基づく評価との比較検証を行った結果，Z-Score 正規化の入力に L1 損失を用いることで，正常領域における微小な再構成誤差のゆらぎ（背景ノイズ）が効果的に抑止され，2 次元ヒートマップ上において異常変調属性の視認性（コントラスト）が著しく向上することを確認したためである．これは，L2 損失（MSE）が微小な再構成誤差に対しても二乗演算によって誤差を拡大評価し，正常通信の些細なゆらぎを背景ノイズとして過剰に強調しやすいのに対し，L1 損失（絶対誤差）は誤差に対して線形に応答するため，定常通信に伴う微小なノイズ成分が低く抑えられ，結果として異常パケット発生時の鋭いスパイクとの明瞭なコントラストが得られるためである．

4.2 Optuna によるモデルパラメータの自動最適化

提案手法の多様な再構成アーキテクチャに対する適用可能性を評価するため，Plain Autoencoder (AE)，Standard Variational Autoencoder (VAE)，および Gaussian Mixture VAE (GM-VAE) の 3 種類の深層再構成モデルを構築した．

© 2026 Information Processing Society of Japan

表 3: テストデータにおける攻撃種別ごとの検知性能の比較
Table 3 Comparison of quantitative detection performance by attack category on the test dataset

攻撃種別 (Attack Category)	サンプル数	攻撃割合	Plain AE		Standard VAE		GM-VAE	
			ROC-AUC	PR-AUC	ROC-AUC	PR-AUC	ROC-AUC	PR-AUC
ANALYSIS	149	0.019%	**0.9606**	**0.0025**	0.7759	0.0006	0.8487	0.0009
BACKDOORS	29	0.004%	**0.9854**	**0.0051**	0.9576	0.0027	0.9704	0.0019
DOS	5,208	0.663%	**0.9319**	**0.0728**	0.8391	0.0312	0.8759	0.0447
EXPLOITS	23,557	3.001%	**0.9541**	**0.3170**	0.9034	0.2261	0.9186	0.2645
FUZZERS	5,272	0.672%	**0.9492**	**0.1205**	0.9042	0.0803	0.9170	0.0827
GENERIC	2,193	0.279%	**0.9587**	**0.1119**	0.8919	0.0524	0.9173	0.0617
RECONNAISSANCE	945	0.120%	**0.9709**	**0.0674**	0.9131	0.0276	0.9360	0.0352
SHELLCODE	63	0.008%	**0.9915**	**0.0140**	0.9508	0.0033	0.9748	0.0038
WORMS	35	0.004%	**0.9168**	**0.0009**	0.8144	0.0007	0.8488	0.0007
Pooled (全攻撃統合)	**37,451**	**4.770%**	**0.9511**	**0.4290**	0.8937	0.3064	0.9126	0.3522

各モデルのハイパーパラメータ（エンコーダの隠れ層構造，潜在空間次元数 z，ガウス混合成分数 K，KL 重み β，学習率，バッチサイズ）の選定には，Optuna によるベイズ最適化（各 30 試行，100 エポック）を適用した．検証データに対する再構成損失が最小となる最良チェックポイントを選定し，最終評価に導入した．選定されたハイパーパラメータを表 2 に示す．

4.3 異常検知性能および攻撃種別ごとの評価・考察

テストデータ（全 785,088 サンプル）に対する各モデルの定量的な検知性能を評価した．全攻撃を統合した評価，および 9 つの個別攻撃種別ごとの詳細な検知結果を表 3 に示す．本評価では，不均衡データ環境における識別性能を評価するため，ROC-AUC（Receiver Operating Characteristic Area Under the Curve）および PR-AUC（Precision-Recall Area Under the Curve）を評価指標として用いる．結果に基づき，以下の 3 つの視点から考察を行う．

4.3.1 不均衡データ環境における PR-AUC による評価

本評価テストセットは，正常 747,637 サンプルに対し，攻撃 37,451 サンプル（攻撃比率約 4.77%）という不均衡トラフィック構造を持つ．ランダム分類器における PR-AUC の理論基準値（Chance Level）が 0.0477 に留まる環境下において，Plain AE は全攻撃統合 PR-AUC で 0.4290（基準値の約 9.0 倍），EXPLOITS 攻撃単体では 0.3170（基準値の約 10.6 倍）という良好な適合率・再現率特性を達成した．これにより，膨大な定常通信中の低頻度な攻撃通信を高い S/N 比で検知できることが実証された．

4.3.2 攻撃カテゴリごとの検知性能に関する考察

SHELLCODE（ROC-AUC: 0.9915），BACKDOORS（0.9854），および RECONNAISSANCE（0.9709）においては，極めて高い検知性能が確認された．これらの攻撃はパケット構造内に不自然なヘッダー属性を伴うため，正常境界からの逸脱が顕著であり，再構成誤差として容易に捕捉される傾向を示した．

一方で，DOS（ROC-AUC: 0.9319）や WORMS（0.9168）などの攻撃では，比較的低い精度にとどまった．これらは個々のパケット単体としては正常なプロトコル手順を模倣しつつ，発生頻度や時間間隔の偏り（過渡的変調）としてのみ攻撃の特徴が表れるため，単一時間窓の特徴量空間において正常通信との識別境界に重なりが生じたためである．

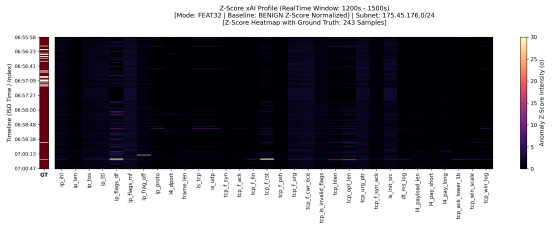
このように，スカラー値（統合された 1 つの異常度）のみに基づく自動二値判定では限界が存在する攻撃に対しても，第 4.4 節で詳述する Z-Score プロファイルを適用することで，単一指標に埋没していた各プロトコル特徴量の微小な変化を属性ごとに個別展開・可視化できる．これにより，アナリストが通信の異常根拠（Root Cause）を迅速に把握し，一次スクリーニング（Triage）を効率的に推進することが可能となる．

4.3.3 決定論的モデルと確率的モデルにおけるトレードオフ

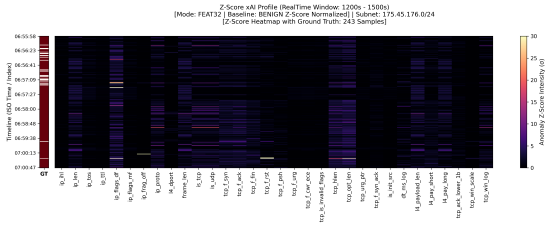
モデル間の比較において，Plain AE は統合評価（Pooled ROC-AUC: 0.9511）を含む全カテゴリで確率的モデル（VAE: 0.8937，GM-VAE: 0.9126）を上回った．Plain AE は厳密な幾何学的復元境界を形成するため，プロトコル属性の微小な変動（フラグやヘッダー長の異変等）に対しても即座に再構成誤差が増大し，二値判定における高い検知感度を発揮する．

一方で，VAE や GM-VAE 等の変分確率モデルは，KL ダイバージェンスによる正則化によって正常通信の多様性を平滑化して包含する．この平滑化特性は閾値近傍での感度をわずかに低下させるものの，Plain AE では過剰に消去されがちな微小な応答が埋没せずに検出される．その結果，攻撃時間帯を通じて連続的な異変として視覚的に把握しやすくなる．すなわち，モデル選定においては「定量的な検知感度」と「定性的な可視化鮮明性」の間に明確なトレードオフが存在する．

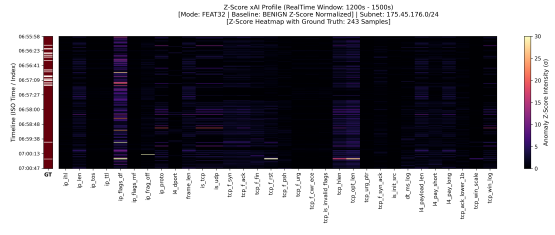
© 2026 Information Processing Society of Japan



(a) Plain AE



(b) Standard VAE



(c) GM-VAE

図 2: `14.pcap` の時間窓 1200s–1500s における各モデルの 2 次元 Z-Score ヒートマップ

Fig. 2 2D Z-Score heatmaps for each model during elapsed time 1200s–1500s of `14.pcap`

4.4 2 次元 Z-Score ヒートマップの定性評価と静的識別限界の検証

正常学習データの再構成誤差から算出した平均 μ_j^{sum} および標準偏差 σ_j^{sum} に基づき，テストデータの再構成誤差を正方向 Z-Score に変換し，$\max(0,\cdot)$ クリッピングを適用した可視化プロファイルを生成した．

図 2 に，特定の送信元サブネット `175.45.176.0/24` から監視対象サブネット `149.171.126.0/24` 宛ての通信（`14.pcap` における 1200 秒 ～ 1500 秒）における，各モデルの 2 次元 Z-Score ヒートマップの定性的比較を示す．

モデル間で可視化特性を比較すると，明確な違いが観察された．Plain AE（図 2(a)）は，‘7:00:13‘ 付近における一時的なプロトコルヘッダーの変調（`ip_frag_off` や `tcp_f_rst` 等）に対し，$+30\sigma$ を超える Z-Score を出力した．一方で，Plain AE が鋭い判定境界を持つ影響から，それ以外の持続的な攻撃時間枠（‘06:55:58‘ ～ ‘06:58:00‘ 付近等）においては応答が抑制されやすく，一過性の局所的なピーク検知に偏重する傾向が見られた．

これに対し，Standard VAE（図 2(b)）および GM-VAE（図 2(c)）などの確率的モデルでは，Ground Truth（GT）が攻撃を示す長時間の時間枠（‘06:55:58‘ ～ ‘06:58:00‘ 付近）と同期して，`ip_flags_df` や `tcp_hlen` などの特定の属性に $+5\sigma$ ～ $+15\sigma$ 程度の Z-Score が持続的な帯状として可視化された．これは，確率的モデルの性質によって一時的に生じるわずかなプロトコル変化への反応が過剰に消去されずに再現され，攻撃の全体的な経過を捉えやすくなっていることを示している．

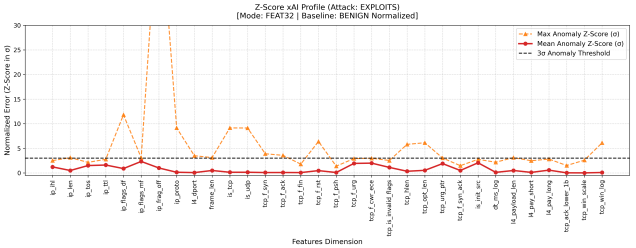


図 3: EXPLOITS 攻撃における 1 次元 Z-Score プロファイル（Mean vs Max ダブルプロット）

Fig. 3 One-dimensional Z-Score profile for EXPLOITS attack (double plot of Mean vs. Max)

このように，1 つの異常度スコア（スカラー値）では捉えきれない攻撃であっても，2 次元 Z-Score ヒートマップとして時系列に沿って可視化することで，アナリストは「どの属性が，どの時間帯にわたって異変を起こしているか（Root Cause）」を一目で捉えることが可能となる．

さらに，図 3 に，発生数の最も多い EXPLOITS 攻撃における 1 次元 Z-Score プロファイル（Mean vs Max）を示す．赤実線の平均値（Mean）プロファイルのみでは，過渡的な攻撃変調が平均化され 3σ 閾値（黒破線）以下へ希釈される現象が確認された．これに対し，オレンジ破線の最大値（Max）プロファイルを併記することで，`ip_frag_off` において $+30\sigma$ を超える異常スパイクが明確に可視化され，時間窓集約によるシグナルの埋没を防ぎつつ変調属性を特定できることが確認された．

なお，前処理段階で定数保持（固定値化）されている属性においてもプロファイル上に微小な Z-Score 偏差が観察されるが，これは，深層再構成モデルの潜在空間において，変動の大きな他の入力属性からの相互干渉および重み伝播が生じることに起因するものである．提案手法では，正常時の統計量に基づく Z-Score 正規化と $\max(0,\cdot)$ クリッピング処理を施すことで，異常スパイクとのコントラスト差を保ち，誤認を防ぐ設計となっている．

図 4 に，異なる時間（PCAP）から抽出された攻撃ごとの 1D Max Z-Score プロファイル間の平均コサイン類似度マトリックス（Plain AE）を示す．同一攻撃カテゴリ内（対角: 0.64 ～ 0.87）と異種攻撃カテゴリ間（非対角: 0.67 ～ 0.87）で同等の高類似度を示しており，有意な差異は見られない．これはプロトコル手順の共通性に加え，UNSW-NB15 データセットに特有の同時多発的な攻撃の混在に起因し，1 次元に集約したプロファイル（静的特徴）

© 2026 Information Processing Society of Japan

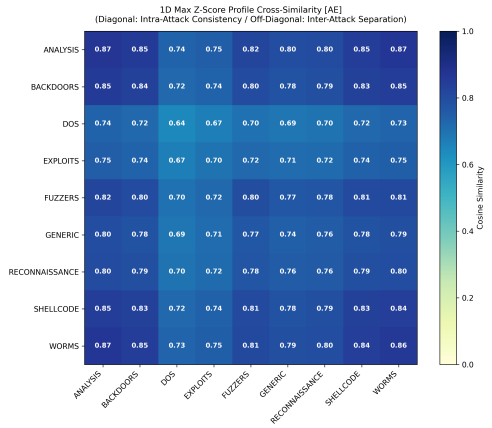


図 4: 1D Max Z-Score プロファイルにおける攻撃カテゴリ間コサイン類似度マトリックス (Plain AE)

Fig. 4 Cosine similarity matrix among attack categories in 1D Max Z-Score profiles (Plain AE)

のみでは攻撃種別の識別が困難であるという「静的識別限界」を裏付けている．これに対し，提案する 2 次元 Z-Score ヒートマップ（図 2）は 1D プロファイル列を時間軸方向へ連続配置することで，単一ブロックでは埋没しがちな微小な応答を持続的な帯状パターンや過渡的なバーストとして可視化する．これにより，アナリストは通信系列全体の推移から異変を視覚的に捉え，迅速な一次スクリーニング（Triage）へ繋げることが可能となる．

5. おわりに

本研究では，深層再構成モデル（AE，VAE，GM-VAE）に基づく教師なし NIDS において，セキュリティアナリストによる一次スクリーニング（Triage）を効果的に支援する異常根拠可視化プロファイリング手法を提案した．パケットの構造的属性を 32 パケット単位で時系列配置した特徴行列を入力とし，正常通信の誤差統計量に基づく Z-Score 正規化と背景ノイズのゼロクランプ処理を組み合わせることで，異常発生のタイミングおよび変調されたプロトコル属性（Root Cause）を明確に強調する 2 次元 Z-Score ヒートマップを構築した．

UNSW-NB15 データセットを用いた定量的評価において，攻撃比率 4.77% の不均衡トラフィック環境下で PR-AUC 0.4290 を達成し，モデルの確率的定式化や潜在空間構造に依存しない一貫した根拠可視化能力を実証した．さらに，プロファイル類似度解析を通じて，単一時間窓（1 行単位）の静的特徴のみでは異種攻撃間での属性類似度が高く自動識別が困難であるという事実を示した上で，本手法が 1 行単位の静的自動分類ではなく，プロファイル列を時間軸方向へ連続配置した 2 次元ヒートマップにより，時系列変化に伴う過渡的な異常変調属性（Root Cause）を視覚的に明示する役割を果たすことを示した．

今後は，リアルタイムインライン環境への実装に向けたパイプラインの高速化を図るとともに，アナリストの視覚的認識負荷（Cognitive Load）や Triage 時間の削減効果を定量的に評価する被験者実験（ユーザビリティ評価）の実施を推進する予定である．

参考文献

[1] Sommer, R. and Paxson, V.: Outside the Closed World: On Using Machine Learning for Network Intrusion Detection, *Proc. 2010 IEEE Symposium on Security and Privacy (SP)*, pp. 305–316 (2010).

[2] García-Teodoro, P., Díaz-Verdejo, J., Maciá-Fernández, G. and Vázquez, E.: Anomaly-based Network Intrusion Detection: Techniques, Systems and Challenges, *Computers & Security*, Vol. 28, No. 1–2, pp. 18–28 (2009).

[3] Gamage, S. and Samarabandu, J.: Deep learning methods in network intrusion detection: A survey and an objective comparison, *Journal of Network and Computer Applications*, Vol. 169, p. 102767 (2020).

[4] Ahmed, M., Mahmood, A. N. and Hu, J.: A Survey of Network Anomaly Detection Techniques, *Journal of Network and Computer Applications*, Vol. 60, pp. 19–31 (2016).

[5] Sakurada, M. and Yairi, T.: Anomaly Detection Using Autoencoders with Nonlinear Dimensionality Reduction, *Proc. 2014 Workshop on Machine Learning for Sensory Data Analysis (MLSDA '14)*, pp. 4–11 (2014).

[6] An, J. and Cho, S.: Variational Autoencoder based Anomaly Detection using Reconstruction Probability, *SNU Data Mining Center 2015-2 Special Lecture on IE (Technical Report: SNUDM-TR-2015-03)* (2015).

[7] Lundberg, S. M. and Lee, S.-I.: A Unified Approach to Interpreting Model Predictions, *Advances in Neural Information Processing Systems (NeurIPS 30)*, pp. 4765–4774 (2017).

[8] Ribeiro, M. T., Singh, S. and Guestrin, C.: "Why Should I Trust You?": Explaining the Predictions of Any Classifier, *Proc. 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '16)*, pp. 1135–1144 (2016).

[9] Capuano, N., Fenza, G., Loia, V. and Stanzione, C.: Explainable Artificial Intelligence in CyberSecurity: A Survey, *IEEE Access* (2022).

[10] Moustafa, N. and Slay, J.: UNSW-NB15: A Comprehensive Data Set for Network Intrusion Detection Systems (UNSW-NB15 Network Data Set), *Proc. 2015 Military Communications and Information Systems Conference (MilCIS)*, pp. 1–6 (2015).

[11] Dilokthanakul, N., Mediano, P. A. M., Garnelo, M., Lee, M. C. H., Salimbeni, H., Arulkumaran, K. and Shanahan, M.: Deep Unsupervised Clustering with Gaussian Mixture Variational Autoencoders, *arXiv preprint arXiv:1611.02648* (2016).

© 2026 Information Processing Society of Japan