Computer Security Symposium 2026
19-23 October 2026

# 多角的評価指標に基づく教師なしアンサンブルNIDSの構築

廣井 陽也[1,a)]　青木 茂樹[1]　宮本 貴朗[1]

**概要**：本研究では，正常トラフィックのみを学習データとして用いるアノマリ型ネットワーク侵入検知システム（NIDS）を提案する．従来のアノマリ型 NIDS では，特定の通信環境へ過適合すること，および単一検知器に生じる攻撃種別ごとの検知性能の偏りを補うために複数検知器を統合する際，不安定なモデルが混入することが課題となっていた．本手法ではまず，トラフィックを 5 秒の区間に分割し，環境依存性の高い特徴量を除外した上で，原理の異なる複数の教師なし検知器（Mahalanobis 距離，Isolation Forest など）を学習する．続いて，学習時の正常データに対する各検知器の挙動から算出した多角的な評価指標（スコア安定性，他モデルとの順位相関，上位分離度）に基づき，冗長または不安定な検知器を排除し，適合度の高いモデルを選定する．最終的に，選定された検知器が出力する異常スコアを順位に変換した上で平均化し，アンサンブル学習を用いた NIDS を構築する．実験評価の結果，本手法は単一検知器で見られる攻撃種別ごとの性能の偏りを低減し，未知の攻撃に対しても安定した検知性能（ROC-AUC および PR-AUC）を達成できることを確認した．

**キーワード**：異常検知，教師なし学習，ネットワーク侵入検知，アンサンブル学習，モデルスクリーニング

# Unsupervised Ensemble NIDS Driven by Multi-Criteria Evaluation Metrics

Haruya Hiroi[1,a)]　Shigeki Aoki[1]　Takao Miyamoto[1]

***Abstract:*** This study proposes an anomaly-based network intrusion detection system (NIDS) trained solely on normal traffic. Conventional anomaly-based NIDSs suffer from overfitting to specific network environments and from the inclusion of unstable models when combining multiple detectors to mitigate single-detector performance bias. To address these issues, we propose a lightweight model screening and rank-aggregation framework. We divide the traffic into 5-second intervals, exclude environment-dependent features, and train multiple unsupervised detectors with distinct underlying principles. We then select effective models by excluding redundant or unstable detectors based on multi-faceted internal metrics computed from normal training data: score stability, rank correlation, and top-tail separation. Finally, the anomaly scores of the selected detectors are rank-transformed and averaged to construct an ensemble NIDS. Experimental evaluation confirms that the proposed method reduces attack-type-dependent performance bias and achieves stable detection performance (ROC-AUC and PR-AUC), even against unknown attacks.

***Keywords:*** anomaly detection, unsupervised learning, network intrusion detection, ensemble learning, model screening

## 1. はじめに

近年，サイバー攻撃の手口は年々巧妙化・多様化しており，既知の攻撃パターンをシグネチャとして登録するシグネチャ型の NIDS（Network Intrusion Detection System）では，未知の攻撃（ゼロデイ攻撃）を検知することが困難である．そのため，正常な通信の統計的性質から逸脱した通信を異常として検知するアノマリ型 NIDS が有効な代替手段として注目されている．アノマリ型 NIDS は正常トラ

[1] 大阪公立大学大学院 情報学研究科
Graduate School of Informatics, Osaka Metropolitan University
[a)] sp25483q@st.omu.ac.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

フィックのみを学習データとして利用できるため，攻撃サンプルの収集やラベル付けが不要であるという利点を持つ．

しかし，実運用に適したアノマリ型 NIDS を構築する上では，特に以下の二つの課題が重要となる．第一に，IP アドレス体系やホスト構成などの特定の通信環境に強く依存する特徴量を用いると，モデルが当該環境固有のパターンに過適合し，他環境への汎化性能が著しく低下する点である．第二に，教師なしアンサンブルにおける「アンサンブル飽和」の問題である．現代のネットワーク攻撃（DoS，ポートスキャン，Web 攻撃等）は異常のあらわれ方が攻撃種別ごとに異なるため，単一の検知原理に依存するモデルでは特定攻撃に対する検知性能の偏りが生じやすい．この偏りを緩和する手段として，異なる検知原理を持つ複数モデルのアンサンブル化が有効なアプローチとなるが，教師なし設定では正解ラベルを用いて各検知器の適性を事前に検証できない．その結果，性能の低い検知器や他の検知器と冗長なモデルが無選別に混入し，かえってアンサンブル全体の検知性能を低下させてしまう課題があった．

本研究ではこの二つの課題に対し，通信環境への依存度が低い特徴量群のみを用いた上で，学習データ（正常トラフィックのみ）に対する各検知器の挙動から算出される三つの内部指標——スコア安定性（変動係数），他モデルとの順位相関，上位分離度——により，正解ラベルを用いずに検知器を選別する「モデルスクリーニング」を導入する．

本論文の主な貢献は以下の 3 点である．

(1) 検知原理の異なる 6 種の教師なし検知器（Mahalanobis 距離, Elliptic Envelope[1], GMM 負対数尤度 [2], PCA 再構成誤差 [3]，Isolation Forest[4]，LOF[5]）を対象に，正解ラベルを必要としない 3 指標（スコア安定性・順位相関・上位分離度）に基づき，不適切なモデルを効果的に排除する軽量なモデルスクリーニングの枠組みの提案．

(2) 選択された検知器群の異常スコアを順位変換して統合する Rank 集約アンサンブルを構築し，CICIDS2017 データセット [6] における評価を通じて，日ごとの性能のばらつきを抑え，評価日における最悪時の検知性能（下限性能）および 4 日平均性能において，単体検知器，無選別アンサンブル，他集約方式に対する優位性を実証．

(3) スクリーニング処理の計算量が検知器数の 2 乗オーダー $\mathcal{O}(|M|^2 n)$ に留まることを示し，実測 17.087ms の低オーバーヘッドで動作することを確認した上での，実運用環境における適用可能性の議論．

## 2. 関連研究

### 2.1 アノマリ型 NIDS とモデル統合の動向

近年のアノマリ型 NIDS の評価においては，文献 [6] のように，現実のネットワークを模した多様な攻撃シナリオと生トラフィックを含むデータセットを用いた評価が主流となっている．こうした研究の多くは，Isolation Forest や Autoencoder など単一の検知原理に基づくモデルを直接適用するか，あるいは複数モデルを統合する場合であっても，事前に固定された検知器の組み合わせや教師あり設定での重み学習に依存している．

その代表例として，オートエンコーダのアンサンブルによって正常・異常なトラフィックパターンを識別する教師なしオンライン NIDS である Kitsune[7] が提案されている．この研究は，正解ラベルを一切用いずに動作し，計算資源の限られた機器上でも実行可能な軽量性を実現した先駆的なものである．同手法では，特徴量間の相関に基づくクラスタリングによって入力特徴量を複数のオートエンコーダへ割り当てる構成をとっており，入力特徴量空間の効率的な分割に重点が置かれている．一方で，検知原理そのものの多様性を確保し，不適切なモデルの混入に伴う「アンサンブル飽和」回避という観点については，さらなる検討の余地が残されている．

また，複数の検知器を組み合わせる既存研究の多くは，教師あり設定での重み学習や，検証用ラベルを用いた固定的な検知器群の選定を前提としている．そのため，正解ラベルが一切得られない完全教師なし環境において，各検知器の挙動から動的にモデル集合を選別し統合するアプローチは，NIDS の分野において十分に開拓されていない．本研究は，この課題に対して教師なしモデル選択（UOMS）の考え方を適用し，既存研究との差別化を図る．

### 2.2 教師なしモデル選択とアンサンブル理論

正解ラベルを用いずに異常検知モデルを評価・選択する研究領域は Unsupervised Outlier Model Selection（UOMS）と呼ばれる．多数のベンチマークタスクにおける検知器性能をメタ学習して新規タスクへモデルを推薦する MetaOD[8] や，内部性能指標から真の性能を推定する適応的探索を導入した ELECT[9] が提案されている．また近年の研究である MetaEns[10] では，各検知器がアンサンブル全体の性能にどれだけ貢献するかをメタ学習で予測し，多様性を考慮しながら検知器を順次選定していく手法が提案されている．

これら UOMS およびアンサンブル統合における主要な課題の一つが，基底検知器の適性評価と多様性の確保である．文献 [11] では，アンサンブルの精度向上には検知器間の「多様性」が不可欠である一方，冗長な（強く相関した）検知器の混入が全体性能を劣化させることが指摘されている．また文献 [12] では，教師なし設定において検知器間の相関に基づき冗長なモデルを除外するヒューリスティックが提案されている．さらに文献 [13] では，単一の内部指標では真の性能との対応が不安定であるのに対し，複数指標の組合せが評価の頑健性を高めることが示されている．

本手法のモデルスクリーニングは，これらの知見を踏ま

© 2026 Information Processing Society of Japan

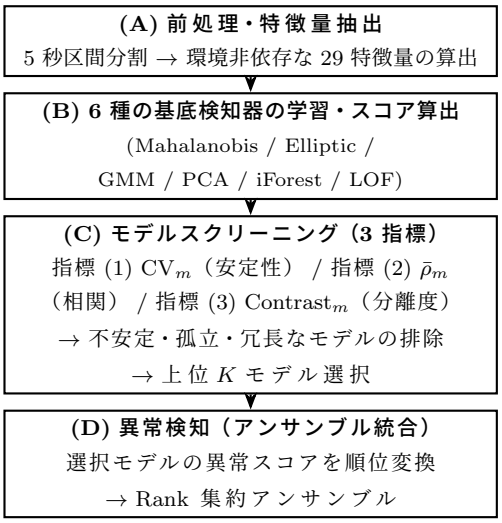



**図 1** 提案手法の全体フロー
**Fig. 1** Overall flow of the proposed method.

え，相関に基づく重複排除と多角的な内部指標（安定性・相関・分離度）の併用を設計に採り入れている．一方で，MetaOD[8] や MetaEns[10] などの既存手法が大規模な事前メタ学習や外部ベンチマーク集合を必要とするのに対し，本手法は対象タスクの学習データセットのみでスクリーニングを完結できる軽量性を備えている点に明確な差異がある．

### 2.3 スコア集約手法

異なる検知器が出力するスコアはスケールや分布形状が大きく異なるため，単純な平均処理は不適切である．多数の異常検知アンサンブルを対象とした大規模実験を行った文献 [14] では，スコア正規化手法や集約方式がアンサンブル性能に与える影響を比較し，順位変換に基づく集約が検知器間のスコアスケールの違いや分布の歪みに対して頑健であることを示している．本手法もこれに倣い，正規化後のスコアを検知器ごとに順位へ変換したうえで平均する Rank 集約（rank aggregation）を採用している．

## 3. 提案手法

提案手法は図 1 に示すように，(A) 環境非依存な特徴量に基づく区間統計量の算出，(B) 6 検知器の学習とスコア算出，(C) 多角的評価指標に基づくモデルスクリーニング，(D) Rank 集約アンサンブルによる異常検知，の 4 段階から構成される．学習フェーズでは正常トラフィックのみを含むデータを用い，攻撃データの収集や検証用ラベルに一切依存しない教師なしアノマリ検知（正常データのみによる学習）の設定を採用している．

### 3.1 基底検知器の選定

本手法のアンサンブルを構成する基底検知器には，検知原理の異なる代表的な教師なしアルゴリズムを採用する．具体的には，統計的距離に基づく Mahalanobis 距離および Elliptic Envelope（Minimum Covariance Determinant: MCD[1]），確率密度モデルである GMM 負対数尤度 [2]，線形部分空間からの再構成誤差に基づく PCA 再構成誤差 [3]，分割の容易さに基づく Isolation Forest[4]，密度ベースの Local Outlier Factor（LOF）[5] の計 6 種で構成する．

これらの検知器は互いに独立した検知原理を持つため，特定の攻撃に対する相互補完（多様性の確保）が期待できる．しかし，正解ラベルが存在しない教師なし環境下でこれらを無選別に統合すると，低性能なモデルや冗長なモデルが混入し，アンサンブル全体の検知性能を低下させる「アンサンブル飽和」を引き起こす．そのため，3.3 節で述べるモデルスクリーニングによる厳密な選別が必要となる．

各検知器 $m$ は，正常トラフィックのみを含む学習データ $X_{\mathrm{tr}}$ に対して学習され，異常スコアベクトル $\boldsymbol{s}_m \in \mathbb{R}^n$（$n$ は学習データの区間数）を出力する．

### 3.2 環境非依存特徴量

本手法では，パケットキャプチャを先頭パケットのタイムスタンプを起点として重複のない 5 秒の連続区間へ分割し，各区間内のパケット群から算出した統計量を 1 区間として扱う．区間幅を 5 秒としたのは，ブルートフォースやポートスキャンのようなバースト性を持つ通信の統計的特徴を 1 区間内に十分含められる一方，区間が長すぎると異常な通信の特徴が区間内の正常な通信によって希釈され，統計量上で見えにくくなることを避けるためである．

IP アドレスやポート番号，タイムスタンプ等，特定のキャプチャ環境やネットワーク構成に強く依存する特徴量は，モデルが当該環境固有のパターンを学習する主要因となる．そこで本手法では，パケットサイズの平均・分散，TTL の平均・分散，各 TCP フラグ（SYN, FIN, RST, ACK, PSH, URG, ECE）の出現数およびフラグ組合せの出現数・出現率など，通信プロトコルの挙動そのものを反映する 29 個の特徴量のみを各区間について算出する．これらは環境非依存性が高く，異なるネットワーク構成間でも同様の意味を持つため，過適合の抑制に寄与すると考えられる．

### 3.3 モデルスクリーニング（3 指標）

モデルスクリーニングでは，正解ラベルを一切使用せず，学習データに対する各検知器のスコア挙動から算出する以下の 3 指標を用いる．

#### 3.3.1 スコア安定性（変動係数）

各検知器のスコアの変動係数 CV$_m$ は式 (1) により算出する．

$$\mathrm{CV}_m = \frac{\mathrm{std}(\boldsymbol{s}_m)}{|\mathrm{mean}(\boldsymbol{s}_m)| + \varepsilon} \tag{1}$$

CV$_m$ が極端に大きい検知器は，学習データ内での挙動が

© 2026 Information Processing Society of Japan

不安定であり，未知データに対しても信頼性の低いスコアを出力すると判断して除外候補とする．なお予備検討により，スコアをパーセンタイル順位化してから CV を計算すると，値の重複が少なく連続的なスコアにおいては順位化処理によって本来の分布形状（値の散らばり）の情報が失われ，指標 (1) および指標 (3) の判別力が消失することを確認したため，これらは正規化前の未加工スコアに対して計算する．

#### 3.3.2 他モデルとの順位相関（平均相関 $\bar{\rho}$）

各検知器ペア間のスピアマン順位相関 $r(m, m')$ の絶対値 $|r(m, m')|$ を算出し，各検知器について自身を除く他検知器との平均相関 $\bar{\rho}_m$ を式 (2) により求める．

$$\bar{\rho}_m = \frac{1}{|M \setminus \{m\}|} \sum_{m' \neq m} |r(m, m')| \tag{2}$$

本指標は「主要グループへの同調度」を表し，相関の符号ではなく検知器間の結合の強さのみを評価する．$\bar{\rho}_m$ が低くかつ $\mathrm{CV}_m$ が全体の中央値を上回る検知器は，他の検知器群から孤立した不安定なノイズ源とみなして除外する．また，2 検知器間の $|r(m, m')|$ が閾値（0.95）を超える場合は冗長なペアとみなし，$\bar{\rho}_m$ が低い方を除外する．これは，未加工スコアの $\mathrm{CV}_m$ のみで重複判定を行った場合に，たまたま分散が小さかった不安定なモデルが誤って残存する問題を回避するための処理である．なお相関行列と $\bar{\rho}_m$ は，除外判定前の初期集合 $M$（本実験では 6 検知器）に対して一度だけ算出し，除外後に再計算することはしない．これは除外の順序によって結果が変動することを避け，手続きを決定的にするためである．全ペア間の順位相関算出に伴う計算量は，検知器数 $|M|$ および学習データ区間数 $n$ に対して $\mathcal{O}(|M|^2 n)$ となり，スクリーニング全体の計算量を支配する．

#### 3.3.3 上位分離度（Contrast）

各検知器のスコア分布について，95 パーセンタイル値 $p_{95}$ と 99 パーセンタイル値 $p_{99}$ の差をスコアの標準偏差で正規化した上位分離度 $\mathrm{Contrast}_m$ を式 (3) により算出する．

$$\mathrm{Contrast}_m = \frac{p_{99} - p_{95}}{\mathrm{std}(\boldsymbol{s}_m) + \varepsilon} \tag{3}$$

この値が大きいほど，スコア分布の上位（潜在的な異常候補）が中央付近から明確に分離しており，判別力が高いと解釈できる．分母に IQR ではなく $\mathrm{std} + \varepsilon$（$\varepsilon = 10^{-5}$）を用いるのは，IQR がゼロに近くなる離散的かつ同値の重複が多い分布におけるゼロ除算を回避するためである．

以上により不安定・孤立・冗長な検知器を除外した後，残った検知器を安定性スコアと分離度スコアの等重み合成スコアでランキングし，上位 $K$ 個を選択する．安定性スコアは $\mathrm{CV}_m$ の値を反転（小さいほど高評価となるよう変換）して Min–Max 正規化したもの，分離度スコアは $\mathrm{Contrast}_m$ をそのまま Min–Max 正規化したものであり，具体的には式 (4) および式 (5) で与えられる．

$$\mathrm{StabilityScore}_m = \frac{\mathrm{CV}_{\max} - \mathrm{CV}_m}{\mathrm{CV}_{\max} - \mathrm{CV}_{\min} + \varepsilon} \tag{4}$$

$$\mathrm{SeparationScore}_m = \frac{\mathrm{Contrast}_m - \mathrm{Contrast}_{\min}}{\mathrm{Contrast}_{\max} - \mathrm{Contrast}_{\min} + \varepsilon} \tag{5}$$

等重み合成スコア $\mathrm{Composite}_m$ は式 (6) で定義される．

$$\mathrm{Composite}_m = 0.5\,\mathrm{StabilityScore}_m + 0.5\,\mathrm{SeparationScore}_m \tag{6}$$

ここで最大値・最小値は，$\bar{\rho}_m$ と同様に除外判定前の初期集合 $M$ におけるものであり，除外後に再計算しない．両スコアはともに $[0, 1]$ に正規化され，値が大きいほど望ましい．選択した数が $K$ に満たない場合は，除外済みの検知器から合成スコアの高い順に不足分を補充する．

### 3.4 Rank 集約アンサンブル

選択された $K$ 個の検知器のスコアを，学習データを用いて Min–Max 正規化し，評価対象データにも同一スケールを適用する．スコア集約には，スコアを検知器ごとに $[0, 1]$ の順位（$\mathrm{rank}/(n-1)$）へ変換した上で $K$ 個間で平均する Rank 集約（rank aggregation）を採用し，アンサンブル異常スコア $S(x)$ を式 (7) により算出する．

$$S(x) = \frac{1}{K} \sum_{m \in S_{\mathrm{selected}}} \mathrm{rank}_m(x) \tag{7}$$

順位ベースの集約により，スコアスケールの違いや分布の歪みに影響されにくい頑健な統合が可能となる．なお，他の主要なスコア集約方式（Max 集約，Mean 集約，重み付き平均集約）との比較評価は，4.3 において行う．

## 4. 評価実験

### 4.1 実験設定

**データセットと前処理**

評価には CICIDS2017 データセット [6] を使用した．月曜日の正常トラフィックのみを学習データとし，火曜日（FTP/SSH ブルートフォース），水曜日（DoS/Heartbleed），木曜日（Web アタック・侵入），金曜日（ボットネット・ポートスキャン・DDoS）の各データを評価データとした．本実験では CICIDS2017 で公式に配布されている CSV ではなく PCAP を直接解析し，5 秒の連続時間窓に分割して前述の環境非依存な 29 特徴量を算出した．評価ラベルは，文献 [15] に基づく補正フロー情報をパケットへ割り当てた後，5 秒区間単位へ統合して作成し，攻撃パケットが 1 つでも含まれる区間を異常と定義した．

**比較対象と評価指標**

比較条件は，(i) 単体 6 検知器（Mahalanobis 距離，Elliptic Envelope，GMM 負対数尤度，PCA 再構成誤差，Isolation Forest，LOF），(ii) 全 6 検知器をそのまま統合した無選別

© 2026 Information Processing Society of Japan

**表 1**　各検知器の多角的評価指標に基づくスクリーニング結果
**Table 1**　Screening results of candidate detectors based on multi-faceted evaluation metrics.

| 検知器 | CV | $\bar{\rho}_m$ | Contrast | 安定性 | 分離度 | 合成 | 判定 | 除外理由 |
|---|---|---|---|---|---|---|---|---|
| Mahalanobis 距離 | 0.983 | 0.860 | 3.287 | 0.844 | 0.936 | 0.890 | 選択 | — |
| Elliptic Envelope | 1.041 | 0.859 | 1.905 | 0.835 | 0.542 | 0.689 | 除外 | Mahalanobis 距離，Isolation Forest と重複（$\|r\|>0.95$） |
| GMM 負対数尤度 | 0.302 | 0.802 | 1.844 | 0.952 | 0.525 | 0.739 | 選択 | — |
| PCA 再構成誤差 | 0.000 | 0.735 | 0.000 | 1.000 | 0.000 | 0.500 | 選択 | — |
| Isolation Forest | 0.208 | 0.861 | 0.788 | 0.967 | 0.224 | 0.596 | 選択 | — |
| LOF | 6.302 | 0.579 | 3.512 | 0.000 | 1.000 | 0.500 | 除外 | CV が外れ値（不安定），$\bar{\rho}_m$ が最低（孤立） |

**表 2**　評価日別の ROC-AUC および PR-AUC の比較
**Table 2**　Comparison of ROC-AUC and PR-AUC for each evaluation day.

| 条件 | 火 | | 水 | | 木 | | 金 | | 平均 | |
|---|---|---|---|---|---|---|---|---|---|---|
| | ROC | PR | ROC | PR | ROC | PR | ROC | PR | ROC | PR |
| Mahalanobis 距離 | 0.8415 | 0.7003 | 0.9703 | 0.9545 | 0.9312 | 0.8450 | 0.9826 | 0.9447 | 0.9314 | 0.8611 |
| Elliptic Envelope | 0.8015 | 0.6818 | 0.8562 | 0.7583 | 0.8207 | 0.6927 | 0.9807 | 0.9411 | 0.8648 | 0.7685 |
| GMM 負対数尤度 | 0.8284 | 0.6763 | 0.9661 | 0.9479 | 0.9307 | 0.8399 | 0.9882 | 0.9656 | 0.9283 | 0.8574 |
| PCA 再構成誤差 | 0.7794 | 0.7720 | 0.9673 | 0.9634 | 0.8419 | 0.7807 | 0.9424 | 0.8926 | 0.8828 | 0.8522 |
| Isolation Forest | 0.9101 | 0.8209 | 0.9520 | 0.9181 | 0.7848 | 0.6350 | 0.9823 | 0.9357 | 0.9073 | 0.8274 |
| LOF | 0.7031 | 0.5548 | 0.8027 | 0.5390 | 0.5368 | 0.4761 | 0.9277 | 0.5487 | 0.7426 | 0.5296 |
| 無選別（全 6 検知器） | 0.8669 | 0.7934 | 0.9757 | 0.9656 | 0.9006 | 0.7875 | **0.9835** | **0.9494** | 0.9317 | 0.8740 |
| 提案手法（選択 4 検知器） | **0.8675** | **0.8082** | **0.9781** | **0.9699** | **0.9179** | **0.8108** | 0.9782 | 0.9388 | **0.9354** | **0.8819** |

Rank 集約，(iii) 提案手法（スクリーニングにより選択されたモデルの Rank 集約）の 3 条件とした．評価指標には ROC-AUC および PR-AUC を使用した．

**実装環境**

実装には Python 3 系および scikit-learn を用い，乱数シードは `random_state=42` に固定した．全実験は Google Colaboratory 上の同一 CPU 環境（Intel Xeon 2.20GHz，2 vCPU，12.7 GB RAM）にて実行し，処理時間を測定した．

### 4.2　モデル選択結果および検知性能

表 1 に，学習データに対する 3 指標の算出結果とスクリーニング判定結果を示す．Mahalanobis 距離と高い順位相関を示した Elliptic Envelope，および不安定かつ孤立した挙動を示した LOF の 2 モデルが除外された．結果として，Mahalanobis 距離，GMM 負対数尤度，PCA 再構成誤差，Isolation Forest の 4 モデルが選択された（$K = 4$）．

表 2 に評価日別の検知性能を示す．提案手法は 4 日平均で ROC-AUC 0.9354, PR-AUC 0.8819 を記録し，単体モデル中最良であった Mahalanobis 距離（ROC-AUC 0.9314, PR-AUC 0.8611）および無選別 Rank 集約（ROC-AUC 0.9317，PR-AUC 0.8740）を上回った．曜日別に見ると，水曜日において提案手法が全条件中で最高性能を達成した一方，火曜日は Isolation Forest 単体，木曜日は Mahalanobis 距離単体，金曜日は無選別 Rank 集約がそれぞれ提案手法をわずかに上回った．しかし，提案手法において最も低いスコアとなった火曜日（最悪評価日）においては ROC-AUC 0.8675 を維持し，比較対象中で最も高い下限性能（頑健性）を示した．

**表 3**　選択 4 検知器に対する集約方式別の平均性能
**Table 3**　Average performance by aggregation method for the selected four detectors.

| 方式 | ROC-AUC | PR-AUC |
|---|---|---|
| Max | 0.8955 | 0.8177 |
| Mean | 0.9202 | 0.8470 |
| 重み付き平均 | 0.9237 | 0.8511 |
| Rank（提案） | **0.9354** | **0.8819** |
| （参考）無選別・Rank | 0.9317 | 0.8740 |

### 4.3　詳細評価および計算コスト

**集約方式の比較**

選択された 4 モデルが出力する異常スコアの統合において，スコアスケールや分布形状の違いが検知精度へ与える影響を評価するため，各種スコア集約方式による平均性能の比較を表 3 に示す．Rank 集約が ROC-AUC 0.9354, PR-AUC 0.8819 を記録して最良となり，重み付き平均（0.9237），Mean 集約（0.9202），Max 集約（0.8955）の順となった．

**総当たり探索との比較**

全 6 モデルから 4 モデルを選択する全 15 通りの組み合

© 2026 Information Processing Society of Japan

表 4　各検知器および提案手法の計算コストの実測値
**Table 4**　Measured training time, inference time, and screening overhead.

| 検知器 | 学習時間 [s] | 推論時間/区間 [$\mu$s] |
|---|---|---|
| Mahalanobis 距離 | 0.028 | 0.65 |
| Elliptic Envelope | 0.919 | 0.48 |
| GMM 負対数尤度 | 0.440 | 2.95 |
| PCA 再構成誤差 | 0.033 | 2.16 |
| Isolation Forest | 0.587 | 5.38 |
| LOF | 0.008 | 2.08 |
| 無選別（全 6 種） | — | 47.3 |
| 提案手法（選択 4 種） | — | **38.5** |

※モデルスクリーニング自体の処理時間は $17.087 \pm 0.654$ ms であった．なお，アンサンブル推論時間には基底検知器の実行時間と統合処理のオーバーヘッドが含まれる．

わせを総当たりで評価した結果，提案手法が選択した 4 モデルの組み合わせが平均 ROC-AUC 0.9354 を記録し，全 15 通りの中で第 1 位となった．

**計算コストの実測**

表 4 に，各モデルの学習時間，1 区間あたりの推論時間，およびアンサンブル統合時の計算コストの実測値を示す．モデルスクリーニング自体の全体計算量は，前述の通り全ペア間相関計算に由来する $\mathcal{O}(|M|^2 n)$ に留まり，実測処理時間は $17.087 \pm 0.654$ ms であった．これは学習フェーズにおいて極めて低オーバーヘッドで動作することを示している．また，1 区間（5 秒窓）あたりの推論時間は，選択された 4 モデルの合計で 38.5 $\mu$s となり，無選別アンサンブル（全 6 モデル合計 47.3 $\mu$s）と比較して約 19%削減された．

## 5. 結果と考察

### 5.1 各モデルの挙動解析とスクリーニングの妥当性

正解ラベルを用いないモデルスクリーニング機構が，各検知器の特性や不適切な挙動を正しく捉えてモデル選別を行えたかを分析・検証する．具体的には，除外対象となった LOF の不振要因，選択された Mahalanobis 距離および GMM の安定性の背景，そして提案した 3 指標の相互補完的な役割について順に考察する．

**LOF の不振要因**

LOF が著しく低い検知性能を示した主因は，本手法が採用した 5 秒時間窓による統計量化と LOF の動作原理とのミスマッチにある．LOF は局所的な点群の密度比に基づき異常判定を行う．しかし，パケット列を 5 秒間の平均値や出現数へ集約する前処理によって個々のパケットの局所的構造が平滑化され，さらに 29 次元の特徴空間において距離の差分が縮小した結果，異常区間と正常区間の局所密度の差が喪失したと考えられる．提案手法のスクリーニングにおいては，正解ラベルを用いずに，指標 (1)CV の異常な高さ（6.302）および指標 (2) 相関の低さ（0.579）によって，この不適切な挙動を示した LOF を確実に孤立ノイズとして除外できた．

**Mahalanobis 距離・GMM の安定性**

Mahalanobis 距離および GMM 負対数尤度が全日程で高い性能を示した背景には，プロトコル統計量の多次元依存構造がある．パケットサイズ，TTL，TCP フラグの出現率等の連続値特徴量は，正常通信時において強い相関や多峰性の分布を形成する．Mahalanobis 距離は共分散構造の崩れを捉え，GMM は正常トラフィックの多峰的密度分布を正確にモデル化できるため，安定したスクリーニング指標値を示し，検知においても優位に機能したと考えられる．

**3 指標の相補的役割**

本評価結果は，提案した 3 指標が相互補完的に機能することを示している．LOF は指標 (3)Contrast 単体では全モデル中最良の数値（3.512）を示したが，これは真の判別力ではなくノイズに起因する分布の歪みであった．指標 (1)CV および指標 (2) 相関を組み合わせることで，この擬似的な高評価を判定し，不適切なモデルとして適切に排除することが可能となった．また，重複検知器（Elliptic Envelope）の排除を含め，多角的な指標設計がモデル選択の頑健性向上に寄与している．総当たり評価における 1 位の組み合わせとスクリーニング結果が完全一致した事実も，正解ラベル非依存な本選択機構の有効性を裏付けている．

### 5.2 Rank 集約の有効性と未知攻撃への汎化性能

モデルスクリーニングにより選定された検知器群に対し，Rank 集約が有効に機能したメカニズム，およびそれが未知の攻撃シナリオに対する汎化性能へ与える影響について考察する．具体的には，基底検知器間のスコア分布差の吸収効果，および曜日（攻撃種別）ごとの検知性能のばらつき低減による安定性について順に分析する．

**スコア分布差の吸収**

各モデルが出力する未加工スコアの分布形態は大きく異なる．Mahalanobis 距離は二乗距離に由来する重い裾を持ち，PCA 再構成誤差は狭い領域にスコアが集中し，Isolation Forest は階層構造に起因する離散性を示す．Min-Max 正規化を行っても，これらを加算・比較した場合には特定モデルの分布形状が支配的となる．Max 集約の低迷（ROC-AUC 0.8955）は，特定モデルの突発的な誤検知スコアをそのまま採用してしまう点に起因する．Rank 集約はスコアを順位に変換して一様分布化するため，スケールや分布形状の差異を解消し，各モデルの相対的スコアのみを公平に統合できたと考えられる．

**曜日別攻撃差分に対する安定性**

単体モデルの性能は攻撃種別（曜日）によって大きく変動する．例えば Isolation Forest はポートスキャン（金曜日）に対して高い検知力を示す一方，特徴量の相関変化が

© 2026 Information Processing Society of Japan

主となる Web 攻撃（木曜日）では判別力が低下する．提案手法による Rank 集約アンサンブルは，単体モデルの強みを維持しつつ弱点を補完することで，最悪日（火曜日）の ROC-AUC を 0.8675 に底上げし，日ごとの性能ばらつきを低減させた．これは，事前情報の存在しない未知の攻撃環境においても安定した検知を達成できることを示唆している．

### 5.3 実運用における効率性と手法の限界

**計算資源の削減効果**

モデルスクリーニングの処理時間（$17.087 \pm 0.654$ ms）は無視できるほど軽微であり，学習時間が最も大きい Elliptic Envelope を排除したことで，全体の学習および再学習コストが大幅に削減された．また，推論時間が約 19%削減されたことは，5 秒窓でのリアルタイムインライン監視における余剰リソースの確保に直結する．

**本手法の限界と今後の展望**

本研究における課題と限界として，以下が挙げられる．(1) 検知器数 6，選択数 $K = 4$ という小規模な探索空間での検証にとどまっており，より多様なモデル群に対するスケーラビリティの検証を要する．(2) ハイパーパラメータ（相関閾値 0.95 等）の感度分析やデータセット依存性の評価が十分ではない．(3) 単一のデータセット（CICIDS2017）での評価であるため，異なる通信環境データにおける汎化性の実証が必要である．今後は，メタ学習型 UOMS 手法との定量的比較，時間窓幅の感度検証，およびリアルタイムなオンライン学習環境への適用拡張を進める．

## 6. おわりに

本研究では，正常トラフィックのみを学習データとする教師なしアンサンブル NIDS において，環境依存性の低い 29 特徴量の採用と，正解ラベルを用いない 3 つの内部指標（スコア安定性，他モデルとの順位相関，上位分離度）に基づくモデルスクリーニング，および選択された検知器の Rank 集約を組み合わせた手法を提案した．CICIDS2017 を用いた評価では，6 検知器のうち Elliptic Envelope と LOF が除外され，残る 4 検知器による Rank 集約アンサンブルが単体最良および無選別アンサンブルをいずれも上回る検知性能（4 評価日平均 ROC-AUC 0.9354，PR-AUC 0.8819）を達成した．特に，評価日別の最悪値が全条件中で最高であり，攻撃種別が事前に未知である条件下での頑健性が確認された．また，選択された組合せは $K = 4$ の全 15 通りを事後的に評価した際の最良組合せと一致し，スクリーニングの処理時間は約 17 ms にとどまった．以上より，正解ラベルも外部のメタ学習用データセットも用いることなく，検知性能と計算コストの双方を改善するモデル選択が可能であることを示した．

**参考文献**


[1] Rousseeuw, P. J. and Driessen, K. V.: A Fast Algorithm for the Minimum Covariance Determinant Estimator, *Technometrics*, Vol.41, No.3, pp.212–223 (1999).

[2] McLachlan, G. and Peel, D.: *Finite Mixture Models*, John Wiley & Sons (2000).

[3] Shyu, M.-L., Chen, S.-C., Sarinnapakorn, K. and Chang, L.: A Novel Anomaly Detection Scheme Based on Principal Component Classifier, *Proc. ICDM Workshop on Data Mining for Computer Security* (2003).

[4] Liu, F. T., Ting, K. M. and Zhou, Z.-H.: Isolation Forest, *Proc. IEEE International Conference on Data Mining (ICDM)*, pp.413–422 (2008).

[5] Breunig, M. M., Kriegel, H.-P., Ng, R. T. and Sander, J.: LOF: Identifying Density-Based Local Outliers, *Proc. ACM SIGMOD International Conference on Management of Data*, pp.93–104 (2000).

[6] Sharafaldin, I., Lashkari, A. H. and Ghorbani, A. A.: Toward Generating a New Intrusion Detection Dataset and Intrusion Traffic Characterization, *Proc. 4th International Conference on Information Systems Security and Privacy (ICISSP)*, pp.108–116 (2018).

[7] Mirsky, Y., Doitshman, T., Elovici, Y. and Shabtai, A.: Kitsune: An Ensemble of Autoencoders for Online Network Intrusion Detection, *Proc. Network and Distributed System Security Symposium (NDSS)* (2018).

[8] Zhao, Y., Rossi, R. and Akoglu, L.: Automatic Unsupervised Outlier Model Selection, *Advances in Neural Information Processing Systems (NeurIPS)*, Vol.34, pp.4489–4502 (2021).

[9] Zhao, Y., Zhang, S. and Akoglu, L.: Toward Unsupervised Outlier Model Selection, *Proc. IEEE International Conference on Data Mining (ICDM)*, pp.773–782 (2022).

[10] Phan, H.-P., Vu, T.-A., Kieu, T., Xuan, S. H., Yang, B. and Jensen, C. S.: Automatic Unsupervised Ensemble Outlier Model Selection, Extended Version, *arXiv preprint arXiv:2605.16567* (2026).

[11] Aggarwal, C. C. and Sathe, S.: Theoretical Foundations and Algorithms for Outlier Ensembles, *ACM SIGKDD Explorations Newsletter*, Vol.17, No.1, pp.24–47 (2015).

[12] Zimek, A., Campello, R. J. G. B. and Sander, J.: Ensembles for Unsupervised Outlier Detection: Challenges and Research Questions, *ACM SIGKDD Explorations Newsletter*, Vol.15, No.1, pp.11–22 (2014).

[13] Ma, M. Q., Zhao, Y., Zhang, X. and Akoglu, L.: The Need for Unsupervised Outlier Model Selection: A Review and Evaluation of Internal Evaluation Strategies, *ACM SIGKDD Explorations Newsletter*, Vol.25, No.1, pp.19–35 (2023).

[14] Klüttermann, S. and Müller, E.: Evaluating and Comparing Heterogeneous Ensemble Methods for Unsupervised Anomaly Detection, *Proc. International Joint Conference on Neural Networks (IJCNN)* (2023).

[15] Engelen, G., Rimmer, V. and Joosen, W.: Troubleshooting an Intrusion Detection Dataset: the CICIDS2017 Case Study, *Proc. IEEE Security and Privacy Workshops (SPW)*, pp.7–12 (2021).


© 2026 Information Processing Society of Japan