重ね合わせ知覚を用いたCAPTCHA認証の提案と生成AIに対する突破耐性評価

安田 誠崇[1,a)]　島本 裕大[1]　秋山 満昭[2]　山内 利宏[3]

概要：既存の CAPTCHA 認証の多くは，提示画面の視覚情報から解答や必要な操作を把握できる構成となっている．このような CAPTCHA 認証に対しては，画像認識や機械学習を用いた従来の突破手法に加え，視覚言語モデルを備えた生成 AI の発展により，ほとんどの種類において突破事例が報告されている．そこで本研究では，初期画面に表示された個々の視覚要素のみから解答情報を直接読み取れず，複数の視覚要素を移動・重ね合わせることにより，文字や方向などの解答情報を知覚する CAPTCHA 認証を提案する．また，構成や操作方法の異なる 4 種類の課題を実装し，既存研究において複数種類の CAPTCHA 認証を自律的に突破する能力が示されているエージェント型ソルバ Halligan と Web インターフェース上の ChatGPT-5.5 を用いて突破耐性を評価と，共著者 2 名による予備的なパイロット調査を実施した．評価の結果，Halligan は全課題の突破に失敗し，多数のトークンと数分規模の推論時間を要した．ChatGPT-5.5 は 60 件中 26 件で正しい回答値を出力したものの，同様に数分規模の推論時間を要した．一方で，共著者を対象とした予備調査では，すべての課題に正答し，平均解答時間は最大で約 31 秒であった．以上の結果から，操作結果を確認しながら位置修正を反復する課題構成は，人間による解答を維持しつつ，生成 AI による自動突破を困難にする可能性を示した．

Design of a CAPTCHA Scheme Using Overlay-Induced Visual Perception and an Evaluation of Its Resistance to Generative AI

Masataka Yasuda[1,a)]　Yuta Shimamoto[1]　Mitsuaki Akiyama[2]　Toshihiro Yamauchi[3]

Abstract: Many existing CAPTCHAs allow the required answer or operation to be inferred from visual information on the screen. For such CAPTCHAs, in addition to conventional attacks based on image recognition and machine learning, successful attacks have been reported for most types with advances in generative AI equipped with vision-language models. We propose a CAPTCHA scheme in which answer information, such as characters and directions, is revealed by moving and overlaying multiple visual elements rather than being directly readable on the initial screen. We implemented four task types and evaluated them using Halligan, an agent-based solver shown in prior work to autonomously solve multiple CAPTCHA types, and ChatGPT-5.5 through its web interface. Halligan failed to solve any task while requiring substantial token usage and several minutes of inference. ChatGPT-5.5 produced correct answers in 26 of 60 trials but similarly required several minutes. In a preliminary pilot study with coauthors, all tasks were solved correctly, and the longest mean solution time was approximately 31 seconds. These results suggest that iterative position adjustment based on interaction outcomes may hinder automated solving while preserving human solvability.

1. はじめに

大規模言語モデルをはじめとする生成 AI は，登場以降利用が急速に拡大している．米国の 18 歳から 64 歳を対象

[1] 岡山大学 大学院環境生命自然科学研究科
Graduate School of Environmental, Life, Natural Science and Technology, Okayama University, Okayama, 700-8530, Japan
[2] NTT 株式会社
NTT, Inc.
[3] 岡山大学学術研究院環境生命自然科学学域
Faculty of Environmental, Life, Natural Science and Technology, Okayama University, Okayama, 700-8530 Japan
[a)] yasuda-m2@s.okayama-u.ac.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

とした継続調査では，生成 AI の利用率は 2026 年 5 月時点で 61.8%に達したと報告されている [1]．生成 AI の用途には，Web 検索機能やブラウザ操作機能を利用して，ユーザの質問に関連する Web サイトへアクセスし，複数の情報を取得することも含まれている [2]．

一方，Web サービスに対する自動アクセスは，生成 AI の登場以前から，情報の大量取得や不正ログインなどが問題となってきた．加えて，生成 AI や AI エージェントによる自律的な Web アクセスの事例も報告されており，問題がさらに拡大する可能性がある [3]．

そこで，Web サイトへの機械的な自動アクセスに対し，CAPTCHA 認証が用いられている．CAPTCHA 認証は，ユーザに課題を提示し，課題の解答結果や操作過程に基づいて，人と bot を識別する仕組みである．

しかし，AI の発展に伴い，bot には困難であると考えられてきた CAPTCHA 認証に対して，AI による突破事例が報告されている．生成 AI の登場以前には，画像認識や機械学習を利用した突破手法が報告されてきた [4], [5]．さらに，生成 AI の登場により，CAPTCHA 認証画面の操作対象や課題の目的を推論し，ブラウザ上で操作を実行する自律的な突破も可能となっている [6], [7]．

既存の CAPTCHA 認証では，初期画面に解答対象となる文字，選択対象となる画像が表示されている場合が多い．これは，CAPTCHA 認証課題の提示時点で，解答または最終的に実行すべき操作を推定できる構成である．このような課題構成では，生成 AI の画像理解能力および推論能力が向上するほど，自動突破が容易になる可能性がある．

そこで本研究では，初期画面に表示された個々の視覚要素のみからは解答情報を直接読み取ることができず，視覚要素を移動・重ね合わせた後に初めて解答情報を知覚できる CAPTCHA 認証を提案する．本研究における重ね合わせ知覚とは，複数の視覚要素が特定の位置関係に配置された場合にのみ，文字，入力順序または移動方向などの情報を理解することを指す．提案方式では，生成 AI が初期画面を解析するだけでなく，操作対象と移動先を適切に選択した上で，操作後の画面を確認しながら位置を修正し，顕在化した情報から正解値を導出する必要がある．本研究は，重ね合わせ知覚に基づく CAPTCHA 認証を設計・評価し，人間による解答を可能としつつ，生成 AI による正解値推定および自動突破を困難にする課題構成上の要素を明らかにすることを目的とする．

本研究では，次の Research Question（RQ）を設定した．

RQ：重ね合わせ知覚に基づく課題構成上のどのような要素が，人間による解答を可能とし，生成 AI による CAPTCHA 認証の突破を困難にするか．

本研究の主な貢献を以下に示す．

- CAPTCHA 課題の操作前において，配置候補を絞り込みにくい課題構成が，生成 AI による正解値推定を困難にする可能性を示した．
- CAPTCHA 課題の操作過程において，配置・確認・修正の反復を必要とする探索的な課題構成が，生成 AI による自動突破を困難にする可能性を示した．
- 4 種類の提案 CAPTCHA 課題に対して，人間による解答可能性と既存 CAPTCHA 認証と同程度の解答時間を予備的に確認し，実運用に向けた可能性を示した．

2. 関連研究

2.1 既存 CAPTCHA 認証

CAPTCHA 認証には，文字認識型，画像選択型，パズル型および行動分析型などの方式が存在する [8]．文字認識型では，歪みやノイズを加えた文字列を正しく読み取り，入力させる [9]．画像選択型では，複数の画像から指定された対象を含む画像を選択させる [10]．パズル型では，画面上の視覚要素を適切な位置に移動させる方式が提案されている [11]．また，明示的な課題を提示せず，端末情報やマウス軌跡などにより識別する方式も存在する [8]．

これらのうち，視覚的な課題を提示する方式では，提示時点で解答対象または操作対象を把握できる場合がある．文字認識型では読み取るべき文字列が表示され，画像選択型では選択候補が表示される．また，パズル型では移動対象と，その配置先となる領域が同時に表示される．

また，人の視覚的な知覚特性を利用した取り組みとして，Ding らは，イラストと錯覚を利用する Illusion CAPTCHA を提案した [12]．Illusion CAPTCHA では，画像の見方によって認識される物体が変化する錯覚を利用し，生成 AI に対する耐性が報告されている．一方，提示課題の錯覚に隠されたイラストに関する前提知識が必要となる．これに対し，本研究では，特定の物体や文化的知識に依存しない，アルファベット，数字，および記号を用いる．

2.2 CAPTCHA 認証に対する AI 突破

視覚言語モデルといった生成 AI を用いて複数の CAPTCHA 認証に対する突破能力を評価する研究が行われている．Wu らは，文字認識，クリック位置推定，インタラクティブ操作および論理問題から構成される 20 種類の CAPTCHA 課題を統一的に評価する MCA-Bench を提案した [6]．評価の結果，単純な視覚認識課題では高い性能を示す一方，物理的な操作や多段階の推論を必要とする課題では突破性能が低下することを報告している．

さらに，Teoh らは，2025 年の USENIX Security Symposium で ChatGPT の API を用いて CAPTCHA 認証の目的や GUI 要素を解析し，クリックやドラッグなどのブラウザ操作を自律的に生成・実行するエージェント型 CAPTCHA

© 2026 Information Processing Society of Japan

ソルバ Halligan を提案した [7]．Halligan は，CAPTCHA 認証ごとの追加学習を行わず，LLM による推論を用いることで，文字入力，画像選択，回転，スライド，ドラッグなど，視覚認識および操作を含む 26 種類の CAPTCHA 認証を対象に突破することができる．評価では，各種類 100 問の合計 2,600 問の CAPTCHA 課題に対して 60.7%の突破率を示しており，視覚認識だけでなく，課題理解からブラウザ操作までを含む CAPTCHA 突破が可能であることを報告している．

2.3 本研究の位置付け

reCAPTCHA v2 や GeeTest Slider といった既存の CAPTCHA 認証では，初期画面から解答や操作を推定できる場合がある．また，既存の生成 AI による突破には，視覚認識や推論に加え，Halligan のように未知の CAPTCHA 認証に対してブラウザ操作を自律的に実行する手法が報告されている．このため，生成 AI により，一連の認証突破操作ができることを想定した評価が必要である．

これに対し，本研究では，視覚要素を適切な位置へ操作することで初めて解答情報が形成される課題構成を対象とする．さらに，初期画面からの正解値推定能力と，状態確認や位置修正を含む一連の自動突破能力を分離して評価することで，生成 AI による CAPTCHA 突破を困難にする課題構成上の要素を明らかにする．

3. 提案 CAPTCHA 認証

3.1 AI 突破耐性を持つ CAPTCHA 認証の設計要素

生成 AI による CAPTCHA 認証の突破を困難にする課題構成を検討するにあたり，本研究では，解答に至るまでに複数の処理を段階的に必要とする構成に着目した．具体的には，初期画面から解答情報を直接取得するのではなく，視覚要素間の関係から適切な配置位置を推定し，実際に操作した後に得られる情報から正解値を導出する．

この構成では，適切な配置位置を推定できなければ，解答に必要な情報そのものが十分に顕在化しない．また，適切な位置へ配置できた場合でも，操作後に現れた文字，順序または方向などの情報を正しく読み取り，正解値へ変換する必要がある．したがって，配置位置の推定や操作後の情報取得における誤りが後続の情報取得にも影響するため，一連の操作を完遂できない可能性が高い．

以上から，本研究では，適切な配置位置の推定，視覚要素の操作，および操作後に顕在化した情報の読み取りを段階的に必要とする課題構成が，生成 AI による CAPTCHA 認証の突破を困難にするという仮説を立てた．

3.2 重ね合わせ知覚を用いた CAPTCHA 認証

3.1 節で示した仮説を検討するため，本研究では，複数の視覚要素を移動・重ね合わせることによって解答情報が顕在化する 4 種類の CAPTCHA 課題を設計した．以降では，それぞれをパターン (i)〜(iv) と呼ぶ．**表 1** に各パターンにおけるタスクの特徴を示す．なお，パターン (ii)〜(iv) の初期画面および正解位置へ移動後の画面を，付録 A.1.1 節の**図 A·1**〜**図 A·6** に示す．

表 1: 各問題パターンのタスク説明

問題パターン	課題遂行時のタスク内容
パターン (i)	視覚要素を重ね合わせ，顕在化したアルファベットを読み取って入力
パターン (ii)	複数の視覚要素を適切な位置へ移動し，顕在化したアルファベットを示された順序に従って入力
パターン (iii)	視覚要素を適切な位置へ移動し，顕在化した数字の位置に対応するアルファベットを数字の順序に従って入力
パターン (iv)	視覚要素を重ね合わせ，顕在化した起点から方向情報に従って入力位置をたどり，該当するアルファベットを入力

4 種類の課題はいずれも，視覚要素を移動・重ね合わせる操作を基本とした．一方で，重ね合わせによって顕在化する情報，および顕在化した情報から正解値を導出する方法は異なる．これらの構成を比較することで，どのような推定，操作および読み取りを必要とする課題が，生成 AI による突破を困難にするかを分析した．

課題への回答方法はボタン入力で統一した．また，位置情報や方向情報を入力位置と対応づけるため，入力ボタンを 3 行 3 列に配置し，共通して A〜I の 9 文字を正解値に用いた．さらに，特定の物体や文化的知識への依存を抑えるため，解答に必要となる情報はアルファベット，数字，および方向を表す記号によって構成した．

パターン (i)：視覚要素の重ね合わせによってアルファベット文字列を顕在化させ，その文字列から正解値を導出する構成である．**図 1** に初期画面を，**図 2** に正解位置へ移動した後の画面を示す．具体的な実装として，画面上に 2 つの移動可能な視覚要素を提示する．それぞれの視覚要素には解答となる文字列の一部が含まれており，適切な位置関係で重ね合わせることで，分割されていた情報が結合されてアルファベット文字列が顕在化する．このため，操作後の状態を確認しながら位置関係を調整する必要がある．

パターン (ii)：視覚要素の重ね合わせによってアルファベットとその入力順序を顕在化させ，示された順序に基づいて正解値を導出する構成である．具体的な実装として，固定されたボードと，3 つの移動可能な要素を提示する．各視覚要素をボード上の適切な位置へ重ね合わせることで，解答に使用するアルファベットと入力順序が顕在化する．このため，複数の視覚要素についてボードとの位置関

© 2026 Information Processing Society of Japan

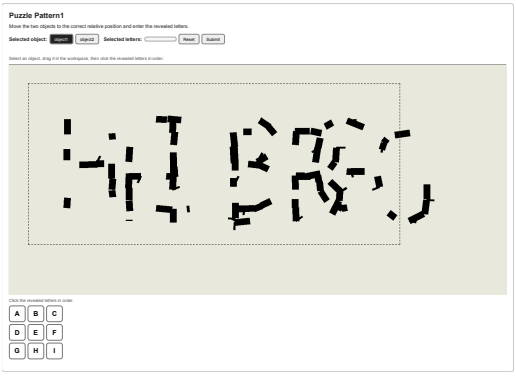


図 1: パターン (i) の初期画面



図 2: パターン (i) の正解位置へ移動後の画面

係を把握する必要がある．

パターン (iii)：視覚要素の重ね合わせにより数字と位置情報を顕在化させ，入力位置との対応関係から正解値を導出する構成である．具体的には，固定された背景と 1 つの移動可能な視覚要素を提示する．視覚要素を背景上の適切な位置へ重ね合わせることで，9 分割された領域内に入力順序を示す数字が顕在化する．数字の位置と対応する入力ボタンを特定し，数字が示す順序に従って正解値を導出する．このため，視覚要素の位置合わせに加えて，操作後に得られた位置情報から正解値を導出する処理が必要となる．

パターン (iv)：視覚要素の重ね合わせによって起点となるアルファベットと移動方向を顕在化させ，起点から方向情報に従って入力位置をたどることで正解値を導出する構成である．具体的な実装として，固定された鍵型の視覚要素と，1 つの移動可能な鍵型の視覚要素を提示する．2 つの視覚要素を適切な位置で重ね合わせることで，起点文字と移動方向を表す矢印が顕在化する．起点から矢印が示す方向へ入力ボタンをたどり，正解値を導出する．このため，視覚要素の位置合わせに加えて，操作後に得られた方向情報から正解値を導出する処理が必要となる．

4. 評価方法

4.1 エージェント型 AI による評価方針

提案 CAPTCHA 認証では，正解値を導出するために，視覚要素の移動，操作結果の確認，および必要に応じた位置修正が必要となる．そこで，生成 AI がこれらの操作を自律的に実行し，CAPTCHA 認証を突破できるかを確認するため，以下の Sub Question1 を設定した．

SQ1：提案 CAPTCHA 認証は，視覚要素の認識，操作および位置修正を自律的に行う生成 AI に耐性を持つか．

SQ1 を検証するため，本評価では 2.2 節で示した Halligan [7] を用いた．Halligan は，視覚言語モデルを利用して CAPTCHA 認証画面を解析し，解法となるブラウザ操作コードを生成・実行することで，クリックやドラッグ等を自律的に行うエージェント型 CAPTCHA ソルバである．このため，提案 CAPTCHA 認証で必要となる視覚要素の認識，操作および位置修正を含む一連の突破過程を評価できることから選定した．

公開されている Halligan の実装は，GPT-4o をベースに用いていた．本評価では，より新しいモデルに対する提案方式の耐性を確認するため，2026 年 6 月時点で最新モデルであった GPT-5.5 に変更し，API 仕様に対応するためコードの一部を修正した．ただし，提案方式に固有の解法，正解配置または解答情報を与える変更は行っていない．

評価対象は， 3.2 節で設計したパターン (i)〜(iv) とした．各パターン 5 問の CAPTCHA 問題を生成し，各問題に対して 3 回ずつ評価し，1 パターン当たり 15 試行，4 パターン全体で合計 60 試行を独立して実施した．Halligan が回答値を送信し，正解と判定された場合を突破成功とした．一方で，送信した回答値が正解値と異なる場合，およびブラウザ操作途中で処理が停止し，送信処理を実行できなかった場合は，突破失敗とした．これにより，回答送信到達という処理上の成否と，CAPTCHA 認証を突破できたかという認証上の成否を区別した．

評価指標として，突破件数，サーバへの回答値送信到達件数，GPT-5.5 API の Input および Output トークン数，ならびに総推論時間を取得した．これらは，突破に必要となる計算資源および時間のコストを評価するために用いた．また，回答値と正解値との類似度を確認するため，レーベンシュタイン距離を算出した [13], [14]．ただし，課題間で正解文字列の長さが異なるため，課題間の絶対的な難易度を直接比較する指標ではなく，誤答が正解値にどの程度近かったかを補助的に確認するために用いた．

4.2 Web インターフェース上の AI による評価方針

Halligan による評価では，ブラウザ操作コードの生成および実行能力が結果に影響する．そこで，ブラウザ操作を伴わない条件において，初期画面のみから正解値を推定できるかを確認するため，以下の Sub Question2 を設定した．

SQ2：生成 AI は，提案 CAPTCHA 認証の初期画面画像のみから正解値を推定できるか．

SQ2 を検証するため，評価には，Web インターフェースを介する ChatGPT-5.5（以下，Web 版 ChatGPT）を使用

© 2026 Information Processing Society of Japan

した．推論設定を「高」とし，各試行で知識が共有されないように一時チャットで実施した．推論設定理由として，応答速度よりも推論能力を重視し，提案 CAPTCHA 認証から正解値を推定できるかを評価するためである．入力として，各課題の初期画面画像を 1 枚添付し，プロンプトには，以下の文章を使用した．

「問題を解くために必要となる入力値を出力してください.」

入力画像例を付録 A.2.1 の **図 A·7** に示す．このとき初期画面画像以外に，ドラッグ後の画面，正解画像，課題ごとの追加説明は入力していない．

評価対象は Halligan 評価と同様に，各パターン 15 試行，合計 60 試行とした．Web 版 ChatGPT が出力した回答値と問題の正解値が完全に一致した場合を正解とした．

評価指標として，回答の完全一致件数およびプロンプトの送信から回答値が出力されるまでの推論時間を取得した．また，本評価でも同様に，回答値と正解値との類似度を確認するため，レーベンシュタイン距離を算出した．

4.3 課題構成の違いによる比較評価方針

4.1 節と 4.2 節では，ブラウザ操作を含む自動突破と，初期画面のみからの正解値推定のそれぞれについて評価方針を示した．これらの評価結果を用いて，視覚要素の構成および操作方法の違いが両者に与える影響を比較するため，以下の Sub Question3 を設定した．

SQ3：視覚要素の構成と操作方法の違いは，生成 AI による正解値の推定と自動突破にどのような影響を与えるか．

SQ3 については，パターン (i)〜(iv) 間で，Web 版 ChatGPT による正解値推定の結果，Halligan による突破件数，サーバ送信到達件数，および推論コストを比較した．

4.4 ユーザ調査に基づく正答率および解答時間の評価方針

CAPTCHA 認証では，生成 AI による突破を困難にするだけでなく，人が課題を解答できることが求められる．そこで，提案方式が人にとって解答可能であることを予備的に確認するため，以下の Sub Question4 を設定した．

SQ4：提案 CAPTCHA 認証は人間にとって解答可能か．

SQ4 を検証するため，共著者 2 名を対象としたパイロット調査を実施した．各参加者は，パターン (i)〜(iv) を各 3 問，合計 12 問解答した．CAPTCHA 認証画面が表示されてから，参加者が正答するまでの時間を解答時間として記録した．評価指標として，正答率および解答時間を取得し，パターンごとの違いおよび試行回数に伴う解答時間の変化を確認した．

5. 評価結果

5.1 Halligan によるブラウザ操作評価結果

表 2 に，Halligan による評価結果を示す．評価の結果，正しい回答値を送信した試行は確認されず，突破件数は 0 件であった．一方，Halligan が回答値をサーバへ送信する段階まで到達した試行は 40 件であった．これは回答値の送信処理まで到達したことを意味する．

表 2: Halligan によるブラウザ操作評価結果

項目	(i)	(ii)	(iii)	(iv)	全体
突破件数	0/15	0/15	0/15	0/15	0/60
サーバ送信到達件数	12/15	13/15	1/15	14/15	40/60
平均 Input [token]	67,179	25,734	16,656	28,181	34,437
平均 Output [token]	29,867	37,065	39,061	23,664	32,414
平均総推論時間 [s]	568	624	743	454	597

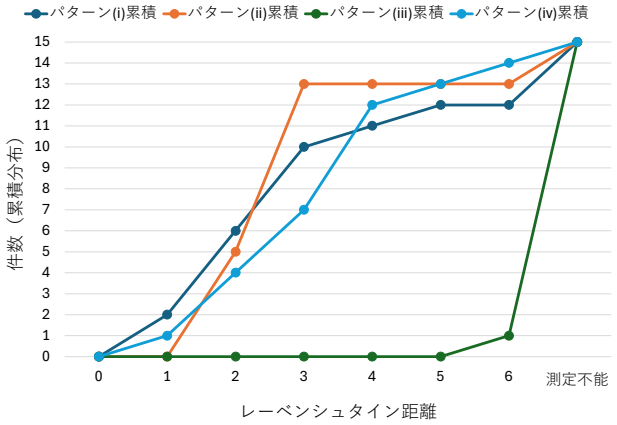


図 3: Halligan におけるレーベンシュタイン距離

全体における 1 試行当たりの平均 Input は 34,437 トークン，平均 Output は 32,414 トークンであり，平均総推論時間は 597 秒であった．

各パターンでは，パターン (i) が最も平均トークン消費が多く，パターン (iii) が最も平均総推論時間が長かった．一方，パターン (iv) は平均トークン消費および平均総推論時間が最も小さく，サーバ送信到達件数も 14 件と最も多かった．しかし，いずれのパターンにおいても，サーバ送信値は正解値と一致しなかった．

図 3 に，パターン別のレーベンシュタイン距離の累積分布を示す．サーバ送信に到達しなかった試行は測定不能とした．パターン (i)，(ii)，(iv) では，レーベンシュタイン距離が 1 または 2 となる回答値が，それぞれ 6 件，5 件，4 件確認された．一方，パターン (iii) では 14 件がサーバ送信に到達せず，回答値の近接性を他のパターンと同様に確認できなかった．

実行ログを確認した結果，突破失敗の要因として，生成 AI により出力されたコードの実行時エラー，ドラッグ位置の誤りによる解答情報の読み取り失敗，および内部で生成された回答候補とサーバ送信値との不一致が確認された．

以上より，SQ1 に対して，Halligan は全 60 試行で提案 CAPTCHA 認証を突破できなかった．20 試行ではサーバ送信に到達せず，実行ログではブラウザ操作コードの実行

© 2026 Information Processing Society of Japan

表 3: Web 版 ChatGPT による静止画像評価結果

項目	(i)	(ii)	(iii)	(iv)	全体
完全一致件数	0/15	10/15	11/15	5/15	26/60
平均推論時間（一致）[s]	–	470	452	494	467
平均推論時間（不一致）[s]	808	555	728	460	659

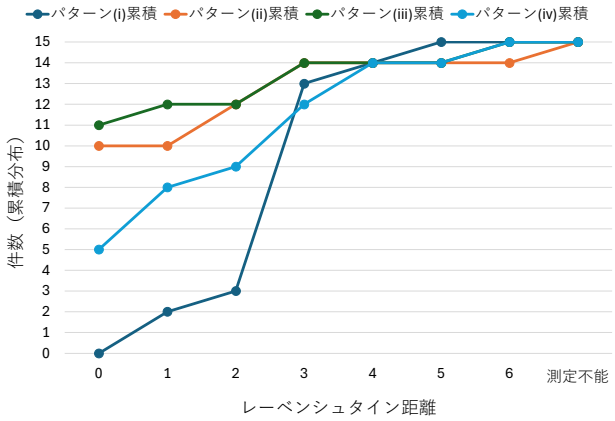


図 4: Web 版 ChatGPT におけるレーベンシュタイン距離

時エラーなどが確認された．一方，40 試行ではサーバへ回答値の送信が行われたものの，正解値と一致する回答値は確認されなかった．

5.2 Web 版 ChatGPT による静止画像評価結果

表 3 に，Web 版 ChatGPT による静止画像評価結果を示す．全体として，Web 版 ChatGPT が出力した回答値と正解値が完全に一致した割合は 43.3%であった．パターン別の完全一致件数は，パターン (i) が 0 件と最も少なく，パターン (iii) が 11 件と最も多かった．

完全一致時と不一致時の全体の平均推論時間を比較すると，それぞれ 467 秒と 659 秒であり，不一致時の方が長かった．一方，パターン (iv) では，完全一致時の平均推論時間の方が長かった．また，パターン (i) では完全一致に至らなかったため，完全一致時と不一致時の平均推論時間を比較できなかった．以上より，回答の正誤による推論時間の傾向はパターン間で一貫しておらず，本結果のみから推論時間と正誤との関係を判断することは困難である．

図 4 に，パターン別のレーベンシュタイン距離の累積分布を示す．回答値を出力できなかった試行は測定不能とした．正解値との距離が 2 以下となる回答値は，パターン (i) では 3 件であったのに対し，パターン (ii)，(iii)，(iv) では，それぞれ 12 件，12 件，9 件であった．

以上より，SQ2 に対して，初期画面のみから正解値を推定できた試行は 26/60 であった．パターン別では，パターン (ii) では 10/15，パターン (iii) では 11/15，パターン (iv) では 5/15 の試行で正解値を推定できた．一方，パターン (i) では正解値と一致する回答値を推定できなかった．

5.3 4 種類の課題比較

5.2 節の結果より，Web 版 ChatGPT 評価では，26/60 で正解値と一致する回答値を推定できたものの，パターンの違いによって結果は異なった．このため，初期画面からの正解値推定の成否は，課題構成によって異なることが確認された．

5.1 節の結果より，Halligan による評価では，全パターンで突破件数が 0 件であった．サーバ送信到達件数は，パターン (i)，(ii)，(iv) ではそれぞれ 12 件，13 件，14 件到達していた．一方で，パターン (iii) は 1 件であった．特に，静止画像評価で完全一致件数が最も多かったパターン (iii) では，Halligan によるサーバ送信到達件数が最も少なかった．このことから，初期画面から正解値の推定能力と，ブラウザ操作を含む一連の処理を完遂できる能力は異なることが分かった．

トークン消費は，パターン (i) が最も多く，97,046 トークンであった．また，平均総推論時間は，パターン (iii) が 743 秒と最も長かった．一方，パターン (iv) は，トークン消費，平均総推論時間が最も小さく，サーバ送信到達件数も最も多かった．しかし，いずれのパターンも突破には至らなかったことから，推論資源の消費量やサーバ送信への到達しやすさは，突破成功と直接対応しなかった．

以上より，SQ3 に対して，パターン (i) は初期画面からの正解値推定が最も困難であり，Halligan のトークン消費も最大であった．パターン (iii) は初期画面から正解値を推定しやすい一方，Halligan ではサーバ送信到達件数が最も少なく，推論時間も最長であった．また，パターン (iv) はサーバ送信まで到達しやすく推論コストも小さかったが，認証突破には至らず，初期画面からの正解値推定に対する耐性はパターン (ii)，(iii) よりも高かった．

5.4 共著者によるパイロット調査結果

表 4 に，共著者 2 名によるパイロット調査の結果を示す．実施の結果，正答率が 100%であった．

パターン別では，パターン (i) の平均解答時間が約 16 秒と最も短く，パターン (iv) が約 31 秒と最も長かった．また，試行回別に 4 パターンの平均解答時間を算出したところ，1 回目は 39.433 秒，2 回目は 19.641 秒，3 回目は 18.512 秒であり，2 回目以降では 1 回目より短い解答時間が確認された．参加者別および試行回別の詳細な結果は付録の **表 A·3**，**表 A·4** に示す．

以上より，SQ4 に対して，共著者 2 名によるパイロット調査評価では全ての課題で正答し，平均解答時間は最長で 31 秒程度であった．

6. 考察

6.1 正解値推定能力と自動突破能力の違い

5.3 節で示したように，Web 版 ChatGPT では，約 4 割

© 2026 Information Processing Society of Japan

表 4: パイロット調査結果

項目	(i)	(ii)	(iii)	(iv)
正答数／試行数	6/6	6/6	6/6	6/6
平均解答時間 [s]	16.362	29.356	26.397	31.334

の試行で初期画面から正しい回答値を推定できた．一方，Halligan による CAPTCHA 認証の自動突破件数は 0 件であった．この差は，正解に至るまでに必要となる処理が異なることが原因であると推察できる．提案方式では，生成 AI に対して，課題理解，操作対象の選択，配置位置の探索，操作後の状態確認，位置修正，解答情報の読み取り，回答値の生成という複数段階の処理が要求される．このため，各段階で生じた誤りは後続処理へ影響し，各段階を個別には実行できた場合でも，一連の処理のいずれかで誤りが生じることで，突破が困難となる可能性がある．

また，レーベンシュタイン距離が 2 以下となる回答は，パターン (i) では Halligan の方が多かった一方，パターン (ii)〜(iv) では Web 版 ChatGPT の方が多かった．この結果として，パターン (i) では固定された配置基準がなく，Web 版 ChatGPT は静止画像のみから 2 つの視覚要素の相対的な配置関係を推定する必要がある．これに対し，Halligan では，実際に視覚要素を操作し，操作後の状態を確認できる．この能力差が，パターン (i) における正解値への類似度の違いに影響した可能性がある．

6.2 課題構成が AI 耐性に与える影響

3.1 節では，適切な位置関係の推定，視覚要素の操作，および操作後に顕在化した情報の読み取りを段階的に必要とする課題構成が，生成 AI による突破を困難にするという仮説を立てた．評価結果から，単に解答情報を操作後に顕在化させるだけでなく，正しい配置位置をどのように推定させるかが AI 耐性に影響すると推察できる．

初期画面から配置候補を絞り込みやすい構成では，解答情報を操作後に顕在化させる場合であっても，操作を行わずに正解値を推定される可能性がある．パターン (ii) およびパターン (iii) では，固定されたボードまたは背景が配置位置を推定する手がかりとなり得る．静止画像評価では，それぞれ 10 件，11 件の一致が確認された．

一方，操作前の時点で配置候補を絞り込みにくい構成は，生成 AI による正解値の推定を困難にした可能性がある．パターン (i) では，2 つの視覚要素がともに移動可能であり，配置位置の基準となる固定要素が存在しない．このため，2 つの要素の相対的な配置候補から適切な位置関係を推定することが必要となる．静止画像評価では完全一致が 0/15 試行であり，エージェント型 AI 評価での平均総トークン数も 4 パターン中で最も多かった．

さらに，移動対象自体を認識できる場合でも，正解位置の探索・修正を必要とする構成は，生成 AI による正解値の推定を困難にする可能性がある．パターン (iv) では，移動要素が明確である一方，初期画面のみから正しい重ね合わせ位置を特定することは容易ではない．このため，実際に配置し，操作後の状態を確認し，必要に応じて位置を修正する探索的な操作が必要となる．静止画像評価の完全一致は 5/15 試行であり，パターン (ii)，(iii) より少なかった．

6.3 既存 CAPTCHA 認証との解答時間の比較

提案方式を CAPTCHA 認証として利用するためには，生成 AI による突破を困難にするだけでなく，人間が時間的負担なく解答できることが求められる．

Searles らは，実運用されている CAPTCHA 認証を対象として，人間による解答時間の違いを評価している [15]．このうち，視覚要素を適切な位置へ移動するパズル型 CAPTCHA では約 28〜30 秒，視覚情報の理解と操作を必要とするゲーム型 CAPTCHA では約 8〜42 秒の解答時間が報告されている．

本研究のパイロット評価では，提案方式の平均解答時間は約 16 秒〜約 31 秒であり，操作や視覚情報の理解を必要とする既存 CAPTCHA 認証と同程度であったことを推察できる．加えて，5.4 節より，課題を解く回数が増すことで操作方法への習熟が進む可能性が示されており，課題の慣れによる解答時の時間的負担は小さくなると推察できる．

以上より，解答時間の観点から，提案方式が実運用される既存の CAPTCHA 認証と比較して大きな負担を生じさせるものではないと推察できる．

6.4 人間と生成 AI の遂行結果および突破コスト

5.4 節より，人間による平均解答時間は約 16 秒〜約 31 秒であった．一方，Web 版 ChatGPT では，正解値と完全一致した試行でも平均約 467 秒，また，Halligan では，平均 454 秒〜743 秒を要した．このことから，人間と生成 AI との間で提案方式の遂行時間に大きな差が確認された．

さらに，Halligan による自動突破では GPT-5.5 API の利用に伴う金銭的コストが発生した．GPT-5.5 の標準 API 料金について，本評価で取得したトークン数から概算した 1 試行当たりの平均 API 利用料金は，約 0.85 ドル〜1.26 ドルであり，全体平均は約 1.14 ドルであった [16]．

以上より，提案 CAPTCHA 認証では，突破率だけでなく，自動突破に必要となる時間および金銭的コストも攻撃者側の負担となる可能性がある．

6.5 RQ への回答

以上の考察を踏まえ，RQ に対して，本評価では，重ね合わせ操作前に配置候補を絞りにくくし，操作過程で視覚情報の配置，確認，修正を反復する探索的な操作を必要とする課題構成が，生成 AI による突破を困難にする可能性

© 2026 Information Processing Society of Japan

が示された．一方で，単に視覚要素を移動・重ね合わせて解答情報を顕在化させるだけでは，十分な AI 耐性につながらない場合がある．また，共著者 2 名によるパイロット調査では，全試行で正答することができ，平均解答時間も既存 CAPTCHA 認証と同程度であった．このため，重ね合わせ知覚に基づく課題構成上の要素によって，人間による解答を可能としつつ，生成 AI による突破を困難にできる可能性が示された．

6.6 限界点

本評価にはいくつかの限界がある．まず，生成 AI による評価では GPT-5.5 のみを使用し，各パターンに対し 15 回の評価のみであるため，異なるモデルやより多くの課題に対する評価は限定的である．また，生成 AI の視覚理解能力，推論能力およびエージェントとしての操作能力は今後向上することが見込まれるため，本評価結果は評価実施時点における突破耐性の可能性を示すものであり，将来の生成 AI に対する耐性を保証するものではない．

さらに，本研究では人による評価は共著者 2 名を対象とした予備的なパイロット調査であるため，一般利用者の正答率や解答時間，ユーザビリティは一般化できない．

7. おわりに

本研究では，初期画面から解答情報を取得しにくい構成に着目し，視覚要素の操作によって解答情報を知覚できる CAPTCHA 認証を提案した．さらに，生成 AI による正解値推定および自動突破と，人による解答可能性を評価した．

評価の結果，Halligan は，全 60 試行で突破に失敗し，平均推論時間は 454 秒〜743 秒であった．Web 版 ChatGPT では，26/60 試行で正解値を推定し，平均推論時間は約 467 秒であった．一方で，共著者によるパイロット調査では，全試行で正答し，平均解答時間は最大約 31 秒であった．

以上より，操作前に正解配置の候補を絞り込みにくくし，操作結果に基づく配置・確認・修正といった探索的操作を要求する課題構成は，人による解答可能性を保ちつつ，生成 AI に対する突破耐性を高める上で重要である可能性を示した．

今後は，一般利用者を対象とした評価を実施し，提案方式の正答率，解答時間およびユーザビリティを検証する．

謝辞 本研究は，JST 国家戦略分野の若手研究者及び博士後期課程学生の育成事業（博士後期課程学生支援）JPMJBS2403 の支援を受けたものです．

参考文献

[1] Harvard Project on Workforce: GenAI Adoption Tracker, Harvard Project on Workforce (online), available from ⟨https://www.genaiadoptiontracker.com/⟩ (accessed 2026-08-20).

[2] Microsoft: 2026 Work Trend Index report: Agents, human agency, and the opportunity for every organization, Microsoft (online), available from ⟨https://www.microsoft.com/en-us/worklab/work-trend-index/agents-human-agency-and-the-opportunity-for-every-organization⟩ (accessed 2026-08-20).

[3] 読売新聞：悪性 bot の実態とは... 転売目的での利用「手入力なら数分かかる」チケットのネット購入わずか 5 秒、1 分での完売の闇，読売新聞（オンライン），入手先 ⟨https://www.yomiuri.co.jp/national/20260819-GYT1T00038/⟩（参照 2026-08-20）．

[4] Bursztein, E., Martin, M. and Mitchell, J.: Text-based CAPTCHA Strengths and Weaknesses, *Proc. 18th ACM Conference on Computer and Communications Security*, pp. 125–138 (2011).

[5] Hossen, M. I., Tu, Y., Rabby, M. F. et al.: An Object Detection based Solver for Google's Image reCAPTCHA v2, *Proc. 23rd International Symposium on Research in Attacks, Intrusions and Defenses*, pp. 269–284 (2020).

[6] Wu, Z., Xue, Y., Feng, Y. et al.: MCA-Bench: A Multimodal Benchmark for Evaluating CAPTCHA Robustness Against VLM-based Attacks, *Proc. AAAI Conference on Artificial Intelligence*, Vol. 40, No. 44, pp. 38039–38047 (2026).

[7] Teoh, X., Lin, Y., Li, S. et al.: Are CAPTCHAs Still Bot-hard? Generalized Visual CAPTCHA Solving with Agentic Vision Language Model, *Proc. USENIX Security Symposium 2025*, pp. 3747–3766 (2025).

[8] Guerar, M., Verderame, L., Migliardi, M. et al.: Gotta CAPTCHA 'Em All: A Survey of 20 Years of the Human-or-computer Dilemma, *ACM Computing Surveys*, Vol. 54, No. 9, pp. 1–33 (2021).

[9] von Ahn, L., Blum, M., Hopper, N. J. et al.: CAPTCHA: Using Hard AI Problems for Security, *Proc. EUROCRYPT 2003*, pp. 294–311 (2003).

[10] Elson, J., Douceur, J. R., Howell, J. et al.: Asirra: A CAPTCHA that Exploits Interest-Aligned Manual Image Categorization, *Proc. 14th ACM Conference on Computer and Communications Security*, pp. 366–374 (2007).

[11] Gao, H., Yao, D., Liu, H. et al.: A Novel Image Based CAPTCHA Using Jigsaw Puzzle, *Proc. 13th IEEE International Conference on Computational Science and Engineering*, pp. 351–356 (2010).

[12] Ding, Z., Deng, G., Liu, Y. et al.: IllusionCAPTCHA: A CAPTCHA based on Visual Illusion, *Proc. ACM Web Conference 2025*, pp. 3683–3691 (2025).

[13] Levenshtein, V. I.: Binary Codes Capable of Correcting Deletions, Insertions and Reversals, *Soviet Physics Doklady*, Vol. 10, No. 8, pp. 707–710 (1966).

[14] Navarro, G.: A Guided Tour to Approximate String Matching, *ACM Computing Surveys*, Vol. 33, No. 1, pp. 31–88 (2001).

[15] Searles, A., Nakatsuka, Y., Ozturk, E. et al.: An empirical study & evaluation of modern CAPTCHAs, *Proc. 32nd USENIX Security Symposium*, pp. 3081–3097 (2023).

[16] OpenAI Developers: Pricing | OpenAI API, OpenAI (online), available from ⟨https://developers.openai.com/api/docs/pricing⟩ (accessed 2026-08-20).

© 2026 Information Processing Society of Japan

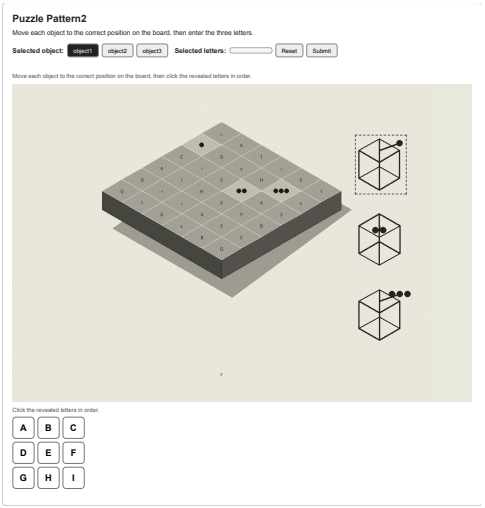


図 A·1: パターン (ii) の初期画面

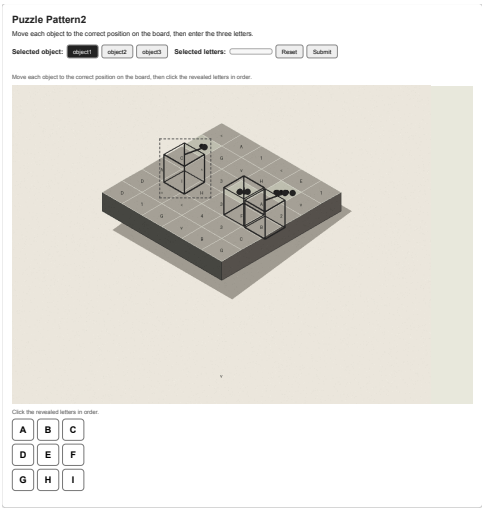


図 A·2: パターン (ii) の正解位置へ移動後の画面

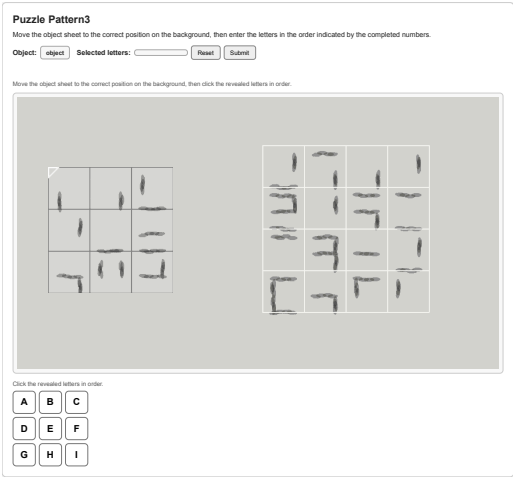


図 A·3: パターン (iii) の初期画面

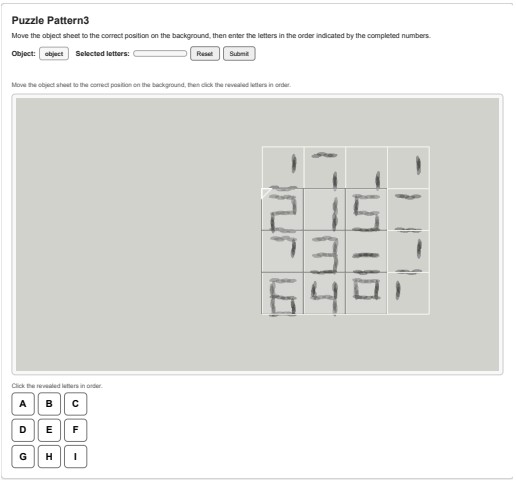


図 A·4: パターン (iii) の正解位置へ移動後の画面

8. 研究倫理

本研究では，提案 CAPTCHA 認証の動作確認，人による解答可能性の確認，および解答時間の把握を目的として，共著者を対象とした予備評価を実施した．この予備評価はユーザによる解答の一例として示すためのものであり，提案手法の有効性を検証することを目的としたものではない．一般参加者を対象としたユーザ評価実験については，所属機関の研究倫理審査委員会の承認を得た後に実施する予定である．

付　　録

A.1 提案 CAPTCHA 認証

A.1.1 パターン別の CAPTCHA 認証画面

本文 3.2 節では，パターン (i) の認証画面を例として提案 CAPTCHA 認証を示した．ここでは，本文で省略したパターン (ii)〜(iv) についての認証画面を示す．また，パターン (i)〜(iv) の具体的な解答例を示す． 図 A·1 および **図 A·2** はパターン (ii)， **図 A·3** および **図 A·4** はパターン (iii)， **図 A·5** および 図 A·6 はパターン (iv) の初期画面，および正解位置へ移動した後の画面である．いずれのパターンにおいても，初期画面状態では正解値を直接読み取ることができず，視覚要素を適切な位置に配置することで解答に必要となる情報が顕在化する．

具体的な解答例として，パターン (i) では，重ね合わせによってアルファベット文字列が顕在化し，本文の 図 2 の例では「HIBG」を順に入力する．パターン (ii) では，各視覚要素を正解位置へ配置した後，顕在化したアルファベットを示された入力順序に従って入力する． 図 A·2 の例では「IFB」を入力する．パターン (iii) では，顕在化した数字の位置を 3 行 3 列の入力ボタンと対応付け，数字が示す順序に従って該当するアルファベットを入力する． 図 A·4 の例では「BAEHCG」を入力する．パターン (iv) では，顕在化したアルファベットを起点とし，矢印が示す方向に従って入力位置を順次たどり，通過するアルファベットを順に入力する． 図 A·6 の例では「DGHI」を入力する．

© 2026 Information Processing Society of Japan

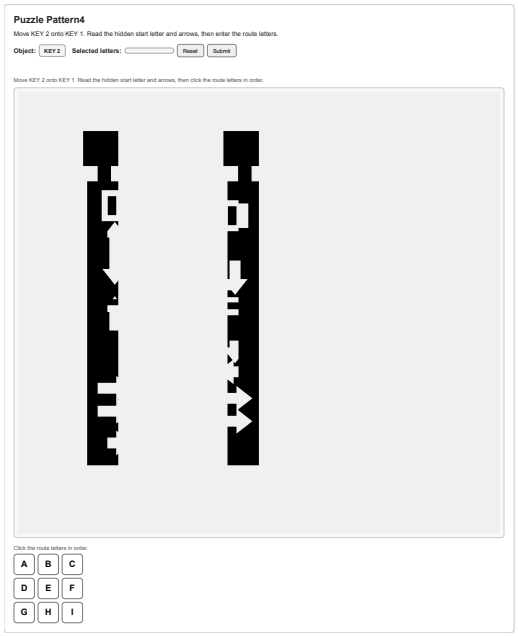


図 A·5: パターン (iv) の初期画面

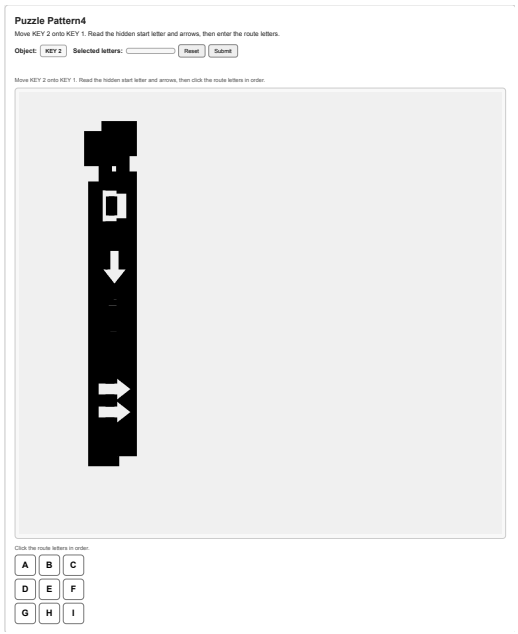


図 A·6: パターン (iv) の正解位置へ移動後の画面

A.1.2 CAPTCHA 課題の生成方法

提案 CAPTCHA 認証では，課題ごとに正解値，視覚要素，および正解配置位置を生成することで，各パターンの CAPTCHA 課題を自動生成できるように実装した．**表 A·1** に，各パターンを構成する視覚要素と，正解位置への配置によって顕在化する情報を示す．

パターン (i) では，正解値となるアルファベット文字列を生成し，その文字列を 2 つの視覚要素へ分割して配置する．各視覚要素を単独で観察した場合には文字列全体を読み取ることができず，2 つの要素を適切な位置関係で重ね合わせた場合に文字列が形成されるように生成する．パターン (ii)〜(iv) についても同様に，課題ごとに生成されるアルファベット，入力順序，位置情報または方向情報を決定し，それらの情報が正解位置への配置後に顕在化するように視覚要素を生成する．パターン (ii) ではアルファベットと入力順序，パターン (iii) では数字と位置情報，パターン (iv) では起点となるアルファベットと方向情報が顕在化する．

表 A·1: 各パターンにおける視覚要素の構成と顕在化情報

パターン	視覚要素	顕在化する情報
(i)	文字断片を含む 2 つの移動要素	アルファベット文字列
(ii)	固定ボードと 3 つの移動要素	アルファベット/入力順序
(iii)	数字断片を含む背景と移動要素	数字/位置情報
(iv)	起点文字・方向情報の断片を含む固定要素と移動要素	起点アルファベット/方向情報



図 A·7: Web 版 ChatGPT のプロンプト例

A.2 生成 AI による評価の補足

A.2.1 Web 版 ChatGPT における入力例

本文 4.2 節で示した Web 版 ChatGPT による静止画像評価について，実際の入力例を 図 A·7 に示す．各試行では，評価対象となる CAPTCHA 認証の初期画面のスクリーンショットを 1 枚添付し，**「問題を解くために必要となる入力値を出力してください.」**というプロンプトを入力した．このとき，正解画像，各パターンの解法といった情報は与えていない．

A.2.2 試行回別の評価結果

Halligan および Web 版 ChatGPT による評価では，生成 AI の出力が同一の入力に対しても試行ごとに変動する可能性を考慮し，各問題について同一条件で 3 回の評価を実施した．本文 5.1 節および 5.2 節では 3 試行を合算した結果を示したため，本節では，試行回ごとの評価結果と，

© 2026 Information Processing Society of Japan

表 A·2: 生成 AI による評価の試行回別結果

評価方法	試行 1	試行 2	試行 3	合計
Halligan	0/20	0/20	0/20	0/60
Web 版 ChatGPT	8/20	10/20	8/20	26/60

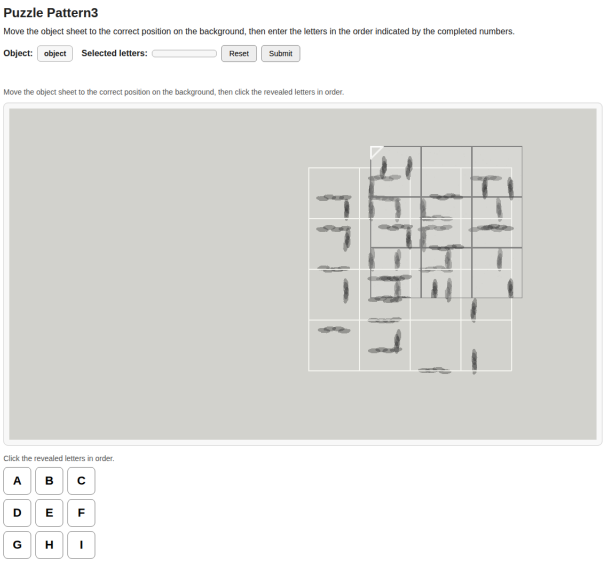


図 A·8: Halligan の配置位置推定の失敗例

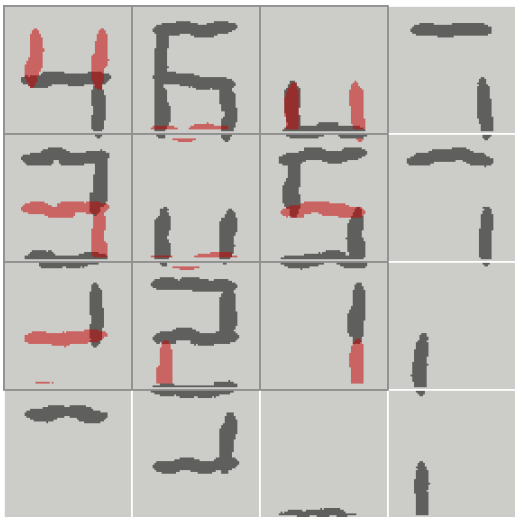


図 A·9: Web 版 ChatGPT の配置位置推定の成功例

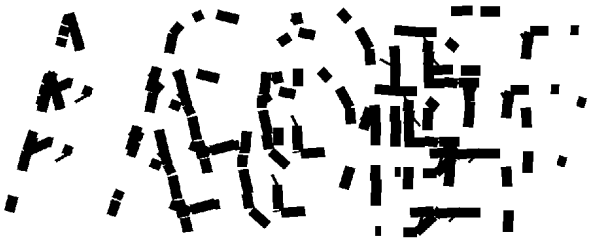


図 A·10: Web 版 ChatGPT の配置位置推定の失敗例

両評価において確認された代表的な推論・操作事例を補足する．

表 A·2 に，試行回ごとの評価結果を示す．Halligan では，いずれの試行回においても CAPTCHA 認証の突破は確認されなかった．一方，Web 版 ChatGPT では，正解値との一致件数が試行 1 から順に 8 件，10 件，8 件であり，試行による変動はみられたものの，特定の試行回に正解が顕著に偏る傾向は確認されなかった．

A.2.3 代表的な推論・操作事例

A.2.3.1 Halligan における操作事例

Halligan による代表的な操作失敗例を示す． **図 A·8** は，パターン (iii) に対して Halligan がブラウザ操作を実行した後の画面である．Halligan は，移動対象となる視覚要素を認識し，背景上へのドラッグ操作を実行したものの，正解となる配置位置を特定できておらず，数字を読み取るために必要な視覚情報が正しく顕在化していない．この例では，課題の操作方法を推定して実際のブラウザ操作まで実行できた場合であっても，正解配置の決定に失敗することで突破に至らなかった．

A.2.3.2 Web 版 ChatGPT における推論事例

Web 版 ChatGPT による評価では，初期画面の静止画像のみを入力した場合であっても，視覚要素の配置位置を推定し，内部的に視覚情報の操作を模倣しながら正解値を導出する事例が確認された．

図 A·9 に，パターン (iii) において正解値を出力した試行の例を示す．この試行では，視覚要素を赤色で強調表示しながら配置候補を探索し，その後，操作後の状態に相当する視覚情報を構成することで，顕在化した数字および位置情報から正解値を導出していた．

これに対して， **図 A·10** に，パターン (i) において正解値を出力できなかった試行の例を示す．この試行においても，視覚要素の配置関係および重ね合わせ後の状態を内部的に操作し，推定する処理が行われたが，どの情報が視覚要素のブロックであるかの対応関係や配置関係を適切に推定できず，正しい文字列を読み取ることはできなかった．

これらの事例から，Web 版 ChatGPT は静止画像評価においても，初期画面から視覚要素の配置関係を推定し，操作後の状態を擬似的に構成する場合があることが確認された．一方で，このような推定が行われた場合でも，配置関係や操作後状態を正しく推定できなければ，正解値には到達しない．このことは，初期画面から正解配置の候補をどの程度絞り込めるかが，静止画像からの正解値推定に影響する可能性を示している．

© 2026 Information Processing Society of Japan

表 A·3: 共著者による参加者別・試行回別の詳細結果

		1 回目				2 回目				3 回目			
参加者	項目	(i)	(ii)	(iii)	(iv)	(i)	(ii)	(iii)	(iv)	(i)	(ii)	(iii)	(iv)
A	解答時間 [s]	18.535	35.296	27.651	23.450	11.650	23.316	20.149	16.075	13.904	24.978	24.218	17.254
B	解答時間 [s]	28.946	42.610	45.483	93.496	12.157	28.978	24.751	20.055	12.982	20.958	16.131	17.674

A.3 パイロット調査評価結果

A.3.1 実施方法

本文 4.4 節では，共著者 2 名を対象としたパイロット調査の概要およびパターン別の評価結果を示した．本節では，本文で省略した調査の実施方法について補足する．

各参加者は，パターン (i)〜(iv) についてそれぞれ 3 問ずつ，計 12 問を解答した．実施前には，移動対象の選択，視覚要素のドラッグ，文字ボタンによる入力といった CAPTCHA 認証画面に共通する基本的な操作方法を説明した．このとき，各パターンにおける正解配置や正解値の導出方法については説明していない．

各問題の解答時間は，問題画面が表示された時点から計測を開始し，正解判定が表示された時点で計測を終了した．不正解となった場合には，問題を初期状態に戻し，同一問題への解答を継続した．したがって，不正解後の再試行に要した時間についても解答時間に含まれる．

問題は，以下の順序で実施した．なお，各試行回では異なる CAPTCHA 認証課題を提示し，同一の課題を繰り返し使用していない．

- 1 回目：パターン (i) → (ii) → (iii) → (iv)
- 2 回目：パターン (i) → (ii) → (iii) → (iv)
- 3 回目：パターン (i) → (ii) → (iii) → (iv)

A.3.2 試行回数による解答時間

各参加者のパターン別・試行回数別の解答時間を 表 A·3 に，平均解答時間を 表 A·4 に示す．共著者 2 名はいずれも，全 12 問を初回の回答で正答したため，正答率の記載を省略する．

2 名の解答時間を試行回ごとに平均すると，1 回目は 39.433 秒，2 回目は 19.641 秒，3 回目は 18.512 秒であった．1 回目と比較して 2 回目および 3 回目では解答時間が短くなっており，特に 1 回目から 2 回目にかけて大きく短縮した．参加者別にみても，参加者 A の平均解答時間は 1 回目 26.233 秒，2 回目 17.798 秒，3 回目 20.089 秒，参加者 B ではそれぞれ 52.634 秒，21.485 秒，16.936 秒であり，両参加者とも 1 回目と比較して 2 回目以降の解答時間が短い傾向がみられた．

各試行回では異なる CAPTCHA 認証課題を提示していることから，この時間短縮は同一課題の正解値を記憶したことによるものではなく，視覚要素の移動や顕在化した情報の読み取りなど，提案 CAPTCHA 認証の操作方法への習熟が影響した可能性がある．

表 A·4: 試行回数別の平均解答時間

参加者	項目	1 回目	2 回目	3 回目
A	平均解答時間 [s]	26.233	17.798	20.089
B	平均解答時間 [s]	52.634	21.485	16.936
全体	平均解答時間 [s]	39.433	19.641	18.512

A.3.3 解答時に得られたコメント

パイロット調査の実施中，参加者 1 名から，パターン (iv) において重ね合わせによって顕在化する起点文字が認識しにくい場合があるとの口頭コメントが得られた．具体的には，起点文字「D」が顕在化する課題について，その文字形状を「D」と認識しにくいとの指摘があった．

なお，本調査では参加者からのコメントを評価項目として収集していないため，このコメントは参考的な意見として位置付ける．今後のユーザ評価では，パターン (iv) における起点文字の視認性についても確認する必要がある．

© 2026 Information Processing Society of Japan