スマートフォンを対象としたリズムゲームにおける代行プレイの検出に向けた基礎検証

細江 乃愛[1,a)]　高田 哲司[1,b)]

概要：オンラインゲームにおける不正行為が問題となっている．なかでも代行プレイという不正行為は人による不正行為であり，大きな問題となっている．特にこの不正行為は，技術的対策が難しく，また課題クリアや報酬獲得が目的でない場合もあるためゲームスキルや成績による検出も難しい場合がある．そこで本研究では，スマートフォン向けリズムゲームにおいて取得できるタップ操作情報および端末センサ情報に，プレイヤ識別に利用可能な個人差が含まれるかを検証する．9 名の参加者に 3 日間にわたってプレイデータを収集し，そこから抽出した特徴量を用いて参加者ペアごとに機械学習モデルを構築した．またその学習モデルを用いて学習データとは異なる日のデータで判別精度を評価した．その結果，スマートフォン向けリズムゲームの操作情報にはプレイヤ間の識別に利用可能な個人差が含まれ，特に端末センサ情報は，プレイ結果だけでは区別しにくいプレイヤ間の識別を補助できる可能性が示された．

キーワード：代行プレイ，プレイヤ識別，不正行為検出，継続認証，リズムゲーム

A Feasibility Study on Detecting Substitute Play in Smartphone Rhythm Games

Noa Hosoe[1,a)]　Tetsuji Takada[1,b)]

Abstract: Online games face various forms of cheating. Among them, account boosting, in which another person plays on behalf of the account owner, poses a particularly serious problem because it is conducted by humans rather than automated tools. This type of cheating is difficult to prevent using purely technical countermeasures. In addition, when the purpose is not necessarily to clear difficult content or obtain rewards, it may also be difficult to detect account boosting based solely on game skill or performance. In this study, we investigate whether tap interaction data and device sensor data obtained during gameplay in a smartphone rhythm game contain individual characteristics that can be used to distinguish players. We collected gameplay data from nine participants over three days and constructed machine learning models for each pair of participants using features extracted from the collected data. The classification performance of these models was then evaluated using data collected on days different from those used for training. The results indicate that interaction data from smartphone rhythm games contain individual differences that can be used for player identification. In particular, device sensor data may help distinguish between players who are difficult to differentiate based only on gameplay performance.

Keywords: Boosting, Player Identification, Cheating Detection, Continuous Authentication, Rhythm Games

1. はじめに

オンラインゲームでは，ランキングの上昇やゲーム内報酬の獲得など，ゲーム内で有利な結果を得ることを目的と

[1] 電気通信大学 大学院情報理工学研究科
The University of Electro-Communications
[a)] noa.20000629@gmail.com
[b)] zetaka@computer.org

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

してさまざまな不正行為が行われている．このような不正行為はプレイヤ間の公平性やランキング，報酬制度に対する信頼性を損なうため，ゲーム運営側には不正行為を発見し，適切な措置を講じることが求められる．

本研究では，オンラインゲームにおける不正行為の一つである代行プレイに着目する．代行プレイは，第三者がアカウント所有者に代わってゲームをプレイする行為であり，ゲームプログラムや端末を改変することなく，正規のゲーム環境と許可された操作のみで成立する．そのため，ゲームプログラムの改変や不正ツールの利用を対象とした技術的な不正検知手法では検出が困難である．また，アカウント所有者と代行者のゲームスキルが近い場合には，スコアや勝敗などのプレイ結果にも明確な変化が現れず，ゲーム成績のみからプレイヤの交代を判断することも困難である．

そこで本研究では，スマートフォン向けリズムゲームを対象として，プレイ中に取得できるタップ操作情報および端末センサ情報に，プレイヤを区別可能な個人差が含まれているかを明らかにする．検証のため，実験用ゲームを実装し，9 名の参加者から複数日にわたってプレイデータを収集した．取得した情報から特徴量を算出し，異なる 2 名の参加者をアカウント所有者と代行者に見立てた二値分類モデルを構築した．タップ特徴量のみ，センサ特徴量のみ，および両者を併用した場合についてプレイヤ間の判別性能を比較し，さらにプレイヤ間のゲームスキル差と判別性能との関係を分析した．

その結果，多くの参加者ペアにおいてプレイヤ間を高い精度で判別できた．また，ゲームスキルの差が小さい参加者ペアでは，タップ特徴量のみでは判別が困難な場合であっても，センサ特徴量を利用することで判別精度が向上するケースが確認された．以上より，ゲームプレイ中に取得される操作情報および端末センサ情報が，ゲーム成績のみでは検出が困難な代行プレイの検出に利用できる可能性を示した．

本論文の主な貢献は以下のとおりである．

(1) スマートフォン向けリズムゲームというコンテキストにおいて，ゲームプレイ中の操作情報および端末センサ情報にはプレイヤを判別可能な個人差が含まれることを明らかにした
(2) 上記 2 カテゴリのゲームプレイ情報から抽出した特徴量により，2 者間のゲームスキル差によらずプレイヤ判別ができる場合があることを示した

2. オンラインゲームにおける不正行為とその対策

オンラインゲームは，ゲーム運営側によって設定された規約と運営者・プレイヤ間の信頼関係によって成り立っている．運営によって適切なルール・公平な競技環境が維持されることを前提にプレイヤはゲームプレイを楽しみ，自身の能力アップや報酬獲得を目指す，時には金銭を投じて有利なプレイ条件や報酬を得ることもある．このオンラインゲームにおいて不正行為が問題となっている．不正行為が横行すると，ルールを守っているプレイヤが長時間プレイするなど相応の労力を払わないと得られない報酬を不正者が簡単に得ることになる．その結果，本来であればルールを守るプレイヤが得たであろう報酬が不正者に渡るということも起こりうる．これにより，有利な条件や多くの報酬を持つプレイヤがゲーム内に出現することとなり，それに対してルールを遵守するプレイヤは不快感・徒労感を覚え，ゲームをやめてしまうことになる．これによりプレイヤが減少し，収益が悪化してゲームの運用停止・終了を引き起こすことになる．このことから，オンラインゲームの運営側にとって不正行為の撲滅はゲームの寿命にかかわる重要な課題であり，規約制定だけにとどまらず不正行為の検出とそれに応じた措置を講じることが必要となる．

不正行為には技術的側面と人的側面がある．技術的側面とは，プログラムやデータの改変，通信の介入やチートツールの使用，マクロ・Bot による自動操作など技術的な手段により不正行為を行うことを指す．一方，人的側面とは技術的手段を使用しない不正行為を指す．高スキルのプレイヤにアカウントを貸し出し，報酬獲得や課題クリアなどを依頼する行為 (Boosting) はその一例である．これらの問題に対し，技術的側面による不正行為には，ゲームプログラムや実行環境の監視など技術的な対策が存在する．一方，人的側面による不正行為は，正規のゲーム環境および許可された操作によって行われるため，技術的な対策の応用では対応が困難である．そのため，ゲーム運営側では人的側面による不正行為を利用規約などによって禁止している．例えば，複数人で対戦する MOBA（Multiplayer Online Battle Arena）に分類される「League of Legends」では，アカウント共有や Boosting を処分対象としている [1]．また，1 人でプレイするリズムゲームでも，アカウントの貸与・共有や第三者によるプレイ代行を禁止している [2][3].

しかし，規約によって禁止されていても，実際にアカウントを操作している人物がアカウント所有者本人であるかをゲーム運営側が把握することは容易ではない．プレイ成績の変化から代行プレイを推定できる場合もあるが，アカウント所有者と代行者のゲームスキルが同程度であれば，スコアや勝敗などに明確な変化が現れない可能性がある．このような場合，プレイ結果のみを用いて代行プレイを検出することは困難である．

2.1 本研究の焦点: スマートフォンゲームにおける代行プレイ

本研究ではオンラインゲームの不正行為対策として“代行プレイ”に焦点をあてる．また，リズムゲームを対象ゲームとし，かつスマートフォンというプレイ環境を想定

© 2026 Information Processing Society of Japan

する．本節ではそれらの選定理由について述べる．

代行プレイに焦点をあてる理由は，(1) 人的側面による不正行為であり，(2) ゲームスキルに無関係な不正行為がありうる点である．代行プレイとは，アカウント所有者と代行者の２者で行われる不正行為であり，技術的側面は不要である．よって既存の技術的対策では対応困難である．さらに，代行プレイの目的には「プレイ回数やプレイ時間を増やす」というものがあり，この場合には高スキルな代行者を必要としないこともある．よってゲーム成績やスキルを基準とする代行者の特定は困難である．

次にリズムゲームを対象とする理由を述べる．１つはゲームスキルに無関係な代行プレイがありうるゲームジャンルという点である．リズムゲームは曲単位でスコアを積み重ねるため「プレイ曲数を増やす」が目的の代行プレイが起こりうる．そしてそのために高スキルな代行者が必要というわけではない．もう１つの理由は，プレイヤによるプレイの自由度が低い点である．Role Playing Game(RPG) や First-Person Shooter(FPS) ジャンルのゲームとは異なり，リズムゲームでは曲によって入力する時刻や位置があらかじめ定められている．そのため，プレイヤは指示された操作に対して，どの程度正確に入力できるかを競うことになる．このように，プレイヤごとの移動経路や戦術などの行動選択による違いをおさえた上で，プレイヤ個別の操作にあらわれる個人差を分析できる点は，本研究に適した条件であると考える．一方で，すべてのプレイヤに対して同一の操作が要求されるため，プレイヤ間の操作差そのものが小さくなり，個人差が現れにくくなる可能性もある．

最後に，スマートフォン環境を前提とする理由について述べる．第一に，スマートフォンゲーム[*1]は専用のゲーム機器を用意する必要がなく，日常的に利用している端末にアプリケーションをインストールすることでゲームを開始できる．そのため，ゲームへの参入が容易であり，多くのプレイヤが参加しやすい．参加者が増えることで，ランキングやイベントなどにおけるプレイヤ間の競争も生じやすくなり，その中でより高い順位や報酬を得ようとする動機から，不正行為が行われる可能性も高まると考えられる．したがって，スマートフォンゲームは不正行為対策を重要視すべき環境の１つである．第二に，スマートフォンゲームでは代行プレイそのものを実行しやすい．スマートフォンゲームのプレイヤは，通常，各自がスマートフォン端末および正規のゲームアプリケーションを所有している．そのため，アカウント所有者が自身の端末を他者に貸す，アカウント情報を共有して他者の端末からログインさせる，あるいは他者の端末上であらかじめ自身のアカウントにログインしておくといった方法によって，第三者が正規の端末およびゲームアプリケーションを用いてプレイすることが容易である．この場合，ゲームプログラムや端末に技術的な改変を加えることなく，プレイヤだけを入れ替えることで代行プレイが成立する．以上が本研究でスマートフォン環境を対象とする理由である．

[*1] 以降，本論文ではスマートフォンゲームを「スマホゲーム」と略記する．

3. 関連研究

本章では，ゲームにおける不正検知とプレイヤ識別に関する研究，継続認証に関する研究を関連研究として取り上げ，それらと本研究の差異について議論する．

3.1 不正検知に関する研究

Ding ら [4] は，オンラインゲーム『Dota 2』を対象として，Smurf および Booster である可能性が高いプレイヤを試合成績から検出する手法を提案した．Smurf とは，スキルのある上級者が初心者のふりをして，格下の相手と対戦する行為を行うプレイヤを指す．これにより初級者同士の対戦のはずが実際は両者の間にスキル差がある状態となり，同等レベル同士での公平な対戦とならず報酬やランク制度の公平性が損なわれることになる．一方，Booster とは，前述した Boosting を行うプレイヤのことを指す．これら２種の不正行為を行うプレイヤを検出する手法としては，直近 20 試合の勝率や総合勝率などの試合成績を入力とし，K-means を用いてプレイヤをクラスタリングした後，高成績のプレイヤ群に対して四分位範囲を用いた外れ値検出を行うことで，Smurf または Booster である可能性が高いプレイヤを識別する．提案手法の検証としては，ゲームの専門家による判定と提案システムによる判定結果を比較することで行った．その結果，40 人中 38 人の判定が一致した．

この研究ではゲーム内の試合成績を入力とし，Smurf または Booster であるか否かの二値分類を行っている．そのため，検証対象となったアカウントが不正行為に関与していることが分かるにとどまる．これに対して本研究では，アカウントではなくプレイヤに注目し，そのプレイヤがアカウントを登録した本人であるかを判定する．

3.2 プレイヤ識別に関する研究

Liebers ら [5] は VR リズムゲーム「Beat Saber」のプレイ中にヘッドセットとコントローラから取得可能な情報を用いてプレイヤを識別する研究を行った．15 名の参加者に対し同一楽曲を 8 週間にわたって繰り返しプレイさせデータを収集した．このデータから Random Forest による分類モデルを構築し，検証を行った．1，2 日目のデータで学習し，3 日目のデータでテストを行ったところ F1-score は 0.81 であった．

Liebers らの研究は，プレイヤの識別を目的としているが，本研究とは判定に使用するデータが異なる．

© 2026 Information Processing Society of Japan

3.3 継続認証に関する研究

継続認証 (Continuous Authentication) とは，既存の個人認証の後も継続してユーザのふるまいを監視し，他者による操作と判断した場合はあらためて個人認証を求める仕組みである．この手法はふるまいによって操作者を判定することから，代行者かアカウント所有のプレイヤかを判定する点で代行者検出と類似しているといえる．

Incel ら はモバイルバンキングアプリを対象に「DAKOTA」という継続認証を提案した [6]．アプリ利用時のスクロール操作 (座標・圧力)，加速度，角速度を入力とし，複数のアルゴリズムで分類器を構築して 45 名の参加者による検証を行った．その結果，二値 SVM が最良の結果となり，EER が 3.5%となった．

Sitova らは，スマートフォンの文字入力操作を対象とした継続認証手法「HMOG」を提案した [7]．座位および歩行中の文字入力操作を 100 名に行わせ，タッチ情報ならびに加速度，角速度，地磁気を収集した．認証には Scaled Manhattan，Scaled Euclidean，1-Class SVM の 3 種類の認証器を用いて性能を比較し，最も良好な性能を示した Scaled Manhattan を用いて各特徴量から得られる認証スコアを統合した．その結果，HMOG，タップおよびキーストローク特徴を組み合わせた場合，座位において EER 10.05%を達成した．

これらの研究と本研究では入力情報に類似点があるものの，判定に使用する情報を収集する際のコンテキストが異なる．既存研究ではスクロール操作や文字入力を対象としているのに対し，本研究ではリズムゲームにおけるタップ操作を対象としている．

4. 研究方法

4.1 概要

本研究では代行プレイを検出することを目的とし，その基礎検討としてスマートフォンでリズムゲームをプレイすることで得られる情報に，プレイヤに依拠する個人差が存在するかを明らかにする．研究方法の概要を以下に示す．

(1) プレイデータの収集
(2) 特徴量の作成と判別器の構築
(3) 検証実験

本章では (1) および (2) について述べる．(3) の検証実験とその結果については 5 章で述べる．

4.2 データ収集

本研究ではデータ収集のためにリズムゲームを Android 端末向けに実装し，9 名の実験参加者に実際にプレイしてもらうことでプレイデータを収集した．図 1 にゲームプレイ中の様子を示す．

ゲームの基本操作は一般的なリズムゲームと同様であり，楽曲に合わせて移動するノーツが判定領域に到達したタイミングで，プレイヤが対応する位置をタップするものである．実験には下記の 2 種類の楽曲を用いた．楽曲 A[8] は，Beats Per Minute(BPM)110 の比較的ゆったりとした曲で，曲の長さは 2 分 8 秒，ノーツ数は 103 である．楽曲 B[9] は，BPM170 のアップテンポな曲で，曲の長さは 2 分 21 秒，ノーツ数は 137 である．

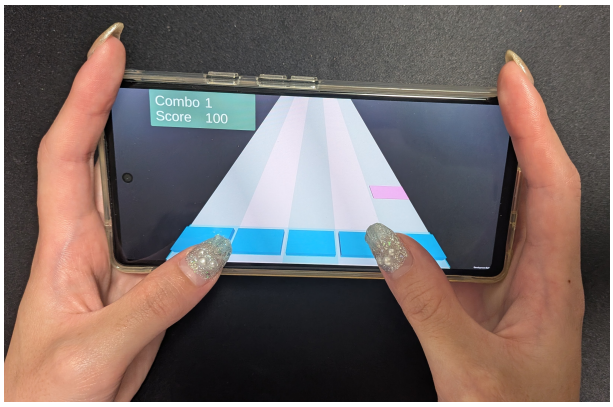


図 1 実験に使用したリズムゲームのプレイ画面．音楽に合わせてピンク色のノーツが移動し，青色の判定領域に重なったタイミングで，プレイヤは対応する位置をタップする．

表 1 ゲームプレイ中に取得する情報

情報の種類	取得項目
タップ操作情報	ノーツの目標時刻
	実際のタップ時刻
	目標時刻とタップ時刻の時間差
	判定結果（Perfect / Good / Bad）
端末センサ情報	加速度（x, y, z）
	角速度（x, y, z）

また，ゲームプレイ時の姿勢として 2 種類の条件を設定した．1 つはスマートフォンを手に持ってプレイする条件 (“Hold 条件”)，もう 1 つはスマートフォンを机上に置いてプレイする条件 (“Desk 条件”) である．

実装したゲームアプリでは，タップ操作に関する情報と端末センサ情報を収集した．取得した情報を表 1 に示す．タップ操作情報として，各ノーツについて 4 種類の情報を記録した．また，端末の加速度センサおよびジャイロセンサから，加速度 3 軸および角速度 3 軸の計 6 種類の情報を 30 Hz で取得した．

1 回の実験で 12 プレイ分のデータを取得した（2 楽曲を 3 回ずつ，2 種の姿勢で実施）．この実験を参加者ごとにそれぞれ異なる日に 3 回実施し，1 名につき計 36 プレイ分のデータを収集した．なお，各実験の実施間隔は統一していない．実験には，すべての参加者が実験実施側で用意した Google Pixel 6a を使用した．本実験では，ゲームプレイ中に取得する操作・端末センサ情報以外の情報は収集していない．なお，本実験は，電気通信大学の人を対象とする研究に関する倫理審査を受け，承認を得た上で実施した．

© 2026 Information Processing Society of Japan

表 2　プレイデータから算出する特徴量

情報の種類	特徴量	個数
タップ	符号付き時間差：平均・中央値・標準偏差	3
	絶対時間差：平均・中央値・標準偏差	3
	二乗平均平方根誤差	1
	早押し率・遅押し率	2
	判定割合（Perfect・Good・Bad）	3
	タップ特徴量 合計	12
加速度	各軸：平均・標準偏差	6
	3 軸ノルム：平均・標準偏差・最大値	3
	隣接時点間の変化量ノルム：平均・標準偏差	2
	小計	11
角速度	各軸：平均・標準偏差	6
	3 軸ノルム：平均・標準偏差・最大値	3
	隣接時点間の変化量ノルム：平均・標準偏差	2
	小計	11
	センサ特徴量 合計	22

4.3　判別器作成

判別器の作成は，以下の手順で行った．

(1) 特徴量抽出

(2) 判別器構築

4.3.1　特徴量抽出

4.2 節で収集したプレイデータのうち，タップ操作情報および端末センサ情報から，プレイヤごとの操作の違いを表しうる特徴量を算出した．算出した特徴量の一覧を表 2 に示す．判別器への入力データ群として，タップ特徴量のみの 12 個，センサ特徴量のみの 22 個，および両者を併用した 34 個の 3 群を設定した．

4.3.2　判別器構築

判別器構築の条件として，2 種類の楽曲，2 種類の姿勢，前述した 3 種類の入力データ群，および 2 種類の識別アルゴリズム（Random Forest（以降 RF），ロジスティクス回帰（以降 LR）），すなわち $(2 \times 2 \times 3 \times 2 = 24)$ 条件を設定した．

各構築条件に対して，9 名の参加者から 36 ペア（${}_9C_2$）を作成し，一方をアカウント所有者に相当する正規プレイヤ，もう一方を代行者に相当する非正規プレイヤとして評価を行った．判別器の構築には 1，2 回目のプレイデータを用いた．最終的な判定精度の評価には，学習に使用していない 3 回目のプレイデータを用いた．

以上より，合計 $24 \times 36 = 864$ 個の二値分類モデルを構築した．

5.　検証実験

本章では，構築した 864 個の判別器を用い，3 回目のプレイデータを対象として，判別器に設定された各条件における判定精度を測定した．その結果得られた判定精度を用い，以下の 3 点について結果を示す．

(1) 2 者間の判別精度

(2) 楽曲・姿勢条件による影響

(3) スキル差と判別精度の関係

なお，以降では，判別器構築時に設定した 3 種の特徴量，すなわちタップ特徴量のみ，センサ特徴量のみ，および両者を併用した特徴量を，それぞれ F-Tap，F-Sensor，F-Comb と略記する．

また，以降の議論では，2 者間におけるゲームスキルの差を考慮するため，スキル指標を定義した．各参加者について，ゲームプレイ時に得られた Score 値を平均 0，標準偏差 1 となるよう標準化した上で平均値を算出し，これを各プレイヤのスキル値とした．さらに，2 名のプレイヤのスキル値の差の絶対値を Skill Gap と定義した．

この定義に基づいて分析した結果，Skill Gap の範囲は $0.0 \leq \text{Skill Gap} \leq 3.51$ となった．9 名の参加者間における Skill Gap を図 2 に示す．9 名の参加者による 2 者間の判定精度を図 3 に示す．

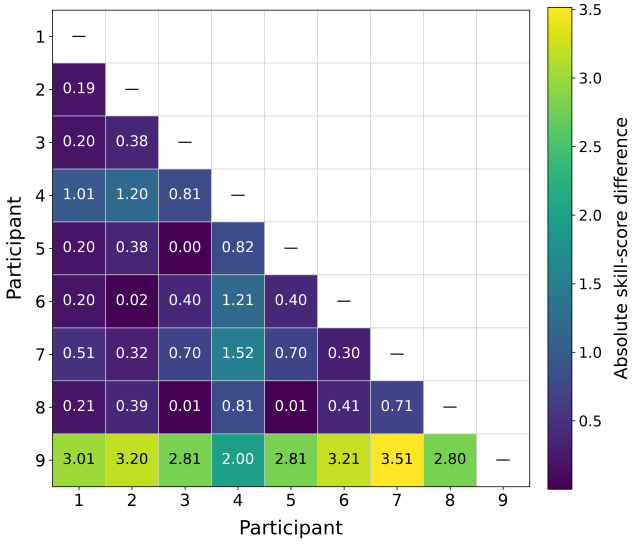


図 2　各ペアの Skill Gap

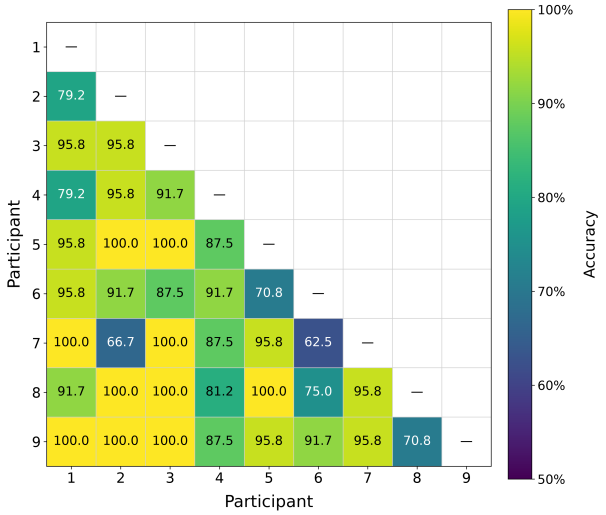


図 3　各ペアの平均 Accuracy

さらに，Skill Gap の値に基づき，以下の 3 つのスキル

© 2026 Information Processing Society of Japan

差グループを定義し，以降の議論に用いる．

- **スキル差小（Small Gap: Sg）**
  定義：Skill Gap < 0.5，該当ペア数：17
- **スキル差中（Middle Gap: Mg）**
  定義：$0.5 \leq$ Skill Gap < 1.5，該当ペア数：10
- **スキル差大（Large Gap: Lg）**
  定義：Skill Gap ≥ 1.5，該当ペア数：9

5.1 2 者間の判別精度

紙面の都合上，図 3 の各セルには，F-Comb 条件の RF 判別器を用いて得られた Accuracy（以降，Acc）について，楽曲および姿勢の 4 条件の平均値を各ペアの判別精度として示している．

全 36 ペアにおける Acc の平均は 90.45%であった．また，各ペアにおける判定精度とスキル差グループとの関係を表 3 に示す．

表 3 スキル差グループ別の判定精度分布

Acc	Sg	Mg	Lg	小計	累積度数（%）
100%	5	2	3	10	27.8
90%台	6	5	3	14	66.7
80%台	1	2	2	5	80.6
70%台	3	1	1	5	94.4
60%台	2	0	0	2	100.0

Acc が 90%以上となったペアは 24 ペアで，全体の 66.7%であった．さらに，80%以上となったペアは 29 ペアで，全体の 80.6%であった．一方，80%未満となった 7 ペアのうち 5 ペアは Sg に属していた．

5.2 楽曲・姿勢条件による影響

楽曲，姿勢，特徴量群および分類アルゴリズムごとの平均 Acc を図 4 に示す．4 種類の楽曲・姿勢条件のうち，多くの条件で F-Tap よりも F-Sensor または F-Comb の方が高い Acc を示した．

また，F-Comb かつ RF を用いた場合について，楽曲および姿勢ごとの平均 Acc を表 4 に示す．平均 Acc は 87.0%から 94.7%の範囲であり，最も高かったのは楽曲 B・Desk 条件の 94.7%，最も低かったのは楽曲 A・Desk 条件の 87.0%であった．また，楽曲 A では Hold 条件の方が Desk 条件より高い Acc を示した一方，楽曲 B では Desk 条件の方が高い Acc を示しており，楽曲と姿勢の組合せによって判別精度の傾向が異なることが確認された．

表 4 楽曲および端末姿勢ごとの Accuracy

	楽曲 A	楽曲 B	diff (A-B)
Hold	91.7	89.4	2.3
Desk	87.0	94.7	-7.7
diff (Hold-Desk)	4.7	-5.3	

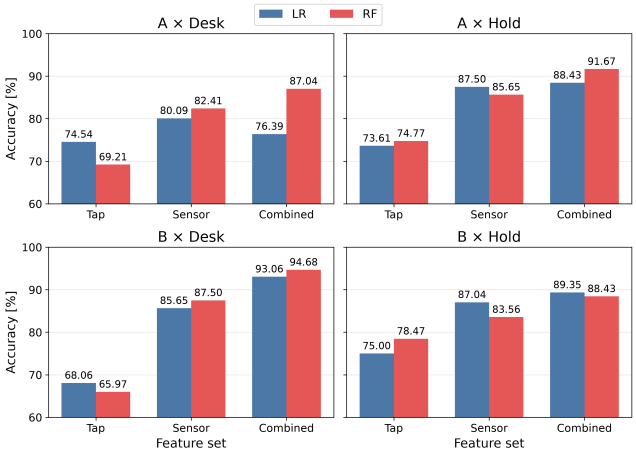


図 4 楽曲・姿勢・特徴量・分類アルゴリズムごとの平均 Accuracy

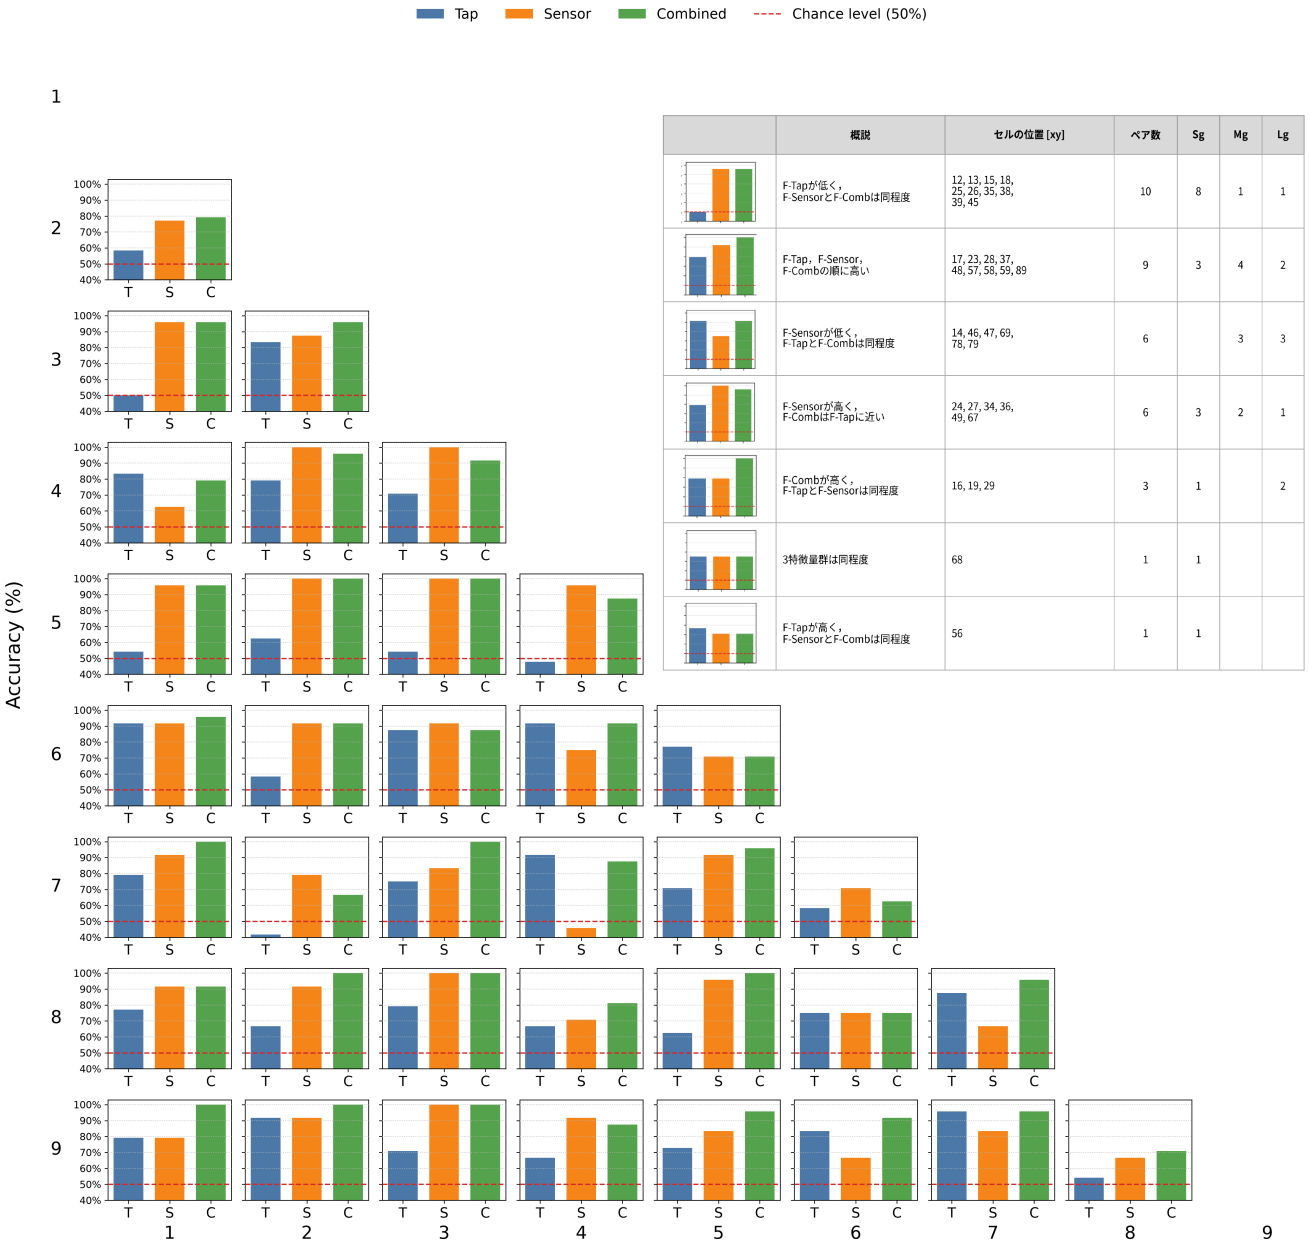
5.3 スキル差と特徴量の関係

各参加者ペアについて，F-Tap，F-Sensor，F-Comb を用いた場合の平均 Acc を図 5 に示す．各小グラフは 1 組の参加者ペアに対応し，楽曲，姿勢および分類アルゴリズムの各条件で得られた Acc を特徴量群ごとに平均した値を示している．また，3 種類の特徴量群における Acc の変化傾向に基づいて参加者ペアを類型化し，各類型に含まれるペア数を Skill Gap の群別に集計した結果を同図右上に示す．

Sg に属する 17 ペアのうち 11 ペアでは，F-Tap よりも F-Sensor または F-Comb を用いた場合に高い Acc を示した．特に，F-Tap のみ判別精度が低く，F-Sensor と F-Comb で同程度の高い精度を示す類型には 10 ペアが該当し，そのうち 8 ペアが Sg であった．一方，F-Sensor のみ判別精度が低くなる類型には 6 ペアが該当し，そのすべてが Mg または Lg であった．

以上より，Skill Gap の小さい参加者ペアでは F-Tap より F-Sensor または F-Comb の判別精度が高くなる組合せが多く確認された一方，Skill Gap が中程度以上のペアでは F-Sensor のみ精度が低下する組合せも確認された．

© 2026 Information Processing Society of Japan



	概説	セルの位置 [xy]	ペア数	Sg	Mg	Lg
	F-Tapが低く，F-SensorとF-Combは同程度	12, 13, 15, 18, 25, 26, 35, 38, 39, 45	10	8	1	1
	F-Tap，F-Sensor，F-Combの順に高い	17, 23, 28, 37, 48, 57, 58, 59, 89	9	3	4	2
	F-Sensorが低く，F-TapとF-Combは同程度	14, 46, 47, 69, 78, 79	6		3	3
	F-Sensorが高く，F-CombはF-Tapに近い	24, 27, 34, 36, 49, 67	6	3	2	1
	F-Combが高く，F-TapとF-Sensorは同程度	16, 19, 29	3	1		2
	3特徴量群は同程度	68	1	1		
	F-Tapが高く，F-SensorとF-Combは同程度	56	1	1		

図 5　タップ特徴量のみ，センサ特徴量のみ，併用時での各ペアの Accuracy

6.　考察

6.1　検証結果について

5.1 節では，全 36 ペアのうち 24 ペアで Acc が 90%以上，29 ペアで 80%以上となった．このことから，本研究で取得したタップ操作情報および端末センサ情報には，多くの参加者ペアを高い精度で判別可能な個人差が含まれていると考えられる．

一方，Acc が 80%未満の 7 ペアのうち 5 ペアは Sg に属していた．この結果から，ゲームスキルが近い参加者間では，判別が困難となるケースが比較的多いことが示唆される．ただし，Sg に属するペアの中にも高い判別精度を示すものが存在するため，Skill Gap のみが判別精度を決定する要因ではなく，プレイヤごとの操作特性も影響していると考えられる．

次に，5.2 節では，F-Comb かつ RF を用いた場合の平均 Acc が，楽曲・姿勢の 4 条件すべてで 87.0%以上となり，最も高い楽曲 B・Desk 条件では 94.7%であった．このことから，本実験で扱った範囲では，楽曲や姿勢が異なる場合でも一定の判別性能が維持されることが確認された．一方で，楽曲 A では Hold 条件が Desk 条件を上回ったのに対し，楽曲 B では Desk 条件が Hold 条件を上回っており，楽曲と姿勢の組合せによって判別精度の傾向は異なっていた．したがって，実際の代行プレイ検出においては，特定のプレイ条件だけでなく，複数の楽曲や姿勢におけるデータを考慮する必要があると考えられる．

© 2026 Information Processing Society of Japan

最後に，5.3 節では，Sg に属する 17 ペアのうち 11 ペアで，F-Tap よりも F-Sensor または F-Comb の方が高い Acc を示した．特に，F-Tap のみ判別精度が低く，F-Sensor と F-Comb で同程度の高い精度を示す類型には 10 ペアが該当し，そのうち 8 ペアが Sg であった．この結果から，ゲームスキルが近い参加者同士では，タップタイミングやゲーム成績に関連する特徴のみでは差が現れにくい一方，端末センサ情報によって，ゲームスキルとは異なるプレイヤ固有の特徴を捉えられた可能性がある．

一方，F-Sensor のみ判別精度が低くなる類型には 6 ペアが該当し，そのすべてが Mg または Lg であった．Skill Gap が大きい参加者間では，タップ特徴量に表れるゲームスキルの差が判別に強く寄与し，相対的にセンサ特徴量の寄与が小さくなった可能性がある．以上より，ゲームスキルが近く，プレイ結果のみでは区別しにくいプレイヤ間では端末センサ情報が有効となる一方，ゲームスキル差が大きい場合にはタップ特徴量が有効となる可能性が示唆される．

6.2 制限事項について

本研究にはいくつかの制限がある．実験参加者は 9 名であり，同一参加者が複数のペアに含まれるため，特定参加者のプレイ特性が複数の結果に影響している可能性がある．また，Skill Gap 各群のペア数は均等ではなく，スキル差と判別精度の関係を一般化するには追加検証が必要である．さらに，本実験では特定の端末，楽曲および姿勢のみを用いており，異なる環境における再現性についても検証する必要がある．

6.3 今後の課題

実際の代行プレイ検出では，未知の代行者を想定する必要がある．今後は，アカウント所有者本人のデータのみからプレイ傾向をモデル化し，One-Class 分類などによって未知の他者によるプレイを検出する手法を検討する．また，参加者数およびデータ量を増やし，特にゲームスキルが近いプレイヤ間でセンサ特徴量が安定して個人差を捉えられるかを検証する．これにより，実際のサービス環境において，事前に代行者のデータを用意できない場合でも適用可能な検出手法の実現を目指す．

7. おわりに

本研究では，スマートフォン向けリズムゲームにおける代行プレイ検出の基礎検討として，プレイ中に取得されるタップ操作情報および端末センサ情報にプレイヤに依拠する個人差が存在するかを検証した．

9 名の参加者から取得したプレイデータを用いて 2 者間の判別を行った結果，多くの参加者ペアにおいて高い判別精度が得られた．また，タップ特徴量とセンサ特徴量を併用した F-Comb では，全体として高い判別精度を示す傾向が確認された．さらに，ゲームスキルの差が小さい参加者間では，タップ特徴量のみと比較してセンサ特徴量を用いた場合に判別精度が向上するケースが多く確認された．

これらの結果から，ゲームプレイ中に取得されるタップ操作情報および端末センサ情報には，プレイヤの判別に寄与する個人差が含まれており，これらを利用した代行プレイ検出の可能性が示された．

今後は，参加者数およびプレイデータ量を増やすとともに，本人のデータを基準として未知の他者によるプレイを検出する手法について検討し，実際の代行プレイ検出を想定した評価を行う．

参考文献

[1] Riot Games. Account Penalties and Enforcement FAQ. League of Legends. 入手先〈https://www.leagueoflegends.com/en-us/news/dev/account-penalties-and-enforcement-faq/〉（参照 2026-07-30）.

[2] ブシロード. 利用規約. バンドリ！ ガールズバンドパーティ！入手先〈https://bang-dream.bushimo.jp/rule/〉（参照 2026-07-30）.

[3] セガ, Colorful Palette. プレイガイドライン. プロジェクトセカイ カラフルステージ！ feat. 初音ミク. 入手先〈https://pjsekai.sega.jp/guideline/index.html〉（参照 2026-07-30）.

[4] Ying-Jih Ding, Wun-She Yap, and Kok-Chin Khor. Profiling and identifying smurfs or boosters on dota 2 using k-means and iqr. *IEEE Transactions on Games*, Vol. 16, No. 3, pp. 577–585, 2024.

[5] Jonathan Liebers, Christian Burschik, Uwe Gruenefeld, and Stefan Schneegass. Exploring the stability of behavioral biometrics in virtual reality in a remote field study: Towards implicit and continuous user identification through body movements. In *Proceedings of the 29th ACM Symposium on Virtual Reality Software and Technology*, VRST '23, pp. 1–12, New York, NY, USA, 2023. Association for Computing Machinery.

[6] Özlem Durmaz Incel, Seçil Günay, Yasemin Akan, Yunus Barlas, Okan Engin Basar, Gülfem Isiklar Alptekin, and Mustafa Isbilen. Dakota: Sensor and touch screen-based continuous authentication on a mobile banking application. *IEEE Access*, Vol. 9, pp. 38943–38960, 2021.

[7] Zdeňka Sitová, Jaroslav Šeděnka, Qing Yang, Ge Peng, Gang Zhou, Paolo Gasti, and Kiran S. Balagani. Hmog: New behavioral biometric features for continuous authentication of smartphone users. *IEEE Transactions on Information Forensics and Security*, Vol. 11, No. 5, pp. 877–892, 2016.

[8] MFP〔Marron Fields Production〕. Retail Magic Hour, 2026. DOVA-SYNDROME, 入手先：https://dova-s.jp/bgm/detail/23236（参照 2026-07-30）.

[9] MFP〔Marron Fields Production〕. Rogue Circuit, 2025. DOVA-SYNDROME, 入手先：https://dova-s.jp/bgm/detail/22403（参照 2026-07-30）.

© 2026 Information Processing Society of Japan