グラフによる領域間の関係推論を用いた可視光虹彩認証

舞原 慶太[1,a)]　大塚 陸人[2]　庄司 悠歩[2]　戸泉 貴裕[2]　伊藤 厚史[2]　市野 将嗣[1]

概要：虹彩認証では離れた領域の特徴どうしの関係をとらえる大域特徴が有効だが，その抽出に用いるTransformer は訓練データを多く必要とし，規模の小さい可視光虹彩認証では学習が難しい．Convolutional Neural Network（CNN）に Self-Attention を組み込む方法も，全画素間の関係を学習するため過学習が懸念される．そこで本稿では，特徴マップを少数のノードに集約して関係を推論するグラフベースのモジュールである Global Reasoning Unit を DenseNet169 の中間層に挿入し，パラメータの自由度を高めすぎずに大域特徴を抽出する手法を提案する．実験では，UBIRIS.v2 と PolyU のいずれのデータセットでも，虹彩認証で用いられているものを含む 27 種類のネットワークから等価エラー率（EER）を改善し，UBIRIS.v2 では EER が 3.37%から 2.90%へ改善した．

キーワード：可視光虹彩認証，大域特徴，関係推論，グラフ畳み込み

Visible Iris Recognition Using Graph-Based Global Reasoning

Keita Maihara[1,a)]　Rikuto Otsuka[2]　Yuho Shoji[2]　Takahiro Toizumi[2]　Atsushi Ito[2]
Masatsugu Ichino[1]

Abstract: Global features, which capture relationships between features in distant regions, are effective for iris recognition, but methods for extracting them mainly rely on Transformers, which require large amounts of training data and are difficult to train for visible iris recognition. Incorporating self-attention into a CNN raises a concern of overfitting, since it learns all pixel-pair relationships individually. We propose a method that inserts Global Reasoning Units, a graph-based relational reasoning module, into the intermediate layers of DenseNet169. Experiments show that it improves the equal error rate (EER) over all 27 networks including those used in iris recognition on both the UBIRIS.v2 and PolyU datasets, reducing the EER from 3.37% to 2.90% on UBIRIS.v2.

Keywords: Visible Iris Recognition, Global Feature, Relational Reasoning, Graph Convolution

1. はじめに

虹彩認証は，人間の虹彩が持つ複雑な模様を利用するため生体認証の中でも特に高い精度で個人を識別することが可能であり [1]，一般には安定して鮮明な虹彩模様を取得できる近赤外虹彩画像が用いられる．しかしその撮影には専用の装置が必要となるため，利用シーンを拡大するうえでは広く普及している可視光カメラを用いて認証を行うことが望ましい．一方，可視光虹彩画像の不鮮明さやノイズといった影響から，その認証精度は近赤外画像を用いる場合に依然として及んでおらず，可視光虹彩画像からより優れた特徴を抽出する方法が求められる．

近年，CNN を用いた虹彩認証が提案されており [2], [3]，CNN では畳み込みによって局所的な特徴を抽出する．一方で，離れた領域の特徴どうしの関係（大域特徴）も認証に有効であることが示されており，これを抽出する試みが行われている．Sun ら [4] は，Vision Transformer（ViT）[5] をベースとした特徴抽出器を用いることで，離れた虹彩模様の特徴をモデル化できることを示し，Wei ら [6] は，局所特徴

[1] 電気通信大学大学院
The University of Electro-Communications
[2] 日本電気株式会社バイオメトリクス研究所
NEC Corporation
[a)] keita.maihara@uec.ac.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

が失われた画像においても大域特徴を抽出することで認証精度を向上できることを示している．しかし，これらの手法は大規模な訓練データを必要とする Transformer をアーキテクチャとして用いるものが中心であり，Transformer が主に適用されている近赤外虹彩認証と比べて本研究が対象とする可視光虹彩認証ではデータセット規模が小さく学習が難しい．また，Global Average Pooling（GAP）によって特徴マップ全体から大域的な情報を扱える SE[7] や CBAM[8]，ECA[9] といったモジュールを CNN に挿入する手法も用いられているが，得られるのは各チャネルにおける空間方向の平均であり，大域特徴を抽出するものではない．小さな訓練データでも学習が可能な CNN をバックボーンとしたまま，その中間層に ViT で用いられる Self-Attention をモジュールとして挿入することも考えられるが，すべての画素どうしの関係を個別に学習するためパラメータの自由度が高く過学習が懸念される．汎化性を損なわずに大域特徴を抽出する手法が求められる．

本稿では可視光虹彩認証において，汎化性を確保しながら大域特徴を抽出する手法を提案する．本稿の貢献は以下の通りである．

- CNN である DenseNet169 の中間層に Global Reasoning Unit（GloRe）[10] を挿入する手法を提案する．GloRe は中間層の特徴マップを少数のノードに集約したうえで，大域特徴を抽出する．ノード集約によりパラメータの自由度を制限するため，データセット規模が比較的小さい可視光虹彩認証においても，過学習を招くことなく大域特徴を抽出することができる．
- 可視光虹彩認証の研究において広く用いられている UBIRIS.v2[11] を用いた評価により，提案手法が CNN に挿入される既存のモジュールよりも高い認証精度を達成し，かつ過学習が抑えられていることを定量的に示す．PolyU データセットを用いた評価により，他のデータセットでも認証精度を改善できることを示す．

2. 関連研究

2.1 虹彩認証における局所特徴の利用

虹彩認証では虹彩の微細な模様が個人性を持つため，畳み込みによって局所特徴を抽出する，一般画像認識の分野で提案された CNN を特徴抽出器として用いる手法が広く採用されている．Hafner ら [14] は，DenseNet[15] と ResNet[16] の比較から DenseNet の方が高い精度を示すことを報告している．また，Ebrahimpour[17] は MobileNet[18] を，Hsiao ら [19] は EfficientNet[20] を，Zhao ら [21] は CapsNet[22] を用いており，Zhang ら [23] は Maxout ユニットを用いた軽量な CNN である MaxoutCNN を提案している．可視光虹彩認証でも，Zanlorensi ら [24] は ResNet と VGG[25] を，Prasanth ら [26] は DenseNet および InceptionV3[27] を，Lozej ら [28] は Xception[29] を用いている．

2.2 虹彩認証における大域特徴の利用

前節の手法はいずれも局所特徴を抽出するものであるが，虹彩認証では大域特徴を抽出して認証精度を向上させる試みも行われている．近赤外虹彩認証では，Sun ら [4] が，CNN では抽出できない大域特徴を抽出するために，ViT をベースとした特徴抽出器を用いる手法を提案している．Wei ら [6] は，CNN をベースとした局所特徴を抽出するブランチと ViT をベースとした大域特徴を抽出するブランチを組み合わせた手法を提案し，局所特徴が消えた画像において大域特徴を抽出することで認証精度を向上できることを示している．また，Gao ら [30] は Swin Transformer[31] を，可視光虹彩認証においては Latif ら [32] が ViT を，それぞれ特徴抽出に用いている．また，Zola ら [33] は，可視光虹彩画像をグラフとして表現し，Graph Siamese Neural Network で学習する手法を提案しているが，2 層のグラフ畳み込みのみで構成されるため，k 近傍法に基づく手法よりも精度が低い．

また，虹彩認証において CNN に挿入されるモジュールとしては SE[7]，CBAM[8]，ECA[9] が用いられており [34], [35], [36]，これらはチャネル方向の重み付けを行うが，GAP を含むため特徴マップ全体にわたる大域的な情報を扱うことはできる．ただし，得られるのは各チャネルにおける空間方向の平均であり，大域特徴，すなわち複数の領域の特徴どうしの関係を表すものではない．

2.3 一般画像認識において提案されたネットワーク

虹彩認証での使用実績はないものの一般画像認識において良好な性能を示している ResNet を拡張した ResNeXt[37] と WideResNet[38]，MetaFormer 構造を取り入れた RepViT[39] と PoolFormer[40]，画像のパッチをノードとするグラフとして表現しグラフ畳み込みによって特徴を更新する Vision GNN[41] も本稿では比較する．

2.4 グラフに基づく関係推論

一般画像認識の分野では，畳み込みのみでは大域特徴を十分に抽出できない問題を解消するため，CNN の中間層に挿入することで大域特徴を抽出できるモジュールも提案されており，Chen ら [10] は特徴マップを少数のノードから成るグラフ空間へ射影し，グラフ畳み込みによってノード間の関係推論を行った後に座標空間へ逆射影する Global Reasoning Unit（GloRe）を提案した．

2.5 可視光虹彩認証における課題

2.1 節で述べた通り，虹彩認証では局所特徴を抽出する CNN が有効である一方，畳み込みは局所的な演算であるため大域特徴を抽出できず，識別に利用できる情報を取りこぼしている可能性がある．実際に 2.2 節で述べた通り，虹彩認証では大域特徴を抽出することで認証精度を向上で

© 2026 Information Processing Society of Japan

きることが示されている．

しかし，その抽出を目的とした手法は訓練データを多く要する Transformer を用いるものが中心であり，本稿が対象とするデータセット規模の小さい可視光虹彩認証では学習が困難である．画像をグラフとして表現する手法 [33] も，畳み込みを含まないため局所特徴を利用できない．

また，虹彩認証で用いられてきた CNN ベースの手法は，GAP によって大域的な情報を扱える SE や ECA，CBAM の挿入にとどまり，得られるのは各チャネルの平均であるため，大域特徴を抽出するものではない．以上のことから，可視光虹彩認証において精度を向上させるためには，CNN をバックボーンとしたまま大域特徴を抽出する必要があるといえる．

2.2 節で述べたように，CNN の中間層にモジュールを挿入するアプローチの一つとして，ViT で用いられる Self-Attention[42] を組み込むことが挙げられる．これは特徴マップ上のすべての位置どうしの類似度を計算し，その重みに基づいて特徴を集約する機構であり，畳み込みによる局所特徴の抽出を保持したまま大域特徴を抽出できる一方，すべての画素どうしの関係を個別に学習するためパラメータの自由度が高く，訓練データが限られる可視光虹彩認証においては過学習が懸念される．特に生体認証では，登録される人物が学習時に現れないクラスであることが一般的であり，訓練クラスへの過学習は未知のクラスに対する識別性の低下に直結する．したがって，可視光虹彩認証では汎化性を確保しながら大域特徴を抽出する手法が求められる．

3. 提案手法

2.5 節で述べた課題点を踏まえて，本稿では CNN をバックボーンとしたまま，グラフベースの関係推論によって大域特徴を抽出する手法を提案する．提案手法のポイントは次の通りである．

- バックボーンに CNN である DenseNet169[15] を用いる．これにより，データセット規模の小さい可視光虹彩認証においても学習が可能であり，虹彩の微細な模様を捉える局所特徴を利用できる．
- バックボーンの中間層に，グラフベースの関係推論モジュールである GloRe [10] を挿入する．GloRe は特徴マップを少数のノードへ集約したうえで関係を推論するため，パラメータの自由度を過度に高めることなく過学習を抑えながら汎化性を確保し，大域特徴を抽出できる．

3.1 アーキテクチャ

提案手法の構成を**図 1**(a) に示す．虹彩画像を入力とし，DenseNet169 で特徴を抽出したのち，GAP と全結合層により 256 次元の特徴ベクトルを出力する．バックボーンに用いる DenseNet は，各層の出力を後続のすべての層へ連結する構造を持ち，浅い層で得られた局所的なテクスチャを深い層まで保持できるため，微細な模様が個人性を担う虹彩認証に適していると考えられる．実際に 5.1 節に示す通り，UBIRIS.v2 に対して複数のネットワークを同一条件で比較したところ，認証精度の評価指標である等価エラー率（equal error rate，EER）が最も良かったものは DenseNet169 であり，本手法ではこれを採用する．

GloRe は，予備実験に基づき Dense Block 3 内の奇数番目の Dense Layer の直後に挿入する．特徴マップの高さを H，幅を W とすると，Self-Attention が HW 個の位置どうしの関係を個別に学習するのに対し，GloRe は複数の位置を N 個のノードへ圧縮したうえで，ノードどうしの関係を学習する．関係の推論が圧縮されたノードの上で行われるためパラメータの自由度を過度に高めずに済み，過学習を抑えて汎化性を確保できる一方，ノードは特徴マップ全体から集約されるため，大域特徴を抽出することができる．

3.2 GloRe による関係推論

GloRe の構造を図 1(b) に示す．GloRe は，座標空間の特徴をグラフ空間のノードへまとめる集約，ノードどうしの関係推論，座標空間への逆射影の 3 つの処理から成る．入力の特徴マップを $X \in \mathbb{R}^{L \times C}$ とする．ここで C はチャネル数，$L = H \times W$ は空間上の位置の数である．

図 1(b) の集約では，座標空間の特徴を N 個のノードから成るグラフ空間へ射影する．i 番目のノードの特徴 v_i は，式 (1) に示すように特徴マップ上のすべての位置の重み付き和として与えられる．

$$v_i = b_i X = \sum_{\forall j} b_{ij} x_j \tag{1}$$

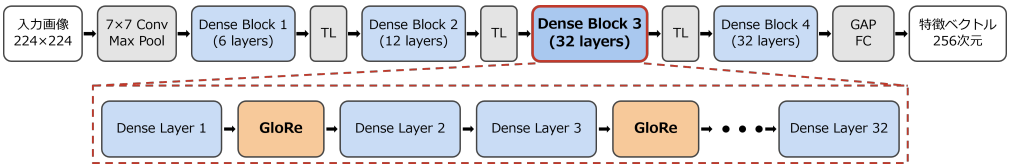
ここで x_j は特徴マップの j 番目の位置の特徴，$B = [b_1, \cdots, b_N] \in \mathbb{R}^{N \times L}$ は学習可能な射影の重みである．各ノードの特徴を並べた行列を $V = [v_1, \cdots, v_N]^\top \in \mathbb{R}^{N \times C'}$ とし，C' はグラフ空間におけるノードの状態の次元である．

図 1(b) の関係推論では，得られた N 個のノードを全結合グラフとみなし，式 (2) のグラフ畳み込みによってノード間の関係を推論する．

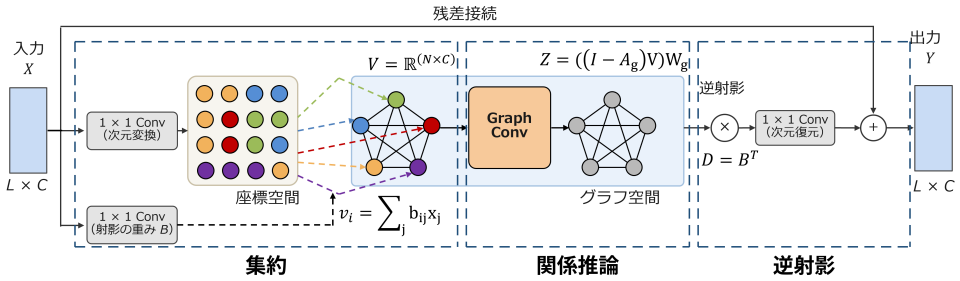
$$Z = GVW_g = ((I - A_g)V)W_g \tag{2}$$

ここで $Z \in \mathbb{R}^{N \times C'}$ は関係推論を行った後のノードの特徴，G および $A_g \in \mathbb{R}^{N \times N}$ はノード間で情報を伝播させる隣接行列，$W_g \in \mathbb{R}^{C' \times C'}$ はノードの状態を更新する重み，I は学習を安定させるショートカットとして働く恒等行列である．A_g は W_g とともに学習されるためノード間の関連はデータから獲得され，ノードは特徴マップ全体から集約されているため，このグラフ畳み込みによって離れた領域の特徴どうしの関係が推論される．

© 2026 Information Processing Society of Japan



(a) ネットワーク全体の構成



(b) GloRe の構造

図 1　提案手法のネットワーク構成

Fig. 1　Network architecture of the proposed method. (a) Overall architecture. (b) Structure of the Global Reasoning Unit.

図 1(b) の逆射影では，更新されたノードの特徴を $D = B^{\top}$ により座標空間へ戻し，次元を入力と揃える畳み込み層を適用したうえで入力 X に加算する．

4.　実験の方法

提案手法が高い認証精度を達成し，かつ過学習が抑えられていることを示すため，既存手法との EER の比較に加えて，識別性の指標である d' の比較を行う．

4.1　データセット

本実験には，可視光虹彩認証で広く利用されている UBIRIS.v2[11] と，PolyU データセット [12], [13] を用いた．UBIRIS.v2 は，可視光カメラを用いて非理想的な環境で撮影されたデータセットであり，261 人分の虹彩画像 11,101 枚を 400 × 300 画素で含み，照明や視線の方向，眼鏡の有無などの違いを持つ．クラス数を増やすために左右の虹彩画像を別のクラスとして扱い，枚数の偏りをなくすために各クラスから 11 枚をランダムに選出した．クラスを 8:2 に分割して訓練セットとテストセットとし，さらに訓練セットのクラスを 8:2 に分割して訓練セットと検証セットとしたため，各セットにおけるクラスの重なりはない．この結果，訓練セットは 328 クラス 3,608 枚，検証セットは 83 クラス 913 枚，テストセットは 103 クラス 1,133 枚となった．なお，分割および画像の選出はシード値によって制御した．

PolyU データセット [12], [13] は，近赤外画像と可視光画像を同時に撮影したデータセットであり，209 人の被験者から左右の虹彩をそれぞれ 15 枚ずつ撮影した画像を 640 × 480 画素で含み，専用の撮影装置を用いて撮影されているため非理想的な環境で撮影された UBIRIS.v2 と比べて虹彩領域の鏡面反射や視線のずれ，ブレの影響が小さい．本実験では，このうち可視光画像を用いた．UBIRIS.v2 と同様に，クラス数を増やすために左右の虹彩画像を別のクラスとして扱い，同じ比率でクラスを分割して，訓練セット 250 クラス，検証セット 63 クラス，テストセット 79 クラスとした．ただし，実験に使用する画像枚数を確保するため各クラスの枚数は揃えていない．そのため，各セットの画像枚数はシード値によって変動し，訓練セットが約 3,280 枚，検証セットが約 800 枚，テストセットが約 1,020 枚である．

4.2　前処理

いずれのデータセットについても，虹彩画像に対して同様の前処理を行った．まず，IrisParseNet[43] を用いて虹彩の中心座標と虹彩直径を取得した．このとき，UBIRIS.v2 の一部で学習済みのモデルにより全画像の虹彩推定を行った後に手作業で微調整を行い，虹彩が髪に隠れている，目を閉じているなどの理由で実験に使用できないと判断した画像を除外した．次に，Bicubic 補間により虹彩直径が 192 画素になるよう正規化し，虹彩の中心座標を中心に 224 × 224 画素の大きさで画像を切り抜いた．

4.3　比較手法

比較手法は 2 つの群から成る．1 つ目は，特徴抽出器として用いるネットワークが異なる手法であり，計 27 種類を選定した．虹彩認証で使用されている ResNet，DenseNet，VGG，MobileNet，EfficientNet，Swin Transformer，CapsNet，MaxoutCNN，InceptionV3，Xception，Vision Transformer，および虹彩認証での使用実績はないものの一般画像認識において良好な性能を示す ResNeXt，WideResNet，

© 2026 Information Processing Society of Japan

RepViT，PoolFormer，Vision GNN を対象とした．

2 つ目は，DenseNet169 にモジュールを挿入した手法であり，2.2 節で述べた虹彩認証で使用されているモジュールである SE，CBAM，ECA と 2.5 節で述べた Self-Attention を対象とする．いずれのモジュールも提案手法と同じ位置に同じ個数だけ挿入し，比較する対象がモジュールの違いのみとなるようにした．また，モジュールを挿入しない DenseNet169 を Baseline とする．なお，Self-Attention は大域特徴を抽出することのできる機構として本稿で検証したものであり，挿入位置の特徴マップの各位置をトークンとみなし計算した．今回適用する層ではトークンの次元が 32 と小さく，ヘッドを分割すると性能が低下する可能性があるため，ヘッド数が 4 の Multi Head Self Attention（MHSA）に加えて，ヘッド数が 1 の Single Head Self Attention（SHSA）も対象とした．

4.4 学習方法

提案手法に用いる GloRe は，予備実験の結果に基づきノード数を $N = 128$，ノードの状態の次元を $C' = 256$ とした．損失関数は softmax と cross entropy loss，特徴ベクトルの次元数は 256，バッチサイズは 32 とした．重みは畳み込み層を He[44]，全結合層を Xavier[45] の初期値で，Transformer の position embedding と class token を標準正規分布で初期化し，データ拡張として Random Rotation，Random Affine，Color Jitter を適用した．

最適化手法は，予備実験の結果に基づきデータセットおよびアーキテクチャごとに設定した．重み減衰はいずれも 0.0005 とし，モーメンタム付き SGD のモーメンタム係数は 0.9，AdamW の β_1，β_2 はそれぞれ 0.9，0.99 とした．UBIRIS.v2 では，CNN および GNN にモーメンタム付き SGD（学習率 = 0.01）を，Transformer に AdamW（学習率 = 0.0001）を用いた．PolyU では，CNN に AdamW（学習率 = 0.01），GNN に AdamW（学習率 = 0.001）を用い，Transformer は変更していない．ただし，VGG は学習率 = 0.01 では収束しなかったため，0.001 とした．提案手法およびモジュールを挿入した手法には，各データセットにおいて CNN と同じ設定を用いた．学習率は最初の 2,000 イテレーションで線形に Warmup し，検証セットの EER が 20,000 イテレーション改善しない場合に 0.1 倍，さらに 10,000 イテレーション改善しない場合は早期停止した．

4.5 評価方法

実験の全体フローを**図 2** に示す．青色で示したネットワーク部（特徴抽出器）を変更して評価を行い，学習時には訓練画像を入力して分類損失により特徴抽出器を学習する．検証・テスト時には，認証において想定される登録画像とテスト画像の組を同一の特徴抽出器に入力し，特徴ベクトル間のコサイン類似度をマッチングスコアとして照合する．認証精度の評価指標には，他人受入率と本人拒否率が等しくなる EER を用いた．学習した特徴抽出器により各セットから特徴ベクトルを抽出し，セット内の全ペアを登録画像とテスト画像の組とみなして EER を算出した．テストセットの評価には検証セットの EER が最も改善したイテレーションのモデルを用いた．UBIRIS.v2 では，学習結果の安定性を調査するため，各ネットワークに対して異なるシード値を用いて 10 回の学習を行い，得られた EER の平均と，そのばらつきを表す標準偏差を示す．なお，4.5.2 節で述べる d' については 10 回の学習の平均を示す．また，別のデータセットにおいても EER を改善できるかを確認するため，PolyU データセットについても 27 種類のネットワークとの比較に限り 2 シード分の学習を行い，平均値を示す．以上の条件のもとで，本稿では提案手法に対して先行研究との比較，汎化性の評価，提案手法が認証に成功した画像の分析の 3 つの評価を行った．

4.5.1 先行研究との比較

4.3 節で述べた 2 群の比較手法と提案手法について，テストセットに対する EER を比較する．1 群目との比較により既存のネットワークとの優劣を，2 群目との比較によりバックボーンと挿入位置を揃えた条件での機構の違いの影響を明らかにする．結果は 5.1 節に示す．

4.5.2 パラメータの自由度の違いが汎化性に与える影響の評価

汎化性が損なわれていないかを調べるため，訓練に用いたクラスと未知のクラスに対する識別性の差を比較する．訓練セットに対する EER はすべての手法で約 0%に到達し訓練データへの当てはまりの強さを比較できないため，識別性の指標には Daugman[46] が虹彩認証において用いた式 (3) の d' を用いる．ここで，μ_{gen}，σ^2_{gen} は本人ペア，μ_{imp}，σ^2_{imp} は他人ペアのスコアの平均と分散である．

$$d' = \frac{\mu_{\mathrm{gen}} - \mu_{\mathrm{imp}}}{\sqrt{(\sigma^2_{\mathrm{gen}} + \sigma^2_{\mathrm{imp}})/2}} \tag{3}$$

訓練セットに対する d' が大きくテストセットに対する d' が小さい場合には，訓練データへの過度な適合が生じていると解釈できる．結果は 5.2 節に示す．

4.5.3 提案手法が認証に成功した画像の分析

提案手法がどのような画像で認証に寄与しているかを調べるため，UBIRIS.v2 において Baseline では本人拒否となり，提案手法では正しく本人と判定された本人ペアの画像を確認する．結果は 5.3 節に示す．

5. 実験の結果と考察

本章では，4.5 節で述べた 3 つの評価の結果を示す．5.1 節では比較手法との EER の比較により提案手法が既存のネットワークおよびモジュールよりも高い認証精度を達成できることを，5.2 節では，2.5 節で述べた通り過学習が懸

© 2026 Information Processing Society of Japan

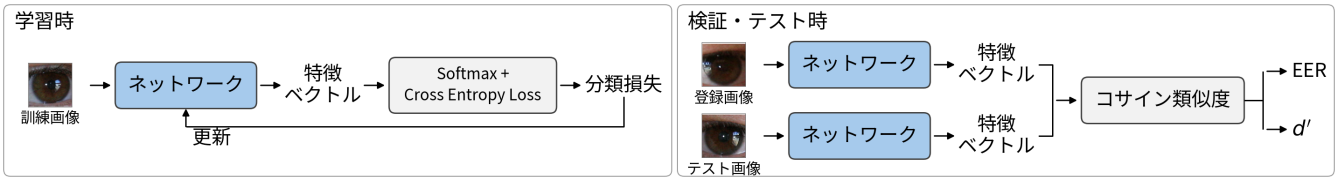


図 2　実験の全体フロー
Fig. 2　Overall flow of the experiments.

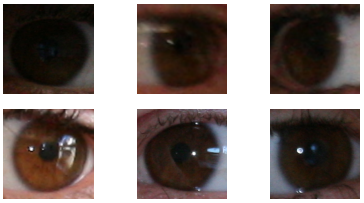
念されるのが大域特徴を抽出する機構であることから，同じく大域特徴を抽出する Self-Attention との d' の比較により大域特徴の抽出によって汎化性が損なわれていないことを，5.3 節では提案手法がどのような画像において認証精度の改善に寄与しているかを，それぞれ示す．

5.1　先行研究との比較

まず，**表 1** に，特徴抽出器として用いるネットワークが異なる手法との EER の比較を示す．提案手法は UBIRIS.v2 において EER=2.90%と 27 種類のいずれのネットワークよりも EER が改善し，その中で最も EER が改善した DenseNet169 から 0.47 ポイント改善した．PolyU においても，提案手法は EER=1.72%と最も EER が改善した．

アーキテクチャごとに見ると，Transformer 系は最も EER が改善した Swin Transformer でも 6.54%と CNN 系の多くより EER が悪化した．Self-Attention によって大域特徴を抽出できる点では有利であるにもかかわらず CNN 系より EER が悪化したのは，Transformer が学習に大規模なデータセットを必要とする [5] ため，UBIRIS.v2 や PolyU の規模では十分に学習できなかったためであると考えられる．また，Vision GNN は PolyU において EER=1.82%と提案手法に次いで EER が改善しており，グラフによる特徴抽出が認証精度の改善に寄与することを示唆している．一方で UBIRIS.v2 では 4.16%と多くの CNN 系より EER が悪化した．これは，Vision GNN では数層の CNN を用いてグラフノードを生成しており，虹彩領域の鏡面反射や視線のずれ，ブレを含む画像ではノードが安定しないためであると考えられる．提案手法では，DenseNet の中間層まで計算した受容野の広い特徴からノードを生成するため，UBIRIS.v2 においても EER が改善したと考えられる．

次に，**表 2** に，DenseNet169 に各モジュールを挿入した場合の EER を示す．提案手法は比較したすべての手法の中で最も EER が改善し，虹彩認証で使用されているモジュールのうち最も EER が改善した ECA から 0.29 ポイント改善した．また，提案手法で用いる GloRe や Self-Attention を用いる手法（SHSA，MHSA）は，GAP によって特徴マップを集約する手法（SE，ECA，CBAM）よりも EER が改善する傾向にあり，可視光虹彩認証においては特徴マップ全体を集約するだけではなく大域特徴を抽出することが認証精度の改善に寄与すると考えられる．



(a) 被験者 A　(b) 被験者 B　(c) 被験者 C
図 3　Baseline が拒否し提案手法が受け入れた本人ペアの例
Fig. 3　Examples of genuine pairs falsely rejected by the baseline and accepted by the proposed method.

5.2　パラメータの自由度の違いが汎化性に与える影響

4.5.2 節で述べた d' による比較の結果を表 2 に示す．提案手法は，訓練セットに対する d' が 5.48 と Self-Attention を用いる手法よりも小さい，すなわち訓練データへの当てはまりが弱いにもかかわらず，テストセットに対する d' は 3.95 と比較した手法の中で最も大きい値を示した．これは提案手法で用いる GloRe の導入によって過学習が生じていないことを示しており，領域単位に集約されたノードの上で関係を推論することでパラメータの自由度が抑えられたことが汎化性の確保に寄与していると考えられる．

これに対し SHSA は，訓練セットに対する d' が 5.62 と最も大きい一方でテストセットに対する d' は 3.91 と提案手法より識別性が低く，すべての位置どうしの関係を個別に学習する Self-Attention では訓練データへの過学習が進みやすいためであると考えられる．

5.3　提案手法が認証に成功した画像の分析

4.5.3 節で述べた比較の結果として，**図 3** に，UBIRIS.v2 において Baseline では本人拒否となり，提案手法では正しく本人と判定された本人ペアの例を示す．各列は異なる被験者の，上下 2 枚を照合した 1 つのペアを表す．上段の画像はいずれも暗さやブレ，視線方向によって虹彩の模様が不明瞭で局所特徴が乏しいが，提案手法は大域特徴を抽出することで識別的な特徴を獲得していると考えられる．

6.　まとめ

本稿では，可視光虹彩認証において汎化性を損なわずに大域特徴を抽出するために，DenseNet169 に GloRe を挿入する手法を提案した．評価実験の結果，提案手法は UBIRIS.v2 において EER=2.90%を達成し，PolyU データ

© 2026 Information Processing Society of Japan

表 1　ネットワークごとの EER の比較
Table 1　Comparison of EER by network.

	EER [%]			EER [%]	
ネットワーク	UBIRIS.v2	PolyU	ネットワーク	UBIRIS.v2	PolyU
提案手法	**2.90 ± 0.49**	**1.72**	Vision GNN[41]	4.16 ± 0.50	1.82
DenseNet169[15]	3.37 ± 0.36	2.16	EfficientNet-B0[20]	4.20 ± 0.61	2.02
DenseNet201[15]	3.46 ± 0.43	2.02	InceptionV3[27]	4.46 ± 0.51	2.43
DenseNet121[15]	3.48 ± 0.48	1.89	MobileNetV3-Small[47]	4.75 ± 0.57	2.50
ResNeXt50[37]	3.49 ± 0.39	2.61	VGG13[25]	5.45 ± 0.58	3.84
MobileNetV2[18]	3.53 ± 0.39	2.08	VGG11[25]	5.49 ± 0.76	3.59
WideResNet50[38]	3.57 ± 0.45	2.25	VGG16[25]	5.52 ± 0.51	4.15
Xception[29]	3.65 ± 0.44	1.98	RepViT[39]	5.56 ± 0.59	2.00
ResNet50[16]	3.65 ± 0.44	2.56	VGG19[25]	6.13 ± 0.55	4.46
ResNet18[16]	3.74 ± 0.41	2.14	Swin Transformer[31]	6.54 ± 0.59	2.12
ResNet34[16]	3.85 ± 0.52	2.56	MaxoutCNN[23]	6.64 ± 0.63	3.23
ResNet101[16]	3.92 ± 0.37	2.71	CapsNet[22]	6.75 ± 0.94	3.28
ResNet152[16]	3.94 ± 0.46	2.37	PoolFormer[40]	7.64 ± 0.77	2.82
MobileNetV3-Large[47]	4.03 ± 0.57	2.61	Vision Transformer[5]	10.03 ± 0.68	2.58

表 2　モジュールごとの比較
Table 2　Comparison by module.

手法	テスト EER [%]	訓練 d'	テスト d'
提案手法	**2.90 ± 0.49**	5.48	**3.95**
SHSA	3.11 ± 0.58	5.62	3.91
MHSA	3.18 ± 0.42	5.53	3.88
ECA[9]	3.19 ± 0.47	5.52	3.87
SE[7]	3.27 ± 0.49	5.53	3.81
Baseline	3.37 ± 0.36	5.46	3.77
CBAM[8]	3.53 ± 0.31	5.44	3.75

セットとあわせていずれも比較手法の中で最も EER が改善した．また，d' の比較により Self-Attention を用いる手法よりも過学習を招くことなく汎化性を確保しながら大域特徴を抽出できていることを示した．今後の課題としてノード数やノードの状態の次元数の検討があげられる．

参考文献

[1] 一般社団法人日本自動認識システム協会：よくわかる生体認証，オーム社 (2019)．

[2] Zhao, Z., Kumar, A.: Towards More Accurate Iris Recognition Using Deeply Learned Spatially Corresponding Features, IEEE International Conference on Computer Vision, pp. 3809–3818 (2017).

[3] Yang, K., Xu, Z., Fei, J.: DualSANet: Dual Spatial Attention Network for Iris Recognition, IEEE/CVF Winter Conference on Applications of Computer Vision, pp. 889–897 (2021).

[4] Sun, X., Wang, C., Wang, Y., Wei, J., Sun, Z.: IrisFormer: A Dedicated Transformer Framework for Iris Recognition, IEEE Signal Processing Letters, Vol. 32, pp. 431–435 (2025).

[5] Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J., Houlsby, N.: An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale, International Conference on Learning Representations (2021).

[6] Wei, J., Wang, Y., Huang, H., He, R., Sun, Z., Gao, X.: Contextual Measures for Iris Recognition, IEEE Transactions on Information Forensics and Security, Vol. 18, pp. 57–70 (2023).

[7] Hu, J., Shen, L., Sun, G.: Squeeze-and-Excitation Networks, IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 7132–7141 (2018).

[8] Woo, S., Park, J., Lee, J. Y., Kweon, I. S.: CBAM: Convolutional Block Attention Module, European Conference on Computer Vision, pp. 3–19 (2018).

[9] Wang, Q., Wu, B., Zhu, P., Li, P., Zuo, W., Hu, Q.: ECA-Net: Efficient Channel Attention for Deep Convolutional Neural Networks, IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 11534–11542 (2020).

[10] Chen, Y., Rohrbach, M., Yan, Z., Yan, S., Feng, J., Kalantidis, Y.: Graph-Based Global Reasoning Networks, IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 433–442 (2019).

[11] Proença, H., Filipe, S., Santos, R., Oliveira, J., Alexandre, L. A.: The UBIRIS.v2: A Database of Visible Wavelength Iris Images Captured On-the-Move and At-a-Distance, IEEE Transactions on Pattern Analysis and Machine Intelligence, Vol. 32, No. 8, pp. 1529–1535 (2010).

[12] Ramaiah, N. P., Kumar, A.: Towards More Accurate Iris Recognition Using Cross-Spectral Matching, IEEE Transactions on Image Processing, Vol. 26, No. 1, pp. 208–221 (2017).

[13] The Hong Kong Polytechnic University: PolyU Cross-Spectral Iris Image Database, available from ⟨`http://www4.comp.polyu.edu.hk/~csajaykr/polyuiris.htm`⟩.

[14] Hafner, A., Peer, P., Emeršič, Ž., Vitek, M.: Deep Iris Feature Extraction, International Conference on Artificial Intelligence in Information and Communication, pp. 258–262 (2021).

[15] Huang, G., Liu, Z., van der Maaten, L., Weinberger, K. Q.: Densely Connected Convolutional Networks, IEEE Conference on Computer Vision and Pattern Recognition, pp. 4700–4708 (2017).

© 2026 Information Processing Society of Japan

[16] He, K., Zhang, X., Ren, S., Sun, J.: Deep Residual Learning for Image Recognition, IEEE Conference on Computer Vision and Pattern Recognition, pp. 770–778 (2016).
[17] Ebrahimpour, N.: Iris Recognition Using MobileNet for Biometric Authentication, International Zeugma Conference on Scientific Research, pp. 583–588 (2023).
[18] Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., Chen, L.-C.: MobileNetV2: Inverted Residuals and Linear Bottlenecks, IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 4510–4520 (2018).
[19] Hsiao, C.-S., Fan, C.-P., Hwang, Y.-T.: Design and Analysis of Deep-Learning Based Iris Recognition Technologies by Combination of U-Net and EfficientNet, International Conference on Information and Education Technology, pp. 433–437 (2021).
[20] Tan, M., Le, Q.: EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks, International Conference on Machine Learning, pp. 6105–6114 (2019).
[21] Zhao, T., Liu, Y., Huo, G., Zhu, X.: A Deep Learning Iris Recognition Method Based on Capsule Network Architecture, IEEE Access, Vol. 7, pp. 49691–49701 (2019).
[22] Sabour, S., Frosst, N., Hinton, G. E.: Dynamic Routing Between Capsules, Advances in Neural Information Processing Systems, Vol. 30, pp. 3856–3866 (2017).
[23] Zhang, Q., Li, H., Sun, Z., Tan, T.: Deep Feature Fusion for Iris and Periocular Biometrics on Mobile Devices, IEEE Transactions on Information Forensics and Security, Vol. 13, No. 11, pp. 2897–2912 (2018).
[24] Zanlorensi, L. A., Luz, E., Laroca, R., Britto, A. S., Oliveira, L. S., Menotti, D.: The Impact of Preprocessing on Deep Representations for Iris Recognition on Unconstrained Environments, SIBGRAPI Conference on Graphics, Patterns and Images, pp. 289–296 (2018).
[25] Simonyan, K., Zisserman, A.: Very Deep Convolutional Networks for Large-Scale Image Recognition, International Conference on Learning Representations (2015).
[26] Prasanth, N., Sai Kiran, C. U., Nethi, S., Ketineni, T., Srinivasu, N., Pradeepini, G.: Fusion of Iris and Periocular Biometrics Authentication Using CNN, International Conference on Computing Methodologies and Communication, pp. 378–382 (2023).
[27] Szegedy, C., Vanhoucke, V., Ioffe, S., Shlens, J., Wojna, Z.: Rethinking the Inception Architecture for Computer Vision, IEEE Conference on Computer Vision and Pattern Recognition, pp. 2818–2826 (2016).
[28] Lozej, J., Štepec, D., Štruc, V., Peer, P.: Influence of Segmentation on Deep Iris Recognition Performance, International Workshop on Biometrics and Forensics, pp. 1–6 (2019).
[29] Chollet, F.: Xception: Deep Learning with Depthwise Separable Convolutions, IEEE Conference on Computer Vision and Pattern Recognition, pp. 1800–1807 (2017).
[30] Gao, R., Bourlai, T.: On Designing a SwinIris Transformer Based Iris Recognition System, IEEE Access, Vol. 12, pp. 30723–30737 (2024).
[31] Liu, Z., Lin, Y., Cao, Y., Hu, H., Wei, Y., Zhang, Z., Lin, S., Guo, B.: Swin Transformer: Hierarchical Vision Transformer Using Shifted Windows, IEEE/CVF International Conference on Computer Vision, pp. 9992–10002 (2021).
[32] Latif, S. A., Sidek, K. A., Hashim, A. H. A.: An Efficient Iris Recognition Technique Using CNN and Vision Transformer, Journal of Advanced Research in Applied Sciences and Engineering Technology, Vol. 34, No. 2, pp. 235–245 (2023).
[33] Zola, F., Fernandez-Carrasco, J. A., Bruse, J. L., Galar, M., Geradts, Z.: Verification System Based on Long-Range Iris and Graph Siamese Neural Networks, European Symposium on Software Engineering, pp. 80–88 (2022).
[34] Kawakami, S., Kawai, H., Ito, K., Aoki, T., Yasumura, Y., Fujio, M., Kaga, Y., Takahashi, K.: A Simple and Accurate CNN for Iris Recognition, Asia-Pacific Signal and Information Processing Association Annual Summit and Conference, pp. 1566–1571 (2022).
[35] Pang, Y., Wang, Z., Jiang, N., Qin, J., Li, S.: CBAM-DenseNet with Multi-Feature Quality Filtering: Advancing Accuracy in Small-Sample Iris Recognition, Frontiers in Artificial Intelligence, Vol. 8, 1714882 (2026).
[36] Wu, W., Chen, Y., Zeng, Z.: Non-segmentation and Deep-Learning Frameworks for Iris Recognition, Chinese Conference on Biometric Recognition, Lecture Notes in Computer Science, Vol. 12878, pp. 325–334 (2021).
[37] Xie, S., Girshick, R., Dollár, P., Tu, Z., He, K.: Aggregated Residual Transformations for Deep Neural Networks, IEEE Conference on Computer Vision and Pattern Recognition, pp. 5987–5995 (2017).
[38] Zagoruyko, S., Komodakis, N.: Wide Residual Networks, British Machine Vision Conference, pp. 87.1–87.12 (2016).
[39] Wang, A., Chen, H., Lin, Z., Han, J., Ding, G.: RepViT: Revisiting Mobile CNN From ViT Perspective, IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 15909–15920 (2024).
[40] Yu, W., Luo, M., Zhou, P., Si, C., Zhou, Y., Wang, X., Feng, J., Yan, S.: MetaFormer Is Actually What You Need for Vision, IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 10809–10819 (2022).
[41] Han, K., Wang, Y., Guo, J., Tang, Y., Wu, E.: Vision GNN: An Image Is Worth Graph of Nodes, Advances in Neural Information Processing Systems, Vol. 35, pp. 8291–8303 (2022).
[42] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., Polosukhin, I.: Attention Is All You Need, Advances in Neural Information Processing Systems, Vol. 30, pp. 5998–6008 (2017).
[43] Wang, C., Muhammad, J., Wang, Y., He, Z., Sun, Z.: Towards Complete and Accurate Iris Segmentation Using Deep Multi-Task Attention Network for Non-Cooperative Iris Recognition, IEEE Transactions on Information Forensics and Security, Vol. 15, pp. 2944–2959 (2020).
[44] He, K., Zhang, X., Ren, S., Sun, J.: Delving Deep into Rectifiers: Surpassing Human-Level Performance on ImageNet Classification, IEEE International Conference on Computer Vision, pp. 1026–1034 (2015).
[45] Glorot, X., Bengio, Y.: Understanding the Difficulty of Training Deep Feedforward Neural Networks, International Conference on Artificial Intelligence and Statistics, Vol. 9, pp. 249–256 (2010).
[46] Daugman, J.: How Iris Recognition Works, IEEE Transactions on Circuits and Systems for Video Technology, Vol. 14, No. 1, pp. 21–30 (2004).
[47] Howard, A., Sandler, M., Chen, B., Wang, W., Chen, L.-C., Tan, M., Chu, G., Vasudevan, V., Zhu, Y., Pang, R., Adam, H., Le, Q.: Searching for MobileNetV3, IEEE/CVF International Conference on Computer Vision, pp. 1314–1324 (2019).

© 2026 Information Processing Society of Japan

研究倫理

本稿における研究倫理について研究者同士で議論し，実験手順の正当性について検討を行った．本稿の実験で使用した UBIRIS.v2 データセット [11] は，Proença らによって収集，公開されたオープンな虹彩画像データセットである．使用の際には管理者と連絡を取り，利用許諾を受けてダウンロードした．また，ダウンロードしたデータセットは適切に管理を行い，利用規約を遵守した上で実験に使用した．PolyU データセット [12], [13] は，Ramaiah らによって The Hong Kong Polytechnic University で収集，公開された近赤外および可視光の虹彩画像データセットである．UBIRIS.v2 と同様に，使用の際には管理者と連絡を取り，利用許諾を受けてダウンロードした．また，ダウンロードしたデータセットは適切に管理を行い，利用規約を遵守した上で実験に使用した．したがって，本稿の実験によってプライバシーをはじめとする研究倫理に抵触することはないと考える．

© 2026 Information Processing Society of Japan